



PROPOSAL TUGAS AKHIR - EF234702

EVALUASI FITUR *HANDCRAFTED* DAN MODEL *SPEECH* PRALATIH UNTUK ESTIMASI KEPRIBADIAN *BIG FIVE* BERBASIS AUDIO DENGAN PROTOKOL *STRICT SPLIT* DAN ADAPTASI LoRA

Muhammad Aqil Farrukh

NRP 5025221158

Dosen Pembimbing

Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D

NPP 1987202012004

Dosen Ko-pembimbing

Dini Adni Navastara, S.Kom., M.Sc.

NIP 198510172015042001

Program Studi S-1 Teknik Informatika

Departemen Teknik Informatika

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2025

Halaman ini sengaja dikosongkan

LEMBAR PENGESAHAN
EVALUASI FITUR *HANDCRAFTED* DAN MODEL *SPEECH* PRALATIH
UNTUK ESTIMASI KEPERIBADIAN *BIG FIVE* BERBASIS AUDIO DENGAN
PROTOKOL *STRICT SPLIT* DAN ADAPTASI LoRA

PROPOSAL TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Komputer pada
Program Studi S-1 Teknik Informatika
Departemen Teknik Informatika
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember

Oleh: **Muhammad Aqil Farrukh**

NRP. 5025221158

Disetujui oleh Tim Penguji Proposal Tugas Akhir:

- | | |
|---|---------------|
| 1. Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D | Pembimbing |
| 2. Dini Adni Navastara, S.Kom., M.Sc. | Ko-pembimbing |
| 3. <Nama dan gelar penguji> | Penguji |
| 4. <Nama dan gelar penguji> | Penguji |

SURABAYA

Januari, 2026

Halaman ini sengaja dikosongkan.

APPROVAL SHEET

FINAL EVALUATION OF *HANDCRAFTED FEATURES* AND *PRETRAINED SPEECH* MODELS FOR *AUDIO-ONLY BIG FIVE PERSONALITY* ESTIMATION USING A *STRICT SPLIT* PROTOCOL AND LoRA ADAPTATION

FINAL PROJECT PROPOSAL

Submitted to fulfill one of the requirements
for obtaining a Bachelor of Computer Science degree at
Undergraduate Study Program of Informatics
Department of Informatics
Faculty of Intelligent Electrical and Informatics Technology
Institut Teknologi Sepuluh Nopember

By: **Muhammad Aqil Farrukh**

NRP. 5025221158

Approved by Final Project Proposal Examiner Team:

- | | | |
|----|--|------------|
| 1. | Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D | Advisor |
| 2. | Dini Adni Navastara, S.Kom., M.Sc. | Co-advisor |
| 3. | <Name and title> | Examiner 1 |
| 4. | <Name and title> | Examiner 2 |

SURABAYA

January, 2026

This page is intentionally left blank.

ABSTRAK

EVALUASI FITUR *HANDCRAFTED* DAN MODEL *SPEECH* PRALATIH UNTUK ESTIMASI KEPRIBADIAN *BIG FIVE* BERBASIS AUDIO DENGAN PROTOKOL *STRICT SPLIT* DAN ADAPTASI LoRA

Nama Mahasiswa / NRP : Muhammad Aqil Farrukh / 5025221158
Departemen : Teknik Informatika FTEIC - ITS
Dosen Pembimbing : Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D
Dosen Ko-pembimbing : Dini Adni Navastara, S.Kom., M.Sc.

Abstrak

Pemodelan kepribadian dari kesan pertama umumnya memanfaatkan informasi multimodal, namun pada banyak skenario hanya sinyal suara yang tersedia atau lebih aman digunakan. Karena itu, diperlukan evaluasi representasi suara yang mampu memprediksi lima *trait Big Five* secara andal tanpa teks maupun visual. Dataset yang digunakan adalah *Chalearn First impressions V2* yang memuat klip sekitar 15 detik dengan label *Big Five* pada rentang 0 sampai 1. Audio diekstrak dari video, distandardisasi menjadi 16 kHz mono dengan durasi maksimum 15 detik, lalu dibagi menggunakan protokol *strict split* untuk menjaga pemisahan sumber antar *train*, *validation*, dan *test* sehingga potensi kebocoran informasi dapat ditekan. Dua kelompok representasi dibandingkan, yaitu fitur akustik *handcrafted* eGeMAPS dan *embedding* dari model *speech* pralatih berbasis Transformer seperti wav2vec 2.0, HuBERT, dan WavLM yang digunakan sebagai *frozen feature extractor*. Lima skor *trait* diprediksi menggunakan *head* regresi ringan. Evaluasi dilakukan memakai MAE, RMSE, dan R^2 , serta skor akurasi yang dihitung sebagai $1 - \text{MAE}$ untuk memudahkan interpretasi. Setelah *baseline* terbaik ditentukan, *backbone* terbaik diadaptasi dengan parameter efisien *fine-tuning* melalui LoRA untuk mengukur dampak adaptasi parameter terhadap kinerja.

Kata kunci: *audio-only, apparent personality, Big Five, Chalearn First impressions V2, eGeMAPS, LoRA, strict split, wav2vec 2.0, WavLM.*

Halaman ini sengaja dikosongkan.

ABSTRACT

EVALUATION OF HANDCRAFTED FEATURES AND PRETRAINED SPEECH MODELS FOR AUDIO-ONLY BIG FIVE PERSONALITY ESTIMATION USING A STRICT SPLIT PROTOCOL AND LoRA ADAPTATION

Full Name / Student ID : Muhammad Aqil Farrukh / 5025221158
Department : Informatics ELECTICS - ITS
Advisor : Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D
Co-advisor : Dini Adni Navastara, S.Kom., M.Sc.

Abstract

Apparent personality estimation from first impressions is commonly addressed using multimodal cues, yet in many real-world settings only speech is available or preferable to use due to practicality and privacy considerations. Therefore, it is important to examine which speech representations can reliably predict the Big Five traits without relying on text or visual information. The Chalearn First impressions V2 dataset is used in this work, consisting of short clips of approximately 15 seconds with Big Five labels in the 0 to 1 range. Audio is extracted from videos, standardized to 16 kHz mono with a maximum duration of 15 seconds, and split using a strict split protocol to keep sources disjoint across training, validation, and test sets and thereby reduce potential information leakage. Two representation families are compared: handcrafted acoustic features (eGeMAPS) and embeddings from pretrained Transformer-based speech models such as wav2vec 2.0, HuBERT, and WavLM used as frozen feature extractors. A lightweight regression head predicts the five trait scores. Performance is evaluated using MAE, RMSE, and R^2 , along with an accuracy score defined as 1 minus MAE for interpretability. After selecting the best baseline, the best backbone is further adapted using parameter-efficient fine-tuning with LoRA to assess the impact of model adaptation on performance.

Keywords: audio-only, Big Five, apparent personality, pretrained speech model, eGeMAPS, LoRA, strict split.

This page is intentionally left blank.

DAFTAR ISI

LEMBAR PENGESAHAN.....	i
APPROVAL SHEET	iii
ABSTRAK	v
<i>ABSTRACT</i>	vii
DAFTAR ISI.....	ix
DAFTAR GAMBAR	xi
DAFTAR TABEL	xiii
DAFTAR KODE SUMBER	xv
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah	3
1.4 Tujuan.....	3
1.5 Manfaat.....	4
BAB 2 TINJAUAN PUSTAKA	5
2.1 Hasil Penelitian Terdahulu	5
2.2 Dasar Teori	13
2.2.1 Kepribadian <i>Big Five</i>	13
2.2.2 <i>Apparent Personality</i> & Karakter Tugas Prediksi	14
2.2.3 Dataset <i>First impressions</i> V2 (<i>Chalearn</i>).....	14
2.2.4 Praproses Audio.....	15
2.2.5 Protokol Pembagian Data & Risiko <i>Leakage</i>	17
2.2.6 Transformer	18
2.2.7 Kerangka Pembelajaran Representasi Ucapan Berbasis <i>Self-Supervised: wav2vec 2.0</i>	22
2.2.8 Kerangka Pembelajaran Representasi Ucapan Berbasis <i>Masked Prediction: HuBERT 25</i>	
2.2.9 Kerangka Pra-latih Ujaran untuk Tugas Umum: WavLM	32
2.2.10 Ekstraksi Fitur	37
2.2.11 Pemodelan Untuk Regresi	40
2.2.12 <i>Parameter-Efficient Fine-tuning: LoRA</i>	42
2.2.13 Optimisasi dan Strategi <i>Training</i>	43
2.2.14 Metrik Evaluasi	45

BAB 3	METODOLOGI.....	47
3.1	Perancangan Sistem.....	47
3.1.1	Desain Penelitian & Alur Umum	48
3.1.2	Prosedur <i>Strict Split</i>	50
3.1.3	Prosedur Praproses Dataset	51
3.1.4	Skenario <i>baseline</i> representasi & model	53
3.1.5	Strategi <i>Fine-tuning</i> dan <i>Tuning</i> Hyperparameter LoRA.....	54
3.1.6	Prosedur Pelatihan per-Run	55
3.2	Bahan dan Peralatan yang Digunakan	56
3.2.1	Dataset	56
3.2.2	Perangkat Keras Hardware	57
3.3	Urutan Pelaksanaan Penelitian	57
DAFTAR PUSTAKA		59
LAMPIRAN.....		63

DAFTAR GAMBAR

Gambar 2.1 Arsitektur Transformer (Vaswani dkk., 2017)	18
Gambar 2.2 Scaled Dot-Product Attention dan Multi-head Attention (Vaswani dkk., 2017) .	19
Gambar 2.3 Kerangka wav2vec 2.0 (Baevski dkk., 2020)	22
Gambar 2.4 Skema HuBERT untuk memprediksi assignment cluster pada frame yang dilakukan masking (Hsu dkk., 2021).....	26
Gambar 2.5 Kualitas assignment cluster dari fitur tiap layer dan tiap iterasi (Hsu dkk., 2021)	28
Gambar 2.6 Arsitektur WavLM (Chen dkk., 2022)	33
Gambar 2.7 Analisis bobot layer pada beberapa tugas SUPERB untuk membandingkan pola kontribusi layer (Chen dkk., 2022).....	36
Gambar 2.8 Analisis bobot layer untuk speaker verification, speaker diarization, dan speech separation.....	37
Gambar 3.1 Diaram Alir Umum Penelitian Audio-only Personality Estimation	48
Gambar 3.2 Diagram Alir Prosedur Split Strict Dataset	50
Gambar 3.3 Alur Praproses Dataset	51
Gambar 3.4 Alur Skenario dan Representasi Model	53
Gambar 3.5 Diagram Alir Strategi Fine-tuning dengan LoRA	54
Gambar 3.6 Diagram Alir Pelatihan per-Run.....	55

Halaman ini sengaja dikosongkan.

DAFTAR TABEL

Tabel 2.1 Tabel Penelitian Terkait	10
Tabel 2.2 Ringkasan kompleksitas dan path length beberapa tipe lapisan (Vaswani dkk., 2017)	21
Tabel 2.3 Perbandingan WER LibriSpeech pada variasi jumlah data berlabel dan sumber data tak berlabel (Baevski dkk., 2020).....	24
Tabel 2.4 Pengaruh objective pelatihan dan kualitas clustering terhadap kinerja pada dev-other WER (Hsu dkk., 2021)	27
Tabel 2.5 Ringkasan arsitektur model HuBERT untuk BASE, LARGE, dan X-LARGE (Hsu dkk., 2021).....	29
Tabel 2.6 Hasil dan perbandingan pada pengaturan low resource LibriSpeech untuk 10 menit, 1 jam, 10 jam, dan 100 jam data berlabel (Hsu dkk., 2021).....	30
Tabel 2.7 Perbandingan dengan literatur pada pengaturan high resource LibriSpeech menggunakan 960 jam data berlabel (Hsu dkk., 2021)	32
Tabel 2.8 Ringkasan konfigurasi varian WavLM dan data pralatih (Chen dkk., 2022).....	35
Tabel 2.9 Ringkasan kelompok fitur akustik dan contoh parameternya	40
Tabel 2.10 Perbandingan regresi linear dan Ridge regression untuk mengurangi overfitting ..	42
Tabel 2.11 Ringkasan perbedaan Adam dan AdamW terkait penerapan weight decay.....	45
Tabel 3.1 Lini masa pengerjaan tugas akhir	57

Halaman ini sengaja dikosongkan.

DAFTAR KODE SUMBER

Halaman ini sengaja dikosongkan.

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Suara manusia tidak hanya menyampaikan isi pesan, tetapi juga berisi informasi paralinguistik, yaitu isyarat di luar kata-kata yang tercermin dari cara berbicara (misalnya prosodi dan kualitas suara) dan dapat mencerminkan karakteristik penutur (Rubio dkk., 2024). Dalam teknologi pemrosesan ujaran, sinyal suara dimanfaatkan tidak hanya untuk mengenali konten, tetapi juga untuk tugas nonlinguistik, yakni tugas yang tidak berfokus pada pengenalan kata atau teks, seperti pengenalan penutur (Barchi dkk., 2023). Sejalan dengan itu, sejumlah studi melaporkan bahwa karakteristik vokal dapat menjadi petunjuk yang relevan terhadap *trait* kepribadian sehingga memungkinkan estimasi kepribadian berbasis ujaran (Barchi dkk., 2023; Rubio dkk., 2024).

Perkembangan model pembelajaran mesin dan ketersediaan dataset berkontribusi pada perkembangan *automatic personality recognition* (APR) serta memungkinkan pengujian sejauh mana fitur suara dapat memprediksi kepribadian (Ghassemi dkk., 2024; Rubio dkk., 2024). Dalam ranah *apparent personality*, label kepribadian merepresentasikan persepsi pengamat terhadap subjek dari cuplikan perilaku yang tampak ataupun terdengar, bukan skor yang diisi sendiri oleh subjek (*self-report*) (Barchi dkk., 2023; Ghassemi dkk., 2024). Sejumlah studi pada konteks ini memanfaatkan isyarat multimodal dari klip video pendek (misalnya audio dan visual) (Ghassemi dkk., 2024; Zhao dkk., 2022). Namun pendekatan berbasis suara tetap relevan terutama pada skenario yang menekankan interaksi lisan, termasuk seleksi personel (Rubio dkk., 2024).

Rubio dkk. (2024) melaporkan bahwa dalam banyak studi, kepribadian dimodelkan menggunakan kerangka *Big Five* dan dianalisis hubungannya dengan ciri vokal. Beberapa penelitian dalam teknologi analisis suara, sudah menggunakan teori umum yang diterima secara luas seperti *Big Five Personality* dan telah melaporkan temuan yang lebih jelas terkait hubungan ciri vokal dan kepribadian dibanding penelitian terdahulu. Seperti fitur-fitur akustik yang berkorelasi dengan kepribadian manusia. Sebagai contoh, *Extraversion* sering dilaporkan berasosiasi dengan isyarat prosodik seperti kecepatan bicara dan variasi *pitch*. Selain itu, tinjauan lain juga merangkum bahwa kelancaran berbicara, *loudness*, dan *speech rate* dilaporkan berkorelasi dengan *Extraversion*, serta ada temuan yang mengaitkan variasi intensitas maupun persepsi *pitch* dengan penilaian seperti *self-confidence* atau *submissiveness/dominance* (Rubio dkk., 2024).

Dari sisi data, Rubio dkk. (2024) menyebutkan bahwa *First impressions V2 Corpus* (Ponce-López dkk., 2016) adalah salah satu contoh dataset yang dipakai di riset *personality* yang diekstrak dari YouTube, sehingga audionya dapat dimanfaatkan untuk eksperimen *audio-only*. Korpus ini terdiri dari 10.000 klip dengan durasi rata-rata sekitar 15 detik yang diekstrak dari lebih dari 3.000 video YouTube, dan pembagiannya mengikuti rasio *train*, validasi, dan *test* sebesar 3:1:1. Selain menyediakan audio, korpus ini juga memberikan label *Big Five* pada rentang 0 sampai 1 untuk setiap klip, sehingga sesuai untuk tugas regresi estimasi kepribadian (Zhao dkk., 2022). Karena setiap klip menyediakan audio, penelitian ini memanfaatkan audio hasil ekstraksi dari korpus tersebut sebagai sumber data untuk eksperimen estimasi kepribadian dengan data suara.

Pada banyak penelitian awal, prediksi *Big Five* dari suara dilakukan dengan mengekstrak fitur akustik *handcrafted* (misalnya prosodik, spektral, MFCC, jitter, shimmer) yang kemudian dipadukan dengan algoritme prediksi (Barchi dkk., 2023; Rubio dkk., 2024). Salah satu *feature set* yang sering digunakan dalam studi paralinguistik adalah *extended Geneva Minimalistic Acoustic Parameter Set* (eGeMAPS), yaitu kumpulan fitur akustik terstandar yang dirancang untuk analisis aspek afektif dan paralinguistik pada ujaran (Barchi dkk., 2023). Hasil dari pendekatan berbasis fitur ini umumnya masih terbatas. Studi yang memakai set deskriptor akustik yang luas untuk memprediksi *self-report* hanya mampu menjelaskan sekitar 16% variansi (Barchi dkk., 2023). Selain itu, kinerja bisa tampak lebih tinggi jika evaluasi dan pemisahan data tidak ketat (misalnya potongan dari video yang sama muncul di data latih dan uji) (Barchi dkk., 2023). Perkembangan terkini kemudian bergeser ke penggunaan model pralatih berbasis Transformer yang mampu mempelajari representasi dari sinyal audio secara lebih beragam tanpa bergantung pada rekayasa fitur manual (Barchi dkk., 2023).

Baevski dkk. (2020) memperkenalkan wav2vec 2.0, yang merupakan model *self-supervised* untuk *speech* yang menggunakan Transformer sebagai *context network*. Pada model ini sebagian representasi laten dari *encoder* dan dilakukan *masking*, lalu model dilatih dengan *objective* kontrastif untuk memilih representasi yang benar dari sekumpulan kandidat yang mencakup *distractor*. HuBERT memakai ide *masked prediction* juga, tetapi targetnya berasal dari langkah *offline clustering* sehingga model belajar memprediksi label target pada bagian yang dimasking (Hsu dkk., 2021). WavLM memperluas kerangka ini dengan menambahkan komponen *denoising* (misalnya *input* dibuat *Noisy/overlapped* saat *pretraining*) dan memperbesar data pralatih menjadi sekitar 94.000 jam agar representasinya lebih kuat dipakai di beragam tugas, termasuk non-ASR (Chen dkk., 2022). Dalam penelitian ini, *backbone* pralatih digunakan dalam dua skema, yaitu sebagai *frozen feature extractor* dan sebagai model yang diadaptasi melalui *fine-tuning*. Agar *fine-tuning* lebih efisien dan tidak memerlukan pembaruan seluruh parameter *backbone*, digunakan pendekatan *parameter-efficient fine-tuning* (PEFT) berupa *Low-Rank Adaptation* (LoRA) (Goncalves dkk., 2024; Hu dkk., 2021).

Dari sisi penerapan, estimasi kepribadian berbasis suara sering dibahas untuk skenario yang melibatkan interaksi lisan seperti wawancara kerja dan seleksi personel, serta untuk mendukung perancangan antarmuka suara pada interaksi manusia dan komputer (Rubio dkk., 2024). Namun, agar pendekatan *audio-only* dapat diandalkan, evaluasi perlu dilakukan dengan *pipeline* yang terdefinisi jelas dan protokol pemisahan data yang ketat untuk meminimalkan bias, khususnya pada dataset yang bersumber dari video daring (Barchi dkk., 2023; Ghassemi dkk., 2024). Oleh karena itu, penelitian ini menyusun *pipeline audio-only* yang mencakup praproses untuk menstandarkan *input* audio, penerapan *strict split* berbasis *group_id* untuk seleksi model dan *tuning*, serta perbandingan *baseline* fitur *handcrafted* (eGeMAPS) dengan *embedding* dari *backbone* Transformer pralatih (wav2vec 2.0, HuBERT, dan WavLM) dalam skema *frozen feature extraction*. *Backbone* terbaik kemudian diadaptasi menggunakan *fine-tuning* yang efisien melalui LoRA dan dievaluasi menggunakan metrik berbasis MAE dan metrik lainnya.

1.2 Rumusan Masalah

Berdasarkan latar belakang, diperlukan evaluasi yang terukur untuk menilai efektivitas pendekatan *audio-only* dalam estimasi kepribadian *Big Five*, khususnya dengan protokol pemisahan data yang ketat guna meminimalkan bias. Oleh karena itu, penelitian ini dirumuskan ke dalam beberapa rumusan masalah berikut:

1. Bagaimana rancangan *pipeline audio-only* (praproses dan *strict split*) yang memadai untuk evaluasi estimasi *Big Five*?
2. Bagaimana perbandingan kinerja *embedding* dari *backbone* pralatih dan fitur *handcrafted* pada protokol pemisahan data *strict split* dan *non-strict split* dengan konfigurasi evaluasi yang sama?
3. Bagaimana pengaruh adaptasi *backbone* terbaik menggunakan LoRA terhadap kinerja dibandingkan skema *frozen feature extraction*, serta seperti apa pola peningkatannya pada masing-masing dimensi *Big Five*?

1.3 Batasan Masalah

Untuk menjaga fokus dan keterkelolaan penelitian, maka batasan masalah yang ditetapkan adalah sebagai berikut:

1. Penelitian ini hanya membahas estimasi kepribadian menggunakan kerangka *Big Five*, yaitu *Openness*, *Conscientiousness*, *Extraversion*, *Agreeableness*, dan *Neuroticism*, dengan label regresi.
2. Penelitian ini dibatasi hanya menggunakan dataset *Chlearn First impressions V2* (*First impressions V2 Corpus*) sebagai sumber data dan label. Dataset lain di luar *Chlearn* tidak termasuk dalam ruang lingkup penelitian.
3. Data yang dianalisis hanya berupa suara/audio. Data visual atau multimodal lain tidak termasuk dalam lingkup penelitian ini.
4. Audio yang digunakan merupakan hasil ekstraksi dari video pada dataset, dengan durasi maksimum 15 detik per sampel. Seluruh audio diseragamkan formatnya melalui praproses (menjadi mono 16 kHz) agar konsisten untuk pemodelan.
5. Penelitian ini tidak berfokus pada perbaikan kualitas rekaman secara mendalam. Variasi kualitas suara seperti *noise* atau musik latar ditangani sebatas penyesuaian dasar, dan sebagian data dapat dikeluarkan bila tidak memenuhi kriteria kelayakan penelitian.
6. Pendekatan yang dibandingkan dibatasi pada dua kelompok: (a) fitur akustik *handcrafted* (eGeMAPS) dan (b) representasi dari *backbone* Transformer pralatih (wav2vec 2.0, HuBERT, WavLM) dalam skema *frozen feature extractor*.
7. *Fine-tuning* dibatasi pada *backbone* terbaik menggunakan LoRA sebagai metode *parameter-efficient fine-tuning* (PEFT).

1.4 Tujuan

Berdasarkan rumusan masalah yang telah disusun, tujuan penelitian ini adalah sebagai berikut:

1. Menyusun dan mendeskripsikan rancangan *pipeline audio-only* yang mencakup tahapan praproses dan penerapan *strict split*, sehingga evaluasi estimasi kepribadian *Big Five* dapat dilakukan secara terukur dan konsisten.
2. Membandingkan kinerja representasi suara berupa *embedding backbone* pralatih dengan fitur *handcrafted* pada dua protokol pemisahan data (*strict split* dan *non-strict split*) menggunakan konfigurasi evaluasi yang sama (praproses, model prediksi, dan metrik).
3. Menganalisis pengaruh adaptasi *backbone* terbaik menggunakan LoRA terhadap kinerja prediksi dibandingkan skema *frozen feature extraction*, serta mengidentifikasi pola perubahan kinerja pada masing-masing dimensi *Big Five*.

1.5 Manfaat

Penelitian ini diharapkan memberikan kontribusi baik secara akademik maupun praktis. Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan gambaran dan referensi mengenai estimasi kepribadian *Big Five* berbasis *audio-only*, termasuk perbandingan antara fitur akustik *handcrafted* (eGeMAPS) dan representasi dari model audio pralatih.
2. Menyediakan rancangan *pipeline* dan protokol evaluasi yang lebih jelas untuk eksperimen *audio-only* pada dataset *Chlearn First impressions V2*, terutama terkait praproses, pemisahan data yang ketat, dan evaluasi kinerja.
3. Memberikan hasil perbandingan kinerja beberapa *backbone* pralatih (wav2vec 2.0, HuBERT, dan WavLM) serta menunjukkan dampak adaptasi efisien menggunakan LoRA terhadap peningkatan kinerja model.
4. Menjadi bahan pertimbangan awal bagi pengembangan sistem yang memanfaatkan informasi suara dalam konteks interaksi lisan, dengan tetap mempertimbangkan batasan dan cakupan penelitian ini.

BAB 2

TINJAUAN PUSTAKA

Bab ini membahas referensi dan teori yang digunakan dalam penelitian. Pembahasan dimulai dari ringkasan penelitian terdahulu yang relevan untuk memberikan gambaran pendekatan yang sudah digunakan pada estimasi kepribadian *Big Five*, terutama pada skenario berbasis suara. Setelah itu, dijelaskan dasar teori yang mendukung perancangan metode penelitian, meliputi karakteristik tugas dan dataset, ekstraksi fitur *audio-only*, penggunaan representasi prelatih, protokol pemisahan data yang lebih ketat untuk mengurangi potensi bias, serta metrik evaluasi yang digunakan. Susunan ini membantu menghubungkan pembahasan literatur dengan rancangan metode pada bab berikutnya.

2.1 Hasil Penelitian Terdahulu

Penyusunan proposal ini melibatkan penelitian-penelitian terdahulu yang relevan, yang dijadikan sebagai dasar perancangan *pipeline* dan pembandingan hasil pada tugas estimasi kepribadian *Big Five* berbasis *audio-only*. Studi-studi tersebut digunakan untuk memahami karakteristik tugas dan dataset, memilih pendekatan ekstraksi fitur dan pemodelan yang sesuai, serta mengidentifikasi praktik evaluasi yang valid agar hasil yang diperoleh tidak bias. Selain itu, penelitian terdahulu juga dimanfaatkan sebagai pembandingan untuk menempatkan capaian penelitian ini dalam konteks literatur yang ada, baik dari sisi metrik kinerja maupun asumsi dan keterbatasan yang dilaporkan. Ringkasan penelitian terdahulu yang menjadi rujukan utama dalam proposal ini disajikan pada Tabel 2.1

Kesalahan! Sumber referensi tidak ditemukan..

Studi awal yang menjadi fondasi dataset pada ranah *apparent personality* adalah Ponce-López dkk. (2016) yang dalam konteks *Challenge Chalearn Looking at People* (LAP) 2016. Studi ini memperkenalkan dataset “*First impressions*” yang berisi 10.000 klip pendek dari YouTube dengan durasi 15 detik, dan label *Big Five* yang diperoleh dari penilaian manusia (AMT), sehingga merepresentasikan *apparent personality* alih-alih *self-report*. Selain itu, dijelaskan juga proses kurasi data dari video YouTube dan penekanan konteks “*first impression*” sebagai skenario penilaian. Penelitian ini mengambil dataset tersebut sebagai sumber data utama karena relevan untuk skenario *audio-only* dan memiliki label *Big Five* kontinu. Perbedaannya, penelitian ini memfokuskan eksperimen pada *track* audio serta menerapkan pemisahan data ketat berbasis *group_id* untuk meminimalkan potensi *overlap* antar *split*.

Pada sisi metodologi pemodelan modern, Hu dkk. (2021) memperkenalkan LoRA sebagai pendekatan *parameter-efficient fine-tuning* yang mengadaptasi model besar tanpa memperbarui seluruh bobot prelatih. Ide utamanya adalah menjaga bobot prelatih tetap *frozen* lalu menambahkan komponen ber-rank rendah yang dilatih untuk tugas target. Penelitian ini mengambil konsep LoRA untuk tahap adaptasi *backbone* terbaik agar *fine-tuning* lebih efisien. Perbedaannya, pada penelitian ini LoRA dimanfaatkan untuk mengadaptasi *backbone* audio pada tugas regresi estimasi *Big Five* berbasis suara.

Penelitian yang dijadikan referensi dalam penelitian ini adalah Aslan dkk. (2021) yang mengevaluasi prediksi *apparent personality* pada dataset *Chalearn First impressions V2*, yaitu 10.000 video berdurasi rata-rata sekitar 15 detik dengan pembagian *official split* 6.000 *train*, 2.000 *validation*, dan 2.000 *test*, serta label *Big Five* kontinu pada rentang 0 sampai 1 yang diperoleh melalui penilaian manusia (AMT). Dengan demikian, label yang digunakan bukan *self-report*, melainkan persepsi pengamat. Dari sisi metode, Aslan dkk. (2021) mengusulkan

kerangka multimodal dengan empat modalitas, yakni *ambient appearance*, *facial appearance*, *voice*, dan *transcribed speech*, yang masing-masing dibangun menggunakan *backbone* pralatih yang dinyatakan eksplisit, yaitu ResNet-v2-101 untuk jalur visual (*ambient* dan *face*), VGGish untuk jalur audio (*voice*), serta ELMo untuk jalur teks (*transcription*). Pada jalur *voice*, audio diproses menjadi *log mel-spectrogram* dan dipotong menjadi segmen berdurasi 960 ms (sesuai masukan VGGish) sebelum diekstraksi menjadi representasi suara menggunakan VGGish, sedangkan jalur teks memanfaatkan representasi ELMo dengan bobot yang dibekukan sebelum dilanjutkan ke lapisan *fully-connected*.

Strategi pelatihan yang dilakukan oleh Aslan dkk. (2021) terbagi oleh dua tahap, yaitu (1) pelatihan *subnetwork* per-modalitas untuk meminimalkan rata-rata MAE lima *trait*, kemudian (2) penggabungan representasi melalui konkatenasi dan pemodelan lanjut menggunakan *feature attention* serta *error consistency constraint* untuk mengurangi perbedaan tingkat kesalahan antar-*trait* sehingga prediksi lebih seimbang. Pada tahap pelatihan digunakan Adam, dan *learning rate* dipilih berdasarkan kesalahan validasi terendah, dengan ruang pencarian 10^{-3} hingga 10^{-6} . Nilai terbaik yang dilaporkan adalah 10^{-4} untuk *voice subnetwork* dan 10^{-5} untuk *subnetwork* lainnya. Karena kompleksitas komputasi, hanya enam detik pertama video digunakan untuk modalitas visual, sementara audio digunakan sepenuhnya. Evaluasi mengikuti metrik *challenge*, yaitu $accuracy = 1 - MAE$, dan kinerja dirangkum sebagai *mean accuracy* (rata-rata akurasi per-*trait*). Hasil utama menunjukkan bahwa *voice* saja mencapai *mean accuracy* 0,9045, penggabungan seluruh modalitas mencapai 0,9172, dan konfigurasi dengan *feature attention* serta *error consistency constraint* mencapai 0,9181. Studi ini diadopsi sebagai rujukan definisi evaluasi berbasis MAE (termasuk pelaporan *mean accuracy*) dan praktik pelatihan yang eksplisit (pemakaian Adam dan pemilihan *learning rate* berbasis validasi). Namun, studi tersebut berfokus pada kerangka multimodal dengan *official split* serta pembatasan durasi visual, sehingga kajian *audio-only* dan protokol pemisahan data yang lebih ketat belum menjadi fokus utama. Berbeda dari (Aslan dkk., 2021), penelitian ini berfokus pada skenario *audio-only*, menerapkan pemisahan data yang lebih ketat berbasis *group_id* untuk mengurangi potensi bias, membandingkan baseline fitur *handcrafted* (eGeMAPS) dengan embedding dari *backbone* Transformer pralatih khusus audio (wav2vec 2.0, HuBERT, dan WavLM) dalam skema *frozen feature extraction*, lalu mengadaptasi *backbone* terbaik melalui *fine-tuning* efisien menggunakan LoRA.

Penelitian berikutnya yang dijadikan referensi dalam penelitian ini salah satunya adalah penelitian yang dilakukan oleh Zhao dkk. (2022) menggunakan dataset *Chalearn First impression V2* (10.000 klip, ± 15 detik, dengan *split* 6.000 *train*, 2.000 *val*, dan 2.000 *test*) (Ponce-López dkk., 2016), dataset ini digunakan untuk prediksi kepribadian berbasis skor *Big Five Personality* sekaligus skor *Interview*. Modalitas yang dimanfaatkan dalam penelitian ini adalah audio dan visual (*global scene* dan *local face*). Untuk bagian dari dataset yang dimanfaatkan hanya *train* dan *val*. Pada tahap praproses, audio dari setiap video dibagi menjadi segmen yang berurutan dengan durasi 0,96 detik untuk menyesuaikan *input* VGGish (*backbone* audio pralatih yang digunakan untuk ekstraksi fitur audio). Sedangkan untuk praproses visual, sampel diambil 100 *frame* latar dengan interval yang sama dan di-*resize* menjadi 224x224, serta dilakukan deteksi wajah dengan MTCNN untuk memperoleh 30 *frame* wajah (jika kurang dari 30, *frame* awal/akhir diulang) yang juga di-*resize* menjadi 224x224. Fitur lokal audio diekstrak menggunakan VGGish yang menghasilkan 128 dimensi per segmen, sementara fitur lokal visual yaitu latar dan wajah diekstrak dengan VGG-Face yang menghasilkan fitur 4096 dimensi per *frame*.

Setelah fitur lokal diekstrak, ketergantungan temporal dimodelkan untuk membentuk representasi global *level-video* menggunakan Bi-LSTM dan juga Transformer (*encoder* standar) yang dilakukan secara paralel. Tahap prediksi terdiri dari dua skema yaitu *single modality* dan multimodal. Skema multimodal dilakukan dengan *linear regression layer* sehingga dari tiga jenis fitur (audio/latar/wajah) dan dua model temporal (Bi-LSTM dan Transformer) diperoleh enam hasil prediksi (satu fitur menghasilkan dua prediksi dari dua model) yang kemudian digabung menggunakan *decision-level fusion (late fusion)* berbobot, dengan bobot α dicari secara analitik dari optimisasi minimasi MSE (*Mean Squared Error*) dengan syarat jumlah seluruh bobot harus sama dengan 1. Sedangkan untuk skema *single-modality* yaitu setiap fitur diprediksi dengan menggunakan Bi-LSTM yang dikombinasikan dengan Transformer (menggabungkan fitur global dari kedua model) dan dilanjutkan regressor untuk menghasilkan prediksi, jadi untuk skema ini total menghasilkan 3 prediksi. Evaluasi yang digunakan mengikuti *challenge* yaitu $S = 1 - \text{MAE}$ (semakin kecil MAE semakin baik). Hasil eksperimen menunjukkan bahwa pada skema dua atau *single-modality (hybrid Transformer dan Bi-LSTM)*, urutan kinerja terbaik adalah wajah (average *Big Five* 0,9124), kemudian latar (0,9039), dan audio (0,8952). Ketika ketiga modality tersebut digabung pada skema multimodal melalui *weighted decision-level fusion* yang terdiri dari 6 prediksi (Transformer dan Bi-LSTM untuk tiap modality), kinerja naik menjadi 0,9167 pada rata-rata *Big Five*. Penelitian ini diadopsi terutama sebagai acuan penggunaan evaluasi berbasis MAE ($S = 1 - \text{MAE}$) serta gambaran bahwa kinerja *audio-only* pada dataset yang sama cenderung berada di bawah modalitas visual pada kondisi *official split*. Keterbatasan yang relevan untuk konteks penelitian ini adalah fokus studi Zhao dkk. (2022) pada skenario multimodal dengan representasi audio berbasis VGGish, sehingga eksplorasi *backbone* Transformer pralatih khusus audio untuk skenario *audio-only* belum menjadi fokus utama. Berbeda dari Zhao dkk. (2022), penelitian ini menitikberatkan pada skenario *audio-only*, menerapkan pemisahan data yang lebih ketat berbasis *group id* untuk mengurangi potensi bias, membandingkan *baseline* fitur *handcrafted* (eGeMAPS) dengan *embedding* dari *backbone* Transformer pralatih khusus audio (wav2vec 2.0, HuBERT, dan WavLM) dalam skema *frozen feature extraction*, lalu mengadaptasi *backbone* terbaik melalui *fine-tuning* menggunakan LoRA.

Penelitian selanjutnya yang dijadikan rujukan adalah Barchi dkk. (2023) yang memfokuskan prediksi *apparent personality* dari sinyal ujaran dengan memanfaatkan representasi *self-supervised* (wav2vec 2.0) dan fitur akustik *handcrafted* pada “*First impressions Dataset*” (*Chalearn LAP 2016*), yaitu sekitar 10.000 klip berdurasi 15 detik dari YouTube vlog dengan label *Big Five* hasil penilaian pendengar (AMT) dan kemudian dinormalisasi, sehingga labelnya bukan *self-report*. Studi ini menyoroti isu kualitas data audio, khususnya keberadaan musik latar, lalu melakukan anotasi keberadaan musik dan memfokuskan eksperimen utama pada subset tanpa musik agar sinyal ujaran lebih dominan. Dari sisi representasi, Barchi dkk. (2023) membandingkan dua jalur utama pada skenario *audio-only*: (1) jalur “klasik” berupa eGeMAPS yang diekstraksi dengan openSMILE serta ditambah fitur *speech ratio* (rasio durasi bicara) yang dihitung menggunakan Silero VAD, dan (2) jalur “modern” berupa *embedding* wav2vec 2.0 base yang diekstraksi dari seluruh *layer* (bukan hanya *layer* terakhir. Untuk pemodelan, digunakan Random Forest Regressor dengan ringkasan *embedding* wav2vec 2.0 yang direduksi dimensinya menggunakan PCA, serta DNN yang memanfaatkan urutan *embedding* wav2vec 2.0 sebelum dilakukan pooling untuk memprediksi lima *trait*. Berbeda dengan metrik berbasis MAE pada *challenge*, Barchi dkk. (2023) mengevaluasi kinerja menggunakan koefisien determinasi R^2 dan melaporkan R^2_{avg} sebagai rata-rata per-*trait*.

Barchi dkk. (2023) menekankan pentingnya protokol pemisahan data yang tidak “bocor” dengan menunjukkan bahwa *official split* dapat menghasilkan kinerja yang terlalu optimistis karena potongan dari video yang sama bisa muncul di *split* berbeda, sehingga mereka menerapkan pemisahan berdasarkan video identifier dan menjaga keseimbangan distribusi melalui stratifikasi (gender, *ethnicity*, dan rata-rata rating) dalam skema 5-fold *cross-validation*. Hasil utamanya menunjukkan bahwa model DNN berbasis wav2vec 2.0 mencapai R^2_{avg} sekitar 0,33 pada *official split*, namun turun menjadi sekitar 0,28 pada *split* yang lebih ketat berbasis video identifier, yang memperkuat argumen bahwa evaluasi sangat sensitif terhadap strategi *split* (Barchi dkk., 2023). Studi ini relevan dan selaras dengan penelitian ini karena sama-sama menempatkan eGeMAPS sebagai *baseline*, memanfaatkan *embedding self-supervised* dari model audio prelatih, dan menekankan perlunya pemisahan data yang ketat untuk mengurangi bias pada dataset berbasis video daring. Metode yang diadopsi dari Barchi dkk. (2023) dalam penelitian ini adalah (1) penggunaan eGeMAPS sebagai pembanding *baseline audio-only*, (2) pemanfaatan Silero VAD untuk memperoleh informasi terkait durasi bicara dan rasionya, serta (3) prinsip pemisahan data yang ketat berbasis grup untuk meminimalkan overlap yang dapat membuat kinerja terlihat lebih tinggi. Adapun perbedaannya, penelitian ini tidak membatasi eksplorasi pada wav2vec 2.0 saja, melainkan membandingkan beberapa *backbone* Transformer prelatih khusus audio (wav2vec 2.0, HuBERT, dan WavLM) pada skema *frozen feature extraction*, kemudian mengadaptasi *backbone* terbaik melalui *fine-tuning* efisien menggunakan LoRA. Selain itu, evaluasi difokuskan pada metrik berbasis MAE agar konsisten dengan karakter tugas regresi *Big Five* pada dataset tersebut. Gap yang dapat ditarik dari studi Barchi dkk. (2023) untuk menjadi motivasi penelitian ini adalah terbatasnya eksplorasi *backbone* audio prelatih di luar wav2vec 2.0 serta belum adanya kajian adaptasi parameter-efisien untuk meningkatkan kinerja pada skenario *audio-only* dengan protokol pemisahan data yang ketat.

Salah satu referensi lain yang diambil adalah penelitian oleh Rubio dkk. (2024) yang melakukan estimasi kepribadian dengan merekam 100 partisipan saat wawancara, lalu membandingkan prediksi berbasis suara terhadap skor *Big Five* dari NEO-FFI (*NEO Five-Factor Inventory*) yang mana merupakan sebuah kuesioner yang bersifat *self-report*, penilaian orang dekat, dan rating ahli. Pada sisi pemrosesan, Rubio menggunakan pendekatan *audio-only* yang masih klasik, yaitu mengambil segmen audio dari wawancara lalu mengekstrak fitur menggunakan OpenSMILE dengan set AVEC2011 sebanyak sekitar 1941 fitur yang mencakup MFCC, jitter, shimmer, dan berbagai fitur akustik lain. Untuk tahap prediksi, skor tiap *trait Big Five* yang awalnya kontinu diubah menjadi tiga kelas (low/medium/high) menggunakan batas persentil P25 dan P75 pada data *training*, sehingga 25% terbawah menjadi low, 50% di tengah menjadi medium, dan 25% teratas menjadi high. Selanjutnya dalam studi dilakukan Random Forest untuk mengklasifikasikan *level* tersebut, dengan *input* top-5 fitur yang korelasinya paling tinggi terhadap *trait* yang diprediksi. Hasilnya menunjukkan adanya sinyal prediktif pada fitur suara dengan korelasi yang cenderung moderat (skor pearson r sekitar 0,3–0,4), sehingga suara dapat memberi “petunjuk” terhadap *trait* meskipun belum deterministik, dan kemudian dilakukan prediksi model klasifikasi (low/medium/high) dan didapatkan kinerja yang memiliki akurasi keseluruhan 43% hingga 60% tergantung *trait* dan sumber label. Dalam penelitian ini, bagian yang diadopsi dari Rubio dkk. (2024) adalah konteks bahwa sinyal paralinguistik pada suara dapat digunakan untuk mengestimasi *Big Five* dan pentingnya pelaporan evaluasi yang eksplisit, namun perbedaan utama terletak pada penggunaan dataset *Chlearn First impressions V2* dengan label *apparent personality* pada rentang 0 sampai 1, fokus pada skenario regresi *audio-*

only, penerapan pemisahan data yang lebih ketat berbasis *group_id* untuk meminimalkan potensi bias, serta perbandingan representasi fitur *handcrafted* eGeMAPS dibanding AVEC2011 yang digunakan Rubio dkk. (2024) dalam penelitiannya. Selain itu, penelitian ini menambahkan pembandingan dari *backbone* Transformer pralatih khusus audio (wav2vec 2.0, HuBERT, WavLM), kemudian mengadaptasi *backbone* terbaik melalui *fine-tuning* efisien menggunakan LoRA.

Penelitian lain yang dijadikan referensi dalam penelitian ini adalah penelitian oleh Ghassemi dkk. (2024) yang mengusulkan kerangka *multimodal* untuk prediksi *apparent personality* pada dataset *Chlearn First impressions V2*, yang berisi 10.000 video berdurasi 15 detik dengan label *Big Five* (serta *Interview score*) pada rentang 0 sampai 1 dari penilaian pengamat. Dalam studi tersebut digunakan tiga modalitas utama yaitu audio, visual, dan verbal (transkrip) dengan representasi yang menggabungkan fitur *handcrafted* dan *embedding* hasil *transfer learning*: audio diekstrak sebagai fitur akustik berbasis jendela waktu dan *embedding* berbasis Wav2Vec, visual menggunakan fitur OpenFace serta *embedding* CNN bergaya FaceNet/Inception, sedangkan transkrip dipetakan menjadi *embedding* menggunakan BERT. Untuk merangkum informasi temporal, Ghassemi dkk. (2024) memperkenalkan agregasi temporal tak terawasi yang menggabungkan fungsi statistik dan *temporal autoencoder*, lalu melakukan *early fusion* sebelum modul regresi berbasis *deep ensemble* MLP.

Aspek penting lain pada penelitian (Ghassemi dkk., 2024) adalah protokol pemisahan data: selain mengevaluasi pada *official split*, studi ini menekankan adanya *subject-dependency* pada *split* asli dan mengusulkan *dependency-free split* berbasis YouTube *channel ID* dengan pembagian 6.000/2.000/2.000 agar validasi lebih mencerminkan generalisasi antarsubjek. Evaluasi dilaporkan menggunakan R^2 dan *mean accuracy* $A = 1 - \text{MAE}$, dengan R^2 sebagai metrik utama dan A untuk pembandingan dengan literatur. Hasil kunci menunjukkan bahwa pada *dependency-free split* gabungan audio dan visual mencapai R^2 rata-rata sekitar 0,369, sedangkan fitur verbal sendiri relatif lemah (R^2 rata-rata sekitar 0,037), dan pada *split* asli nilai rata-rata dapat meningkat hingga sekitar R^2 0,514 (dengan *mean accuracy* sekitar 0,919), yang mengindikasikan bahwa evaluasi pada *split* asli berpotensi terlalu optimis. Keterbatasan yang relevan untuk konteks penelitian ini adalah fokus Ghassemi dkk. (2024) yang dominan pada skenario *multimodal* dan rancangan agregasi temporal/strategi fitur, sehingga eksplorasi khusus skenario *audio-only* serta perbandingan sistematis antar *backbone* audio terkini dan adaptasi *parameter-efficient fine-tuning* tidak menjadi fokus utama. Kontribusi yang diadopsi pada penelitian ini terutama adalah penekanan pentingnya pemisahan data yang lebih ketat untuk meminimalkan bias/leakage serta pelaporan evaluasi berbasis MAE (dan $1 - \text{MAE}$) sebagai pembandingan literatur, sedangkan pembedanya adalah fokus *audio-only* tanpa visual/transkrip, pembandingan *baseline* eGeMAPS dengan *backbone* Transformer pralatih khusus audio dalam skema *frozen feature extraction*, dan adaptasi *backbone* terbaik melalui *fine-tuning* efisien menggunakan LoRA.

Tabel 2.1 Tabel Penelitian Terkait

Judul	Setup Dataset	Metode Inti	Diadopsi pada Penelitian Ini	Perbedaan dan Gap yang diisi
<i>Multimodal assessment of apparent personality using feature attention and error consistency constraint</i> (Aslan dkk., 2021)	<i>Chalearn</i> FI-V2 (Ponce-López dkk., 2016), <i>official split</i> 6.000/2.000/2.000 label <i>Big Five</i> 0 sampai 1 (AMT) dengan 4 modalitas : visual ambient, wajah, suara, transkrip.	<i>Backbone</i>: ResNet-v2-101 (visual), VGGish (suara), ELMo (teks). - Dua tahap: pelatihan per modalitas lalu fusi dengan <i>feature attention</i> dan <i>error consistency</i>. - Metrik: $1 - \text{MAE}$ dengan <i>mean accuracy</i> terbaik sekitar 0,918.	Evaluasi berbasis MAE dan pelaporan $1 - \text{MAE}$ (<i>mean accuracy</i>) dan contoh pelaporan hasil per- <i>trait</i> dan rata-rata.	Fokus utama multimodal dan <i>official split</i> . Sedangkan penelitian ini berfokus <i>audio-only</i> , dengan dua jenis <i>split</i> , dan membandingkan eGeMAPS vs <i>backbone</i> audio Transformer, lalu LoRA untuk adaptasi <i>backbone</i> terbaik.
<i>Integrating audio and visual modalities for multimodal personality trait recognition via hybrid deep learning</i> (Zhao dkk., 2022)	<i>Chalearn</i> FI-V2 (Ponce-López dkk., 2016), <i>split</i> 6.000/2.000/2.000 dengan prediksi <i>Big Five</i> dan <i>Interview score</i> dengan modalitas audio dan visual (latar dan wajah).	- Representasi: VGGish (audio) dan VGG-Face (visual). - Model temporal: Bi-LSTM dan Transformer dan fusi keputusan berbobot. - Metrik: $S = 1 - \text{MAE}$, kinerja multimodal sekitar 0,9167, <i>audio-only</i> lebih rendah dari visual.	Acuan metrik <i>challenge</i> berbasis MAE ($S = 1 - \text{MAE}$) sebagai pembanding literatur.	Studi berfokus multimodal dan representasi audio VGGish dan tidak ada perbandingan <i>backbone</i> audio Transformer modern. Sedangkan penelitian ini mengevaluasi <i>audio-only</i> dengan eGeMAPS vs wav2vec 2.0/HuBERT/WavLM, <i>split</i> ketat berbasis <i>group_id</i> , lalu LoRA pada <i>backbone</i> terbaik.

Judul	Setup Dataset	Metode Inti	Diadopsi pada Penelitian Ini	Perbedaan dan Gap yang diisi
<i>Apparent personality prediction from speech using expert features and wav2vec 2.0</i> (Barchi dkk., 2023)	<i>First impressions.</i> Berisi sekitar 10.000 klip 15 detik; label <i>Big Five</i> dari AMT (<i>apparent</i>) dengan analisis musik latar dan subset tanpa musik.	• <i>Baseline</i>: eGeMAPS dan fitur durasi bicara dari Silero VAD. • Representasi modern: <i>embedding</i> wav2vec 2.0; model RF dan DNN. • Metrik: R^2_{avg}; DNN sekitar 0,33 (<i>official</i>) turun sekitar 0,28 pada <i>split</i> lebih ketat.	eGeMAPS sebagai <i>baseline</i> , Silero VAD untuk statistik durasi bicara, dan sebagai motivasi pentingnya <i>split</i> ketat.	Studi mengeksplor wav2vec 2.0 dan belum membahas adaptasi PEFT untuk <i>audio-only</i> . Sedangkan penelitian ini membandingkan wav2vec 2.0/HuBERT/WavLM pada skema <i>frozen</i> , lalu LoRA untuk <i>backbone</i> terbaik dengan protokol <i>split</i> berbasis <i>group_id</i> .
<i>Feasibility of Big Data Analytics to Assess Personality Based on Voice Analysis</i> (Rubio dkk., 2024)	100 partisipan wawancara dengan label <i>Big Five</i> dari NEO-FFI (<i>self-report</i>) dan pembandingan dengan penilaian pihak lain (orang dekat dan ahli).	• Fitur akustik OpenSMILE (AVEC2011 sekitar 1941 fitur). • Prediksi dibuat klasifikasi 3 kelas; model Random Forest. • Prediksi dibuat klasifikasi 3 kelas dengan model Random Forest.	Konteks relevansi sinyal paralinguistik dan pentingnya pelaporan evaluasi eksplisit.	Setup berbeda (<i>self-report</i> dan klasifikasi 3 kelas, bukan regresi <i>apparent personality</i>). Penelitian ini memakai <i>Chlearn</i> FI-V2 (<i>apparent</i> , regresi dengan nilai 0 sampai 1), <i>audio-only</i> , <i>split</i> ketat berbasis <i>group_id</i> , serta membandingkan eGeMAPS dan <i>embedding backbone</i> audio Transformer.

Judul	Setup Dataset	Metode Inti	Diadopsi pada Penelitian Ini	Perbedaan dan Gap yang diisi
<i>Unsupervised Multimodal Learning for Dependency-free Personality Recognition</i> (Ghassemi dkk., 2024)	<i>Chalearn</i> FI-V2 (Ponce-López dkk., 2016), 10.000 video 15 detik; label <i>Big Five</i> nilai 0 sampai 1 (<i>apparent</i>) dan konteks evaluasi pada <i>official</i> vs <i>dependency-free split</i> berbasis YouTube <i>channel ID</i> .	- Representasi: BERT (teks), wav2vec (audio), OpenFace dan CNN (visual). - Peringkasan temporal tak terawasi dan <i>ensemble</i> MLP untuk regresi. - Hasil: audio dan visual R^2_{avg} sekitar 0,369 pada <i>dependency-free</i>, pada <i>official split</i> bisa lebih tinggi.	Motivasi bahwa pemisahan data yang lebih ketat diperlukan untuk mengurangi bias pada dataset berbasis kanal. Dan ide pelaporan MAE/1 – MAE sebagai pembandingan literatur.	Fokus dominan multimodal dan desain peringkasan temporal. Masih tidak ada eksplorasi <i>audio-only</i> dan perbandingan beberapa <i>backbone</i> audio modern. Sedangkan penelitian ini memusatkan evaluasi pada <i>audio-only</i> dengan ekstraksi fitur eGeMAPS dan Transformer.s

2.2 Dasar Teori

Subbab ini menjelaskan dasar teori yang digunakan sebagai acuan dalam penelitian. Pembahasan mencakup konsep kepribadian *Big Five* dan karakter tugas prediksi berbasis audio, serta gambaran umum dataset yang digunakan. Selanjutnya dibahas prinsip pengolahan sinyal ujaran dan pendekatan ekstraksi fitur, baik fitur *handcrafted* maupun representasi *embedding* dari model *self supervised speech*. Subbab ini juga menguraikan konsep pemodelan regresi untuk memprediksi lima *trait* kepribadian, termasuk pilihan *baseline* dan pendekatan *fine-tuning* yang efisien parameter seperti LoRA. Pada bagian akhir dijelaskan konsep optimisasi dan strategi pelatihan model, metrik evaluasi, serta prinsip pembagian data sebagai landasan untuk metode yang dipaparkan pada bab berikutnya.

2.2.1 Kepribadian *Big Five*

Model Lima Faktor atau yang dikenal sebagai *Big Five Personality* merupakan organisasi hierarkis dari sifat-sifat kepribadian yang dikelompokkan ke dalam lima dimensi dasar, yaitu *Extraversion*, *Agreeableness*, *Conscientiousness*, *Neuroticism*, dan *Openness to Experience* (McCrae & John, 1992). Model ini berakar pada hipotesis leksikal, yang menyatakan bahwa perbedaan individu yang paling penting dalam transaksi manusia akan dikodekan sebagai istilah tunggal dalam bahasa (Goldberg, 1990). Pendekatan ini mengasumsikan bahwa analisis terhadap struktur bahasa sifat (*trait adjectives*) dapat mengungkap taksonomi komprehensif dari kepribadian manusia (Goldberg, 1990; McCrae & John, 1992).

Secara spesifik, kelima dimensi tersebut merepresentasikan *level* abstraksi tertinggi dalam deskripsi kepribadian sebagai berikut.

1. *Extraversion* (atau *Surgency*), berkaitan dengan kuantitas dan intensitas interaksi interpersonal serta tingkat aktivitas, di mana individu dengan skor tinggi cenderung bersosialisasi, aktif, dan asertif, sedangkan individu dengan skor rendah cenderung pendiam dan menarik diri (Goldberg, 1990; McCrae & John, 1992).
2. *Agreeableness*, mencerminkan kualitas orientasi interpersonal seseorang mulai dari belas kasih (*compassion*) hingga antagonisme dalam pikiran, perasaan, dan tindakan (McCrae & John, 1992).
3. *Conscientiousness* (atau *Dependability*), menggambarkan derajat organisasi, ketekunan, dan motivasi dalam perilaku yang diarahkan pada tujuan, yang membedakan individu yang dapat diandalkan dan tertib dengan mereka yang lalai atau tidak teratur (Goldberg, 1990; McCrae & John, 1992).
4. *Neuroticism* (lawan dari *Emotional Stability*) mengacu pada kecenderungan untuk mengalami distres psikologis dan afek negatif kronis seperti kecemasan, depresi, dan rasa tidak aman (McCrae & John, 1992).
5. *Openness to Experience* yang mencakup apresiasi terhadap seni, emosi, petualangan, ide-ide yang tidak biasa, serta rasa ingin tahu. Meskipun terdapat variasi dalam penamaan faktor kelima, struktur lima faktor ini terbukti kuat (*robust*) dan dapat direplikasi lintas berbagai metode ekstraksi faktor maupun budaya yang berbeda (Goldberg, 1990; McCrae & John, 1992).

2.2.2 *Apparent Personality & Karakter Tugas Prediksi*

Dalam ranah komputasi kepribadian, terdapat perbedaan mendasar antara kepribadian yang dilaporkan sendiri (*self-reported personality*) dan kepribadian yang tampak (*apparent personality*). Sementara *self-reported personality* diperoleh melalui kuesioner yang diisi oleh subjek, *apparent personality* mengacu pada persepsi atau kesan pertama (*first impressions*) yang dibentuk oleh pengamat eksternal terhadap subjek berdasarkan paparan perilaku yang singkat (Barchi dkk., 2023; Ponce-López dkk., 2016). Dataset *First impressions V2* yang digunakan dalam penelitian ini dirancang khusus untuk tugas prediksi *apparent personality*, di mana label kebenaran dasar (*ground truth*) tidak mencerminkan profil psikologis internal subjek, melainkan bagaimana subjek tersebut dipersepsikan oleh orang lain dalam konteks interaksi sosial singkat, seperti wawancara kerja (Ponce-López dkk., 2016).

Karakteristik utama dari tugas prediksi pada dataset ini adalah penggunaan label kontinu dalam rentang untuk kelima dimensi *Big Five*. Label ini diperoleh melalui mekanisme anotasi manusia menggunakan *Amazon Mechanical Turk* (AMT). Karena penilaian kepribadian bersifat subjektif dan rentan terhadap bias penilai, Ponce-López dkk. (2016) menerapkan strategi pelabelan berbasis perbandingan berpasangan (*pairwise comparisons*). Dalam metode ini, penganotasi tidak memberikan skor absolut, melainkan membandingkan dua video dan menentukan subjek mana yang lebih menonjol pada *trait* tertentu. Skor kardinal akhir kemudian direkonstruksi menggunakan model Bradley-Terry-Luce (BTL) untuk mengurangi variansi dan bias kalibrasi antar penganotasi (Ponce-López dkk., 2016).

Tugas prediksi ini pada dasarnya adalah masalah regresi, di mana model dilatih untuk meminimalkan selisih antara skor prediksi dan label persepsi manusia. Evaluasi standar dalam tugas ini umumnya menggunakan metrik akurasi rata-rata (*Mean Accuracy*) yang didefinisikan sebagai $1 - \text{MAE}$ (*Mean Absolute Error*) (Ponce-López dkk., 2016). Namun, Barchi dkk. (2023) menyarankan penggunaan koefisien determinasi (R^2) sebagai metrik pelengkap untuk melihat proporsi variansi yang dapat dijelaskan oleh model, mengingat tugas ini memiliki tingkat kesulitan yang tinggi. Berdasarkan analisis Barchi dkk. (2023), dimensi *Agreeableness* konsisten menjadi *trait* yang paling sulit diprediksi dibandingkan *trait* lainnya, yang diduga disebabkan oleh rendahnya kesepakatan antar penganotasi manusia untuk dimensi tersebut.

Tantangan lain dalam tugas prediksi ini berkaitan dengan bias demografis dan protokol evaluasi. Barchi dkk. (2023) mencatat adanya ketidakseimbangan representasi etnis dalam dataset serta bias penilaian, di mana subjek perempuan cenderung mendapatkan skor rata-rata yang lebih tinggi dibandingkan laki-laki pada kelima *trait*. Selain itu, terdapat isu kritical pada pembagian data resmi (*official split*) dataset ini, di mana potongan klip dari video asli yang sama dapat tersebar ke dalam data latih (*training*) dan data uji (*test*). Kondisi ini dapat menyebabkan kebocoran informasi (*data leakage*), sehingga model mengenali kondisi akustik atau latar belakang subjek alih-alih mempelajari fitur kepribadian, yang berujung pada hasil evaluasi yang terlalu optimis (Barchi dkk., 2023). Oleh karena itu, strategi pembagian data yang ketat berdasarkan identitas video atau grup sangat diperlukan untuk memastikan validitas pengukuran kinerja model prediksi.

2.2.3 *Dataset First impressions V2 (Chalearn)*

Dataset *First impressions V2* merupakan korpus skala besar yang dikembangkan untuk tugas analisis kepribadian otomatis berdasarkan persepsi (*apparent personality*) dalam konteks

tantangan *Chalearn Looking at People*. Dataset ini terdiri dari 10.000 klip video pendek berdurasi rata-rata 15 detik yang diekstraksi dari lebih dari 3.000 video YouTube definisi tinggi (HD). Subjek dalam video berbicara menghadap kamera dalam bahasa Inggris, yang merepresentasikan situasi presentasi diri atau wawancara kerja daring (Ponce-López dkk., 2016).

Label anotasi utama pada dataset ini mencakup lima dimensi kepribadian (*Big Five Personality Traits*), yaitu *Openness*, *Conscientiousness*, *Extraversion*, *Agreeableness*, dan *Neuroticism*. Untuk menghasilkan label yang objektif, ground truth diperoleh melalui penilaian manusia menggunakan layanan Amazon Mechanical Turk (AMT) dengan mekanisme perbandingan berpasangan (*pairwise comparisons*) antar video untuk menghindari bias subjektivitas penilai. Skor akhir direkonstruksi menggunakan model Bradley-Terry-Luce (BTL) menjadi nilai kontinu dalam rentang (Ponce-López dkk., 2016). Pada pengembangan selanjutnya untuk kompetisi penyaringan kandidat kerja, dimensi *Neuroticism* sering dikonversi menjadi *Non-Neuroticism* (kestabilan emosi) agar semua skor memiliki skala positif (Escalante dkk., 2022).

Selain dimensi kepribadian, Escalante dkk. (2022) memperkaya dataset ini dengan label tambahan untuk mendukung tugas analisis explainability dan rekomendasi perekrutan. Anotasi tambahan tersebut adalah sebagai berikut.

1. Variabel Wawancara Kerja (*Job-Interview Variable*): Sebuah label yang mengindikasikan apakah seseorang layak diundang untuk wawancara kerja atau tidak, berdasarkan skor kuantitatif prediksi kepribadian.
2. Atribut Demografis: Untuk keperluan analisis bias, dataset ini dilengkapi dengan anotasi manual untuk gender (laki-laki dan perempuan) dan etnisitas (*ethnicity*) yang dikategorikan ke dalam kelompok Asia, Kaukasia, dan Afro-Amerika.
3. Kelompok Usia (*Age Groups*): Subjek dalam video dianotasi ke dalam delapan kelompok usia terpisah, yaitu: 0–6, 7–13, 14–18, 19–24, 25–32, 33–45, 46–60, dan 61+ tahun.
4. Transkripsi Teks: Transkripsi manual dari ucapan audio disediakan untuk memungkinkan penggunaan modalitas teks dalam analisis.

Distribusi data standar membagi 10.000 klip ini menjadi 6.000 data latih (*training*), 2.000 data validasi, dan 2.000 data uji (*test*) (Escalante dkk., 2022; Ponce-López dkk., 2016). Keberagaman subjek dijaga dengan mengambil sumber dari ribuan saluran YouTube yang berbeda, mencakup variasi luas dalam hal gender, usia, dan latar belakang etnis (Ponce-López dkk., 2016).

2.2.4 Praproses Audio

Dalam sistem prediksi kepribadian berbasis suara, praproses bertujuan memastikan sinyal audio memiliki format yang konsisten dan memuat informasi ujaran yang memadai sebelum masuk ke tahap ekstraksi fitur maupun pemodelan. Pada dataset *First impressions Chalearn* (Ponce-López dkk., 2016), data berasal dari klip YouTube sehingga variasi kondisi perekaman (misalnya perbedaan format, laju sampel, serta keberadaan segmen hening atau musik latar) perlu ditangani melalui standardisasi dan pembersihan berbasis kualitas ujaran (Barchi dkk., 2023; Ghassemi dkk., 2024).

a) Standardisasi format sinyal

Langkah awal praproses adalah memuat dan mendekode audio untuk memastikan berkas dapat diproses dengan benar dan menghasilkan sinyal yang valid. Setelah audio berhasil dibaca, sinyal diseragamkan ke format deterministik (misalnya mono) dan laju sampel disesuaikan agar konsisten dengan praktik *input* pada model *self-supervised speech* yang umum digunakan. Sebagai contoh, pada implementasi *feature extractor wav2vec 2.0*, parameter *sampling_rate* secara default menggunakan 16.000 Hz sehingga audio umumnya diseragamkan ke 16 kHz sebelum diekstraksi fiturnya (Baevski dkk., 2020).

b) Penyeragaman durasi (*trim*/pad ke durasi target)

Dataset *First impressions* menyediakan klip berdurasi 15 detik. Untuk memudahkan pemrosesan *batch* dan menjaga konsistensi dimensi *input*, sinyal biasanya dipaksa menjadi panjang tetap T (misalnya 15 detik) melalui *trimming* atau *padding* (Barchi dkk., 2023). Secara operasional, panjang target dalam satuan sampel dapat dinyatakan sebagai:

$$LT = T \cdot f_s \quad (2.1)$$

Hubungan ini mengikuti definisi f_s sebagai “jumlah sampel per detik”, sehingga total sampel untuk durasi T diperoleh dari perkalian T dan f_s (Smith, 1999). Jika panjang sinyal $L \geq L_T$, sinyal dipotong hingga L_T . Jika $L < L_T$, sinyal diisi (*padding*) sampai L_T , dan sampel dapat ditandai sebagai durasi pendek untuk analisis lanjutan. Selain itu, sampel yang sangat pendek umumnya kurang informatif karena tidak menyediakan konteks temporal yang memadai. Barchi dkk. menunjukkan bahwa kinerja model menurun tajam ketika durasi sinyal semakin pendek.

c) Voice Activity Detection dan pengukuran rasio ujaran

Voice Activity Detection (VAD) merupakan teknik pemrosesan wicara untuk membedakan bagian yang mengandung *speech* dan *non-speech* (misalnya hening/*noise*) pada sinyal audio. Dalam konteks penelitian *audio-only* pada *First impressions*, Barchi dkk. mengekstraksi *speech* timestamps menggunakan Silero VAD, lalu menghitung *speech* ratio sebagai rasio durasi ujaran terhadap durasi total seperti pada persamaan 2.2 berikut (Silero Team, 2024).

$$speech_{sec} = \sum_{i=1}^N (t_i^{end} - t_i^{start}) \quad (2.2)$$

Selanjutnya, *speech* ratio (atau *voiced* ratio) didefinisikan sebagai perbandingan durasi ujaran terhadap durasi total sinyal. Dengan durasi total T , perhitungannya tertulis pada persamaan 2.3 sebagai berikut:

$$speech_{ratio} = \frac{speech_{sec}}{T} \quad (2.3)$$

2.2.5 Protokol Pembagian Data & Risiko *Leakage*

Pembagian data ke dalam set pelatihan, validasi, dan pengujian dilakukan agar kinerja model dapat dinilai pada data yang tidak ikut dipakai saat pelatihan. Pada dataset yang dikumpulkan dari lingkungan tidak terkontrol seperti YouTube, sampel sering berasal dari sumber yang sama sehingga pola rekaman, karakter pembicara, atau konteks video dapat menjadi mirip antar sampel. Jika kemiripan yang berasal dari sumber tersebut ikut terbawa ke set yang berbeda, maka kinerja yang diukur tidak sepenuhnya menggambarkan kemampuan generalisasi model pada data baru. Kondisi ini dibahas dalam konteks *First impressions* oleh Barchi dkk. (2023) dan Ghassemi dkk. (2024).

Pada protokol pembagian resmi, risiko kebocoran dapat muncul ketika potongan dari video yang sama terdistribusi ke lebih dari satu *split*. Situasi ini dijelaskan oleh Barchi dkk. (2023), dan hasil evaluasi yang diperoleh kemudian dapat menjadi lebih tinggi karena model berhadapan dengan kondisi data uji yang masih memiliki kedekatan dengan data latih. Dalam konteks ini, kebocoran tidak selalu berarti duplikasi file yang persis sama, namun lebih sering muncul sebagai kemiripan sumber yang membuat data uji tidak benar benar independen dari data latih (Barchi dkk., 2023).

Risiko yang serupa juga dijelaskan pada *level* yang lebih tinggi oleh Ghassemi dkk. (2024), yaitu pada *level* kanal YouTube. Ketika video dari kanal yang sama tersebar ke *train*, validasi, dan *test*, hubungan antar sampel dapat terbentuk karena gaya perekaman dan karakteristik konteks kanal cenderung konsisten. Hal tersebut dapat membuat proses pengembangan model menjadi bias, karena pemilihan hiperparameter yang dilakukan berdasarkan validasi berpotensi ikut terbantu oleh kesamaan kanal antara *training* dan *validation*. Dalam studi tersebut, pembagian yang dibuat bebas ketergantungan pada *level* kanal ditujukan untuk mengurangi efek ini, sehingga pengukuran kinerja lebih mendekati kondisi generalisasi yang diharapkan Ghassemi dkk. (2024).

Ketika protokol pembagian dibuat lebih ketat, penurunan kinerja dapat terjadi karena model tidak lagi diuntungkan oleh kemiripan sumber antar *split*. Ghassemi dkk. (2024) melaporkan adanya penurunan kinerja ketika pembagian bebas ketergantungan diterapkan, dan temuan tersebut dapat dipandang sebagai indikasi bahwa pembagian yang mengandung ketergantungan memang cenderung memberi hasil evaluasi yang lebih optimistis. Dengan kata lain, perbedaan hasil antara *split* resmi dan *split* ketat dapat membantu menunjukkan seberapa besar pengaruh ketergantungan sumber terhadap evaluasi (Ghassemi dkk., 2024).

Selain memastikan independensi sumber antar *split*, keseimbangan distribusi juga perlu diperhatikan agar perbandingan kinerja lebih adil. Barchi dkk. (2023) menjelaskan bahwa proses pembagian dapat dilakukan dengan mempertimbangkan distribusi atribut seperti gender dan *ethnicity*, serta ringkasan label yang dihitung dari lima *trait*, sehingga karakteristik set pelatihan, validasi, dan pengujian tidak jauh berbeda. Pendekatan ini membantu mengurangi kemungkinan bahwa kinerja yang terlihat baik hanya dipengaruhi oleh komposisi set uji yang lebih mudah, bukan karena model yang lebih baik (Barchi dkk., 2023).

Berdasarkan uraian tersebut, protokol pembagian data pada penelitian ini secara prinsip diarahkan pada dua hal. Independensi sumber antar *split* dijaga untuk menekan kemungkinan


kebocoran, dan distribusi atribut penting dijaga agar perbandingan hasil antar skenario tetap wajar. Rincian implementasi teknis terkait pembentukan unit kelompok dan prosedur pembagiannya ditempatkan pada Bab 3, sedangkan bagian ini menekankan alasan konseptual dan risiko yang ingin dikurangi melalui protokol pembagian yang lebih ketat (Barchi dkk., 2023; Ghassemi dkk., 2024).

2.2.6 Transformer

Transformer merupakan arsitektur jaringan saraf untuk pemodelan data berurutan yang dibangun dengan mekanisme atensi. Pada pendekatan ini, ketergantungan antarposisi dalam suatu urutan tidak perlu dimodelkan melalui proses rekuren, karena hubungan antarposisi dapat dihitung langsung melalui *self-attention*. Arsitektur Transformer diperkenalkan dalam konteks *sequence transduction* berbasis struktur *encoder* dan *decoder*, lalu ditunjukkan bahwa tumpukan *self-attention* dan *feed-forward network* dapat digunakan sebagai komponen utama pemodelan urutan (Vaswani dkk., 2017).

a) Gambaran umum arsitektur Transformer

Pada Transformer, sebuah *encoder* digunakan untuk memetakan urutan masukan menjadi representasi kontinu, lalu *decoder* digunakan untuk menghasilkan urutan keluaran secara autoregresif. Arsitektur lengkap *encoder* dan *decoder* ditampilkan pada gambar utama paper tersebut.



Gambar 2.1 Arsitektur Transformer (Vaswani dkk., 2017)

Pada bagian *encoder*, beberapa lapisan identik ditumpuk. Pada paper Vaswani dkk. (2017), jumlah lapisan *encoder* ditetapkan $N = 6$. Setiap lapisan *encoder* terdiri dari dua sublapisan, yaitu *multi-head self-attention* dan *position-wise feed-forward network*. Pada bagian *decoder*, struktur yang mirip digunakan, namun satu sublapisan tambahan diberikan untuk melakukan atensi ke keluaran *encoder*. Selain itu, *masking* diterapkan pada *self-attention* di *decoder* agar sebuah posisi tidak “melihat” token pada posisi setelahnya, sehingga sifat autoregresif tetap terjaga (Vaswani dkk., 2017).

b) *Residual connection* dan *layer normalization*


Pada setiap sublapisan *encoder* maupun *decoder*, koneksi *Residual* dan normalisasi digunakan agar pelatihan tetap stabil. Bentuk umum operasi yang digunakan dinyatakan pada persamaan 2.4 sebagai berikut.

$$\text{LayerNorm}(x + \text{Sublayer}(x)) \quad (2.4)$$

Pada persamaan tersebut, $\text{Sublayer}(x)$ menyatakan fungsi yang diimplementasikan oleh sublapisan, misalnya atensi atau *feed-forward*. Agar penjumlahan *Residual* dapat dilakukan secara konsisten, seluruh sublapisan disusun untuk menghasilkan dimensi keluaran yang sama, yang pada konfigurasi dasar paper tersebut dinyatakan sebagai $d_{\text{model}} = 512$ (Vaswani dkk., 2017).

c) Mekanisme atensi dan Scaled Dot-Product Attention

Sebuah fungsi atensi dipandang sebagai pemetaan dari *query* dan sekumpulan pasangan *key* dan *value* menjadi keluaran berbentuk penjumlahan berbobot atas *value*. Bobot dihitung menggunakan fungsi kompatibilitas antara *query* dan *key* (Vaswani dkk., 2017). Pada paper tersebut, bentuk atensi yang digunakan adalah *Scaled Dot-Product Attention*. Mekanismenya ditunjukkan pada gambar berikut.



Gambar 2.2 Scaled Dot-Product Attention dan Multi-head Attention (Vaswani dkk., 2017)

Jika Q, K, dan V masing masing menyatakan matriks *query*, *key*, dan *value*, maka keluaran atensi dihitung sebagai berikut.

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.5)$$

Pada rumus tersebut, pembagian dengan $\sqrt{d_k}$ digunakan untuk mengendalikan skala hasil perkalian titik, karena nilai dot product dapat membesar seiring dimensi d_k dan dapat mendorong *softmax* ke area dengan gradien yang kecil (Vaswani dkk., 2017).

d) *Multi-head Attention*

Agar informasi dari beberapa subruang representasi dapat dipertimbangkan, atensi tidak dihitung hanya sekali. Proyeksi linear terpisah diterapkan untuk membentuk beberapa kepala atensi, lalu hasilnya digabungkan. Definisi yang digunakan pada paper tersebut dituliskan sebagai berikut.

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O \quad (2.6)$$

Dengan

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (2.7)$$

Pada konfigurasi dasar, jumlah kepala ditetapkan $h = 8$, dan dimensi per kepala dipilih $d_k = d_v = \frac{d_{model}}{h} = 64$. Matriks proyeksi W_i^Q , W_i^K , W_i^V , dan W^O dipelajari selama pelatihan (Vaswani dkk., 2017).

e) *Position-wise Feed-Forward Network*

Selain atensi, setiap lapisan *encoder* dan *decoder* memuat *feed-forward network* yang diterapkan secara identik pada setiap posisi urutan. Bentuk yang digunakan pada paper tersebut adalah dua transformasi linear dengan aktivasi ReLU.

$$FFN(x) = max(0, xW_1 + b_1)W_2 + b_2 \quad (2.8)$$

Pada konfigurasi dasar, dimensi masukan dan keluaran FFN sama dengan $d_{model} = 512$, sedangkan dimensi lapisan tersembunyi ditetapkan $d_{ff} = 2048$ (Vaswani dkk., 2017).

f) *Embedding, softmax, dan pembobotan skala*

Untuk mengubah token diskrit menjadi vektor kontinu, *embedding* dipelajari dengan dimensi d_{model} . Pada paper Vaswani dkk. (2017), bobot *embedding* juga dibagi dengan transformasi linear sebelum *softmax* pada keluaran *decoder*. Selain itu, *embedding* dikalikan dengan $\sqrt{d_{model}}$ agar skala representasi lebih sesuai ketika dijumlahkan dengan *positional encoding* (Vaswani dkk., 2017).

g) *Positional encoding*

Karena Transformer tidak memakai rekuren maupun konvolusi, informasi urutan perlu disisipkan secara eksplisit. Hal ini dilakukan dengan menambahkan *positional encoding* ke *embedding* pada bagian bawah tumpukan *encoder* dan *decoder*. Pada paper tersebut, *positional encoding* sinusoidal digunakan sebagai berikut.

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) \quad (2.9)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right) \quad (2.10)$$

Pada rumus di atas, pos menyatakan indeks posisi token, sedangkan i menyatakan indeks dimensi. Bentuk sinus dan cosinus dengan frekuensi berbeda dipilih agar relasi posisi relatif dapat dipelajari lebih mudah oleh model, karena pergeseran posisi tertentu dapat direpresentasikan melalui transformasi linear terhadap *encoding* posisi lain (Vaswani dkk., 2017).

h) Catatan kompleksitas dan jalur ketergantungan

Perbandingan konseptual antara *self-attention*, rekuren, dan konvolusi juga dibahas melalui kompleksitas per lapisan, jumlah operasi sekuensial minimum, dan panjang jalur maksimum antarposisi. Pada ringkasan yang ditampilkan di paper, *self-attention* memiliki jumlah operasi sekuensial minimum yang konstan, sedangkan lapisan rekuren memerlukan operasi sekuensial yang bertambah seiring panjang urutan (Vaswani dkk., 2017).


Tabel 2.2 Ringkasan kompleksitas dan *path length* beberapa tipe lapisan (Vaswani dkk., 2017)

Jenis lapisan	Kompleksitas per lapisan	Operasi sekuensial	Panjang jalur maksimum
<i>Self attention</i>	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Rekuren	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Konvolusional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log n_k(n))$
<i>Self attention</i> terbatas	$O(r \cdot n \cdot d)$	$O(1)$	$O\left(\frac{n}{r}\right)$

Perbandingan karakteristik komputasi beberapa jenis lapisan pada pemodelan sekuens telah diringkas pada Tabel 2.2. Pada tabel tersebut, kompleksitas per lapisan untuk *self attention* dinyatakan sebagai $O(n^2 \cdot d)$, sementara jumlah operasi sekuensial minimum dinyatakan $O(1)$ dan panjang jalur maksimum antarpotongan urutan dinyatakan $O(1)$. Untuk lapisan rekuren, kompleksitas per lapisan dituliskan $O(n \cdot d^2)$ dengan operasi sekuensial $O(n)$ dan panjang jalur maksimum $O(n)$. Pada lapisan konvolusional, kompleksitas per lapisan dinyatakan $O(k \cdot n \cdot d^2)$ dengan operasi sekuensial $O(1)$ dan panjang jalur maksimum $O(\log n_k(n))$. Selain itu, *restricted self attention* dituliskan memiliki kompleksitas $O(r \cdot n \cdot d)$ dengan operasi sekuensial $O(1)$ dan panjang jalur maksimum $O\left(\frac{n}{r}\right)$ (Vaswani dkk., 2017). Pada Tabel 2.2, n digunakan untuk menyatakan panjang urutan, d digunakan untuk menyatakan dimensi representasi, k digunakan untuk menyatakan ukuran kernel pada konvolusi, dan r digunakan untuk menyatakan ukuran lingkungan yang diperhatikan pada *restricted self attention* (Vaswani dkk., 2017).

2.2.7 Kerangka Pembelajaran Representasi Ucapan Berbasis *Self-Supervised*: wav2vec 2.0

wav2vec 2.0 diperkenalkan sebagai kerangka pembelajaran representasi ucapan secara *self supervised* yang memakai audio mentah sebagai masukan, lalu representasi yang dihasilkan dapat dipakai kembali pada tugas berlabel melalui tahap *fine-tuning*. Gambaran alur model dari sinyal audio hingga perhitungan *Loss* kontrasif ditampilkan pada ilustrasi arsitektur, sehingga keterkaitan antara *feature encoder*, *context network*, dan modul kuantisasi dapat dilihat secara utuh pada Gambar 2.3 (Baevski dkk., 2020).



Gambar 2.3 Kerangka wav2vec 2.0 (Baevski dkk., 2020)

Misalkan sinyal ucapan dinyatakan sebagai X . Sinyal ini dipetakan oleh *feature encoder* f menjadi urutan representasi laten $Z = \{z_t\}_{t=1}^T$, sehingga pemetaan dapat dituliskan sebagai $f: X \rightarrow Z$. Selanjutnya, representasi laten tersebut diproses oleh *context network* g berbasis Transformer untuk membentuk representasi kontekstual $C = \{c_t\}_{t=1}^T$, sehingga $g: Z \rightarrow C$ (Baevski et al., 2020, p. 2). Pada saat yang sama, target untuk pembelajaran kontrasif dibentuk dari representasi diskret $Q = \{q_t\}$ yang dihasilkan oleh modul kuantisasi, sehingga target diskret tersebut dipakai sebagai acuan ketika langkah waktu tertentu pada Z dimask dan harus diprediksi melalui konteks C (Baevski dkk., 2020).

Kuantisasi pada wav2vec 2.0 dijelaskan melalui product quantization, yaitu beberapa codebook dipakai secara paralel, kemudian satu entri dipilih dari tiap codebook, hasilnya digabungkan, lalu diproyeksikan untuk membentuk vektor target diskret. Apabila jumlah codebook dinyatakan sebagai G dan tiap codebook memiliki V entri $e \in \mathbb{R}^{V \times \frac{d}{G}}$, maka satu entri dipilih dari masing masing codebook untuk menghasilkan $(e_1, \dots, e_G)$. Vektor tersebut kemudian dikonkatenasi dan ditransformasikan secara linear dari $\mathbb{R}^d$ ke $\mathbb{R}^f$ untuk memperoleh $q \in \mathbb{R}^f$. Mekanisme pemilihan entri dibuat tetap dapat diturunkan gradiennya melalui Gumbel *Softmax*, sehingga pembelajaran end to end masih dapat dilakukan walaupun target yang dipakai bersifat diskret (Baevski dkk., 2020).

Untuk Gumbel *Softmax*, keluaran *encoder* z dipetakan menjadi logits $l \in \mathbb{R}^{G \times V}$. Probabilitas pemilihan entri ke v pada kelompok g didefinisikan sebagai berikut.

$$p_{g,v} = \frac{\exp((l_{g,v} + n_v)/\tau)}{\sum_{k=1}^V \exp(l_{g,k} + n_k/\tau)} \quad (2.11)$$

Pada definisi tersebut, τ dinyatakan sebagai parameter temperatur dan *noise* Gumbel dinyatakan sebagai $n = -\log(-\log u)$ dengan $u \sim U(0,1)$. Pemilihan diskret pada *forward* pass dijelaskan dapat dilakukan melalui operasi *argmax*, sedangkan estimasi gradien dijaga melalui *straight through estimator* agar parameter masih dapat diperbarui (Baevski dkk., 2020).

Masking pada *wav2vec 2.0* tidak diterapkan pada *waveform*, tetapi diterapkan pada urutan laten Z sebelum masuk ke *context network*. Sejumlah indeks awal dipilih tanpa pengembalian dengan proporsi tertentu, lalu setiap indeks awal diperluas menjadi *span* sepanjang M langkah waktu yang dilakukan *masking*, dan *span* yang terbentuk dinyatakan boleh saling tumpang tindih. Posisi yang dilakukan *masking* kemudian diganti oleh satu vektor *mask* terlatih yang dipakai bersama, sedangkan masukan ke modul kuantisasi dinyatakan tidak dilakukan *masking*, sehingga target diskret q_t tetap berasal dari representasi laten asli (Baevski dkk., 2020).

Pada tahap pralatih, *objective* dilaporkan disusun sebagai gabungan *Loss* kontrasif dan *Loss* diversitas codebook. Bentuk total *Loss* dituliskan sebagai berikut.

$$L_m = -\log \left(\frac{\exp(\text{sim}(c_t, q_t)/\kappa)}{\sum_{\tilde{q} \in Q_t} \exp(\text{sim}(c_t, \tilde{q})/\kappa)} \right) \quad (2.12)$$

Pada persamaan tersebut, κ dinyatakan sebagai temperatur, sedangkan kemiripan dihitung menggunakan *cosine similarity*, yaitu

$$\text{sim}(a, b) = \frac{a^\top b}{\|a\| \|b\|} \quad (2.13)$$

Agar penggunaan entri codebook tidak terkonsentrasi pada sebagian kecil entri, *Loss* diversitas L_d ditambahkan dengan cara mendorong entropi distribusi pemilihan entri pada tiap codebook menjadi besar (Baevski dkk., 2020). Jika $\bar{p}_g$ dinyatakan sebagai distribusi rata rata untuk codebook ke g , maka *Loss* diversitas dituliskan sebagai berikut.

$$L_d = \frac{1}{GV} \sum_{g=1}^G -H(\bar{p}_g) = \frac{1}{GV} \sum_{g=1}^G \sum_{v=1}^V \bar{p}_{g,v} \log \bar{p}_{g,v} \quad (2.14)$$

Setelah pralatih, *fine-tuning* untuk pengenalan ujaran dijelaskan dilakukan dengan menambahkan proyeksi linear acak di atas *context network* ke C kelas, kemudian optimisasi dilakukan menggunakan CTC (*Connectionist Temporal Classification*). Pada fase ini, *masking* tambahan selama pelatihan juga dijelaskan diterapkan melalui versi modifikasi SpecAugment, yaitu *masking* pada dimensi waktu dan kanal, sehingga kecenderungan *overfitting* dilaporkan dapat ditekan pada pengaturan data berlabel yang terbatas. Ringkasan hasil evaluasi WER (*Word Error Rate*) pada beberapa skenario jumlah data berlabel kemudian disajikan pada Tabel

2.3 dibawah ini sebagai bagian dari pelaporan eksperimen, sehingga konteks pemakaian pralatih dan *fine-tuning* pada tugas ASR dapat ditinjau secara empiris (Baevski dkk., 2020).


Tabel 2.3 Perbandingan WER LibriSpeech pada variasi jumlah data berlabel dan sumber data tak berlabel (Baevski dkk., 2020)

Labeled setup	Model	Unlabeled data	LM	dev clean	dev other	test clean	test other
10 min	<i>Discrete</i> BERT	LS-960	4-gram	15.7	24.1	16.3	25.2
	wav2vec 2.0 BASE	LS-960	4-gram	8.9	15.7	9.1	15.6
	wav2vec 2.0 BASE	LS-960	Transf.	6.6	13.2	6.9	12.9
	wav2vec 2.0 <i>LARGE</i>	LS-960	Transf.	6.6	10.6	6.8	10.8
	wav2vec 2.0 <i>LARGE</i>	LV-60k	Transf.	4.6	7.9	4.8	8.2
1 h	<i>Discrete</i> BERT	LS-960	4-gram	8.5	16.4	9.0	17.6
	wav2vec 2.0 BASE	LS-960	4-gram	5.0	10.8	5.5	11.3
	wav2vec 2.0 BASE	LS-960	Transf.	3.8	9.0	4.0	9.3
	wav2vec 2.0 <i>LARGE</i>	LS-960	Transf.	3.8	7.1	3.9	7.6
	wav2vec 2.0 <i>LARGE</i>	LV-60k	Transf.	2.9	5.4	2.9	5.8
10 h	<i>Discrete</i> BERT	LS-960	4-gram	5.3	13.2	5.9	14.1
	<i>Iterative pseudo-labeling</i>	LS-960	4-gram dan Transf.	23.51	25.48	24.37	26.02
	<i>Iterative pseudo-labeling</i>	LV-60k	4-gram dan Transf.	17.00	19.34	18.03	19.92
	wav2vec 2.0 BASE	LS-960	4-gram	3.8	9.1	4.3	9.5

	wav2vec 2.0 BASE	LS-960	Transf.	2.9	7.4	3.2	7.8
	wav2vec 2.0 <i>LARGE</i>	LS-960	Transf.	2.9	5.7	3.2	6.1
	wav2vec 2.0 <i>LARGE</i>	LV-60k	Transf.	2.4	4.8	2.6	4.9
100 h	<i>Hybrid DNN/HMM</i>	-	4-gram	5.0	19.5	5.8	18.6
	TTS data <i>augmentation</i>	-	LSTM	N/A	N/A	4.3	13.5
	<i>Discrete BERT</i>	LS-960	4-gram	4.0	10.9	4.5	12.1
	<i>Iterative pseudo-labeling</i>	LS-860	4-gram dan Transf.	4.98	7.97	5.59	8.95
	<i>Iterative pseudo-labeling</i>	LV-60k	4-gram dan Transf.	3.19	6.14	3.72	7.11
	<i>Noisy student</i>	LS-860	LSTM	3.9	8.8	4.2	8.6
	wav2vec 2.0 BASE	LS-960	4-gram	2.7	7.9	3.4	8.0
	wav2vec 2.0 BASE	LS-960	Transf.	2.2	6.3	2.6	6.3
	wav2vec 2.0 <i>LARGE</i>	LS-960	Transf.	2.1	4.8	2.3	5.0
	wav2vec 2.0 <i>LARGE</i>	LV-60k	Transf.	1.9	4.0	2.0	4.0

2.2.8 Kerangka Pembelajaran Representasi Ucapan Berbasis *Masked Prediction*: HuBERT

HuBERT diperkenalkan sebagai pendekatan pembelajaran representasi ucapan secara *self supervised* yang memanfaatkan prediksi unit tersembunyi pada bagian masukan yang dilakukan *masking*, dengan target yang diperoleh dari proses *clustering* secara *offline*. Alur umum HuBERT, mulai dari pemberian label *cluster* untuk tiap *frame* hingga prediksi pada *frame* yang dilakukan *masking*, ditunjukkan pada Gambar 2.4 sehingga peran target hasil *clustering* sebagai label terjajar dapat ditinjau secara langsung (Hsu dkk., 2021).



Gambar 2.4 Skema HuBERT untuk memprediksi *assignment cluster* pada *frame* yang dilakukan *masking* (Hsu dkk., 2021).

Pada formulasi metode, sebuah ujaran dinyatakan sebagai urutan *frame* $X = [x_1, \dots, x_T]$ dengan panjang T . Unit tersembunyi yang ditemukan melalui *clustering* dinyatakan sebagai $h(X) = Z = [z_1, \dots, z_T]$, dengan $z_t \in [C]$ sebagai variabel kategorikal dengan C kelas, dan h dapat berupa k *means*. Target Z ini tidak diasumsikan sebagai transkripsi fonetik yang benar, namun konsistensinya diperlakukan sebagai aspek yang penting agar struktur sekuens pada data ucapan dapat dipelajari melalui *objective* prediksi bertipe BERT (Hsu dkk., 2021).

a) *Masked prediction* pada unit tersembunyi

Misalkan $M \subset [T]$ menyatakan himpunan indeks yang dilakukan *masking*. Masukan yang sudah dikorupsi dinyatakan sebagai $\tilde{X} = r(X, M)$, yaitu x_t diganti dengan *embedding mask* $\tilde{x}$ untuk setiap $t \in M$ (Hsu dkk., 2021). Sebuah model prediksi bertipe *masked prediction* dinyatakan sebagai f , lalu distribusi kelas pada tiap langkah waktu dinyatakan sebagai $p_f(z_t | \tilde{X}, t)$. *Loss cross entropy* pada posisi yang dilakukan *masking* dinyatakan sebagai

$$L_m(f; X, M, Z) = - \sum_{t \in M} \log p_f(z_t | \tilde{X}, t) \quad (2.15)$$

dan *loss* pada posisi yang tidak dilakukan *masking* dinyatakan serupa, yaitu

$$L_u(f; X, M, Z) = - \sum_{t \notin M} \log p_f(z_t | \tilde{X}, t) \quad (2.16)$$

Total *loss* kemudian dirumuskan sebagai gabungan berbobot

$$L = \alpha L_m + (1 - \alpha) L_u \quad (2.17)$$

dengan α mengatur porsi kontribusi *loss* pada *frame* yang dilakukan *masking*. Pada pengaturan HuBERT, *loss* pada *frame* yang dilakukan *masking* dijadikan fokus utama melalui pemilihan $\alpha = 1$, sehingga target pada *frame* yang tidak terlihat harus diinferensi dari konteks, dan pembelajaran relasi temporal jarak jauh menjadi terdorong tanpa bergantung penuh pada kualitas label *cluster*. Hasil *ablation* terkait perbedaan α dan kualitas *clustering* dilaporkan pada Tabel 2.4, sehingga dampak pemakaian *loss* hanya pada *frame* yang dilakukan *masking* dapat ditinjau dari metrik WER pada pengaturan eksperimen yang terkontrol (Hsu dkk., 2021).

Tabel 2.4 Pengaruh *objective* pelatihan dan kualitas *clustering* terhadap kinerja pada *dev-other* WER (Hsu dkk., 2021)

Teacher (guru)	C	PNMI	WER dev- other $\alpha=1.0$	WER dev- other $\alpha=0.5$	WER dev- other $\alpha=0.0$
Chenone (<i>supervised</i> top-line)	8976	0.809	10.38	9.16	9.79
K-means pada MFCC	50	0.227	18.68	31.07	94.60
K-means pada MFCC	100	0.243	17.86	29.57	96.37
K-means pada MFCC	500	0.276	18.40	33.42	97.66
K-means pada BASE- it1-layer6	500	0.637	11.91	13.47	23.29
K-means pada BASE- it2-layer9	500	0.704	10.75	11.59	13.79

Strategi *masking* dijelaskan mengikuti pola *span masking*, yaitu sebagian indeks dipilih sebagai titik awal dengan proporsi tertentu, lalu *span* sepanjang l langkah waktu dilakukan *masking*. Pola ini dipakai agar konteks di sekitar *span* perlu dimodelkan untuk memprediksi target pada *span* yang hilang, sementara struktur sekuens tetap dipertahankan (Hsu dkk., 2021).

b) *Ensemble* target dan *objective* multi target


Kualitas target dinyatakan dapat ditingkatkan dengan memakai beberapa model *clustering*, sehingga target dari beberapa granularitas dapat dipelajari secara bersamaan. Misalkan target dari *clustering* ke k dinyatakan sebagai $Z^{(k)}$. *Loss* pada posisi yang dilakukan *masking* kemudian dituliskan sebagai penjumlahan lintas model *clustering*

$$L_m(f; X, Z^{(k)}_k, M) = - \sum_{t \in M} \sum_k \log p_f^{(k)}(z_t^{(k)} | \tilde{X}, t) \quad (2.18)$$

Formulasi ini diperlakukan serupa dengan *multitask learning*, namun tugasnya dibentuk dari proses *unsupervised clustering* (Hsu dkk., 2021).

c) *Iterative refinement* pada label *cluster*

Refinement iteratif dijelaskan dilakukan dengan cara membangun *cluster* baru dari representasi laten yang dihasilkan model HuBERT pada iterasi sebelumnya, sehingga unit tersembunyi yang dipakai sebagai target dapat berubah mengikuti peningkatan kualitas representasi. Pada pelaporan eksperimen, proses ini dicontohkan melalui penggunaan *k means* pada fitur MFCC untuk iterasi awal, lalu *k means* dijalankan kembali pada fitur dari *layer* Transformer tertentu pada model yang sudah dipelajari untuk membentuk target pada iterasi berikutnya. Analisis kualitas *clustering* lintas *layer* dan lintas iterasi divisualisasikan pada Figure 2, sehingga perubahan metrik seperti *phone purity*, *cluster purity*, dan PNMI dapat diamati ketika fitur yang dipakai untuk *clustering* dipindahkan antar *layer* (Hsu dkk., 2021).



Gambar 2.5 Kualitas *assignment cluster* dari fitur tiap *layer* dan tiap iterasi (Hsu dkk., 2021)

d) Arsitektur dan parameterisasi distribusi kelas

Implementasi HuBERT dijelaskan mengikuti kerangka arsitektur wav2vec 2.0, yaitu memakai *convolutional waveform encoder*, BERT *encoder* berbasis blok Transformer, lapisan proyeksi, dan *embedding* untuk kode target. Ringkasan konfigurasi ukuran model yang dipakai, yaitu BASE, *LARGE*, dan X *LARGE*, disajikan pada Tabel 2.5 yang memuat jumlah *layer* Transformer, dimensi *embedding*, dimensi *feed forward*, jumlah *head* atensi, serta jumlah parameter (Hsu dkk., 2021).

Tabel 2.5 Ringkasan arsitektur model HuBERT untuk BASE, *LARGE*, dan X-*LARGE* (Hsu dkk., 2021)

Komponen	Parameter	BASE	<i>LARGE</i>	X- <i>LARGE</i>
CNN <i>Encoder</i>	Strides	5, 2, 2, 2, 2, 2, 2	5, 2, 2, 2, 2, 2, 2	5, 2, 2, 2, 2, 2, 2
CNN <i>Encoder</i>	Lebar kernel	10, 3, 3, 3, 3, 2, 2	10, 3, 3, 3, 3, 2, 2	10, 3, 3, 3, 3, 2, 2
CNN <i>Encoder</i>	<i>Channel</i>	512	512	512
Transformer	Jumlah <i>layer</i>	12	24	48
Transformer	Dimensi <i>embedding</i>	768	1024	1280
Transformer	Dimensi FFN internal	3072	4096	5120
Transformer	Probabilitas <i>layerdrop</i>	0.05	0	0
Transformer	Jumlah <i>head</i> atensi	8	16	16
Projection	Dimensi	256	768	1024
Total parameter	Jumlah parameter	95M	317M	964M

e) *Fine-tuning* untuk ASR dan ringkasan hasil eksperimen

Pada tahap *fine-tuning* untuk pengenalan ujaran, *objective* CTC digunakan, dan seluruh bobot model dioptimasi kecuali *convolutional audio encoder* yang dipertahankan dalam keadaan *frozen*, lalu lapisan proyeksi pada pralatih diganti dengan *softmax* baru yang diinisialisasi acak. Ringkasan perbandingan kinerja pada skenario low resource disajikan pada Tabel 2.6, sedangkan perbandingan pada pengaturan high resource dengan seluruh data berlabel Librispeech disajikan pada Tabel 2.7, sehingga pengaruh ukuran model dan jumlah data *fine-tuning* terhadap WER dapat ditinjau pada beberapa kondisi pelatihan (Hsu dkk., 2021).

Tabel 2.6 Hasil dan perbandingan pada pengaturan *low resource LibriSpeech* untuk 10 menit, 1 jam, 10 jam, dan 100 jam data berlabel (Hsu dkk., 2021).

Skenario data berlabel	Model	Data tak berlabel	LM	dev-clean	dev-other	test-clean	test-other
10 menit	DiscreteBERT	LS-960	4-gram	15.7	24.1	16.3	25.2
	wav2vec 2.0 BASE	LS-960	4-gram	8.9	15.7	9.1	15.6
	wav2vec 2.0 <i>LARGE</i>	LL-60k	4-gram	6.3	9.8	6.6	10.3
	wav2vec 2.0 <i>LARGE</i>	LL-60k	Transformer	4.6	7.9	4.8	8.2
	HuBERT BASE	LS-960	4-gram	9.1	15.0	9.7	15.3
	HuBERT <i>LARGE</i>	LL-60k	4-gram	6.1	9.4	6.6	10.1
	HuBERT <i>LARGE</i>	LL-60k	Transformer	4.3	7.0	4.7	7.6
	HuBERT <i>X-LARGE</i>	LL-60k	Transformer	4.4	6.1	4.6	6.8
1 jam	DeCoAR 2.0	LS-960	4-gram	-	-	13.8	29.1
	DiscreteBERT	LS-960	4-gram	8.5	16.4	9.0	17.6
	wav2vec 2.0 BASE	LS-960	4-gram	5.0	10.8	5.5	11.3
	wav2vec 2.0 <i>LARGE</i>	LL-60k	Transformer	2.9	5.4	2.9	5.8
	HuBERT BASE	LS-960	4-gram	5.6	10.9	6.1	11.3
	HuBERT <i>LARGE</i>	LL-60k	Transformer	2.6	4.9	2.9	5.4
	HuBERT <i>X-LARGE</i>	LL-60k	Transformer	2.6	4.2	2.8	4.8
10 jam	SlimIPL	LS-960	4-gram dan Transformer	5.3	7.9	5.5	9.0

	DeCoAR 2.0	LS-960	4-gram	-	-	5.4	13.3
	DiscreteBERT	LS-960	4-gram	5.3	13.2	5.9	14.1
	wav2vec 2.0 BASE	LS-960	4-gram	3.8	9.1	4.3	9.5
	wav2vec 2.0 <i>LARGE</i>	LL-60k	Transformer	2.4	4.8	2.6	4.9
	HuBERT BASE	LS-960	4-gram	3.9	9.0	4.3	9.4
	HuBERT <i>LARGE</i>	LL-60k	Transformer	2.2	4.3	2.4	4.6
	HuBERT <i>X-LARGE</i>	LL-60k	Transformer	2.1	3.6	2.3	4.0
100 jam	IPL	LL-60k	4-gram dan Transformer	3.19	6.14	3.72	7.11
	SlimIPL	LS-860	4-gram dan Transformer	2.2	4.6	2.7	5.2
	Noisy Student	LS-860	LSTM	3.9	8.8	4.2	8.6
	DeCoAR 2.0	LS-960	4-gram	-	-	5.0	12.1
	DiscreteBERT	LS-960	4-gram	4.0	10.9	4.5	12.1
	wav2vec 2.0 BASE	LS-960	4-gram	2.7	7.9	3.4	8.0
	wav2vec 2.0 <i>LARGE</i>	LL-60k	Transformer	1.9	4.0	2.0	4.0
	HuBERT BASE	LS-960	4-gram	2.7	7.8	3.4	8.1
	HuBERT <i>LARGE</i>	LL-60k	Transformer	1.8	3.7	2.1	3.9
	HuBERT <i>X-LARGE</i>	LL-60k	Transformer	1.7	3.0	1.9	3.5

Tabel 2.7 Perbandingan dengan literatur pada pengaturan *high resource LibriSpeech* menggunakan 960 jam data berlabel (Hsu dkk., 2021)


Kategori	Model	Data tak berlabel	LM	dev-clean	dev-other	test-clean	test-other
<i>Supervised</i>	Conformer L	-	LSTM	-	-	1.9	3.9
<i>Self-Training</i>	IPL	LL-60k	4-gram dan Transformer	1.85	3.26	2.10	4.01
<i>Self-Training</i>	Noisy Student	LV-60k	LSTM	1.6	3.4	1.7	3.4
<i>Pre-Training</i>	wav2vec 2.0 <i>LARGE</i>	LL-60k	Transformer	1.6	3.0	1.8	3.3
<i>Pre-Training</i>	pre-trained Conformer XXL	LL-60k	LSTM	1.5	3.0	1.5	3.1
<i>Pre-Training dan Self-Training</i>	wav2vec 2.0 dan <i>self-training</i>	LL-60k	Transformer	1.1	2.7	1.5	3.1
<i>Pre-Training dan Self-Training</i>	pre-trained Conformer XXL dan Noisy Student	LL-60k	LSTM	1.3	2.6	1.4	2.6
Karya ini (Pre-Training)	HuBERT <i>LARGE</i>	LL-60k	Transformer	1.5	3.0	1.9	3.3
Karya ini (Pre-Training)	HuBERT <i>X-LARGE</i>	LL-60k	Transformer	1.5	2.5	1.8	2.9

2.2.9 Kerangka Pra-latih Ujaran untuk Tugas Umum: WavLM

WavLM diperkenalkan sebagai model pralatih *self supervised* untuk pemrosesan suara yang ditujukan agar representasi yang dipelajari dapat digunakan pada berbagai tugas, tidak hanya pengenalan ujaran. Pada sinyal suara, informasi yang berkaitan dengan konten ujaran, identitas

pembicara, dan aspek paralinguistik dapat muncul secara bersamaan, sehingga representasi universal perlu dibentuk melalui rancangan objektif dan data pralatih yang sesuai. Pada WavLM, pemodelan *masked speech prediction* tetap dipertahankan seperti pada pendekatan berbasis unit diskret, namun pembelajaran juga diarahkan melalui denoising dengan cara masukan dibuat menyerupai ucapan yang bising atau tumpang tindih antar pembicara. Dengan strategi tersebut, representasi diharapkan tidak hanya memadai untuk tugas ASR, tetapi juga dapat mendukung tugas non ASR seperti diarization dan separation. Selain itu, pada *backbone* Transformer ditambahkan *Gated relative position* bias agar informasi urutan dapat dimodelkan dengan lebih adaptif, dan data pralatih diperluas menjadi campuran 94 ribu jam dari beberapa sumber untuk mengurangi ketidakcocokan domain (Chen dkk., 2022).

Arsitektur WavLM disusun dari *convolutional feature encoder* dan Transformer *encoder*. *Convolutional encoder* dibentuk dari tujuh blok konvolusi temporal yang diikuti *layer normalization* dan aktivasi GELU, dengan 512 *channel*, stride (5, 2, 2, 2, 2, 2, 2) dan lebar kernel (10, 3, 3, 3, 3, 2, 2). Dengan konfigurasi ini, satu keluaran representasi dipetakan untuk kurang lebih 25 ms audio dengan pergeseran 20 ms. Keluaran konvolusi kemudian dimasking dan dipakai sebagai masukan Transformer. Skema umum arsitektur tersebut dapat dilihat pada Gambar 2.6(Chen dkk., 2022).



Gambar 2.6 Arsitektur WavLM (Chen dkk., 2022)

a) *Gated relative position* bias pada *self attention*

Pada modul *self attention*, state masukan dinotasikan sebagai $\{h_i\}_{i=1}^T$. Proyeksi linear untuk *query*, *key*, dan *value* dituliskan sebagai berikut.

$$q_i, k_i, v_i = h_i W_Q, h_i W_K, h_i W_V \quad (2.19)$$

Bobot atensi untuk pasangan indeks i dan j dihitung dari logit yang ditambah bias posisi relatif r_{i-j} .

$$a_{(ij)} \propto \exp\left((q_i \cdot k_j)/\sqrt{d_k} + r_{(i-j)}\right) \quad (2.20)$$

Keluaran *self attention* dinyatakan sebagai kombinasi berbobot dari *value*.

$$\tilde{h}_i = \sum (j = 1)^T a_{(ij)} v_j \quad (2.21)$$

Bias posisi relatif pada WavLM dibentuk dengan mekanisme gate yang dikondisikan pada *query*. Dua gate dihitung memakai fungsi sigmoid.

$$\begin{aligned} g_i^{(update)} &= \sigma(q_i \cdot u), g_i^{(reset)} = \sigma(q_i \cdot w) \\ \widetilde{r_{(i-j)}} &= \omega g_i^{(reset)} d_{(i-j)} \\ r_{(i-j)} &= d_{(i-j)} + g_i^{(update)} d_{(i-j)} + (1 - g_i^{(update)}) \widetilde{r_{(i-j)}} \end{aligned} \quad (2.22)$$

Pada persamaan tersebut, d_{i-j} merupakan parameter bias posisi relatif yang dapat dipelajari, ω adalah parameter vektor yang dapat dipelajari, ω adalah parameter skalar yang dapat dipelajari, dan $\sigma(\cdot)$ adalah sigmoid. Untuk membatasi jumlah parameter, d_{i-j} dibentuk sebagai bucket *relative position embedding* yang dipakai bersama pada semua *layer* Transformer. Jumlah *embedding* dinyatakan dengan n , dan jarak maksimum dinyatakan dengan m . Pemetaannya dituliskan pada persamaan berikut.

$$d_{|i-j|} = \begin{cases} |i-j|, & |i-j| < \frac{n}{4} \\ \left\lceil \frac{n}{4} \left(\frac{\log(|i-j|) - \log(\frac{n}{4})}{\log m - \log \frac{n}{4}} + 1 \right) \right\rceil, & \frac{n}{4} \leq |i-j| \leq m \\ \frac{n}{2} - 1, & |i-j| \geq m \end{cases} \quad (2.25)$$

Arah pergeseran ditambahkan dengan indikator untuk membedakan offset positif dan negatif.

$$d_{(i-j)} = d_{(|i-j|)} + n/21_{(i-j>0)} \quad (2.24)$$

Dengan cara tersebut, bias posisi relatif dapat berubah mengikuti konten pada *frame* yang sedang diproses, sehingga peran jarak yang sama dapat berbeda ketika kondisi sinyal berubah, misalnya antara segmen diam dan segmen ujaran (Chen dkk., 2022).

b) *Masked speech* denoising dan *prediction*

Pada WavLM, masukan yang dipakai untuk jaringan dapat dibuat sebagai versi simulasi yang bising atau tumpang tindih, sementara target *pseudo* label tetap diturunkan dari ujaran asli yang tidak tercampur. Kerangka ini disusun agar prediksi pada bagian yang dimasking tetap mengikuti tujuan *masked prediction*, namun kondisi masukan yang lebih kompleks dipakai untuk mendorong pemodelan informasi yang relevan bagi tugas multi *speaker*. Objektif yang digunakan mengikuti bentuk *masked prediction Loss*, dengan kerugian hanya dihitung pada indeks waktu yang dimasking.

$$L = - \sum (l \in K) \sum (t \in M) \log p(z_t | h_t^L) 1_{(i-j>0)} \quad (2.25)$$

Pada persamaan tersebut, M adalah himpunan indeks waktu yang dimasking, h_t^L adalah keluaran *layer* Transformer ke L pada waktu t , dan z_t adalah *pseudo* label diskret yang diperoleh dari proses *clustering*, misalnya melalui k *means* pada MFCC atau representasi laten dari model iterasi sebelumnya. Prosedur simulasi *Noisy* atau *overlapped speech* dijelaskan sebagai algoritma pada paper, di mana sebagian *utterance* dalam *batch* dipilih secara acak untuk dicampur dengan *noise* atau *utterance* lain pada rentang waktu acak, dengan panjang campuran dibatasi agar tidak melebihi setengah panjang sinyal sehingga pembicara utama tetap dapat didefinisikan (Chen dkk., 2022).

c) Data pralatih dan konfigurasi model

Untuk meningkatkan keragaman domain, data pralatih diperluas menjadi Mix 94.000 jam yang terdiri dari 60.000 jam *Libri Light*, 10.000 jam *GigaSpeech*, dan 24k jam *VoxPopuli*. Pada konfigurasi eksperimen, WavLM Base dilatih pada 960 jam *LibriSpeech* untuk 400.000 langkah, sedangkan WavLM Base+ dan WavLM *Large* dilatih pada Mix 94.000 jam dengan jumlah langkah yang lebih besar. Label semu untuk Base diambil dari *clustering* keluaran *layer* ke 6 pada model HuBERT iterasi pertama, sedangkan untuk Base+ dan *Large* label semu diambil dari *clustering* keluaran *layer* ke 9 pada HuBERT Base iterasi kedua yang dirilis. Denoising modeling diterapkan pada sebagian *utterance*, dengan probabilitas *mixing noise* yang dibedakan antar varian model (Chen dkk., 2022).

Tabel 2.8 Ringkasan konfigurasi varian WavLM dan data pralatih (Chen dkk., 2022)

Varian	Layer Transformer	Dimensi hidden	Head atensi	Jumlah parameter	Data pralatih	Langkah pembaruan
WavLM Base	12	768	8	94.70M	960 jam	400k
WavLM Base+	12	768	8	94.70M	94k jam	1.2M

WavLM <i>Large</i>	24	1024	12	316.62M	94k jam	700k
-----------------------	----	------	----	---------	---------	------

d) Stabilitas pelatihan pada presisi rendah


Pelatihan dengan fp16 atau mixed precision dapat mengalami overflow ketika skor atensi terlalu besar. Untuk mengurangi risiko tersebut, *softmax* dimanfaatkan karena bersifat invarian terhadap penambahan konstanta pada semua koordinat, sehingga logit dapat digeser dengan nilai maksimum, lalu diskalakan. Implementasi yang dituliskan pada paper dapat diringkas sebagai berikut.

$$a_{(ij)} \propto \exp\left((q_i \cdot k_j)/\sqrt{(d)} + r_{(i-j)}\right) = \exp\left(\left((q_i)/(c\sqrt{(d)}) \cdot k_j - \max_{(j')} \left((q_i)/(c\sqrt{(d)}) \cdot k_{(j')}\right)\right) c + r_{(i-j)}\right) \quad (2.26)$$


Konstanta skala c dipilih bernilai 32 pada eksperimen yang dilaporkan, sehingga nilai maksimum di dalam eksponensial dapat dijaga agar tidak melewati batas representasi fp16 (Chen dkk., 2022).

e) Keterkaitan dengan evaluasi representasi lintas tugas


Pada evaluasi lintas tugas yang mengikuti kebijakan SUPERB, representasi dari berbagai *layer* dapat digabung sebagai *weighted* sum, lalu dipakai oleh model downstream, sementara *backbone* pralatih dapat dipertahankan dalam kondisi dibekukan. Pola kontribusi *layer* dianalisis melalui bobot tersebut dan divisualisasikan pada Gambar 2.7, di mana kontribusi *layer* bawah cenderung muncul pada tugas terkait pembicara, sedangkan *layer* atas lebih berperan pada tugas terkait konten dan semantik. Visualisasi serupa juga ditampilkan untuk tugas *speaker* verification, diarization, dan separation pada Gambar 2.8 (Chen dkk., 2022).



Gambar 2.7 Analisis bobot *layer* pada beberapa tugas SUPERB untuk membandingkan pola kontribusi *layer* (Chen dkk., 2022)



(a) WavLM Base+



(b) WavLM Large

Gambar 2.8 Analisis bobot *layer* untuk *speaker verification*, *speaker diarization*, dan *speech separation*.

2.2.10 Ekstraksi Fitur

Ekstraksi fitur akustik dilakukan untuk mengubah sinyal ucapan mentah menjadi representasi numerik yang lebih ringkas, sehingga informasi yang relevan bagi tugas prediksi dapat dimodelkan lebih stabil. Pada praktiknya, fitur umumnya dibentuk dari analisis sinyal berdurasi pendek, karena karakteristik ucapan berubah seiring waktu dan lebih mudah diperkirakan pada potongan sinyal yang pendek. Pendekatan ini juga digunakan oleh banyak perangkat ekstraksi fitur yang menghasilkan deret waktu deskriptor tingkat rendah, lalu diringkas menjadi vektor statis dengan berbagai fungsi statistik, sehingga satu rekaman dapat diwakili oleh satu vektor fitur (Eyben dkk., 2010).

Pada tahap awal, penekanan frekuensi tinggi sering diterapkan untuk mengurangi kemiringan spektrum alami pada sinyal ucapan. Operasi ini biasanya ditulis sebagai filter orde satu pada Persamaan (2.27), di mana keluaran $y[n]$ dibentuk dari sinyal masukan $x[n]$ dan sampel sebelumnya dengan koefisien α . Bentuk ini dipakai sebagai langkah praproses sebelum pemingkakan dan transformasi frekuensi dilakukan (Weenink, 2007).

$$y[n] = x[n] - \alpha x[n - 1] \quad (2.27)$$

Setelah itu, sinyal dibagi menjadi *frame* dan setiap *frame* dikenai fungsi jendela agar kebocoran spektral dapat ditekan. Sinyal berjendela dapat dituliskan seperti pada Persamaan (2.28) sebagai perkalian titik demi titik antara sinyal *frame* dan jendela $w[n]$. Selanjutnya, spektrum *frame* dihitung melalui transformasi Fourier diskrit sebagaimana Persamaan (2.29). Formulasi ini merupakan bentuk dasar analisis waktu pendek yang menghasilkan representasi spektral per *frame*, sehingga fitur spektral dan cepstral dapat diturunkan dari magnitudo spektrum tersebut (Ney & Schluter, 2010).

$$y[n] = w[n] \cdot x[n] \quad (2.28)$$

$$Y[k] = \sum_{n=0}^{N-1} y[n] e^{-j2\pi kn/N}, \omega_k = (2\pi k)/N \quad (2.29)$$

a) Fitur spektral dan MFCC

Fitur spektral memanfaatkan distribusi energi terhadap frekuensi, misalnya energi pada pita frekuensi tertentu, kemiringan spektrum, atau ukuran bentuk spektrum. Salah satu representasi yang sangat umum adalah *Mel Frequency Cepstral Coefficients* atau MFCC. Secara historis, MFCC diperkenalkan sebagai representasi parametrik yang efektif untuk sinyal ucapan dengan memakai bank filter pada skala mel dan kompresi log sebelum dilakukan transformasi kosinus diskrit (Davis & Mermelstein, 1980).

Skala mel digunakan untuk memetakan frekuensi linear ke skala persepsi pendengaran, dan salah satu bentuk pemetaannya dituliskan pada Persamaan (2.30). Setelah energi spektral dijumlahkan melalui filter segitiga yang berjarak sama pada skala mel, nilai energi tersebut dikompresi dengan log dan diproyeksikan menjadi koefisien cepstral melalui transformasi kosinus seperti Persamaan (2.31). Pada persamaan ini, X_k merepresentasikan keluaran bank filter, dan indeks m menunjukkan urutan koefisien cepstral yang diambil. Bentuk ini menggambarkan inti proses MFCC sebagai “log mel filterbank” yang diikuti oleh proyeksi kosinus (Ney & Schlüter, 2010).

$$f_{mel} = 2595 \cdot \log_{10}(1 + f/700) \quad (2.30)$$

$$\hat{x}[m] = 1/K \sum_{k=1}^K \log(X_k) \cos(\pi m/K(k - 1/2)) \quad (2.31)$$

Pada praktik ekstraksi fitur berbasis toolkit, MFCC biasanya dihitung sebagai deret waktu per *frame*, kemudian dapat diturunkan lagi dengan operasi turunan waktu seperti delta, atau diringkas menjadi statistik global per rekaman. Mekanisme “deret waktu lalu diringkas” ini juga merupakan pola yang dinyatakan oleh openSMILE, yaitu deskriptor tingkat rendah seperti MFCC, F0, formant, dan *loudness* dapat diproses lanjut dengan delta *regression* dan berbagai functionals statistik agar diperoleh fitur ringkasan (Eyben dkk., 2010).

b) Fitur prosodik, kualitas suara, dan fungsi ringkasan

Selain MFCC, fitur prosodik sering dibentuk dari kontur *pitch* atau F0, intensitas, serta indikasi ritme seperti laju suku kata semu atau jeda. Fitur kualitas suara juga sering digunakan, misalnya jitter dan shimmer untuk menangkap variasi periodisitas, serta ukuran terkait harmonik dan *noise*. Dalam konteks ekstraksi berbasis perangkat lunak, openSMILE dinyatakan mendukung berbagai deskriptor tingkat rendah seperti MFCC, *loudness*, fundamental *frequency*, dan formant *frequencies*, serta mendukung penerapan delta *regression* dan functionals statistik pada deret waktu tersebut (Eyben dkk., 2010).

Agar fitur dari deret waktu menjadi vektor statis, functionals umum seperti rata rata dan simpangan baku sering diterapkan. Pada Persamaan (2.32) dan (2.33), dua contoh ringkasan

statistik dituliskan untuk sebuah deret nilai x_t sepanjang T frame. Ringkasan semacam ini juga digunakan dalam penyusunan set fitur standar seperti GeMAPS dan eGeMAPS, di mana *mean* dan *coefficient of variation* disebut sebagai functionals yang diterapkan pada deskriptor tertentu (Eyben dkk., 2016).

$$\mu = 1/T \sum_{t=1}^T x_t \quad (2.32)$$

$$\sigma = \sqrt{\widehat{\left(1/T \sum_{t=1}^T (x_t - \mu)^2\right)}} \quad (2.33)$$

Koefisien variasi yang disebut pada penyusunan GeMAPS dapat dinyatakan sebagai $CoV = \sigma/\mu$, sehingga variasi relatif terhadap nilai rata rata dapat ditangkap, dan ini dipakai bersama *mean* pada beberapa deskriptor yang dihitung pada region *voiced* atau *unvoiced* sesuai definisi set tersebut (Eyben dkk., 2016).

c) eGeMAPS dan openSMILE

GeMAPS diperkenalkan sebagai set parameter akustik minimalistik untuk analisis suara dan affective computing, dan implementasinya dinyatakan tersedia melalui toolkit openSMILE. Pada definisinya, total 62 parameter dijelaskan sebagai hasil dari penerapan functionals pada 18 *low level* descriptors serta sejumlah functionals tambahan pada *pitch* dan *loudness*, ditambah beberapa fitur temporal. Untuk melengkapi keterbatasan set minimal yang tidak memuat parameter cepstral, eGeMAPS ditetapkan sebagai set perluasan yang menambahkan antara lain MFCC 1 sampai 4, spectral flux, serta bandwidth formant tertentu, sehingga total parameter menjadi 88 ketika digabungkan dengan set minimal (Eyben dkk., 2016).

Di sisi implementasi, openSMILE dijelaskan sebagai toolkit ekstraksi fitur audio yang dapat dikonfigurasi melalui satu berkas konfigurasi, dan mendukung pemrosesan incremental maupun *batch*. Dukungan fitur yang disebut meliputi MFCC, PLP cepstral *coefficients*, LPC, LSF, fundamental *frequency*, dan formant *frequencies*, serta penerapan delta *regression* dan berbagai functionals statistik (Eyben dkk., 2010). Dengan demikian, eGeMAPS dapat dipandang sebagai salah satu konfigurasi fitur yang terstandarisasi, sementara openSMILE berperan sebagai mesin ekstraksinya.

d) Normalisasi fitur untuk pemodelan

Agar skala antar fitur lebih sebanding, standardisasi sering diterapkan sebelum regresor dilatih. Standardisasi ini dapat dituliskan pada Persamaan (2.34), di mana sebuah nilai fitur x diubah menjadi z menggunakan rata rata μ dan simpangan baku s . Pada praktiknya, μ dan s diestimasi dari data latih, lalu transformasi yang sama diterapkan pada data validasi dan uji agar kebocoran informasi dapat dihindari, dan prinsip ini juga ditegaskan pada materi praktik *preprocessing* serta dokumentasi StandardScaler (scikit-learn developers, 2007).

$$z = (x - \mu)/s \quad (2.34)$$

Ringkasan dari kelompok fitur akustik yang sudah dijelaskan sebelumnya akan ditunjukkan pada Tabel 2.9 sebagai berikut.

Tabel 2.9 Ringkasan kelompok fitur akustik dan contoh parameternya

Kelompok fitur	Contoh parameter	Bentuk keluaran	Catatan ringkas
Spektral	energi pita, spectral slope, spectral roll-off, spectral flux	per <i>frame</i> lalu diringkas	diturunkan dari representasi spektrum hasil STFT atau DFT
Cepstral	MFCC	per <i>frame</i> lalu diringkas	energi mel yang dilogaritmakan lalu diproyeksikan dengan DCT menjadi koefisien cepstral
Prosodik	F0 atau <i>pitch</i> , rentang F0, <i>loudness</i> atau energi	kontur lalu diringkas	menggambarkan intonasi dan dinamika kuat lemah suara sepanjang waktu
Kualitas suara	jitter, shimmer, HNR	per <i>frame</i> atau per segmen	<i>voiced</i> segment sering dipakai sebagai dasar perhitungan ukuran ketakteraturan dan <i>noise</i> relatif
Temporal	durasi <i>voiced</i> , durasi <i>unvoiced</i> , rasio <i>voiced</i> , jumlah segmen <i>voiced</i>	per rekaman atau per segmen	meringkas pola aktivitas bicara dan jeda yang muncul pada rekaman

2.2.11 Pemodelan Untuk Regresi

Pada prediksi skor *Big Five* berbasis fitur audio, keluaran yang dihasilkan berupa nilai kontinu. Karena itu, pemodelan regresi digunakan untuk memetakan vektor fitur $x \in \mathbb{R}^p$ menjadi target $y \in \mathbb{R}$. Jika lima *trait* diprediksi sekaligus, target dapat dinyatakan sebagai $Y \in \mathbb{R}^{n \times 5}$ sehingga pemodelan dilakukan sebagai regresi multi output. Dukungan regresi multi output telah disediakan pada implementasi Ridge ketika y diberikan sebagai array dua dimensi (scikit-learn developers, 2007).

a) Regresi linear sebagai model dasar

Regresi linear digunakan sebagai *baseline* karena hubungan antara fitur dan target dinyatakan melalui kombinasi linear koefisien. Bentuk model dituliskan pada Persamaan (2.35), di mana $X \in \mathbb{R}^{n \times p}$ adalah matriks fitur, $\beta \in \mathbb{R}^p$ adalah koefisien, dan ϵ adalah galat.

Persamaan ini dipakai untuk menyatakan bahwa prediksi dihasilkan dari perkalian $X\beta$ dan deviasi terhadap target dimodelkan sebagai *Residual* (Hastie dkk., 2009).

$$y = X\beta + \epsilon \quad (2.35)$$

Koefisien pada ordinary least squares diperoleh dengan meminimalkan jumlah kuadrat *Residual*. Objektif ini dituliskan pada Persamaan (2.36) dan dipakai untuk mencari $\hat{\beta}$ yang membuat selisih y dan $X\beta$ sekecil mungkin dalam norma Euclidean (James dkk., 2013).

$$\widehat{\beta}_{(OLS)} = \operatorname{argmin}_{(\beta)} \|y - X\beta\|_2^2 \quad (2.36)$$

Pada fitur audio, kolinearitas sering muncul karena beberapa fitur diturunkan dari sumber spektral yang sama atau dari ringkasan statistik yang serupa. Dalam kondisi demikian, estimator OLS dapat memiliki varians yang tinggi sehingga generalisasi dapat menurun walaupun *error* pelatihan terlihat kecil. Fenomena ini dibahas dalam konteks trade off bias varians dan regularisasi pada metode pemodelan statistik (Hastie dkk., 2009; James dkk., 2013).

b) Ridge regression untuk menekan *overfitting*

Ketika jumlah fitur cukup banyak atau antar fitur saling berkorelasi, koefisien pada regresi linear biasa cenderung menjadi tidak stabil, sehingga kinerja pada data baru dapat menurun walaupun galat pada data latih terlihat kecil. Kondisi seperti ini dibahas dalam kerangka trade off bias dan varians pada pemodelan statistik, di mana varians estimator yang tinggi dapat memicu *overfitting* pada data latih (Hastie dkk., 2009; James dkk., 2013).

Ridge regression digunakan untuk mengurangi ketidakstabilan tersebut dengan cara melakukan regularisasi L2, sehingga koefisien model didorong menjadi lebih kecil dan solusi menjadi lebih terkondisi ketika prediktor tidak ortogonal atau saling berkorelasi (Hoerl & Kennard, 1970). Pada pengaturan ini, sebuah parameter regularisasi dipakai untuk mengatur seberapa kuat *shrinkage* dilakukan. Jika regularisasi dibuat lebih kuat, model cenderung menjadi lebih sederhana karena sensitivitas koefisien terhadap variasi pada data latih menjadi berkurang. Prinsip bahwa regularisasi memperbaiki conditioning masalah dan dapat menurunkan varians estimasi juga dinyatakan pada dokumentasi fungsi ridge regression (scikit-learn developers, 2007).

c) Standardisasi fitur sebelum Ridge

Karena penalti L2 dipengaruhi oleh skala fitur, standardisasi umumnya diterapkan sebelum Ridge agar kontribusi penalti tidak didominasi oleh fitur yang memiliki rentang lebih besar. Praktik yang lazim adalah menghitung rata rata dan simpangan baku dari data latih, lalu transformasi yang sama diterapkan pada data validasi dan uji. Penjelasan kebutuhan rescaling dalam konteks metode *shrinkage* dan regularisasi dibahas sebagai praktik umum pada pembahasan regresi teratur (James dkk., 2013).

d) Regresi multi output untuk *Big Five*

Jika lima *trait Big Five* diprediksi sekaligus, target dapat diperlakukan sebagai keluaran multi output sehingga satu estimator dipakai untuk memprediksi beberapa target kontinu secara bersamaan. Dukungan multi variate regression dinyatakan tersedia pada Ridge ketika y diberikan sebagai array dua dimensi, dan parameter regularisasi juga dapat

diberikan per target bila diperlukan. Dengan cara tersebut, sebuah fitur audio yang sama dapat dipetakan menjadi lima skor *trait* tanpa harus melatih lima model yang terpisah, walaupun pelatihan terpisah tetap mungkin dilakukan jika ingin memisahkan konfigurasi tiap target (scikit-learn developers, 2007).

e) Pemilihan parameter regularisasi

Nilai regularisasi umumnya tidak ditetapkan secara langsung, tetapi dipilih menggunakan validasi atau *cross validation*. Prosedur ini dipakai agar tingkat regularisasi ditentukan berdasarkan kinerja pada data yang tidak dipakai untuk fitting, sehingga risiko *overfitting* terhadap data latih dapat ditekan. Pemilihan parameter regularisasi berbasis validasi dibahas dalam pembahasan metode *shrinkage* pada literatur pengantar statistical *learning* (James dkk., 2013).

Tabel 2.10 di bawah ini dapat dipakai untuk merangkum perbedaan regresi linear biasa dan Ridge pada konteks fitur audio.

Tabel 2.10 Perbandingan regresi linear dan Ridge *regression* untuk mengurangi *overfitting*

Aspek	Regresi linear (OLS)	Ridge <i>regression</i>
Tujuan	pemetaan linear dari fitur ke target	pemetaan linear dengan regularisasi L2 agar koefisien lebih stabil
Perilaku saat fitur saling berkorelasi	koefisien dapat sensitif terhadap perubahan data	koefisien cenderung mengalami <i>shrinkage</i> sehingga varians berkurang
Kontrol kompleksitas	tidak ada parameter khusus	ada parameter regularisasi alpha atau lambda yang mengatur kekuatan <i>shrinkage</i>
Risiko <i>overfitting</i>	dapat meningkat saat fitur banyak dan kolinear	cenderung ditekan melalui regularisasi
Kebutuhan standardisasi	fitur disarankan distandarisasi	standardisasi lebih penting karena penalti bergantung pada skala fitur
Dukungan multi output	umumnya dapat menerima y 2D tergantung implementasi	mendukung multi output ketika y berbentuk (n_samples, n_targets)

2.2.12 Parameter-Efficient Fine-tuning: LoRA

Pada tahap adaptasi model pralatih, pembaruan seluruh parameter sering dilakukan melalui *fine-tuning* penuh. Namun pada model Transformer berukuran besar, pendekatan tersebut cenderung membuat kebutuhan memori meningkat karena parameter yang dilatih, gradien, dan state *optimizer* harus disimpan untuk seluruh bobot. Sebagai alternatif, pendekatan parameter efficient *fine-tuning* dapat digunakan dengan cara hanya melatih sejumlah kecil parameter

tambahan, sementara bobot pralatih tetap dibekukan. Salah satu metode yang banyak digunakan adalah Low Rank Adaptation atau LoRA. Pada LoRA, pembaruan bobot dianggap tidak perlu memiliki derajat kebebasan penuh, sehingga pembaruan dapat direpresentasikan sebagai matriks berperingkat rendah. Dengan cara ini, penyimpanan model adaptasi per tugas dapat dibuat lebih ringkas dibanding menyimpan salinan model hasil *fine-tuning* penuh (Hu dkk., 2021).

Misalkan terdapat transformasi linear pada Transformer, misalnya proyeksi pada *attention* atau pada *feed forward network*. Untuk sebuah *input* vektor x , keluaran linear standar dapat dituliskan pada Persamaan (2.37).

$$y = Wx \quad (2.37)$$

Pada LoRA, bobot pralatih W tidak diperbarui. Sebagai gantinya, pembaruan bobot ΔW dimodelkan sebagai hasil perkalian dua matriks berukuran kecil, yaitu B dan A , dengan rank r yang dipilih jauh lebih kecil daripada dimensi aslinya. Formulasi tersebut dapat dituliskan pada Persamaan (2.38) sampai Persamaan (2.39) (Hu dkk., 2021).

$$W' = W + \Delta W \quad (2.38)$$

$$\Delta W = \alpha/r BA \quad (2.39)$$

Dengan demikian, keluaran *layer* menjadi seperti pada Persamaan (2.40).

$$y = Wx + \alpha/r BAx \quad (2.40)$$

Pada persamaan tersebut, $A \in \mathbb{R}^{r \times d_{in}}$ dan $B \in \mathbb{R}^{d_{out} \times r}$, sedangkan α digunakan sebagai faktor skala agar besar pembaruan dapat diatur tanpa harus menaikkan rank. Karena hanya Adan Byang dilatih, jumlah parameter yang diperbarui dapat ditekan. Dampak praktisnya adalah kebutuhan memori selama pelatihan dapat berkurang, terutama karena state *optimizer* tidak lagi disimpan untuk seluruh bobot model (Hu dkk., 2021).

Pada arsitektur Transformer, LoRA umumnya disisipkan pada *layer* linear tertentu, misalnya pada proyeksi *query* dan *value* di *self attention*, atau pada proyeksi lain yang dianggap dominan terhadap adaptasi tugas. Pada tahap inferensi, kontribusi LoRA dapat digabungkan ke dalam bobot efektif W' , sehingga tidak diperlukan modul tambahan yang menambah latensi, berbeda dari beberapa pendekatan adapter yang menambahkan blok baru di antara *layer* (Houlsby dkk., 2019; Hu dkk., 2021).

Jika dibandingkan dengan metode parameter efficient lain, posisi LoRA dapat dipahami sebagai pendekatan yang mengubah transformasi linear melalui pembaruan berperingkat rendah, sementara metode seperti *prefix tuning* menambahkan vektor kondisi yang dapat diatensi tanpa mengubah bobot utama, dan metode seperti BitFit hanya memperbarui bias pada *layer* tertentu. Pemilihan LoRA pada penelitian berbasis *backbone* audio Transformer umumnya dilakukan ketika adaptasi perlu tetap stabil, namun pembaruan penuh dianggap kurang efisien dari sisi sumber daya dan penyimpanan model per skenario (Lisa Li & Liang, 2021; Zaken dkk., 2022).

2.2.13 Optimisasi dan Strategi *Training*

Optimisasi dibutuhkan untuk memperbarui parameter model agar nilai fungsi *loss* menurun secara bertahap. Pada pelatihan jaringan saraf modern, *optimizer* berbasis gradien stokastik sering dipakai karena pembaruan dilakukan menggunakan minibatch sehingga komputasi lebih

terjangkau pada dataset besar. Pada sub bab ini, Adam dan AdamW dijelaskan karena keduanya banyak dipakai pada pelatihan model berbasis Transformer (Kingma & Ba, 2017).

a) Adam

Adam digunakan dengan menggabungkan dua ide utama, yaitu momentum dan adaptasi laju belajar per parameter. Gradien pada setiap langkah tidak hanya dipakai secara langsung, tetapi diringkas melalui estimasi momen pertama sebagai rata rata bergerak eksponensial dari gradien, dan estimasi momen kedua sebagai rata rata bergerak eksponensial dari kuadrat gradien. Koreksi bias juga diterapkan pada dua estimasi tersebut karena nilai awalnya dimulai dari nol, sehingga pada langkah awal estimasi dapat terlalu kecil jika tidak dikoreksi. Dengan mekanisme ini, pembaruan parameter cenderung menjadi lebih stabil ketika gradien bersifat bising atau berskala berbeda antar dimensi (Kingma & Ba, 2017).

Parameter yang umumnya melekat pada Adam adalah laju belajar, dua koefisien peluruhan untuk momen pertama dan kedua, serta konstanta kecil untuk stabilitas numerik. Nilai default yang sering dijadikan rujukan juga diberikan pada paper aslinya, sehingga titik awal konfigurasi dapat ditetapkan secara lebih terarah sebelum dilakukan penalaan lebih lanjut (Kingma & Ba, 2017).

b) AdamW

Regularisasi berbasis *weight decay* sering ditambahkan untuk menekan kompleksitas model. Pada SGD, *weight decay* memiliki hubungan yang sepadan dengan penalti L2 ketika ditinjau dalam bentuk tertentu, namun kesepadanan ini tidak lagi berlaku untuk *optimizer* adaptif seperti Adam. Kondisi ini menyebabkan penggunaan penalti L2 yang disebut sebagai *weight decay* pada implementasi tertentu dapat memberi efek regularisasi yang berbeda dari *weight decay* yang dimaksud dalam literatur (Loshchilov & Hutter, 2019).

AdamW diperkenalkan dengan memisahkan *weight decay* dari langkah pembaruan gradien. *Weight decay* diterapkan langsung pada bobot sebagai peluruhan parameter, sementara pembaruan berbasis gradien tetap mengikuti mekanisme Adam. Pemisahan ini ditujukan agar pengaturan *weight decay* menjadi lebih konsisten dan tidak tercampur ke dalam estimasi momen pada Adam. AdamW diperkenalkan dengan memisahkan *weight decay* dari langkah pembaruan gradien. *Weight decay* diterapkan langsung pada bobot sebagai peluruhan parameter, sementara pembaruan berbasis gradien tetap mengikuti mekanisme Adam. Pemisahan ini ditujukan agar pengaturan *weight decay* menjadi lebih konsisten dan tidak tercampur ke dalam estimasi momen pada Adam (Loshchilov & Hutter, 2019).

c) Strategi *training* yang sering dipakai bersama Adam dan AdamW

Agar pelatihan lebih stabil, laju belajar umumnya tidak dijaga tetap. Pada pelatihan Transformer, strategi warmup sering dipakai, yaitu laju belajar dinaikkan secara bertahap pada langkah awal, lalu diturunkan mengikuti jadwal tertentu. Skema warmup dan penurunan laju belajar telah digunakan pada Transformer, dan pemakaian jadwal laju belajar dibahas sebagai bagian penting dari stabilitas *training* (Vaswani dkk., 2017). Di luar itu, berbagai bentuk penurunan laju belajar seperti step, linear, atau cosine juga sering dipakai dan dibahas dalam studi tentang jadwal *learning rate* (Lewkowycz, 2021).

Ketika gradien menjadi sangat besar, pembaruan dapat menjadi tidak stabil. Untuk kondisi ini, pemotongan norma gradien sering diterapkan agar ledakan gradien dapat diredam tanpa

mengubah arah pembaruan secara ekstrem. Strategi gradient norm clipping dibahas sebagai solusi praktis untuk exploding gradients (Pascanu dkk., 2013).

Selain itu, penghentian pelatihan berbasis kinerja validasi sering digunakan ketika indikasi *overfitting* mulai muncul. Pada pendekatan ini, pelatihan dihentikan ketika metrik validasi tidak membaik dalam beberapa epoch tertentu, sehingga model yang disimpan adalah model dengan kinerja validasi terbaik. *Early stopping* dibahas sebagai teknik yang memanfaatkan validasi untuk mendeteksi saat *overfitting* mulai terjadi (Prechelt, 1997).

Tabel 2.11 berikut bisa dipakai untuk meringkas perbedaan Adam dan AdamW pada praktik *training*.

Tabel 2.11 Ringkasan perbedaan Adam dan AdamW terkait penerapan *weight decay*

Aspek	Adam	AdamW
Mekanisme inti	Optimisasi adaptif dengan estimasi momen pertama dan momen kedua serta koreksi bias	Mekanisme Adam yang sama
Cara memasukkan <i>weight decay</i>	Pada implementasi yang umum, regularisasi L2 sering digabung ke gradien sehingga efeknya tidak identik dengan <i>weight decay</i> pada <i>optimizer</i> adaptif	<i>Weight decay</i> dipisahkan dari update gradien sehingga peluruhan bobot diterapkan secara terpisah
Alasan pemakaian	Stabil untuk gradien yang bising atau jarang muncul	<i>Weight decay</i> dibuat lebih konsisten pada <i>optimizer</i> adaptif melalui <i>decoupling</i>

2.2.14 Metrik Evaluasi

Pada tugas prediksi *Big Five* dengan keluaran kontinu, nilai target umumnya berada pada rentang 0 sampai 1 sehingga kesalahan prediksi dapat diukur sebagai jarak numerik antara nilai prediksi dan nilai ground truth. Pada *Chalearn First impressions Challenge*, metrik yang dipakai untuk pelaporan kinerja disebut sebagai *accuracy* dan metrik ini didefinisikan sebagai satu dikurangi MAE. Karena terdapat lima *trait* yang diprediksi terpisah, nilai *mean accuracy* dihitung sebagai rata rata dari *accuracy* per *trait* (Aslan dkk., 2021).

a) *Accuracy* berbasis MAE

Accuracy per *trait* didefinisikan dari MAE per *trait* sebagai berikut (Aslan dkk., 2021).

$$Acc_j = 1 - MAE_j \quad (2.41)$$

dengan j menyatakan indeks *trait* *Big Five*. Selanjutnya, ringkasan kinerja dilaporkan sebagai *mean accuracy*, yaitu rata rata dari lima nilai *accuracy* (Aslan dkk., 2021).

$$MeanAcc = 1/|S| \sum (j \in S) Acc_j \quad (2.42)$$

Dengan $S = Openness, Conscientiousness, Extraversion, Agreeableness, Neuroticism$ dan $|S| = 5$ (Aslan dkk., 2021).

b) *Mean Absolute Error* (MAE)

MAE mengukur rata rata selisih absolut antara nilai prediksi dan nilai target. Untuk kasus multi output seperti *Big Five*, MAE dapat dihitung per *trait*, lalu dapat dirata ratakan untuk mendapatkan ringkasan kesalahan. Pada notasi per *trait*, MAE didefinisikan sebagai berikut (Aslan dkk., 2021).

$$MAE_j = 1/n \sum_{(i=1)}^n |y_i^{(j)} - \widehat{y}_i^{(j)}| \quad (2.43)$$

dengan n menyatakan jumlah sampel, $y_i^{(j)}$ adalah target *trait* ke j untuk sampel ke i , dan $\widehat{y}_i^{(j)}$ adalah prediksi model. Jika diperlukan satu nilai ringkas untuk semua *trait*, MAE dapat dirata ratakan di atas himpunan *trait*, sehingga diperoleh *average* MAE (Aslan dkk., 2021).

$$MAE = \frac{1}{|S|} \sum_{j \in S} MAE_j \quad (2.44)$$

c) *Root Mean Squared Error* (RMSE)

RMSE mengukur akar dari rata rata kuadrat selisih prediksi terhadap target. RMSE sering dipakai ketika kesalahan besar ingin diberi penalti lebih berat karena adanya operasi kuadrat sebelum dirata ratakan. Definisinya dapat dituliskan sebagai berikut (National Institute of Standards & Technology, 2010).

$$RMSE_j = \sqrt{\left(\frac{1}{n} \sum_{(i=1)}^n (y_i^{(j)} - \widehat{y}_i^{(j)})^2 \right)} \quad (2.45)$$

Dalam implementasi evaluasi regresi, RMSE juga didukung sebagai metrik regresi pada pustaka umum pembelajaran mesin (scikit-learn developers, 2007).

d) Koefisien Determinasi R^2

Koefisien determinasi R^2 menilai seberapa besar variasi target yang dapat dijelaskan oleh prediksi model relatif terhadap prediktor *baseline* yang selalu memprediksi rata rata target. Pada definisi umum, R^2 dituliskan sebagai berikut (scikit-learn developers, 2007).

$$R^2 = 1 - \left(\sum_{(i=1)}^n (y_i - \widehat{y}_i)^2 \right) / \left(\sum_{(i=1)}^n (y_i - \bar{y})^2 \right) \quad (2.46)$$

dengan $\bar{y}$ adalah rata rata dari y_i . Nilai terbaik adalah 1, nilai 0 setara dengan model konstan yang selalu memprediksi rata rata target, dan nilai dapat menjadi negatif bila prediksi lebih buruk daripada *baseline* tersebut (scikit-learn developers, 2007).

BAB 3

METODOLOGI

Bab ini menjelaskan metodologi penelitian yang digunakan untuk membangun dan mengevaluasi *pipeline* estimasi kepribadian *Big Five* berbasis suara. Tahapan yang dibahas disusun secara sistematis, mulai dari penyiapan data, praproses audio, pembagian data untuk evaluasi yang terkontrol, perancangan skenario pemodelan, hingga prosedur pelatihan dan pengujian. Keluaran yang dituju pada *pipeline* ini berupa nilai prediksi untuk lima dimensi *Big Five* dalam bentuk regresi, sehingga fokus utama metodologi adalah memastikan proses ekstraksi dan evaluasi berjalan konsisten.

Metodologi pada bab ini dituliskan untuk memperjelas alur implementasi dan memastikan setiap langkah memiliki keterkaitan yang konsisten dengan tujuan evaluasi. Penjelasan disusun agar proses yang dilakukan dapat ditelusuri kembali, termasuk alasan teknis di balik pemilihan tahapan tertentu dan bagaimana tahapan tersebut mempengaruhi hasil eksperimen. Selain alur proses, bagian-bagian yang berkaitan dengan pengaturan eksperimen seperti konsistensi parameter, pencatatan hasil, dan cara membandingkan antar skenario juga dijelaskan secara ringkas agar interpretasi hasil tidak terlepas dari prosedur yang digunakan.

Struktur bab disusun sebagai berikut. Subbab 3.1 memaparkan perancangan sistem dan alur umum penelitian beserta rincian tahap utama. Subbab 3.2 menjelaskan bahan dan peralatan yang digunakan selama penelitian. Subbab 3.3 merangkum urutan pelaksanaan penelitian sebagai acuan rencana kerja, sehingga keterkaitan antar tahap dapat terlihat secara runtut dari awal hingga akhir.

3.1 Perancangan Sistem


Subbab ini membahas perancangan sistem yang menjadi dasar pelaksanaan eksperimen pada penelitian ini. Gambaran alur umum ditunjukkan terlebih dahulu untuk memperlihatkan hubungan antar tahapan, sebelum masing-masing proses dijelaskan lebih rinci pada subbab berikutnya. Diagram alur juga digunakan untuk menandai batas antar blok proses, sehingga pembaca dapat melihat bagian mana yang merupakan praproses, bagian pembagian data, dan bagian pemodelan serta evaluasi.

Secara umum, alur sistem dimulai dari penyiapan dataset dan ekstraksi audio dari video. Setelah itu dilakukan praproses audio pada *level* per sampel untuk menyeragamkan kondisi *input*, sehingga data yang masuk ke tahap pemodelan berada pada format yang konsisten. Pada tahap ini dapat terjadi penyesuaian tambahan sesuai kebutuhan penelitian, misalnya penanganan kualitas audio atau pembuatan varian audio yang lebih fokus pada segmen ujaran, selama tetap mengikuti aturan praproses yang sama untuk seluruh sampel.

Tahap berikutnya mencakup penerapan protokol pembagian data yang digunakan untuk evaluasi, kemudian proses *training* dan *validation* dijalankan sesuai protokol tersebut. Dengan rancangan ini, perbandingan antar skenario dapat dilakukan dalam kerangka *pipeline* yang sama dan hasil eksperimen dapat diinterpretasikan dengan lebih terstruktur. Selain itu, pengaturan eksperimen seperti konfigurasi pelatihan, pencatatan kinerja, dan keluaran model disusun konsisten agar perbedaan hasil lebih merefleksikan perbedaan skenario, bukan perbedaan

prosedur. Penjelasan desain penelitian dan alur umum sistem dijabarkan pada Subbab 3.1.1 sebagai pengantar sebelum masuk ke rincian tahap berikutnya.

3.1.1 Desain Penelitian & Alur Umum



Gambar 3.1 Diaram Alir Umum Penelitian *Audio-only Personality Estimation*

Penelitian ini menggunakan desain eksperimen untuk melakukan estimasi kepribadian *Big Five* berbasis suara (*audio-only personality estimation*). Secara umum, alur penelitian dimulai dari menyiapkan data mentah berupa video, mengubahnya menjadi audio, melakukan praproses audio, menyusun protokol pembagian data (*split*), menjalankan beberapa skenario representasi fitur dan model, hingga memperoleh konfigurasi terbaik dan melakukan evaluasi final pada data uji. Alur lengkap penelitian ditunjukkan pada Gambar 3.1.

Tahap awal penelitian adalah pengunduhan dataset dan ekstraksi audio dari video agar seluruh sampel berada pada format audio yang seragam untuk diproses lebih lanjut. Setelah itu dilakukan praproses audio per sampel, misalnya penyeragaman *sampling rate*, konversi kanal, dan langkah lain yang diperlukan agar kualitas *input* stabil. Pada tahap ini, penelitian juga dapat menghasilkan keluaran audio siap pakai (misalnya audio *full* berdurasi tetap dan/atau audio *speech-only*) beserta metadata pendukung untuk kontrol kualitas. Detail teknis praproses ini dijelaskan pada subbab tersendiri, sementara pada subbab ini ditampilkan sebagai gambaran alur umum.


Selanjutnya, penelitian menerapkan Protokol *Strict Split* untuk membentuk pembagian data *train_strict*, *val_strict*, dan *test_strict* dengan prinsip disjoint pada *level* grup tertentu (*group_id*), sehingga mengurangi risiko kebocoran informasi antar *split*. Pada alur ini, *test_strict* dikunci dan tidak digunakan dalam proses pemilihan model maupun *tuning*. Di samping *strict split*, penelitian juga mempertahankan *official split* sebagai pembanding agar hasil dapat dibandingkan dengan studi terdahulu yang melaporkan kinerja pada *split* resmi dataset. Dengan demikian, penelitian menghasilkan dua jalur evaluasi: (1) *train & validation strict* untuk seleksi model yang lebih konservatif, dan (2) *train & validation official* untuk pembanding pelaporan.

Setelah dataset siap, penelitian menjalankan semua skenario representasi dan model, yang mencakup beberapa pendekatan seperti penggunaan fitur *handcrafted* (eGeMAPS) dan *embedding* dari *backbone* SSL dalam kondisi *frozen*, serta skenario lanjutan berupa *fine-tuning backbone* terbaik menggunakan LoRA. Setiap skenario menghasilkan keluaran berupa prediksi *Big Five* dan metrik evaluasi, baik pada jalur *strict* maupun *official*. Hasil evaluasi kemudian dibandingkan untuk menentukan metode dan konfigurasi terbaik, dengan prioritas pemilihan berdasarkan kinerja pada *val_strict* agar proses seleksi tidak bias terhadap data uji.

Setelah konfigurasi terbaik diperoleh, penelitian melakukan pelatihan ulang (*retrain*) menggunakan gabungan data *train* dan *val* (pada protokol yang dipilih) dengan tujuan memperoleh model yang lebih stabil sebelum diuji. Tahap berikutnya adalah evaluasi pada data *test* yang dilakukan sekali dan tanpa *tuning*, khususnya untuk *test_strict* yang sejak awal dikunci. Terakhir, seluruh hasil dari berbagai skenario dan model dirangkum dalam perbandingan final, sehingga dapat disimpulkan metode mana yang memberikan kinerja terbaik untuk tugas estimasi *Big Five* berbasis audio pada dataset yang digunakan.

Agar pembahasan sistematis, setiap blok besar pada Gambar 3.1 (praproses, *strict split*, skenario model, *fine-tuning* LoRA, dan detail *training loop*) dijelaskan lebih rinci pada subbab-subbab berikutnya.

3.1.2 Prosedur *Strict Split*




Gambar 3.2 Diagram Alir Prosedur *Split Strict* Dataset

Pada tahap ini diterapkan *strict split* sebagai protokol pembagian data utama untuk seleksi model dan *tuning* seperti yang ditunjukkan pada Gambar 3.2, dengan tujuan meminimalkan risiko kebocoran informasi (*leakage*) antar *split* akibat kemiripan sumber atau identitas data. *Strict split* dibentuk pada level grup menggunakan variabel *group_id*, sehingga seluruh sampel dengan *group_id* yang sama wajib berada pada *split* yang sama dan tidak boleh muncul di *split* lain. Pembatasan ini menjaga agar evaluasi lebih merefleksikan kemampuan generalisasi model pada identitas pembicara yang berbeda, bukan karena model melihat karakteristik pembicara yang sama pada tahap pelatihan.

Proses dimulai dari menyiapkan input berupa audio hasil praproses (*preprocessed_full.wav*, 16 kHz mono 15 detik) dan metadata manifest.csv. Selanjutnya dihitung ringkasan label per sampel berupa *avg_trait* sebagai rata-rata dari lima trait *Big Five* untuk membantu menjaga keseimbangan distribusi label pada tahap pembagian. Data kemudian dirangkum pada level grup dengan menyusun daftar *group_id* beserta ringkasan distribusinya, misalnya komposisi gender dan *ethnicity* serta statistik *avg_trait* per grup. Berdasarkan ringkasan tersebut, dilakukan pembagian 3:1:1 pada level *group_id* untuk membentuk *train_strict*, *val_strict*, dan *test_strict*, dengan stratifikasi agar distribusi gender dan *ethnicity* serta *avg_trait* pada tiap *split* mendekati distribusi keseluruhan dataset.

Setelah *split* terbentuk, dilakukan validasi *split* untuk memastikan prosedur *strict split* terpenuhi. Validasi mencakup pengecekan *group_id disjoint* antar *split* sebagai syarat utama, pengecekan *clip_id disjoint* sebagai *sanity check*, pemeriksaan rasio ukuran yang mendekati 3:1:1 dalam toleransi wajar, serta ringkasan distribusi gender, *ethnicity*, dan *avg_trait* per *split* untuk memastikan tidak ada *split* yang terlalu timpang. Apabila kriteria belum terpenuhi, alokasi *group_id* diperbaiki dan proses *split* diulang hingga lolos validasi. Rangkaian prosedur ini dirangkum pada Gambar 3.2, dan setelah validasi, *test_strict* dikunci serta hanya digunakan sekali pada evaluasi final tanpa dipakai dalam proses *tuning*.

3.1.3 Prosedur Praproses Dataset



Gambar 3.3 Alur Praproses Dataset

Pada tahap *preprocessing*, seluruh sampel audio disiapkan agar memiliki format yang seragam dan memenuhi kualitas minimum sebelum masuk ke proses *strict split* dan pelatihan model. Proses diawali dengan mengambil metadata dari *official* dataset, terutama *clip_id* atau nama file, atribut *gender* dan *ethnicity*, serta label *Big Five*. Selanjutnya dilakukan pemetaan *clip_id* menjadi *group_id* (misalnya berdasarkan bagian *prefix* sebelum ekstensi) agar setiap klip dapat ditautkan ke identitas grup yang konsisten untuk kebutuhan pemisahan berbasis grup pada tahap berikutnya. Dengan demikian, sejak awal preprocessing sudah menyiapkan informasi yang diperlukan untuk mencegah tercampurnya sampel dari grup yang sama di *split* berbeda.

Setelah metadata siap, audio per klip (hasil ekstraksi dari video) dimuat lalu dilakukan *decode* dan pengecekan format untuk memastikan berkas tidak korup serta parameter dasar dapat dibaca dengan benar, seperti jumlah kanal, *sample rate*, dan durasi. Jika proses decode gagal, sampel dikategorikan sebagai *hard-fail* dan langsung dihapus dari kandidat data dengan alasan *decode_failed*. Jika decode berhasil, dilakukan pengecekan durasi, dan sampel dengan durasi yang terlalu pendek (misalnya < 1 detik) juga diperlakukan sebagai *hard-fail* dan dihapus dengan alasan *too_short* karena dianggap tidak cukup representatif untuk analisis suara.

Untuk sampel yang lolos, audio kemudian dinormalisasi secara deterministik dengan konversi menjadi mono dan *resample* ke 16 kHz. Setelah itu durasi dipaksa ke target 15 detik, yaitu dengan trim bila durasi lebih panjang dari 15 detik, atau padding bila lebih pendek dari 15 detik. Penyeragaman ini dilakukan agar seluruh klip memiliki panjang masukan yang konsisten sehingga proses ekstraksi representasi dan pelatihan model tidak dipengaruhi variasi panjang sinyal. Sampel yang dipadding tetap dipertahankan, namun diberi penanda *flag_short=1* untuk membedakan klip yang durasi aslinya kurang dari target dan memungkinkan analisis tambahan apabila diperlukan.


Berikutnya, dilakukan estimasi aktivitas ujaran menggunakan Silero VAD untuk memperoleh *speech timestamps* dan menghitung statistik ringkas, seperti *speech_sec*, *voiced_ratio*, dan *num_segments* (atau *n_seg*). Tahap ini berfungsi sebagai *quality control* untuk memastikan klip memang mengandung ujaran yang memadai, bukan dominan hening atau noise. Sampel yang memiliki ujaran terlalu sedikit (misalnya *speech_sec* < 2 detik) dikategorikan sebagai bagian dari cleaning dan dihapus dengan alasan *too_little_speech*. Pemisahan antara *hard-fail* dan *cleaning* membantu memperjelas bahwa sebagian data dibuang karena masalah teknis berkas, sedangkan sebagian lain dibuang karena kandungan ujarannya tidak memenuhi ambang minimal untuk eksperimen *audio-only*.

Selain menjadi filter kualitas, keluaran VAD juga memberikan gambaran karakteristik data yang digunakan, misalnya seberapa sering klip memiliki segmen ujaran yang terputus-putus atau dominan hening. Informasi seperti *voiced_ratio* dan *num_segments* dapat dipakai sebagai indikator tambahan untuk memonitor kondisi dataset setelah cleaning, misalnya untuk memastikan bahwa data yang tersisa tidak didominasi klip dengan ujaran yang sangat pendek namun lolos ambang *speech_sec*. Walaupun pada tahap ini ambang yang digunakan hanya *speech_sec*, pencatatan metrik lain tetap dipertahankan agar proses preprocessing dapat diaudit dan, bila diperlukan, kriteria cleaning dapat dievaluasi ulang tanpa mengulang keseluruhan pipeline dari awal.

Dari sisi implementasi, seluruh langkah pada preprocessing dibuat deterministik agar hasilnya konsisten ketika pipeline dijalankan ulang. Konversi kanal, *resampling*, serta kebijakan trim atau padding diterapkan dengan aturan yang sama untuk semua sampel, sehingga setiap *clip_id* akan menghasilkan keluaran yang identik selama sumber audionya sama. Pendekatan ini penting untuk menjaga reproduktibilitas eksperimen, terutama ketika proses pelatihan dilakukan dalam beberapa skenario dan parameter berbeda. Selain itu, pencatatan alasan *drop* pada setiap tahap juga membantu menelusuri sumber perubahan jika jumlah sampel bersih berbeda setelah dilakukan penyesuaian kecil pada pipeline, misalnya perubahan ambang durasi atau ambang *speech_sec*.

Seluruh hasil preprocessing kemudian disimpan sebagai artefak yang siap dipakai pada tahap berikutnya. Untuk sampel yang lolos, dibuat berkas audio akhir *preprocessed_full.wav* (16 kHz, mono, 15 detik) serta *manifest.csv* yang memuat metadata awal ditambah metadata hasil preprocessing, seperti durasi, *flag_short*, statistik VAD (*speech_sec*, *voiced_ratio*, *num_segments*), dan *drop_reason* bila sampel dibuang. Untuk sampel yang tidak lolos, dicatat pada log terpisah *drop_list.csv* berisi *list* dan alasan penghapusan. Artefak ini juga memudahkan pelacakan jumlah sampel yang tersisa pada tiap tahap. Rangkaian preprocessing ini dirangkum dalam bentuk diagram alir pada Gambar 3.3, dan keluaran tahap ini menjadi input langsung untuk proses *strict split* serta pelatihan model.

3.1.4 Skenario *baseline* representasi & model




Gambar 3.4 Alur Skenario dan Representasi Model

Pada Skenario *baseline* representasi & model, penelitian ini membandingkan beberapa pendekatan dasar (*baseline*) untuk memprediksi *Big Five* dari audio, sebelum masuk ke tahap *fine-tuning*. Secara umum terdapat dua jalur utama, yaitu (1) representasi *embedding* dari transformer *speech pretrained* dalam kondisi *frozen*, dan (2) fitur *handcrafted* berbasis eGeMAPS. Pada jalur *embedding*, digunakan beberapa *backbone* SSL yang umum dipakai untuk representasi suara, yaitu HuBERT, wav2vec 2.0, dan WavLM. Untuk setiap *backbone*, audio diekstraksi menjadi *embedding*, lalu dilakukan pooling statistik (*mean+std*) agar representasi *frame-level* berubah menjadi satu vektor klip per sampel; hasilnya adalah beberapa vektor klip (satu per *backbone*) yang kemudian masing-masing dilatih menggunakan regressor dan modelnya disimpan sehingga menghasilkan prediksi *Big Five* dari tiap *backbone*. Pada jalur

handcrafted, seluruh fitur eGeMAPS diambil dari audio, kemudian dilakukan standarisasi menggunakan StandardScaler (hanya di-fit pada data *train*), lalu fitur tersebut dilatih menggunakan regressor ter-regularisasi untuk menghasilkan prediksi *Big Five* dan modelnya disimpan. Seluruh output skenario *baseline* (prediksi, metrik, dan model) dikumpulkan untuk dibandingkan, dan khusus pada protokol *strict split*, pemilihan *backbone*/model terbaik dilakukan berdasarkan kinerja pada *val_strict* (bukan *test*) sebelum dilanjutkan ke tahap fine-tune *backbone* terbaik sebagai subproses terpisah. Rangkaian skenario *baseline* ini dirangkum dalam diagram alir pada Gambar 3.4.

3.1.5 Strategi *Fine-tuning* dan *Tuning* Hyperparameter LoRA



Gambar 3.5 Diagram Alir Strategi *Fine-tuning* dengan LoRA

Pada skenario *fine-tuning* seperti yang ditunjukkan pada Gambar 3.5, model dimulai dari backbone SSL terbaik yang sebelumnya dipilih berdasarkan performa validasi pada skema *strict split*. Dataset *strict split* sudah dipersiapkan menjadi *train_strict*, *val_strict*, dan *test_strict*, lalu *test_strict* dikunci agar tidak dipakai pada proses pemilihan hiperparameter. Dengan pengaturan ini, seluruh keputusan tuning hanya bergantung pada *val_strict*, sehingga evaluasi akhir pada *test_strict* tetap merefleksikan generalisasi model tanpa “terbocor” oleh proses seleksi.

Backbone terpilih kemudian dimuat dari bobot pralatih, lalu parameter backbone asli dibuat tidak terlatih (misalnya `requires_grad=False`). Setelah itu dipasang LoRA (PEFT) pada modul target tertentu di dalam arsitektur, umumnya pada proyeksi perhatian seperti `q_proj` dan `v_proj`.


Intinya, LoRA menambahkan komponen bobot ber-rank rendah yang dilatih untuk memodifikasi perilaku layer tertentu, sementara bobot backbone utama tetap dibekukan. Di sisi keluaran, ditambahkan regression head yang memetakan representasi backbone menjadi 5 skor *Big Five*, sehingga parameter yang benar-benar dioptimasi hanya LoRA dan head.

Untuk menjaga konsistensi antar percobaan, beberapa parameter dibuat tetap pada semua run. Loss yang dipakai adalah MAE (dirata-ratakan atas 5 trait), sedangkan skor seleksi ditulis sebagai $S = 1 - \text{MAE}$ pada *val_strict* agar “semakin besar semakin baik” ketika dibandingkan antar konfigurasi. Optimisasi memakai AdamW dengan pengaturan umum seperti *weight decay*, jumlah epoch maksimum, *early stopping* berbasis *patience*, *gradient clipping*, dan *seed* untuk mengurangi variasi akibat inisialisasi acak. Selama training, model disimpan sebagai checkpoint “terbaik” berdasarkan nilai S tertinggi di validasi.

Tuning dilakukan dalam dua fase agar jumlah kombinasi yang diuji tidak terlalu banyak. Fase 1 memvariasikan *learning rate* (LR) dengan rank LoRA dibuat tetap, lalu dipilih *LR_best* berdasarkan skor validasi terbaik. Setelah itu Fase 2 memvariasikan rank LoRA (r) dengan LR yang sudah dikunci menjadi *LR_best*, lalu dipilih *r_best* berdasarkan perbandingan skor validasi. Dengan strategi dua fase ini, pemilihan hiperparameter tetap terarah dan lebih efisien dibanding menguji semua kombinasi $\text{LR} \times \text{r}$ sekaligus.

Setelah konfigurasi terbaik (*LR_best*, *r_best*) diperoleh, dilakukan retrain final menggunakan gabungan *train_strict* + *val_strict* dengan konfigurasi tersebut tanpa tuning lanjutan, kemudian model diuji sekali pada *test_strict*. Pada tahap akhir ini dilaporkan MAE dan skor S sesuai definisi yang sama, dan checkpoint terbaik disimpan sebagai output utama. Alur ini memastikan bahwa LoRA digunakan sebagai metode *fine-tuning* yang ringan, terkontrol, dan tetap mengikuti prinsip evaluasi yang ketat karena pemilihan model tidak pernah menggunakan *test_strict* sebelum evaluasi final.

3.1.6 Prosedur Pelatihan per-Run



Gambar 3.6 Diagram Alir Pelatihan per-Run

Tahap ini akan menjelaskan alur pada setiap *run* (satu konfigurasi *hyperparameter*) selama proses pelatihan pada skema *strict*. Proses diawali dengan inisialisasi keadaan run, yaitu menetapkan nilai awal *best_S* (skor terbaik sementara), *patience_cnt* (penghitung *early stopping*), serta epoch awal. Pada tahap ini juga dilakukan inisialisasi optimizer sesuai konfigurasi run (misalnya nilai *learning rate*) dan penyiapan mekanisme *early stopping*.

Selanjutnya, loop berjalan selama epoch masih berada dalam batas MaxEpoch. Pada setiap iterasi, model dilatih selama 1 epoch menggunakan data *train_strict*. Di dalam epoch, proses pelatihan mengikuti urutan standar *forward pass* untuk menghasilkan prediksi, perhitungan loss, *backward pass* untuk menghitung gradien, penerapan *gradient clipping* untuk menjaga stabilitas optimisasi, dan diakhiri dengan langkah update parameter melalui optimizer. Setelah 1 epoch training selesai, model dievaluasi pada *val_strict* untuk menghitung MAE, lalu skor seleksi didefinisikan sebagai $S = 1 - \text{MAE}$ (menggunakan rata-rata MAE dari lima trait) sebagaimana diringkas pada Gambar 3.6.

Skor validasi pada epoch tersebut kemudian dibandingkan dengan *best_S*. Jika *S* lebih baik daripada *best_S*, maka *best_S* diperbarui, *patience_cnt* direset menjadi 0, dan checkpoint model terbaik disimpan untuk run tersebut (misalnya berupa bobot LoRA dan regression head beserta informasi pelatihan yang relevan). Sebaliknya, jika skor tidak membaik, *patience_cnt* dinaikkan satu. Mekanisme ini memastikan bahwa hanya model dengan performa validasi terbaik yang dipertahankan, sementara epoch-epoch yang tidak memberi peningkatan tidak memperbarui checkpoint.

Tahap berikutnya adalah pemeriksaan kondisi penghentian. Jika *patience_cnt* mencapai nilai *Patience*, maka run dihentikan lebih awal (*early stopping*) karena performa validasi tidak membaik dalam beberapa epoch berturut-turut. Jika belum mencapai *Patience*, nilai epoch dinaikkan dan loop kembali ke proses training epoch berikutnya hingga MaxEpoch tercapai. Setelah run berhenti, baik karena *early stopping* maupun karena MaxEpoch terpenuhi, ringkasan hasil run dicatat berupa *best_S*, konfigurasi hiperparameter, dan rujukan checkpoint terbaik. Ringkasan ini kemudian digunakan oleh alur tuning pada tahap berikutnya untuk memilih konfigurasi terbaik berdasarkan skor validasi, sesuai rangkaian proses yang dirujuk pada Gambar 3.6.

3.2 Bahan dan Peralatan yang Digunakan

Bagian ini menjelaskan bahan dan peralatan yang digunakan selama penelitian. Bahan penelitian berfokus pada dataset yang menjadi sumber data utama untuk pemodelan kepribadian berbasis suara. Peralatan penelitian mencakup perangkat keras dan lingkungan komputasi yang digunakan untuk menjalankan tahap praproses audio, ekstraksi fitur, pelatihan model, serta evaluasi kinerja.

3.2.1 Dataset

Dataset yang digunakan adalah *Chalearn First impressions V2*. Dataset ini terdiri dari 10.000 klip dengan durasi rata rata sekitar 15 detik yang diekstraksi dari lebih dari 3.000 video YouTube berkualitas tinggi. Data pada dataset ini pada dasarnya bersifat multimodal karena memuat video dan audio, namun pada penelitian ini hanya sinyal audio yang digunakan. Audio diperoleh dengan mengekstraksi kanal suara dari setiap klip sehingga seluruh tahapan pemodelan dilakukan dalam skenario *audio-only*.

Setiap sampel memiliki anotasi target berupa lima skor kepribadian *Big Five* yaitu *Openness*, *Conscientiousness*, *Extraversion*, *Agreeableness*, dan *Neuroticism*. Kelima skor tersebut berbentuk nilai kontinu dengan rentang 0 sampai 1, sehingga tugas yang dikerjakan termasuk regresi multivariabel. Dataset juga menyediakan pembagian data resmi ke dalam *train*, *validation*, dan *test* dengan rasio 3 banding 1 banding 1.

3.2.2 Perangkat Keras Hardware

Proses komputasi pada penelitian ini dijalankan menggunakan perangkat laptop sebagai lingkungan utama untuk pengolahan data, praproses audio, ekstraksi fitur, pelatihan model pada skala terbatas, serta evaluasi. Laptop yang digunakan memiliki prosesor Intel Core i5 1135G7 generasi ke 11 dengan 4 inti dan 8 thread, serta memori utama sebesar 16 GB DDR4 yang berjalan pada konfigurasi dual *channel*. Untuk kebutuhan grafis dan akselerasi komputasi tertentu, perangkat menyediakan GPU terintegrasi Intel Iris Xe Graphics dan GPU diskrit NVIDIA GeForce MX350 dengan VRAM 2 GB.

Pada beberapa tahap yang membutuhkan komputasi lebih berat, terutama saat eksperimen dilakukan berulang atau ketika pelatihan model memerlukan akselerasi GPU yang lebih memadai, lingkungan komputasi berbasis cloud digunakan sebagai alternatif. Salah satu opsi yang dipertimbangkan adalah Kaggle Notebook, sehingga proses pelatihan dan pengujian dapat dijalankan pada sumber daya komputasi yang disediakan platform tersebut. Penggunaan Kaggle bersifat pelengkap, sedangkan pencatatan hasil eksperimen dan pengelolaan data tetap dilakukan secara konsisten agar konfigurasi penelitian yang dilaporkan sesuai dengan implementasinya.

3.3 Urutan Pelaksanaan Penelitian

Penelitian tugas akhir ini akan dilaksanakan selama enam bulan dari Januari sampai dengan Juni 2026. Lini masa pengerjaan tugas akhir bisa dilihat pada Tabel 3.1.

Tabel 3.1 Lini masa pengerjaan tugas akhir

No	Aktivitas	JAN	FEB	MAR	APR	MEI	JUNI
1	Studi literatur & Pemahaman Konteks Permasalahan						
2	Pengumpulan Dataset						
3	Praproses Data (<i>Data Preprocessing</i>)						
4	Perancangan dan Implementasi Model						
5	Pengujian dan Evaluasi (<i>Testing</i>)						
6	Evaluasi						
7	Penulisan laporan Tugas Akhir						

Halaman ini sengaja dikosongkan.

DAFTAR PUSTAKA

- Aslan, S., Gdkbay, U., & Dibeklioglu, H. (2021). Multimodal assessment of apparent personality using feature attention and error consistency constraint. *Image and Vision Computing, 110*. <https://doi.org/10.1016/j.imavis.2021.104163>
- Baevski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations*. <http://arxiv.org/abs/2006.11477>
- Barchi, R., Pepino, L., Gauder, L., Estienne, L., Meza, M., Riera, P., & Ferrer, L. (2023). *Apparent personality prediction from speech using expert features and wav2vec 2.0*. 21–25. <https://doi.org/10.21437/smm.2023-5>
- Chen, S., Wang, C., Chen, Z., Wu, Y., Liu, S., Chen, Z., Li, J., Kanda, N., Yoshioka, T., Xiao, X., Wu, J., Zhou, L., Ren, S., Qian, Y., Qian, Y., Wu, J., Zeng, M., Yu, X., & Wei, F. (2022). *WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing*. <https://doi.org/10.1109/JSTSP.2022.3188113>
- Davis, S. B., & Mermelstein, P. (1980). *Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences*.
- Escalante, H. J., Kaya, H., Salah, A. A., Escalera, S., Gucluturk, Y., Guclu, U., Baro, X., Guyon, I., Junior, J. C. S. J., Madadi, M., Ayache, S., Viegas, E., Gurpnar, F., Wicaksana, A. S., Liem, C. C. S., Van Gerven, M. A. J., & Van Lier, R. (2022). Modeling, Recognizing, and Explaining Apparent Personality from Videos. *IEEE Transactions on Affective Computing, 13*(2), 894–911. <https://doi.org/10.1109/TAFFC.2020.2973984>
- Eyben, F., Scherer, K. R., Schuller, B. W., Sundberg, J., Andre, E., Busso, C., Devillers, L. Y., Epps, J., Laukka, P., Narayanan, S. S., & Truong, K. P. (2016). The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for Voice Research and Affective Computing. *IEEE Transactions on Affective Computing, 7*(2), 190–202. <https://doi.org/10.1109/TAFFC.2015.2457417>
- Eyben, F., Wllmer, M., & Schuller, B. (2010). OpenSMILE - The Munich versatile and fast open-source audio feature extractor. *MM'10 - Proceedings of the ACM Multimedia 2010 International Conference*, 1459–1462. <https://doi.org/10.1145/1873951.1874246>
- Ghassemi, S., Zhang, T., Van Breda, W., Koutsoumpis, A., Oostrom, J. K., Holtrop, D., & De Vries, R. E. (2024). Unsupervised Multimodal Learning for Dependency-Free Personality Recognition. *IEEE Transactions on Affective Computing, 15*(3), 1053–1066. <https://doi.org/10.1109/TAFFC.2023.3318367>
- Goldberg, L. R. (1990). *An Alternative “Description of Personality”: The Big-Five Factor Structure*.
- Goncalves, L., Robinson, D., Richerson, E., & Busso, C. (2024). Bridging Emotions Across Languages: Low Rank Adaptation for Multilingual Speech Emotion Recognition. *Proceedings of the Annual Conference of the International Speech Communication Association, INTERSPEECH*, 4688–4692. <https://doi.org/10.21437/Interspeech.2024-1226>

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *Springer Series in Statistics The Elements of Statistical Learning Data Mining, Inference, and Prediction*.
- Hoerl, A. E., & Kennard, R. W. (1970). *Ridge Regression: Biased Estimation for Nonorthogonal Problems* (Vol. 12, Nomor 1).
- Houlsby, N., Giurgiu, A., Jastrzebski, S. J., Morrone, B., De Laroussilhe, Q., Gesmundo, A., Attariyan, M., & Gelly, S. (2019). *Parameter-Efficient Transfer Learning for NLP*. <https://gluebenchmark.com/>
- Hsu, W.-N., Bolte, B., Tsai, Y.-H. H., Lakhotia, K., Salakhutdinov, R., & Mohamed, A. (2021). *HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units*. <http://arxiv.org/abs/2106.07447>
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). *LoRA: Low-Rank Adaptation of Large Language Models*. <http://arxiv.org/abs/2106.09685>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning with Applications in R Second Edition*.
- Kingma, D. P., & Ba, J. (2017). *Adam: A Method for Stochastic Optimization*. <http://arxiv.org/abs/1412.6980>
- Lewkowycz, A. (2021). *How to decay your learning rate*. <http://arxiv.org/abs/2103.12682>
- Lisa Li, X., & Liang, P. (2021). *Prefix-Tuning: Optimizing Continuous Prompts for Generation*.
- Loshchilov, I., & Hutter, F. (2019). *Decoupled Weight Decay Regularization*. <http://arxiv.org/abs/1711.05101>
- Mccrae, R. R., & John, O. P. (1992). *An Introduction to the Five-Factor Model and Its Applications*. <https://digitalcommons.unl.edu/publichealthresources>
- National Institute of Standards, & Technology. (2010). *Root Mean Square Error (LET)*. <https://www.itl.nist.gov/div898/software/dataplot/refman2/auxillar/rms.htm>
- Ney, I. H., & Schlüter, R. (2010). *Introduction to Automatic Speech Recognition*. http://www-i6.informatik.rwth-aachen.de/web/Teaching/Lectures/WS10_11/asr
- Pascanu, R., Mikolov, T., & Bengio, Y. (2013). *On the difficulty of training recurrent neural networks*.
- Ponce-López, V. P., Chen, B., Oliu, M., Corneanu, C., Clapes, A., Guyon, I., Baro, X., Escalante, H. J., & Escalera, S. (2016). *ChaLearn LAP 2016: First Round Challenge on First Impressions - Dataset and Results* (G. Hua & H. Jégou, Ed.; Vol. 9915). Springer International Publishing. <https://doi.org/10.1007/978-3-319-49409-8>
- Prechelt, L. (1997). *Early Stopping | but when?*
- Rubio, V. J., Aguado, D., Toledano, D. T., & Fernández-Gallego, M. P. (2024). Feasibility of Big Data Analytics to Assess Personality Based on Voice Analysis. *Sensors*, 24(22). <https://doi.org/10.3390/s24227151>

- scikit-learn developers. (2007). *scale — scikit-learn 1.8.0 documentation*. <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.scale.html>
- Silero Team. (2024). Silero VAD: pre-trained enterprise-grade Voice Activity Detector (VAD), Number Detector and Language Classifier. Dalam *GitHub repository*. <https://github.com/snakers4/silero-vad>
- Smith, S. W. (1999). *Digital Signal Processing Second Edition* (Vol. 2). California Technical Publishing. www.DSPguide.com
- Vaswani, A., Brain, G., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention Is All You Need*.
- Weenink, D. (2007). *Speech Signal Processing*.
- Zaken, E. Ben, Ravfogel, S., & Goldberg, Y. (2022). *BitFit: Simple Parameter-efficient Fine-tuning for Transformer-based Masked Language-models*. <http://arxiv.org/abs/2106.10199>
- Zhao, X., Liao, Y., Tang, Z., Xu, Y., Tao, X., Wang, D., Wang, G., & Lu, H. (2022). Integrating audio and visual modalities for multimodal personality trait recognition via hybrid deep learning. *Frontiers in Neuroscience*, 16. <https://doi.org/10.3389/fnins.2022.1107284>

Halaman ini sengaja dikosongkan.

LAMPIRAN