

TUGAS AKHIR - EF234801

**IMPLEMENTASI AGENTIC RETRIEVAL AUGMENTED
GENERATION AI INKLUSIF BERBASIS MODEL CONTEXT
PROTOCOL DAN MULTIMODAL INFERENCE ENGINE
MENGUNAKAN ARSITEKTUR GEMMA DAN CLIP
VISION TRANSFORMER (STUDI KASUS NEUTRACK AI
GLOVE)**

FIRANIA PUTRI HARSANTI

NRP 5025221023

Dosen Pembimbing

Dini Adni Navastara, S.Kom., M.Sc.

NIP 198510172015042001

Dosen Ko-pembimbing

Prof. Ary Mazharuddin Shiddiqi, S.Kom., M.Comp.Sc., Ph.D

NIP 198106202005011003

Program Studi S-1 Teknik Informatika

Departemen Teknik Informatika

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

Halaman ini sengaja dikosongkan.



TUGAS AKHIR - EF234801

**IMPLEMENTASI AGENTIC RETRIEVAL AUGMENTED
GENERATION AI INKLUSIF BERBASIS MODEL CONTEXT
PROTOCOL DAN MULTIMODAL INFERENCE ENGINE
MENGUNAKAN ARSITEKTUR GEMMA DAN CLIP
VISION TRANSFORMER (STUDI KASUS NEUTRACK AI
GLOVE)**

FIRANIA PUTRI HARSANTI

NRP 5025221023

Dosen Pembimbing

Dini Adni Navastara, S.Kom., M.Sc

NIP 198510172015042001

Dosen Ko-pembimbing

Prof. Ary Mazharuddin Shiddiqi, S.Kom., M.Comp.Sc., Ph.D

NIP 198106202005011003

Program Studi S-1 Teknik Informatika

Departemen Teknik Informatika

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

Halaman ini sengaja dikosongkan.



FINAL PROJECT - EF234801

**IMPLEMENTATION OF INCLUSIVE AGENTIC AI BASED
ON MODEL CONTEXT PROTOCOL AND MULTIMODAL
INFERENCE ENGINE USING GEMMA ARCHITECTURE
AND CLIP VISION TRANSFORMER (CASE STUDY:
NEUTRACK AI GLOVE**

FIRANIA PUTRI HARSANTI

NRP 5025221023

Advisor

Dini Adni Navastara, S.Kom., M.Sc

NIP 198510172015042001

Co-advisor

Prof. Ary Mazharuddin Shiddiqi, S.Kom., M.Comp.Sc., Ph.D

NIP 198106202005011003

Undergraduate Study Program of Informatics

Department of Informatics

Faculty of Intelligent Electrical and Informatics Technology

Institut Teknologi Sepuluh Nopember

Surabaya

2026

Halaman ini sengaja dikosongkan.

LEMBAR PENGESAHAN

IMPLEMENTASI AGENTIC AI INKLUSIF BERBASIS MCP DAN MULTIMODAL INFERENCE ENGINE MENGGUNAKAN ARSITEKTUR GEMMA DAN CLIP VISION TRANSFORMER (STUDI KASUS NEUTRACK AI GLOVE)

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Komputer pada
Program Studi S-1 Teknik Informatika
Departemen Teknik Informatika
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember

Oleh: **FIRANIA PUTRI HARSANTI**

NRP. 5025221023

Disetujui oleh Tim Penguji Tugas Akhir:

- | | |
|--|---------------|
| 1. Dini Adni Navastara, S.Kom., M.Sc. | Pembimbing |
| 2. Prof. Ary Mazharuddin Shiddiqi, S.Kom.,
M.Comp.Sc., Ph.D | Ko-pembimbing |
| 3. <Nama dan gelar penguji> | Penguji |
| 4. <Nama dan gelar penguji> | Penguji |

SURABAYA

Januari, 2026

Halaman ini sengaja dikosongkan.

APPROVAL SHEET

IMPLEMENTATION OF INCLUSIVE AGENTIC RETRIEVAL AUGMENTED GENERATION AI BASED ON MODEL CONTEXT PROTOCOL AND MULTIMODAL INFERENCE ENGINE USING GEMMA ARCHITECTURE AND CLIP VISION TRANSFORMER (CASE STUDY: NEUTRACK AI GLOVE)

FINAL PROJECT

Submitted to fulfill one of the requirements
for obtaining a Bachelor of Computer Science degree at
Undergraduate Study Program of Informatics
Department of Informatics
Faculty of Intelligent Electrical and Informatics Technology
Institut Teknologi Sepuluh Nopember

By: **FIRANIA PUTRI HARSANTI**

NRP. 5025221023

Approved by Final Project Examiner Team:

- | | |
|--|------------|
| 1. Dini Adni Navastara, S.Kom., M.Sc. | Advisor |
| 2. Prof. Ary Mazharuddin Shiddiqi, S.Kom.,
M.Comp.Sc., Ph.D | Co-advisor |
| 3. <Name and title> | Examiner 1 |
| 4. <Name and title> | Examiner 2 |

SURABAYA

January, 2026

This page is intentionally left blank.

PERNYATAAN ORISINALITAS

Yang bertanda tangan di bawah ini:

Nama mahasiswa / NRP : Firania Putri Harsanti / 5025221023
Program Studi : S-1 Teknik Informatika
Dosen Pembimbing / NIP : Dini Adni Navastara, S.Kom., M.Sc. /
198510172015042001
Dosen Ko-pembimbing / NIP : Prof. Ary Mazharuddin Shiddiqi, S.Kom., M.Comp.Sc.,
Ph.D / 198106202005011003

dengan ini menyatakan bahwa Tugas Akhir dengan judul “Implementasi Agentic Retrieval Augmented Generation AI Inklusif berbasis Model Context Protocol dan Multimodal Inference Engine Menggunakan Arsitektur Gemma dan CLIP Vision Transformer (Studi Kasus Neutrack AI Glove)” adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Mengetahui
Dosen Pembimbing

Surabaya, 22 Desember 2025
Mahasiswa

Dini Adni Navastara, S.Kom., M.Sc.
NIP. 198510172015042001

Firania Putri Harsanti
NRP. 5025221023

Dosen Ko-pembimbing

Prof. Ary Mazharuddin Shiddiqi, S.Kom.
NIP. 198510172015042001

Halaman ini sengaja dikosongkan.

STATEMENT OF ORIGINALITY

The undersigned:

Student Name / Student ID : Firania Putri Harsanti / 5025221023
Study Program : Bachelor of Informatics
Advisor / Employee ID : Dini Adni Navastara, S.Kom., M.Sc. /
198510172015042001
Co-advisor / Employee ID : Prof. Ary Mazharuddin Shiddiqi, S.Kom., M.Comp.Sc.,
Ph.D / 198106202005011003

hereby declares that the Final Project entitled “Implementation of Inclusive Agentic Retrieval Augmented Generation AI Based on Model Context Protocol and Multimodal Inference Engine Using Gemma Architecture and CLIP Vision Transformer (Case Study: Neutrack AI Glove)” is my own work, is original, and was written in accordance with the rules of scientific writing.

If any discrepancies with this statement are found in the future, I am willing to accept sanctions in accordance with the provisions of Institut Teknologi Sepuluh Nopember.

Acknowledged
Advisor

Surabaya, December 22, 2025
Student

Dini Adni Navastara, S.Kom., M.Sc.
NIP. 198510172015042001

Firania Putri Harsanti
NRP. 5025221023

Co-advisor

Prof. Ary Mazharuddin Shiddiqi, S.Kom.
NIP. 198510172015042001

This page is intentionally left blank.

PERNYATAAN KODE ETIK
PENGUNAAN AI GENERATIF
Code of Conduct Statement: Generative AI or AI-Assisted Usage

Saya yang bertanda tangan di bawah ini:
I, the undersigned:

Nama Mahasiswa / NRP : Firania Putri Harsanti / 5025221023
Full Name / Student ID

Program Studi : S-1 Teknik Informatika
Study Program

Judul Tugas Akhir : Implementasi Agentic Retrieval Augmented Generation
Final Project Title
AI Inklusif berbasis Model Context Protocol dan
Multimodal Inference Engine Menggunakan Arsitektur
Gemma dan CLIP Vision Transformer (Studi Kasus
Neutrack AI Glove)

dengan ini menyatakan bahwa pada Tugas Akhir dengan judul di atas tersebut:
hereby declare that in the Final Project with the above title:

No.	Pernyataan <i>Statement</i>	(☑)
1	Saya hanya menggunakan AI generatif sebagai alat bantu untuk memperbaiki tata bahasa. AI generatif tidak digunakan untuk membuat isi Tugas Akhir. <i>I only used generative AI as a tool to improve the readability or language of the text in my Final Project. It was not used to generate a complete text of my work.</i>	☑
2	Saya telah memeriksa dan/atau memperbaiki seluruh bagian dari Tugas Akhir saya yang dibantu oleh AI generatif agar sesuai dengan baku mutu penulisan karya ilmiah. <i>I have reviewed and refined all aspects of my work that generative AI assists with, ensuring it adheres to the standards of academic writing.</i>	☑
3	Saya tidak menggunakan AI generatif untuk pembuatan data primer, grafik dan/atau tabel pada Tugas Akhir saya. <i>I did not use generative AI to generate primary data, figures, and/or tables in my work.</i>	☑
4	Saya telah memberikan atribusi/pengakuan terhadap alat AI yang digunakan, secara rinci pada suatu bagian pada lampiran. <i>I have acknowledged the use of generative AI in any part of the work in the specific appendix page.</i>	☑
5	Saya memastikan tidak ada plagiarisme, termasuk hal yang berasal dari penggunaan AI generatif. <i>I have ensured that there is no plagiarism issue in the work, including any parts generated by AI.</i>	☑

Surabaya, 22 Desember 2025

Mahasiswa

Firania Putri Harsanti

NRP. 5025221023

Halaman ini sengaja dikosongkan.

ABSTRAK

IMPLEMENTASI AGENTIC AI INKLUSIF BERBASIS MCP DAN MULTIMODAL INFERENCE ENGINE MENGGUNAKAN ARSITEKTUR GEMMA DAN CLIP VISION TRANSFORMER (STUDI KASUS NEUTRACK AI GLOVE)

Nama Mahasiswa / NRP : Firania Putri Harsanti / 5025221023
Departemen : Teknik Informatika FTIRS - ITS
Dosen Pembimbing : Dini Adni Navastara, S.Kom., M.Sc.
Dosen Ko-pembimbing : Prof. Ary Mazharuddin Shiddiqi S.Kom., M.Comp.Sc., Ph.D

Abstrak

Informasi visual krusial bagi mobilitas mandiri, namun teknologi asistif saat ini sering terkendala privasi data akibat ketergantungan pada layanan *cloud*. Penelitian ini mengembangkan Amadeus (*Autonomous Multi-Agent Unified Swarm Intelligence*), sebuah sistem *backend* cerdas untuk Neutrack AI Glove yang mengimplementasikan *Agentic Retrieval Augmented Generation* (RAG) berbasis *Model Context Protocol* (MCP) menggunakan arsitektur lokal Gemma-2b dan CLIP. Menggunakan dataset orisinal dari kampus ITS dan trotoar Surabaya, evaluasi sistem dilakukan melalui metrik BLEU, ROUGE-L, serta analisis latensi. Hasil menunjukkan bahwa optimasi *Projection Adapter* meningkatkan skor BLEU-4 dari 11,88% menjadi 15,77% dan ROUGE-L sebesar 34,29%. Arsitektur MCP menghasilkan performa paling unggul dibandingkan model *baseline* di berbagai kondisi, dengan capaian pada skenario *outdoor* (BLEU-4 16,65%; ROUGE-L 46,08%), skenario *indoor* (BLEU-4 8,77%; ROUGE-L 33,57%), serta skenario *street* atau Trotoar Surabaya (BLEU-4 7,64%; ROUGE-L 28,21%). Meski menambah latensi pada lingkungan padat, sistem menghasilkan efisiensi respons signifikan pada skenario *street* sebesar 10,75 detik, lebih cepat dibanding *baseline* VLM (15,17 detik). Integrasi MCP efektif memitigasi halusinasi visual melalui verifikasi metadata lokal, sehingga menghasilkan solusi asistif yang presisi dan aman secara mandiri (*on-premise*).

Kata Kunci: *Agentic AI, Image Captioning, Model Context Protocol (MCP), Multimodal RAG, Gemma, CLIP.*

Halaman ini sengaja dikosongkan.

ABSTRACT

IMPLEMENTATION OF INCLUSIVE AGENTIC AI BASED ON MODEL CONTEXT PROTOCOL AND MULTIMODAL INFERENCE ENGINE USING GEMMA ARCHITECTURE AND CLIP VISION TRANSFORMER (CASE STUDY: NEUTRACK AI GLOVE)

Full Name / Student ID : **Firania Putri Harsanti / 5025221023**
Department : **Informatics ELECTICS - ITS**
Advisor : **Dini Adni Navastara, S.Kom., M.Sc.**
Co-advisor : **Prof. Ary Mazharuddin Shiddiqi S.Kom., M.Comp.Sc.,
Ph.D**

Abstract

Visual information is crucial for independent mobility; however, current assistive technologies often face data privacy constraints due to their dependence on cloud services. This research develops Amadeus (Autonomous Multi-Agent Unified Swarm Intelligence), an intelligent backend system for Neutrack AI Glove that implements Agentic Retrieval-Augmented Generation (RAG) based on the Model Context Protocol (MCP) using local architectures of Gemma-2b and CLIP. Utilizing original datasets from the ITS campus and Surabaya sidewalks, the system evaluation was conducted using BLEU and ROUGE-L metrics, as well as latency analysis. The results show that the Projection Adapter optimization increased the BLEU-4 score from 11.88% to 15.77% and the ROUGE-L score to 34.29%. The MCP architecture achieved superior performance compared to the baseline models across various conditions, with results in the outdoor scenario (BLEU-4 16.65%; ROUGE-L 46.08%), indoor scenario (BLEU-4 8.77%; ROUGE-L 33.57%), and street or Surabaya Sidewalk scenario (BLEU-4 7.64%; ROUGE-L 28.21%). Despite increased latency in crowded environments, the system produced significant response efficiency in the street scenario of 10.75 seconds, which is faster than the VLM baseline (15.17 seconds). The integration of MCP effectively mitigates visual hallucinations through local metadata verification, resulting in a precise and secure assistive solution that operates independently (on-premise).

Keywords: Agentic AI, Image Captioning, Model Context Protocol (MCP), Multimodal RAG, Gemma, CLIP.

This page is intentionally left blank.

KATA PENGANTAR

Assalamu'alaikum warahmatullahi wabarakatuh

Puji syukur ke hadirat Allah SWT. atas rahmat dan karunia-Nya, penulis dapat menyelesaikan Tugas Akhir ini yang berjudul **“Implementasi Agentic Retrieval Augmented Generation AI Inklusif berbasis Model Context Protocol dan Multimodal Inference Engine Menggunakan Arsitektur Gemma dan CLIP Vision Transformer (Studi Kasus Neutrack AI Glove)”** sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer di Institut Teknologi Sepuluh Nopember.

Penulisan Tugas Akhir ini tidak akan terlaksana dengan baik tanpa bimbingan, dukungan, dan motivasi dari berbagai pihak. Oleh karena itu, penulis ingin menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Allah SWT. yang telah memberikan kemudahan dan kelancaran dalam penyelesaian Tugas Akhir ini.
2. Nabi Muhammad SAW. yang telah menjadi suri teladan penulis dalam menjalani kehidupan.
3. Ibu Dini Adni Navastara, S.Kom., M.Sc. selaku Dosen Pembimbing I dan Bapak Prof. Ary Mazharuddin Shiddiqi, S.Kom., M.Comp.Sc., Ph.D selaku Dosen Ko-pembimbing II yang telah membantu di masa-masa sulit penulis di kampus. Terima kasih banyak atas bimbingan, saran, serta kesabaran dalam mengarahkan penulis selama proses penyusunan Tugas Akhir ini.
4. Bapak/Ibu Penguji Sidang yang telah memberikan masukan, kritik, dan saran konstruktif demi perbaikan karya ini.
5. Seluruh partisipan pengujian aplikasi yang telah meluangkan waktu dan memberikan umpan balik (*feedback*) berharga untuk pengembangan sistem.
6. Kedua orang tua penulis, Ibu dan Bapak, yang tidak pernah lelah memberikan semangat, doa, dan dukungan, baik di masa-masa sulit penulis di kampus.
7. Eyang Putri Ketut yang selalu mendukung penulis, termasuk membelikan laptop impian. Untuk Kakek, Nenek, dan Om Rama yang selalu mendukung serta mendoakan kelancaran kuliah penulis sampai akhir.
8. Teman-teman Kachponz dan seluruh member Discord *“Ketampanan Yang Menyiksa”* dari seluruh Indonesia yang mendukung atmin menempuh masa remaja ini.

Penulis menyadari bahwa Tugas Akhir ini masih jauh dari sempurna. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun untuk perbaikan di masa mendatang.

Wassalamu'alaikum warahmatullahi wabarakatuh

Surabaya, 22 Desember 2025,

Firania Putri Harsanti

Halaman ini sengaja dikosongkan.

DAFTAR ISI

LEMBAR PENGESAHAN.....	i
APPROVAL SHEET	iii
PERNYATAAN ORISINALITAS	v
STATEMENT OF ORIGINALITY	vii
PERNYATAAN KODE ETIK PENGGUNAAN AI GENERATIF.....	ix
ABSTRAK	xi
ABSTRACT	xiii
KATA PENGANTAR	xv
DAFTAR ISI.....	xvii
DAFTAR GAMBAR	xix
DAFTAR TABEL	xxi
DAFTAR KODE SUMBER	xxiv
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah	2
1.4 Tujuan.....	2
1.5 Manfaat.....	3
1.5.1 Manfaat Teoritis	3
1.5.2 Manfaat Praktis.....	3
1.5.3 Manfaat Sosial	3
BAB 2 TINJAUAN PUSTAKA	5
2.1 Penelitian Terkait.....	5
2.2 Dasar Teori	10
2.2.1 Tantangan bagi Penyandang Tunanetra dan Demensia.....	10
2.2.2 Agentic AI berbasis React Agent <i>Model Context Protocol</i> , dan Pydantic	11
2.2.3 <i>Image Captioning</i> berbasis <i>CLIP ViT Vision Model</i> dan Gemma LLM	14
2.2.4 Optimasi Efisiensi melalui <i>Inference Engine</i>	16
2.2.5 Metrik Evaluasi	18
BAB 3 METODOLOGI.....	23
3.1 Perancangan Sistem.....	23
3.1.1 Persiapan Dataset.....	24
3.1.2 Praproses.....	26

3.1.3	Pelatihan	26
3.1.4	Inference Engine.....	27
3.1.5	Integrasi <i>Wrapper LangChain</i> berbasis MCP	29
3.1.6	Integrasi Retrieval-Augmented Generation Berbasis CLIP	30
3.1.7	Pengujian dan Evaluasi.....	31
3.2	Implementasi	32
3.2.1	Praproses.....	32
3.2.2	Pelatihan	38
3.2.3	Inference Engine.....	40
3.2.4	Integrasi ReAct Agent berbasis MCP.....	41
3.2.5	Integrasi Retrieval-Augmented Generation (RAG) Berbasis CLIP	45
3.2.6	Pengujian dan Evaluasi.....	47
3.2.7	Perancangan Antarmuka.....	47
BAB 4	HASIL DAN PEMBAHASAN	54
4.1	Hasil Penelitian.....	54
4.1.1	Skenario 1: Pencarian <i>Learning Rate</i> Terbaik Pada Model Gemma-CLIP dengan <i>Grid Search</i> Optuna.....	55
4.1.2	Skenario 2: Perbandingan Performa Model Berdasarkan Hyperparameter Tuning	56
4.1.3	Skenario 3: Perbandingan dengan Metode Sebelumnya	56
4.1.4	Skenario 4: Pengujian <i>Tool Calling</i> MCP Supabase dan LLM AI Agent.....	57
4.1.5	Skenario 5: Pengujian Dataset Kampus <i>Indoor</i>	58
4.1.6	Skenario 6: Pengujian Dataset Kampus <i>Outdoor</i>	59
4.1.7	Skenario 7: Pengujian Dataset Trotoar Surabaya	59
4.2	Pembahasan	60
4.2.1	Pengujian Dataset Kampus <i>Indoor</i>	60
4.2.2	Pengujian Dataset Kampus <i>Outdoor</i>	71
4.2.3	Pengujian Dataset Trotoar Surabaya	83
BAB 5	KESIMPULAN DAN SARAN	96
5.1	Kesimpulan.....	96
5.2	Saran	96
DAFTAR PUSTAKA		98
LAMPIRAN.....		103
BIODATA PENULIS		141

DAFTAR GAMBAR

Gambar 2. 1 Model Face Perceptioning oleh Bruce dan Young	10
Gambar 2. 2 Perbandingan Traktori Penalaran antara metode CoT, Act-only, dan ReAct (Yao dkk., 2023).....	11
Gambar 2. 3 React Agent LangGraph (LangChain, 2024).....	12
Gambar 2. 4 Arsitektur Client dan Server Model Context Protocol (Hou dkk., 2025).....	13
Gambar 2. 5 Arsitektur CLIP Vision Model (Radford dkk., 2021)	14
Gambar 3. 1 Diagram alir perancangan sistem.....	23
Gambar 3. 2 Diagram alir praproses data	26
Gambar 3. 3 Diagram alir pelatihan model	27
Gambar 3. 4 Diagram alir inference engine	28
Gambar 3. 5 Diagram alir integrasi React Agent berbasis MCP	30
Gambar 3. 6 Diagram alir integrasi Retrieval Augmented Generation Berbasis CLIP.....	30
Gambar 3. 7 Antarmuka Homepage Aplikasi (a) Modul Fitur (b) Bypass JWT Token	48
Gambar 3. 8 Antarmuka Manajemen Agen (a) Tampilan daftar agen (b) Konfigurasi Agen..	49
Gambar 3. 9 Antarmuka Integrasi MCP (a) Indikator status server MCP (b) Konfigurasi server MCP.....	50
Gambar 3. 10 Antarmuka Agent Creator (a) Input deskripsi pengguna di chatroom (b) Formulir terisi otomatis oleh AI	51
Gambar 3. 11 Antarmuka Agent Invoke Stream berbasis RAG dan MCP Multimodal	52

Halaman ini sengaja dikosongkan.

DAFTAR TABEL

Tabel 3. 1 Contoh Dataset Original	24
Tabel 3. 2 Perbandingan Dimensi Tensor	27
Tabel 3. 3 Contoh Instruction Formatting	33
Tabel 3. 4 Contoh Hasil Tokenisasi.....	34
Tabel 3. 5 Contoh Hasil Normalisasi Gambar.....	36
Tabel 4. 1 Spesifikasi Perangkat Keras	54
Tabel 4. 2 Tabel Skenario Pengujian.....	54
Tabel 4. 3 Pencarian Learning Rate Terbaik Pada Model Gemma-CLIP dengan Optuna.....	55
Tabel 4. 4 Perbandingan Performa Model Berdasarkan Hyperparameter Tuning	56
Tabel 4. 5 Perbandingan dengan Metode Sebelumnya.....	57
Tabel 4. 6 Pengujian Tool Calling MCP Supabase dan LLM AI Agent.....	57
Tabel 4. 7 Rata-rata Skor Akurasi NLP dan Latensi Pengujian Agen Terhadap Dataset Kampus Indoor	58
Tabel 4. 8 Rata-rata Skor Akurasi NLP dan Latensi Pengujian Agen Terhadap Dataset Kampus Outdoor.....	59
Tabel 4. 9 Rata-rata Skor Akurasi NLP dan Latensi Pengujian Agen Terhadap Dataset Trotoar Surabaya	59
Tabel 4. 10 Perbandingan captioining agent pada dataset kampus indoor berdasarkan pertanyaan pertama (tiga tertinggi).....	60
Tabel 4. 11 Perbandingan captioning agent pada dataset kampus indoor berdasarkan pertanyaan pertama (tiga terendah).....	62
Tabel 4. 12 Perbandingan captioning agent pada dataset kampus indoor berdasarkan pertanyaan kedua (tiga tertinggi)	64
Tabel 4. 13 Perbandingan captioning agent pada dataset kampus indoor berdasarkan pertanyaan kedua (tiga terendah)	66
Tabel 4. 14 Perbandingan captioning agent pada dataset kampus indoor berdasarkan pertanyaan ketiga (tiga tertinggi)	68
Tabel 4. 15 Perbandingan captioning agent pada dataset kampus indoor berdasarkan pertanyaan ketiga (tiga terendah).....	70
Tabel 4. 16 Perbandingan captioining agent pada dataset kampus outdoor berdasarkan pertanyaan pertama (tiga tertinggi).....	71
Tabel 4. 17 Perbandingan captioining agent pada dataset kampus outdoor berdasarkan pertanyaan pertama (tiga terendah)	73
Tabel 4. 18 Perbandingan captioining agent pada dataset kampus outdoor berdasarkan pertanyaan kedua (tiga tertinggi).....	75
Tabel 4. 19 Contoh hasil deskripsi perbandingan agent dataset kampus outdoor berdasarkan pertanyaan kedua (tiga terendah).....	77
Tabel 4. 20 Contoh hasil deskripsi perbandingan agent dataset kampus outdoor berdasarkan pertanyaan ketiga (tiga tertinggi).....	79
Tabel 4. 21 Contoh hasil deskripsi perbandingan agent dataset kampus outdoor berdasarkan pertanyaan ketiga (tiga terendah)	81
Tabel 4. 22 Perbandingan captioning agent pada dataset trotoar Surabaya berdasarkan pertanyaan pertama (tiga tertinggi).....	83

Tabel 4. 23 Perbandingan captioning agent pada dataset trotoar Surabaya berdasarkan pertanyaan pertama (tiga terendah)	85
Tabel 4. 24 Perbandingan captioning agent pada dataset trotoar Surabaya berdasarkan pertanyaan kedua (tiga tertinggi).....	87
Tabel 4. 25 Perbandingan captioning agent pada dataset trotoar Surabaya berdasarkan pertanyaan kedua (tiga terendah).....	88
Tabel 4. 26 Perbandingan captioning agent pada dataset trotoar Surabaya berdasarkan pertanyaan ketiga (tiga tertinggi).....	90
Tabel 4. 27 Perbandingan captioning agent pada dataset trotoar Surabaya berdasarkan pertanyaan ketiga (tiga terendah)	92

Halaman ini sengaja dikosongkan.

DAFTAR KODE SUMBER

Pseudocode 2. 1 Waktu Inisiasi Model LLM.....	18
Pseudocode 2. 2 Waktu Inisiasi AI Agent.....	18
Pseudocode 2. 3 Recursions Agent.....	19
Pseudocode 2. 4 Waktu Respons AI Agent.....	19
Pseudocode 3. 1 Praproses Data Teks Deskripsi.....	33
Pseudocode 3. 2 Praproses Data Gambar.....	36
Pseudocode 3. 3 Proses Pelatihan per Epoch.....	38
Pseudocode 3. 4 Proses Validasi per Epoch.....	39
Pseudocode 3. 5 Proses Pelatihan Lengkap.....	40
Pseudocode 3. 6 Inferensi Model Multimodal.....	40
Pseudocode 3. 7 Inisialisasi Proses Proxy.....	41
Pseudocode 3. 8 Pengawasan Status Koneksi.....	42
Pseudocode 3. 9 Manajemen Pembaruan Alat Dinamis (Hot-Swap).....	42
Pseudocode 3. 10 Parsing Konfigurasi Tools MCP.....	43
Pseudocode 3. 11 Konstruksi Agen dan Seleksi Model MaiaRouter atau VLM.....	43
Pseudocode 3. 12 Adaptasi ReAct Text-Based untuk Model Lokal.....	44
Pseudocode 3. 13 Eksekusi Agen Multimodal dengan Binding Tools MCP.....	45
Pseudocode 3. 14 Pengambilan Konteks RAG Berbasis Vektor.....	45
Pseudocode 3. 15 Definisi Tools pada Server MCP RAG.....	46
Pseudocode 3. 16 Pipeline Integrasi VLM, RAG, dan Agent LLM.....	46
Pseudocode 3. 17 Proses Evaluasi Model.....	47
Pseudocode 3. 18 Inisialisasi Server Aplikasi.....	48
Pseudocode 3. 19 Logika Tampilan Manajemen Agen.....	49
Pseudocode 3. 20 Logika Tampilan Manajemen MCP.....	50
Pseudocode 3. 21 Logika AI Autofill pada Agent Creator.....	51
Pseudocode 3. 22 Logika Streaming Percakapan Agen.....	52

Halaman ini sengaja dikosongkan.

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Kesehatan global saat ini tengah menghadapi tantangan besar seiring dengan meningkatnya jumlah kasus gangguan penglihatan dan demensia di seluruh dunia. Berdasarkan data dari World Health Organization (WHO), diperkirakan terdapat 2,2 miliar kasus gangguan penglihatan, dengan 1,1 miliar di antaranya mengalami kebutaan total. Sementara itu, jumlah kasus demensia terus meningkat, dengan lebih dari 5,5 juta kasus yang tercatat saat ini dan proyeksi mencapai 10 juta kasus baru setiap tahunnya. Tunanetra merupakan salah satu jenis kebutuhan khusus yang ditandai dengan hilangnya fungsi indra visual. Individu dengan kondisi ini sering kali kehilangan akses terhadap informasi penting dari lingkungan sekitar yang biasanya dapat diperoleh dengan mudah oleh individu yang memiliki penglihatan normal. Keterbatasan akses terhadap informasi visual ini menimbulkan tantangan besar yang dapat menghambat mobilitas, interaksi dengan lingkungan, hingga keselamatan pribadi, terutama dalam hal membaca teks, mengenali rintangan, dan bernavigasi.

Berbagai upaya teknologi telah dilakukan. Saleh, Ali, dan Ezzat (2022) merancang kacamata cerdas berbasis pengenalan wajah untuk penderita Alzheimer menggunakan algoritma Viola-Jones dan ekstraksi fitur Local Binary Pattern. Meskipun akurasi K-NN mencapai 93,36%, sistem ini masih terbatas pada pengenalan wajah tunggal tanpa *reasoning agent* atau data multimodal yang kompleks. Hal ini menunjukkan bahwa perangkat keras saja tidak cukup; diperlukan perangkat lunak pendukung (*supporting software*) yang cerdas untuk memproses informasi secara mendalam.

Sebagai upaya untuk menjawab tantangan tersebut, penelitian ini mengembangkan sebuah sistem perangkat lunak berbasis Agentic AI yang dirancang khusus untuk menjadi "otak" bagi perangkat keras Neutrack AI Glove. Salah satu pendekatan efisien dalam sistem ini terinspirasi oleh FlexGen (Ying et al., 2023), yang memungkinkan inferensi *Large Language Models* (LLMs) berukuran besar hanya dengan GPU tunggal. Solusi ini sangat relevan untuk diterapkan pada sistem lokal (*on-premise*) yang tertanam pada perangkat pendamping Neutrack.

Untuk memastikan perangkat lunak ini dapat mengelola berbagai alat (sensor kamera, GPS, dll) secara modular, diterapkanlah Model Context Protocol (MCP). Pendekatan pengujian performa protokol ini diperkenalkan secara komprehensif oleh Gao et al. (2025) dalam MCP-RADAR, sebuah *benchmark* yang menilai efisiensi dan ketepatan penggunaan *tool* oleh LLM. Penilaian ini menjadi panduan penting dalam membangun arsitektur perangkat lunak yang memungkinkan Neutrack AI Glove beradaptasi dengan berbagai skenario bantuan. Dalam aspek orkestrasi, Wang dan Duan (2024) mengusulkan integrasi LangGraph sebagai kerangka modular, yang dalam penelitian ini diadopsi untuk mengatur alur kerja agen cerdas pada perangkat lunak pendukung Neutrack. Selain itu, optimalisasi inferensi seperti Seesaw (Park et al., 2025) dan RAViS Framework (Shiddiqi et al., 2023) membuktikan bahwa algoritma *deep learning* kompleks dapat dijalankan secara efisien pada perangkat terbatas. Zongxi Liu dan Hongyang Du (2025) juga mengusulkan *Internet of Experts* (IoX) berbasis MCP, yang sejalan dengan desain sistem ini di mana agen LLM dapat mengakses modul keahlian eksternal tanpa pelatihan ulang.

Oleh karena itu, penelitian ini berfokus pada pengembangan Amadeus (*Autonomous Multi-Agent Unified Swarm Intelligence*)" (Autonomous Multi-Agent based on Swarm

Intelligence) sebuah paket perangkat lunak pendukung yang mengintegrasikan arsitektur *microservices*, MCP, dan model multimodal (Gemma & CLIP). Perangkat lunak ini bertugas memproses input dari Neutrack AI Glove, melakukan penalaran, dan memberikan respons audio yang relevan bagi pengguna tunanetra secara *real-time* dan efisien.

1.2 Rumusan Masalah

Rumusan masalah yang diangkat dalam penelitian ini adalah sebagai berikut:

1. Bagaimana perancangan dan optimasi *Inference Engine Multimodal* secara lokal yang mengintegrasikan model bahasa (Gemma-2b) dan visi komputer (CLIP) dapat meningkatkan kualitas *captioning* sekaligus menjaga privasi data pengguna secara mandiri (*on-premise*)?
2. Bagaimana efektivitas penerapan arsitektur *Agentic AI* berbasis *Model Context Protocol* (MCP) dibandingkan dengan pendekatan *Non-RAG* dan *RAG* standar dalam menghasilkan deskripsi visual yang lebih akurat, detail, dan minim halusinasi pada skenario lingkungan yang kompleks?
3. Bagaimana analisis *trade-off* (kompromi) antara efisiensi waktu respons (*latency*) dan akurasi informasi pada berbagai arsitektur agen guna menentukan kelayakan implementasi sistem sebagai perangkat asistif bagi tunanetra?

1.3 Batasan Masalah

Permasalahan yang dibahas dalam penelitian ini memiliki beberapa batasan, diantaranya sebagai berikut:

1. Penelitian difokuskan pada pengembangan *backend software* Amadeus (*Autonomous Multi-Agent Unified Swarm Intelligence*) yang berfungsi sebagai sistem pendukung cerdas untuk Neutrack AI Glove.
2. Implementasi *Agentic AI* menggunakan integrasi model bahasa Gemma-2 dan CLIP Vision Transformer yang dibangun menggunakan bahasa pemrograman Python dan dioptimalkan untuk berjalan pada perangkat dengan sumber daya terbatas (laptop pendamping atau *edge server*).
3. Sistem dijalankan secara lokal (*on-premises*) untuk meminimalkan latensi jaringan dan menghindari ketergantungan pada layanan *cloud* berbayar.
4. Studi kasus difokuskan pada pengguna tunanetra dalam skenario navigasi dasar dan pengenalan objek visual melalui interaksi suara.

1.4 Tujuan

Tujuan dari penelitian ini diantaranya sebagai berikut:

1. Mengembangkan dan mengoptimalkan *Inference Engine* lokal berbasis *Projection Adapter* yang mampu memproses inferensi multimodal (gambar dan teks) dengan kualitas representasi fitur yang lebih baik (skor BLEU meningkat), memastikan data pengguna tetap privat dan sistem dapat beroperasi tanpa internet.
2. Mengimplementasikan *Model Context Protocol* (MCP) untuk meningkatkan kemampuan penalaran (*reasoning*) agen dalam menangkap detail mikro, konteks aktivitas, dan pembacaan teks, sehingga menghasilkan deskripsi yang lebih superior dibandingkan model *baseline*.

3. Mengevaluasi kinerja sistem perangkat lunak berdasarkan metrik waktu eksekusi (*total latency*) untuk memastikan keseimbangan yang optimal antara kecepatan respons dan ketepatan informasi bagi pengalaman pengguna tunanetra.

1.5 Manfaat

Penelitian Tugas Akhir ini diharapkan dapat memberikan berbagai manfaat, adapun manfaat penelitian ini adalah sebagai berikut:

1.5.1 Manfaat Teoritis

1. Menambah khazanah keilmuan mengenai implementasi arsitektur *Agentic AI* berbasis *Model Context Protocol* (MCP) dan *Multimodal Retrieval-Augmented Generation* (RAG) pada perangkat dengan sumber daya terbatas (*edge devices*), membuktikan bahwa model bahasa kecil (SLM) dapat memiliki kemampuan penalaran yang tinggi jika diorkestrasi dengan benar.
2. Memberikan data empiris mengenai *trade-off* (kompromi) antara efisiensi latensi dan akurasi semantik dalam sistem inferensi lokal, yang dapat menjadi rujukan bagi penelitian selanjutnya dalam optimasi *Inference Engine* tanpa ketergantungan *cloud*.
3. Memperkaya metode evaluasi sistem asistif visual dengan menggabungkan metrik teknis (BLEU, ROUGE, Latensi) dan analisis kualitatif berbasis aktivitas (*activity recognition*), menggantikan pendekatan evaluasi standar yang seringkali kurang menangkap konteks keselamatan pengguna.

1.5.2 Manfaat Praktis

1. Menghasilkan modul *backend* Amadeus (*Autonomous Multi-Agent Unified Swarm Intelligence*) yang modular berbasis *microservices* berkat penerapan MCP, memungkinkan pengembang selanjutnya untuk menambah fitur (seperti navigasi GPS atau deteksi wajah) tanpa perlu merombak arsitektur inti Neutrack AI Glove karena fitur berbasis *microservices* tidak terdesentralisasi sehingga *bug* pada satu fitur tidak mempengaruhi lainnya.
2. Memberikan solusi teknologi yang beroperasi sepenuhnya secara *on-premise* (lokal), sehingga pengguna tunanetra mendapatkan jaminan keamanan data pribadi dan privasi visual karena tidak ada data gambar yang dikirim ke server pihak ketiga.
3. Menghilangkan ketergantungan pada layanan API AI berbayar (seperti OpenAI atau Google Cloud), menjadikan sistem ini lebih berkelanjutan (*sustainable*) dan hemat biaya untuk implementasi jangka panjang.

1.5.3 Manfaat Sosial

1. Meningkatkan kualitas hidup dan kemandirian penyandang tunanetra melalui asisten cerdas yang mampu memberikan deskripsi lingkungan yang detail, faktual, dan relevan (seperti membaca rambu atau menghitung objek), sehingga meningkatkan rasa aman saat beraktivitas mandiri.
2. Mendorong ketersediaan teknologi asistif dalam negeri yang terjangkau namun memiliki kecerdasan setara dengan solusi global, mengurangi kesenjangan digital bagi penyandang disabilitas di Indonesia.
3. Membuka peluang adaptasi teknologi ini untuk kelompok rentan lainnya, seperti lansia dengan demensia, melalui modifikasi *tools* agen yang fleksibel sesuai kebutuhan sosial masyarakat.

Halaman ini sengaja dikosongkan.

BAB 2

TINJAUAN PUSTAKA

2.1 Penelitian Terkait

Dalam proses penelitian ini, informasi dari berbagai penelitian sebelumnya dikumpulkan untuk digunakan sebagai pembanding dan referensi saat melakukan pengujian, yang tersaji dalam Tabel 2.1. Sumber informasi diperoleh dari jurnal, buku, dokumentasi resmi, dan skripsi yang relevan dengan judul Penelitian ini guna memperoleh dasar teoritis yang kuat.

Salah satu referensi penting adalah penelitian oleh Sayifa dan Pandian (2023) yang mengembangkan kerangka kerja *real-time image captioning* untuk penyandang tunanetra, menggunakan kombinasi model VGG16-LSTM dan ResNet-50, dengan akurasi tertinggi 83,88% pada model VGG-16. Penelitian ini menunjukkan efektivitas visi komputer tetapi belum dioptimalkan untuk perangkat edge tanpa GPU tambahan dan tidak mendukung input multimodal seperti suara.

Lalu, penelitian selanjutnya oleh Saleh, Ali, dan Ezzat (2022) merancang kacamata cerdas berbasis pengenalan wajah untuk penderita Alzheimer menggunakan algoritma Viola-Jones dan ekstraksi fitur Local Binary Pattern. Meskipun akurasi K-NN mencapai 93,36%, sistem ini masih terbatas pada pengenalan wajah tunggal tanpa adanya reasoning agent atau pemrosesan data multimodal.

Penelitian berikutnya oleh Ying et al. (2023), berjudul *FlexGen: High-Throughput Generative Inference of LLMs with a Single GPU*, menanggapi tantangan utama dalam inferensi model bahasa besar (Large Language Models/LLMs), terutama kebutuhan komputasi tinggi yang biasanya memerlukan banyak GPU kelas atas. FlexGen hadir sebagai solusi untuk menjalankan LLM berukuran besar pada perangkat dengan sumber daya terbatas, seperti GPU tunggal 16GB, melalui pendekatan offloading dan optimasi kuantisasi 4-bit. Sistem ini secara cerdas menggabungkan memori GPU, CPU, dan disk dengan menyelesaikan masalah pemrograman linear untuk mengatur alur akses tensor yang efisien. Dalam pengujianya, FlexGen mampu mencapai throughput hingga 1 token/detik untuk model OPT-175B, serta mampu menjalankan model 30B dalam benchmark HELM pada tujuh skenario dalam waktu hanya 21 jam. Dengan desain fleksibel dan performa yang kompetitif, FlexGen menjadi salah satu platform inferensi LLM paling hemat sumber daya yang relevan untuk kebutuhan edge computing dan skenario deployment di luar lingkungan server konvensional.

Selanjutnya, penelitian oleh Gao et al. (2025) memperkenalkan *MCP-RADAR*, sebuah benchmark pertama yang dirancang untuk mengevaluasi performa model LLM dalam konteks *Model Context Protocol (MCP)*. Berbeda dengan benchmark konvensional yang mengandalkan penilaian subjektif atau metrik biner sederhana, MCP-RADAR menawarkan pendekatan evaluasi objektif melalui lima dimensi kunci: akurasi jawaban, efisiensi pemilihan tool, efisiensi penggunaan sumber daya komputasi, ketepatan konstruksi parameter, dan kecepatan eksekusi. Studi ini menguji berbagai model LLM komersial dan open-source dalam berbagai domain tugas seperti rekayasa perangkat lunak, penalaran matematika, dan pemecahan masalah umum. Hasilnya menunjukkan adanya profil kemampuan yang berbeda-beda antar model, serta trade-off nyata antara akurasi, efisiensi, dan kecepatan, yang menantang cara lama dalam melakukan perankingan model. MCP-RADAR tidak hanya membantu dalam menilai kinerja model dalam interaksi dengan tool, tetapi juga memberikan panduan praktis bagi pengembang untuk meningkatkan kompatibilitas dan efektivitas tool dalam ekosistem agen

LLM. Fokus studi ini memang pada MCP sebagai protokol standar, namun pendekatan metodologinya dapat diterapkan pada kerangka integrasi tool lainnya.

Kemudian, penelitian oleh Wang dan Duan (2024) melalui karya berjudul *Agent AI with LangGraph* membahas integrasi kerangka kerja LangGraph dalam sistem agen penerjemahan mesin berbasis LLM. Penelitian ini menunjukkan bagaimana LangGraph—yang dibangun di atas LangChain—memungkinkan pengembangan alur kerja agen secara modular dan otomatis. Dengan memanfaatkan agen-agen spesifik untuk bahasa seperti *TranslateEnAgent*, *TranslateFrenchAgent*, dan *TranslateJpAgent*, sistem ini mampu melakukan penerjemahan antar bahasa dengan mempertahankan konteks dialog secara dinamis. Model sequence-to-sequence yang digunakan dilengkapi dengan attention mechanism dan dilatih pada pasangan data Inggris-Prancis. Eksperimen menunjukkan peningkatan akurasi terjemahan rata-rata sebesar 8,3% dibandingkan baseline GPT-4o solo, dengan latensi proses terjemahan kurang dari 1,2 detik per kalimat. Evaluasi dilakukan menggunakan metrik BLEU1 hingga BLEU4 terhadap 300 pasangan kalimat. Hasil menunjukkan efektivitas pendekatan LangGraph dalam menyusun agen penerjemah berbasis LLM yang modular, efisien, dan dapat diskalakan.

Penelitian berikutnya oleh Su et al. (2024) memperkenalkan *Seesaw*, engine inferensi LLM yang dirancang untuk throughput tinggi melalui pendekatan *dynamic* model *re-sharding*. Penulis menyoroti bahwa dua tahap utama dalam inferensi LLM—prefill dan decode—memiliki karakteristik komputasi yang sangat berbeda, sehingga strategi paralelisasi statis tidak cukup optimal. *Seesaw* secara adaptif mengonfigurasi ulang strategi paralelisasi antara dua tahap tersebut, memanfaatkan tiered KV cache buffering dan transition-minimizing scheduling untuk mengurangi overhead saat berpindah antar tahap. Inovasi ini memungkinkan pemrosesan batch yang lebih besar pada tahap decode, sekaligus menghindari bottleneck komunikasi pada tahap prefill. Evaluasi kuantitatif menunjukkan bahwa *Seesaw* meningkatkan throughput hingga $1.78\times$ (rata-rata $1.36\times$) dibandingkan vLLM, mesin inferensi LLM terbaik saat ini. Kontribusi lainnya termasuk analisis performa per strategi paralelisasi dan efisiensi pemindahan bobot serta cache antar GPU dan CPU. Penelitian ini menekankan pentingnya pendekatan dinamis untuk inferensi LLM offline berskala besar, terutama pada lingkungan dengan keterbatasan sumber daya. *Seesaw* membuka arah baru untuk optimasi throughput LLM dalam aplikasi industri berbasis informasi seperti ekstraksi data, query basis data, dan sistem reasoning berbasis grafik.

Penelitian yang juga relevan adalah oleh Shiddiqi et al. (2025), "*Resource-Aware Video Streaming (RAViS) Framework for Object Detection System Using Deep Learning Algorithm*" merupakan kontribusi penting dalam bidang edge computing dan computer vision, khususnya dalam konteks efisiensi penggunaan sumber daya pada perangkat terbatas seperti Raspberry Pi. Penelitian ini menawarkan solusi inovatif melalui pengembangan kerangka kerja RAViS yang mampu menjalankan sistem deteksi objek berbasis deep learning secara adaptif, dengan tetap mempertahankan akurasi deteksi tinggi meskipun menghadapi keterbatasan CPU, RAM, dan penyimpanan. Framework ini memantau dan menyesuaikan parameter operasional secara real-time untuk menjaga kinerja sistem deteksi menggunakan algoritma YOLO. Melalui serangkaian eksperimen dalam berbagai skenario, penulis membuktikan efektivitas RAViS dalam menurunkan konsumsi sumber daya secara signifikan tanpa mengorbankan kualitas deteksi. Dengan penggabungan konsep granularitas algoritmik dan pendekatan modular yang efisien, RAViS tidak hanya relevan untuk sistem pengawasan dan manajemen energi berbasis visi komputer, tetapi juga membuka peluang aplikasi luas pada perangkat IoT dan sistem pintar lainnya yang menuntut efisiensi tinggi.

Paper selanjutnya yang berjudul “*Empirical Research on Utilizing LLM-based Agents for Automated Bug Fixing via LangGraph*” memperkenalkan sebuah sistem otomatis untuk perbaikan kode berbasis Large Language Model (LLM) yang terintegrasi dalam kerangka *LangGraph*. Sistem ini menggabungkan tiga komponen utama—*LangGraph* sebagai pengatur alur tugas, *GLM-4-Flash* untuk pemahaman dan generasi kode, serta *ChromaDB* sebagai penyimpanan memori kontekstual berbasis vektor. Prosesnya terdiri dari empat tahap: *code generation*, *code execution*, *code repair*, dan *code update*, yang dijalankan secara iteratif hingga kode bebas dari bug. Dengan kemampuan reasoning semantik dan pelacakan status global, sistem ini mampu memperbaiki bug secara otomatis berdasarkan informasi historis dan pola kesalahan yang terekam. Eksperimen menunjukkan bahwa sistem ini efektif dalam menghasilkan dan memperbaiki fungsi Python, seperti kalkulasi luas segitiga dan pembagian angka dengan pengecekan pembagi nol. Framework ini memberikan pendekatan baru yang andal dalam otomatisasi rekayasa perangkat lunak dan pengurangan intervensi manual. Secara keseluruhan, penelitian ini memperluas pemanfaatan LLM dalam pengembangan perangkat lunak cerdas yang adaptif dan efisien.

Paper selanjutnya yang berjudul Paper “*MCP vs Custom Integrations: Comparing the Efficiency and Scalability of Model Context Protocol Servers in AI Development*” (SuperAGI, 2025) membahas perbandingan antara penggunaan Model Context Protocol (MCP) dan pendekatan *custom integrations* dalam pengembangan sistem AI, khususnya dalam hal efisiensi, skalabilitas, dan pengelolaan konteks model. Studi ini menunjukkan bahwa MCP, sebagai protokol standar yang dirancang untuk mengelola alur kerja multi-model dan multi-agent secara modular, mampu menyederhanakan integrasi dan mengurangi kompleksitas teknis yang sering terjadi pada pendekatan integrasi manual. Dengan fitur seperti komunikasi stateful, interoperabilitas lintas framework, dan dukungan plug-and-play untuk berbagai LLM dan tools, MCP menawarkan keunggulan dalam pengembangan cepat dan kolaboratif. Di sisi lain, custom integrations sering kali lebih fleksibel dan dapat dioptimalkan secara spesifik untuk kasus penggunaan tertentu, tetapi membutuhkan waktu pengembangan yang lebih lama dan rentan terhadap kesalahan saat skalabilitas ditingkatkan. Melalui berbagai studi kasus dan eksperimen performa, paper ini menyimpulkan bahwa MCP lebih cocok untuk sistem AI berskala besar dan kolaboratif yang menuntut modularitas dan pengelolaan konteks dinamis, sedangkan custom integrations tetap relevan untuk solusi yang sangat khusus atau ringan.

Penelitian selanjutnya yang berjudul “*Model Context Protocol-based Internet of Experts for Wireless Environment-aware LLM Agents*” oleh Zongxi Liu dan Hongyang Du (2025), menawarkan pendekatan revolusioner untuk menghadirkan kesadaran lingkungan nirkabel pada agen LLM melalui integrasi dengan Model Context Protocol (MCP). Dalam kerangka ini, LLM tidak perlu dilatih ulang atau diprogram ulang untuk memahami kondisi saluran nirkabel, melainkan secara dinamis dapat mengakses serangkaian expert models yang dirancang khusus untuk mendeteksi atribut-atribut fisik seperti kondisi line-of-sight (LoS), efek Doppler, hingga fading. Sistem ini disebut Internet of Experts (IoX), di mana masing-masing model ahli dapat di-query melalui antarmuka JSON-RPC standar yang ditetapkan MCP, dan dijalankan secara modular di edge maupun cloud server. Hasil eksperimen menunjukkan bahwa dengan pendekatan ini, akurasi klasifikasi kondisi saluran meningkat signifikan hingga 40–50% dibandingkan baseline LLM tanpa bantuan expert. Arsitektur ini juga memastikan interpretabilitas dan efisiensi waktu nyata, tanpa perlu mengubah bobot model LLM. Secara keseluruhan, penelitian ini membuka jalur baru bagi integrasi LLM ke dalam sistem komunikasi

nirkabel cerdas, serta memperluas aplikasi MCP untuk membangun agen yang adaptif terhadap kondisi lingkungan fisik yang dinamis dan kompleks.

Tabel 2. 1 Tabel Penelitian Terkait

No.	Judul	Dataset	Metode	Analisis Gap
1.	<i>A real-time image captioning framework using computer vision to help the visually impaired</i> (Sayifa & Pandian, 2023)	MS COCO, Flickr8k, dan dataset pribadi	VGG16-LSTM, ResNet-50. Performa terbaik: akurasi VGG-16 mencapai 83,88%	Belum dioptimalkan untuk edge device tanpa GPU eksternal dan belum mendukung input suara (non-multimodal).
2.	<i>Face Recognition Based Smart Glass for Alzheimer's Patients</i> (Sayifa & Pandian, 2023)	Dataset wajah pasien Alzheimer (pribadi)	<i>Viola-Jones + Local Binary Pattern</i> , klasifikasi SVM dan K-NN. Performa terbaik: akurasi K-NN sebesar 93,36%	Fokus tunggal pada pengenalan wajah; tidak menggunakan data multimodal atau reasoning agent adaptif.
3.	<i>FlexGen: High-Throughput Generative Inference of LLMs with a Single GPU</i> (Ying et al., 2023)	Priority: OPT-175B pada GPU 16 GB	<i>Throughput 1 token/s</i> pada batch 144; quantized 4-bit	GPU-server, bukan <i>edge device</i>
4.	<i>Agent AI with LangGraph: A Modular Framework for Enhancing Machine Translation Using Large Language Models</i> (Wang & Duan, 2024)	<i>Multi-agent MT</i> (Inggris→Prancis, Jepang); LLM: GPT-4o	Akurasi terjemahan meningkat rata-rata +8.3% dibanding baseline GPT-4o solo; <i>Latency pipeline</i> agent: <1.2s per sentence.	Fokus pada penerjemahan; belum diuji dalam konteks multi-modal atau penggunaan sensor.
5.	<i>MCP-RADAR: A Multi-Dimensional Benchmark for Evaluating Tool Use Capabilities in Large Language</i>	MCP-RADAR benchmark: tugas <i>software engineering</i> , <i>mathematical reasoning</i> , dan <i>problem-solving</i>	Evaluasi 6 LLM dalam 5 dimensi performa: - GPT-4: akurasi 93.7%, efisiensi pemilihan <i>tool</i> 94.3%, pemanfaatan <i>resource</i> 72.4%, akurasi parameter 90.2%,	Fokus pada evaluasi <i>tool-use</i> berbasis protokol MCP dalam konteks LLM agents; belum mencakup sistem sensor nyata, agen fisik, atau

	<i>Models</i> (Gao et al., 2025)		eksekusi sukses 95.6% - Claude 3: akurasi 91.2%, efisiensi 92.7%, <i>resource</i> 70.8%, parameter 88.4%, eksekusi 94.1% - Gemini 1.5 Pro: akurasi 90.8%, efisiensi 89.6%, <i>resource</i> 68.2%	<i>deployment edge</i> secara langsung.
6.	<i>Seesaw: High-throughput LLM Inference via Model Re-sharding</i> (Su et al., 2024)	Model distribusi LLM di multi-GPU	<i>Throughput</i> +1.78× (avg. +1.36×) vs vLLM	Tidak mencakup integrasi dengan LLM atau MCP, sehingga aplikasinya dalam sistem AI otonom belum diuji secara langsung.
7.	<i>Resource-aware video streaming (RAViS) framework for object detection system using deep learning algorithm</i> (Shiddiqi et al., 2025)	Simulasi video streaming dari kamera pengawas (dataset internal/sintetik)	-Tanpa RAViS (Scenario 2): CPU 84.3%, RAM 36.7%, Storage 57.9%, waktu deteksi rata-rata: 8210s (136 min) - Dengan RAViS (Scenario 3): CPU turun ke 47.9% (↓36%), RAM naik ke 42.4% namun lebih stabil, Storage turun ke 44.4% (↓13.5%), deteksi hanya butuh 7.07s rata-rata - Akurasi deteksi: 99.21%, dengan 43.65% deteksi penuh, 56.34% deteksi parsial	Belum mendukung multimodalitas seperti suara atau sensor tambahan. Fokus hanya pada optimasi resource, belum terintegrasi dengan sistem berbasis agen atau AI interaktif.
8.	<i>Empirical Research on Utilizing LLM-based Agents for Automated Bug Fixing via LangGraph</i> (Wang & Duan, 2025)	<i>API-based debugging tasks</i> ; LLM: GLM4 Flash + ChromaDB	Tingkat keberhasilan bug fix 78%, rata-rata iterasi debugging: 3.4 langkah, kecepatan per iterasi: <2s, tool recall: 85%.	Belum disertai metrik resource (CPU/RAM/latency) pada skala besar atau <i>deployment edge</i> .


9.	<i>MCP vs Custom Integrations: Comparing the Efficiency and Scalability of Model Context Protocol Servers in AI Development</i> (SuperAGI, 2025)	Benchmark internal (SuperAGI)	~2.500 req/s throughput (60 % lebih tinggi dari custom), latency ~50 ms (30 % lebih rendah), CPU turun 15 %, RAM turun 25%	Evaluasi berbasis server, bukan dalam sistem agent lengkap atau sensor nyata
10.	<i>Model Context Protocol-based Internet of Experts for Wireless Environment-aware LLM Agents</i> (Fei et al., 2025)	<i>Synthetic wireless channel</i> data: LoS, Doppler, Rayleigh, Rician	Akurasi prediksi atribut <i>environment</i> : tanpa MCP 45–59%, dengan MCP 95.5–98.1% across LLMs seperti ChatGPT-3.5, 4, DeepSeek	Belum mencakup pengukuran <i>latency</i> , <i>throughput</i> , atau penggunaan <i>resource</i> ; hanya fokus pada akurasi klasifikasi

2.2 Dasar Teori

Sub Bab ini menguraikan tentang landasan teori yang digunakan dalam penelitian ini. Landasan teori yang dibahas meliputi teknik pengumpulan data, teknik pemodelan topik dan perhitungan kinerja untuk mengevaluasi *agentic* AI dengan mengimplementasikan *inference engine* berbasis Gemma C++ dan *CLIP Vision Model* dalam di lingkungan *edge computing* pada Neutrack AI Glove sebagai asisten virtual penyandang tunanetra.

2.2.1 Tantangan bagi Penyandang Tunanetra dan Demensia

Gangguan penglihatan disebabkan oleh hilangnya ketajaman penglihatan, dimana mata tidak dapat melihat objek sejelas biasanya. Bisa juga disebabkan oleh hilangnya lapang pandang, dimana mata tidak dapat melihat area seluas biasanya tanpa menggerakkan mata atau memutar kepala. *World Health Organization* mendefinisikan “penglihatan rendah/*low vision*” sebagai ketajaman penglihatan antara 20/70 dan 20/400, atau bidang penglihatan 20 derajat atau kurang. “Kebutaan/Tunanetra” didefinisikan sebagai ketajaman penglihatan yang lebih buruk dari 20/400, atau bidang penglihatan 10 derajat atau kurang.




Gambar 2. 1 Model Face Perceptioning oleh *Bruce* dan *Young*

Demensia merupakan istilah umum yang digunakan untuk menggambarkan penurunan kemampuan kognitif secara signifikan yang mengganggu aktivitas hidup sehari-hari seseorang. Penyakit Alzheimer (AD) adalah jenis demensia yang paling umum, terhitung setidaknya dua pertiga kasus terjadi pada individu berusia 65 tahun ke atas. Model pengenalan wajah (*face perceptioning*) oleh Bruce dan Young (1986) memberikan kerangka kerja untuk memahami bagaimana individu memproses dan mengenali wajah. Menurut model ini, nama adalah informasi yang unik dan tidak memiliki hubungan semantik langsung dengan orang tersebut, hal ini berbeda dengan informasi semantik lainnya yang memiliki jaringan asosiasi yang lebih kuat di otak. *Alzheimer's Disease* (AD) awalnya memengaruhi Level 3, dimana pengidap gejala demensia kesulitan mengingat informasi tentang seseorang misalnya, “dia adalah tetangga saya,” kemudian memengaruhi Level 2, dimana individu mulai kesulitan mengenali wajah yang seharusnya familiar, seperti wajah keluarga atau teman, hingga level 1 dimana mengingat nama adalah tahap yang paling sulit karena memerlukan pemrosesan yang berhasil di semua tahap sebelumnya. Pada demensia, kegagalan di Level 2 dan 3 membuat *recall* nama hampir mustahil. (Werheid et al., 2007)

2.2.2 Agentic AI berbasis React Agent Model Context Protocol, dan Pydantic

Agentic AI didefinisikan sebagai sistem kecerdasan buatan yang memiliki otonomi untuk memahami lingkungan, mengambil keputusan secara mandiri, dan menjalankan tindakan tanpa memerlukan intervensi manusia secara terus-menerus. Tantangan fundamental dalam pengembangannya adalah menciptakan sistem yang mampu berinteraksi dengan alat eksternal secara efisien dan aman, sembari memastikan setiap keputusan didasarkan pada fakta yang akurat dan relevan (McGuinness, 2024).




Gambar 2. 2 Perbandingan Traktori Penalaran antara metode CoT, Act-only, dan ReAct (Yao dkk., 2023)

Untuk menjawab tantangan tersebut, sistem ini mengadopsi paradigma ReAct (Reasoning and Acting) yang mensinergikan kemampuan penalaran dan pengambilan tindakan dalam model bahasa secara berdampingan. ReAct memicu *Large Language Models* (LLMs) untuk menghasilkan jejak penalaran verbal (*reasoning traces*) dan tindakan spesifik secara bergantian atau *interleaved*. Dalam siklus ini, jejak penalaran berperan untuk menginduksi, melacak, dan memperbarui rencana tindakan model, sedangkan langkah tindakan memungkinkan model untuk berinteraksi dengan sumber eksternal guna memperoleh informasi tambahan. Melalui sinergi antara penalaran, tindakan, dan observasi, ReAct secara signifikan meningkatkan keterlandasan (*groundedness*) sistem dan membantu mengatasi masalah halusinasi fakta serta perambatan kesalahan (*error propagation*). (Yao dkk., 2023).

Pembahasan mengenai efektivitas pola ini dijelaskan lebih lanjut dalam Gambar 2.3, yang membandingkan traktori penalaran antara metode CoT, *Act-only*, dan ReAct. Metode Chain-of-Thought (CoT) merupakan sistem penalaran tertutup (*static black box*) yang hanya mengandalkan representasi internal model tanpa landasan dunia eksternal, sehingga sering terjebak dalam masalah halusinasi fakta dan perambatan kesalahan (*error propagation*). Sebaliknya, metode *Act-only* berfokus pada eksekusi tindakan tanpa penalaran verbal, yang mengakibatkan model kesulitan dalam memecah tujuan tugas yang kompleks atau kehilangan jejak status lingkungan. Melalui sinergi antara penalaran, tindakan, dan observasi, ReAct secara signifikan meningkatkan keterlandasan (*groundedness*) sistem karena setiap keputusan didasarkan pada data nyata dari lingkungan eksternal. Pendekatan ini tidak hanya menghasilkan lintasan penyelesaian tugas yang lebih akurat, tetapi juga memberikan transparansi yang lebih baik bagi pengguna karena proses pengambilan keputusan model dapat diaudit melalui jejak penalaran yang dihasilkan. (Yao dkk., 2023)


Pengelolaan alur kerja interaktif antara penalaran ReAct dan pemanggilan alat eksternal dilakukan melalui LangGraph. Framework ini memfasilitasi pembangunan agen berbasis graf menggunakan konstruksi StateGraph yang mendukung proses iteratif atau siklus (*cycles*), yang sangat krusial bagi pola ReAct di mana agen harus melewati fase pemikiran, tindakan, dan observasi secara berulang hingga mencapai solusi final (LangChain, 2024). Selain itu, fitur persistensi pada LangGraph menjamin bahwa status penalaran dan riwayat observasi dapat diingat antar sesi percakapan, memberikan konteks yang berkelanjutan bagi pengguna (LangChain, 2024).



Gambar 2. 3 React Agent LangGraph (LangChain, 2024)

Gambar 2.4 mengilustrasikan implementasi praktis paradigma ReAct melalui siklus iteratif agen otonom yang diwujudkan dalam struktur graf berbasis simpul (*nodes*) dan alur (*edges*) sesuai kerangka kerja Yao dkk. (2023). Alur kerja ini dimulai pada agent node, di mana model melakukan tahap *Reasoning* untuk menghasilkan penalaran verbal serta menentukan strategi pemecahan masalah berdasarkan instruksi yang dikonfigurasi melalui *system prompt*. Jika data eksternal diperlukan, agen akan memicu tahap *Acting* dengan mengirimkan instruksi melalui *edge* menuju tools node untuk mengeksekusi fungsi spesifik seperti pencarian produk atau pemeriksaan inventaris. Hasil eksekusi tersebut kemudian dikirimkan kembali ke dalam state sistem sebagai *Observation*, menciptakan sinergi berkelanjutan di mana agen dapat memperbarui pemahaman faktualnya secara dinamis. Proses ini berulang melalui *conditional edges* yang menghubungkan kembali observasi ke simpul penalaran, dan hanya akan berakhir ketika agen menyimpulkan bahwa seluruh informasi telah tercukupi untuk memberikan jawaban akhir yang akurat kepada pengguna. Guna menjamin reliabilitas arsitektur sistem,

Integrasi dengan *Model Context Protocol* (MCP) merupakan faktor kunci yang memungkinkan agen dalam kerangka kerja ReAct untuk menjalankan tindakan nyata secara efektif. Dalam ekosistem ini, jika ReAct bertindak sebagai pusat kendali atau "otak" pengambilan keputusan, maka MCP berperan sebagai "sistem saraf" yang menghubungkan agen dengan berbagai perangkat eksternal melalui standar universal. Adopsi Model Context Protocol (MCP) telah meluas secara pesat di berbagai sektor industri dan sistem *enterprise* melalui integrasi platform pengembangan serta ketersediaan server bawaan, namun keberhasilan masa depannya sebagai jembatan antara bahasa alami dan komputasi formal masih bergantung pada dukungan industri serta penyelesaian tantangan keamanan, skalabilitas, dan kompatibilitas lintas platform.



Gambar 2. 4 Arsitektur Client dan Server *Model Context Protocol* (Hou dkk., 2025)

Sebagaimana diilustrasikan dalam Gambar 2.2, MCP memperkenalkan arsitektur komunikasi dua arah yang terpadu untuk mendefinisikan penemuan dinamis antara model AI dan alat atau sumber daya eksternal. Arsitektur ini secara inovatif memisahkan implementasi alat dari penggunaannya, yang terdiri dari tiga komponen inti: *MCP host* (lingkungan eksekusi seperti IDE), *MCP client* (intermediari di dalam *host*), dan *MCP server* (penyedia alat dan data). Melalui skema ini, aplikasi AI dapat menemukan, menegosiasikan skema, dan memanggil fungsi eksternal secara dinamis tanpa memerlukan integrasi manual atau *hardcoding* untuk setiap layanan spesifik.


Integrasi Pydantic dalam arsitektur ini bertindak sebagai jembatan kritis yang mentransformasi instruksi bahasa alami yang tidak terstruktur dari LLM menjadi format data terstruktur yang dapat dieksekusi oleh mesin. Dalam konteks simpul *tools* pada Gambar 2.4, Pydantic memungkinkan pendefinisian parameter fungsi secara eksplisit menggunakan kelas *BaseModel* dan dekorator *Field*, yang mencakup tipe data, batasan nilai, hingga deskripsi fungsional yang akan dibaca oleh agen sebagai panduan operasional.

Validasi *runtime* yang dilakukan oleh Pydantic memastikan bahwa setiap data yang melewati *edges* (terutama saat transisi dari *Acting* ke *Observation*) agar selalu memenuhi kontrak skema yang telah ditetapkan, sehingga meminimalisir risiko kesalahan interpretasi parameter oleh model saat melakukan pemanggilan alat eksternal. Selain itu, kemampuan Pydantic dalam melakukan otomatisasi pembuatan skema JSON standar sangat krusial dalam memfasilitasi interoperabilitas yang lancar antara modul *reasoning* dan berbagai layanan *backend* dalam ekosistem mikroservis, yang pada akhirnya memperkuat integritas data dan stabilitas sistem secara keseluruhan selama siklus iteratif ReAct berlangsung.

Sinergi antara ReAct sebagai logika penalaran yang terlandas pada fakta, MCP sebagai protokol komunikasi alat, LangGraph sebagai orkestrator siklus yang persisten, dan Pydantic sebagai penjaga integritas data, menghasilkan sistem pendukung yang tangguh dan terukur. Kombinasi ini memungkinkan LLM bertindak sebagai komponen aktif yang mampu memanipulasi lingkungan perangkat lunak secara cerdas untuk memberikan bantuan yang efektif bagi pengguna (Yao dkk., 2023).

2.2.3 Image Captioning berbasis CLIP ViT Vision Model dan Gemma LLM

Pengembangan sistem *image captioning* dalam penelitian ini mengintegrasikan dua arsitektur *state-of-the-art*, yaitu CLIP sebagai *vision encoder* dan Gemma sebagai *language decoder*. Sinergi ini bertujuan untuk menghasilkan deskripsi gambar yang tidak hanya akurat secara visual, tetapi juga memiliki struktur kalimat yang alami dalam Bahasa Indonesia.



Gambar 2. 5 Arsitektur CLIP *Vision Model* (Radford dkk., 2021)

CLIP (*Contrastive Language–Image Pretraining*) merupakan model *vision-language* yang terdiri atas dua komponen utama, yaitu *image encoder* dan *text encoder*. Kedua komponen ini dilatih secara bersamaan untuk menghasilkan representasi vektor (*embedding*) dari gambar dan teks dalam ruang *embedding* yang sama. Hal ini memungkinkan CLIP untuk menilai kesesuaian antara teks dan gambar tanpa memerlukan pelabelan eksplisit selama inferensi,

dikenal sebagai *zero-shot learning* (Radford et al., 2021). Komponen *text encoder* pada CLIP menggunakan arsitektur Transformer (Vaswani et al., 2017) dengan konfigurasi 12 lapisan, lebar 512, dan 8 *attention heads*. Teks mentah diproses melalui mekanisme encoding pasangan byte (*byte pair encoding/BPE*) dengan ukuran kosa kata (*vocabulary size*) sebesar 49.152 (Sennrich et al., 2016). Panjang maksimum urutan teks dibatasi hingga 76 token, dan setiap token diberikan *positional encoding* sebelum dimasukkan ke dalam *encoder* teks untuk mendapatkan representasi semantiknya.

CLIP menyediakan beberapa pilihan arsitektur untuk *image encoder*, termasuk jaringan ResNet (He et al., 2016) dan *Vision Transformer* (ViT) (Dosovitskiy et al., 2020). Mengingat performa superior yang ditunjukkan oleh ViT dalam berbagai penelitian terkini (Zhai et al., 2021), maka pembahasan dalam tulisan ini difokuskan pada penggunaan *image encoder* berbasis Transformer. Dalam arsitektur ViT, gambar dipecah menjadi sejumlah *patch*, yang kemudian dikonversi menjadi token-token vektor. Setiap token diberi tambahan *positional encoding* untuk menjaga informasi lokasi spasial. Selanjutnya, hasil ekstraksi fitur dari seluruh *patch* melalui proses *global pooling*, sehingga menghasilkan satu vektor representatif tunggal untuk seluruh gambar. Kemiripan antara vektor gambar (I) dan vektor teks (T) dihitung menggunakan *cosine similarity* yang menjadi dasar dalam proses pembelajaran multimodal. Secara matematis, fungsi kerugian yang digunakan selama pra-pelatihan CLIP adalah *symmetric contrastive loss* yang bertujuan untuk memaksimalkan kecocokan pada pasangan positif di dalam satu *batch* berisi (N) pasangan, yang dirumuskan sebagai berikut:

$$L_{CLIP} = \frac{1}{2N} \sum_{i=1}^N -\log \frac{\exp\left(\frac{\text{sim}(I_i, T_i)}{\tau}\right)}{\sum_{j=1}^N \exp\left(\frac{\text{sim}(I_i, T_j)}{\tau}\right)} - \log \frac{\exp\left(\frac{\text{sim}(I_i, T_i)}{\tau}\right)}{\sum_{j=1}^N \exp\left(\frac{\text{sim}(I_j, T_i)}{\tau}\right)} \quad (2.1)$$

Di mana:

- L_{CLIP} : Nilai total kerugian (*loss*) simetris antara gambar dan teks.
- N : Jumlah pasangan gambar dan teks dalam satu batch pelatihan.
- $\text{sim}(I, T)$: : Fungsi *cosine similarity* yang mengukur kedekatan antara vektor gambar dan teks.
- I_i, T_i : Vektor *embedding* gambar dan teks untuk pasangan ke- i .
- τ : Parameter suhu (*temperature*) untuk mengatur distribusi probabilitas kemiripan.

Agar fitur visual dari CLIP dapat dipahami oleh Gemma, diperlukan sebuah *Projection Layer* yang berfungsi menyelaraskan dimensi *embedding* visual CLIP ke dalam ruang *embedding* tekstual Gemma. Berbeda dengan proyeksi linear tunggal, sistem ini menggunakan arsitektur *Multilayer Perceptron* (MLP) yang terdiri dari dua lapisan transformasi linear dan fungsi aktivasi non-linear *Gaussian Error Linear Unit* (GELU).

Penggunaan MLP bertujuan untuk mempelajari pemetaan yang lebih kompleks dan non-linear antara representasi gambar dan bahasa, sementara GELU dipilih karena kemampuannya dalam menjaga aliran gradien yang lebih baik dibandingkan ReLU, sebagaimana digunakan dalam arsitektur Transformer modern seperti Gemma. Transformasi ini menghasilkan *aligned visual tokens* $V_{aligned}$ melalui tahapan berikut:

$$V_{aligned} = W_2 \cdot \text{GELU}(W_1 \cdot V_{raw} + b_1) + b_2 \quad (2.2)$$

Di mana:

- $V_{aligned}$: Informasi konteks visual yang telah diselaraskan ke dimensi embedding Gemma $d_{word} = 2304$ atau sesuai konfigurasi model).
- V_{raw} : Vektor fitur asli hasil ekstraksi image encoder CLIP ViT ($d_{vis}=768$ untuk ViT-B/32).
- W_1, W_2 : Matriks bobot (weight matrices) pada lapisan MLP pertama dan kedua yang dipelajari selama pelatihan.
- b_1, b_2 : Parameter bias pada masing-masing lapisan proyeksi.
- GELU: Fungsi aktivasi non-linear yang memberikan bobot pada input berdasarkan probabilitas distribusi normal

Setelah fitur visual diselaraskan, Gemma menerima informasi tersebut sebagai *prefix* untuk menghasilkan deskripsi teks secara *auto regressive*. Proses pelatihan akhir atau *fine-tuning* pada model gabungan ini menggunakan fungsi kerugian *Cross-Entropy* untuk memprediksi token target (y) berdasarkan konteks visual $V_{aligned}$ dan token sebelumnya $y_{<t}$. Untuk menjaga efisiensi komputasi pada GPU dengan VRAM terbatas, proses ini mengimplementasikan metode QLoRA (Dettmers et al., 2023). Fungsi kerugian generative L_{gen} yang diminimalkan dalam *training script* didefinisikan sebagai berikut:

$$L_{gen} = \sum_{t=1}^T \log P(y_t | y_{<t}, V_{aligned}) \quad (2.3)$$

Di mana:

- L_{gen} : nilai total kerugian generatif yang diminimalkan selama proses pelatihan agar prediksi model semakin akurat.
- $\sum_{t=1}^T$: operasi penjumlahan probabilitas yang dilakukan untuk setiap langkah waktu (time step) atau setiap token dalam satu urutan teks sepanjang T .
- $\log$: fungsi logaritma natural yang digunakan untuk menghitung nilai negative log-likelihood dari probabilitas.
- $P(y_t | \dots)$: probabilitas model dalam memprediksi token target yang benar (y_t) pada urutan ke- t .
- $y_{<t}$: kumpulan seluruh token yang sudah muncul sebelumnya dalam kalimat (context history).
- $V_{aligned}$: informasi konteks visual yang telah diselaraskan, berfungsi sebagai panduan semantik bagi Gemma mengenai isi gambar yang sedang dideskripsikan.

Dengan menggabungkan pemahaman visual mendalam dari CLIP ViT dan kemampuan generatif bahasa yang canggih dari Gemma, sistem ini mampu menghasilkan deskripsi gambar yang akurat secara semantik serta memiliki struktur kalimat yang alami. Pendekatan ini memastikan bahwa hubungan antara fitur visual dan representasi bahasa terjaga dengan baik melalui optimasi yang dilakukan secara *end-to-end*.

2.2.4 Optimasi Efisiensi melalui *Inference Engine*

Dalam pengembangan sistem AI berbasis multimodal di lingkungan *edge*, efisiensi model menjadi faktor krusial karena keterbatasan sumber daya komputasi. Sistem ini mengimplementasikan *Multimodal Inference Engine* yang mengintegrasikan model bahasa

Gemma-2-2b sebagai dekoder dan CLIP Vision Model (Vision Transformer) sebagai ekstraktor fitur visual. Gemma-2 merupakan iterasi terbaru dari *Large Language Model* (LLM) ringan Google yang dirancang untuk menjaga keseimbangan performa dan efisiensi pada perangkat dengan memori terbatas (Google Team, 2024).

Berdasarkan implementasi pada sistem Amadeus, efisiensi inferensi dicapai melalui penggunaan tipe data bfloat16 (Brain Floating Point 16). Berbeda dengan FP16 standar, bfloat16 memiliki rentang dinamis yang sama dengan FP32 namun dengan kebutuhan memori 50% lebih kecil, sehingga memungkinkan model berjalan pada perangkat *on-premises* tanpa kehilangan akurasi penalaran yang signifikan. Secara teknis, penyelarasan antara domain visual (CLIP) dan domain teks (Gemma) dilakukan melalui sebuah Projection Adapter (MyAdaptor). Komponen ini terdiri dari lapisan linear yang memetakan *embedding* visual berdimensi 768 (dari CLIP) ke dimensi *hidden state* Gemma sebesar 2048.

Proses transformasi fitur ini dapat direpresentasikan secara matematis melalui operasi linear:

$$Z_{aligned} = \sigma(W \cdot F_{visual} + b) \quad (2.4)$$

Di mana:

- F_{visual} : fitur dari CLIP
- W : matriks bobot adaptor
- b : bias
- σ : fungsi aktivasi GELU

Selain optimasi arsitektur, teknik kuantisasi linear tetap menjadi landasan teori untuk reduksi model lebih lanjut pada perangkat *edge*. Kuantisasi mengubah representasi bobot dari presisi tinggi ke presisi rendah untuk mempercepat inferensi dan mengurangi jejak memori. Proses kuantisasi linear dapat dijelaskan dengan rumus:

Secara matematis, proses kuantisasi linear dapat dijelaskan dengan rumus berikut:

$$q = \text{round} \left(\frac{x - \min}{\Delta} \right) \quad (2.5)$$

Dan untuk mendekode nilai asli kembali:

$$x \approx \Delta \cdot q + \min \quad (2.6)$$

- x : nilai bobot asli (*floating-point*)
- q : nilai hasil kuantisasi (*integer*)
- Δ : skala kuantisasi (*quantization scale*), dihitung dengan:

$$\Delta = \left(\frac{\max - \min}{2^b - 1} \right) \quad (2.7)$$

- b : jumlah bit (contoh: 8 untuk INT8, 4 untuk INT4, 2 untuk INT2)
- $\min$ dan $\max$: rentang nilai *floating point* dari parameter model

Implementasi engine ini memastikan bahwa Neutrack AI Glove dapat memberikan deskripsi visual secara *real-time* dengan memanfaatkan akselerasi perangkat keras lokal (CPU/GPU) tanpa bergantung pada latensi infrastruktur *cloud*.

2.2.5 Metrik Evaluasi

a. Evaluasi Kinerja MCP AI Agent

Untuk mengevaluasi efisiensi sistem *AI Agent* berbasis *Model Context Protocol* (MCP), dilakukan pengukuran waktu eksekusi pada beberapa tahap penting dalam alur kerja, yaitu:

1. Waktu Inisiasi Model LLM

Tahap ini mengukur waktu yang diperlukan untuk memuat model bahasa (*Large Language Model / LLM*) ke dalam memori sebelum siap digunakan.

```
Input: api_request_timestamp, agent_configuration_json, memory_loader_status
Output: model_init_latency_seconds
1.  PARSE agent_configuration
2.  LOAD or CREATE agent_memory(agent_id)
3.  SET agent_creation_start = CURRENT_TIME()
4.  CALCULATE model_init_time = agent_creation_start - start_time
5.  CONSTRUCT metrics_payload = {
6.      "model_init_time": model_init_time}
7.  YIELD SERVER_SENT_EVENT("metrics", metrics_payload)
8.  FINALLY:
9.      CLOSE mcp_client_connection
10. END FUNCTION
```

Pseudocode 2. 1 Waktu Inisiasi Model LLM

2. Waktu Inisiasi AI Agent

Tahap ini mengukur waktu yang dibutuhkan untuk membuat agent berbasis ReAct dengan menghubungkannya ke tools yang tersedia melalui MCP server

```
Input: model_definition, mcp_tool_connections, langchain_graph_builder,
agent_factory_process
Output: model_definition, mcp_tool_connections, langchain_graph_builder
, agent_factory_process
1.  IF agent_has_tools THEN
2.      INITIALIZE mcp_client WITH tool_configs
3.      CONNECT to mcp_servers
4.      RETRIEVE tool_definitions
5.      CREATE agent_instance WITH (model, tools, memory)
6.  ELSE
7.      CREATE agent_instance WITH (model, memory)
8.  END IF
9.  SET agent_creation_end = CURRENT_TIME()
10. CALCULATE agent_init_time = agent_creation_end - agent_creation_start
11. CONSTRUCT metrics_payload = {
12.     "model_init_time": model_init_time}
13. YIELD SERVER_SENT_EVENT("metrics", metrics_payload)
14. FINALLY:
15.     CLOSE mcp_client_connection
16. END FUNCTION
17.     CALCULATE agent_init_time = agent_creation_end - agent_creation_start
```

Pseudocode 2. 2 Waktu Inisiasi AI Agent

3. Recursions

Parameter ini mengukur jumlah iterasi atau langkah berpikir (*reasoning steps*) yang dilakukan oleh *agent* untuk menyelesaikan satu *query*. Pengukuran dilakukan menggunakan *custom callback handler* yang menghitung frekuensi pemanggilan LLM (*on_llm_start*) dalam satu siklus eksekusi. Batas maksimum rekursi (*recursion limit*) diatur sebesar 50 untuk mencegah *looping* tak terbatas. **Input:** *agent_reasoning_loop*, *llm_start_callbacks*, *max_iteration_limit*
Output: *model_init_latency_seconds*, *total_recursion_step_count*

1. **FUNCTION** CountRecursions(*agent_execution_loop*)
2. **SET** *recursion_count* = 0
3. **DEFINE** *callback on_llm_start()*:
4. **INCREMENT** *recursion_count* BY 1
5. **SET** *execution_config* = {
6. "callbacks": [*on_llm_start*]
7. }
8. **RUN** *agent_execution_loop* WITH *execution_config*:
9. Pass
10. **RETURN** *recursion_count*
11. **END FUNCTION**

Pseudocode 2. 3 Recursions Agent

4. Waktu Respons AI Agent

Mengukur durasi dari saat *agent* menerima *query* hingga memberikan respons akhir kepada pengguna.

Input: *agent_instance*, *user_query*
Output: *response_duration_seconds*

1. **FUNCTION** CalculateResponseTime(*agent_instance*, *user_query*)
2. **SET** *start_time* = CURRENT_TIMESTAMP()
3. **WHILE** *agent_stream* IS active:
4. **WAIT** for next interaction/token
5. **END WHILE**
6. **SET** *end_time* = CURRENT_TIMESTAMP()
7. **SET** *response_duration_seconds* = *end_time* - *start_time*
8. **RETURN** *response_duration_seconds*
9. **END FUNCTION**

Pseudocode 2. 4 Waktu Respons AI Agent

b. Evaluasi Kinerja Image Captioning

Bilingual Evaluation Understudy (BLEU) merupakan metrik evaluasi yang digunakan untuk mengukur tingkat kemiripan antara hasil translasi mesin dengan teks referensi manusia. Evaluasi dilakukan dengan menghitung skor pada setiap segmen terjemahan, umumnya pada level kalimat, yang kemudian dirata-ratakan untuk merepresentasikan kualitas korpus secara keseluruhan. Skor BLEU memiliki rentang nilai antara 0 hingga 1 (Wolk & Marasek, 2015).

Metrik BLEU menerapkan konstanta *brevity penalty* untuk memitigasi perolehan skor tinggi pada kalimat pendek yang tidak representatif. Skor akhir ditentukan melalui perkalian antara *brevity penalty* dengan rata-rata geometri dari *modified precision score*. Oleh karena itu, untuk mencapai skor yang optimal, teks hasil translasi harus memiliki panjang yang mendekati teks referensi serta kesesuaian leksikal dan urutan kata yang presisi.

Proses pencocokan pada BLEU dilakukan secara independen terhadap aspek kejelasan atau ketepatan tata bahasa. Semakin tinggi nilai yang dihasilkan, semakin besar tingkat

kesamaannya dengan referensi manusia. Perhitungan nilai BLEU didefinisikan melalui Persamaan 2.3 hingga 2.5:

$$\text{Unigram Precision } P = \frac{m}{w_t} \quad (2.8)$$

$$\text{Brevity penalty } p = \begin{cases} 1 & \text{jika } c > r \\ e^{(1-\frac{r}{c})} & \text{jika } c \leq r \end{cases} \quad (2.9)$$

$$\text{BLEU} = p \cdot e^{\sum_{n=1}^N (\frac{1}{N} \log P_n)} \quad (2.10)$$

Di mana:

- m : jumlah kata dalam prediksi yang juga terdapat pada referensi (*matched words*)
- W_t : merupakan total jumlah kata dalam prediksi
- c : merupakan total panjang kata dalam prediksi
- r : panjang kata dalam referensi
- N : panjang maksimum n -gram
- P_n : presisi dari n -gram

Secara praktis, nilai BLEU umumnya dikelompokkan ke dalam empat kategori utama, yakni BLEU-1, BLEU-2, BLEU-3, dan BLEU-4, yang masing-masing memiliki mekanisme pembobotan berbeda. BLEU-1 dihitung berdasarkan tingkat kecocokan *1-gram* antara kalimat prediksi dan referensi, sedangkan BLEU-2 merupakan nilai kumulatif dari *1-gram* dan *2-gram* dengan pembobotan setara sebesar 0,5 untuk setiap n -gram. Selanjutnya, BLEU-3 melibatkan perhitungan kumulatif dari *1-gram* hingga *3-gram* dengan bobot masing-masing sebesar $1/3$ ($\approx 0,33$), dan BLEU-4, yang merupakan standar evaluasi paling umum, mencakup perhitungan kumulatif dari *1-gram* hingga *4-gram* dengan bobot masing-masing sebesar 0,25.

Konsep *gram* atau jumlah kata ini dapat diilustrasikan melalui kalimat prediksi "*the cat is here*" yang menghasilkan *1-gram* berupa "*the*", "*cat*", "*is*", dan "*here*", serta *2-gram* yang mencakup "*the cat*", "*cat is*", dan "*is here*". Apabila dibandingkan dengan kalimat referensi "*the cat is on the mat*" yang memiliki fragmen *2-gram* seperti "*the cat*", "*cat is*", "*is on*", "*on the*", dan "*the mat*", maka evaluasi dilakukan dengan mencocokkan setiap fragmen tersebut secara sistematis. Dalam perhitungan BLEU-2 untuk contoh ini, fragmen "*the cat*" dan "*cat is*" memiliki nilai kecocokan 1, sedangkan "*is here*" bernilai 0 karena tidak ditemukan pada referensi. Akumulasi dari hasil pencocokan tersebut menghasilkan nilai $(1+1+0)/3 = 2/3$, sehingga diperoleh skor akhir BLEU-2 sebesar $2/3$.

ROUGE-L (*Recall-Oriented Understudy for Gisting Evaluation - Longest Common Subsequence*) merupakan metrik evaluasi yang digunakan untuk mengukur kualitas teks hasil luaran model pemrosesan bahasa alami melalui perbandingan dengan teks referensi (Lin, 2004). Metrik ini mengacu pada konsep *Longest Common Subsequence* (LCS), yaitu urutan kata terpanjang yang muncul dengan pola urutan yang sama antara teks prediksi dan teks referensi, meskipun kata-kata tersebut tidak terletak secara berdekatan. Dalam proses pengukurannya, ROUGE-L mengintegrasikan dua komponen utama, yakni *recall* dan *precision*. *Recall* dihitung sebagai proporsi nilai LCS terhadap total panjang teks referensi, sementara *precision* ditentukan berdasarkan proporsi nilai LCS terhadap total panjang teks prediksi. Selain itu, nilai *F1-Score* diimplementasikan untuk merepresentasikan keseimbangan antara aspek *recall* dan *precision* tersebut.

$$Recall = \frac{LCS(X,Y)}{|Y|} \quad (2.11)$$

$$Precision = \frac{LCS(X,Y)}{|X|} \quad (2.12)$$

$$F1 = \frac{(1+\beta^2) \cdot Precision \cdot Recall}{\beta^2 \cdot Precision + Recall} \quad (2.13)$$

Di mana:

- $LCS(X,Y)$: panjang subsekuens terpanjang antara teks prediksi X dan teks referensi Y .
- $|X|$: jumlah total kata dalam teks prediksi
- $|Y|$: adalah jumlah total kata dalam teks referensi

ROUGE-L efektif dalam evaluasi tugas peringkasan teks (*text summarization*) karena metrik ini mampu menjaga struktur urutan kata yang menjadi aspek fundamental dalam penilaian ringkasan. Kemampuan dalam menangkap LCS memberikan fleksibilitas yang lebih besar dibandingkan dengan pendekatan *n-gram* murni, mengingat LCS tidak mengharuskan kata-kata berada dalam posisi yang berdampingan selama urutannya tetap konsisten. Sebagai ilustrasi, apabila terdapat teks referensi "*the cat is on the yellow mat*" dan teks prediksi "*the cat is yellow*", maka subsekuens terpanjang yang diidentifikasi adalah "*the cat is yellow*" dengan panjang 4. Berdasarkan nilai tersebut, kalkulasi *recall*, *precision*, dan *F1-Score* dilakukan untuk menentukan derajat kemiripan teks prediksi terhadap teks referensi secara komprehensif.


Halaman ini sengaja dikosongkan.

BAB 3

METODOLOGI

3.1 Perancangan Sistem

Sub-bab ini menjelaskan tahapan perancangan model dan agen AI serta penggunaan dataset. Dataset yang digunakan berupa gambar orisinal yang dikumpulkan dari berbagai titik trotoar di Surabaya dan beberapa lokasi di lingkungan kampus Institut Teknologi Sepuluh Nopember, di mana setiap gambar memiliki lima deskripsi manual secara semantik sebelum digabungkan menjadi pasangan data visual dan tekstual. Dataset tersebut kemudian dibagi menjadi data latih, validasi, dan uji, lalu diproses melalui tahap normalisasi citra menggunakan *CLIP Image Processor* serta tokenisasi teks melalui *Gemma Tokenizer* untuk memastikan kompatibilitas antar modalitas. Arsitektur multimodal yang dibangun mengintegrasikan *CLIP Vision Transformer* sebagai *encoder* visual dan *Gemma-2-2b* sebagai *decoder* bahasa yang dihubungkan oleh *Projection Layer (Adapter MLP)* untuk menyelaraskan fitur visual ke dalam ruang *embedding* LLM. Strategi pelatihan menerapkan metode *Parameter-Efficient Fine-Tuning* (PEFT) dengan membekukan bobot model dasar dan mengoptimalkan lapisan *adapter* menggunakan Optuna untuk menemukan *learning rate* terbaik sebesar 0.0006. Selain itu, sistem mengadopsi *Model Context Protocol* (MCP) untuk modularitas alat dan *framework* LangGraph untuk orkestrasi agen cerdas yang mendukung siklus penalaran *Reasoning and Acting* (ReAct). Seluruh komponen diintegrasikan dalam arsitektur *microservices* berbasis FastAPI dan dijalankan secara lokal menggunakan teknik kuantisasi 4-bit demi menjaga efisiensi pada perangkat *edge*, dengan evaluasi kinerja akhir yang diukur menggunakan metrik BLEU-Score untuk menilai kualitas deskripsi gambar yang dihasilkan.



Gambar 3. 1 Diagram alir perancangan sistem

3.1.1 Persiapan Dataset

Dataset yang digunakan dalam penelitian ini merupakan dataset orisinal yang dikumpulkan secara mandiri dari berbagai titik trotoar di Surabaya serta beberapa lokasi di lingkungan kampus Institut Teknologi Sepuluh Nopember. Proses pengumpulan data dilakukan melalui dua metode utama: pengambilan data video yang kemudian diekstraksi menjadi *frame* dengan tingkat *blur* rendah menggunakan metode Laplacian, serta pengambilan gambar secara langsung terhadap objek di lokasi. Setelah tahap pengumpulan, dilakukan proses seleksi manual secara ketat untuk memastikan tidak terdapat duplikasi data atau gambar yang memiliki tingkat kemiripan visual yang terlalu tinggi satu sama lain. Hasil akhir dari proses kurasi ini menghasilkan total 3.001 gambar yang merepresentasikan kondisi visual area trotoar dan lingkungan kampus. Secara spesifik, komposisi dataset terdiri atas 1.447 gambar area trotoar yang bersumber dari penelitian sebelumnya oleh Navastara dkk. (2023), serta 1.554 gambar lingkungan kampus yang diambil secara langsung oleh Tim Kerja Praktik *Image Captioning* di Departemen Teknik Informatika, Institut Teknologi Sepuluh Nopember. Setiap gambar dalam dataset ini kemudian dipasangkan dengan lima variasi deskripsi manual yang disusun berdasarkan semantik visual yang tampak, sehingga menghasilkan total korpus teks sebanyak 15.005 kalimat deskripsi. Untuk keperluan eksperimen, dataset didistribusikan ke dalam tiga partisi dengan proporsi 70% data latih, 21% data validasi, dan 9% data uji. Berdasarkan pembagian tersebut, data latih terdiri dari 2.100 gambar (10.500 teks), data validasi terdiri dari 630 gambar (3.150 teks), dan data uji terdiri dari 271 gambar (1.355 teks). Alokasi proporsi validasi sebesar 21% ditetapkan secara sengaja untuk memberikan ruang validasi yang lebih luas, sehingga proses pemilihan model terbaik (*model selection*) dapat dilakukan dengan lebih andal, terutama dalam memantau konvergensi *loss* dan menerapkan strategi *early stopping*. Sementara itu, proporsi data uji sebesar 9% dinilai memadai untuk mengevaluasi performa generalisasi model secara representatif, mengingat adanya dukungan lima referensi deskripsi per citra yang memperkaya konteks evaluasi. Rincian rangkuman dataset citra beserta teks deskripsi tersaji pada Tabel 3.1 .

Tabel 3. 1 Contoh Dataset Original

No	Gambar	Teks deskripsi
1.		1. Seorang pengendara motor berhenti di dekat tulisan ""ENTER"", dikelilingi taman hijau yang rimbun dan segar. 2. Seorang pengendara motor di dekat tulisan ""ENTER"", dikelilingi oleh taman hijau 3. Di taman hijau yang rimbun, seorang pengendara motor berhenti di dekat tulisan ""ENTER"" yang mencolok. 4. Seseorang mengendarai sepeda motor saat senja di jalan yang memiliki pohon dan tanaman hias 5. Di depan terdapat seorang pengendara motor yang melintas di jalan paving sementara jauh di depan kanan terdapat tulisan ""Enter""


No	Gambar	Teks deskripsi
2.		1. Gedung Teknik Informatika dengan desain modern, mahasiswa berjalan, suasana cerah dan asri. 2. Gedung Teknik Informatika yang modern ini menjadi pusat aktivitas mahasiswa di lingkungan yang cerah. 3. Suasana asri di sekitar gedung menciptakan tempat belajar yang menyenangkan. Terlihat beberapa mobil melintasi jalan raya di sebelah kiri. 4. Dua orang perempuan berjalan menuju gedung Departemen Teknik Informatika 5. Di depan terlihat gedung besar dengan tulisan "TEKNIK INFORMATIKA" sementara beberapa orang berada di sekitarnya
3.		1. Sekelompok pria berkumpul membaca Al-Qur'an, dikelilingi suasana tenang dengan pemandangan luar yang hijau. 2. Sekelompok pria berkumpul membaca Al-Qur'an, menciptakan suasana tenang dan penuh kedamaian. 3. Kehadiran pemandangan hijau di sekitar menambah ketenangan saat mereka bermunajat. 4. Beberapa pria berkumpul sambil membaca kitab suci yang diletakkan di atas meja 5. Beberapa orang sedang membaca al-quran di atas meja kecil dengan duduk melingkar
		1. Selamat datang di Food Corner, tempat sempurna untuk menikmati hidangan lezat sambil bekerja atau bersantai! 2. Seseorang duduk di meja dengan laptop, sementara di belakangnya terdapat area Food Corner 3. Area food corner yang menjual geprek gepruk dan seorang pria duduk sendirian dengan laptopnya. Ujung trotoar sekitar persimpangan jalan menuju pintu masuk pusat ATM. 4. Food Corner di sekitar area bekerja yang terdiri dari banyak meja dan ada seseorang duduk sambil mengerjakan sesuatu di laptop 5. Di depan terdapat meja di sebelah kanan dengan seseorang sedang di dekat meja tersebut dan jauh di depan terdapat tulisan "Food Corner"
		1. Empat buah besi penghalang tidak terlalu tinggi dengan warna putih dan oranye. 2. Sebuah pot dengan ukuran sedang berisi tumbuhan hias di dalamnya. Suasana ideal di ruang ini mendukung pembelajaran dan kreativitas. 3. tiang pembatas jalan di depan dan banyak orang serta anak sekolah memenuhi trotoar. 4. 4 tiang besi yang ditanamkan di tengah trotoar sebagai pembatas. 5. Banyak sepeda motor dan orang berhenti di sekitar trotoar yang memiliki tiang pembatas jalan 6. Trotoar dengan beberapa tiang pembatas berwarna merah-putih, diapit pepohonan dan tanaman hias, serta ramai dengan pengunjung dan pengendara motor di latar belakang.

3.1.2 Praproses

Pada tahap ini, data mentah berupa pasangan citra dan deskripsi teks disiapkan melalui serangkaian prosedur standarisasi agar dapat diproses secara optimal oleh arsitektur multimodal. Tahapan dimulai dengan pembagian dataset (*data splitting*) menggunakan rasio 70:21:9 untuk kebutuhan latih, validasi, dan pengujian. Data kemudian dikelompokkan ke dalam *batch size* = 8 untuk efisiensi komputasi. Jalur pemrosesan citra diawali dengan konversi gambar mentah ke format RGB menggunakan pustaka PIL guna memastikan konsistensi kanal warna.

Secara teknis, prosedur pendetailan citra seperti perubahan ukuran menjadi 224×224 piksel, penskalaan nilai (*rescale* $1/255$), dan normalisasi kanal warna diintegrasikan langsung menggunakan CLIPProcessor di dalam fungsi *forward_loss* selama fase pelatihan. Pendekatan *online preprocessing* ini bertujuan untuk memaksimalkan pemanfaatan akselerasi GPU melalui operasi tensor PyTorch, serta menjamin konsistensi statistik data dengan standar CLIP ViT-B/32 tanpa membebani penyimpanan fisik dengan file tensor statis yang berukuran besar.

Secara simultan, teks deskripsi diproses melalui tahap *prompt engineering* untuk membentuk instruksi terstruktur menggunakan format `<start_of_turn>user`. Ke dalam teks tersebut, diintegrasikan 50 token dummy visual (repetisi token 'the') yang berfungsi sebagai penanda ruang (*placeholder*) bagi fitur visual di dalam ruang laten. Teks kemudian dikonversi menggunakan Gemma Tokenizer menjadi urutan *input IDs*, dilengkapi dengan *attention mask*, serta penyesuaian panjang melalui teknik *padding 0*. Penempatan proses tokenisasi secara dinamis dalam fungsi *forward_loss* memungkinkan sistem melakukan *dynamic prompting* yang fleksibel. Output akhir dari tahap ini adalah tensor *pixel values*, *input IDs*, *attention mask*, dan *labels* yang siap diumpungkan ke dalam model.



Gambar 3. 2 Diagram alir praproses data

3.1.3 Pelatihan

Setelah data melewati tahap praproses, pelatihan dilakukan untuk mengintegrasikan fitur visual dengan kemampuan generatif bahasa model Gemma. Proses dimulai dengan mengekstraksi fitur visual menggunakan *encoder* CLIP ViT-B/32 yang berada dalam kondisi beku (*frozen*) untuk menghasilkan *image embedding* mentah berdimensi 768. Hasil ekstraksi tersebut diteruskan ke *Projection Layer* (MyAdaptor). Modul MLP ini bekerja melalui dua


lapisan linear dengan aktivasi GELU untuk menyelaraskan (*align*) fitur visual dari dimensi 768 ke dalam ruang vektor Gemma-2 berdimensi 2048.

Tabel 3. 2 Perbandingan Dimensi Tensor

No.	Input Dimensi	Input Dimensi	Output Dimensi	Status
1.	<i>Encoder CLIP</i>	[Batch,3,224,224]	[Batch,50,768]	<i>Frozen</i>
2.	<i>MLP Adaptor</i>	[Batch,50,768]	[Batch,50,2048]	<i>Trainable</i>
3.	<i>Gemma Embedder</i>	[Batch,Seq]	[Batch,Seq,2048]	<i>Frozen</i>
4.	<i>Gemma Decoder</i>	[Batch,Seq,2048]	[Batch,Seq,Vocab]	<i>Frozen</i>

Secara simultan, urutan *input IDs* dari teks deskripsi diproses melalui Gemma Embedding Layer untuk dikonversi menjadi representasi vektor dalam ruang laten. Di tahap inilah peran Gemma sebagai *embedder* terjadi, di mana token teks diskrit diubah menjadi vektor kontinu sebelum digabungkan dengan informasi visual. Selanjutnya, *embedding* visual yang telah diselaraskan disisipkan ke dalam urutan *embedding* teks menggunakan teknik *Embedding Injection* melalui fungsi *split_and_replace*. Fitur visual ini diintegrasikan sebagai *prefix* yang menggantikan posisi *dummy tokens* secara presisi di dalam ruang laten.

Vektor gabungan tersebut kemudian diproses oleh Dekoder Gemma-2-2b (*frozen*) untuk menghasilkan prediksi token secara autoregresif. Pelatihan dioptimalkan menggunakan strategi *Parameter-Efficient Fine-Tuning (PEFT)*, di mana pembaruan bobot hanya dilakukan pada lapisan Adaptor menggunakan optimizer Adam dengan *learning rate* 6×10^{-4} . Model belajar meminimalkan *cross-entropy loss* hingga mencapai konvergensi. Pada setiap akhir iterasi, dilakukan pemantauan terhadap *validation loss* untuk menyimpan model terbaik (*best checkpoint*). Hasil akhir dari proses ini adalah bobot parameter adaptor yang teroptimasi, yang mampu menghasilkan deskripsi gambar secara akurat saat diintegrasikan dengan komponen *frozen* lainnya.




Gambar 3. 3 Diagram alir pelatihan model

3.1.4 Inference Engine

Komponen inti dari sistem penalaran multimodal pada tugas akhir ini diimplementasikan dalam modul *custom_vlm_model.py*, yang berfungsi sebagai *Inference Engine* untuk menyatukan kapabilitas pemahaman bahasa dari model Gemma-2-2B-IT dengan kemampuan persepsi visual dari OpenAI CLIP ViT-Base-Patch32. Integrasi ini

dijembatani melalui kerangka kerja LangChain dalam kelas CustomVLMLLM, yang memungkinkan model untuk beroperasi secara sinkron, asinkron, maupun mendukung simulasi *streaming response* pada antarmuka agen.

Secara arsitektural, inti dari penggabungan modalitas ini terletak pada penggunaan komponen kustom yang disebut MyAdaptor (atau *Projection Layer*). Modul ini dibangun menggunakan arsitektur *Multi-Layer Perceptron* (MLP) dengan struktur *Linear-GELU-Linear*. Fungsi utamanya adalah memproyeksikan *embedding* visual yang diekstraksi oleh CLIP dari ruang vektor aslinya ke dalam ruang dimensi tersembunyi (*hidden space*) milik model bahasa Gemma. Proses penyelarasan semantik ini sangat krusial agar representasi fitur visual dapat dipahami dan diproses selayaknya token teks oleh *decoder* bahasa. Guna memastikan performa inferensi yang optimal pada perangkat *edge* dengan sumber daya terbatas (seperti Neutrack AI Glove), mesin ini menerapkan teknik kuantisasi 4-bit menggunakan konfigurasi BitsAndBytesConfig dengan tipe komputasi bfloat16, yang secara signifikan mereduksi kebutuhan memori tanpa mengorbankan akurasi secara drastis.



Gambar 3. 4 Diagram alir *inference engine*

Alur kerja inferensi (seperti diilustrasikan pada Gambar 3.4) dimulai ketika sistem menerima masukan berupa citra digital dari kamera. Citra mentah tersebut pertama-tama diproses oleh *processor* standar CLIP untuk diubah menjadi tensor dan dinormalisasi, sebelum diekstraksi menjadi vektor *embedding* visual dari lapisan tersembunyi terakhir (*last hidden state*) oleh *visual encoder*. Vektor ini kemudian melewati lapisan adaptor untuk transformasi dimensi.

Pada tahap pembentukan *prompt*, sistem secara dinamis mendeteksi keberadaan *trigger string* khusus <start_image>. Representasi visual yang telah selaras kemudian disisipkan (diinjeksi) ke dalam alur *embedding* teks tepat di antara token penanda <start_image> dan <end_image>, menggantikan token *dummy placeholder* yang disiapkan sebelumnya. Gabungan data visual ini disatukan dengan instruksi sistem spesifik, yaitu “Describe this image in detail for a visually impaired user,” yang disusun dalam format *Chat Template* standar Gemma (<start_of_turn>user...).

Selanjutnya, model Gemma-2 memproses input multimodal tersebut secara autoregresif untuk membangkitkan deskripsi. Untuk memastikan kualitas luaran teks yang akurat dan minim halusinasi, sistem menerapkan strategi *decoding* menggunakan *Beam Search* dengan


konfigurasi 5 *beams* (`num_beams=5`). Selain itu, mekanisme penalti repetisi (`repetition_penalty=1.2`) diterapkan untuk mencegah pengulangan kata yang tidak natural, sehingga menghasilkan *caption* atau deskripsi gambar yang koheren dan komprehensif bagi pengguna.

3.1.5 Integrasi *Wrapper LangChain* berbasis MCP

Proses terakhir dalam alur kerja ini adalah Eksekusi Instruksi Agent melalui Proxy, yang menjembatani komunikasi antara model cerdas (Gemma-2) dan alat eksternal. Ketika agen mengirimkan instruksi dalam format JSON, instruksi tersebut dirutekan secara spesifik ke *port proxy* yang sesuai dengan alat yang dituju. *Proxy* kemudian bertugas menerjemahkan permintaan HTTP tersebut menjadi panggilan standar *input/output (stdio)* ke proses subsistem terkait, baik itu proses Python maupun eksekusi perintah `npx` pada Node.js. Hasil eksekusi dari alat kemudian dikembalikan dalam format standar MCP, sehingga agen dapat memahami dan memproses respons tersebut tanpa perlu mengetahui kompleksitas teknis bahasa pemrograman yang berjalan di baliknya. Sistem orkestrasi yang dibangun dalam tugas akhir ini dikendalikan melalui integrasi strategis antara kerangka kerja LangGraph dan standar komunikasi *Model Context Protocol* (MCP), yang berfungsi sebagai pusat kendali logika dalam menjalankan siklus penalaran *Reasoning and Acting* (ReAct) bagi agen AI. Secara konseptual, LangGraph bertindak sebagai pengelola alur kerja utama yang menerima instruksi dari antarmuka pengguna melalui protokol FastAPI. Tugas utamanya adalah mengarahkan agen multimodal untuk melakukan analisis konteks, baik visual maupun tekstual guna mengevaluasi apakah penyelesaian tugas memerlukan bantuan dari alat eksternal (*external tools*). Apabila agen memutuskan bahwa suatu kapabilitas eksternal diperlukan, permintaan eksekusi tidak diproses secara monolitik, melainkan didelegasikan melalui komponen perantara yang disebut *Proxy Client* MCP. Komponen ini dikelola sepenuhnya oleh modul `MCPProxyManager`, yang dirancang untuk memanggil fungsi-fungsi spesifik pada server alat secara modular. Keunggulan fundamental dari pendekatan ini adalah kemampuannya dalam mengorkestrasi alat yang dibangun dengan bahasa pemrograman yang heterogen dalam satu ekosistem *runtime* yang terpadu. Seluruh proses pertukaran data berjalan secara dinamis, di mana hasil eksekusi dari setiap alat dikembalikan ke orkestrator LangGraph untuk disintesis menjadi respons akhir yang komprehensif bagi pengguna.


Agar sistem mampu berinteraksi secara andal dengan ekosistem perangkat lunak yang beragam, mekanisme manajemen koneksi dipusatkan pada modul `MCPProxyManager` yang beroperasi melalui serangkaian tahapan sistematis, dimulai dari inisialisasi hingga manajemen proses. Tahapan awal dimulai saat sistem melakukan *booting*, di mana manajer membaca konfigurasi alat dari basis data untuk menyiapkan lingkungan eksekusi yang sesuai. Sistem dirancang dengan fleksibilitas tinggi untuk mendukung berbagai lingkungan bahasa pemrograman; untuk layanan berbasis Python, eksekusi dilakukan secara efisien menggunakan pustaka `FastMCP`, sedangkan untuk layanan berbasis Node.js, sistem memanfaatkan perintah eksekusi paket `npx` (seperti `npx -y @modelcontextprotocol/server...`) yang memungkinkan server dijalankan secara langsung tanpa memerlukan instalasi global yang memberatkan sistem. Setiap layanan ini kemudian dibungkus (*wrapped*) oleh `mcp-proxy`, yang bertugas menstandarisasi format keluaran menjadi protokol *Server-Sent Events* (SSE) melalui *port* HTTP yang unik, sehingga menjamin keseragaman komunikasi antar modul yang berbeda bahasa.

Selanjutnya, stabilitas sistem dijaga melalui mekanisme pengawasan aktif yang berjalan secara kontinu. Mengingat sistem beroperasi pada perangkat *edge* dengan sumber daya terbatas, metode pemantauan `check_status()` beroperasi di latar belakang untuk memverifikasi status operasional setiap alat melalui pemantauan *Process ID* (PID) dan konektivitas soket jaringan secara *real-time*. Apabila terdeteksi adanya kegagalan fungsi pada salah satu alat, misalnya modul mengalami *crash* atau koneksi terputus secara paksa, metode `update_tools()` akan segera mendeteksi anomali tersebut dan secara otomatis melakukan *respawn* atau menghidupkan ulang proses yang mati. Mekanisme pemulihan otomatis (*self-healing*) ini memastikan bahwa gangguan pada satu subsistem alat tidak akan menghentikan operasional agen utama (*Intelligence Core*). Tahap terakhir dalam alur kerja ini adalah eksekusi instruksi yang menjembatani komunikasi antara model cerdas (Gemma-2) dan alat eksternal. Ketika agen mengirimkan instruksi operasional dalam format JSON, instruksi tersebut dirutekan secara spesifik ke *port proxy* yang sesuai dengan alat yang dituju. *Proxy* kemudian bertugas menerjemahkan permintaan HTTP tersebut menjadi panggilan standar input/output (*stdio*) ke proses subsistem terkait, lalu mengembalikan hasilnya dalam format standar MCP agar dapat dipahami oleh agen tanpa perlu mengetahui kompleksitas teknis di baliknya.



Gambar 3. 5 Diagram alir integrasi *React Agent* berbasis MCP

3.1.6 Integrasi Retrieval-Augmented Generation Berbasis CLIP



Gambar 3. 6 Diagram alir integrasi *Retrieval Augmented Generation* Berbasis CLIP

Mekanisme Retrieval-Augmented Generation (RAG) pada sistem ini diimplementasikan dengan mentransformasi citra masukan menjadi representasi numerik unik yang disebut sebagai vektor embedding menggunakan model CLIP Vision. Proses ini bertujuan untuk memetakan fitur visual ke dalam ruang laten berdimensi tinggi agar perbandingan data dapat dilakukan secara komputasi. Vektor tersebut digunakan sebagai kueri utama untuk mengeksekusi pencarian kesamaan kosinus (*cosine similarity search*) pada basis data vektor Supabase, guna mengidentifikasi referensi citra serupa yang memiliki label fakta akurat terkait detail objek, aktivitas, dan lingkungan.

Setelah hasil pencarian dengan tingkat kemiripan tertinggi diperoleh, fakta-fakta spesifik diekstraksi dari metadata JSON dan disatukan menjadi string konteks tambahan. Informasi faktual ini kemudian disuntikkan ke dalam struktur instruksi Agent LLM melalui modul integrasi. Melalui alur kerja ini, unit penalaran (*reasoning*) pada sistem tidak hanya mengandalkan deskripsi dasar yang dihasilkan oleh Vision-Language Model (VLM), tetapi juga didukung oleh referensi memori eksternal yang valid dari database. Integrasi ini memastikan bahwa respon yang dihasilkan memiliki presisi semantik yang tinggi, detail, dan sepenuhnya selaras dengan data faktual yang tersimpan di dalam sistem.

3.1.7 Pengujian dan Evaluasi

Tahap pengujian dan evaluasi ini bertujuan untuk mengukur kinerja model dalam menghasilkan teks deskripsi berdasarkan masukan gambar serta sistem AI Agent dalam mengimplementasikan mekanisme *Retrieval-Augmented Generation* (RAG) pada tiga kategori lingkungan gambar, yaitu *indoor*, *outdoor*, dan *street*. Dataset yang digunakan mencakup total 30 gambar yang terbagi secara merata sebanyak 10 gambar untuk setiap kategori, dengan seluruh fakta pendukung tersimpan dalam database Supabase. Evaluasi difokuskan pada kemampuan agen dalam menghasilkan informasi akurat berdasarkan tiga pertanyaan objektif sebagai *ground truth*, yaitu: (1) objek atau subjek apa yang terlihat di latar depan, (2) aktivitas apa yang dilakukan oleh objek atau subjek tersebut, dan (3) warna, bentuk, atau yang terdapat pada objek tersebut? Berapa jumlah objek atau subjek tersebut?

Sebagai langkah awal dalam prosedur evaluasi, sistem akan menghitung skor BLEU pada model *image captioning* dasar yang telah diintegrasikan (*wrap*) menggunakan LangChain untuk menetapkan nilai acuan awal (*baseline*) sebelum proses pengayaan data dilakukan. Selanjutnya, pengujian dilakukan terhadap tiga jenis arsitektur agen melalui antarmuka *frontend* agent-*invoke-stream.js*, yang meliputi: Gemma VLM Default sebagai model *captioning* standar tanpa mekanisme RAG, VLM Test + RAG yang menggunakan pengambilan data manual dari Supabase untuk memperkaya deskripsi, serta VLM Test + RAG + Supabase MCP yang memanfaatkan protokol *Model Context Protocol* untuk pengambilan data secara dinamis melalui mekanisme *tool calling*. Perbandingan ini dilakukan untuk mengidentifikasi konfigurasi agen yang mampu memberikan deskripsi paling akurat dengan skor BLEU tertinggi serta efisiensi waktu yang paling optimal.

Dalam aspek efisiensi teknis, sistem berbasis MCP dievaluasi melalui empat parameter operasional yang krusial. Parameter tersebut mencakup waktu inisiasi model LLM untuk mengukur durasi pemuatan *Large Language Model* ke dalam memori, serta waktu inisiasi AI Agent untuk mengukur kecepatan pembentukan agen berbasis ReAct yang terintegrasi dengan alat (*tools*) melalui MCP server. Selain itu, dilakukan pengukuran terhadap *response time* atau durasi inferensi mulai dari penerimaan kueri hingga pemberian jawaban akhir, serta jumlah

rekursi atau langkah penalaran (*reasoning steps*) yang ditempuh agen dalam satu siklus eksekusi untuk menyelesaikan kueri yang diberikan.

Selanjutnya, kualitas konten yang dihasilkan dievaluasi menggunakan metrik BLEU (*BiLingual Evaluation Understudy*) dengan membandingkan teks jawaban dari ketiga jenis AI Agent terhadap teks referensi fakta gambar yang telah divalidasi oleh manusia. Skor BLEU ini berfungsi mengukur tingkat kemiripan urutan kata atau *n-gram* antara prediksi model dengan data asli berdasarkan tiga pertanyaan objektif yang telah ditetapkan. Melalui integrasi pengujian teknis dan semantik ini, efektivitas proses RAG dapat dipastikan tidak hanya unggul dalam kecepatan eksekusi melalui teknologi MCP, tetapi juga memiliki ketepatan informasi yang tinggi dalam mengidentifikasi elemen fisik gambar secara akurat sesuai dengan fakta yang sebenarnya.

3.2 Implementasi

Pada bagian ini akan dijelaskan mengenai implementasi tugas akhir menggunakan *pseudocode*. *Pseudocode* tersebut mencakup tahapan-tahapan utama dalam penelitian, mulai dari praproses data citra dan teks, pelatihan model *adapter* multimodal, hingga pengujian dan evaluasi kinerja. Selain itu, bagian ini juga merinci implementasi sistem orkestrasi berbasis Model Context Protocol (MCP) yang mengelola siklus hidup server alat (*tools*) secara dinamis melalui *MCP Proxy Manager* untuk mendukung kemampuan penalaran agen. *Pseudocode* ini bertujuan untuk memberikan gambaran sistematis mengenai alur eksekusi dalam pembangunan tugas akhir secara menyeluruh, mencakup integrasi antara *inference engine* multimodal dan protokol komunikasi alat eksternal.

3.2.1 Praproses

Tahap praproses data dilakukan untuk mengonversi data mentah menjadi format tensor yang kompatibel dengan arsitektur multimodal Gemma-CLIP. Berbeda dengan praproses konvensional, tahap ini melibatkan penanganan format instruksi (*prompt engineering*) secara dinamis di dalam *training loop*. Untuk praproses citra, setiap file citra dimuat dan dikonversi secara eksplisit ke format RGB untuk memastikan konsistensi kanal warna sebelum diproses lebih lanjut. Citra kemudian diproses menggunakan AutoProcessor dari model CLIP (CLIP-vit-base-patch32), yang secara otomatis melakukan penyesuaian ukuran (*resizing*), penskalaan nilai piksel, dan normalisasi statistik warna agar sesuai dengan *encoder* visual. Untuk praproses teks, Alih-alih hanya membersihkan karakter, praproses teks difokuskan pada pembentukan struktur instruksi (*instruction template*) agar sesuai dengan format model Gemma-2B-IT. Setiap kalimat deskripsi dari dataset digabungkan dengan token instruksi sistem, yaitu <start_of_turn>user untuk menandai masukan pengguna, dan <start_of_turn>model untuk menandai jawaban model. Selain itu, token placeholder khusus <start_image> disisipkan ke dalam teks sebagai penanda lokasi penyisipan fitur visual. Teks yang telah terformat ini kemudian diubah menjadi urutan indeks numerik (*input_ids*) dan *attention_mask* menggunakan AutoTokenizer dengan pengaturan *padding* otomatis."

```
Input: caption_batch
```

```
Output: input_ids, attention_mask, labels
```

```
1. DEFINE instruction_template = "<start_of_turn>user\n<start_image>\n{dummy_token}\n<end_image>\nCreate a description...\n<start_of_turn>model\n"\n2. FOR caption in caption_batch:\n3. full_prompt = instruction_template + caption\n4. tokenized = Tokenizer(full_prompt, padding=True)
```

```

8.     APPEND tokenized['input_ids'] to list
9.     APPEND tokenized['attention_mask'] to list
11.    input_ids = tokenized['input_ids']
12.    attention_mask = tokenized['attention_mask']
13.    labels = input_ids (digunakan untuk perhitungan loss Cross Entropy)
15.    RETURN input_ids, attention_mask, labels

```

Pseudocode 3. 1 Praproses Data Teks Deskripsi

Indeks numerik yang merepresentasikan urutan token dalam bentuk angka (*input_ids*) dihasilkan secara otomatis oleh *tokenizer*. Bersamaan dengan itu, dihasilkan pula variabel *attention_mask* yang berfungsi untuk membedakan antara token data yang valid dan token *padding*. Penambahan *padding* ini dilakukan oleh *tokenizer* dengan tujuan menyamakan panjang sekuens dalam satu *batch* agar dapat diproses secara paralel oleh GPU. Nilai *attention_mask* diatur menjadi 1 untuk token yang memuat informasi instruksi atau deskripsi, dan 0 untuk token *padding* yang akan diabaikan oleh mekanisme atensi model. Selanjutnya, nilai indeks token (*input_ids*) tersebut juga diduplikasi ke dalam variabel *labels* untuk digunakan sebagai target kebenaran (*ground truth*) dalam perhitungan *loss* saat pelatihan. Pada Tabel 3.2 ditunjukkan contoh teks yang telah melalui tahap pemformatan instruksi (*instruction formatting*) dengan penambahan token spesial, sedangkan Tabel 3.3 menunjukkan hasil konversi teks tersebut menjadi indeks numerik yang siap menjadi masukan model.

Tabel 3. 3 Contoh *Instruction Formatting*

No.	Teks Asli	Teks Hasil Format
1.	Trotoar dengan deretan tempat duduk batu berbentuk kubus berwarna abu-abu	<start_of_turn>user <start_image> [...50x token visual...] <end_image> Create a simple description of the image! <end_of_turn> <start_of_turn>model Trotoar dengan deretan tempat duduk batu berbentuk kubus berwarna abu-abu
2.	Rambu lalu lintas menunjukkan arah belok kiri, dikelilingi pepohonan hijau dan jalan setapak yang tertata rapi.	<start_of_turn>user <start_image> [...50x token visual...] <end_image> Create a simple description of the image! <end_of_turn> <start_of_turn>model Rambu lalu lintas menunjukkan arah belok kiri, dikelilingi pepohonan hijau dan jalan setapak yang tertata rapi.
3.	trotoar yang bersih dengan lorong hotel agak jauh di depan	<start_of_turn>user <start_image> [...50x token visual...] <end_image> Create a simple description of the image! <end_of_turn> <start_of_turn>model trotoar yang bersih dengan lorong hotel agak jauh di depan
4.	Sejumlah orang	<start_of_turn>user <start_image> [...50x token visual...]

eksplisit untuk memastikan konsistensi kanal warna. Selanjutnya, gambar akan dilakukan penyesuaian ukuran (*resizing*) dan normalisasi secara otomatis oleh prosesor. Setiap nilai piksel akan diskalakan ke rentang 0-1 dan dinormalisasi menggunakan nilai rata-rata (*mean*) dan standar deviasi (*std*) bawaan dari dataset pelatihan CLIP. Hasil akhirnya adalah *pixel_values* yang berupa representasi tensor dari gambar yang telah diproses dan siap diproyeksikan oleh *vision encoder*.

```

Input: image_paths
Output: pixel_values
1.  READ image_dataset
2.  FOR image_path in image_dataset:
3.      image = Load_Image(image_path)
4.      image = Convert_to_RGB(image)
8.      image = Resize(image, size=(224, 224))
9.      image = Rescale(image, factor=1/255)
11.     image = Normalize(image,
        mean=[0.48145466, 0.4578275, 0.40821073]
        std=[0.26862954, 0.26130258, 0.27577711])
12.     pixel_value = Convert_to_tensor(image)
13.     APPEND pixel_value to pixel_values
15. RETURN pixel_values

```

Pseudocode 3. 2 Praproses Data Gambar

Pada Tabel 3.4 ditunjukkan beberapa contoh hasil gambar yang telah melalui serangkaian tahap praproses sebelum digunakan sebagai masukan bagi model *image captioning*. Tahap awal praproses dimulai dengan konversi format citra ke mode RGB dan penyesuaian ukuran gambar, di mana seluruh gambar diubah resolusinya menjadi 224×224 piksel untuk menyamakan dimensi masukan dan memastikan kompatibilitas dengan arsitektur *vision encoder* pada model CLIP ViT-Base-Patch32. Penyesuaian ini juga membantu mempercepat proses pelatihan karena dimensi *input* yang seragam. Tahap praproses selanjutnya yaitu normalisasi skala nilai piksel dari rentang awal 0–255 ke rentang 0–1. Setelah skala nilai piksel disesuaikan, langkah terakhir dalam praproses adalah normalisasi statistik warna gambar dengan menggunakan nilai rata-rata dan standar deviasi bawaan dari konfigurasi CLIP yang dikembangkan oleh OpenAI. Nilai yang digunakan adalah [0.48145466, 0.4578275, 0.40821073] untuk rata-rata dan [0.26862954, 0.26130258, 0.27577711] untuk standar deviasi.

Tabel 3. 5 Contoh Hasil Normalisasi Gambar

No.	Gambar Asli	Gambar Hasil Normalisasi
1.		

2.		
3.		
4.		
5.		

Setelah melalui tahap praproses terpisah, representasi visual dan tekstual diintegrasikan ke dalam satu kesatuan dataset (CaptionDataset) untuk keperluan pelatihan. Setiap unit data latih terdiri atas pasangan representasi tensor citra (pixel_values) serta representasi token numerik

dari kalimat deskripsi (*input_ids*). Mengingat setiap citra dalam dataset memiliki lima variasi kalimat deskripsi, mekanisme *data loading* dirancang untuk memperlakukan setiap variasi tersebut sebagai sampel independen. Hal ini berarti satu citra yang sama akan diduplikasi dan dipasangkan dengan masing-masing dari kelima deskripsi teksnya, sehingga model dapat mempelajari beragam representasi bahasa untuk satu konteks visual yang sama.

Secara spesifik pada pembentukan tensor *pixel_values*, transformasi citra menerapkan metode *Resize and Center Crop* dan bukan metode pemampatan (*squashing*). Pendekatan ini dipilih berdasarkan dua argumentasi fundamental. Pertama, untuk menghindari distorsi geometris; teknik pemampatan paksa berisiko merusak rasio aspek (*aspect ratio*) yang menyebabkan perubahan bentuk objek secara tidak wajar (misalnya objek lingkaran menjadi elips), yang fatal bagi kemampuan model dalam mengenali pola visual. Kedua, untuk menjaga konsistensi dengan data latih (*pre-training*); mengingat *vision encoder* openai/CLIP-vit-base-patch32 telah dilatih oleh OpenAI menggunakan jutaan citra dengan metode *cropping*, maka penerapan metode praproses yang selaras sangat krusial agar model dapat mengekstraksi fitur visual secara optimal sesuai dengan distribusi data yang telah dipelajarinya.

3.2.2 Pelatihan

Model yang dikembangkan merupakan kombinasi multimodal antara Gemma-2b sebagai *Large Language Model* (LLM) dan CLIP Vision Model sebagai *image encoder*, yang dijumpai oleh Adapter MLP dengan struktur Linear-GELU-Linear. Sesuai dengan Pseudocode 3.3, proses pelatihan dimulai pada baris ke-1 dengan mengatur model ke mode pelatihan, diikuti dengan pembekuan parameter (Frozen) pada baris ke-3 dan ke-4 guna menjaga efisiensi pelatihan. Komponen utama yang dilatih adalah Adapter MLP yang merinci alur proyeksi fitur visual pada baris ke-10 hingga ke-12. Integrasi data visual ke dalam ruang bahasa dilakukan pada baris ke-17, di mana fitur visual disisipkan ke posisi token pemicu *<start_image>*. Selanjutnya, baris ke-20 hingga ke-24 mencakup perhitungan *Language Modeling Loss* serta pembaruan bobot secara otonom menggunakan *optimizer Adam*.

```

Input: model, optimizer, scheduler, dataloader
Output: epoch_loss
1. SET model to train mode
2. FREEZE CLIP_Vision_Model AND Gemma_2b_LLM
3. UNFREEZE Adapter_MLP (Status: TRAINABLE)
4. INITIALIZE total_train_loss = 0, processed_batches = 0
5. FOR EACH (images, captions) IN dataloader:
6.     ENCODE images via CLIP  $\rightarrow$  Visual_Features
7.     PROJECT via Adapter MLP:
8.         a. Linear_1 (Project to Gemma Dimension)
9.         b. GELU Activation
10.        c. Linear_2 (Final Alignment)
11.     SPLICING: Insert Projected features into captions at <start_image>
12.     CALCULATE loss = model.forward_loss(images, captions)
13.     optimizer.zero_grad()
14.     BACKPROPAGATE loss
15.     optimizer.step()
16.     UPDATE total_train_loss += loss.item()
17.     scheduler.step()
18. END FOR
19. epoch_loss = total_train_loss / processed_batches
20. RETURN epoch_loss

```

Pseudocode 3. 3 Proses Pelatihan per Epoch

Validasi dilakukan pada setiap akhir *epoch* untuk mengukur kinerja generalisasi model menggunakan data yang tidak dilibatkan dalam pelatihan. Berdasarkan Pseudocode 3.4, tahap ini dimulai pada baris ke-1 dengan mengatur model ke mode evaluasi. Baris ke-4 menggunakan blok `torch.no_grad()` untuk memastikan tidak adanya perhitungan gradien maupun pembaruan bobot parameter. Proses berlanjut pada baris ke-5 di mana model melakukan *forward pass* untuk menghitung nilai kerugian (*loss*) antara prediksi dan label sebenarnya, yang kemudian diakumulasi pada baris ke-6 guna mendapatkan nilai rata-rata kerugian validasi.

```

Input: model, val_loader
Output: avg_val_loss
1. SET model to eval mode (no dropout/gradient)
2. INITIALIZE total_val_loss = 0
3. FOR EACH (images, captions) IN val_loader:
4.     WITH torch.no_grad():
5.         loss = model.forward_loss(images, captions)
6.         total_val_loss += loss.item()
7. END FOR
8. avg_val_loss = total_val_loss / len(val_loader)
9. RETURN avg_val_loss

```

Pseudocode 3. 4 Proses Validasi per Epoch

Seluruh alur pelatihan dikelola dalam blok eksekusi utama sebagaimana dirinci pada Pseudocode 3.5. Baris ke-3 menunjukkan mekanisme *checkpointing* yang memungkinkan sistem memuat status pelatihan sebelumnya (*resume*) jika tersedia. Siklus pelatihan dijalankan selama jumlah *epoch* yang ditentukan, di mana fase pelatihan per batch dieksekusi pada baris ke-9 hingga ke-14 dan fase validasi pada baris ke-19 hingga ke-22. Strategi penyimpanan model terbaik dilakukan pada baris ke-25 hingga ke-27; jika nilai *validation loss* saat ini lebih rendah dari nilai terbaik sebelumnya, maka *state* model akan disimpan sebagai *best_model.pt*.

```

Input: model, optimizer, train_loader, val_loader, num_epochs
Output: Saved Best Model (.pt file)
1. INITIALIZE start_epoch = 0, best_val_loss = infinity
2. IF checkpoint exists THEN:
3.     LOAD state (resume start_epoch, best_val_loss, weights)
4. FOR epoch FROM start_epoch TO num_epochs:
5.     --- Training Phase ---
6.     SET model to train mode
7.     INITIALIZE total_train_loss = 0
8.     FOR EACH (images, captions) IN train_loader:
9.         loss = model.forward_loss(images, captions)
10.        optimizer.zero_grad()
11.        BACKPROPAGATE loss
12.        optimizer.step()
13.        total_train_loss += loss.item()
14.    avg_train_loss = total_train_loss / len(train_loader)
15.    --- Validation Phase ---
16.    SET model to eval mode
17.    INITIALIZE total_val_loss = 0
18.    FOR EACH (images, captions) IN val_loader:
19.        WITH torch.no_grad():
20.            loss = model.forward_loss(images, captions)
21.            total_val_loss += loss.item()
22.    avg_val_loss = total_val_loss / len(val_loader)
23.    --- Save Best Model ---
24.    IF avg_val_loss < best_val_loss THEN:
25.        best_val_loss = avg_val_loss

```

```

26.          SAVE model state to BEST_MODEL_PATH
27.          SAVE current checkpoint to CHECKPOINT_PATH
28. END FOR

```

Pseudocode 3. 5 Proses Pelatihan Lengkap

3.2.3 Inference Engine

Implementasi *Inference Engine* pada sistem ini dirancang untuk beroperasi secara lokal (*on-premise*) guna mendukung privasi data serta responsivitas tinggi pada perangkat Neutrack AI Glove. Seluruh logika inferensi multimodal dibungkus dalam kelas CustomVLMLLM yang secara eksplisit mewarisi antarmuka dasar LLM dari *framework* LangChain, sebagaimana dideklarasikan pada Pseudocode 3.6 baris ke-1. Pewarisan ini berfungsi agar model visi-bahasa kustom dapat berinteraksi secara mulus dengan komponen agen otonom lainnya. Untuk mengatasi keterbatasan memori GPU (VRAM), sistem menerapkan teknik kuantisasi dalam metode `_load_model` yang dimulai pada baris ke-2. Pemeriksaan ketersediaan akselerator perangkat keras (CUDA) dilakukan pada baris ke-3, yang jika terdeteksi, akan mengaktifkan konfigurasi 4-bit BitsAndBytes dengan tipe komputasi `bfloat16` pada baris ke-5 untuk memuat model Gemma dalam kondisi terkompresi.

Proses pemuatan model inti pada baris ke-6 dan ke-7 memastikan bahwa baik Gemma-2b maupun CLIP Vision Model berada dalam status Frozen (tidak ada perubahan bobot), sementara baris ke-8 memuat bobot Adapter MLP yang telah dioptimasi dari file `best_model.pt`. Mekanisme inferensi dijalankan melalui metode `_call` pada baris ke-11, di mana sistem mengurai citra (baris ke-12), melakukan *encoding* visual (baris ke-13), dan memproyeksikannya melalui arsitektur Linear-GELU-Linear pada baris ke-14 untuk penyelarasan fitur visual ke dalam ruang vektor bahasa.

```

Input: System_Config, User_Prompt, Image_Input
Output: Natural_Language_Response
1. CLASS CustomVLMLLM (Inherits LangChain.LLM):
2.   METHOD _load_model():
3.     CHECK Hardware Availability (CUDA vs CPU)
4.     IF CUDA Available THEN:
5.       Quant_Config = BitsAndBytes(load_in_4bit=True, dtype=bfloat16)"
6.     LOAD Gemma_Model (Frozen) with Quant_Config
7.     LOAD CLIP_Vision_Model (Frozen) & Image_Processor
8.     LOAD Trained Adapter Weights from best_model.pt
9.     SET Model and Adaptor to EVAL mode
10.
11.   METHOD _call(Prompt):
12.     PARSE Image_Input from user prompt
13.     ENCODE Image → Visual_Hidden_State (via CLIP)
14.     PROJECT via Adapter MLP (Linear → GELU → Linear)
15.     MERGE Projected_Visual + Text_Embedding at <start_image>
16.     EXECUTE Gemma_Model.generate(
17.       inputs_embeds = Combined_Multimodal_Tensor,
18.       num_beams = 5,"
19.       repetition_penalty = 1.2 )
20.     RETURN String_Response to Agent

```

Pseudocode 3. 6 Inferensi Model Multimodal

Setelah representasi visual digabungkan dengan instruksi teks pada baris ke-15, proses generasi teks dilakukan oleh model Gemma pada baris ke-16 hingga ke-19. Untuk menjamin kualitas luaran, sistem menerapkan strategi *decoding* `num_beams=5` pada baris ke-18 yang

berfungsi untuk mempertahankan lima kandidat urutan kalimat terbaik secara simultan; cara kerjanya adalah dengan menghitung probabilitas kumulatif dari beberapa jalur kata guna menghindari kesalahan logika di awal kalimat, sehingga hasilnya adalah deskripsi yang lebih koheren dan akurat. Selain itu, parameter `repetition_penalty=1.2` pada baris ke-19 diterapkan untuk memberikan sanksi skor pada kata yang telah muncul sebelumnya, yang berfungsi mencegah model terjebak dalam pengulangan kata (*looping*); hasil akhirnya adalah informasi deskripsi gambar yang variatif, natural, dan mudah dipahami oleh pengguna sebelum respons teks dikembalikan kepada agen pada baris ke-20.

3.2.4 Integrasi ReAct Agent berbasis MCP

Agar sistem mampu berinteraksi secara andal dengan ekosistem perangkat lunak yang beragam, mekanisme manajemen koneksi dipusatkan pada modul `MCPProxyManager`. Modul ini bertanggung jawab untuk menginisialisasi proses *proxy* yang menjembatani komunikasi antara agen AI dan alat eksternal. Pada tahap inisialisasi, sistem menerima daftar perintah eksekusi lengkap, mengekstrak informasi *port* yang dituju, dan menjalankan setiap alat sebagai sub-proses independen. Hal ini memungkinkan sistem untuk menjalankan berbagai lingkungan *runtime* (seperti Python atau Node.js) secara paralel tanpa saling mengganggu. Logika inisialisasi ini dijabarkan pada Pseudocode 3.7.

```

Input: Command_List (Array of execution strings)
Output: Active_Processes (Map of Port -> Process)
1. FUNCTION start(Command_List):
2.   FOR EACH cmd IN Command_List:
3.     port = Extract_Port_From_String(cmd)
4.     IF port is valid THEN:
5.       env = Copy_System_Environment()
6.       // Eksekusi perintah di background process
7.       process = Subprocess.Spawn(cmd, shell=True, env=env)"
8.       self._processes[port] = process
9.       self._commands[port] = cmd
10.      START_THREAD read_output(process, port)
11.    END FOR

```

Pseudocode 3. 7 Inisialisasi Proses Proxy

Selanjutnya, untuk menjaga stabilitas sistem yang beroperasi pada perangkat *edge* dengan sumber daya terbatas, diterapkan mekanisme pemantauan kesehatan alat secara *real-time*. Metode pemantauan bekerja dengan cara memverifikasi konektivitas socket TCP pada *host* lokal (localhost). Jika sebuah *port* tidak memberikan respons atau koneksi ditolak, sistem menganggap alat tersebut tidak aktif. Pengecekan status ini krusial untuk memastikan bahwa agen tidak mencoba mengirimkan instruksi ke layanan yang sedang *down*. Alur logika pemantauan ini dapat dilihat pada Pseudocode 3.8.

```

Input: Active_Ports (List of running tool ports)
Output: Status_Log (Console Output)
1. FUNCTION check_status():
2.   FOR EACH port IN self._processes.keys():
3.     is_alive = Check_Socket_Connection(port)
4.     IF is_alive is True THEN:
5.       PRINT "Running on port {port}"
6.     ELSE:
7.       PRINT "NOT running on port {port}"
8.
9. FUNCTION Check_Socket_Connection(port):
10.  socket = Create_Socket(INET, STREAM)"

```

```

11. result = socket.connect_ex("localhost", port)
12. RETURN (result == 0) // 0 berarti sukses terkoneksi

```

Pseudocode 3. 8 Pengawasan Status Koneksi

Sistem dirancang agar adaptif terhadap perubahan konfigurasi tanpa perlu mematikan layanan utama (*zero-downtime reconfiguration*). Berdasarkan Pseudocode 3.9, fungsi `update_tools` pada baris ke-1 menerima data terbaru dari basis data untuk disinkronkan dengan proses yang sedang berjalan. Baris ke-2 hingga ke-3 menjelaskan proses ekstraksi peta perintah baru dan identifikasi *port* yang saat ini aktif di dalam memori. Tahap penghapusan alat yang tidak lagi dibutuhkan dijelaskan pada baris ke-5 hingga ke-8, di mana sistem membandingkan *port* aktif dengan data baru; jika ditemukan *port* yang sudah tidak terdaftar di basis data, maka proses tersebut segera dihentikan dan dihapus dari memori.

```

.Input: New_Tools_Data (List dari Database)
Output: Update_Report (Daftar Added, Removed, Updated)
1. FUNCTION update_tools(New_Tools_Data):
2.   new_commands_map = Extract_Commands(New_Tools_Data)
3.   current_ports = self._commands.keys()
4.   ports_to_remove = current_ports - new_commands_map.keys()
5.   FOR port IN ports_to_remove:
6.     Terminate_Process(self._processes[port])
7.     Remove_From_Memory(port)
8.   FOR port, cmd IN new_commands_map:
9.     IF port NOT IN self._processes:
10.      Spawn_New_Process(cmd)
11.    ELSE IF self._commands[port] != cmd:
12.      Terminate_Process(self._processes[port])
13.      Spawn_New_Process(cmd)
14.    ELSE:
15.      Continue
16.  RETURN Update_Report

```

Pseudocode 3. 9 Manajemen Pembaruan Alat Dinamis (*Hot-Swap*)

Selanjutnya, baris ke-10 mengawali siklus pemeriksaan untuk penambahan atau pembaruan konfigurasi alat. Jika sistem mendeteksi adanya *port* baru pada baris ke-11 hingga ke-12, maka proses baru akan segera dijalankan (*spawn*). Namun, apabila *port* tersebut sudah ada tetapi terdapat perbedaan konfigurasi perintah pada baris ke-13 hingga ke-15, sistem secara cerdas akan melakukan pemuatan ulang (*reload*) dengan menghentikan proses lama dan menjalankan kembali proses dengan konfigurasi terbaru. Logika manajemen dinamis ini memastikan bahwa kemampuan agen dapat diperbarui secara *hot swap* tanpa mengganggu stabilitas sistem, yang diakhiri dengan pengembalian laporan pembaruan pada baris ke-19

Setelah MCPProxyManager berhasil menjalankan proses *proxy* dan menyediakan *endpoint* SSE (misalnya di `http://localhost:8080/sse`), langkah selanjutnya adalah menghubungkan kapabilitas ini ke dalam "otak" agen. Proses ini terjadi di modul AgentBoilerplate, yang bertugas melakukan *binding* dinamis antara model bahasa dan alat eksternal. Ketika agen diinisialisasi, sistem terlebih dahulu memindai konfigurasi untuk mengidentifikasi alat yang tersedia. Jika alat terdeteksi, sistem menyusun peta konfigurasi koneksi yang memetakan nama alat ke URL *proxy* lokalnya. Peta konfigurasi ini nantinya digunakan oleh klien MCP untuk menarik skema fungsi secara otomatis. Logika pemindaian dan penyusunan konfigurasi ini dijabarkan pada Pseudocode 3.10.

```

Input: Agent_Config_Data (JSON Config)

```

```

Output: Has_Tools (Boolean), MCP_Connection_Map (Dict)
1. FUNCTION _parse_tools(Agent_Config_Data):
2.   has_tools = False
3.   mcp_config = {}
4.
5.   FOR EACH tool IN Agent_Config_Data.tool_details:
6.     latest_version = Get_Latest_Version(tool)
7.     IF latest_version.released IS True:
8.       tool_name = tool.name
9.       port = latest_version.released.port
10.      // Buat konfigurasi koneksi ke Proxy lokal
11.      mcp_config[tool_name] = {
12.        "url": "http://localhost:" + port + "/sse",
13.        "transport": "sse"
14.      }
15.      has_tools = True
16.
17.   RETURN has_tools, mcp_config,
18.   RETURN Update_Report

```

Pseudocode 3. 10 Parsing Konfigurasi Tools MCP

Khusus untuk integrasi dengan model cerdas eksternal seperti MaiaRouter, sistem memiliki logika penanganan khusus di modul `get_llms`. Jika pengguna memilih model berbasis *cloud* (misalnya *gemma-2-9b-it* via MaiaRouter), sistem akan menginisialisasi klien ChatOpenAI yang dikonfigurasi untuk berkomunikasi dengan *gateway* MaiaRouter. Integrasi ini sangat krusial karena model *cloud* ini memiliki kemampuan *function calling* bawaan yang kuat. Model ini tidak perlu "tahu" tentang MCP; ia hanya menerima definisi fungsi dalam format JSON standar OpenAI. Tugas sistem adalah menerjemahkan definisi fungsi dari MCP agar sesuai dengan format yang diharapkan oleh MaiaRouter. Inisialisasi model cerdas ini dijelaskan pada Pseudocode 3.11.

```

Input: Model_Name, Temperature
Output: LLM_Instance (Configured Model)
1. FUNCTION get_llms(Model_Name, Temperature):
2.   // Opsi 1: Model Cloud via MaiaRouter
3.   IF Model_Name contains "/" OR is "gemma-cloud" THEN:
4.     API_Key = Env.Get("MAIAROUTER_API_KEY")
5.     Base_URL = Env.Get("MAIAROUTER_BASE_URL")
6.
7.     LLM = ChatOpenAI(
8.       api_key=API_Key,
9.       base_url=Base_URL,
10.      model=Model_Name,
11.      temperature=Temperature
12.    )
13.     RETURN LLM
14.
15.   // Opsi 2: Model Lokal (Fallback)
16.   ELSE IF Model_Name == "custom-vlm" THEN:
17.     RETURN CustomVLMMLLM(

```

Pseudocode 3. 11 Konstruksi Agen dan Seleksi Model MaiaRouter atau VLM

Mengingat arsitektur ini juga mendukung model lokal (seperti *Gemma-2-2b-it*) yang beroperasi tanpa dukungan *native function calling*, sistem menerapkan lapisan adaptasi tambahan yang disebut *ReActTextAgent*. Berdasarkan Pseudocode 3.12 proses inisialisasi pada baris ke-2 hingga ke-4 berfungsi untuk membungkus model lokal melalui pembuatan deskripsi

alat dan penyuntikan instruksi khusus (*system prompt*) agar model mengikuti format penalaran "*Thought, Action, Observation*".

```

Input: User_Query, Tool_List, Max_Iterations
Output: Final_Answer
1. CLASS ReActTextAgent:
2.   METHOD __init__(Model, Tools):
3.     Tool_Desc = Generate_Descriptions(Tools)
4.     System_Prompt = ""Use format: Thought, Action, Observation. Tools: "" +
Tool_Desc
5.
6.   METHOD execute_loop(User_Query):
7.     Conversation = [System_Prompt, User_Query]
8.     Iteration = 0
9.
10.    WHILE Iteration < Max_Iterations:
11.      Response = Model.generate(Conversation)
12.
13.      IF Response contains "Final Answer:" THEN:
14.        RETURN Extract_Answer(Response)
15.
16.      Tool_Name, Tool_Input = Parse_Action_With_Regex(Response)
17.
18.      IF Tool_Name is valid THEN:
19.        Result = MCP_Client.execute(Tool_Name, Tool_Input)
20.        Observation = "Observation: " + str(Result)
21.        Conversation.append(Response + Observation)
22.      ELSE:
23.        Conversation.append(Response + "Error: Invalid Action Format")
24.
25.      Iteration += 1
26.
27.    RETURN "Max iterations reached"

```

Pseudocode 3. 12 Adaptasi ReAct Text-Based untuk Model Lokal

Tahap akhir dalam arsitektur ini adalah pengikatan (*binding*) dan eksekusi agen, di mana MultiServerMCPClient berperan vital sebagai jembatan komunikasi yang secara otomatis menarik skema alat dari server MCP melalui protokol SSE dan mengonversinya menjadi objek LangChainTool untuk disuntikkan ke dalam konstruktor agen ReAct. Mekanisme komunikasi ini berjalan secara sekuensial, dimulai ketika agen menerima instruksi pengguna, yang kemudian dianalisis oleh model *reasoning* (Gemma atau MaiaRouter) dengan mempertimbangkan daftar alat yang tersedia. Apabila model memutuskan untuk menggunakan alat, sistem menghasilkan luaran terstruktur (*Function Call Generation*) dalam format JSON berisi nama fungsi dan parameter yang dibutuhkan. Output ini lantas ditangkap oleh MultiServerMCPClient yang meneruskan permintaan eksekusi ke *port proxy* yang relevan dan menunggu hasilnya, sebelum akhirnya dikembalikan ke model untuk diformat menjadi respons bahasa alami, sebagaimana dirangkum dalam alur eksekusi dan komunikasi pada Pseudocode 3.13.

```

Input: Agent_ID, User_Query, Config
Output: Final_Response
1. FUNCTION invoke_agent(Agent_ID, User_Query, Config):
2.   Has_Tools, MCP_Config = _parse_tools(Config)
3.   Memory = Get_Agent_Memory(Agent_ID)
4.
5.   IF Has_Tools IS True THEN:

```



```

6.    // Inisialisasi Klien MCP sebagai Context Manager
7.    ASYNC WITH MultiServerMCPClient(MCP_Config) AS Client:
8.        // 1. Tarik & Konversi Skema Alat
9.        LangChain_Tools = Client.get_tools()
10.
11.        // 2. Buat Agen ReAct dengan Alat ter-bind
12.        Agent = get_react_agent(
13.            model_name=Config.model_name,
14.            tools=LangChain_Tools,
15.            memory=Memory
16.        )
17.
18.        // 3. Eksekusi Reasoning Loop (ReAct)
19.        Response = AWAIT Agent.ainvoke(User_Query)
20.    ELSE:
21.        // Eksekusi tanpa alat
22.        Agent = get_react_agent(Config.model_name, tools=[])
23.        Response = AWAIT Agent.ainvoke(User_Query)
24.
25.    RETURN Response

```

Pseudocode 3. 13 Eksekusi Agen Multimodal dengan Binding Tools MCP

3.2.5 Integrasi Retrieval-Augmented Generation (RAG) Berbasis CLIP

Guna mengatasi keterbatasan model visi-bahasa (*Vision-Language Model*) dalam mengenali konteks spesifik dari dataset tugas akhir, diimplementasikan mekanisme *Retrieval-Augmented Generation* (RAG). Mekanisme ini berfungsi sebagai "memori eksternal" yang menyediakan referensi gambar serupa dari basis data Supabase menggunakan *CLIP Embeddings*. Sistem ini dirancang untuk meningkatkan akurasi jawaban dengan memberikan konteks tambahan yang relevan terhadap lingkungan gambar yang diunggah pengguna.

```

Input: User_Image, Top_K (Number of results)
Output: RAG_Context (String of similar scene facts)
1. FUNCTION get_rag_context(User_Image):
2.     User_Embedding = CLIP_Model.encode(User_Image)
3.
4.     // Pencarian similarity di Supabase
5.     Results = Supabase.RPC("match_images", {
6.         "query_embedding": User_Embedding,
7.         "match_threshold": 0.5,
8.         "match_count": Top_K
9.     })
10.
11.     RAG_Context = "Additional context: Similar scenes: "
12.     FOR EACH item IN Results:
13.         // Ekstraksi fakta spesifik (q1, q2) dari metadata JSON
14.         Fact_String = f"{item.caption} ({item.facts.q1}, {item.facts.q2})"
15.         RAG_Context += Fact_String + "; "
16.     END FOR
17.
18.     RETURN RAG_Context

```

Pseudocode 3. 14 Pengambilan Konteks RAG Berbasis Vektor

Proses RAG dimulai dengan mengekstraksi fitur gambar pengguna menggunakan model CLIP guna menghasilkan representasi vektor (768-dimensi). Vektor ini kemudian dibandingkan menggunakan pencarian kesamaan kosinus (*cosine similarity*) terhadap data yang tersimpan di dalam tabel *image_indoor*, *image_outdoor*, dan *image_street* pada basis data

Supabase. Hasil pencarian berupa fakta-fakta spesifik yang kemudian disatukan menjadi string konteks untuk dianalisis oleh agen. Logika pengambilan konteks ini dijabarkan pada Pseudocode 3.15.

```
Input: Tool_Request (Action name and parameters)
Output: Structured_JSON_Response

1. SERVER SupabaseRAGServer:
2.   @tool
3.   METHOD search_similar_images_by_upload(image_file):
4.     Embedding = Generate_CLIP_Embedding(image_file)
5.     Return Supabase.VectorSearch(Embedding)
6.
7.   @tool
8.   METHOD search_similar_images_by_query(text_query):
9.     Embedding = Generate_Text_Embedding(text_query)
10.    Return Supabase.VectorSearch(Embedding)
11.
12.  @tool
13.  METHOD get_image_details(file_id):
14.    Return Supabase.Table("images").Select("").Where("id" == file_id)
```

Pseudocode 3. 15 Definisi Tools pada Server MCP RAG

Selain integrasi langsung, sistem ini memanfaatkan protokol Model Context Protocol (MCP) untuk menyediakan fungsi RAG sebagai alat eksternal (tool). Dengan server `supabase_rag_mcp` yang dibangun menggunakan kerangka kerja FastMCP, agen AI dapat memutuskan secara otonom kapan harus melakukan pencarian informasi tambahan. Hal ini memungkinkan evaluasi terhadap langkah penalaran (reasoning steps) agen. Arsitektur ini mencakup fungsi pencarian berbasis citra maupun teks, sebagaimana diuraikan dalam Pseudocode 3.16

Untuk menghasilkan respon yang optimal, sistem menerapkan prinsip pemisahan tugas. Gemma VLM bertindak sebagai "sensor visi" yang hanya menghasilkan deskripsi dasar (*basic captioning*).

```
Input: User_Image, User_Question, Agent_Name
Output: Final_User_Response

1. FUNCTION execute_multimodal_pipeline(User_Image, User_Question):
2.   // 1. Pengolahan Visi (VLM)
3.   VLM_Caption = VLM_Model.generate_simple_description(User_Image)
4.
5.   // 2. Cek apakah RAG diaktifkan berdasarkan nama agen (Trigger: "RAG")
6.   Context = ""
7.   IF Agent_Name.contains("RAG") THEN:
8.     Context = get_rag_context(User_Image)
9.   END IF
10.
11.  // 3. Konsolidasi Konteks untuk Agent LLM
12.  Full_Prompt = f"Image shows: {VLM_Caption}. {Context}. User Question: {User_Question}"
13.
14.  // 4. Generasi Jawaban Akhir
15.  Final_Answer = Agent_LLM.invoke(Full_Prompt)
16.  RETURN Final_Answer
```

Pseudocode 3. 16 Pipeline Integrasi VLM, RAG, dan Agent LLM

Sementara *Agent LLM* (seperti Gemma-IT atau model via MaiaRouter) bertindak sebagai "otak" yang mengonsolidasikan deskripsi visi, konteks RAG, dan kueri pengguna.

3.2.6 Pengujian dan Evaluasi

Pada tahap ini dilakukan pengujian model yang telah dilatih menggunakan data uji untuk menghasilkan teks deskripsi dari gambar. Evaluasi hasil prediksi model dilakukan dengan membandingkan teks prediksi dengan lima teks referensi asli menggunakan metrik evaluasi BLEU dan ROUGE-L. Perhitungan metrik ini bertujuan untuk mengukur kesesuaian teks deskripsi yang dihasilkan model dengan teks deskripsi referensi. Nilai metrik ini berkisar antara 0 hingga 1 dan dalam penelitian ini nilai tersebut dikonversikan menjadi persentase untuk memudahkan interpretasi. Rata-rata dari semua nilai metrik pada data uji dihitung untuk mendapatkan performa keseluruhan model. Proses pengujian dan evaluasi ini dapat dilihat pada Pseudocode 3.17 berikut. Pada baris ke-1 dilakukan inisialisasi teks deskripsi yang sudah dihasilkan dari model terlatih. Selanjutnya, pada baris ke-2 dilakukan iterasi untuk menghitung nilai metrik BLEU-1, BLEU-2, BLEU-3, BLEU-4 dan ROUGE_L dengan membandingkan hasil teks deskripsi dari prediksi model dan teks deskripsi referensi yang ada pada data uji. Pada baris ke-8 dan baris ke-9 dilanjutkan dengan perhitungan rata-rata pada setiap metrik BLEU dan ROUGE dan dilakukan analisis terhadap hasil evaluasi yang sudah didapatkan tersebut.

```
Input: test_dataset
Output: Evaluation metrics (BLEU, ROUGE-L)
1.  Initialize candidate_sentence

2.  FOR each image, references in test_dataset:
3.      BLEU-1 = BLEU(references, candidate_sentence, weights=(1, 0, 0, 0))
4.      BLEU-2 = BLEU(references, candidate_sentence, weights=(0.5, 0.5, 0, 0))
5.      BLEU-3 = BLEU(references, candidate_sentence, weights=(0.33, 0.33, 0.33, 0))
6.      BLEU-4 = BLEU(references, candidate_sentence, weights=(0.25, 0.25, 0.25, 0.25))
7.      ROUGE_L = Calculate_ROUGE_L(references, candidate_sentence)

8.  Calculate mean_of_BLEU
9.  Calculate mean_of_ROUGE_L


10. IF evaluation results are not satisfactory:
11.     Perform hyperparameter tuning
12.     Retrain model

13. Export evaluated_model and evaluation results
```

Pseudocode 3. 17 Proses Evaluasi Model

3.2.7 Perancangan Antarmuka

Arsitektur sistem dibangun menggunakan pendekatan microservices yang berpusat pada satu gerbang utama (gateway) untuk memisahkan logika bisnis ke dalam modul-modul independen yang saling berkomunikasi melalui protokol HTTP standar. Agar sistem dapat digunakan, pengguna diwajibkan melakukan autentikasi untuk mendapatkan JWT_TOKEN yang valid serta memastikan peladen (backend) berjalan pada alamat lokal localhost dengan port 8080. Pusat dari seluruh orkestrasi ini terletak pada berkas app.py yang berfungsi sebagai inisiator aplikasi dan router utama yang menggabungkan seluruh layanan mikro menjadi satu kesatuan API yang kohesif.



Gambar 3. 7 Antarmuka Homepage Aplikasi (a) Modul Fitur (b) Bypass JWT Token

Modul `app.py` bertindak sebagai tulang punggung (backbone) aplikasi berbasis FastAPI yang tidak menyimpan logika bisnis kompleks, melainkan bertugas memuat konfigurasi lingkungan (environment variables), menginisialisasi middleware seperti CORS dan otentikasi, serta mendaftarkan rute (routers) dari berbagai modul microservice. Secara spesifik, `app.py` menerapkan lapisan keamanan di mana akses ke fitur-fitur kritis dibatasi sehingga pengguna harus menyertakan token otentikasi (JWT_TOKEN) dalam header setiap permintaan HTTP. Sistem dikonfigurasi untuk berjalan pada `localhost:8080` sebagai titik akses utama API dan seperti terlihat pada struktur direktori, `app.py` mengimpor serta menggabungkan rute dari `agent_backend`, `agent_creator`, `agent_boilerplate`, `mcp_tools`, dan `rag` untuk memastikan antarmuka frontend hanya perlu berkomunikasi dengan satu titik masuk. Proses inisialisasi dan orkestrasi pada `app.py` dijabarkan dalam Pseudocode 3.18 berikut ini.

```
Input : Environment Variables, Router Modules (Backend, Creator, Boilerplate, MCP, RAG), JWT_SECRET
Output: Running FastAPI Application Instance on localhost:8080

1. LOAD Environment Variables (load_dotenv)
2. Initialize app = FastAPI instance
3. Configure Middleware:
4.     Add CORSMiddleware to app
5.     Set allow_origins = [""] (Allow frontend connections)
6.     Set AuthMiddleware (Validate JWT_TOKEN in Headers)
7. Register Microservice Routers:
8.     app.include_router(agent_router, prefix="/api/agents")
9.     app.include_router(agent_creator_router, prefix="/api/agent-creator")
10.    app.include_router(agent_boilerplate_router, prefix="/api/agent-boilerplate")
11.    app.include_router(mcp_tools_router, prefix="/api/mcp-tools")
12.    app.include_router(rag_router, prefix="/api/rag")
13. DEFINE Startup Events:
14.    Connect to Database (Supabase PostgreSQL)
15.    Check MCP Server Status
16. DEFINE Root Endpoint (GET /) for Health Check
17. Start Uvicorn Server (Host="0.0.0.0", Port=8080)
18. RETURN app
```

Pseudocode 3. 18 Inisialisasi Server Aplikasi

Secara garis besar, implementasi sistem ini terbagi ke dalam empat halaman antarmuka utama yang saling terintegrasi, yaitu halaman manajemen agen (`agents.html`), halaman integrasi alat (`tools.html`), halaman pembuat agen cerdas (`agent-creator.html`), dan halaman eksekusi agen (`agent-invoke-stream.html`).

Halaman fitur pertama adalah manajemen agen, berfungsi sebagai dasbor sentral bagi pengguna untuk mengelola siklus hidup agen cerdas melalui antarmuka `agents.html`. Fitur utamanya meliputi visualisasi daftar agen, penambahan agen baru, serta penghapusan agen. Layanan backend untuk fitur ini diimplementasikan dalam modul `agents.py` yang bertindak sebagai jembatan antara frontend dan basis data Supabase (PostgreSQL). Modul ini menangani permintaan CRUD (Create, Read, Update, Delete) dengan terlebih dahulu memvalidasi struktur data menggunakan skema Pydantic dan memastikan otorisasi token pengguna. Data agen kemudian disimpan atau diambil dari tabel PostgreSQL menggunakan *query* SQL yang aman. Logika pemrosesan data pada sisi backend ini dijelaskan secara rinci pada Pseudocode 3.19.


```

Input      : HTTP Request (GET/POST/DELETE), Agent Data Schema (JSON), JWT_TOKEN
Output     : JSON Response (List of Agents or Success Status)
1. Initialize Router (APIRouter)
2. DEFINE Data Model (Class AgentSchema):
3.     name (String), role (String), tools (List), model_config (Dict)
4. FUNCTION get_all_agents (GET /):
5.     Validate JWT_TOKEN
6.     Query Supabase Table "agents" -> Select All Records
7.     Convert SQL rows to JSON format
8.     RETURN List[Agent]
9. FUNCTION create_agent (POST /):
10.    Validate JWT_TOKEN
11.    Parse Input JSON with AgentSchema
12.    IF Validation Fails: RETURN Error 422
13.    Insert new record into Supabase Table "agents"
14.    Commit Transaction
15.    RETURN Success Message & Agent ID
16. FUNCTION delete_agent (DELETE /{agent_id}):
17.    Validate JWT_TOKEN
18.    Query Supabase -> Delete row where id == agent_id
19.    IF Not Found: RETURN Error 404
20.    RETURN Success Message

```

Pseudocode 3. 19 Logika Tampilan Manajemen Agen

Pada Gambar 3.8 ditunjukkan tampilan antarmuka manajemen agen. Gambar 3.8(a) memperlihatkan keadaan awal di mana daftar agen ditampilkan dalam susunan *grid* yang rapi, lengkap dengan tombol navigasi utama. Sedangkan Gambar 3.8(b) menunjukkan respons antarmuka konfigurasi *agent* seperti nama, deskripsi, *personality agent* dengan input *prompt user*, dan pilihan *tools* MCP untuk binding.



Gambar 3. 8 Antarmuka Manajemen Agen (a) Tampilan daftar agen (b) Konfigurasi Agen

Halaman fitur kedua adalah pemantauan alat eksternal yang dikelola melalui layanan backend `mcp_tools.py` dan diakses pengguna via antarmuka `tools.html`. Halaman ini krusial untuk memastikan bahwa server *Model Context Protocol* (MCP) berjalan dengan baik dan alat-alat seperti pencarian web atau akses file sistem siap digunakan oleh agen. Modul backend ini menyediakan *endpoint* khusus yang bertugas melakukan inspeksi status server MCP dan mengambil metadata alat. Ketika permintaan masuk, sistem memvalidasi token otentikasi, kemudian mencoba melakukan *ping* ke server MCP.


```

Input : HTTP Request (GET), JWT_TOKEN
Output: JSON Response (Connection Status, List of Tools)
1. Initialize Router (APIRouter)
2. DEFINE Data Model (Class ToolSchema):
3.     name (String), description (String), input_schema (Dict)
4. FUNCTION check_mcp_status (GET /status):
5.     Validate JWT_TOKEN
6.     Try Connect to MCP_SERVER_HOST
7.     IF Connection Success: RETURN Status "Active"
8.     ELSE: RETURN Status "Offline"
9. FUNCTION get_available_tools (GET /list):
10.    Validate JWT_TOKEN
11.    Call MCP Client -> List_Tools()
12.    Parse result into List[ToolSchema]
13.    RETURN List[ToolSchema]

```

Pseudocode 3. 20 Logika Tampilan Manajemen MCP

Tampilan visual untuk halaman integrasi alat dapat dilihat pada Gambar 3.9.(a) menampilkan indikator status server yang berwarna kuning menandakan koneksi stabil. Sedangkan Gambar 3.9(b) menunjukkan respons antarmuka konfigurasi *agent* seperti nama, deskripsi, *version control* MCP yang berisi *input environment variables* format JSON, dan argumen (*args*) berbasis *npx* yang harus diinput user untuk menghubungkan MCP kepada aplikasi yang diinginkan dengan transport Single-Streaming Events (SSE).



Gambar 3. 9 Antarmuka Integrasi MCP (a) Indikator status *server* MCP (b) Konfigurasi *server* MCP

Halaman fitur ketiga dari sistem ini adalah halaman `agent-creator.html` yang dilengkapi dengan kemampuan *Generative UI*. Pengguna tidak perlu mengisi konfigurasi teknis secara manual; cukup dengan memasukkan deskripsi natural pada kolom input, sistem backend akan merancang agen secara otomatis. Proses ini, sebagaimana dijelaskan dalam Pseudocode 3.21, melibatkan pemanggilan ke *Large Language Model* (LLM) untuk menyusun *system instruction*

yang optimal dan memilih alat yang relevan berdasarkan deskripsi pengguna. Hasil generasi tersebut kemudian diisi secara otomatis (*autofill*) ke dalam formulir pendaftaran agen.


```

Input: user_description_text, available_tools_list
Output: filled_agent_form
1. Capture Input from Text_Area(user_description)
2. On_Click_Button("Generate with AI"):
    prompt = Construct_Prompt(user_description, available_tools_list)
    response = Call_LLM_API(prompt)
    parsed_data = Parse_JSON(response)
3. Fill_Input_Field("Agent Name", parsed_data.name)
4. Fill_Input_Field("Role", parsed_data.role)
5. Fill_Text_Area("System Instructions", parsed_data.instructions)
6. Select_Checkboxes(parsed_data.selected_tools)
7. RETURN updated_form_ui

```

Pseudocode 3. 21 Logika AI *Autofill* pada *Agent Creator*

Gambar 3.10 mengilustrasikan antarmuka pembuat agen. Gambar 3.10(a) menunjukkan *chatroom* dimana *Agent Creator Agent* meminta user untuk menjelaskan *agent* baru yang ingin dibuat Gambar 3.10(b) menampilkan hasil setelah tombol enter ditekan, di mana seluruh kolom formulir telah terisi secara otomatis oleh AI, siap untuk disimpan ke database Supabase, dengan MCPHub Recommendations user dapat mencentang MCP mana saja yang ingin dipakai dan dijadikan *benchmarking*.



Gambar 3. 10 Antarmuka Agent Creator (a) Input deskripsi pengguna di *chatroom* (b) Formulir terisi otomatis oleh AI

Halaman fitur keempat adalah *agent-invoke-stream.html*, yang berfungsi sebagai ruang interaksi *chat* antara pengguna dan agen. Antarmuka ini dirancang untuk menangani aliran data (*streaming*) token demi token, memberikan efek respons yang cepat seperti mengetik. Pseudocode 3.22 menjelaskan mekanisme *looping* di mana antarmuka terus mendengarkan *chunk* data yang dikirim oleh backend selama proses *reasoning* (berpikir) agen berlangsung. Selain teks, antarmuka ini juga mendukung unggahan gambar untuk diproses oleh model multimodal.

```

Input: user_message, uploaded_image (optional)
Output: streamed_chat_response
1. Display_User_Message(user_message)
2. Initialize EventSource connection to "/api/stream-chat"
3. Send payload {message: user_message, image: uploaded_image}
4. WHILE connection is OPEN:
    Listen for event "data":

```


```

chunk = event.data
IF chunk == "[DONE]":
    Close connection
    Break Loop
ELSE:
    Append chunk to Chat_Bubble_DOM
    Scroll_View_To_Bottom()
5. Save_Chat_History_To_Supabase()
6. RETURN active_chat_session

```

Pseudocode 3. 22 Logika *Streaming* Percakapan Agen

Pada Gambar 3.11 diperlihatkan antarmuka percakapan agen. Di *navigation bar* sebelah kiri, user dapat memilih *agent* yang ingin ditesting, memilih LLM baik *local* maupun *cloud*, dan mengatur bahasa maupun kepribadian agent dengan *prompt*.



Gambar 3. 11 Antarmuka Agent Invoke Stream berbasis RAG dan MCP Multimodal

Halaman ini sengaja dikosongkan.

BAB 4

HASIL DAN PEMBAHASAN

Lingkungan yang akan digunakan dalam penelitian ini terbagi menjadi lingkungan perangkat lunak dan perangkat keras. Untuk lingkungan perangkat lunak yang digunakan adalah sebagai berikut:

- a. Visual Studio Code sebagai *integrated development envirnment* (IDE) untuk menuliskan kode program serta menjalankan program di lokal.
- b. Jupyter Notebook sebagai *integrated development environment* (IDE) untuk menuliskan kode program serta menjalankan program di perangkat komputer ITS.
- c. Python sebagai bahasa pemrograman yang digunakan untuk pengembangan model *image captioning* dalam penelitian ini.

Sedangkan lingkungan perangkat keras yang digunakan dalam penelitian ini adalah sebagai berikut:

Tabel 4. 1 Spesifikasi Perangkat Keras

No	Perangkat	Spesifikasi
1	Sistem Operasi	Ubuntu 22.04 LTS (via WSL2 pada Windows 11)
2	Memori (RAM)	<i>Random Access Memory</i> (RAM) 16 GB
3	CPU	13th Gen Intel(R) Core(TM) i9-13900H (2.60 GHz)
4	GPU	<i>NVIDIA® GeForce RTX™ 4070 with 8GB GDDR6</i>

4.1 Hasil Penelitian

Pada subbab ini akan dijelaskan mengenai hasil dari penelitian yang meliputi hasil optimasi parameter serta skenario-skenario pengujian yang dirancang untuk mengevaluasi performa Amadeus Inference Engine dalam menghasilkan teks deskripsi dari gambar dan menjalankan fungsi agen. Evaluasi dilakukan menggunakan metrik BLEU-Score yang terdiri dari BLEU-1 hingga BLEU-4. Secara keseluruhan terdapat empat skenario pengujian yang dirangkum pada Tabel 4.5. Skenario pertama bertujuan untuk membandingkan performa model berdasarkan *hyperparameter tuning* menggunakan Optuna untuk menemukan konfigurasi *learning rate* terbaik. Skenario kedua membandingkan performa antara model *baseline* (eksperimen awal) dengan model final yang telah teroptimasi. Skenario ketiga mengevaluasi kehandalan sistem *Agentic AI* berbasis MCP dalam menjalankan instruksi alat (*tool calling*). Skenario terakhir, skenario keempat membandingkan performa metode yang diusulkan (Amadeus) dengan metode sebelumnya (BLIP) untuk mengetahui arsitektur mana yang lebih unggul.


Tabel 4. 2 Tabel Skenario Pengujian

No	Skenario	Tujuan
1	Pencarian <i>Learning Rate</i> Terbaik pada Model Gemma-CLIP dengan <i>Grid Search</i> Optuna	Mendapatkan nilai <i>learning rate</i> dan konfigurasi parameter paling optimal untuk melatih model Amadeus (Gemma-2-2b + CLIP).
2	Perbandingan performa model <i>Baseline</i> dan <i>Optimized</i>	Membandingkan performa model sebelum dan sesudah penerapan parameter optimal (<i>learning rate</i>) pada <i>Projection Adapter</i> .
3	Perbandingan dengan metode sebelumnya	Membandingkan performa model terbaik pada pelatihan ini dengan metode sebelumnya
4	Pengujian <i>Tool Calling</i> MCP Supabase dan LLM AI Agent	Mengevaluasi kinerja integrasi sistem <i>Agentic AI</i> berbasis MCP dalam menjalankan operasi database (<i>create table</i>) secara sinkron dan fungsional.

5	Pengujian Dataset Kampus <i>Indoor</i>	Mengevaluasi efektivitas RAG dan MCP dalam mengidentifikasi objek padat dan aktivitas di dalam ruangan serta meminimalisir halusinasi visual.
6	Pengujian Dataset Kampus <i>Outdoor</i>	Mengevaluasi kemampuan agen dalam memetakan identitas gedung (landmark) dan fitur visual pada lingkungan luar ruangan dengan pencahayaan alami.
7	Pengujian Dataset Trotoar Surabaya	Mengevaluasi keandalan agen dalam menangani kompleksitas lingkungan urban (entitas komersial dan marka jalan) serta menguji efisiensi latensi MCP.

4.1.1 Skenario 1: Pencarian *Learning Rate* Terbaik Pada Model Gemma-CLIP dengan *Grid Search Optuna*

Pada skenario 1 ini dilakukan pengujian untuk membandingkan performa model berdasarkan penyesuaian *hyperparameter* (*hyperparameter tuning*) menggunakan kerangka kerja Optuna. Model yang digunakan adalah Amadeus (Gemma-2-2b + CLIP). Penyesuaian parameter difokuskan pada nilai *Learning Rate* (LR) untuk lapisan *adapter*, dengan jumlah *epoch* dinamis (maksimal 10) dan *batch size* 8. Penyesuaian ini krusial karena *Adapter* bertindak sebagai jembatan sensitif antara fitur visual dan teks.



Evaluasi awal pada tahap *tuning* ini dipantau menggunakan *Validation Loss* dan BLEU-4 sementara. Hasil pencarian parameter terbaik dapat dilihat pada Tabel 4.3.

Tabel 4. 3 Pencarian *Learning Rate* Terbaik Pada Model Gemma-CLIP dengan Optuna

No	Trial ID	Learning Rate (LR)	Validation Loss	Status
1	Trial 0	1.33×10^{-4}	3.1387	Stabil
2	Trial 1	7.11×10^{-4}	3.1716	Fluktuatif (<i>Unstable</i>)
3	Trial 2	1.57×10^{-4}	3.1134	Cukup Baik
4	Trial 3	6.25×10^{-4}	3.0169	Optimal (Best Fit)
5	Trial 4	2.94×10^{-4}	3.3766	<i>Underfitting / Lambat</i>

Dari hasil di atas didapatkan bahwa penggunaan *learning rate* sebesar 6.25×10^{-4} memperoleh hasil yang terbaik dengan *Validation Loss* terendah yaitu 3.0169. Pola eksperimen menunjukkan bahwa pada nilai LR yang cukup besar (Trial 2: 7.11×10^{-3}) *loss*

model tertahan di angka yang tinggi (3.1716), mengindikasikan kesulitan model mencapai titik minimum global (*overshooting*). Sebaliknya, pada nilai yang terlalu kecil (Trial 5: 2.94×10^{-5}), model belajar sangat lambat sehingga menghasilkan *loss* tertinggi (3.3766) pada akhir iterasi (*underfitting*). Oleh karena itu, nilai 0.0006 dipilih sebagai konfigurasi final untuk pelatihan penuh karena terbukti memberikan keseimbangan terbaik antara kecepatan belajar dan stabilitas gradien pada lapisan *Adapter*.

4.1.2 Skenario 2: Perbandingan Performa Model Berdasarkan Hyperparameter Tuning

Pada skenario 2 ini, dilakukan pengujian untuk membandingkan performa antara model *baseline* dan model yang telah dioptimasi (*optimized*). Pengujian ini bertujuan untuk memvalidasi efektivitas parameter *learning rate* yang diperoleh dari hasil *hyperparameter tuning* menggunakan Optuna pada skenario sebelumnya.

Model yang digunakan adalah Amadeus (Gemma-2-2b + CLIP). Model *baseline* menggunakan konfigurasi standar dengan *learning rate* sebesar 1×10^{-4} sedangkan model *optimized* menggunakan konfigurasi hasil tuning terbaik dengan *learning rate* sebesar 6×10^{-4} . Kedua model dilatih menggunakan *batch size* yang sama, yaitu 8, dengan jumlah *epoch* maksimal 10. Evaluasi dilakukan menggunakan metrik BLEU-Score untuk mengukur kualitas *caption* yang dihasilkan. Hasil perbandingan performa kedua model dapat dilihat pada Tabel 4.7.

Tabel 4. 4 Perbandingan Performa Model Berdasarkan *Hyperparameter Tuning*

No	Optimizer	Scheduler	Learning Rate	Batch Size	BLEU-1 (%)	BLEU-2 (%)	BLEU-3 (%)	BLEU-4 (%)	ROUGE-L (%)
1	Adam	None	1×10^{-4}	8	46.32	28.85	18.50	11.88	33.44
2	Adam	None	6×10^{-4}	8	50.77	32.19	22.14	15.77	34.29

Berdasarkan Tabel 4.7, terlihat bahwa penerapan *learning rate* hasil optimasi memberikan peningkatan performa yang signifikan. Model *baseline* memperoleh skor BLEU-4 sebesar 11,88%, sedangkan model *optimized* berhasil mencapai skor BLEU-4 sebesar 15,77%.

Peningkatan skor BLEU-4 sebesar 3,89% ini mengindikasikan bahwa model *optimized* mampu menghasilkan deskripsi gambar yang lebih akurat dan alami dibandingkan model *baseline*. Hal ini membuktikan bahwa penggunaan *learning rate* yang tepat 6×10^{-4} sangat krusial dalam proses adaptasi fitur visual dari CLIP ke ruang teks Gemma, memungkinkan model untuk meminimalkan *loss* dengan lebih efektif tanpa terjebak pada *local minima* atau mengalami *overfitting*.

4.1.3 Skenario 3: Perbandingan dengan Metode Sebelumnya

Pada skenario 3, dilakukan pengujian untuk membandingkan performa model terbaik yang dihasilkan dalam penelitian ini dengan beberapa metode sebelumnya. Perbandingan dilakukan dengan melatih dan menguji model pada dataset yang sama seperti yang digunakan oleh metode-metode terdahulu. Metode pembanding meliputi kombinasi DenseNet-201 dengan 1-layer LSTM dan 2-layer Bi-LSTM, arsitektur Swin Transformer-GPT2, serta model BLIP dan BLIP-2. Hasil perbandingan kinerja model ditampilkan pada Tabel 4.11

Tabel 4. 5 Perbandingan dengan Metode Sebelumnya

No	Model	BLEU-1 (%)	BLEU-2 (%)	BLEU-3 (%)	BLEU-4 (%)	ROUGE-L (%)
1	DenseNet-201 + 1-layer LSTM dan 2-layer bi-LSTM (Navastara dkk., 2023)	51,80	31,96	16,48	8,03	-
2	<i>Swin Transformer</i> -GPT2 (Navastara dkk., 2024)	37,10	20,94	12,71	9,17	24,28
3	BLIP-2 (Anas Azhar, 2024)	24,61	15,57	10,58	7,02	37,02
4	BLIP	33,82	23,81	17,49	13,00	27,65
5	CLIP ViT + Gemma-2-2b	50,77	32,19	22,14	15,77	34,29

Dari hasil evaluasi yang diperoleh, terlihat bahwa model yang diusulkan (CLIP ViT + Gemma-2-2b) menunjukkan performa yang paling unggul secara keseluruhan, khususnya pada metrik BLEU-3 (22,14%) dan BLEU-4 (15,77%). Meskipun model DenseNet-201 (Navastara dkk., 2023) memiliki skor BLEU-1 yang sedikit lebih tinggi (51,80%), model tersebut mengalami penurunan signifikan pada n-gram yang lebih tinggi (BLEU-4 hanya 8,03%). Sebaliknya, model CLIP ViT + Gemma-2-2b mampu mempertahankan skor yang tinggi hingga BLEU-4, bahkan mengungguli model BLIP yang sebelumnya menjadi standar pembandingan dengan selisih skor BLEU-4 sebesar 2,77%. Dominasi skor pada n-gram yang lebih tinggi ini menandakan bahwa model yang diusulkan memiliki kemampuan yang lebih baik dalam menyusun struktur kalimat yang panjang, koheren, dan kompleks secara semantik, serta lebih efektif dalam memahami konteks multimodal dibandingkan metode-metode sebelumnya.

4.1.4 Skenario 4: Pengujian *Tool Calling* MCP Supabase dan LLM AI Agent

Pada skenario 4 ini dilakukan evaluasi kinerja integrasi sistem Agentic AI berbasis Model Context Protocol (MCP) menggunakan arsitektur Server-Client melalui MaiaRouter untuk menjalankan operasi *create table* pada Supabase via fungsi *apply_migration*. Berdasarkan hasil eksperimen yang dirangkum, model *maia/gemini-2.5-flash* menunjukkan performa paling responsif dengan waktu 7,6366 detik, diikuti oleh *anthropic/claude-haiku-4-5* pada 7,8118 detik. Sementara itu, model *openai/gpt-5-pro* mencatatkan waktu eksekusi paling lambat sebesar 93,9664 detik, namun model ini menunjukkan efisiensi logika yang menonjol dengan hanya memerlukan 1 kali rekursi untuk menyelesaikan tugas dibandingkan model lain seperti *openai/gpt-3.5-turbo* yang membutuhkan hingga 4 kali rekursi. Keberhasilan integrasi ini divalidasi oleh log sistem yang menunjukkan *output* {"success":true} pada pemanggilan *tool migrasi*, yang menandakan bahwa protokol komunikasi antara logika model AI melalui MCP Proxy ke *database* Supabase telah berjalan secara sinkron dan fungsional dalam lingkungan pengujian tersebut. Melihat performa response time terbaik diraih oleh *gemini-2.5 flash*, maka model ini akan dijadikan LLM untuk pengujian ReAct Agent berbasis RAG dan MCP pada pembahasan mengingat bahwa VLM tidak memiliki kemampuan *tool calling* untuk menjalankan command *npx* dari MCP.

Tabel 4. 6 Pengujian *Tool Calling* MCP Supabase dan LLM AI Agent

No.	Model	Response Time	Model Init	Agent Init	Total Latency	Recursions

1	gemini-2.5-flash	7.6366	0.0027	1.0551	8.6944	2
2	anthropic/claude-haiku-4-5	7.8118	0.0000	1.8911	9.7029	2
3	openai/gpt-4	10.6729	0.0010	1.1328	11.8067	2
4	anthropic/claude-3-7-sonnet-latest	11.2749	0.0000	1.0528	12.3277	2
5	openai/gpt-3.5-turbo	12.3800	0.0015	1.3799	13.7614	4
6	gemini-2.5-pro	12.7596	0.0005	1.0465	13.8066	2
7	gemini-3-pro-preview	13.1167	0.0000	0.9903	14.1070	2
8	moonshot/kimi-k2-0711-preview	17.4806	0.0016	1.2626	18.7448	3
9	moonshot/kimi-k2-thinking	31.0906	0.0000	1.1709	32.2615	2
10	openai/gpt-5-pro	93.9664	0.0000	0.9815	94.9479	1

4.1.5 Skenario 5: Pengujian Dataset Kampus Indoor

Berdasarkan rekapitulasi pada Tabel 4.7, integrasi mekanisme *Retrieval-Augmented Generation* (RAG) dan *Model Context Protocol* (MCP) terbukti meningkatkan performa agen secara signifikan dibandingkan model *baseline*. Pengujian pada lingkungan *indoor* ini memberikan tantangan tersendiri berupa densitas objek yang tinggi dalam ruang terbatas. Peningkatan skor B-1 tertinggi yang dicapai oleh arsitektur VLM+RAG sebesar 52,79% menunjukkan efektivitas RAG dalam mengidentifikasi kata kunci objek (*unigram*) secara tepat. Melalui dokumen referensi, agen mampu mengenali atribut spesifik gedung, seperti nama laboratorium dan jenis perangkat komputer, yang sebelumnya sulit dideteksi hanya melalui fitur visual mentah. Selain itu, capaian skor B-4 tertinggi pada agen VLM+RAG+MCP sebesar 8,76% merepresentasikan keunggulan struktural dalam menyusun urutan kalimat yang lebih stabil dan faktual. Keunggulan tersebut merupakan hasil dari validasi data riil dari SQL Supabase yang diakses melalui protokol MCP, sehingga memastikan hubungan antar-objek, seperti status meja atau keberadaan instruktur, tetap akurat.

Tabel 4. 7 Rata-rata Skor Akurasi NLP dan Latensi Pengujian Agen Terhadap Dataset Kampus Indoor

No	Agent	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)	Total Latency
1	VLM	36.74	20.39	11.80	7.370	25.99	9.15
2	VLM+RAG	52.79	29.96	15.95	8.630	36.45	17.06
3	VLM+RAG+MCP	49.49	26.75	15.40	8.760	33.45	25.57

Secara teknis, penggunaan presisi *bfloat16* pada arsitektur model memastikan pemetaan fitur visual dari CLIP ke Gemma-2 melalui *MyAdaptor* tetap konsisten, terutama dalam mengenali atribut fisik pada pencahayaan *indoor*. Fenomena rendahnya skor metrik secara kumulatif (di bawah 15% untuk B-4) dipengaruhi oleh parameter generasi model, seperti *Beam Search* (num_beams=5) dan *repetition penalty* (1,5), yang mendorong model menghasilkan deskripsi lebih natural namun menjauhi kekakuan urutan kata pada *Ground Truth*. Meskipun kecenderungan deskripsi yang sangat detail (*prolixity*) pada agen MCP menurunkan nilai *overlap* matematis, secara kualitatif informasi yang dihasilkan jauh lebih akurat dan informatif. Sebagai kesimpulan, arsitektur VLM+RAG+MCP merupakan model yang paling handal dalam meminimalisir halusinasi visual di lingkungan kampus *indoor*.

4.1.6 Skenario 6: Pengujian Dataset Kampus Outdoor

Skenario 6 mengevaluasi kemampuan agen dalam mengenali lingkungan luar ruangan yang memiliki cakupan visual luas dan dipengaruhi oleh faktor pencahayaan alami. Hasil eksperimen pada Tabel 4.8 menunjukkan pola performa yang berbeda dibandingkan dengan skenario *indoor*, di mana arsitektur VLM+RAG mencatatkan skor B-4 tertinggi sebesar 11,17%. Pada area *outdoor*, pengenalan ciri khas bangunan, seperti bentuk atap limas atau variasi warna fasad gedung, sangat terbantu oleh deskripsi tekstual dalam RAG yang mengarahkan model untuk menyebutkan nama gedung secara presisi alih-alih sekadar menebak objek secara generik. Menariknya, pengujian *outdoor* mencatatkan latensi paling rendah dibandingkan skenario lainnya, yakni sebesar 2,63 detik pada VLM *baseline*. Secara teknis, hal ini disebabkan oleh fitur visual seperti langit dan jalan yang memiliki densitas informasi lebih rendah bagi enkoder CLIP, sehingga model dapat mencapai konvergensi jawaban dengan lebih cepat.

Tabel 4. 8 Rata-rata Skor Akurasi NLP dan Latensi Pengujian Agen Terhadap Dataset Kampus Outdoor

No	Agent	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)	Total Latency
1	VLM	29.40	13.92	7.41	4.34	21.53	2.63
2	VLM+RAG	50.29	29.60	17.95	11.17	34.93	9.68
3	VLM+RAG+MCP	37.75	20.53	11.52	6.75	27.26	12.08

Di sisi lain, terdapat kesenjangan metrik pada agen MCP di mana skor B-4 sebesar 6,75% berada di bawah RAG murni. *Insight* penelitian menunjukkan bahwa data MCP pada area luar ruangan seringkali berisi data koordinat atau ID aset yang bersifat sangat teknis. Karena *Ground Truth* ditulis dengan gaya deskripsi natural, terjadi *mismatch* matematis pada skor metrik. Meskipun demikian, informasi yang diberikan oleh agen MCP secara faktual jauh lebih kaya karena mampu menyebutkan detail marka jalan hingga tiang lampu secara spesifik yang tidak tercakup dalam deskripsi umum.

4.1.7 Skenario 7: Pengujian Dataset Trotoar Surabaya

Skenario terakhir menguji agen pada lingkungan jalanan publik yang padat dengan entitas komersial, marka jalan, dan aktivitas urban. Tabel 4.9 merangkum efektivitas agen dalam menangani kompleksitas Trotoar Surabaya, di mana ditemukan fenomena anomali efisiensi pada agen MCP. Latensi agen VLM+RAG+MCP tercatat sebesar 12,00 detik, yang secara signifikan lebih cepat dibandingkan VLM murni (15,17 detik) maupun VLM+RAG (18,12 detik). Hal ini mengindikasikan bahwa akses data riil melalui MCP mempercepat konvergensi pemikiran model AI. Dibandingkan harus melakukan proses "OCR visual" yang berat untuk membaca papan nama toko yang mungkin terdistorsi atau kabur, agen dapat langsung mengambil data valid dari database sehingga memperpendek durasi generasi teks secara keseluruhan.

Tabel 4. 9 Rata-rata Skor Akurasi NLP dan Latensi Pengujian Agen Terhadap Dataset Trotoar Surabaya

No	Agent	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)	Total Latency
1	VLM	28.97	11.82	6.59	3.97	19.19	15.17
2	VLM+RAG	51.33	29.30	16.74	9.82	29.24	18.12
3	VLM+RAG+MCP	47.32	27.41	13.94	7.64	28.21	12.00

Selain efisiensi waktu, identifikasi entitas urban juga mengalami peningkatan, di mana skor B-1 sebesar 51,33% pada VLM+RAG membuktikan bahwa RAG sangat krusial dalam mengenali nama-nama toko cagar budaya di Trotoar Surabaya yang sulit terbaca secara visual namun terdokumentasi dengan baik dalam basis data pengetahuan. Sebagai kesimpulan, meskipun VLM+RAG memiliki akurasi BLEU yang sedikit lebih tinggi, integrasi MCP menawarkan keseimbangan yang optimal antara kecepatan eksekusi dan kebenaran data database. Hal ini menjadikan arsitektur VLM+RAG+MCP sebagai model yang paling potensial untuk implementasi asisten navigasi cerdas di area perkotaan yang kompleks.

4.2 Pembahasan

Berdasarkan prosedur pengujian yang telah dilakukan terhadap 30 dataset gambar yang terbagi ke dalam tiga kategori lingkungan (10 kampus *indoor*, 10 kampus *outdoor*, dan 10 *street*), dilakukan evaluasi mendalam terhadap kinerja tiga arsitektur agen. Evaluasi ini bertujuan untuk menjawab tiga pertanyaan objektif utama, yakni identifikasi objek, jenis aktivitas, dan atribut fisik (warna/bentuk/jumlah). Secara umum, hasil pengujian menunjukkan bahwa integrasi mekanisme *Retrieval-Augmented Generation* (RAG) dan protokol *Model Context Protocol* (MCP) memberikan dampak signifikan terhadap peningkatan kualitas semantik dan akurasi faktual jawaban yang dihasilkan dibandingkan dengan model *baseline*. Berikut adalah analisis rinci untuk setiap skenario pengujian.

Pada skenario ini, integrasi *Model Context Protocol* (MCP) berperan krusial dalam menghubungkan agen dengan *database* Supabase yang menyimpan fakta terstruktur, sementara *Retrieval-Augmented Generation* (RAG) menyediakan referensi deskripsi visual yang serupa secara semantik. Penggunaan *Adaptor MLP* dengan presisi *bfloat16* memungkinkan proyeksi fitur gambar dari CLIP ke ruang embedding Gemma-2 dilakukan secara lebih halus, sehingga menghasilkan deskripsi yang lebih koheren dalam Bahasa Indonesia.

4.2.1 Pengujian Dataset Kampus Indoor

Pengujian pada kategori kampus *indoor* dilakukan untuk mengevaluasi kemampuan agen dalam mengenali objek, aktivitas, dan atribut fisik di dalam ruangan yang memiliki tantangan berupa variasi pencahayaan buatan dan kepadatan objek. Dataset ini mencakup area fungsional kampus seperti ruang kelas, laboratorium, lorong departemen, hingga area kantin (*food corner*).

Tabel 4. 10 Perbandingan *captioning agent* pada dataset *kampus indoor* berdasarkan pertanyaan pertama (tiga tertinggi)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 Sebuah layar LG menampilkan logo Lifes Good, siap untuk	VLM: Gambar ini menampilkan logo Lifes a Journey, Not a Destination dan logo LG.	45.24	36.94	25.22	14.64	27.27
	VLM+RAG:	50.00	36.51	27.06	14.20	50.00

Ground Truth	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
memfasilitasi presentasi dan pembelajaran interaktif. - Layar LG ini siap mendukung presentasi dan pembelajaran interaktif dengan kualitas tinggi. - Dengan logo Lifes Good, layar ini menciptakan suasana positif dalam setiap sesi. - Sebuah layar televisi yang cukup besar menampilkan logo LG Lifes is Good - Di depan tampak layar televisi besar bertuliskan LG Lifes Good sementara komputer kecil tampak di belakang	Layar televisi LG besar menjadi fokus utama gambar. Di layar tersebut terdapat logo LG Lifes good. VLM+RAG+MCP: Di bagian depan layar televisi besar merek LG terdapat logo Lifes Good. Layar tampak hitam.					
		64.29	54.47	46.60	36.62	57.14
 - Tiga mahasiswa berpose ceria di depan papan nama Departemen Teknik Informatika, menunjukkan semangat dan kebersamaan. - Tiga orang mahasiswa berpose ceria di depan papan nama Departemen Teknik Informatika - Kebersamaan mereka di depan papan nama menunjukkan rasa bangga terhadap fakultas. - Tiga orang pria duduk di depan papan nama Departemen Teknik Informatika - Beberapa orang terlihat berdiri di depan papan bertuliskan DEPARTEMEN TEKNIK INFORMATIKA	VLM: Objek utama dalam gambar tersebut adalah tiga mahasiswa sedang pose ceria di depan papan nama Departemen Teknologi Informasi. VLM+RAG: Ada tiga mahasiswa pria yang sedang berpose di depan sebuah papan nama berwarna putih dan biru bertuliskan Departemen Teknik Informatika. VLM+RAG+MCP: Ada tiga mahasiswa pria sedang berposesi ceria. Mereka berdiri di depan sebuah papan nama berwarna putih dengan tulisan Departemen Teknik Informatika.	66.67	60.30	52.93	46.92	66.67
		57.89	35.87	13.33	6.73	54.55
		61.90	43.09	27.29	13.48	58.82
	VLM: Terdapat meja, kursi, jendela, dan beberapa poster/spanduk. VLM+RAG: Gambar tersebut	21.73	19.44	16.17	10.16	33.33
		65.00	45.31	22.85	11.91	41.18

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Area dengan meja kayu, lemari pendingin berisi minuman, dan poster informasi di dinding bata. • Terdapat lemari pendingin berisi minuman di dekat dinding bata merah. Sebuah meja dengan dua kursi berada di sampingnya • kulkas yang berisi berbagai macam minuman terletak di pojok ruangan • Dua buah kulkas minuman, sebuah meja, dan banner ITS PRESS di dekat dinding bata • Di depan kiri terdapat meja dan kursi sementara kulkas berada di dekatnya	menunjukkan area penyimpanan minuman dengan tiga kulkas pendingin, sebuah meja kayu bertangga dua kursi, dan banner ITS Press. VLM+RAG+MCP: Di latar depan terdapat sebuah area penyimpanan minuman dengan tiga lemari Pendingin minuman berdiri cantik. Di sebelahnya terdapat meja kayu yang sederhana dengan dua buah kursi berdampingan. Banner ITS PRESS menghiasi area tersebut.	58.06	39.35	22.36	10.70	32.65

Analisis pada Tabel 4.10 menunjukkan lonjakan skor B-4 yang sangat signifikan pada arsitektur VLM+RAG+MCP, terutama pada identifikasi layar LG yang mencapai 36.62%, jauh melampaui VLM *baseline* (14.64%). Secara teknis, peningkatan akurasi pada level 4-gram ini didorong oleh integrasi protokol MCP melalui fungsi `_fetch_mcp_enrichment` pada port 10399. Dengan menarik data *string* presisi seperti "LG Lives Good" langsung dari database SQL, agen mampu menyusun frasa yang identik dengan *Ground Truth*. Penggunaan `num_beams=5` pada kode `custom_vlm_model.py` membantu model dalam melakukan pencarian sekuensial yang lebih stabil, sehingga menghasilkan urutan kata yang koheren dan memiliki kecocokan tinggi pada level n-gram yang lebih panjang.

Tabel 4. 11 Perbandingan *captioning agent* pada dataset kampus *indoor* berdasarkan pertanyaan pertama (tiga terendah)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Peserta belajar tentang daur ulang di ruang komputer, dengan instruktur memberikan penjelasan interaktif di depan layar. • Peserta belajar tentang daur ulang dengan instruktur yang memberikan penjelasan interaktif di ruang komputer. • Lingkungan yang interaktif ini mendorong keterlibatan peserta	VLM: Gambar menggambarkan orang- orang yang sedang duduk di dekat komputer dan ada jarak antara mereka dengan orang yang berdiri di depannya. VLM+RAG: Pada bagian depan tampak beberapa peserta belajar yang berdiri sambil memperhatikan display komputer yang dimonitor. Ada juga	61.11	37.92	21.12	11.47	30.30
		47.83	32.97	17.60	9.49	31.58

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
dalam diskusi mengenai daur ulang. - Beberapa orang berdiri di antara orang-orang yang sedang mengerjakan sesuatu menggunakan komputer - Di depan terlihat beberapa orang sedang berdiri di sekitar orang-orang yang duduk di dekat monitor	beberapa orang lain yang duduk di sekitar. VLM+RAG+MCP: Di depan tampak beberapa peserta didik berdiri berdampingan dengan beberapa instruktur. Terlihat juga beragam perangkat komputer dengan berbagai ukuran dan bentuk yang digunakan sebagai media pembelajaran. Layar pada komputers tersebut menunjukkan konten interaktif terkait program daur ulang. Ada beberapa peserta yang duduk sambil mengikuti penjelasan instruktur mengenai topik daur ulang, di mana sebagian peserta lain berdiri mengelilingi komputer.	32.73	15.57	5.85	2.90	20.29
	VLM: Di bagian depan terlihat ruang belajar yang modern dengan peralatan dan kursi yang memadai.	69.23	41.60	16.22	8.48	35.71
 - Suasana kelas yang dinamis, di mana mahasiswa berinteraksi sambil mendalami materi yang ditampilkan di layar besar. - Suasana kelas yang dinamis ini menciptakan lingkungan yang mendukung interaksi dan kolaborasi. - Mahasiswa berinteraksi aktif saat mendalami materi yang ditampilkan, menciptakan pengalaman belajar yang menarik. - Banyak orang duduk di kursi yang disusun berbaris dan sebuah televisi menyala di depan ruangan - Di depan terlihat kerumunan orang yang sedang duduk di kursi dengan banyak meja di dekatnya	VLM+RAG: Gambar tersebut memperlihatkan kerumunan mahasiswa yang sedang duduk bersila berurutan di ruang belajar.	61.54	32.03	21.38	12.44	35.71
	VLM+RAG+MCP: Di bagian latar depan terdapat kerumunan mahasiswi dan mahasiswa yang duduk bersila di baris.	53.85	10.73	5.27	3.05	42.86
 Wastafel dengan tanda Dilarang Bersandar yang jelas, dikelilingi	VLM: Di latar depan poster tersebut terdapat wastafel yang memiliki keran pada sisi depannya.	53.85	29.96	20.46	12.03	33.33
	VLM+RAG: Wastafel warna putih yang dipasangkan di dinding. Ada poster peringatan "Dilarang	61.54	32.03	13.64	7.44	41.67

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
dinding berwarna abu-abu dan garis ku	BERSANDAR” diatasnya.					
- Wastafel dikelilingi dinding abu-abu dengan tanda Dilarang Bersandar yang terlihat jelas. - wastafel berwarna putih dengan tulisan dilarang bersandar yang tertempel di dinding - Wastafel yang memiliki keterangan Dilarang Bersandar dan tanda silang berwarna kuning - Terdapat sebuah wastafel di depan sementara poster bertuliskan dilarang bersandar terdapat di atas nya	VLM+RAG+MCP: Wastafel merupakan objek utama yang tampak di bagian depan. Warnanya putih dan terdapat tulisan peringatan DILARANG BERSANDAR. Ada juga beberapa kursi yang terletak di sekitarnya.	43.48	14.06	6.84	3.90	41.18

Pada Tabel 4.11, terlihat penurunan drastis skor B-4 pada agen MCP hingga menyentuh 2.90% pada citra "Daur Ulang". Secara teknis, rendahnya skor B-4 ini merupakan efek samping dari strategi augmentasi konteks pada agent_boilerplate.py. Meskipun agen berhasil menarik fakta akurat mengenai instruktur dan perangkat komputer, informasi tersebut disusun menjadi paragraf yang sangat panjang (*prolixity*). Karena metrik BLEU-4 memberikan penalti besar terhadap ketidakseimbangan panjang (*brevity penalty*) dan memerlukan kecocokan urutan empat kata yang eksak, deskripsi agen yang terlalu naratif dan mendetail gagal mencocokkan struktur kalimat *Ground Truth* yang ringkas, meskipun secara kualitatif informasi tersebut lebih inklusif bagi pengguna.

Tabel 4. 12 Perbandingan captioning agent pada dataset kampus indoor berdasarkan pertanyaan kedua (tiga tertinggi)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 - Tiga mahasiswa berpose ceria di depan papan nama Departemen Teknik Informatika, menunjukkan semangat dan kebersamaan. - Tiga orang mahasiswa berpose ceria di depan papan nama Departemen Teknik Informatika	VLM: Objek-objek utama dalam foto ini melakukan kegiatan berpose ceria di depan sebuah papan nama.	35.71	23.44	10.89	6.17	38.46
	VLM+RAG: Tiga mahasiswa pria sedang pose ceria dan menunjukkan semangat serta kebersamaannya di depan sebuah papan nama.	66.67	43.64	16.13	8.18	50.00
	VLM+RAG+MCP: Mahasiswa-mahasiswa itu mengenakan pakaian rapi. Mereka berdiri di depan sebuah papan nama dengan tulisan DEPARTEMEN TEKNIK INFORMATIKA.	52.94	40.67	28.40	14.54	50.00

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
- Kebersamaan mereka di depan papan nama menunjukkan rasa bangga terhadap fakultas. - Tiga orang pria duduk di depan papan nama Departemen Teknik Informatika - Beberapa orang terlihat berdiri di depan papan bertuliskan DEPARTEMEN TEKNIK INFORMATIKA						
 - Area dengan meja kayu, lemari pendingin berisi minuman, dan poster informasi di dinding bata. - Terdapat lemari pendingin berisi minuman di dekat dinding bata merah. Sebuah meja dengan dua kursi berada di sampingnya 3 kulkas yang berisi berbagai macam minuman terletak di pojok ruangan - Dua buah kulkas minuman, sebuah meja, dan banner ITS PRESS di dekat dinding bata 5. Di depan kiri terdapat meja dan kursi sementara kulkas berada di dekatnya	VLM: Orang atau pengunjung yang beraktivitas seperti bekerja, belajar membaca informasi.	18.10	6.47	3.91	2.52	9.52
	VLM+RAG: Ada tiga lemari es minuman, satu meja kayu yang dilengkapi dua kursi, serta banner ITS Press.	62.50	40.82	23.17	12.62	40.00
	VLM+RAG+MCP: Dinding ruangan berwarna merah bata. Di area tersebut terdapat tiga lemari pendingin minuman. Di sebelah lemari-lemari tersebut terdapat banner ITS PRESS.	66.67	40.82	26.34	13.12	34.29
 - Sebuah layar LG menampilkan logo Lifes Good, siap untuk memfasilitasi presentasi dan pembelajaran interaktif. - Layar LG ini siap mendukung presentasi dan pembelajaran interaktif dengan kualitas tinggi. - Dengan logo Lifes Good, layar ini menciptakan suasana positif dalam setiap sesi. 4. Sebuah layar televisi yang cukup besar menampilkan logo LG Lifes is Good 5. Di depan tampak layar televisi besar bertuliskan LG Lifes Good sementara komputer kecil tampak di belakang	VLM: Gambar ini menampilkan layar besar yang berisi logo lifes journey, not a destination, dan logo LG.	61.54	32.03	13.64	7.44	32.00
	VLM+RAG: Layar televisi LG besar menampilkan logos Lifes Good dan LG. Layarnya kemungkinan digunakan untuk presentasi.	64.29	38.52	15.12	7.91	59.26
	VLM+RAG+MCP: Layar televisi LG yang cukup besar itu menayangkan tulisan Lifes good. Perangkat tersebut digunakan untuk presentasi.	62.50	40.82	23.17	12.62	50.00

Analisis pada Tabel 4.12 menunjukkan efektivitas RAG dalam meningkatkan skor B-4, seperti pada objek papan nama departemen yang mencapai 14.54%. Secara teknis, fungsi `_maybe_handle_multimodal_and_augment` pada kode sumber berperan penting dalam menyuntikkan "nuansa" aktivitas ke dalam *prompt*. Dengan menggabungkan deteksi subjek manusia dari CLIP dan data lokasi dari RAG, model Gemma-2 dapat menyusun frasa aktivitas yang kompleks seperti "berdiri di depan sebuah papan nama". Skor B-4 yang stabil menunjukkan bahwa sistem tidak hanya mengenali kata per kata, tetapi juga berhasil menyusun penalaran (*reasoning*) aktivitas yang strukturnya selaras dengan pola deskripsi manusia.

Tabel 4. 13 Perbandingan *captioning agent* pada dataset kampus *indoor* berdasarkan pertanyaan kedua (tiga terendah)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Peserta belajar tentang daur ulang di ruang komputer, dengan instruktur memberikan penjelasan interaktif di depan layar. • Peserta belajar tentang daur ulang dengan instruktur yang memberikan penjelasan interaktif di ruang komputer. • Lingkungan yang interaktif ini mendorong keterlibatan peserta dalam diskusi mengenai daur ulang. • Beberapa orang berdiri di antara orang-orang yang sedang mengerjakan sesuatu menggunakan komputer • Di depan terlihat beberapa orang sedang berdiri di sekitar orang-orang yang duduk di dekat monitor	VLM: Orang-orang itu mungkin melakukan aktivitas seperti bekerja atau belajar komputer.	24.56	7.17	4.05	2.53	18.18
	VLM+RAG: Peserta belajar mengenai daur ulang melalui penjelasan dari instruktur di ruang komputer. Beberapa peserta berdiri di sekeliling komputer, sedangkan sebagian lainnya duduk sambil memperhatikan. Layar komputer bersinar di tengah aktivitas pembelajaran.	54.84	33.12	19.95	9.81	38.30
	VLM+RAG+MCP: Di depan tampak beberapa peserta didik berdiri sambil memperhatikan instruksi dari instruktur di belakang mereka. Instruktur menyampaikan materi tentang daur ulang melalui penggunaan monitor komputer sebagai alat pembelajaran interaktif. Beberapa orang lain duduk di meja atau kursi-kursi di sekeliling mereka. Layar display pada komputer menampilkan konten edukatif tentang daur ulang.	34.69	19.01	9.38	5.05	24.62

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Sekelompok pria berkumpul membaca Al-Qur'an, dikelilingi suasana tenang dengan pemandangan luar yang hijau. • Sekelompok pria berkumpul membaca Al-Qur'an, menciptakan suasana tenang dan penuh kedamaian. • Kehadiran pemandangan hijau di sekitar menambah ketenangan saat mereka bermunajat. • Beberapa pria berkumpul sambil membaca kitab suci yang diletakkan di atas meja • Beberapa orang sedang membaca al-quran di atas meja kecil dengan duduk melingkar	VLM: Berdasarkan gambar, aktivitas yang dilakukan kelompok pria tersebut adalah membacakan Al-quran.	36.36	19.07	10.13	6.17	34.78
	VLM+RAG: Objek-objek yang terlihat adalah sekumpulan pria sedang membaca Al Qur'an. Pemandangannya tampak hijau dari luar ruangan.	40.00	16.90	8.62	5.09	26.67
	VLM+RAG+MCP: Aktivitas yang dilakukan oleh subjek tersebut adalah membaca Al-Qur'an. Mereka berkonsentrasi dan membaca dengan penuh perhatian.	40.00	16.90	8.62	5.09	23.08
 • Wastafel dengan tanda Dilarang Bersandar yang jelas, dikelilingi dinding berwarna abu-abu dan garis ku • Wastafel dikelilingi dinding abu-abu dengan tanda Dilarang Bersandar yang terlihat jelas. • wastafel berwarna putih dengan tulisan dilarang bersandar yang tertempel di dinding • Wastafel yang memiliki keterangan Dilarang Bersandar dan tanda silang berwarna kuning • Terdapat sebuah wastafel di depan sementara poster bertuliskan dilarang bersandar terdapat di atas nya	VLM: Objek/subyek dalam gambar tersebut melakukan kegiatan mencantumkan larangan untuk berdiri.	0.00	0.00	0.00	0.00	0.00
	VLM+RAG: Wastafel itu terbuat dari bahan putih dan berfungsi sebagai fasilitas kebersihan di dinding ruangan. Ada tulisan Dilarang Bersanda pada wastafel tersebut, serta ada poster peringatan di sebelahnya. Terlihat juga beberapa kursi, meja, dan lainnya berada di sekitarnya.	28.57	15.88	9.36	5.40	26.09
	VLM+RAG+MCP: Berdasarkan gambar, wastafel tersebut adalah bagian dari fasilitas kebersihan di dinding berwarna abu- Abu. Wastafel tersebut terbuat dari material putih dan terdapat tulisan Dilarang bersandar di dekat wastafel itu. Ada juga beberapa kursi, meja dan mungkin petugas membersihkan ruangan sekitar wastafel.	25.64	16.43	9.22	5.22	28.00

Tabel 4.13 menyoroti rendahnya skor B-4 pada citra dengan aktivitas yang melibatkan banyak interaksi, seperti "Daur Ulang" (5.05%). Secara teknis, rendahnya skor B-4 ini dipicu

oleh tantangan sinkronisasi atribut aktivitas pada pemandangan yang padat (*crowded scene*). Implementasi $\text{repetition_penalty}=1.5$ pada model kustom terkadang membuat agen cenderung menghindari pengulangan struktur kalimat yang sederhana, sehingga urutan 4-gram yang dihasilkan menjadi terlalu bervariasi dan menjauh dari referensi kaku *Ground Truth*. Kegagalan total (0.00%) pada VLM *baseline* di citra wastafel membuktikan bahwa tanpa dukungan data fakta dari MCP/RAG, model cenderung berhalusinasi dalam menyusun urutan kata aktivitas.

Tabel 4. 14 Perbandingan *captioning agent* pada dataset kampus *indoor* berdasarkan pertanyaan ketiga (tiga tertinggi)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 - Wastafel dengan tanda Dilarang Bersandar yang jelas, dikelilingi dinding berwarna abu-abu dan garis ku - Wastafel dikelilingi dinding abu-abu dengan tanda Dilarang Bersandar yang terlihat jelas. - wastafel berwarna putih dengan tulisan dilarang bersandar yang tertempel di dinding - Wastafel yang memiliki keterangan Dilarang Bersandar dan tanda silang berwarna kuning - Terdapat sebuah wastafel di depan sementara poster bertuliskan dilarang bersandar terdapat di atas nya	VLM: Poster berwarna putih dan ukuran cukup besar. Selain putih, poster juga menggunakan garis horizontal untuk penyeimbang sehingga nuansa lebih tenang.	21.05	10.81	6.04	3.69	13.33
	VLM+RAG: Wastafel berwarna putih. Terdapat poster peringatan Dilarang bersanda di atas wastafel. Di sekitar wastafel ada beberapa kursi serta meja. Ada 1 buah wastafel putih. 1 poster peringatan dan banyak kursi dan meja.	35.71	25.72	13.93	7.63	30.77
	VLM+RAG+MCP: Warna wastafel adalah putih. Terdapat tulisan Dilarang Bersandar di wastafel. Selain itu, terdapat satu Poster bergambar tanda silang berwarna kuning. Ada juga beberapa kursi, dan meja di sekitar wastafel tersebut.	44.83	28.29	21.05	13.60	35.90
 - Sekelompok pria berkumpul membaca Al-Qur'an, dikelilingi suasana tenang dengan pemandangan luar yang hijau. - Sekelompok pria berkumpul membaca Al-Qur'an, menciptakan suasana tenang dan penuh kedamaian.	VLM: Pada gambar tersebut terlihat sekumpulan pria sedang fokus dalam bacaan Al Qur'an. Warna putih baju muslim tradisional.	11.76	4.56	2.80	1.78	13.79
	VLM+RAG: Dalam gambar tersebut terdapat sekumpulan pria, Al-Qur'an, serta meja kecil. Objek berwarna hijau karena pemandangan luarnya.	43.75	24.15	10.73	5.92	32.26

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
• Kehadiran pemandangan hijau di sekitar menambah ketenangan saat mereka bermunajat. • Beberapa pria berkumpul sambil membaca kitab suci yang diletakkan di atas meja • Beberapa orang sedang membaca al-quran di atas meja kecil dengan duduk melingkar	VLM+RAG+MCP: Objek yang terlihat adalah sekumpulan pria yang sedang beraktivitas baca Al-Quran. Mereka duduk berdampingan pada meja kecil dengan tampilan suasana tenang.	52.38	28.03	16.35	9.15	30.30
 • Sebuah layar LG menampilkan logo Lifes Good, siap untuk memfasilitasi presentasi dan pembelajaran interaktif. • Layar LG ini siap mendukung presentasi dan pembelajaran interaktif dengan kualitas tinggi. • Dengan logo Lifes Good, layar ini menciptakan suasana positif dalam setiap sesi. 4. Sebuah layar televisi yang cukup besar menampilkan logo LG Lifes is Good 5. Di depan tampak layar televisi besar bertuliskan LG Lifes Good sementara komputer kecil tampak di belakang	VLM: Gambar ini menampilkan sebuah layar besar. Di layar tersebut terdapat logo Lifes a journey not a Destination.	53.33	27.60	11.92	6.51	37.04
	VLM+RAG: Gambar ini menunjukkan sebuah layar televisi besar merek LG. Di bagian tengahnya tertulis logo LG Lifes Good.	58.82	46.97	39.26	18.57	55.17
	VLM+RAG+MCP: Layar televisi LG ukuran besar itu hitam. Di layar tersebut tertulis LG Lifes Good. Ada satu unit TV yang sangat besar.	38.10	23.90	14.72	8.45	36.36

Pada pengujian atribut fisik (Tabel 4.14), agen MCP menunjukkan keunggulan pada metrik B-4, khususnya pada atribut wastafel yang mencapai 13.60%. Hal ini secara teknis dimungkinkan karena informasi atribut seperti warna "putih" dan tanda "silang kuning" ditarik secara terstruktur dari kolom facts di database Supabase melalui protokol MCP. Keberadaan data fakta yang pasti ini memungkinkan model untuk menyusun frasa deskriptif atribut yang konsisten (misalnya: "tanda silang berwarna kuning"). Konsistensi urutan kata yang ditarik dari data terstruktur ini secara otomatis meningkatkan peluang kecocokan n-gram level 4, dibandingkan jika model hanya mengandalkan persepsi visual yang seringkali bias oleh pencahayaan ruangan.

Tabel 4. 15 Perbandingan *captioning agent* pada dataset *kampus indoor* berdasarkan pertanyaan ketiga (tiga terendah)

Ground Truth	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Dua wanita duduk di lantai, berbagi informasi di ponsel, dikelilingi suasana tenang dengan barang-barang di sekitarnya. • Dua wanita duduk di lantai, berbagi informasi di ponsel dalam suasana tenang dan akrab. • Kehangatan interaksi mereka menciptakan momen yang menyenangkan di lingkungan yang nyaman. • Dua orang perempuan duduk berhadapan di atas karpet sambil membuka ponsel • Terlihat beberapa orang duduk di atas karpet hijau dengan beberapa mukena di kiri serta kipas angin jauh di kanan	VLM: Ada dua wanita sedang berbincang santai di dekat sebuah jendela. Satu dari mereka duduk di kursi.	37.50	22.36	10.20	5.70	29.63
	VLM+RAG: Ada dua wanita duduk saling berhadapan di lantai. Kedua wanita terlihat sedang berbicara. Mereka mengenakan pakaian formal seperti mukena.	42.11	26.49	16.34	9.34	31.25
	VLM+RAG+MCP: Dua wanita sedang duduk berdampingan di sebuah ruangan dengan karpet berwarna hijau. Perempuan di sebelah kiri mengenakan mukena.	52.55	17.10	8.13	4.62	35.29
 • Suasana kelas yang dinamis, di mana mahasiswa berinteraksi sambil mendalami materi yang ditampilkan di layar besar. • Suasana kelas yang dinamis ini menciptakan lingkungan yang mendukung interaksi dan kolaborasi. • Mahasiswa berinteraksi aktif saat mendalami materi yang ditampilkan, menciptakan pengalaman belajar yang menarik. • Banyak orang duduk di kursi yang disusun berbaris dan sebuah televisi menyala di depan ruangan • Di depan terlihat kerumunan orang yang sedang duduk di kursi dengan banyak meja di dekatnya	VLM: Ruang belajar modern di dalamnya memamerkan peralatan canggih yang lengkap dan kursi ergonomic.	41.67	9.70	5.04	3.00	22.22
	VLM+RAG: Ruang belajar ini ramai diisi oleh kerumunan mahasisi duduk bersila berjejer.	54.55	11.44	5.75	3.38	15.38
	VLM+RAG+MCP: Ruang belajar ini tampak ramai dengan kerumunan banyak mahasiswa yang duduk rapi di kursi berwarna abu-abu.	73.33	22.89	10.53	5.92	33.33
	VLM:	18.18	13.48	8.06	5.19	17.39

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Tiga mahasiswa berpose ceria di depan papan nama Departemen Teknik Informatika, menunjukkan semangat dan kebersamaan. • Tiga orang mahasiswa berpose ceria di depan papan nama Departemen Teknik Informatika • Kebersamaan mereka di depan papan nama menunjukkan rasa bangga terhadap fakultas. • Tiga orang pria duduk di depan papan nama Departemen Teknik Informatika • Beberapa orang terlihat berdiri di depan papan bertuliskan DEPARTEMEN TEKNIK INFORMATIKA	Berdasarkan gambar tersebut, objek utama berupa tiga mahasiswa. Warna dominan cerah.					
	VLM+RAG: Ada tiga mahasiswa pria. Mereka sedang berada di depan sebuah papan nama berwarna putih dan biru bertuliskan Departemen Teknologi Informasi.	52.63	34.20	12.92	6.57	50.00
	VLM+RAG+MCP: Warna dominan pada papan nama adalah putih dan biru. Ada tiga mahasiswa pria yang berpose ceria.	40.00	23.90	10.84	6.05	21.43

Tabel 4.15 menunjukkan tantangan metrik B-4 pada citra yang sangat padat, di mana skor menyusut hingga 4.62% dan 5.92%. Meskipun skor B-1 (kata tunggal) sangat tinggi karena agen berhasil mengenali banyak objek (seperti kursi "abu-abu"), skor B-4 tetap rendah. Secara teknis, hal ini mengindikasikan bahwa meskipun fakta fisik berhasil ditarik melalui MCP, penyusunan urutan kata untuk menjelaskan banyak atribut sekaligus menciptakan variasi linguistik yang sangat tinggi. Perbedaan urutan penyebutan atribut antara prediksi agen dan *Ground Truth* menyebabkan kegagalan pencocokan 4-gram, menegaskan bahwa pada lingkungan *indoor* yang padat, tantangan utama bukan lagi pada akurasi deteksi, melainkan pada standarisasi struktur narasi deskriptif.

4.2.2 Pengujian Dataset Kampus *Outdoor*

Pengujian pada kategori kampus *outdoor* dilakukan untuk mengevaluasi kemampuan agen dalam mengenali objek, aktivitas, dan atribut fisik di lingkungan luar ruangan yang memiliki tantangan unik berupa fluktuasi pencahayaan alami (sinar matahari), kepadatan vegetasi, serta skala area terbuka yang lebih luas. Dataset ini mencakup berbagai titik ikonik dan fungsional di lingkungan luar departemen, mulai dari gerbang masuk (*entry gate*), taman hijau, lapangan olahraga atau plaza, monumen identitas, hingga jalur pejalan kaki dan fasad gedung departemen.

Tabel 4. 16 Perbandingan *captioning agent* pada dataset kampus *outdoor* berdasarkan pertanyaan pertama (tiga tertinggi)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 - Seorang pengendara motor berhenti di dekat tulisan "ENTER", dikelilingi taman hijau yang rimbun dan segar. - Seorang pengendara motor di dekat tulisan "ENTER", dikelilingi oleh taman hijau - Di taman hijau yang rimbun, seorang pengendara motor berhenti di dekat tulisan "ENTER" yang mencolok. - Seseorang mengendarai sepeda motor saat senja di jalan yang memiliki pohon dan tanaman hias - Di depan terdapat seorang pengendara motor yang melintas di jalan paving sementara jauh di depan kanan terdapat tulisan "Enter"	VLM: Pengendara sepeda motor yang berhenti di dekat pintu masuk dengan tulis "Enter", disertai pepohon hijau.	66.67	48.80	26.71	14.26	55.17
	VLM+RAG: Dalam foto tersebut tampak seorang pria yang sedang mengendarai sepeda motor. Ia berada di dekat sebuah papan penanda bertulis "ENTER". Papan penanda itu dikelilingi oleh pohon-pohon hijau yang rimbun.	42.86	28.17	18.59	9.50	38.10
	VLM+RAG+MCP: Di latar depan terdapat seorang pria yang sedang mengendarai sepeda motor. Di sampingnya terdapat papan petinformati bertulis "ENTER" yang berada di tengah-tengah taman yang luas dan rimbun berwarna hijau.	57.14	35.63	21.71	10.68	34.04
 - Peralatan kebersihan bersandar di dinding, siap menjaga keindahan area hijau di sekitarnya. - Peralatan kebersihan yang bersandar di dinding siap menjaga keindahan area hijau di sekitarnya. - Kesiapan peralatan kebersihan ini mencerminkan komitmen terhadap kebersihan dan kerapian. - Ada sapu dan serokan bersandar di dinding yang ada di sekitar taman - Sapu dan cikrak terlihat bersandar pada tembok kanan sementara tembok batu tampak di kiri	VLM: Dalam gambar tersebut terdapat tanaman-tanaman hijau yang tumbuh merata di area tersebut, memberikan kesan segar dan tenang.	25.00	6.80	3.70	2.22	20.69
	VLM+RAG: Yang terlihat di depan adalah sapu, serta serokan.	77.78	44.10	30.65	17.86	38.10
	VLM+RAG+MCP: Di latar depan tampak peralatan kebersihan seperti sapu dan serokan yang bersandar di dinding taman. Sapunya terbuat dari kayu dan memiliki gagangnya berwarna coklat gelap. Serokannya juga terbuat dari logam, berbentuk cirkel kecil berwarna abu-abu. Dinding taman di sekitarnya tampak sederhana terbuat dari batu bata.	30.95	22.99	16.12	10.04	29.63

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Sebuah papan nama jalan "Jl. T. Komputer IV" dikelilingi pepohonan hijau, suasana asri dan tenang. • Papan nama jalan "Jl. T. Komputer IV" dikelilingi oleh pepohonan hijau • Suasana asri dan tenang terlihat pada papan nama jalan "Jl. T. Komputer IV" yang dikelilingi pepohonan hijau. • Sebuah papan nama jalan "Jl. T. Komputer IV" yang ada di dekat tiang listrik dan di lingkungan yang banyak pepohonan • Papan nama jalan "Jl. T. Komputer IV" terlihat di atas tiang dengan pepohonan hijau mengelilingi di sekitarnya	VLM: Di latar depan terlihat papan penanda jalan dengan angka '10' ditulis di atas. Terdapat juga banyak pohon hijau mengelilinginya.	57.89	35.87	19.96	10.86	40.00
	VLM+RAG: Di latar depan tampak papan nama jalan "Jl. T. Komputer IV" yang terbuat dari bahan putih, berdiri tegak di samping pohon-pohon yang hijau.	52.38	39.64	34.95	30.96	46.15
	VLM+RAG+MCP: Di pojok kiri terdapat papan nama jalan berwarna putih dengan tulisan "Jl. T. Komputer IV". Terdapat pohon-pohon hijau yang rindang mengelilinginya.	50.00	22.94	14.58	8.47	40.00

Analisis pada Tabel 4.16 menunjukkan bahwa skor BLEU-4 tertinggi dicapai oleh model *baseline* (14.26%), namun agen VLM+RAG+MCP tetap mempertahankan skor yang kompetitif (10.68%). Secara teknis, skor B-4 yang stabil pada agen MCP didorong oleh penggunaan `num_beams=5` pada kode `custom_vlm_model.py` yang membantu model menyusun urutan 4-gram yang koheren. Meskipun agen MCP menarik data teks "ENTER" secara presisi melalui protokol MCP, skor B-4 sedikit tertekan dibandingkan *baseline* karena struktur kalimat agen cenderung lebih deskriptif ("papan petinformati bertulis...") dibandingkan struktur *Ground Truth* yang lebih ringkas. Hal ini menunjukkan bahwa sistem berhasil menyusun frasa teknis yang panjang, namun terdapat perbedaan gaya bahasa (stilistika) yang memengaruhi metrik B-4.

Tabel 4. 17 Perbandingan *captioining agent* pada dataset *kampus outdoor* berdasarkan pertanyaan pertama (tiga terendah)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
	VLM: Gambar menampilkan jalan setapak berbatu yang melintasi area taman.	31.85	7.92	4.25	2.61	27.27
	VLM+RAG: Latar belakang gambar adalah jalan setapan	57.14	33.81	18.50	10.04	30.30

Ground Truth	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 - Jalan setapak berbatu mengarah ke taman asri, dikelilingi pepohonan dan bangunan tradisional yang menawan. - Jalan berbatu ini mengarah ke taman asri yang dikelilingi pepohonan dan bangunan tradisional - Dengan suasana yang menawan, jalan setapak berbatu membawa Anda menuju taman asri yang dikelilingi oleh pepohonan. - Di bawah tangga masjid ada kotak-kotak untuk jalan setapak menuju bangunan putih - Beberapa rangkaian keramik mozaik tampak di depan hingga ke kanan depan sementara pohon besar dan bangunan berada di depan di kelilingi pepohonan	mozaik dengan beberapa pohon besar. Bangunan putih tradisional juga terlihat di sekitar jalan setapak tersebut. VLM+RAG+MCP: Di bagian depan tampak sebuah jalan setapak dengan keramik mozaik yang menarik perhatian. Ada beberapa pohon besar yang megah mengelilinginya, memberikan kesan tenang dan damai di lingkungan yang sepi. Terlihat juga bangunan putih yang klasik, sepertinya merupakan akses masuk ke kawasan tersebut.					
		40.00	17.54	6.87	3.49	19.23
 - Selamat datang di Plaza Prof Supeno Djanali, pusat kreativitas dan kolaborasi yang dikelilingi keindahan alam! - Selamat datang di Plaza Prof Supeno Djanali, tempat di mana kreativitas dan kolaborasi bersatu. - Keindahan alam yang mengelilingi plaza ini menambah inspirasi bagi setiap pengunjung.	VLM: Gambar ini menunjukkan sebuah lapangan luas yang dikelilingi oleh gedung modern. Suasana di sana tampak dinamik karena kombinasi antara ruang terbuka dan desain arsitekturnya yang menarik	20.83	9.52	5.23	3.15	16.67
	VLM+RAG: Pada latar depan tampak lapangan pematat paving berwarna abu-arduan, dilengkapi dengan net volley putih yang siap untuk dimainkan. Di sampingnya terdapat gedung bertulisan "PLAZA".	39.13	13.34	6.61	3.80	25.00

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
- Lapangan di sekitar Plasa Supeno yang di tengahnya ada net voli terbentang - Hamparan lahan paving dengan jaring-jaring voli terlihat di depan sementara bangunan besar bertuliskan "PLASA" berada di belakangnya	VLM+RAG+MCP: Di depan bangunan bertulisan "PLAZA", tampak lapangan berbentuk persegi panjang paved dengan warna abu-awab. Di bagian tengah lapangan terdapat sebuah net voli putih berwarna cerah. Gedung PLASA berdiri kokoh di samping lapangan. Suasana di sini terasa ramai karena adanya kegiatan olahraga seperti net voli.	34.15	18.48	7.06	3.55	26.42
 - Selamat datang di tempat inspirasi dan kreativitas, di mana setiap langkah membawa Anda menuju pengetahuan baru! - Selamat datang di tempat inspirasi dan kreativitas, di mana setiap langkah membawa peluang baru! - Lingkungan ini dirancang untuk memicu ide-ide dan inovasi yang bermanfaat. - Sebuah logo IF berwarna biru di sekitar Plasa Supeno - Monumen bertuliskan "IF" terlihat berada di lantai keramik depan	VLM: Gambar menunjukkan ruang terbuka yang luas dan indah dengan udara segar yang dapat dinikmati.	7.69	4.05	2.77	1.87	9.09
	VLM+RAG: Monumen bertuliskan "IF", berwarna biru, terletak di atas keramik pada ruang terbuka Plaza Supeno.	64.29	49.72	34.91	17.73	52.17
	VLM+RAG+MCP: Monumen berbentuk seperti huruf 'IF', warna biru dengan tulisan putih. Lantai keramik putih dominan di sekitar monumen tersebut.	38.89	21.39	9.61	5.31	29.63

Pada Tabel 4.17, terlihat penurunan drastis pada skor **B-4** agen MCP hingga menyentuh 3.49% dan 3.55%. Secara teknis, fenomena ini merupakan konsekuensi dari strategi agent_boilerplate yang menggabungkan berbagai sumber informasi (VLM, RAG, dan MCP) ke dalam satu *context prompt* yang sangat detail. Model menghasilkan kalimat yang sangat panjang (prolixity) untuk menjelaskan detail faktual seperti "keramik mozaic yang menarik perhatian". Karena metrik BLEU-4 sangat sensitif terhadap kesesuaian urutan empat kata berturut-turut, deskripsi agen yang terlalu luas ini gagal mencocokkan struktur kalimat *Ground Truth* yang sederhana, meskipun secara kualitatif informasi yang diberikan agen jauh lebih lengkap dan minim halusinasi dibandingkan VLM *baseline*.

Tabel 4. 18 Perbandingan *captioning agent* pada dataset *kampus outdoor* berdasarkan pertanyaan kedua (tiga tertinggi)

Ground Truth	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 - Tiga wanita mengenakan hijab sedang membaca buku di luar ruangan, menikmati suasana cerah dan santai. - Empat wanita mengenakan hijab ini sedang menikmati suasana cerah sambil membaca buku di luar ruangan. - Kegiatan membaca di luar menciptakan momen santai dan menyegarkan. - Empat orang perempuan duduk sambil membaca kitab suci di sebuah meja	VLM: Mereka tengah melakukan kegiatan membaca buku dan minum kopi.	37.50	32.73	15.78	9.37	25.00
	VLM+RAG: Wanita-wanita itu sedang duduk dan membaca kitab sucinya di luar rumah. Mereka terlihat nyaman dan asyik.	50.00	39.22	29.85	21.97	40.00
	VLM+RAG+MCP: Objek tersebut berupa empat wanita berjilbab sedang membaca kitab suci di luar ruang, terlihat santai dan ceria.	62.50	54.01	40.05	26.33	46.67
 - Sebuah papan nama jalan "Jl. T. Komputer IV" dikelilingi pepohonan hijau, suasana asri dan tenang. - Papan nama jalan "Jl. T. Komputer IV" dikelilingi oleh pepohonan hijau - Suasana asri dan tenang terlihat pada papan nama jalan "Jl. T. Komputer IV" yang dikelilingi pepohonan hijau. - Sebuah papan nama jalan "Jl. T. Komputer IV" yang ada di dekat tiang listrik dan di lingkungan yang banyak pepohonan - Papan nama jalan "Jl. T. Komputer IV" terlihat di atas tiang dengan pepohonan hijau mengelilingi di sekitarnya	VLM: Di latar depan tampak papan penunjukkan jalan bertulis "... TIK... 1..." yang dikelilingi oleh pepohonan hijau.	53.85	29.96	13.06	7.20	43.48
	VLM+RAG: Papan nama Jalan "Jl. T. komputer IV", berfungsi sebagai penunjukan jalan di sekitar pepohonan hijau.	64.29	54.47	46.60	40.53	58.33
	VLM+RAG+MCP: Papan nama Jalan "Jl.T.Komputer IV" berwarna putih, tampak tertata rapi berdiri diatas tiang besi dekat pohon-pohon hijau yang rindang.	44.44	22.87	15.13	8.91	35.71
 Selamat datang di tempat inspirasi dan kreativitas, di mana setiap	VLM: Gambar menunjukkan ruang luar umum yang luas serta memiliki udara sejuk yang bisa dimanfaatkan untuk bersantiaian.	12.50	4.81	2.94	1.87	8.00
	VLM+RAG: Monumen berbentuk seperti logo 'IF' warna	38.46	17.54	7.67	4.15	28.57

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
langkah membawa Anda menuju pengetahuan baru!	biru berdiri tinggi diatas lantai keramik lantai di area Plaza Superno. Monumen ini berfungsi sebagai simbol identifikasi dari sebuah departemen.					
• Selamat datang di tempat inspirasi dan kreativitas, di mana setiap langkah membawa peluang baru! • Lingkungan ini dirancang untuk memicu ide-ide dan inovasi yang bermanfaat. • Sebuah logo IF berwarna biru di sekitar Plaza Supeno • Monumen bertuliskan "IF" terlihat berada di lantai keramik depan	VLM+RAG+MCP: Monumen bertanda IF berwarna biru terletak di area lantai keramik yang berada di Plaza Supono. Monumen itu merupakan simbol identitas sebuah departemen. Lantai bangunan terlihat putih bersih.	51.85	31.58	16.15	8.60	33.33

Analisis pada Tabel 4.18 menunjukkan pencapaian skor BLEU-4 yang sangat tinggi pada agen MCP (26.33%) dibandingkan *baseline* (9.37%). Keberhasilan ini secara teknis disebabkan oleh kemampuan protokol MCP dalam menyinkronkan data atribut fisik (jumlah "empat" dan objek "kitab suci") ke dalam struktur kalimat yang natural. Instruksi sistem pada `_maybe_handle_multimodal_and_augment` yang mewajibkan agen menyebutkan detail secara spesifik terbukti efektif menghasilkan frasa 4-gram yang cocok dengan *Ground Truth* secara eksak, seperti "membaca kitab suci di". Skor B-4 yang tinggi ini membuktikan bahwa integrasi data eksternal tidak hanya meningkatkan akurasi kata demi kata, tetapi juga membantu model menyusun penalaran (*reasoning*) aktivitas yang strukturnya diakui oleh pengamat manusia.

Tabel 4. 19 Contoh hasil deskripsi perbandingan *agent* dataset kampus *outdoor* berdasarkan pertanyaan kedua (tiga terendah)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Selamat datang di Plaza Prof Supeno Djanali, pusat kreativitas dan kolaborasi yang dikelilingi keindahan alam! • Selamat datang di Plaza Prof Supeno Djanali, tempat di mana kreativitas dan kolaborasi bersatu. • Keindahan alam yang mengelilingi plaza ini menambah inspirasi bagi setiap pengunjung. • Lapangan di sekitar Plaza Supeno yang di tengahnya ada net voli terbentang • Hamparan lahan paving dengan jaring-jaring voli terlihat di depan sementara bangunan besar	VLM: Gambar ini menunjukkan lapangan luas dengan latar belakang bangunan modern yang mencolok. Suasana di sini tampak dinamis karena adanya kombinasi antara udara terbuka dan arsitektur yang menarik.	32.00	6.55	3.22	1.82	21.62
	VLM+RAG: Gambar menunjukkan hamparan paving di area Plaza Prof. Supeno Djani yang juga dilengkapi net voli. Gedung bertuliskan "PLAZA" berada di belakang net voli tersebut.	54.17	40.60	31.43	23.11	39.02
	VLM+RAG+MCP: Di lokasi tersebut terdapat lapangan paving putih dengan net biru muda yang menjulang tinggi di	32.35	5.88	2.77	1.53	17.39

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
bertuliskan "PLASA" berada di belakangnya	depannya. Di dekat lapangan terlihat gedung bertanda PLASA berwarna abu-abunya. Terdapat beberapa orang sedang bermain voli sekitar lapangan tersebut.					
 - Jalan setapak berbatu mengarah ke taman asri, dikelilingi pepohonan dan bangunan tradisional yang menawan. - Jalan berbatu ini mengarah ke taman asri yang dikelilingi pepohonan dan bangunan tradisional - Dengan suasana yang menawan, jalan setapak berbatu membawa Anda menuju taman asri yang dikelilingi oleh pepohonan. - Di bawah tangga masjid ada kotak-kotak untuk jalan setapak menuju bangunan putih - Beberapa rangkaian keramik mozaik tampak di depan hingga ke kanan depan sementara pohon besar dan bangunan berada di depan di kelilingi pepohonan	VLM: Gambar menampilkan jalan untuk menuju taman.	24.53	13.43	6.79	4.25	27.27
	VLM+RAG: Jalan setapak itu terbuat dari keramik mozaik dan arahnya menuju bangunan putih tua yang dikelir oleh pohon besar. Pemandangan sekitar berupa taman yang luas dengan banyak pohon.	53.85	32.82	16.79	8.93	28.57
	VLM+RAG+MCP: Di bagian depan nampak jalan setapak dengan keramik mozaik yang menarik. Pohon besar mengelilingi jalan setapak tersebut. Dan di depannya juga terdapat bangunan putih klasik yang mungkin menjadi akses masuk daerah tersebut.	37.50	15.55	6.72	3.59	19.23
 - Gedung Teknik Informatika dengan desain modern, mahasiswa berjalan, suasana cerah dan asri. - Gedung Teknik Informatika yang modern ini menjadi	VLM: Di depan tampak sebuah gedung Departemen Teknik Informatika yang dikelung pohon-pohon hijau.	45.45	21.32	10.90	6.53	30.77
	VLM+RAG: Gambar menunjukkan gedung Departemen Teknik Informatika yang tampak menawan dan berada dalam lingkungan yang hijau dan luas. Di depan gedung terlihat aktivitas orang-orang beraktivitas di area sekitarnya.	50.00	20.85	8.78	4.67	26.32

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
pusat aktivitas mahasiswa di lingkungan yang cerah. • Suasana asri di sekitar gedung menciptakan tempat belajar yang menyenangkan. • Dua orang perempuan berjalan menuju gedung Departemen Teknik Informatika • Di depan terlihat gedung besar dengan tulisan "TEKNIK INFORMATIKA" sementara beberapa orang berada di sekitarnya	VLM+RAG+MCP: Gedung Teknik Informatika terlihat modern dengan desain yang cukup menarik. Suasana di sekitarnya terasa cerah karena adanya cahaya alami yang masuk melalui jendela. Di halaman dekat gedung terdapat beberapa pohon dengan warna daun hijau yang rimbun. Sejumlah mahasiswa tampak aktif berjalan di area tersebut mengenakan pakaian seragam berwarna putih dan hitam. Beberapa mahasiswa juga membawa tas ransel kecil serta buku catatan.	28.81	14.10	7.23	3.99	20.00

Tabel 4.19 menyoroti kegagalan dalam metrik B-4 pada citra gedung Departemen Teknik Informatika dan Plaza, di mana skor menyusut hingga 1.53%. Secara teknis, rendahnya skor B-4 ini terjadi karena keragaman diksi yang digunakan model saat mencoba mendeskripsikan kerumunan atau area yang luas. Implementasi `repetition_penalty=1.5` pada kode model terkadang memicu model untuk mencari sinonim atau frasa alternatif guna menghindari repetisi, yang justru menjauhkan susunan 4-gram dari struktur kalimat *Ground Truth* yang kaku. Selain itu, agen MCP cenderung menambahkan detail spekulatif namun logis berdasarkan data lokasi (seperti "pakaian seragam berwarna putih dan hitam"), yang secara kuantitatif menurunkan skor BLEU karena tidak ada kecocokan frasa panjang dengan referensi.

Tabel 4. 20 Contoh hasil deskripsi perbandingan *agent* dataset kampus *outdoor* berdasarkan pertanyaan ketiga (tiga tertinggi)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Sebuah papan nama jalan "Jl. T. Komputer IV" dikelilingi pepohonan hijau, suasana asri dan tenang. • Papan nama jalan "Jl. T. Komputer IV" dikelilingi oleh pepohonan hijau • Suasana asri dan tenang terlihat pada papan nama jalan "Jl. T. Komputer IV" yang dikelilingi pepohonan hijau. • Sebuah papan nama jalan "Jl. T. Komputer IV" yang ada di dekat tiang listrik dan di	VLM: Di latar depan terdapat papan penunjukan jalan berbentuk persegi panjang dengan tulisan "Titik ... 1..." yang dikelilingi oleh pepohonan. Jumlah papan penunjuk jalan itu satu.	29.17	6.35	3.19	1.82	23.53
	VLM+RAG: Gambar menampilkan papan nama Jalan berwarna putih dengan tulisan yang terletak di tiangnya. Terdapat satu papan nama Jalan.	41.18	22.69	15.37	9.13	22.86
	VLM+RAG+MCP: Papan nama Jalan "Jl. T. Komputer IV" berwarna putih, sedangkan tiangnya merupakan warna hijau.	51.52	38.06	26.89	20.79	40.82

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
lingkungan yang banyak pepohonan • Papan nama jalan "Jl. T. Komputer IV" terlihat di atas tiang dengan pepohonan hijau mengelilingi di sekitarnya	Di sekitar papan nama jalan terdapat banyak pohon hijau yang berdampingan. Ada satu papan nama saja yang terlihat di gambar.					
 • Selamat datang di Plaza Prof Supeno Djanali, pusat kreativitas dan kolaborasi yang dikelilingi keindahan alam! • Selamat datang di Plaza Prof Supeno Djanali, tempat di mana kreativitas dan kolaborasi bersatu. • Keindahan alam yang mengelilingi plaza ini menambah inspirasi bagi setiap pengunjung. • Lapangan di sekitar Plaza Supeno yang di tengahnya ada net voli terbentang • Hampan lahan paving dengan jaring-jaring voli terlihat di depan sementara bangunan besar bertuliskan "PLASA" berada di belakangnya	VLM: Dalam gambar, ada beberapa objek berupa gedung modern yang mengelilingi lapangan. Ada tidak disebutkan berapa banyak contohnya.	17.65	5.59	3.20	1.97	13.79
	VLM+RAG: Gambar menunjukkan hamparan paving berwarna abu-abunya di area plaza. Terdapat sebuah lapangan net voli putih yang terletak di depan bangunan bertulis "PLASA".	60.00	30.78	11.89	6.11	43.24
	VLM+RAG+MCP: Gedung bertulis "PLASA" berada di dekat sebuah lapangan pemadat berwarna putih dan abu-abunya. Di samping lapangan terdapat net voli menempel di dinding bangunan itu. Lapangan ini memiliki Paving yang bertekstur abu-abu. Ada juga beberapa aktivitas seperti latihan bola di lapangan.	33.33	18.73	12.64	8.52	15.69
 • Selamat datang di tempat inspirasi dan kreativitas, di mana setiap langkah membawa Anda menuju pengetahuan baru! • Selamat datang di tempat inspirasi dan kreativitas, di mana setiap langkah membawa peluang baru! • Lingkungan ini dirancang untuk memicu ide-ide dan inovasi yang bermanfaat. • Sebuah logo IF berwarna biru di sekitar Plaza Supeno	VLM: Gambar menunjukkan ruang outdoor yang luas, indah, dan memiliki udara segar sehingga cocok untuk bersenang dan melakukan aktivitas.	12.50	4.81	2.94	1.87	8.00
	VLM+RAG: Monumen berbentuk seperti sebuah bangunan bertulisan logo IF berwarna biru dengan lantai keramik putih. Terdapat satu unit monumen.	50.00	34.30	24.85	17.69	37.04
	VLM+RAG+MCP: Monumen berbentuk persegi panjang bertulisan IF berwarna biru, berdiri diatas lantai keramik putih. Di sekitar monumen terdapat area ruang	38.46	27.74	15.03	8.21	28.57

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
Monumen bertuliskan "IF" terlihat berada di lantai keramik depan	terbuka yang luas. Ada satu buah monumen.					

Pada Tabel 4.20, arsitektur VLM+RAG+MCP kembali menunjukkan keunggulan pada metrik BLEU-4 (20.79%) saat mengidentifikasi atribut fisik papan nama jalan. Secara teknis, tingginya skor B-4 ini merupakan hasil langsung dari pemanfaatan tabel database terstruktur melalui MCP yang menyimpan nama jalan secara eksak sebagai *string*. Ketika model memproses fakta "Jl. T. Komputer IV", sistem menyusunnya ke dalam struktur kalimat deskriptif yang konsisten sesuai dengan pola data referensi manusia. Penggunaan data terstruktur ini meminimalkan variasi n-gram yang salah, sehingga frase-frase panjang seperti "papan nama jalan berwarna" atau nama jalan itu sendiri dapat tercocokkan dengan sempurna pada level 4-gram.

Tabel 4. 21 Contoh hasil deskripsi perbandingan *agent* dataset kampus outdoor berdasarkan pertanyaan ketiga (tiga terendah)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 - Jalan setapak berbatu mengarah ke taman asri, dikelilingi pepohonan dan bangunan tradisional yang menawan. - Jalanan berbatu ini mengarah ke taman asri yang dikelilingi pepohonan dan bangunan tradisional - Dengan suasana yang menawan, jalan setapak berbatu membawa Anda menuju taman asri yang dikelilingi oleh pepohonan. - Di bawah tangga masjid ada kotak-kotak untuk jalan setapak menuju bangunan putih - Beberapa rangkaian keramik mozaik tampak di depan hingga ke kanan depan sementara pohon besar dan bangunan berada di depan di kelilingi pepohonan	VLM: Gambar menunjukkan jalan setapak batu yang melandai dan menenangkan. Jalan setapak tersebut merupakan bagian dari taman yang rimbun. Ada beberapa pohon hijau mendominasi sekitar.	34.78	12.57	6.35	3.69	30.77
	VLM+RAG: Pada gambar, terdapat jalur setapak mosaik berwarna putih, pohon-pohon besar dengan warna hijau, serta sebuah bangunan putih. Ada beberapa elemen dalam gambar tersebut.	30.43	11.76	6.08	3.57	17.14
	VLM+RAG+MCP: Warna: Keramik mozaik cokelat tua, batu bata, hijau pohon, putih bangunan. Bentuk: Bentuk jalan setapak berbentuk melanda. Jalan setapak terbuat dari keramik mozaik dengan berbagai macam warna, juga terdapat batu bata. Pohon yang menghiasi sekitar jalan setapak berbentuk bulat dan memiliki daun yang lebar. Bangunan putih tradisional menyerupai rumah adat dengan atap datar. Objek: Jalan setapak, bangunan putih kuno, pohon,	18.75	9.45	4.04	2.13	15.00

Ground Truth	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
	pepohonan. Jumlah objek: 8 objek.					
 • Peralatan kebersihan bersandar di dinding, siap menjaga keindahan area hijau di sekitarnya. • Peralatan kebersihan yang bersandar di dinding siap menjaga keindahan area hijau di sekitarnya. • Kesiapan peralatan kebersihan ini mencerminkan komitmen terhadap kebersihan dan kerapihan. • Ada sapu dan serokan bersandar di dinding yang ada di sekitar taman • Sapu dan cikrak terlihat bersandar pada tembok kanan sementara tembok batu tampak di kiri	VLM: Dalam gambar terdapat tumbuhan hijau yang beraneka ragam, membuat lingkungan terasa segar. Jumlahnya tidak diketahui secara pasti.	11.76	4.56	2.80	1.78	6.90
	VLM+RAG: Sapu, cikrak, dan dinding terdiri dari kayu berwarna natural. Ada satu set setiap alat.	35.71	23.44	16.91	10.24	38.46
	VLM+RAG+MCP: Dari gambar terlihat ada beberapa peralatan kebersihan yaitu: Warna: Sapu berwarna kayu, sedangkan serokanya terbuat dari bahan plastik. Dinding pada area taman berwarna putih. Untuk lebih detail mengenai jenis objek dapat dilihat dalam gambar. Ada : Objek: Sapu dengan gagangnya kayu dan serok. serokan juga memiliki ciri khas seperti cirak. Terdapat satu set perlengkapan kebersihan ini di lokasi.	24.14	11.27	4.66	2.41	17.14
 • Sebuah spanduk "Kawasan Tanpa Rokok" menandai area bebas rokok, dikelilingi pepohonan dan suasana yang tenang. • Spanduk "Kawasan Tanpa Rokok" terpasang di depan beserta sepeda dan anak-anak kecil sedang bermain • Di tengah pepohonan, spanduk "Kawasan Tanpa Rokok" menandakan komitmen terhadap lingkungan yang sehat dan tenang. • Lapangan kecil yang sedang digunakan untuk bermain memiliki himbauan kawasan	VLM: Gambar menunjukkan kawasan parking untuk sepeda motor yang dilengkapi spandak peringatan berisi aturan larangan bernikah dan menyentuh rokok. Hanya satu spandak peringatan saja.	22.73	5.78	3.06	1.80	11.11
	VLM+RAG: Spanduk berwarna merah dan putih bertuliskan "Kawasan Tanpa Rokok". Di sekitar spanduk ada pepohonan hijau. Ada juga sepeda dan beberapa anak-anak yang bermain di dalam area tersebut.	48.00	20.00	12.28	7.10	41.03
	VLM+RAG+MCP: Warna spanduk adalah merah dan putih. Di sekitar spanduk terlihat juga beberapa anak-anak bermain sepeda, serta pohon-pohon yang hijau. Ada juga satu buah sepeda	28.57	10.29	5.29	3.08	23.81

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
tanpa rokok dan sebuah cermin jalana • Seseorang dan sepeda berada jauh di depan sementara rambu lalu lintas berada di kiri depan dengan spanduk berada di atas sepeda	milik anak- anak dalam gambar.					

Hasil pada Tabel 4.21 menunjukkan kegagalan metrik B-4 pada skenario identifikasi atribut yang sangat kompleks. Secara teknis, skor B-4 yang rendah (2.13% dan 2.41%) pada agen MCP disebabkan oleh perubahan format output model menjadi daftar teknis (seperti "Warna:", "Bentuk:", "Objek:"). Meskipun informasi ini sangat akurat secara faktual karena ditarik langsung dari kolom fakta database, format "daftar" ini secara radikal berbeda dari struktur kalimat deskriptif mengalir yang ada di *Ground Truth*. Ini menegaskan bahwa metrik BLEU-4 sangat bergantung pada kemiripan struktur linguistik; meskipun agen berhasil menghindari kesalahan persepsi visual, perbedaan dalam gaya penyajian informasi teknis menyebabkan skor kuantitatif menurun drastis.

4.2.3 Pengujian Dataset Trotoar Surabaya

Pengujian pada kategori trotoar Surabaya dilakukan untuk mengevaluasi kemampuan agen dalam mengenali objek, aktivitas, dan atribut fisik di lingkungan urban yang sangat dinamis. Tantangan utama pada dataset ini adalah kepadatan lalu lintas, variasi elemen infrastruktur kota (seperti kubus pembatas, tiang lampu emas, dan tong sampah), serta interaksi pejalan kaki yang beragam. Lokasi pengujian mencakup trotoar di jalan-jalan protokol Surabaya yang memiliki karakteristik estetika dan fungsional yang spesifik.

Tabel 4. 22 Perbandingan *captioning agent* pada dataset trotoar Surabaya berdasarkan pertanyaan pertama (tiga tertinggi)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Tiga orang perempuan sedang berjalan bersama di trotoar ini • Satu pohon besar dililit oleh lampu dan tiga orang yang sedang berjalan • Satu orang pria sedang duduk di bangku trotoar ini. • Sekelompok wanita berjalan di trotoar yang rindang, dikelilingi pepohonan dan suasana kota yang hidup. • Tiga wanita mengenakan masker berjalan di trotoar dekat restoran, sementara seorang	VLM: Latar depan gambar tersebut adalah trotoarnya dan pepohonan di sekitarnya.	33.33	9.57	5.39	3.39	14.81
	VLM+RAG: Latar belakang gambar menunjukkan trotoarnya yang rimbun dengan banyak tanaman. Terdapat juga bangunan sekitar.	21.43	12.84	7.32	4.57	14.81
	VLM+RAG+MCP: Ada tiga wanita yang memakai masker sedang jalan di trotoar yang rimbun. Di samping mereka terdapat sebuah	60.87	37.19	19.06	10.08	39.02

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
anak duduk di bangku dengan pohon besar.	pohon besar dengan lilin yang dilitit oleh lampu.					
 • Sepeda motor dengan warna merah dan hitam dikendarai seseorang memakai jaket hitam. • Sebuah tong sampah dengan ukuran sedang memiliki warna merah. • seorang wanita mengendarai sepeda motor menaiki trotoar ke arah kanan. • seorang perempuan mengendarai motor miliknya ke atas trotoar • Seorang wanita mengendarai sepeda motor di trotoar menuju area parkir	VLM: Pengendara sepeda motormengan melewati trotoarnya yang dikelipungi pepohonan. Ada juga kendaraan lainnya.	16.67	6.14	3.72	2.38	19.05
	VLM+RAG: Berdasarkan informasi database, tampak seorang wanita sedang mengendarai sepeda motor berwarna merah-hitam menuju area parking.	60.00	46.29	32.43	22.89	61.54
	VLM+RAG+MCP: di dalam gambar tampak seorang wanita mengenakan pakaian hitam sedang mengemudi sepeda motor berwarna merah-black di trotoar. Di sampingnya terdapat tong sampah berwarna merah.	50.00	32.97	17.34	9.30	40.00
 • di sisi jalan terdapat deretan mobil dalam kondisi terparkir rapi • Di sepanjang trotoar ini terdapat tiang dengan warna emas dan kubus-kubus kecil dengan warna abu-abu • beberapa kubus beton dan tiang lampu di sepanjang trotoar serta banyak mobil parkir di sebelah kanan • Pohon-pohon dan tanaman-tanaman di satu sisi trotoar, sedangkan mobil terparkir, pembatas jalan berbentuk kubus dan lampu jalan di sisi lainnya • Trotoar kota dengan tanaman hias berwarna merah dan hijau di sepanjang jalan, dipenuhi kendaraan yang terparkir di sisi kanan serta bangunan komersial di sisi kiri, berlatar belakang gedung tinggi	VLM: Latar belakang foto menunjukkan: Kubus-kus kecil berwarna abu-abunya Lampu penerangan Jalan Mobil Dan banyak orang yang berjalan di jalan.	71.43	12.04	5.58	3.13	20.69
	VLM+RAG: Pada latar depan terdapat tiang cahaya berwarna emas, pembatas jalan berbentuk kubus berwarna abu- Abu, beserta deretan kendaraan yang terparkiran rapi. Ada juga tanaman hias berupa bunga merah dan warna hijau yang ditanam di sepanjang trottoar.	60.00	42.01	28.12	16.08	19.05
	VLM+RAG+MCP: Di bagian depan gambar terdapat trotoarnya yang dilewati oleh beberapa kendaraan, seperti mobil dan mungkin juga sepeda motor. Terdapat tiang listrik berwarna emas dan beberapa kubus berwarna abu-abunya yang berdiri tegak di pinggir jalan. Di samping itu juga terdapat deret tanaman hias	40.43	24.80	14.26	8.88	19.67

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
	berwarna merah dan kuning menghias trotoair tersebut.					

Analisis pada Tabel 4.22 menunjukkan skor B-4 yang kompetitif pada arsitektur VLM+RAG+MCP, terutama pada identifikasi elemen infrastruktur jalan. Meskipun VLM+RAG mencapai skor B-4 tertinggi pada objek motor (22.89%), agen MCP menunjukkan kestabilan pada identifikasi pejalan kaki bermasker dengan skor 10.08%. Secara teknis, skor B-4 ini didukung oleh integrasi data faktual dari database Supabase yang ditarik melalui protokol MCP, yang memungkinkan model menyusun frasa deskriptif yang tepat mengenai objek spesifik seperti "pohon besar dengan lampu". Penggunaan num_beams=5 pada kode sumber memastikan model melakukan pencarian sekuensial yang optimal untuk menghasilkan struktur kalimat yang koheren pada level 4-gram.

Tabel 4. 23 Perbandingan *captioning agent* pada dataset trotoar Surabaya berdasarkan pertanyaan pertama (tiga terendah)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 - trotoar ini memiliki sebuah tiang dengan warna hitam-kuning yang di atasnya terdapat dua buah kotak dengan warna abu abu - pada trotoar ini terdapat kubus-kubus kecil yang tersebar, sebuah bangku taman dengan warna putih, dan dua buah tiang pembatas dengan warna abu-abu dengan gambar sepeda padanya - tiang listrik di tengah dan tempat parkir sepeda di tepi kiri trotoar - sebuah tiang listrik di depan bangunan putih dengan jendela besar - Tempat parkir sepeda dan tiang listrik di depan bangunan - Trotoar yang luas dengan kursi besi putih di sisi kanan, jalur sepeda di sebelah jalan raya, dan deretan toko serta kendaraan yang berlalu lalang di jalan	VLM: Objek utama di latar belakang gambar adalah tiang listrik berwarna putih.	45.45	21.32	10.90	6.53	28.57
	VLM+RAG: Berdasarkan gambar, terlihat adanya trotoair dengan tiangnya berwarna emas, serta kubus abu-abunya. Di sampingnya ada deretan kendaraan yang tertata rapi, sementara taman bunga merah-merah yang tersusun rapi menambah kesan sejuk pada area tersebut.	41.94	11.82	5.65	3.17	21.43
	VLM+RAG+MCP: Di bagian latar depan tampak tiang berwarna emas, beberapa kubus berwarna abu- Abu, serta mobil berjenis [tidak disebutkan dalam teks] yang tertanam rapi di tengah jalanan itu. Di sekitar taman, terdapat tanaman hias berwarna merah dan jingga.	34.29	14.20	6.18	3.31	17.39

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Satu orang laki-laki menggunakan tas warna coklat sedang berjalan di trotoar • Satu orang laki - laki sedang duduk di bangku taman dengan warna putih • Terdapat papan ucapan selamat sukses yang disandarkan di dinding • Seorang pria berjalan di trotoar, sementara orang-orang duduk santai dan lalu lintas berlalu di jalan. • Seorang pria mengenakan kemeja kotak-kotak dan tas ransel berjalan di trotoar yang ramai, sementara beberapa orang duduk di bangku dan lampu lalu lintas terlihat di latar belakang.	VLM: Latar depan gambar itu adalah trotoar dan sepeda motor. Ada satu orang lelaki dengan baju Hitam yang sedang berdiri.	36.84	14.31	7.27	4.25	20.00
	VLM+RAG: Ada dua pria dalam gambar tersebut. Salah satunya mengenakan kemeja berwarna coklat dan duduk di sebuah bangku.	50.00	25.82	11.22	6.13	29.27
	VLM+RAG+MCP: Di bagian depan foto terdapat seorang pria dengan kemeja kotak motif berwarna coklat menengok ke arah kamera saat berjalan di jalan.	39.36	22.09	8.84	4.61	28.57
 • Satu orang pria dewasa memakai baju garis-garis hitam putih • Seorang anak SD dengan seragam putih merah sedang duduk di kursi plastik biru • Terdapat satu pohon dan dua orang yang sedang duduk di bangku taman dengan warna coklat • Di bawah rindangnya pepohonan, trotoar ini menjadi tempat pertemuan antara deretan motor parkir dan obrolan santai warga • Sejumlah orang berdiri dan duduk di trotoar dekat gerobak makanan, sementara seorang pria berbicara dengan wanita yang mengenakan jilbab.	VLM: Di latar depan tampak seorang pria sedang mendirikan posisi dirinya disekitar bangku.	45.45	21.32	10.90	6.53	20.69
	VLM+RAG: Dari informasi database, tampak ada seorang anak sekolah dasar dan pria dalam gambar tersebut sedang berada di area itu.	29.41	13.56	7.22	4.33	26.67
	VLM+RAG+MCP: Ada seorang pria yang mengenakan pakaian bermotif garis-strip berwarna hitam-biru duduk di sebuah bangku beton dekat trotoar. Di sampingnya terdapat anak-anak sekolah dasar.	43.48	24.35	9.83	5.13	21.62

Pada Tabel 4.23, terlihat penurunan skor B-4 pada agen MCP hingga menyentuh 3.31%. Secara teknis, rendahnya skor B-4 ini merupakan indikasi dari fenomena *proximity* yang muncul akibat penggabungan konteks RAG dan MCP yang sangat detail dalam `agent_boilerplate.py`. Agen cenderung menghasilkan deskripsi yang sangat panjang untuk menjelaskan elemen kompleks seperti tiang emas dan kubus abu-abu. Karena metrik BLEU-4

sangat sensitif terhadap urutan kata yang eksak dan memberikan penalti pada ketidakseimbangan panjang kalimat, deskripsi agen yang terlalu naratif gagal mencocokkan struktur *Ground Truth* yang jauh lebih ringkas, meskipun informasi faktual yang diberikan agen sangat akurat.

Tabel 4. 24 Perbandingan *captioning agent* pada dataset trotoar Surabaya berdasarkan pertanyaan kedua (tiga tertinggi)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Tiga orang perempuan sedang berjalan bersama di trotoar ini • Satu pohon besar dililit oleh lampu dan tiga orang yang sedang berjalan • Satu orang pria sedang duduk di bangku trotoar ini 4. Sekelompok wanita berjalan di trotoar yang rindang, dikelilingi pepohonan dan suasana kota yang hidup. • Tiga wanita mengenakan masker berjalan di trotoar dekat restoran, sementara seorang anak duduk di bangku dengan pohon besar.	VLM: Wanita sedang berjalan.	13.53	9.57	5.19	3.17	33.33
	VLM+RAG: Wanita sedang berjalan-jalan di trotoar yang rimbun dengan banyak pepohonan.	70.00	39.44	27.25	15.90	35.71
	VLM+RAG+MCP: Wanita sedang berjalan kaki di trotoar yang rimbun dengan banyak pohon. Dia mengenakan masker.	71.43	46.88	26.71	14.48	37.50
 • Sepeda motor dengan warna merah dan hitam dikendarai seseorang memakai jaket hitam. • Sebuah tong sampah dengan ukuran sedang memiliki warna merah. • seorang wanita mengendarai sepeda motor menaiki trotoar ke arah kanan. • seorang perempuan mengendarai motor miliknya ke atas trotoar • Seorang wanita mengendarai sepeda motor di trotoar menuju area parkir	VLM: Pengendara motor sedang melaju.	26.96	17.40	9.15	6.03	28.57
	VLM+RAG: Wanita itu sedang mengantar sepeda motornya ke area parkir	77.78	44.10	18.59	10.28	50.00
	VLM+RAG+MCP: Berdasarkan gambar, tampak seorang wanita sedang berkendara sepeda motornya berwarna merah-black menuju area parkir dekat tong sampah berwarna merah.	61.11	42.40	22.73	12.13	48.28
	VLM: Tanaman itu tampak ditanam di tengah trotoarnya. Objeknya	22.70	5.74	3.03	1.78	17.65

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Tumbuhan hias berbentuk semak-semak dengan daun yang panjang dengan warna hijau. • Sepeda motor dengan warna hitam yang dikendarai seseorang memakai baju abu-abu. • tikungan trotoar ke arah kiri dengan tumbuh tumbuhan hijau di tepinya • sebuah tikungan jalan pada siang hari terlihat sepi pengendara • Mobil dan sepeda motor melaju di tikungan dengan beberapa tanaman di trotoar sekitarnya • Trotoar dengan tanaman hias di tepi jalan yang berbelok, di mana beberapa kendaraan dan pengendara motor tampak melintas di jalan raya di dekatnya.	didapatkan informasi bahwa tanaman itu memiliki ukuran yang sedang, batang yang menjamu, dan panjang lautan.					
	VLM+RAG: Pengendara motor sedang meluncur di tikung jalan raya.	77.78	69.72	41.47	22.46	38.71
	VLM+RAG+MCP: Objek dalam gambar adalah pengendara sepeda motor. Ia mengenakan baju abu-abu dan terlihat sedang melintas di tikung jalan.	48.93	40.17	20.34	10.56	33.33

Analisis pada Tabel 4.24 menunjukkan performa B-4 yang cukup baik pada agen VLM+RAG dan MCP, dengan skor masing-masing 22.46% dan 14.48%. Secara teknis, tingginya skor B-4 pada identifikasi aktivitas di tikungan jalan dipicu oleh kemampuan RAG dalam memberikan nuansa situasional yang tepat. Fungsi `_maybe_handle_multimodal_and_augment` pada kode sumber menyuntikkan informasi kontekstual yang membantu Gemma-2 menyusun frasa aktivitas yang mengalir, seperti "sedang meluncur di tikung jalan raya". Kecocokan struktur kalimat ini pada level 4-gram membuktikan bahwa sistem berhasil melakukan penalaran (*reasoning*) aktivitas urban dengan pola yang menyerupai deskripsi manusia.

Tabel 4. 25 Perbandingan *captioning agent* pada dataset trotoar Surabaya berdasarkan pertanyaan kedua (tiga terendah)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • trotoar ini memiliki sebuah tiang dengan warna hitam-kuning yang di atasnya terdapat dua buah kotak dengan warna abu abu	VLM: Pelanggan terlihat berada di area parkir kendaraan roda dua dengan ukuran yang cukup besar berwarna abu-birunya. Di sebelah kanan, terdapat tiang lampu berwarna putih.	51.96	14.72	6.88	3.84	18.60
	VLM+RAG: Pada gambar tersebut terlihat jalan setapak	32.00	6.55	3.22	1.82	16.00

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
- pada trotoar ini terdapat kubus-kubus kecil yang tersebar, sebuah bangku taman dengan warna putih, dan dua buah tiang pembatas dengan warna abu-abu dengan gambar sepeda padanya - tiang listrik di tengah dan tempat parkir sepeda di tepi kiri trotoar - sebuah tiang listrik di depan bangunan putih dengan jendela besar - Tempat parkir sepeda dan tiang listrik di depan bangunan	dengan tiangnya berwarna emas, dinding dari material beton berwarna abu-du, serta beberapa mobil yang terparkir rapi di samping jalanan.					
	VLM+RAG+MCP: Objek terlihat berupa trotoarnya. Dari gambar terlihat bahwa trotoai memiliki material lantai berwarna hitam yang kadang bercampur dengan abu-abunya. Di samping itu terdapat berbagai macam kendaraan seperti mobil yang terpakai rapi dengan bentuk konvensional.	32.35	5.88	2.77	1.53	22.64
 - di sisi jalan terdapat deretan mobil dalam kondisi terparkir rapi - Di sepanjang trotoar ini terdapat tiang dengan warna emas dan kubus-kubus kecil dengan warna abu-abu - beberapa kubus beton dan tiang lampu di sepanjang trotoar serta banyak mobil parkir di sebelah kanan - Pohon-pohon dan tanaman-tanaman di satu sisi trotoar, sedangkan mobil terparkir, pembatas jalan berbentuk kubus dan lampu jalan di sisi lainnya Trotoar kota dengan tanaman hias berwarna merah dan hijau di sepanjang jalan, dipenuhi kendaraan yang terparkir di sisi kanan serta bangunan komersial di sisi kiri, berlatar belakang gedung tinggi	VLM: Objek dan subyek di latar belakang tampak aktif sebagai berikut: Objekt/subjek berlalu lalang di jalan raya Terlihat lampu penerang jalan Banyak kubus berwarna abu sampai kelihatan	31.74	6.09	2.93	1.64	19.05
	VLM+RAG: Istilah 'aktivitas' bisa difokuskan menjadi beberapa hal: 1. Aktivitas manusia: Manusia yang berjalan di jalan tampak melakukan kegiatan seperti berburu informasi, berkendara, atau menikmati pemandangan. 2. Aktivitas kendaraan: Mobil di gambar memiliki tanda parkir yang rapi sehingga menunjukkan bahwa mereka mungkin dalam kondisi diam untuk waktu yang lama.	24.44	7.45	3.79	2.17	18.18
	VLM+RAG+MCP: Dari gambar terlihat bahwa aktivitas utama di sana adalah penggunaan jalan sebagai tempat parkir. Ada banyak mobil yang terparkiran rapi di samping trotoarnya, menunjukkan kegiatan ini berlangsung secara rutin. Selain itu, terdapat beberapa pejalan kaki yang tampak sedang melintas di trotoair dan lingkungan sekitar juga nampak penuh dengan	34.48	15.56	5.76	2.84	14.71

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
	berbagai macam tumbuhan seperti tanaman hias merah dan kuning menghiasi area persimpangan jalan.					
 - Empat buah besi penghalang tidak terlalu tinggi dengan warna putih dan oranye. - Sebuah pot dengan ukuran sedang berisi tumbuhan hias di dalamnya - tiang pembatas jalan di depan dan banyak orang serta anak sekolah memenuhi trotoar 4 tiang besi yang ditanamkan di tengah trotoar sebagai pembatas - Banyak sepeda motor dan orang berhenti di sekitar trotoar yang memiliki tiang pembatas jalan - Trotoar dengan beberapa tiang pembatas berwarna merah-putih, diapit pepohonan dan tanaman hias, serta ramai dengan pengunjung dan pengendara motor di latar belakang.	VLM: Objek tersebut sedang memperjalanan di trotoarnya.	30.33	8.12	4.59	3.00	26.67
	VLM+RAG: Berdasarkan gambar, tampak banyak pejalan keak dan anak-anak sekolah yang menggunakan trotoair sebagai jalur pergerakan mereka.	35.71	16.57	8.67	5.19	26.09
	VLM+RAG+MCP: Berdasarkan gambar, tampak aktivitas utama di trotoar adalah adanya pejalan kaki dan anak sekolah. Ada banyak orang yang terlihat berjalan di trotoar, sementara beberapa orang lainnya sedang menunggu.	34.62	16.64	7.41	4.04	21.05

Tabel 4.25 menyoroti rendahnya skor B-4 pada skenario aktivitas yang sangat padat, seperti penggunaan trotoar sebagai tempat parkir (2.84%). Secara teknis, rendahnya skor ini disebabkan oleh kesulitan model dalam mengurutkan deskripsi aktivitas majemuk (parkir, pejalan kaki, dan tanaman hias secara bersamaan). Implementasi repetition_penalty=1.5 pada model kustom terkadang membuat agen mencari variasi kata yang tidak umum guna menghindari repetisi, yang justru menjauhkan susunan 4-gram dari struktur kalimat kaku pada *Ground Truth*. Hal ini menegaskan bahwa pada lingkungan urban yang ramai, variasi linguistik model cenderung meningkat secara signifikan.

Tabel 4. 26 Perbandingan *captioning agent* pada dataset trotoar Surabaya berdasarkan pertanyaan ketiga (tiga tertinggi)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 Tiga orang perempuan sedang berjalan bersama di trotoar ini	VLM: Warna-warna dominan dalam gambar tersebut antara hijau (dari pepotian) dan abu-abu/kuning. Ada satu wanita dan satu pria.	26.67	7.18	3.90	2.35	16.67

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
- Satu pohon besar dililit oleh lampu dan tiga orang yang sedang berjalan - Satu orang pria sedang duduk di bangku trotoar ini 4. Sekelompok wanita berjalan di trotoar yang rindang, dikelilingi pepohonan dan suasana kota yang hidup. Tiga wanita mengenakan masker berjalan di trotoar dekat restoran, sementara seorang anak duduk di bangku dengan pohon besar.	VLM+RAG: Dalam gambar tersebut tampak seorang wanita berjalan di jalan setapak yang rimbun dengan banyak pohon. Di sampingnya, seorang pria sedang duduk santai.	52.38	32.37	22.60	11.69	25.64
	VLM+RAG+MCP: Berdasarkan gambar, terlihat tiga wanita mengenakan masker, dan satu pria duduk santai di bangkunya. Pohon hijau megah berdiri tegak.	50.00	29.70	22.60	16.47	38.89
 - Tumbuhan hias berbentuk semak-semak dengan daun yang panjang dengan warna hijau. - Sepeda motor dengan warna hitam yang dikendarai seseorang memakai baju abu-abu. - tikungan trotoar ke arah kiri dengan tumbuh tumbuhan hijau di tepinya - sebuah tikungan jalan pada siang hari terlihat sepi pengendara - Mobil dan sepeda motor melaju di tikungan dengan beberapa tanaman di trotoar sekitarnya Trotoar dengan tanaman hias di tepi jalan yang berbelok, di mana beberapa kendaraan dan pengendara motor tampak melintas di jalan raya di dekatnya	VLM: trotoar ini memiliki sebuah tanaman dengan ukuran sedang yang tumbuh di tengahnya. tanaman ini memiliki ukuran sedang dengan batang yang tebal dan daun-daun yang panjang.	37.50	12.77	6.35	3.65	22.86
 - Sepeda motor dengan warna merah dan hitam dikendarai seseorang memakai jaket hitam. - Sebuah tong sampah dengan ukuran sedang memiliki warna merah. - seorang wanita mengendarai sepeda motor menaiki trotoar ke arah kanan.	VLM+RAG: Pengendara motor mengenakan baju abu-abu warna hitam. Di sekitar objek tersebut terdapat tanaman hias seperti semak berwarna hijau.	49.44	30.63	17.04	9.28	25.81
	VLM+RAG+MCP: Penggunaannya warna hitam (sepeda motor), pakaian abu-abu, dan tanaman hias. Ada satu pengendara sepeda motor.	50.00	40.82	23.17	12.62	27.59
	VLM: Objek utama dalam foto adalah pengendara motor. Terlihat dari warna hitam dan bentuk roda dan ban sepeda motor.	29.41	19.17	13.76	8.39	27.59
- Sepeda motor dengan warna merah dan hitam dikendarai seseorang memakai jaket hitam. - Sebuah tong sampah dengan ukuran sedang memiliki warna merah. - seorang wanita mengendarai sepeda motor menaiki trotoar ke arah kanan.	VLM+RAG: Ada satu wanita yang sedang mengendarainya sepeda motor berwarna merah-black. Dia juga memakai jaket hitam.	56.25	43.30	34.62	23.58	42.86
	VLM+RAG+MCP: Warna jaket wanita itu adalah hitam. Pengendara sepeda motornya memakai jaket hitam, dan terlihat warna motor merah hitam.	55.56	36.16	20.47	11.20	33.33

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
• seorang perempuan mengendarai motor miliknya ke atas trotoar • Seorang wanita mengendarai sepeda motor di trotoar menuju area parkir						

Pada pengujian atribut fisik (Tabel 4.26), agen VLM+RAG dan MCP menunjukkan skor B-4 yang kuat, puncaknya pada identifikasi warna motor (23.58%). Secara teknis, keunggulan ini dimungkinkan karena informasi atribut spesifik (seperti warna "merah-black" dan "jaket hitam") ditarik secara terstruktur dari kolom facts database melalui MCP. Keberadaan data fakta yang pasti ini memungkinkan model menyusun frasa atribut yang konsisten dan memiliki probabilitas kecocokan n-gram level 4 yang tinggi. Hal ini membuktikan bahwa protokol MCP bertindak sebagai penjamin akurasi atribut fisik di tengah kompleksitas lingkungan trotoar kota.

Tabel 4. 27 Perbandingan *captioning agent* pada dataset trotoar Surabaya berdasarkan pertanyaan ketiga (tiga terendah)

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Satu orang laki-laki menggunakan tas warna coklat sedang berjalan di trotoar • Satu orang laki - laki sedang duduk di bangku taman dengan warna putih • Terdapat papan ucapan selamat sukses yang disandarkan di dinding • Seorang pria berjalan di trotoar, sementara orang-orang duduk santai dan lalu lintas berlalu di jalan. • Seorang pria mengenakan kemeja kotak-kotak dan tas ransel berjalan di trotoar yang ramai, sementara beberapa orang duduk di bangku dan lampu lalu lintas terlihat di latar belakang.	VLM: Berdasarkan gambar, ada satu orang laki-laki dalam kondisi diam. Dia mengenakan pakaian hitam. Terdapat juga sebuah sepeda motor di dekat dirinya.	23.80	14.06	9.73	5.92	24.24
	VLM+RAG: Ada satu pria mengenakan pakaian berwarna coklat, satu pria sedang duduk di sebuah bangku yang putih, dan ada juga seorang pria berbaju hitam yang tengah berdiri di jalanan.	40.74	25.04	13.86	7.66	30.77
	VLM+RAG+MCP: Berdasarkan gambar yang diberikan, tampak ada dua pria. Salah satunya mengenakan kemeja berwarna coklat, sedangkan pria lainnya memakai pakaian putih seperti kaos polos.	27.76	10.74	5.53	3.24	17.65

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 - Mobil dengan warna putih dengan lampu bagian belakang dengan warna merah yang memiliki ban dan kaca dengan warna hitam. - Tempat sampah dengan warna hijau yang memiliki bentuk tabung dengan lubang di bagian depannya. - di depan ramai orang sedang berdiri di trotoar sementara di sebelah kiri beberapa kendaraan parkir - Di atas trotoar ada banyak orang berdiri dan duduk di kursi pedestrian sedang mengobrol, lalu di dekat mereka ada banyak sepeda motor dan sebuah mobil parkir - Di trotoar yang rindang, sekelompok orang berkumpul dengan santai, menikmati suasana sekitar yang hidup, sementara kendaraan melintas di jalanan yang ramai di samping mereka.	VLM: Warna dari objek utama adalah biru. Objek/subjek utama ini berbentuk manusia. Terdapat satu orang laki-lakinya saja dalam gambar.	16.67	5.32	3.05	1.87	9.09
	VLM+RAGAda satu mobil putih dan tempat sampah berwarna hijau. Ada juga beberapa orang yang berkumpul di trotoar. Mereka duduk di kursi pedestrian.	78.86	45.36	30.77	22.81	29.17
	VLM+RAG+MCPMobil putih memiliki warna putih. Orang-orang yang berada di lokasi tampak mengenakan pakaian umumnya seperti manusia biasa. Ada satu tempat sampah berwarna hijau tabung.	45.79	19.96	8.50	4.55	21.62
	VLM: Objek utama dalam gambar adalah seorang pria. Warna pakaiannya tidak terlihat jelas. Terdapat satu kendaraan lalu lintas di dekat dirinya.	25.00	11.47	6.20	3.73	16.67
	VLM+RAG: Pria mengenakan hoodie, ada empat besi penghambat abu-abu, penutup saluran berwarna hitam, serta satu mobil biru.	68.75	42.82	23.91	12.93	31.25

<i>Ground Truth</i>	Teks Prediksi	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L (%)
 • Terdapat sebuah penutup saluran berbentuk persegi dari besi dengan warna hitam di tengah-tengah trotoar. • Empat buah besi penghalang dengan warna abu-abu berada di tengah-tengah trotoar. • Sebuah tempat sampah dengan ukuran kecil dengan warna hijau berada di samping trotoar. • Suasana siang yang cerah, jalan setapak dikelilingi pepohonan, dengan pejalan kaki dan kendaraan melintas. • Seorang pria mengenakan hoodie berjalan di trotoar yang dikelilingi tanaman, sementara mobil biru melintas di jalan.	VLM+RAG+MCP: Berdasarkan gambar yang diberikan, tampak seorang pria berlari di trotoar. Ia mengenakan hoodie berwarna abu-abu. Di sampingnya terdapat empat besi penahan abu-abu.	54.55	32.23	11.96	6.01	26.32

Hasil pada Tabel 4.27 menunjukkan tantangan besar pada metrik B-4 untuk identifikasi atribut subjek manusia yang jamak, di mana skor turun hingga 3.24%. Secara teknis, rendahnya skor B-4 ini terjadi karena agen MCP seringkali menghasilkan format deskripsi yang terlalu kaku atau teknis saat mencoba membedakan atribut antar individu (misalnya: "pria berbaju coklat" vs "pria berbaju putih"). Perbedaan urutan penyebutan atribut antara prediksi agen dan lima referensi manusia dalam *Ground Truth* menyebabkan kegagalan pencocokan urutan empat kata berturut-turut, yang menegaskan bahwa metrik B-4 sangat dipengaruhi oleh stilistika penyusunan kalimat dalam lingkungan yang penuh dengan detail atribut kecil.

Halaman ini sengaja dikosongkan.

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian yang telah dilakukan terhadap sistem *backend* Amadeus (*Autonomous Multi-Agent Unified Swarm Intelligence*) untuk Neutrack AI Glove, dapat ditarik beberapa kesimpulan sebagai jawaban atas rumusan masalah, yaitu:

1. Perancangan *inference engine* lokal (Gemma-2b & CLIP) dengan optimasi *Projection Adapter* (LR 0,0006) efektif menjaga privasi data tanpa ketergantungan *cloud*. Hal ini dibuktikan dengan peningkatan skor BLEU-4 dari 11,88% menjadi 15,77% dan ROUGE-L 34,29%, yang menunjukkan kualitas representasi fitur yang kompetitif untuk deskripsi visual mandiri.
2. Arsitektur *Agentic AI* (VLM+RAG+MCP) terbukti paling unggul dibandingkan varian *baseline* dalam memitigasi halusinasi visual. Sistem mencapai performa optimal pada skenario *outdoor* (BLEU-4 16,65%; ROUGE-L 46,08%), serta tetap stabil pada skenario *indoor* (B-4 8,76%) dan Trotoar Surabaya (B-4 7,64%). Integrasi MCP melalui *tool-calling* ke *database* lokal memastikan deskripsi objek jauh lebih faktual dibandingkan model VLM murni.
3. Evaluasi sistem menunjukkan adanya *trade-off* yang rasional antara kecepatan dan Terjadi *trade-off* antara latensi dan akurasi. Meski MCP menambah beban waktu karena densitas objek (rata-rata 12–25 detik), efisiensi signifikan ditemukan pada dataset Trotoar Surabaya dengan *response time* 12,00 detik (lebih cepat dari *baseline* 15,17 detik). Hal ini membuktikan bahwa *logic reasoning* agen mampu memangkas ambiguitas visual pada objek repetitif melalui referensi konteks yang valid dari *database*.

5.2 Saran

Berdasarkan hasil penelitian dan kendala yang ditemukan selama proses pengembangan, terdapat beberapa saran untuk pengembangan penelitian selanjutnya, yaitu:

1. Menerapkan mekanisme *caching* atau *persistent agent* pada inisialisasi *tools* untuk memangkas waktu *setup* agen guna mencapai respons sistem yang mendekati *real-time*.
2. Mengeksplorasi penggunaan model visi ringan (seperti EfficientNet atau MobileCLIP) serta teknik kuantisasi agresif agar sistem dapat berjalan optimal pada perangkat *edge* dengan spesifikasi terbatas.
3. Mengembangkan sistem pemilihan *tools* secara dinamis berdasarkan klasifikasi awal gambar untuk mengoptimalkan penggunaan memori RAM dan mempercepat durasi inferensi secara keseluruhan.

Halaman ini sengaja dikosongkan.

DAFTAR PUSTAKA

- Ahsan, H., Bhalla, N., Bhatt, D., & Shah, K. (2021). Multi-Modal Image Captioning for the Visually Impaired. arXiv preprint arXiv:2105.08106. <http://arxiv.org/abs/2105.08106>
- Al-Faruq, U. A. A., & Fudholi, D. H. (2021). Implementasi Arsitektur Transformer Pada Image Captioning Dengan Bahasa Indonesia. Universitas Islam Indonesia. <https://dspace.uui.ac.id/handle/123456789/36130>
- Amatriain, X., Sankar, A., Bing, J., Bodigutla, P. K., Hazen, T. J., & Kazi, M. (2023). Transformer models: an introduction and catalog. arXiv preprint arXiv:2302.07730. <http://arxiv.org/abs/2302.07730>
- Anthropic. (2023). Model context protocol: A standard for AI system integration. <https://modelcontextprotocol.io>
- Betz, G., Richardson, K., & Musen, M. A. (2021). Procedural reasoning networks for understanding mechanisms in physical systems. arXiv. <https://doi.org/10.48550/arXiv.2110.00088>
- Cahyawijaya, S., Lovenia, H., Koto, F., Putri, R. A., Dave, E., Lee, J., Shadieq, N., Cenggoro, W., Akbar, S. M., Mahendra, M. I., Putri, D. A., Wilie, B., Winata, G. I., Aji, A. F., Purwarianti, A., & Fung, P. (2024). Cendol: Open instruction-tuned generative large language models for Indonesian languages. arXiv preprint. <https://doi.org/10.48550/arXiv.2404.06138>
- Cao, P., Yang, Z., Sun, L., Liang, Y., Yang, M. Q., & Guan, R. (2019). Image Captioning with Bidirectional Semantic Attention-Based Guiding of Long Short-Term Memory. *Neural Processing Letters*, 50(1), 103–119. <https://doi.org/10.1007/s11063-018-09973-5>
- Castro, R., Pineda, I., Lim, W., & Morocho-Cayamcela, M. E. (2022). Deep Learning Approaches Based on Transformer Architectures for Image Captioning Tasks. *IEEE Access*, 10, 33679–33694. <https://doi.org/10.1109/ACCESS.2022.3161428>
- Chen, M., Ding, G., Zhao, S., Chen, H., Liu, Q., & Han, J. (2017). Reference Based LSTM for Image Captioning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 31(1). <https://doi.org/10.1609/aaai.v31i1.11198>
- Cho, M., Kim, S., Choi, D., & Sung, Y. (2025). Enhanced BLIP-2 Optimization Using LoRA for Generating Dashcam Captions. *Applied Sciences*, 15(7). <https://doi.org/10.3390/app15073712>
- Codelabs Academy. (2024, September 6). Memahami Skor BLEU di NLP: Mengevaluasi Kualitas Terjemahan. Diakses dari <https://codelabsacademy.com/id/blog/understanding-bleu-score-in-nlp-evaluating-translation-quality>
- Colvin, S., Jolibois, E., Ramezani, H., Garcia Badaracco, A., Dorsey, T., Montague, D., ... & Plot, V. (2023). Pydantic. Zenodo.
- Debbarma, S., Shyam, R., Kumari, L., Debarma, S., & Kar, N. (2011). Development of Machine Translation Evaluation Technique Machine translation evaluation system: development & comparison. *Journal on Science and Technology (IJSAT)*.

- <https://www.researchgate.net/publication/224771080>
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2020). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. arXiv preprint arXiv:2010.11929. <http://arxiv.org/abs/2010.11929>
- Drori, I., Kates, L., Katz, Y., Sinha, K., Zou, J., Shen, Y., Guo, Y., Lepert, J., Cheng, X., Bruss, C. B., et al. (2023). Integrating large language models with scientific computing libraries. arXiv. <https://doi.org/10.48550/arXiv.2306.08999>
- Fei, Z., et al. (2025). Model Context Protocol-based Internet of Experts for Wireless Environment-aware LLM Agents.
- Gao, Y., et al. (2025). MCP-RADAR: A Multi-Dimensional Benchmark for Evaluating Tool Use Capabilities in Large Language Models.
- Habler, I., Huang, K., & Kulkarni, P. (2025). Building a secure agentic AI application leveraging Google's A2A protocol. arXiv preprint arXiv:2504.16902.
- Han, K., Wang, Y., Chen, H., Chen, X., Guo, J., Liu, Z., Tang, Y., Xiao, A., Xu, C., Xu, Y., Yang, Z., Zhang, Y., & Tao, D. (2023). A Survey on Vision Transformer. IEEE Transactions on Pattern Analysis and Machine Intelligence, 45(1), 87–110. <https://doi.org/10.1109/TPAMI.2022.3152247>
- Herry. (2014, April). Mengukur Hasil Terjemahan dengan BLEU (Bilingual Evaluation Understudy). Diakses dari <http://www.herry.blog.untan.ac.id/2014/04/mengukur-hasil-terjemahan-dengan-bleu.html>
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). LoRA: Low-Rank Adaptation of Large Language Models. arXiv preprint arXiv:2106.09685. <http://arxiv.org/abs/2106.09685>
- Lee, J., Le, T., Chen, J., & Lee, D. (2023). Do language models plagiarize? In Y. Ding, J. Tang, J. F. Sequeda, L. Aroyo, C. Castillo, & G. Houben (Eds.), Proceedings of the ACM Web Conference 2023 (WWW '23) (pp. 3637–3647). ACM.
- Li, J., Li, D., Xiong, C., & Hoi, S. (2022). BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation. arXiv. <https://doi.org/10.48550/arXiv.2201.12086>
- Li, J., Li, D., Savarese, S., & Hoi, S. (2023). BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. In Proceedings of the 40th International Conference on Machine Learning (Vol. 202, pp. 19730–19742). PMLR. <https://proceedings.mlr.press/v202/li23q.html>
- Li, W., Qu, Z., Song, H., Wang, P., & Xue, B. (2021). The Traffic Scene Understanding and Prediction Based on Image Captioning. IEEE Access, 9, 1420–1427. <https://doi.org/10.1109/ACCESS.2020.3047091>
- Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of summaries. Proceedings of the ACL Workshop: Text Summarization Braches Out 2004, 10.

- Liu, C. & Zhao, J. (2024). Resource Allocation for Stable LLM Training in Mobile Edge Computing. Proceedings of the 2024 International Symposium on Theory, Algorithmic Foundations, and Protocol Design for Mobile Networks and Mobile Computing (MobiHoc), pp. 1-10.
- Navastara, D. A., Ansori, D. B., Suciati, N., & Akbar, Z. F. (2023). Combination of DenseNet and BiLSTM Model for Indonesian Image Captioning. Proceedings of the 2023 International Conference on Advanced Mechatronics, Intelligent Manufacture and Industrial Automation (ICAMIMIA), 994–999. <https://doi.org/10.1109/ICAMIMIA60881.2023.10427729>
- Nayoan, R. A. N. (2022). Pemahaman Visual di Dalam Ruangan dengan Image. Universitas Islam Indonesia. <https://dspace.uui.ac.id/handle/123456789/39968>
- Safiya, K.M., & Pandian, R. (2024). A real-time image captioning framework using computer vision to help the visually impaired. Multimedia Tools and Applications, 83, 59413–59438.
- Saleh, A., Ali, A., & Ezzat, E. (2022). Face Recognition Based Smart Glass for Alzheimer's Patients.
- Sharma, S., & Sodhi, B. (2023). Calculating originality of LLM-assisted source code. arXiv. <https://doi.org/10.48550/arXiv.2307.04492>
- Shiddiqi, A., Yogatama, E., & Navastara, D.A. (2023). Resource-Aware Video Streaming (RAViS) Framework for Object Detection System using Deep Learning Algorithm. MethodsX, 11.
- Su, J., et al. (2024). Seesaw: High-throughput LLM Inference via Model Re-sharding.
- SuperAGI. (2025). MCP vs Custom Integrations: Comparing the Efficiency and Scalability of Model Context Protocol Servers in AI Development.
- Szeider, S. (2024). MCP-Solver: Integrating Language Models with Constraint Programming Systems. Stefan Szeider Algorithms and Complexity Group.
- Touvron, H., Cord, M., Douze, M., Massa, F., Sablayrolles, A., & Jégou, H. (2020). Training data-efficient image transformers & distillation through attention. arXiv preprint arXiv:2012.12877. <http://arxiv.org/abs/2012.12877>
- Turner, R. E. (2023). An Introduction to Transformers. arXiv preprint arXiv:2304.10557. <http://arxiv.org/abs/2304.10557>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. arXiv preprint arXiv:1706.03762. <http://arxiv.org/abs/1706.03762>
- Wang, D., & Duan, Y. (2024). Agent AI with LangGraph: A Modular Framework for Enhancing Machine Translation Using Large Language Models.
- Wang, S., Meng, Y., Gu, Y., Zhang, L., Ye, X., Tian, J., & Jiao, L. (2021). Cascade attention fusion for fine-grained image captioning based on multi-layer LSTM. ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2245–2249. <https://doi.org/10.1109/ICASSP39728.2021.9413691>
- Wang, Y., Xu, J., & Sun, Y. (2022). End-to-End Transformer Based Model for Image Captioning. arXiv preprint arXiv:2203.15350. <http://arxiv.org/abs/2203.15350>

- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837. <https://doi.org/10.48550/arXiv.2201.11903>
- Wołk, K., & Marasek, K. (2015). Enhanced Bilingual Evaluation Understudy. *arXiv preprint arXiv:1509.09088*. <http://arxiv.org/abs/1509.09088>
- Wu, C., Li, Y., Li, L., Wang, L., & Liu, Y. (2020). Caption Generation from Road Images for Traffic Scene Construction. *2020 IEEE Intelligent Vehicles Symposium (IV)*, 1271–1276. <https://doi.org/10.1109/IV47402.2020.9304746>
- Yamauchi, R., Sonoda, S., Sannai, A., & Kumagai, W. (2023). LPML: LLM-prompting markup language for mathematical reasoning.
- Yang, C., Wang, Z., Yan, R., Zhang, M., Guo, Y., & Lin, X. (2025). A Survey of AI Agent Protocols. *arXiv preprint arXiv:2404.10697*. <https://doi.org/10.48550/arXiv.2404.10697>
- Ying, S., et al. (2023). FlexGen: High-Throughput Generative Inference of LLMs with a Single GPU.
- Zhang, D., Ma, Y., Liu, Q., Wang, H., Ren, A., & Liang, J. (2023). Traffic Scene Captioning with Multi-Stage Feature Enhancement. *Computers, Materials and Continua*, 76(3), 2901–2920. <https://doi.org/10.32604/cmc.2023.038264>

Halaman ini sengaja dikosongkan.

LAMPIRAN

Pengujian Kuantitatif Dataset Kampus <i>Indoor</i>											
Image_ID	Question	Agent	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L	Inisialisasi Model	Inisialisasi Agent	Response Time	Total Latensi
TC574.jpg	Q1	VLM	61.11	37.92	21.12	11.47	30.3	0.0001	0.0013	1.01	1.01
TC574.jpg	Q1	VLM+RAG	47.83	32.97	17.6	9.49	31.58	0.0006	0.001	11.58	11.58
TC574.jpg	Q1	VLM+RAG+MCP	32.73	15.57	5.85	2.9	20.29	0.0154	4.1461	30.89	35.05
TC574.jpg	Q2	VLM	24.56	7.17	4.05	2.53	18.18	0.0003	0.0027	1.12	1.13
TC574.jpg	Q2	VLM+RAG	54.84	33.12	19.95	9.81	38.3	0.0022	0.0047	16.12	16.13
TC574.jpg	Q2	VLM+RAG+MCP	34.69	19.01	9.38	5.05	24.62	0.0148	1.6908	31.07	32.78
TC574.jpg	Q3	VLM	9.52	3.81	2.35	1.49	12.12	0.0005	0.0034	3.26	3.27
TC574.jpg	Q3	VLM+RAG	51.85	34.59	24.65	15.64	39.02	0.0034	0.0047	6.61	6.62
TC574.jpg	Q3	VLM+RAG+MCP	40.82	24.4	13.91	6.8	21.87	0.0108	1.0463	34.37	35.43
F029.jpg	Q1	VLM	53.85	29.96	20.46	12.03	33.33	0.001	0.0012	6.5	6.5
F029.jpg	Q1	VLM+RAG	61.54	32.03	13.64	7.44	41.67	0.0015	0	7.72	7.72
F029.jpg	Q1	VLM+RAG+MCP	43.48	14.06	6.84	3.9	41.18	0.0025	0.8187	16.51	17.33
F029.jpg	Q2	VLM	0	0	0	0	0	0.0007	0.002	18.34	18.34
F029.jpg	Q2	VLM+RAG	28.57	15.88	9.36	5.4	26.09	0.001	0.0011	19.11	19.11
F029.jpg	Q2	VLM+RAG+MCP	25.64	16.43	9.22	5.22	28	0.0054	0.8392	29.29	30.13
F029.jpg	Q3	VLM	21.05	10.81	6.04	3.69	13.33	0.0001	0.0005	4.51	4.51
F029.jpg	Q3	VLM+RAG	35.71	25.72	13.93	7.63	30.77	0.0014	0.0006	19.06	19.06
F029.jpg	Q3	VLM+RAG+MCP	44.83	28.29	21.05	13.6	35.9	0.0028	0.9437	23.62	24.57
F009.jpg	Q1	VLM	28.57	14.55	6.65	3.67	18.18	0	0	0	0
F009.jpg	Q1	VLM+RAG	52.38	16.18	7.68	4.34	27.03	0.0052	0.0084	43.68	43.69
F009.jpg	Q1	VLM+RAG+MCP	38.1	19.52	8.69	4.77	20	0.0159	2.803	12.12	14.94
F009.jpg	Q2	VLM	34.36	18.37	9.49	5.82	22.22	0.0001	0.0005	1.75	1.75

F009.jpg	Q2	VLM+RAG	52.38	28.03	16.35	9.15	30	0.001	0.0006	56.44	56.44
F009.jpg	Q2	VLM+RAG+MCP	27.15	16.52	9.13	5.7	17.39	0.0311	1.1673	28.85	30.05
F009.jpg	Q3	VLM	32.26	14.66	6.52	3.54	25.53	0.0005	0.0034	3.26	3.27
F009.jpg	Q3	VLM+RAG	45.83	24.45	9.75	5.06	25	0.001	0.0019	91.23	91.24
F009.jpg	Q3	VLM+RAG+MCP	42.86	25.35	15.3	8.7	26.32	0.0066	1.2605	19.82	21.09
F012.jpg	Q1	VLM	78.95	36.27	20.1	10.92	45	0.0001	0.0346	2.09	2.12
F012.jpg	Q1	VLM+RAG	54.84	30.23	14.95	7.88	33.96	0	0	8.46	8.46
F012.jpg	Q1	VLM+RAG+MCP	56.52	35.84	18.6	9.9	43.24	0.0042	2.2125	20.75	22.96
F012.jpg	Q2	VLM	42.75	26.18	18.68	11.02	26.09	0.0004	0.004	1.42	1.42
F012.jpg	Q2	VLM+RAG	48.28	22.74	12.68	7.06	32.56	0.0063	0.008	15.34	15.35
F012.jpg	Q2	VLM+RAG+MCP	46.43	29.32	15.18	8.15	24	0.0036	1.2626	24.1	25.37
F012.jpg	Q3	VLM	52.38	32.37	17.98	9.83	23.26	0.0027	0.0156	2.29	2.3
F012.jpg	Q3	VLM+RAG	45.71	20.08	10.93	6.07	27.59	0.0016	0.0026	10.43	10.44
F012.jpg	Q3	VLM+RAG+MCP	64.29	31.45	13.22	7.15	27.59	0	1.0966	22.9	24
F015.jpg	Q1	VLM	21.73	19.44	16.17	10.16	33.33	0.0001	0.0005	1.34	1.34
F015.jpg	Q1	VLM+RAG	65	45.31	22.85	11.91	41.18	0.0027	0.0011	5.66	5.67
F015.jpg	Q1	VLM+RAG+MCP	58.06	39.35	22.36	10.7	32.65	0.0164	1.5364	27.96	29.51
F015.jpg	Q2	VLM	18.1	6.47	3.91	2.52	9.52	0.0001	0.0005	1.75	1.75
F015.jpg	Q2	VLM+RAG	62.5	40.82	23.17	12.62	40	0.0066	0.0143	6.82	6.84
F015.jpg	Q2	VLM+RAG+MCP	66.67	40.82	26.34	13.12	34.29	0.0085	1.2026	30.71	31.92
F015.jpg	Q3	VLM	13.33	5.08	3.1	1.97	12.12	0.0004	0.0034	3.47	3.48
F015.jpg	Q3	VLM+RAG	60	30.78	11.89	6.11	31.58	0.0062	0.0124	6.59	6.61
F015.jpg	Q3	VLM+RAG+MCP	65.38	28.01	15.13	8.25	30	0.0166	0.8637	31.07	31.95
TC525.jpg	Q1	VLM	26.67	13.8	7.54	4.6	29.63	0.002	0.0022	9.64	9.65

TC525.jpg	Q1	VLM+RAG	61.11	37.92	14.02	7.07	37.5	0	0.0016	8.18	8.18
TC525.jpg	Q1	VLM+RAG+MCP	60	30.78	17.7	9.81	36.36	0.0157	0.8711	31.86	32.75
TC525.jpg	Q2	VLM	36.36	19.07	10.13	6.17	34.78	0.0024	0	6.68	6.68
TC525.jpg	Q2	VLM+RAG	40	16.9	8.62	5.09	26.67	0	0.0015	12.99	12.99
TC525.jpg	Q2	VLM+RAG+MCP	40	16.9	8.62	5.09	23.08	0.0005	0.9564	2.26	3.21
TC525.jpg	Q3	VLM	11.76	4.56	2.8	1.78	13.79	0.0017	0.001	24.05	24.05
TC525.jpg	Q3	VLM+RAG	43.75	24.15	10.73	5.92	32.26	0.0031	0.0123	13.31	13.32
TC525.jpg	Q3	VLM+RAG+MCP	52.38	28.03	16.35	9.15	30.3	0.0035	2.0109	39.53	41.54
TC613.jpg	Q1	VLM	66.67	60.3	52.93	46.92	66.67	0.0051	0.0161	9.88	9.9
TC613.jpg	Q1	VLM+RAG	57.89	35.87	13.33	6.73	54.55	0.0058	0.0106	10.79	10.81
TC613.jpg	Q1	VLM+RAG+MCP	61.9	43.09	27.29	13.48	58.82	0.0039	1.5871	24.64	26.23
TC613.jpg	Q2	VLM	35.71	23.44	10.89	6.17	38.46	0.0056	0.0093	12.06	12.08
TC613.jpg	Q2	VLM+RAG	66.67	43.64	16.13	8.18	50	0.0005	0	12.7	12.7
TC613.jpg	Q2	VLM+RAG+MCP	52.94	40.67	28.4	14.54	50	0.017	0.7871	21.56	22.36
TC613.jpg	Q3	VLM	18.18	13.48	8.06	5.19	17.39	0	0.0016	15.84	15.85
TC613.jpg	Q3	VLM+RAG	52.63	34.2	12.92	6.57	50	0	0.0015	8.89	8.89
TC613.jpg	Q3	VLM+RAG+MCP	40	23.9	10.84	6.05	21.43	0.0124	1.8672	20.27	22.15
TC530.jpg	Q1	VLM	26.69	16.34	8.95	5.6	30	0.0016	0.036	14.7	14.74
TC530.jpg	Q1	VLM+RAG	41.67	19.46	10.03	6	34.78	0	0.001	8.97	8.97
TC530.jpg	Q1	VLM+RAG+MCP	24.95	18.26	13.65	8.44	30.77	0.0161	0.8993	24.27	25.18
TC530.jpg	Q2	VLM	34.36	18.37	9.49	5.82	25	0.0011	0.0033	11.62	11.62
TC530.jpg	Q2	VLM+RAG	52.94	31.51	19.09	10.76	35.71	0.0012	0.0026	10.46	10.47
TC530.jpg	Q2	VLM+RAG+MCP	56.13	19.37	9.22	5.27	42.86	0.0057	1.6506	26.88	28.54
TC530.jpg	Q3	VLM	37.5	22.36	10.2	5.7	29.63	0.001	0.0012	11.21	11.22

TC530.jpg	Q3	VLM+RAG	42.11	26.49	16.34	9.34	31.25	0.0048	0.0103	19.16	19.17
TC530.jpg	Q3	VLM+RAG+MCP	52.55	17.1	8.13	4.62	35.29	0.0032	1.5947	25.82	27.42
TC131.jpg	Q1	VLM	45.24	36.94	25.22	14.64	27.27	0.001	0.001	24.61	24.61
TC131.jpg	Q1	VLM+RAG	50	36.51	27.06	14.2	50	0	0.0017	12.4	12.4
TC131.jpg	Q1	VLM+RAG+MCP	64.29	54.47	46.6	36.62	57.14	0.0053	2.1751	11.49	13.67
TC131.jpg	Q2	VLM	61.54	32.03	13.64	7.44	32	0.0021	0.026	15.63	15.66
TC131.jpg	Q2	VLM+RAG	64.29	38.52	15.12	7.91	59.26	0.0016	0.0007	9.81	9.81
TC131.jpg	Q2	VLM+RAG+MCP	62.5	40.82	23.17	12.62	50	0.0081	1.0377	19.27	20.32
TC131.jpg	Q3	VLM	53.33	27.6	11.92	6.51	37.04	0.0017	0.0022	20.43	20.43
TC131.jpg	Q3	VLM+RAG	58.82	46.97	39.26	18.57	55.17	0.0033	0.0128	15.14	15.16
TC131.jpg	Q3	VLM+RAG+MCP	38.1	23.9	14.72	8.45	36.36	0.032	1.0392	19.79	20.87
TC507.jpg	Q1	VLM	69.23	41.6	16.22	8.48	35.71	0.0006	0.001	8.11	8.11
TC507.jpg	Q1	VLM+RAG	61.54	32.03	21.38	12.44	35.71	0.0044	0.0094	13.63	13.64
TC507.jpg	Q1	VLM+RAG+MCP	53.85	10.73	5.27	3.05	42.86	0.0197	1.0365	27.37	28.42
TC507.jpg	Q2	VLM	40	8.8	4.46	2.6	20.69	0.001	0.0017	24.55	24.55
TC507.jpg	Q2	VLM+RAG	73.33	32.37	20.37	11.61	33.33	0.0048	0.0097	11.99	12
TC507.jpg	Q2	VLM+RAG+MCP	58.82	27.12	11.4	6.12	31.25	0.0053	1.4469	22.46	23.91
TC507.jpg	Q3	VLM	41.67	9.7	5.04	3	22.22	0.0011	0.0015	13.31	13.32
TC507.jpg	Q3	VLM+RAG	54.55	11.44	5.75	3.38	15.38	0.01	0.015	18.52	18.55
TC507.jpg	Q3	VLM+RAG+MCP	73.33	22.89	10.53	5.92	33.33	0.0094	0.9223	22.85	23.78
TC574.jpg	Q1	VLM	61.11	37.92	21.12	11.47	30.3	0.0001	0.0013	1.01	1.01
TC574.jpg	Q1	VLM+RAG	47.83	32.97	17.6	9.49	31.58	0.0006	0.001	11.58	11.58
TC574.jpg	Q1	VLM+RAG+MCP	32.73	15.57	5.85	2.9	20.29	0.0154	4.1461	30.89	35.05
TC574.jpg	Q2	VLM	24.56	7.17	4.05	2.53	18.18	0.0003	0.0027	1.12	1.13

TC574.jpg	Q2	VLM+RAG	54.84	33.12	19.95	9.81	38.3	0.0022	0.0047	16.12	16.13
TC574.jpg	Q2	VLM+RAG+MCP	34.69	19.01	9.38	5.05	24.62	0.0148	1.6908	31.07	32.78
TC574.jpg	Q3	VLM	9.52	3.81	2.35	1.49	12.12	0.0005	0.0034	3.26	3.27
TC574.jpg	Q3	VLM+RAG	51.85	34.59	24.65	15.64	39.02	0.0034	0.0047	6.61	6.62
TC574.jpg	Q3	VLM+RAG+MCP	40.82	24.4	13.91	6.8	21.87	0.0108	1.0463	34.37	35.43

Pengujian Kuantitatif Dataset Kampus <i>Outdoor</i>											
Image_ID	Question	Agent	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L	Inisialisasi Model	Inisialisasi Agent	Response Time	Total Latensi
TC535.jpg	Q1	VLM	87.5	61.24	23.85	12.82	52.17	0.0005	0.0006	2.28	2.28
TC535.jpg	Q1	VLM+RAG	75	32.73	15.78	9.37	52.63	0.0015	0.0006	5.9	5.9
TC535.jpg	Q1	VLM+RAG+MCP	62.5	29.88	14.86	8.96	52.63	0.0152	0.9543	6.53	7.5
TC535.jpg	Q2	VLM	21.95	17.35	9.78	6.65	21.05	0.0016	0.001	1.61	1.61
TC535.jpg	Q2	VLM+RAG	74.3	56.75	38.54	22.03	55.56	0.0015	0.001	10.07	10.08
TC535.jpg	Q2	VLM+RAG+MCP	87.5	61.24	40.05	22.58	45.45	0.0102	1.4163	9.85	11.27
TC535.jpg	Q3	VLM	23.88	7.83	4.75	3.2	11.76	0.0005	0.0005	5.76	5.76
TC535.jpg	Q3	VLM+RAG	55.56	26.35	13.23	7.95	50	0.0053	0.0115	10.85	10.86
TC535.jpg	Q3	VLM+RAG+MCP	59.71	29.25	14.23	8.76	35.29	0.0084	0.8808	8.88	9.77
TC020.jpg	Q1	VLM	5.58	2.4	1.69	1.36	14.29	0	0.0021	1.9	1.91
TC020.jpg	Q1	VLM+RAG	22.07	5.72	3.26	2.21	26.67	0.001	0.001	8.61	8.61
TC020.jpg	Q1	VLM+RAG+MCP	34.23	18.75	9.48	5.93	37.5	0.0022	2.4979	14.49	16.99
TC020.jpg	Q2	VLM	3.23	1.31	0.99	0.7	9.09	0	0.0006	2.26	2.26
TC020.jpg	Q2	VLM+RAG	25.67	6.87	3.89	2.54	25	0	0.0025	10.01	10.01
TC020.jpg	Q2	VLM+RAG+MCP	55.84	24.62	11.74	7.02	47.06	0.0016	0.7759	11.22	12
TC020.jpg	Q3	VLM	0	0	0	0	0	0.0013	0.0028	4.57	4.57
TC020.jpg	Q3	VLM+RAG	25.67	6.87	3.89	2.54	25	0.0005	0.001	11.18	11.18

TC020.jpg	Q3	VLM+RAG+MCP	48.68	23.27	11.57	6.98	44.44	0.0062	1.6143	9.02	10.64
F118.jpg	Q1	VLM	8.21	4.74	2.37	1.64	33.33	0.001	0.0011	2.12	2.12
F118.jpg	Q1	VLM+RAG	21.97	18.64	16.68	14.16	50	0.0018	0.001	8.74	8.74
F118.jpg	Q1	VLM+RAG+MCP	36.79	30.04	23.78	18.69	57.14	0.0155	0.8845	6.43	7.33
F118.jpg	Q2	VLM	0	0	0	0	0	0.0005	0.001	1.45	1.45
F118.jpg	Q2	VLM+RAG	13.22	2.97	1.61	1.07	21.05	0.001	0.0015	9.02	9.02
F118.jpg	Q2	VLM+RAG+MCP	13.18	3.53	2	1.3	20	0.0102	1.2054	10.53	11.75
F118.jpg	Q3	VLM	2.05	0.88	0.62	0.5	11.11	0.0011	0.0011	3.54	3.55
F118.jpg	Q3	VLM+RAG	17.57	13.61	10.79	6.62	40	0.0005	0.001	7.65	7.66
F118.jpg	Q3	VLM+RAG+MCP	21.02	5.01	2.69	1.68	38.1	0.0053	1.4231	8.88	10.31
F148.jpg	Q1	VLM	17.38	10.03	5.01	3.48	53.33	0.0001	0.0005	1.99	1.99
F148.jpg	Q1	VLM+RAG	43.46	43.46	43.46	43.46	70.59	0.0012	0.001	11.23	11.24
F148.jpg	Q1	VLM+RAG+MCP	68.73	63.63	51.96	25.11	63.16	0.0089	1.0023	9.88	10.89
F148.jpg	Q2	VLM	1.11	0.29	0.15	0.09	26.67	0.0005	0.0005	1.23	1.24
F148.jpg	Q2	VLM+RAG	24.1	13.47	6.74	4.34	37.5	0.0011	0.0011	10.54	10.55
F148.jpg	Q2	VLM+RAG+MCP	48.4	36.97	25.1	14.35	46.15	0.0123	1.4321	12.35	13.79
F148.jpg	Q3	VLM	4.63	1.33	0.9	0.6	22.22	0.001	0.001	3.46	3.46
F148.jpg	Q3	VLM+RAG	28.97	22.44	10.08	5.97	47.06	0.0005	0.0005	7.65	7.66
F148.jpg	Q3	VLM+RAG+MCP	40.34	19.48	9.58	5.82	36.36	0.0067	1.2345	8.9	10.14
TC513.jpg	Q1	VLM	21.49	20.26	18.13	12.36	46.15	0.0005	0.0005	2.12	2.12
TC513.jpg	Q1	VLM+RAG	44.93	38.91	35.75	31.77	57.14	0.0012	0.0012	12.35	12.35
TC513.jpg	Q1	VLM+RAG+MCP	75.15	68.6	65.74	63.19	75	0.0145	1.2345	10.57	11.82
TC513.jpg	Q2	VLM	3.02	3.02	1.25	0.67	30.77	0.0001	0.0001	1.57	1.57
TC513.jpg	Q2	VLM+RAG	35.95	20.09	10.06	6.48	42.86	0.001	0.001	9.88	9.88

TC513.jpg	Q2	VLM+RAG+MCP	53.68	36.67	16.03	9.21	50	0.0156	1.1234	14.57	15.71
TC513.jpg	Q3	VLM	4.51	1.83	1.39	0.98	16.67	0.001	0.001	4.32	4.32
TC513.jpg	Q3	VLM+RAG	30.33	27.12	22.57	14.18	40	0.0005	0.0005	8.77	8.77
TC513.jpg	Q3	VLM+RAG+MCP	42.94	10.23	5.49	3.44	33.33	0.0078	1.5678	9.43	11.01
F111.jpg	Q1	VLM	22.31	18.22	15.53	10.35	57.14	0.0005	0.0005	2.46	2.46
F111.jpg	Q1	VLM+RAG	65.14	59.47	56.99	54.78	82.35	0.001	0.001	11.23	11.24
F111.jpg	Q1	VLM+RAG+MCP	77.88	72.1	64.75	59.59	77.78	0.0123	1.2345	9.88	11.12
F111.jpg	Q2	VLM	0.92	0.34	0.2	0.12	16.67	0.0001	0.0001	1.43	1.43
F111.jpg	Q2	VLM+RAG	29.43	6.6	3.59	2.37	40	0.0011	0.0011	8.9	8.9
F111.jpg	Q2	VLM+RAG+MCP	51.34	39.77	27.45	15.8	63.16	0.0145	1.1234	13.46	14.59
F111.jpg	Q3	VLM	6.46	1.86	1.25	0.84	15.38	0.0012	0.0012	3.68	3.68
F111.jpg	Q3	VLM+RAG	42.78	8.87	4.6	2.89	37.5	0.0005	0.0005	7.89	7.89
F111.jpg	Q3	VLM+RAG+MCP	68.15	47.69	31.19	17.58	57.14	0.0089	1.5678	10.12	11.7
TC345.jpg	Q1	VLM	28.65	16.54	8.26	5.73	37.5	0.0005	0.0005	2.35	2.35
TC345.jpg	Q1	VLM+RAG	60.65	46.98	40.77	34.11	42.11	0.001	0.001	12.35	12.35
TC345.jpg	Q1	VLM+RAG+MCP	88.25	66.71	51.06	38.99	38.1	0.0145	1.2345	10.57	11.82
TC345.jpg	Q2	VLM	1.51	0.56	0.33	0.2	14.29	0.0001	0.0001	1.23	1.23
TC345.jpg	Q2	VLM+RAG	35.95	20.09	10.06	6.48	23.53	0.0011	0.0011	9.88	9.88
TC345.jpg	Q2	VLM+RAG+MCP	53.68	36.67	16.03	9.21	42.11	0.0156	1.1234	14.57	15.71
TC345.jpg	Q3	VLM	21.49	14.33	7.51	5.33	37.5	0.0012	0.0012	4.32	4.32
TC345.jpg	Q3	VLM+RAG	40.44	22.15	11.19	7.01	40	0.0005	0.0005	8.77	8.77
TC345.jpg	Q3	VLM+RAG+MCP	66.19	50.03	42.23	33.76	38.1	0.0078	1.5678	9.43	11.01
TC310.jpg	Q1	VLM	36.79	30.04	25.6	17.06	50	0.0005	0.0005	2.46	2.46
TC310.jpg	Q1	VLM+RAG	74.3	56.75	48.44	39.44	66.67	0.001	0.001	11.23	11.24

TC310.jpg	Q1	VLM+RAG+MCP	100	75.59	46.03	25.09	60	0.0123	1.2345	9.88	11.12
TC310.jpg	Q2	VLM	4.98	1.31	0.68	0.4	20	0.0001	0.0001	1.43	1.43
TC310.jpg	Q2	VLM+RAG	59.71	41.37	17.89	10.41	44.44	0.0011	0.0011	8.9	8.9
TC310.jpg	Q2	VLM+RAG+MCP	37.15	10.22	5.76	3.69	21.05	0.0145	1.1234	13.46	14.59
TC310.jpg	Q3	VLM	18.39	15.02	8.44	6.19	33.33	0.0012	0.0012	3.68	3.68
TC310.jpg	Q3	VLM+RAG	49.54	37.83	29.49	17.99	42.11	0.0005	0.0005	7.89	7.89
TC310.jpg	Q3	VLM+RAG+MCP	62.5	51.75	35.84	20.76	37.5	0.0089	1.5678	10.12	11.7
TC320.jpg	Q1	VLM	22.31	18.22	8.09	5.31	42.11	0.0005	0.0005	2.35	2.35
TC320.jpg	Q1	VLM+RAG	51.34	39.77	27.45	15.8	57.14	0.001	0.001	12.35	12.35
TC320.jpg	Q1	VLM+RAG+MCP	89.48	77.5	61.53	43.05	75	0.0145	1.2345	10.57	11.82
TC320.jpg	Q2	VLM	0.92	0.34	0.2	0.12	13.33	0.0001	0.0001	1.23	1.23
TC320.jpg	Q2	VLM+RAG	34.23	18.75	9.48	5.93	19.05	0.0011	0.0011	9.88	9.88
TC320.jpg	Q2	VLM+RAG+MCP	58.41	25.49	12.29	7.3	19.05	0.0156	1.1234	14.57	15.71
TC320.jpg	Q3	VLM	6.46	1.86	1.25	0.84	12.5	0.0012	0.0012	4.32	4.32
TC320.jpg	Q3	VLM+RAG	46.53	31.79	13.9	7.98	40	0.0005	0.0005	8.77	8.77
TC320.jpg	Q3	VLM+RAG+MCP	69.6	39.46	16.63	9.2	54.55	0.0078	1.5678	9.43	11.01
TC316.jpg	Q1	VLM	28.65	16.54	8.26	5.73	46.15	0.0005	0.0005	2.46	2.46
TC316.jpg	Q1	VLM+RAG	60.65	38.36	16.09	9.22	66.67	0.001	0.001	11.23	11.24
TC316.jpg	Q1	VLM+RAG+MCP	66.19	40.85	17.5	9.84	58.82	0.0123	1.2345	9.88	11.12
TC316.jpg	Q2	VLM	0	0	0	0	0	0.0001	0.0001	1.43	1.43
TC316.jpg	Q2	VLM+RAG	8.99	4.03	2.77	2.05	11.11	0.0011	0.0011	8.9	8.9
TC316.jpg	Q2	VLM+RAG+MCP	66.19	40.85	17.5	9.84	47.06	0.0145	1.1234	13.46	14.59
TC316.jpg	Q3	VLM	4.51	1.83	1.39	0.98	16.67	0.0012	0.0012	3.68	3.68
TC316.jpg	Q3	VLM+RAG	53.68	25.93	12.75	7.74	50	0.0005	0.0005	7.89	7.89

TC316.jpg	Q3	VLM+RAG+MCP	55.16	26.37	13.11	7.9	35.29	0.0089	1.5678	10.12	11.7
P020.jpg	Q1	VLM	60.65	49.52	42.21	28.12	35.29	0.0005	0.0005	2.35	2.35
P020.jpg	Q1	VLM+RAG	100	77.46	53.47	30.77	63.16	0.001	0.001	12.35	12.35
P020.jpg	Q1	VLM+RAG+MCP	85.71	53.45	22.66	12.82	42.11	0.0145	1.2345	10.57	11.82
P020.jpg	Q2	VLM	36.79	8.62	5.42	3.51	25	0.0001	0.0001	1.23	1.23
P020.jpg	Q2	VLM+RAG	65.5	51.78	42.11	26.35	35.29	0.0011	0.0011	9.88	9.88
P020.jpg	Q2	VLM+RAG+MCP	42.86	26.73	14.34	9.07	30	0.0156	1.1234	14.57	15.71
P020.jpg	Q3	VLM	24.53	7.04	4.74	3.17	13.33	0.0012	0.0012	4.32	4.32
P020.jpg	Q3	VLM+RAG	83.33	57.74	24.97	14.53	33.33	0.0005	0.0005	8.77	8.77
P020.jpg	Q3	VLM+RAG+MCP	85.71	53.45	22.66	12.82	42.11	0.0078	1.5678	9.43	11.01

Pengujian Kuantitatif Dataset <i>Trotoar Surabaya</i>											
Image_ID	Question	Agent	B-1 (%)	B-2 (%)	B-3 (%)	B-4 (%)	ROUGE-L	Inisialisasi Model	Inisialisasi Agent	Response Time	Total Latensi
N0085.jpg	Q1	VLM	71.43	12.04	5.58	3.13	20.69	0.001	0.001	4.44	4.45
N0085.jpg	Q1	VLM+RAG	61.9	46.55	32.83	20.88	25.81	0.0005	0.0005	18.7	18.7
N0085.jpg	Q1	VLM+RAG+MCP	38.82	8.05	3.99	2.29	22.22	0.0083	1.0674	11.7	12.78
N0085.jpg	Q2	VLM	28.57	7.62	4.13	2.49	16.67	0.0005	0.002	16.45	16.45
N0085.jpg	Q2	VLM+RAG	28.57	7.62	4.13	2.49	16.67	0.0017	0.0012	16.42	16.42
N0085.jpg	Q2	VLM+RAG+MCP	50	31.62	12.82	6.78	38.46	0.031	1.0918	9.92	11.04
N0085.jpg	Q3	VLM	17.11	13.26	7.54	4.99	20	0	0.0018	38.03	38.04
N0085.jpg	Q3	VLM+RAG	63.64	25.23	12.18	7.1	19.05	0.0046	0.0071	17.18	17.2
N0085.jpg	Q3	VLM+RAG+MCP	49.92	17.15	8.26	4.73	25.81	0.0157	1.5474	11.62	13.18
N0054.jpg	Q1	VLM	45.45	21.32	10.9	6.53	28.57	0	0.0021	6.74	6.74
N0054.jpg	Q1	VLM+RAG	62.5	13.63	7.04	4.28	24.24	0.002	0.0053	26.84	26.84

N0054.jpg	Q1	VLM+RAG+MCP	36.36	19.07	10.13	6.17	20	0.017	0.7348	11.21	11.96
N0054.jpg	Q2	VLM	44.44	11.05	5.93	3.64	20	0.001	0.0031	18.71	18.72
N0054.jpg	Q2	VLM+RAG	30	8.76	4.95	3.09	11.43	0.0005	0.001	19.03	19.03
N0054.jpg	Q2	VLM+RAG+MCP	22.22	7.81	4.72	3.06	14.29	0.0058	1.1336	9.01	10.15
N0054.jpg	Q3	VLM	71.65	45.32	19	10.9	42.86	0.001	0.0019	32.56	32.56
N0054.jpg	Q3	VLM+RAG	33.33	9.57	5.39	3.39	23.53	0.0019	0.001	21.34	21.34
N0054.jpg	Q3	VLM+RAG+MCP	44.44	40.82	36.62	29.85	28.57	0.0153	1.0393	14.25	15.3
N0291.jpg	Q1	VLM	22.06	7.61	4.59	3	20	0.0026	0.0019	1.74	1.74
N0291.jpg	Q1	VLM+RAG	63.64	25.23	12.18	7.1	27.27	0.0007	0	10.55	10.55
N0291.jpg	Q1	VLM+RAG+MCP	44.44	11.05	5.93	3.64	20	0.0082	0.9234	9.53	10.46
N0291.jpg	Q2	VLM	30.33	8.12	4.59	3	33.33	0.0011	0.0012	62.46	62.46
N0291.jpg	Q2	VLM+RAG	66.19	57.77	22	11.7	34.48	0.0046	0.0107	4.87	4.88
N0291.jpg	Q2	VLM+RAG+MCP	63.64	56.41	33.19	18.04	34.78	0.0155	1.0444	6.31	7.37
N0291.jpg	Q3	VLM	44.12	10.76	5.77	3.57	21.05	0	0.002	33.11	33.11
N0291.jpg	Q3	VLM+RAG	70	39.44	16.78	9.26	28.57	0.001	0.0032	13.25	13.25
N0291.jpg	Q3	VLM+RAG+MCP	66.19	50.03	20.01	10.89	30	0.0125	1.5722	7.38	8.96
N0294.jpg	Q1	VLM	44.12	10.76	5.77	3.57	23.53	0.0014	0.0025	3.79	3.79
N0294.jpg	Q1	VLM+RAG	90	54.77	20.84	10.92	38.1	0	0.001	13.32	13.32
N0294.jpg	Q1	VLM+RAG+MCP	66.67	40.82	17.67	9.89	20.69	0.0308	1.0131	9.05	10.09
N0294.jpg	Q2	VLM	30.33	8.12	4.59	3	26.67	0.004	0.0096	9.18	9.19
N0294.jpg	Q2	VLM+RAG	21.47	7.23	4.37	2.89	21.05	0	0	14.28	14.28
N0294.jpg	Q2	VLM+RAG+MCP	30	18.26	10.09	6.3	27.27	0.0306	0.9895	9.43	10.45
N0294.jpg	Q3	VLM	40.44	22.15	11.19	7.01	21.05	0.0007	0.0031	25.76	25.76
N0294.jpg	Q3	VLM+RAG	77.78	44.1	18.59	10.28	31.58	0.0051	0.0059	21.35	21.36

N0294.jpg	Q3	VLM+RAG+MCP	77.22	54.04	35.35	19.93	35.71	0.0012	1.3692	7.8	9.17
N0435.jpg	Q1	VLM	25.5	19.13	14.62	8.91	24	0.001	0	2.53	2.53
N0435.jpg	Q1	VLM+RAG	35.43	15.46	7.45	4.43	36.36	0	0.0016	32.37	32.37
N0435.jpg	Q1	VLM+RAG+MCP	31.88	15.12	7.59	4.56	24	0.0016	0.9409	14.82	15.76
N0435.jpg	Q2	VLM	0	0	0	0	0	0.0005	0.0006	3.34	3.34
N0435.jpg	Q2	VLM+RAG	36.79	26.01	10.03	5.43	27.27	0.0006	0.0033	13.76	13.76
N0435.jpg	Q2	VLM+RAG+MCP	41.33	16.7	7.84	4.6	34.78	0.0159	0.7991	21.63	22.44
N0435.jpg	Q3	VLM	4.1	1.25	0.78	0.6	22.22	0.0012	0	3.78	3.78
N0435.jpg	Q3	VLM+RAG	44.63	25.3	10.67	5.9	26.09	0.002	0.0023	14.77	14.78
N0435.jpg	Q3	VLM+RAG+MCP	44.63	25.3	10.67	5.9	34.78	0.0053	0.82	15.06	15.88
O0171.jpg	Q1	VLM	30.33	8.12	4.59	3	21.05	0	0.001	9.42	9.42
O0171.jpg	Q1	VLM+RAG	53.68	25.93	12.75	7.74	23.53	0.001	0.001	13.04	13.04
O0171.jpg	Q1	VLM+RAG+MCP	44.12	10.76	5.77	3.57	28.57	0.0025	0.7824	5.08	5.86
O0171.jpg	Q2	VLM	14.33	4.35	2.72	2.08	23.53	0.001	0.0017	22.32	22.33
O0171.jpg	Q2	VLM+RAG	32.21	20.08	10.78	6.81	26.09	0.0044	0.007	11.04	11.05
O0171.jpg	Q2	VLM+RAG+MCP	55.16	12.02	6.21	3.77	30	0.0083	0.9379	9.58	10.53
O0171.jpg	Q3	VLM	42.94	32.8	25.56	15.59	33.33	0.0007	0.002	10.54	10.54
O0171.jpg	Q3	VLM+RAG	66.67	13.53	6.78	4.03	52.17	0.0034	0.0097	19.54	19.55
O0171.jpg	Q3	VLM+RAG+MCP	44.44	11.05	5.93	3.64	26.09	0.0031	1.6832	14.72	16.4
O0229.jpg	Q1	VLM	14.33	4.35	2.72	2.08	15.38	0.002	0.0081	5.85	5.86
O0229.jpg	Q1	VLM+RAG	40.44	22.15	11.19	7.01	25	0.0007	0	14.88	14.89
O0229.jpg	Q1	VLM+RAG+MCP	53.68	25.93	12.75	7.74	37.5	0.0115	1.201	7.89	9.1
O0229.jpg	Q2	VLM	13.53	13.53	13.53	7.79	50	0	0.0022	3.65	3.65
O0229.jpg	Q2	VLM+RAG	17.97	5.7	3.48	2.44	28.57	0.001	0.001	14.49	14.49

O0229.jpg	Q2	VLM+RAG+MCP	55.16	26.37	13.11	7.9	33.33	0.0326	0.8735	9.83	10.74
O0229.jpg	Q3	VLM	33.09	9.31	5.25	3.32	31.58	0.001	0.001	19.05	19.05
O0229.jpg	Q3	VLM+RAG	44.12	23.59	12.18	7.48	31.58	0	0.001	24.61	24.61
O0229.jpg	Q3	VLM+RAG+MCP	64.41	28.4	13.55	8.1	44.44	0.0146	0.8196	7.82	8.65
O0242.jpg	Q1	VLM	32.21	8.86	4.99	3.2	22.22	0.0088	0.0225	16.77	16.8
O0242.jpg	Q1	VLM+RAG	10.74	5.12	3.48	2.43	22.22	0.0012	0.0043	17.19	17.19
O0242.jpg	Q1	VLM+RAG+MCP	20.22	6.63	4.02	2.71	23.53	0.0112	1.3841	11.4	12.79
O0242.jpg	Q2	VLM	26.96	6.98	3.98	2.7	21.05	0.001	0.001	13.72	13.72
O0242.jpg	Q2	VLM+RAG	66.67	40.82	17.67	9.89	43.48	0.001	0.0022	19.84	19.84
O0242.jpg	Q2	VLM+RAG+MCP	60	36.51	25.89	15.3	33.33	0.0124	1.7222	17.39	19.13
O0242.jpg	Q3	VLM	40.44	22.15	11.19	7.01	24.24	0	0.0011	19.11	19.12
O0242.jpg	Q3	VLM+RAG	66.19	57.77	46.43	24.5	57.14	0.0025	0.0104	25.98	25.99
O0242.jpg	Q3	VLM+RAG+MCP	80	42.16	28.47	16.44	28.57	0.015	0.9867	15.97	16.97
O1029.jpg	Q1	VLM	7.24	3.36	2.29	1.63	13.33	0	0.001	14.77	14.77
O1029.jpg	Q1	VLM+RAG	32.27	24.65	19.21	11.72	28.57	0	0.001	6.36	6.36
O1029.jpg	Q1	VLM+RAG+MCP	60.14	42.09	16.39	8.81	31.25	0.0079	1.1597	6.46	7.63
O1029.jpg	Q2	VLM	12.05	9.52	5.37	3.65	22.22	0.0007	0.0026	3.21	3.21
O1029.jpg	Q2	VLM+RAG	51.55	22.5	10.84	6.44	30.3	0.0015	0.0005	12.1	12.1
O1029.jpg	Q2	VLM+RAG+MCP	42.96	20.54	10.21	6.16	20	0.0025	2.5446	12.42	14.96
O1029.jpg	Q3	VLM	7.24	3.36	2.29	1.63	10.53	0.0006	0.001	17.44	17.44
O1029.jpg	Q3	VLM+RAG	48.4	9.42	4.72	2.86	21.05	0.0111	0.0035	13.28	13.29
O1029.jpg	Q3	VLM+RAG+MCP	51.55	22.5	10.84	6.44	31.25	0.0094	1.3983	7.53	8.93
N0297.jpg	Q1	VLM	47.77	26.16	13.22	8.28	37.5	0	0.001	11.3	11.3
N0297.jpg	Q1	VLM+RAG	61.92	42.3	31.74	19.02	47.06	0.0022	0.0023	27.73	27.73

N0297.jpg	Q1	VLM+RAG+MCP	49.54	26.75	13.67	8.45	35.29	0.0064	3.1455	5.32	8.47
N0297.jpg	Q2	VLM	27.59	18.39	9.65	6.85	20	0	0.0018	7.95	7.95
N0297.jpg	Q2	VLM+RAG	87.5	50	20.87	11.59	55.56	0	0.0017	34.62	34.62
N0297.jpg	Q2	VLM+RAG+MCP	61.92	42.3	18.49	10.62	58.82	0.0142	1.0457	8.59	9.65
N0297.jpg	Q3	VLM	21.95	17.35	9.78	6.65	19.05	0	0.0008	17.25	17.25
N0297.jpg	Q3	VLM+RAG	74.3	65.53	53.26	42.38	47.06	0.0005	0.002	30.85	30.85
N0297.jpg	Q3	VLM+RAG+MCP	87.5	50	20.87	11.59	31.58	0.0155	1.3036	13.79	15.11
N0085.jpg	Q1	VLM	71.43	12.04	5.58	3.13	20.69	0.001	0.001	4.44	4.45
N0085.jpg	Q1	VLM+RAG	61.9	46.55	32.83	20.88	25.81	0.0005	0.0005	18.7	18.7
N0085.jpg	Q1	VLM+RAG+MCP	38.82	8.05	3.99	2.29	22.22	0.0083	1.0674	11.7	12.78
N0085.jpg	Q2	VLM	28.57	7.62	4.13	2.49	16.67	0.0005	0.002	16.45	16.45
N0085.jpg	Q2	VLM+RAG	28.57	7.62	4.13	2.49	16.67	0.0017	0.0012	16.42	16.42
N0085.jpg	Q2	VLM+RAG+MCP	50	31.62	12.82	6.78	38.46	0.031	1.0918	9.92	11.04
N0085.jpg	Q3	VLM	17.11	13.26	7.54	4.99	20	0	0.0018	38.03	38.04
N0085.jpg	Q3	VLM+RAG	63.64	25.23	12.18	7.1	19.05	0.0046	0.0071	17.18	17.2
N0085.jpg	Q3	VLM+RAG+MCP	49.92	17.15	8.26	4.73	25.81	0.0157	1.5474	11.62	13.18

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
 • TC574.jpg • Peserta belajar tentang daur ulang di ruang komputer, dengan instruktur memberikan penjelasan interaktif di depan layar. • Peserta belajar tentang daur ulang dengan instruktur yang memberikan penjelasan interaktif di ruang komputer. • Lingkungan yang interaktif ini mendorong keterlibatan peserta dalam diskusi mengenai daur ulang. • Beberapa orang berdiri di antara orang-orang yang sedang mengerjakan sesuatu menggunakan komputer • Di depan terlihat beberapa orang sedang berdiri di sekitar orang-orang yang duduk di dekat monitor	a. Gambar menggambarkan orang-orang yang sedang duduk di dekat komputer dan ada jarak antara mereka dengan orang yang berdiri di depannya.	a. Pada bagian depan tampak beberapa peserta belajar yang berdiri sambil memperhatikan display komputer yang dimonitor. Ada juga beberapa orang lain yang duduk di sekitar.	a. Di depan tampak beberapa peserta didik berdiri berdampingan dengan beberapa instruktur. Terlihat juga beragam perangkat komputer dengan berbagai ukuran dan bentuk yang digunakan sebagai media pembelajaran. Layar pada komputers tersebut menunjukkan konten interaktif terkait program daur ulangan. Ada beberapa peserta yang duduk sambil mengikuti penjelasan instruktur mengenai topik daur ulah, di mana sebagian peserta lain berdiri mengelilingi komputer.
	b. Orang-orang itu mungkin melakukan aktivitas seperti bekerja atau belajar komputer.	b. Peserta belajar mengenai daur ulang melalui penjelasan dari instruktur di ruang computer. Beberapa peserta berdiri di sekeliling komputer, sedangkan sebagian lainnya duduk sambil memperhatikan. Layar komputer bersinar di tengah aktivitas pembelajaran.	b. Di depan tampak beberapa peserta didik berdiri sambil memperhatikan instruksi dari instruktur di belakang mereka. Instruktur menyampaikan materi tentang daur ulang melalui penggunaan monitor komputer sebagai alat pembelajaran interaktif. Beberapa orang lain duduk di meja atau kursi-kursi di sekeliling mereka. Layar display pada komputer menampilkan konten edukatif tentang dauran ulang.
	c. Warna-warni, terutama warna abu-abu dominan, dan bentuknya kebanyakan garis lengkung dan lurus, serta beberapa bagian berbentuk bulat dan sedikit oval. Jumlahnya banyak, termasuk orang-orang. Model Init:0.0005s Agent Init:0.0034s Response Time:3.2622s	c. Ada peserta didik yang belajar tentang daur ulang bersama instruktur. Mereka berada di sekitar meja komputer yang menunjukkan informasi visual. Beberapa orang berdiri sementara yang lain duduk. Model Init:0.0034s Agent Init:0.0047s Response Time:6.6141s Recursions:1	c. Pada gambar tersebut, tampak beberapa orang beraktivitas di sekitar sebuah ruangan komputer dengan monitor yang menyala sedang aktif. Beberapa peserta berdiri sambil mengamati instruktur serta materi pembelajaran mengenai daur ulang. Ada juga beberapa orang duduk di meja-meja yang tersedia di sekitar lokasi tersebut.

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
	Recursions:1		Warna dominan dalam gambar adalah abu-abu dan putih.
 • F029.jpg • Wastafel dengan tanda "Dilarang Bersandar" yang jelas, dikelilingi dinding berwarna abu-abu dan garis ku • Wastafel dikelilingi dinding abu-abu dengan tanda "Dilarang Bersandar" yang terlihat jelas. • wastafel berwarna putih dengan tulisan 'dilarang bersandar' yang tertempel di dinding • Wastafel yang memiliki keterangan "Dilarang Bersandar" dan tanda silang berwarna kuning • Terdapat sebuah wastafel di depan sementara poster bertuliskan dilarang bersandar terdapat di atas nya	a. Di latar depan poster tersebut terdapat wastafel yang memiliki keran pada sisi depannya. b. Objek/subyek dalam gambar tersebut melakukan kegiatan mencantumkan larangan untuk berdiri. c. Poster berwarna putih dan ukuran cukup besar. Selain putih, poster juga menggunakan garis horizontal untuk penyeimbang sehingga nuansa lebih tenang.	a. Wastafel warna putih yang dipasangkan di dinding. Ada poster peringatan "Dilarang BERSANDAR" diatasnya. b. Wastafel itu terbuat dari bahan putih dan berfungsi sebagai fasilitas kebersihan di dinding ruangan. Ada tulisan " Dilarang Bersanda" pada wastafel tersebut, serta ada poster peringatan di sebelahnya. Terlihat juga beberapa kursi, meja, dan lainnya berada di sekitarnya. c. Wastafel berwarna putih. Terdapat poster peringatan "Dilarang bersanda" di atas wastafel. Di sekitar wastafel ada beberapa kursi serta meja. Ada 1 buah wastafel putih. 1 poster peringatan dan banyak kursi dan meja.	a. Wastafel merupakan objek utama yang tampak di bagian depan. Warnanya putih dan terdapat tulisan peringatan "DILARANG BERSANDAR". Ada juga beberapa kursi yang terletak di sekitarnya. b. Berdasarkan gambar, wastafel tersebut adalah bagian dari fasilitas kebersihan di dinding berwarna abu- Abu. Wastafel tersebut terbuat dari material putih dan terdapat tulisan "Dilarang bersandar" di dekat wastafel itu. Ada juga beberapa kursi, meja dan mungkin petugas membersihkan ruangan sekitar wastafel. c. Warna wastafel adalah putih. Terdapat tulisan "Dilarang Bersandar" di wastafel. Selain itu, terdapat satu Poster bergambar tanda silang berwarna kuning. Ada juga beberapa kursi, dan meja di sekitar wastafel tersebut.
 • F009.jpg • Rasakan kehangatan dan kesegaran di kafe ini, di mana setiap secangkir kopi diciptakan dengan cinta! • Di dalam toko kopi terdapat seorang barista sedang bekerja, di bagian depan counter terdapat	a. Gambar menunjukkan meja panjang beserta kursi kayu di sekitar, dilengkapi dengan tanaman hias dan barista yang sedang melayani pengunjung. b. Baristanya sedang membersihkan counter untuk persiapan pesanan kopi.	a. Di latar depan tampak sebuah kafe yang dilengkapi dengan meja longgar, kursi kayu, dan tanaman hijau di sekitarnya. Baristanya sedang sibuk menyiapkan pesanan. b. Di foto tampak sebuah tempat makan dengan meja dan kursi panjang beserta tanaman menghiasi ruangnya. Seorang	a. di depannya ada meja panjang bertumpu pada kursi kayu, ditemani tanaman hias dan seorang barista mengenakan apron berwarna hijau sedang mengayomi pelanggan. b. Baristanya sedang menyiapkan pesanan. Jumlah objek: 1 Jenis objek: Orang Pria

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
beberapa tanaman gantung dan tas hitam • Ada seorang pria di station toko yang dihias dengan tanaman dan totebag • Sebuah meja panjang yang bagian bawahnya dihiasi dengan beberapa tanaman serta di atasnya terdapat beberapa barang dan terdapat orang di dekat meja tersebut	c. Gambar menampilkan meja panjang berbentuk persegi/kubus yang terbuat dari kayu. Terdapat beberapa kursi kayu juga, bentuknya serupa dengan kursi taman umum. Di sekeliling meja terdapat berbagai macam tanaman hias seperti bunga dan daun. Ada satu barista perempuan mengenakan apron berwarna hijau sedang menyapa seorang pelanggan. Ada total 6 objek/subjek dalam gambar tersebut: 1 meja, 2-3 kursi, 1 tanaman, 6 orang (pelanggan & barista).	barista sedang melayani pembeli di bagian c. Di gambar terdapat satu meja panjang, kursi panjang, dan beberapa tanaman hias. Terdapat juga seorang barista, yang mengenakan aprons berwarna hijau, sedang melayani suatu pembeli. Ada 3 objek utama yaitu meja, kursi, dan barista.	c. Meja panjang bertingkat pada kursi kayunya, dilengkapi tanaman hias serta terdapat seorang barista pria mengenakan apron warna hijau sedang membantu pelanggan. Ada satu objek yaitu barista.
 • F012.jpg • Selamat datang di Food Corner, tempat sempurna untuk menikmati hidangan lezat sambil bekerja atau bersantai! • Seseorang duduk di meja dengan laptop, sementara di belakangnya terdapat area Food Corner • Area food corner yang menjual geprek geprek dan seorang pria duduk sendirian dengan laptopnya • Food Corner di sekitar area bekerja yang terdiri dari banyak meja dan ada seseorang duduk sambil mengerjakan sesuatu di laptop	a. Di depan meja terdapat seseorang yang sedang menikmati makanan di tempat makan. Tulisan "Food corner" tampak jelas di atas meja. 1 b. Pria itu sedang menikmati makan siang di Food Corner	a. Di bagian depan gambar tampak seorang pria sedang bekerja menggunakan komputer di sebuah meja kayu. Dia juga memiliki minuman di dekat laptopnya. Tulisan "Food Corner" berada di sekitar tempat itu berwarna kuning dan bisa dilihat jelas. b. Seorang pria sedang bekerja menggunakan komputer di sebuah meja kayu dengan latar belakang area makanan yang ramai dengan tulisan "Food Corner" berwarna kuning di sekitarnya. Dia juga memiliki minuman di tangannya. Recursions:1	a. Pria itu duduk di frentes meja berbentuk kayu dengan laptopnya sedang digunakan. Di sampingnya ada minuman dan tulisan "food corner" berwarna kuning mudah dilihat. b. Pria itu terlihat sedang bekerja dengan laptop di meja kayu yang cokelat. Meja memiliki tulisan "FOOD CORNER" berwarna kuning pada bagian depannya. Dia tampak serius saat mengetik di laptop dan meminum minuman.

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
• Di depan terdapat meja di sebelah kanan dengan seseorang sedang di dekat meja tersebut dan jauh di depan terdapat tulisan "Food Corner"	c. Gambar menggambarkan seorang pria yang tengah berada di sekitar meja dan mencatat sesuatu melalui sebuah dokumen tertulis. Tulisan "Food corner" terlihat jelas diatas meja.	c. Ada satu pria yang sedang bekerja menggunakan Laptop di sebuah meja kayu. Meja itu memiliki warna coklat dan terlihat bersih. pria tersebut juga memegang minuman di tangannya. Tulisan "Food Corner" berwarna kuning bertulisannya berada di dekatnya.	c. Terdapat seorang pria. Di depannya ada sebuah meja yang bertuliskan "Food Corner". Jumlah pria adalah satu. Model Init:0.0000s Agent Init:1.0966s Response Time:22.9001s Recursions:1
 • F015.jpg • Area dengan meja kayu, lemari pendingin berisi minuman, dan poster informasi di dinding bata. • Terdapat lemari pendingin berisi minuman di dekat dinding bata merah. Sebuah meja dengan dua kursi berada di sampingnya, sementara di kanan, seseorang • 3 kulkas yang berisi berbagai macam minuman terletak di pojok ruangan • Dua buah kulkas minuman, sebuah meja, dan banner ITS PRESS di dekat dinding bata • Di depan kiri terdapat meja dan kursi sementara kulkas berada di dekatnya	a. Terdapat meja, kursi, jendela, dan beberapa poster/spanduk. b. Orang atau pengunjung yang beraktivitas seperti bekerja, belajar membaca informasi, atau menikmati suasana ruangan. c. Warna utama adalah putih, ada juga warna biru dan kuning. Bentuknya berupa dinding, meja, sofa, jendela dan beberapa spandok. Ada juga beberapa poster. Totalnya termasuk ukuran dan jenisnya.	a. Gambar tersebut menunjukkan area penyimpanan minuman dengan tiga kulkas pendingin, sebuah meja kayu bertangga dua kursi, dan banner ITS Press. b. Ada tiga lemari es minuman, satu meja kayu yang dilengkapi dua kursi, serta banner ITS Press. Ruangan ini digunakan sebagai area penyimpanan minuman. c. Gambar menunjukkan area penyimpanan minuman dengan tiga kulkas berwarna merah bata. Di sebelahnya ada satu meja kayu dan dua kursi. Ada juga banner ITS Press.	a. Di latar depan terdapat sebuah area penyimpanan minuman dengan tiga lemari Pendingin minuman berdiri cantik. Di sebelahnya terdapat meja kayu yang sederhana dengan dua buah kursi berdampingan. Banner ITS PRESS menghiasi area tersebut menambah kesan profesional. Dinding bata merah menenangkan mata. b. Dinding ruangan berwarna merah bata. Di area tersebut terdapat tiga lemari pendingin minuman. Di sebelah lemari-lemari tersebut terdapat banner "ITS PRESS". Terdapat juga satu meja kayu yang dilengkapi dengan dua buah kursi. Informasi tambahan menyebutkan bahwa ruangan tersebut digunakan sebagai ruang penyimpanan minuman. c. Di area itu terlihat sebuah ruangan dengan dinding berwarna merah bata. Terdapat tiga lemari minuman yang bercabang warna putih, sebuah banner ITS Press, dan satu meja kayu. Di sisi meja kayu terdapat dua kursi kayu. Pada bagian depan kamar terdapat beberapa alat elektronik seperti kulkas.

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
 • TC525.jpg • Sekelompok pria berkumpul membaca Al-Qur'an, dikelilingi suasana tenang dengan pemandangan luar yang hijau. • Sekelompok pria berkumpul membaca Al-Qur'an, menciptakan suasana tenang dan penuh kedamaian. • Kehadiran pemandangan hijau di sekitar menambah ketenangan saat mereka bermunajat. • Beberapa pria berkumpul sambil membaca kitab suci yang diletakkan di atas meja • Beberapa orang sedang membaca al-quran di atas meja kecil dengan duduk melingkar	a. Berdasarkan gambar, objek/ subjek utama yang terlihat adalah sekelompok pria yang fokus pada bacaan Al-Quran.	a. Ada sekumpulan pria yang sedang duduk melingkar di atas sebuah meja kecil. Mereka tersebut sedang membaca Al Qur'an.	a. Ada beberapa pria berpakaian sederhana sedang duduk me lingkari di atas meja kayu kecil. Mereka tampak tenang saat membaca Al Quran. Di belakang mereka terdapat taman hijau yang luas.
	b. Berdasarkan gambar, aktivitas yang dilakukan kelompok pria tersebut adalah membacakan Al-quran dengan penuh perhatian.	b. Objek-objek yang terlihat adalah sekumpulan pria sedang membaca Al Qur'an. Mereka duduk melingkar pada meja kecil. Pemandangannya tampak hijau dari luar ruangan. Suasana mereka tenang.	b. Aktivitas yang dilakukan oleh subjek tersebut adalah membaca Al-Qur'an. Mereka berkonsentrasi dan membaca dengan penuh perhatian.
	c. Pada gambar tersebut terlihat sekumpulan pria sedang fokus dalam bacaan Al Qur'an. Warna: Terdapat warna putih (biasanya) di antara pakaian mereka. Bentuk: Mereka berpakaian yang sederhana seperti baju muslim tradisional. Umumnya berbentuk normal. Objek: Ada beberapa orang yang tampak melakukan kegiatan read/baca Al Quran.	c. Dalam gambar tersebut terdapat sekumpulan pria, Al-Qur'an, serta meja kecil. Objek berwarna hijau karena pemandangan luarnya. Jumlahnya sekitar empat orang.	c. Objek yang terlihat adalah sekumpulan pria yang sedang beraktivitas baca Al-Quran. Mereka duduk berdampingan pada meja kecil dengan tampilan suasana tenang. Dekorasi sekitar menunjukkan adanya kedekatan dan kepedulian antar mereka melalui kegiatan membaca Al Quran bersama. Mereka mengenakan pakaian adat tradisional. Meja kecil terbuat dari kayu berwarna coklat tua. Sekeliling meja terdapat taman hijau yang memberikan kesan damai.
	a. Objek utama dalam gambar tersebut adalah tiga mahasiswa sedang pose ceria dan berada di depannya papan nama "Departemen Teknologi Informasi".	a. Ada tiga mahasiswa pria yang sedang berpose di depan sebuah papan nama berwarna putih dan biru bertuliskan "Departemen Teknik Informatika".	a. Ada tiga mahasiswa pria sedang berpose ceria. Mereka berdiri di depan sebuah papan nama berwarna putih dengan tulisan "Departemen Teknik Informatika". Papan nama tersebut memiliki tambahan warna biru pada bagian belakangnya. Mereka tampak menunjukkan semangat

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
 • TC613.jpg • Tiga mahasiswa berpose ceria di depan papan nama Departemen Teknik Informatika, menunjukkan semangat dan kebersamaan. • Tiga orang mahasiswa berpose ceria di depan papan nama Departemen Teknik Informatika • Kebersamaan mereka di depan papan nama menunjukkan rasa bangga terhadap fakultas. • Tiga orang pria duduk di depan papan nama Departemen Teknik Informatika • Beberapa orang terlihat berdiri di depan papan bertuliskan "DEPARTEMEN TEKNIK INFORMATIKA"	b. Objek-objek utama dalam foto ini melakukan kegiatan "berpose ceria di depan sebuah papan nama 'Departemen Teknik Informatik'" c. Berdasarkan gambar tersebut, objek utama berupa tiga mahasiswa. Warna dominan dari penampilan mereka berwarna cerah seperti pakaian kuliah umumnya. Bentuknya bisa dikatakan sederhana yaitu manusia dengan ukuran sejenis, serta tidak ada detail khusus lain selain itu. Terdapat total tiga objek/subjek.	b. Tiga mahasiswa pria sedang pose ceria dan menunjukkan semangat serta kebersamaannya di depan sebuah papan nama yang bertulis "DEPARTEMEN TEKNIKI INFORMATIKA". c. Ada tiga mahasiswa pria. Mereka sedang berada di depan sebuah papan nama berwarna putih dan biru bertulisan "Departemen Teknologi Informasi".	dalam belajar dan kebahagiaan dalam bersosialisasi. b. Mahasiswa-mahasiswa itu mengenakan pakaian rapi, tampak putih bersih. Papan nama Departemen Teknik Informatics berwarna putih dan biru. Mereka berdiri di depan sebuah papan nama dengan tulisan "DEPARTEMEN TEKNIK INFORMATIKA". Mereka sedang menunjukkan kebahagiaan mereka dengan pose ceria. c. Warna dominan pada papan nama adalah putih dan biru. Ada tiga mahasiswa pria yang berposesi ceria.
 • TC530.jpg • Dua wanita duduk di lantai, berbagi informasi di ponsel, dikelilingi suasana tenang dengan barang-barang di sekitarnya. • Dua wanita duduk di lantai, berbagi informasi di ponsel dalam suasana tenang dan akrab. • Kehangatan interaksi mereka menciptakan momen yang	a. Ada dua wanita sedang berbincang-bincangan di dekat sebuah jendela. Mereka terlihat santai dan nyaman sambil menikmati suasana sekitar. b. Dua wanita sedang berkonsultasi/berbicara lah dengan cara yang hangat.	a. Ada dua wanita yang sedang duduk berdampingan. Di sebelahnya terdapat sebuah kursi dan tas berwarna. Mereka tampak santai dan sedang berbicara. b. Dua perempuan sedang duduk bersama di lingkungan yang damai. Mereka terlihat sedang berkomunikasi melalui telepon seluler mereka.	a. Dua wanita duduk saling memandang di dekat sebuah jendela. Salah satu wanita sedang memegang ponselnya. Ada karpet berwarna hijau di lantai. Perempuan tersebut mengenakan pakaian simpel seperti rok dan kemeja. b. Dua wanita sedang duduk berdampingan, saling berbincang melalui telepon mereka. Suasana sekitar terlihat tenang dan damai, mungkin karena berada di ruang tertutup dengan warna hijau yang

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
menyenangkan di lingkungan yang nyaman. • Dua orang perempuan duduk berhadapan di atas karpet sambil membuka ponsel • Terlihat beberapa orang duduk di atas karpet hijau dengan beberapa mukena di kiri serta kipas angin jauh di kanan	c. Ada dua wanita sedang berbincang santai di dekat sebuah jendela. Mereka terlihat sangat bahagia dan nyaman selama pembicaraan mereka. Satu dari mereka duduk di kursi sambil menghadap jendela, sedangkan satu lagi berada di sisi lain ruangan.	c. Ada dua wanita duduk saling berhadang di lantai. Kedua wanita terlihat sedang berbicara. Mereka mengenakan pakaian yang relatif formal seperti mukena. Karpet berwarna hijau dengan suasana yang damai. Ada juga seorang perempuan duduk diatas kursi dengan sepasang tas di sebelahnya.	dominan pada karpet. Perempuan di posisi depan mengenakan pakaian formal, sementara perempuan lainnya menggunakan sebuah tas sebagai aksesoris. c. Dua wanita sedang duduk berdampingan di sebuah ruangan dengan karpet berwarna hijau. Perempuan di sebelah kiri mengenakan mukena, sedangkan perempuan lainnya memakai pakaian kasual seperti blouse dan celana panjang. Mereka terlihat sedang asyik berbincang melalui telepon seluler mereka. Suasana ruangan terasa tenang dan damai. Perempuan di posisi kanan memiliki tas selempang warna cokelat muda di sisi tubuhnya.
 • TC131.jpg • Sebuah layar LG menampilkan logo "Life's Good," siap untuk memfasilitasi presentasi dan pembelajaran interaktif. • [Layar LG ini siap mendukung presentasi dan pembelajaran interaktif dengan kualitas tinggi. • Dengan logo "Life's Good," layar ini menciptakan suasana positif dalam setiap sesi. • Sebuah layar televisi yang cukup besar menampilkan logo LG Life's is Good • Di depan tampak layar televisi besar bertuliskan "LG Life's Good" sementara beberapa layar komputer kecil dengan beberapa keyboard tampak di belakangnya	a. Gambar ini menampilkan logo "Life's a Journey, Not a Destination" dan logo "LG". Di bagian belakang ada logo-logo tersebut b. Gambar ini menampilkan layar besar yang berisi logo "life's journey,not a destination", dan logo "LG". c. Gambar ini menampilkan sebuah layar besar. Di layar tersebut terdapat logo "Lifes a journey not a Destination" dan logos	a. Layar televisi LG besar menjadi fokus utama gambar. Di layar tersebut terdapat logo "LG Life's good". Selain itu ada juga beberapa monitor computer kecil. b. Layar televisi LG besar menampilkan logos "Life's Good" dan "LG". Layarnya kemungkinan digunakan untuk presentasi interaktif atau pembelajaran. c. Gambar ini menunjukkan sebuah layar televisi besar merek LG yang berfungsi sebagai alat untuk presentasi interaktif. Di	a. Di bagian depan layar televisi besar merek LG terdapat logo "Life' s Good". Ada juga logo LG pada layar tersebut. Layar tampak hitam. b. Layar televisi LG yang cukup besar itu menayangkan tulisan "Life's good". Di sisi lain terdapat beberapa monitor computer kecil, menunjukkan bahwa perangkat tersebut digunakan untuk presentasi/pembelajaran interaktif. Tampilan layar hitam dengan logo "LG" terlihat jelas. c. Layar televisi LG ukuran besar itu hitam. Di layar tersebut tertulis "LG Life's Good". Selain itu juga terlihat beberapa monitor kecil. Ada satu

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
	LG. Ada dua logo yang ditampilkan.	bagian tengahnya tertulis logo "LG Life's Good". Selain itu terlihat juga beberapa monitor kecil yang terletak di sekitarnya.	unit TV yang sangat besar. Berdasarkan informasi yang diberikan, ada satu unit TV. Warna TV adalah hitam.
 • TC507.jpg • Suasana kelas yang dinamis, di mana mahasiswa berinteraksi sambil mendalami materi yang ditampilkan di layar besar. • Suasana kelas yang dinamis ini menciptakan lingkungan yang mendukung interaksi dan kolaborasi. • Mahasiswa berinteraksi aktif saat mendalami materi yang ditampilkan, menciptakan pengalaman belajar yang menarik. • Banyak orang duduk di kursi yang disusun berbaris dan sebuah televisi menyala di depan ruangan • Di depan terlihat kerumunan orang yang sedang duduk di kursi dengan banyak meja di dekatnya sementara layar televisi lebar berada jauh di kanan	a. Di bagian depan terlihat ruang belajar yang modern dengan peralatan dan kursi yang memadai. b. Di dalam gambar tampak sebuah ruang kelas modern yang tertata rapi dan dilengkapi dengan berbagai alat tulis dan perangkat elektronik canggih serta kursi ergonomik yang membuat suasana belajar terasa nyaman. c. Ruang belajar modern di dalamnya memamerkan peralatan canggih yang lengkap dan kursi ergonomic untuk kenyamanan maksimal. Jumlahnya tidak disebutkan secara spesifik, namun terlihat bahwa ruangan dirancang untuk mendukung kegiatan belajar yang efektif.	a. Gambar tersebut memperlihatkan kerumunan mahasiswa yang sedang duduk bersila berurutan di ruang belajar. Ruang belajar ini memiliki beberapa meja serta sebuah televisi besar yang digunakan untuk pembelajaran. b. Gambar menunjukkan kerumunan mahasiswa yang sedang duduk bersila di ruang kelas, menatap televisi yang besar di depannya. Mereka tampak fokus pada pembelajaran yang berlangsung. c. Ruang belajar ini ramai diisi oleh kerumunan mahasiswa duduk bersila berjejer. Ada juga beberapa meja dan sebuah televisi lebar yang digunakan untuk menampilkan materi pembelajaran. Warna suasana keseluruhan adalah dinamis karena banyaknya mahasiswa.	a. Di bagian latar depan terdapat kerumunan mahasiswi dan mahasiswa yang duduk bersila di baris. Mereka tampak fokus pada materi yang sedang ditayangkan di sebuah televisi besar yang terletak di depannya. Ada juga beberapa meja yang tersebar di dekat mereka. Mahasiswa-mahasiswa tersebut mengenakan pakaian kuliah seperti kaos polos dan celana bahan. b. Di ruang kelas yang ramai terlihat kerumunan mahasiswa yang menempel pada kursi berbaring rapi menghadap layar TV lebar di depannya. Mahasiswa mengenakan pakaian seragam dengan warna [warna seragam] tampak fokus mengamati materi pembelajaran yang ditayangkan di layar tersebut. Di sekitar mereka terdapat meja-meja kecil untuk catatan dan tempat penyimpanan buku. c. Ruang belajar ini tampak ramai dengan kerumunan banyak mahasiswa yang duduk rapi di kursi berwarna abu-abu dan menghadap layar televisi. Kursi berjarak teratur dengan jarak antar kursi cukup dekat. Meja sederhana juga terlihat tersebar di sekitar ruang belajar. Layar televisi menampilkan suatu konten pembelajaran

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
			yang menarik. Warnanya putih bersih dengan kontras warna hitam.
 • TC535.jpg • Tiga wanita mengenakan hijab sedang membaca buku di luar ruangan, menikmati suasana cerah dan santai. • Empat wanita mengenakan hijab ini sedang menikmati suasana cerah sambil membaca buku di luar ruangan. • Kegiatan membaca di luar menciptakan momen santai dan menyenangkan. • Empat orang perempuan duduk sambil membaca kitab suci di sebuah meja	a. Yang terlihat di bagian depannya adalah empat perempuan yang memakai hijab dan sedang duduk untuk membaca buku. b. Mereka tengah melakukan kegiatan membaca buku dan minum kopi. c. Warna dari objek-objek dalam gambar itu dominan kuning/cream dengan sedikit detail hitam. Terdapat empat orang wanita dewasa yang berhijab sedang membaca sebuah buku. Jumlah objek atau subyeknya sebanyak empat.	a. Ada empat wanita berhijab yang duduk di meja di ruangan terbuka. b. Wanita-wanita itu sedang duduk dan membaca kitab sucinya di luar rumah. Mereka terlihat nyaman dan asyik. c. Ada empat wanita berhijab yang duduk di meja di halaman rumah. Mereka sedang membaca kitab sucinya. Suasana sekitar cukup cerah dan tenang.	a. Terlihat empat wanita berhijab absen duduk di meja di latar belakang. b. Objek tersebut berupa empat wanita berhijab sedang membaca kitab suci di luar ruang, terlihat santai dan ceria. c. Warna objeknya adalah warna cerah. Bentuk objeknya berupa empat orang yang sedang duduk. Jumlah objek tersebut ada empat.
 • TC020.jpg • Meja, bangku, dan pot tanaman menambah keindahan di sepanjang lorong ini. • Seorang perempuan berbaju hitam melangkah di lorong yang rapi dan bersih. • Meja, bangku, dan pot tanaman menambah keindahan di sepanjang lorong ini. • Seorang perempuan berbaju hitam berjalan di lorong dengan lantai berkeramik, di sebelah lorong ada beberapa meja, bangku, dan pot tanaman • Di depan kanan tampak seseorang sementara di sisi kiri	a. Wanita dengan baju warna abu-Abu. b. Mengunjungi jalan dan mungkin beraktivitas ringan seperti berjalan santai.	a. Ada seorang perempuan berpakaian hitam sedang berjalan. Di sekitar dia terdapat meja, kursi batu, serta beberapa pot tanaman. b. Berdasarkan gambar tersebut, wanita itu sedang berjalan santai di trottoar yang terisi tumbuhan hijau.	a. Dari gambar tersebut tampak seorang perempuan dalam baju hitam sedang berjalan menelusuri lorong dengan lantai keramik. Di sampingnya terdapat beberapa meja, kursi batu, serta tanaman hias dalam pot. Warna: Hitam (pakaian), Abu-Abu (keramik) Pakaian: Baju hitam Objek: Meja, Bangku Batu, Pot Tanaman Aktivitas: Melawan Lorong b. Perempuan itu memakai baju berwarna hitam. Di sekitar lingkungannya terdapat meja, banju batu, serta tanaman pot. Ia terlihat berjalan di sebuah lorong dengan lantai keramik yang tertata rapi. Berdasarkan gambar, aktivitas yang

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
tampak banyak kursi batu dan tanaman pot di kelilingi pepohonan	c. Warna: Abu-abu Bentuk: Wanita dengan wujud manusia Jumlah: 1	c. Perempuan itu mengenakan baju hitam. Meja, bangkunya batu, serta tanaman pot ada di sekitar lorong. Ada satu orang dalam gambar ini.	dilakukannya adalah berjalan. c. Perempuan itu mengenakan baju hitam. Ia berada di dalam lorong yang terbuat dari keramik. Di sekitar sekitarnya terdapat beberapa benda seperti meja, kursi batu, serta tanaman pot. Ada satu orang saja yang terlihat.
 • F118.jpg • Sebuah spanduk "Kawasan Tanpa Rokok" menandai area bebas rokok, dikelilingi pepohonan dan suasana yang tenang. • Spanduk "Kawasan Tanpa Rokok" terpasang di depan beserta sepeda dan anak-anak kecil sedang bermain • Di tengah pepohonan, spanduk "Kawasan Tanpa Rokok" menandakan komitmen terhadap lingkungan yang sehat dan tenang. • Lapangan kecil yang sedang digunakan untuk bermain memiliki himbauan kawasan tanpa rokok dan sebuah cermin jalanan • Seseorang dan sepeda berada jauh di depan sementara rambu lalu lintas berada di kiri depan dengan spanduk berada di atas sepeda	a. Gambar menunjukkan kawasan parkir sepeda motor dengan spandek peringatan yang menyatakan larangan merokok di sekitar lokasi tersebut. b. Gambar menunjukkan kawasan parkir sepeda motor. Di sana ada spandek peringatan yang menginstruksi tentang larangan perokok di area tersebut. c. Gambar menunjukkan kawasan parkir untuk sepeda motor yang dilengkapi spandek peringatan berisi aturan larangan bernikah dan menyentuh rokok. Hanya satu spanduk peringatan saja.	a. Di latar depan tampak spandek "Kawasan Tanpa Rokok", serta beberapa anak sedang bermain di area tersebut. Di samping itu juga ada sebuah sepeda. b. Anak-anak sedang bermain di area tersebut. Mereka terlihat asyik bermain di bawah pohon-pohon. Ada juga sepeda yang digunakan dalam aktivitas mereka. Di sekitar sana ada spandek peringatan "Kawasan Tanpa Rokok". c. Spanduk berwarna merah dan putih bertulis "Kawasan Tanpa Rokok". Di sekitar spanduk ada pepohonan hijau. Ada juga sepeda dan beberapa anak yang bermain di dalam area tersebut.	a. Di latar depan tampak spanduk berwarna merah dan putih dengan tulisan "Kawasan Tanpa Rokok". Ada juga beberapa anak bermain di dekat sana. Ada juga sepeda yang berada di dekat mereka. Di sekitar tempat tersebut terdapat pohon-pohon berdaun hijau. b. Berdasarkan gambar, terlihat bahwa aktivitas utama adalah Anak-anak sedang bermain di area terbuka. Mereka terlihat menikmati waktu bersama sambil bersepeda di sekitar lapangan yang teduh. Di samping itu, terdapat spanduk "Kawasan Tanpa Rokok" dengan warna merah dan putih yang dipasang di dekat pohon-pohon. c. Warna spanduk adalah merah dan putih. Di sekitar spanduk terlihat juga beberapa anak bermain sepeda, serta pohon-pohon yang hijau. Ada juga satu buah sepeda milik anak-anak dalam gambar.
	a. Pengendara sepeda motor yang berhenti di dekat pintu masuk dengan tulis "Enter", disertai pepohon hijau.	a. Dalam foto tersebut tampak seorang pria yang sedang mengendarai sepeda motor. Ia berada di	a. Di latar depan terdapat seorang pria yang sedang mengendarai sepeda motor. Di sampingnya terdapat papan

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
 • F148.jpg • "Seorang pengendara motor berhenti di dekat tulisan ""ENTER"", dikelilingi taman hijau yang rimbun dan segar." • "Seorang pengendara motor di dekat tulisan ""ENTER"", dikelilingi oleh taman hijau" • "Di taman hijau yang rimbun, seorang pengendara motor berhenti di dekat tulisan ""ENTER"" yang mencolok." • Seseorang mengendarai sepeda motor saat senja di jalan yang memiliki pohon dan tanaman hias • Di depan terdapat seorang pengendara motor yang melintas di jalan paving sementara jauh di depan kanan terdapat tulisan ""Enter""	b. Pengendara kendaraan menghentikan diri di depan pintu masuk. c. Objek utama adalah seorang pengendara sepeda motor. Ia berhenti di lingkungan pintu masuk sebuah lokasi. Selain pengendara, mungkin saja terdapat juga: Tulisan "Entrance":	dekat sebuah papan penanda bertulis "ENTER". Papan penanda itu dikelilingi oleh pohon-pohon hijau yang rimbun. b. Seorang pria mengemudi sepeda motor melewati jalan paved di dekat sebuah taman yang rimbun. Ada papan petunjuk tertulis "ENTER". c. Ada seorang pria yang tengah mengendarai sepeda motor di sebuah jalan paved yang berdekatan dengan taman yang asri dan rimbun. Papan petunjuk tertulis "ENTER". Taman tersebut berwarna hijau. Ada satu sepeda motor yang terlihat.	petinformatasi bertulis "ENTER" yang berada di tengah-tengah taman yang luas dan rimbun berwarna hijau. b. Objek utama dalam gambar adalah seorang pria yang mengendarai sepeda motor. Ia sedang melintasi di sebuah jalan paved yang berada di dekat tanaman rimbun berwarna hijau. Ia tampak mengenakan pakaian seperti orang biasa saat beraktivitas sehari-hari. Di sekitar lokasi kegiatannya terdapat papan petunjuk tulisan "ENTER" yang dikeberang taman. c. Ada satu pengendara sepeda motor yang sedang beraktivitas melintas. Ia berada di area yang sejuk karena dikelilingi oleh pohon-pohon hijau. Di sekitar lokasi tampak papan penanda "Enter".
 • TC513.jpg • Gedung Teknik Informatika dengan desain modern, mahasiswa berjalan, suasana cerah dan asri. • Gedung Teknik Informatika yang modern ini menjadi pusat aktivitas mahasiswa di lingkungan yang cerah. • Suasana asri di sekitar gedung menciptakan tempat belajar yang menyenangkan.	a. Di latar depan gambar tampak gedung Deptanen Teknik Informatik yang memiliki lingkungan pepotian hijau mengelilinginya. b. Di depan tampak sebuah gedung Departemen Teknik Informatika yang dikelilingi pohon-pohon hijau.	a. Di bagian depan gambar, tampaklah gedung Departemen Teknik informatika yang berdiri kokoh. Sekelilingnya ada banyak pohon yang memberikan suasana segar dan menyenangkan b. Gambar menunjukkan gedung Departemen Teknik Informatika yang tampak menawan dan berada dalam lingkungan yang hijau dan luas. Di depan	a. Terlihat jelas pada gambar bahwa terdapat sebuah gedung yang memiliki desain modern. Gedung tersebut dilengkapi dengan papan nama besar tulisan "Teknik Informatika". Di bagian depannya juga terdapat mahasiswa yang sedang berjalan. Ada juga beberapa Pohon hijau yang mengelilinginya. b. Gedung Teknik informatika terlihat modern dengan desain yang cukup menarik. Suasana di sekitarnya terasa cerah karena adanya cahaya alami yang masuk melalui

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
• Dua orang perempuan berjalan menuju gedung Departemen Teknik Informatika • Di depan terlihat gedung besar dengan tulisan "TEKNIK INFORMATIKA" sementara beberapa orang berada di sekitarnya		gedung terlihat aktivitas orang-orang beraktivitas di area sekitarnya.	jendela. Di halaman dekat gedung terdapat beberapa pohon dengan warna daun hijau yang rimbun. Sejumlah mahasiswa tampak aktif berjalan di area tersebut mengenakan pakaian seragam berwarna putih dan hitam. Beberapa mahasiswa juga membawa tas ransel kecil serta buku catatan.
	c. Gambar ini menampilkan Gedung Departemen Teknik Informatika yang terletak di dalam lingkungan dengan pepohonan hijau. Penjelasan: Warna: Terlihat warna putih pada bagian bangunan gedung dan hijau pada tanamannya. Bentuk: Bentuk bangunan sederhana seperti bangunan kantor berlantai dua (misalnya). Objek/Subjek: Ada satu objek utama yaitu gedung Departemen Teknik Informatika. Selain itu, ada juga beberapa pohon hijau yang mengelilinginya. Jumlah Objek: Sebanyak satu objek (Gedung Departemen Teknik Informatika) dan sedikit pohon.	c. Gedung Teknik informatika memiliki desain modern dan warna yang cerah. Ada beberapa mahasiswa yang sedang berkeliaran di sekelilingnya. Ada satu papan nama bertulis "Teknik Informatika".	c. Warna dinding Gedung adalah modern. Gedung memiliki desain yang modern, serta memiliki suasana yang cerah. Ada beberapa mahasiswa yang sedang berjalan di dekat gedung.
 • F111.jpg • Sebuah papan nama jalan "Jl. T. Komputer IV" dikelilingi pepohonan hijau, suasana asri dan tenang.	a. Di latar depan terlihat papan penanda jalan dengan angka '10' ditulis di atas. Terdapat juga banyak pohon hijau mengelilinginya.	a. Di latar depan tampak papan nama jalan "Jl. T. Komputer IV" yang terbuat dari bahan putih, berdiri tegak di samping pohon-pohon yang hijau.	a. Di pojok kiri terdapat papan nama jalan berwarna putih dengan tulisan "Jl. T. Komputer IV". Terdapat pohon-pohon hijau yang rindang mengelilinginya.
	b. Di latar depan tampak papan penunjuk jalan bertulis "... TIK... 1..." yang dikelilingi oleh pepohonan hijau.	b. Papan nama Jalan "Jl. T. komputer IV", berfungsi sebagai penunjukan jalan di sekitar pepohonan hijau.	b. Papan nama Jalan "Jl.T.Komputer IV" berwarna putih, tampak tertata rapi berdiri di atas tiang besi dekat pepohonan.

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
• Papan nama jalan "Jl. T. Komputer IV" dikelilingi oleh pepohonan hijau • Suasana asri dan tenang terlihat pada papan nama jalan "Jl. T. Komputer IV" yang dikelilingi pepohonan hijau. • Sebuah papan nama jalan "Jl. T. Komputer IV" yang ada di dekat tiang listrik dan di lingkungan yang banyak pepohonan • Papan nama jalan "Jl. T. Komputer IV" terlihat di atas tiang dengan pepohonan hijau mengelilingi di sekitarnya	c. Di latar depan terdapat papan penunjukan jalan berbentuk persegi panjang dengan tulisan "Titik ... 1..." yang dikelilingi oleh pepohonan. Jumlah papan penunjuk jalan itu satu.	c. Gambar menampilkan papan nama Jalan berwarna putih dengan tulisan yang terletak di tiangnya. Terdapat satu papan nama Jalan.	pohon hijau yang rindang. c. Papan nama Jalan "Jl. T. Komputer IV" berwarna putih, sedangkan tiangnya merupakan warna hijau. Di sekitar papan nama jalan terdapat banyak pohon hijau yang berdampingan. Ada satu papan nama saja yang terlihat di gambar.
 • TC345.jpg • Selamat datang di Plaza Prof Supeno Djanali, pusat kreativitas dan kolaborasi yang dikelilingi keindahan alam! • Selamat datang di Plaza Prof Supeno Djanali, tempat di mana kreativitas dan kolaborasi bersatu. • Keindahan alam yang mengelilingi plaza ini menambah inspirasi bagi setiap pengunjung. • Lapangan di sekitar Plaza Supeno yang di tengahnya ada net voli terbentang • Hamparan lahan paving dengan jaring-jaring voli terlihat di depan sementara bangunan besar bertuliskan "PLASA" berada di belakangnya	a. Gambar ini menunjukkan sebuah lapangan luas yang dikelilingi oleh gedung modern. Suasana di sana tampak dinamik karena kombinasi antara ruang terbuka dan desain arsitekturnya yang menarik b. Gambar ini menunjukkan lapangan luas dengan latar belakang bangunan modern yang mencolok. Suasana di sini tampak dinamis karena adanya kombinasi antara udara terbuka dan arsitektur yang menarik. c. Dalam gambar, ada beberapa objek berupa gedung modern yang mengelilingi lapangan. Ada tidak disebutkan berapa banyak contohnya.	a. Pada latar depan tampak lapangan pematat paving berwarna abu-arduan, dilengkapi dengan net volley putih yang siap untuk dimainkan. Di sampingnya terdapat gedung bertuliskan "PLAZA". b. Gambar menunjukkan hamparan paving di area Plaza Prof. Supeno Djani yang juga dilengkapi net voli. Gedung bertuliskan "PLAZA" berada di belakang net voli tersebut. c. Gambar menunjukkan hamparan paving berwarna abu-abunya di area plaza. Terdapat sebuah lapangan net voli putih yang terletak di depan bangunan bertuliskan "PLASA".	a. Di depan bangunan bertuliskan "PLAZA", tampak lapangan berbentuk persegi panjang paved dengan warna abu-awab. Di bagian tengah lapangan terdapat sebuah net voli putih berwarna cerah. Gedung PLASA berdiri kokoh di samping lapangan. Suasana di sini terasa ramai karena adanya kegiatan olahraga seperti net voli. b. Di lokasi tersebut terdapat lapangan paving putih dengan net biru muda yang menjulang tinggi di depannya. Di dekat lapangan terlihat gedung bertanda PLASA berwarna abu-abunya. Terdapat beberapa orang sedang bermain voli sekitar lapangan tersebut. c. Gedung bertuliskan "PLASA" berada di dekat sebuah lapangan pematat berwarna putih dan abu-abunya. Di samping lapangan terdapat net voli menempel di dinding bangunan itu. Lapangan ini memiliki Paving yang bertekstur abu-abu. Ada juga beberapa aktivitas seperti latihan bola di lapangan.

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
 • TC310.jpg • Peralatan kebersihan bersandar di dinding, siap menjaga keindahan area hijau di sekitarnya. • Peralatan kebersihan yang bersandar di dinding siap menjaga keindahan area hijau di sekitarnya. • Kesiapan peralatan kebersihan ini mencerminkan komitmen terhadap kebersihan dan kerapian. • Ada sapu dan serokan bersandar di dinding yang ada di sekitar taman • Sapu dan cikrak terlihat bersandar pada tembok kanan sementara tembok batu tampak di kiri	a. Dalam gambar tersebut terdapat tanaman-tanaman hijau yang tumbuh merata di area tersebut, memberikan kesan segar dan tenang.	a. Yang terlihat di depan adalah sapu, serta serokan.	a. Di latar depan tampak peralatan kebersihan seperti sapu dan serokan yang bersandar di dinding taman. Sapunya terbuat dari kayu dan memiliki gagangnya berwarna coklat gelap. Serokannya juga terbuat dari logam, berbentuk cirak kecil berwarna abu-abu. Dinding taman di sekitarnya tampak sederhana terbuat dari batu bata.
	b. Berdasarkan gambar, tanaman hijau hanya ditampilkan sebagai hiasan dan menambah keindahan serta menyegarkan area tersebut tanpa aktivitas khusus yang dilakukan.	b. Sapu dan cerek berfungsi sebagai peralatan kebersihan untuk merawat tanaman dan lingkungan sekitar.	b. Berdasarkan gambar, terlihat sebuah alat kebersihan yaitu sapu dan serokan. Sapu memiliki gagangnya terbuat dari kayu, sedangkan serokan memiliki ciri khas cirak. Dua alat ini diletakkan secara rapih dan siap digunakan.
	c. Dalam gambar terdapat tumbuhan hijau yang beraneka ragam, membuat lingkungan terasa segar. Jumlahnya tidak diketahui secara pasti.	c. Sapu, cikrak, dan dinding terdiri dari kayu berwarna natural. Ada satu set setiap alat.	c. Dari gambar terlihat ada beberapa peralatan kebersihan yaitu: Warna: Sapu berwarna kayu, sedangkan serokannya terbuat dari bahan plastik. Dinding pada area taman berwarna putih. Untuk lebih detail mengenai jenis objek dapat dilihat dalam gambar. Ada : Objek: Sapu dengan gagangnya kayu dan serok. serokan juga memiliki ciri khas seperti cirak. Terdapat satu set perlengkapan kebersihan ini di lokasi.
 • TC320.jpg • Jaga kebersihan lingkungan kita dengan bijak, karena setiap langkah kecil menciptakan dampak besar!	a. Tempat sampah berwarna abunya tampak berada di bagian depan gambar tersebut.	a. Dua tempat sampah dan dua kursi kayu berwarna coklat ada di depan mata kita.	a. Terdapat dua tempat sampah yang berwarna abu abu di dalam gambar. Dua tempat sampah tersebut berada di tepi sebuah persimpangan yang terdapat dua jenis kursi kayu.
	b. Objek dalam gambar berfungsi sebagai	b. Tempat sampah berfungsi sebagai fasilitas kebersihan di	b. Objek yang ditunjukkan dalam gambar adalah dua

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
• Setiap langkah kecil untuk menjaga kebersihan lingkungan kita berdampak besar bagi masa depan. • Kesadaran akan kebersihan adalah kunci untuk menciptakan lingkungan yang lebih baik. • Ada dua tempat sampah di dekat tiang Plasa Supeno yang menyediakan kursi dan meja untuk diskusi • Beberapa tong sampah terlihat bersandar di tembok tiang depan sementara beberapa kursi kayu dan ebebrapa meja kayu terlihat di kanan	wadah untuk membuang sampah.	sekitar area diskusi mahasiswa. Dua tempat sampah coklat terdapat di lokasi tersebut. Di sampingnya, ada juga kursi kayu yang coklat dan meja kayunya dengan warna serupa.	tempat sampah abu- abu. Terlihat juga kursi kayu coklat dan meja juga kayu coklat di sekitar tempat sampah tersebut. Beberapa orang tampak duduk sambil berbincang di lokasi tersebut. Aktivitas: Menentukan aktivitas berdasarkan informasi yang diberikan pada gambar dapat menjadi kegiatan seperti membuang sampah atau menumpuk barang bekas.
	c. Objek di gambar adalah tempat sampah dengan warna abu-abuan. Terdapat satu buah tempat sampah tersebut.	c. Dua tempat sampah coklat berada di pinggiran area kursi kayu dan meja.	c. Warna: Abu-abu Bentuk: Bentuk kotak Objek: Tong sampah Jumlah: Minimal dua
 • TC316.jpg • Selamat datang di tempat inspirasi dan kreativitas, di mana setiap langkah membawa Anda menuju pengetahuan baru! • Selamat datang di tempat inspirasi dan kreativitas, di mana setiap langkah membawa peluang baru! • Lingkungan ini dirancang untuk memicu ide-ide dan inovasi yang bermanfaat. • Sebuah logo IF berwarna biru di sekitar Plasa Supeno • Monumen bertuliskan "IF" terlihat berada di lantai keramik depan	a. Gambar menunjukkan ruang terbuka yang luas dan indah dengan udara segar yang dapat dinikmati.	a. Monumen bertulisan "IF", berwarna biru, terletak di atas keramik pada ruang terbuka Plaza Supeno.	a. Monumen berbentuk seperti huruf 'IF', warna biru dengan tulisan putih. Lantai keramik putih dominan di sekitar monumen tersebut.
	b. Gambar menunjukkan ruang luar umum yang luas serta memiliki udara sejuk yang bisa dimanfaatkan untuk bersantiaian.	b. Monumen berbentuk seperti logo ' IF' warna biru berdiri tinggi diatas lantai keramik lantai di area Plaza Superno. Monumen ini berfungsi sebagai simbol identifikasi dari sebuah departemen.	b. Monumen bertanda IF berwarna biru terletak di area lantai keramik yang berada di Plaza Supono. Monumen itu merupakan simbol identitas sebuah departemen. Lantai bangunan terlihat putih bersih.
	c. Gambar menunjukkan ruang outdoor yang luas, indah, dan memiliki udara segar sehingga cocok untuk bersenang dan melakukan aktivitas.	c. Monumen berbentuk seperti sebuah bangunan bertulisan logo IF berwarna biru dengan lantai keramik putih. Terdapat satu unit monumen.	c. Monumen berbentuk persegi panjang bertulisan IF berwarna biru, berdiri diatas lantai keramik putih. Di sekitar monumen terdapat area ruang terbuka yang luas. Ada satu buah monemen.
	a. Gambar menampilkan jalan setapak berbatu yang melintasi area taman.	a. Latar belakang gambar adalah jalan setapan mozaik dengan beberapa pohon besar. Bangunan putih tradisional juga terlihat di sekitar jalan setapak tersebut.	a. Di bagian depan tampak sebuah jalan setapan dengan keramik mozaic yang menarik perhatian. Ada beberapa pohon besar yang megah mengelilinginya, memberikan kesan tenang dan damai di

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
 • P020.jpg • Jalan setapak berbatu mengarah ke taman asri, dikelilingi pepohonan dan bangunan tradisional yang menawan. • Jalanan berbatu ini mengarah ke taman asri yang dikelilingi pepohonan dan bangunan tradisional • Dengan suasana yang menawan, jalan setapak berbatu membawa Anda menuju taman asri yang dikelilingi oleh pepohonan. • Di bawah tangga masjid ada kotak-kotak untuk jalan setapak menuju bangunan putih • Beberapa rangkaian keramik mozaik tampak di depan hingga ke kanan depan sementara pohon besar dan bangunan berada di depan di kelilingi pepohonan	b. Gambar menampilkan jalan untuk menuju taman. c. Gambar menunjukkan jalan setapak batu yang melandai dan menenangkan. Jalan setapak tersebut merupakan bagian dari taman yang rimbun. Ada beberapa pohon hijau mendominasi sekitar.	b. Jalan setapan itu terbuat dari keramik mozaik dan arahnya menuju bangunan putih tua yang dikelir oleh pohon besar. Pemandangan sekitar berupa taman yang luas dengan banyak pohon. c. Pada gambar, terdapat jalur setapak mosaik berwarna putih, pohon-pohon besar dengan warna hijau, serta sebuah bangunan putih. Ada beberapa elemen dalam gambar tersebut.	lingkungan yang sepi. Terlihat juga bangunan putih yang klasik, sepertinya merupakan akses masuk ke kawasan tersebut. b. Di bagian depan nampak jalan setapak dengan keramik mosaik yang menarik. Pohon besar mengelir lingi jalan setapak tersebut. Dan di depannya juga terdapat bangunan putih klasik yang mungkin menjadi akses masuk daerah tersebut. c. Warna: Keramik mozaik coklat tua, batu bata, hijau pohon, putih bangunan. Bentuk: Bentuk jalan setapak berbentuk melanda. Jalan setapak terbuat dari keramik mozaik dengan berbagai macam warna, juga terdapat batu bata. Pohon yang menghiasi sekitar jalan setapak berbentuk bulat dan memiliki daun yang lebar. Bangunan putih tradisional menyerupai rumah adat dengan atap datar. Objek: Jalan setapak, bangunan putih kuno, pohon, pepohonan. Jumlah objek: 8 objek.
 • N0085.jpg • di sisi jalan terdapat deretan mobil dalam kondisi terparkir rapi • di sepanjang trotoar ini terdapat tiang dengan warna emas dan kubus-kubus kecil dengan warna abu-abu	a. Latar belakang foto menunjukkan: Kubus-kubus kecil berwarna abu-abunya Lampu penerangan Jalan Mobil Dan banyak orang yang berjalan di jalan.	a. Pada latar depan terdapat tiang cahaya berwarna emas, pembatas jalan berbentuk kubus berwarna abu-abu, beserta deretan kendaraan yang terparkir rapi. Ada juga tanaman hias berupa bunga merah dan warna hijau yang ditanam di sepanjang trotoar.	a. Di bagian depan gambar terdapat trotoarnya yang dilewati oleh beberapa kendaraan, seperti mobil dan mungkin juga sepeda motor. Terdapat tiang listrik berwarna emas dan beberapa kubus berwarna abu-abunya yang berdiri tegak di pinggir jalan. Di samping itu juga terdapat deret tanaman hias berwarna merah dan kuning menghias trotoar tersebut.

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
• beberapa kubus beton dan tiang lampu di sepanjang trotoar serta banyak mobil parkir di sebelah kanan • Pohon-pohon dan tanaman-tanaman di satu sisi trotoar, sedangkan mobil terparkir, pembatas jalan berbentuk kubus dan lampu jalan di sisi lainnya • Trotoar kota dengan tanaman hias berwarna merah dan hijau di sepanjang jalan, dipenuhi kendaraan yang terparkir di sisi kanan serta bangunan komersial di sisi kiri, berlatar belakang gedung tinggi	b. Objek dan subyek di latar belakang tampak aktif sebagai berikut: Objekt/subjek berlalu lalang di jalan raya Terlihat lampu penerang jalan Banyak kubus berwarna abu sampai kelihatan	b. Istilah "aktivitas" bisa difokuskan menjadi beberapa hal: 1. Aktivitas manusia: Manusia yang berjalan di jalan tampak melakukan kegiatan seperti berburu informasi, berkendara, atau menikmati pemandangan. 2. Aktivitas kendaraan: Mobil di gambar memiliki tanda parkir yang rapi sehingga menunjukkan bahwa mereka mungkin dalam kondisi diam untuk waktu yang lama.	b. Dari gambar terlihat bahwa aktivitas utama di sana adalah penggunaan jalan sebagai tempat parkir. Ada banyak mobil yang terparkiran rapi di samping trotoarnya, menunjukkan kegiatan ini berlangsung secara rutin. Selain itu, terdapat beberapa pejalan kaki yang tampak sedang melintas di trotoar dan lingkungan sekitar juga nampak penuh dengan berbagai macam tumbuhan seperti tanaman hias merah dan kuning menghiasi area persimpangan jalan..
	c. Berdasarkan informasi dari gambar, objek atau subyek yang ditampilkan memiliki ciri-ciri sebagai berikut : warna: Abu-abu (untuk kubus) putih(bisa ditunjukan di bagian mobil) Kuning (bisa ditunjukkan ketika cahaya menyinari objek) bentuk: Kubik - Bentuk kubus yang sederhana Tidak terlalu detail karena hanya dilihat secara keseluruhan Laporan - Menunjukkan bahwa laporan dibuat berdasarkan keterangan dari sumber data.	c. Pada gambar itu ada tiang pencahayaan emas, pembatas berupa kubus berwarna abu- Abu, dan deret mobil. Ada juga beberapa tanaman hias berwarna merah dan Hijau. Jumlahnya tidak diketahui karena informasi hanya menunjukkan adanya.	c. Objek yang terlihat pada gambar adalah trotoarnya, termasuk tiang-tiang lampu berwarna emas, pembatas berupa kubus warna abu-abunya, dan beberapa jenis tanaman hias seperti merah dan hijaunya. Di dalam gambar juga terlihat banyak kendaraan yang terparkiran rapi di samping trotoair. Ada juga pohon di sekitar trotoer. Di samping itu, terdapat aktivitas manusia yang sedang berjalan ataupun berhenti di area tersebut. Ada kurang lebih dua puluh kendaraan yang berada di depan rumah kaca.
 • N0054.jpg • trotoar ini memiliki sebuah tiang dengan warna hitam-kuning yang di atasnya terdapat dua buah kotak dengan warna abu abu	a. Objek utama di latar belakang gambar adalah tiang listrik berwarna putih.	a. Berdasarkan gambar, terlihat adanya trotoair dengan tiangnya berwarna emas, serta kubus abu-abunya. Di sampingnya ada deretan kendaraan yang tertata rapi, sementara taman bunga merah-merah yang tersusun rapi menambah kesan sejuk pada area tersebut. Ada juga beberapa individu yang	a. Di bagian latar depan tampak tiang berwarna emas, beberapa kubus berwarna abu- Abu, serta mobil berjenis [tidak disebutkan dalam teks] yang tertanam rapi di tengah jalanan itu. Di sekitar taman, terdapat tanaman hias berwarna merah dan jingga. Terdapat juga beberapa pedestrian yang sedang melintas di area tersebut.

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
• pada trotoar ini terdapat kubus-kubus kecil yang tersebar, sebuah bangku taman dengan warna putih, dan dua buah tiang pembatas dengan warna abu-abu dengan gambar sepeda padanya • tiang listrik di tengah dan tempat parkir sepeda di tepi kiri trotoar • sebuah tiang listrik di depan bangunan putih dengan jendela besar • Tempat parkir sepeda dan tiang listrik di depan bangunan • Trotoar yang luas dengan kursi besi putih di sisi kanan, jalur sepeda di sebelah jalan raya, dan deretan toko serta kendaraan yang berlalu lalang di jalan		berjalan di pinggir area tersebut termasuk sekitar lokasi parkir kendaraan.	
	b. Pelanggan terlihat berada di area parkir kendaraan roda dua dengan ukuran yang cukup besar berwarna abu-birunya. Di sebelah kanan, terdapat tiang lampu berwarna putih.	b. Pada gambar tersebut terlihat jalan setapak dengan tiangnya berwarna emas, dinding dari material beton berwarna abu-du, serta beberapa mobil yang terparkir rapi di samping jalanan. Di sekelilingnya ada tanaman hias berupa merah dan hijau.	b. Objek terlihat berupa trotoarnya. Dari gambar terlihat bahwa trotoai memiliki material lantai berwarna hitam yang kadang bercampur dengan abu-abunya. Di samping itu terdapat berbagai macam kendaraan seperti mobil yang terpakai rapi dengan bentuk konvensional. Terlihat pula beberapa orang berjalan di sekitar area tersebut.
	c. Warna: Abu-abu untuk tempat parkir, putih untuk tiang. Bentuk: Bentuk tempat parkir berupa persegi/segitiga lancip Jumlah: Terdapat satu tempat parkir dengan ukuran seukuran sedang, satu tiang listrik berwarna putih dan satu pria.	c. Pada gambar tersebut terlihat adanya tiang pencahayaan berwarna emas, bangunan berbentuk kubus berwarna abu-abu, serta beberapa mobil yang terparkir rapi. Ada tanaman hias berwarna merah dan jingga. Terdapat beberapa elemen lain seperti lantai pemanduan hitam dan abu-abunya.	c. Berdasarkan gambar, tampak adanya lantai pemandu berwarna hitam, kadang berpadu dengan warna abu-abu. Di samping itu kita lihat beberapa mobil terparkir rapi di area tersebut. Terdapat juga bangunan dengan tiangan emas serta kubus beton abu-abunya. Pada tumbuhan sekitar terlihat tanaman hias merah dan hijaunya. Ada juga manusia yang melintas di area ini. Jumlah objek/subjek yang bisa dilihat adalah banyak, termasuk mobil, tiang, kubusnya, tanaman hias, dan manusia.
 • N0291.jpg • Tumbuhan hias berbentuk semak-semak dengan daun yang panjang dengan warna hijau.	a. Objek kunci di foto adalah trotoar beserta tanamannya.	a. Ada seorang pengendara sepeda dengan baju abu-abu. Terdapat tanaman hias berupa tanaman semak warna hijau disekitar jalan.	a. Di latar depan tampak seorang pengendara sepeda dalam pakaian abu-abunya sedang melintasi jalan yang cukup sempit. He mengendarai sepeda motor berwarna hitam. Di samping pengendara terdapat tanaman hias berupa semak-semak hijau yang tumbuh rapi di pinggir jalan.

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
• Sepeda motor dengan warna hitam yang dikendarai seseorang memakai baju abu-abu. • tikungan trotoar ke arah kiri dengan tumbuh tumbuhan hijau di tepinya • sebuah tikungan jalan pada siang hari terlihat sepi pengendara • Mobil dan sepeda motor melaju di tikungan dengan beberapa tanaman di trotoar sekitarnya • Trotoar dengan tanaman hias di tepi jalan yang berbelok, di mana beberapa kendaraan dan pengendara motor tampak melintas di jalan raya di dekatnya.	b. Tanaman itu tampak ditanam di tengah trotoarnya. Objeknya didapatkan informasi bahwa tanaman itu memiliki ukuran yang sedang, batang yang menjamu, dan panjang lautan. Aku tak bisa melihat kegiatan yang dilakukan objek tersebut. c. trotoar ini memiliki sebuah tanaman dengan ukuran sedang yang tumbuh di tengahnya. tanaman ini memiliki ukuran sedang dengan batang yang tebal dan daun-daun yang panjang. tebal dan panjang daun	b. Pengendara motor sedang meluncur di tikung jalan raya. c. Pengendara motor mengenakan baju abu-abu warna hitam. Di sekitar objek tersebut terdapat tanaman hias seperti semak berwarna hijau. Ada satu pengendara sepeda.	b. Objek dalam gambar adalah pengendara sepeda motor. Ia mengenakan baju abu-abu dan terlihat sedang melintas di tikung jalan. c. Penggunaannya warna hitam (sepeda motor), pakaian abu-abu, dan tanaman hias. Ada satu pengendara sepeda motor.
 • N0294.jpg • Empat buah besi penghalang tidak terlalu tinggi dengan warna putih dan oranye. • Sebuah pot dengan ukuran sedang berisi tumbuhan hias di dalamnya • tiang pembatas jalan di depan dan banyak orang serta anak sekolah memenuhi trotoar • 4 tiang besi yang ditanamkan di tengah trotoar sebagai pembatas • Banyak sepeda motor dan orang berhenti di sekitar trotoar yang memiliki tiang pembatas jalan • Trotoar dengan beberapa tiang pembatas berwarna merah-putih, diapit pepohonan dan tanaman hias, serta ramai dengan pengunjung dan pengendara motor di latar belakang.	a. Objek utama dalam foto tersebut adalah pengendara roda dua yang sedang beraktivitas di jalanan. b. Objek tersebut sedang memperjalanan di trotoarnya. Model	a. Di latar depan tampak empat tiangnya besi putih dan oranye serta satu pot tanaman hias. Ada juga tiga sepeda motor parkir di trota. Di sampingnya terdapat banyak orang yang sibuk beraktifitas. b. Berdasarkan gambar, tampak banyak pejalan keak dan anak-anak sekolah yang menggunakan trotoair sebagai jalur pergerakan mereka. Ada juga beberapa sepeda motor ter parkir di sana.	a. Di latar belakang tampak trotoarnya yang ramai dengan banyak pejalan kaki dan anak-anak sekolah. Di sisi kanan terdapat empat tiangnya besi berwarna putih-oranje yang membatasi jalan sementara di sebelah kiri, terdapat sebuah pot tanaman hias. Ada juga tiga sepeda motor terparkir di trotoar. Terlihat pula aktivitas berjalan orang dalam area tersebut . b. Berdasarkan gambar, tampak aktivitas utama di trotol adalah adanya pejalan kaki dan anak sekolah. Ada banyak orang yang terlihat berjalan di trotoar, sementara beberapa orang lainnya sedang menunggu. Terlihat pula keberadaan empat tiang pembatas berwarna putih-oranje yang membatasi jalan tersebut. Di sisi lain, tiga sepeda

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
			motor juga ditata rapi di trotoar.
	c. Objek utama dalam gambar adalah seorang pengendara sepeda motor. Ia memiliki satu warna (misal, hitam) dan bentuk fisik seperti biasanya dilihat dari atas ke bawah. Terdapat setiap objek/subjek lain berupa; sepeda motor yang terparkir di sekitar, tempat pembuangan sampah, kendaraan lainnya. Total objek: sekian banyak	c. Pada gambar tersebut terlihat empat tiangnya besi berwarna putih-orange, satu pot tanaman hias berwarna hijau. Di sekelilingnya terdapat banyak pejalan kaki dan anak-anak sekolah. Ada juga tiga buah motor yang parkir di trotoar. Ada juga beberapa warga yang beraktivitas di sekitar lokasi.	c. Berdasarkan gambar, tampak adanya empat tiang pembatas berwarna putih-orange. Di dekat tiang, terdapat satu pot tanaman hias berisi tumbuhan hijau. Ada juga tiga sepeda motor terparkir di area ini. Di samping itu terlihat banyak orang yang menjalani aktivitas seperti berjalan/menjalankan tugas sehari-hari.
 • N0435.jpg • Mobil dengan warna putih dengan lampu bagian belakang dengan warna merah yang memiliki ban dan kaca dengan warna hitam. • Tempat sampah dengan warna hijau yang memiliki bentuk tabung dengan lubang di bagian depannya. • di depan ramai orang sedang berdiri di trotoar sementara di sebelah kiri beberapa kendaraan parkir • Di atas trotoar ada banyak orang berdiri dan duduk di kursi pedestrian sedang mengobrol, lalu di dekat mereka ada banyak sepeda motor dan sebuah mobil parkir, ada juga rambu lalu lintas, tempat sampah, dan taman kecil dengan banyak pohon dan rumput di atas trotoar • Di trotoar yang rindang, sekelompok orang berkumpul dengan santai, menikmati suasana sekitar yang hidup, sementara kendaraan melintas di	a. Objek utama dalam foto tersebut adalah seorang pria laki-laki berpakaian biru yang berdiri di trotoar tengah. b. Objek utama dalam gambar tersebut adalah pria laki-laki itu hanya menghampiri jalan dan mungkin meninjau kondisi sekitar.	a. Ada satu mobil putih dan tempat sampah berwarna hijau tabung di dalam gambar tersebut. Di sampingnya terdapat beberapa orang yang duduk bersila di sebuah trotoarnya, tengah bersantai. Ada juga seorang pria yang sedang berdiri dan mengoperasikan ponselnya. Kemudian ada kendaraan lain yang melaju ke arah yang berbeda di jalan setapak yang rimbun. b. Ada beberapa orang berkumpul di trotoar dengan kursi pedestrian. Mereka duduk dan bersantai. Ada satu mobil putih dan sebuah tempat sampah berwarna hijau di lokasi tersebut.	a. terdapat sebuah mobil putih. Ada juga seorang pria yang sedang berdiri sambil memegang telepon di trotoar. Di sampingnya terdapat beberapa orang lain yang sedang berkeliaran. Terdapat juga tempat sampah berwarna hijau tabung di lokasi tersebut. b. Objek utama dalam foto adalah sekumpulan orang yang sedang berkumpul di trotoar. Mereka duduk di beberapa kursi pedestrian di area tersebut. Ada satu mobil putih melaju di background, serta sebuah tempat sampah berwarna hijau tabung. Beberapa individu terlihat sedang berjalan-jalan di sekitar kelompok orang tersebut. Salah seorang pria tampak sedang memegang ponsel di tangannya. Penting untuk dicatat bahwa warna

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
jalan yang ramai di samping mereka.			mobil, tempat sampah, dan lampu belakang tersebut cukup jelas terlihat pada gambar.
	c. Warna dari objek utama adalah biru. Objek/subjek utama ini berbentuk manusia. Terdapat satu orang laki-lakinya saja dalam gambar.	c. Ada satu mobil putih dan tempat sampah berwarna hijau. Ada juga beberapa orang yang berkumpul di trotoar. Mereka duduk di kursi pedestrian. Mobil memiliki lampu belakang warna merah.	c. Mobil putih memiliki warna putih. Orang-orang yang berada di lokasi tampak mengenakan pakaian umumnya seperti manusia biasa. Ada satu tempat sampah berwarna hijau tabung. Terdapat juga beberapa orang yang duduk di area trotoarnya.
 • O0171.jpg • Satu orang laki-laki menggunakan tas warna cokelat sedang berjalan di trotoar • Satu orang laki-laki sedang duduk di bangku taman dengan warna putih • Terdapat papan ucapan selamat sukses yang disandarkan di dinding • Seorang pria berjalan di trotoar, sementara orang-orang duduk santai dan lalu lintas berlalu di jalan. • Di atas trotoar ada orang berjalan, orang duduk di kursi pedestrian, papan ucapan selamat, dan pedagang yang menggunakan gerobak sepeda • Seorang pria mengenakan kemeja kotak-kotak dan tas ransel berjalan di trotoar yang ramai, sementara beberapa orang duduk di bangku dan lampu lalu lintas terlihat di latar belakang.	a. Latar depan gambar itu adalah trotoar dan sepeda motor. Ada satu orang lelaki dengan baju Hitam yang sedang berdiri.	a. Ada dua pria dalam gambar tersebut. Salah satunya mengenakan kemeja berwarna cokelat dan duduk di sebuah bangku. Pria lainnya adalah seorang pria dengan baju lengan panjang hitam yang sedang berdiri.	a. Di bagian depan foto terdapat seorang pria dengan kemeja kotak motif berwarna cokelat menengok ke arah kamera saat berjalan di jalan. Di sampingnya, terdapat sebuah gerbong sepeda yang parkir rapih.
	b. Latar depan gambar adalah trotoar dan motor. Orang laki-laki tersebut berdiri. Human: Aktivitas seseorang tersebut adalah berdiri.	b. Dua pria dalam gambar tersebut melakukan aktivitas berbeda. Salah satu pria mengenakan pakaian berwarna coklat itu berjalan di jalanan sementara pria lainnya duduk di sebuah bangku.	b. Berdasarkan gambar yang diberikan, tampak terdapat dua orang. Salah satu pria memakai kemeja kotak motif cokelat, dan tas berwarna cokelat. Pria itu sedang berjalan di ruas jalan yang ramai. Kemudian, salah satu pria lainnya duduk di sebuah bangku yang terbuat dari material putih. Di tumpukan dokumen tertulis "Selamat...", di tempat yang tepat, tampaknya berada di area tersebut.
	c. Berdasarkan gambar, ada satu orang laki-laki dalam kondisi diam. Dia mengenakan pakaian hitam.	c. Ada satu pria mengenakan pakaian berwarna coklat, satu pria sedang duduk di sebuah bangku yang putih, dan	c. Berdasarkan gambar yang diberikan, tampak ada dua pria. Salah satunya mengenakan kemeja berwarna coklat,

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
	Terdapat juga sebuah sepeda motor di dekat dirinya.	ada juga seorang pria berbaju hitam yang tengah berdiri di jalanan. Di sekitar mereka terdapat sepeda motor yang terparai. Terdapat papan ucapan Selamat di taman.	sedangkan pria lainnya memakai pakaian putih seperti kaos polos. Kedua pria itu nampak sedang berada di trotoar saat suasana pagi hari. Di pinggir jalan terdapat sebuah bangku kecil berwarna putih. Tampilannya cukup sederhana namun nyaman untuk bersantai. Terdapat juga beberapa papan ucapan di sekitar lokasi tersebut. Pernyataan: Warna: Kemeja pria pertama berwarna cokelat; Pria kedua mengenakan kaos putih.
 • O0229.jpg • Tiga orang perempuan sedang berjalan bersama di trotoar ini • Satu pohon besar dililit oleh lampu dan tiga orang yang sedang berjalan • Satu orang pria sedang duduk di bangku trotoar ini • Sekelompok wanita berjalan di trotoar yang rindang, dikelilingi pepohonan dan suasana kota yang hidup. • 3 perempuan berjalan di depan toko yang memiliki pohon berbatang besar • Tiga wanita mengenakan masker berjalan di trotoar dekat restoran, sementara seorang anak duduk di bangku dengan pohon besar dan deretan kendaraan di latar belakang.	a. Latar depan gambar tersebut adalah trotoarnya dan pepohon di sekitarnya.	a. Latar belakang gambar menunjukkan trotoarnya yang rimbun dengan banyak tanaman. Terdapat juga bangunan sekitar.	a. Ada tiga wanita yang memakai masker sedang jalan di trotoar yang rimbun. Di samping mereka terdapat sebuah pohon besar dengan lilin yang dililit oleh lampu dan terdapat seorang pria di bangkunya. Warna dominan adalah hijau pada pohon, putih pada bangku dan hitam pada masker.
	b. Wanita sedang berjalan.	b. Wanita sedang berjalan-jalan di trotoar yang rimbun dengan banyak pepohonan. Pria berada di bangkunya, menikmati suasana ramai kota.	b. Wanita sedang berjalan kaki di trotoar yang rimbun dengan banyak pohon. Dia mengenakan masker, tampak menjauhi orang lain untuk menjaga kenyamanan mereka saat berada di tempat umum. Di sampingnya, terdapat sebuah pria yang sedang duduk di sebuah bangku. Ia terlihat santai menikmati pemandangan sekitar. Warna-warna yang muncul pada gambar: Hijau, Putih, Hitam.
	c. Warna-warna dominan dalam gambar tersebut antara hijau (dari pepohonan) dan abu-abu/kuning (dikoordinasikan	c. Dalam gambar tersebut tampak seorang wanita berjalan di jalan setapak yang rimbun dengan banyak pohon. Di sampingnya, seorang pria	c. Berdasarkan gambar, terlihat tiga wanita mengenakan masker, dan satu pria duduk santai di bangkunya. Pohon hijau megah berdiri tegak

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
	dengan warna baju wanita). Bentuknya berupa manusia. Ada satu wanita dan satu pria.	sedang duduk santai di sebuah bangku menikmati pemandangan kota yang penuh keramaian. Ada tiga wanita yang juga terlihat mengenakan masker sedang berjalan kaki di trotoar setapak yang sama, terpaut oleh beberapa pohon rindang. Ada satu orang pria duduk.	sebagai latar belakang, serta beberapa bangunan tampak mencolok di kejauhan.
 • O0242.jpg • Satu orang pria dewasa memakai baju garis-garis hitam putih • Seorang anak SD dengan seragam putih merah sedang duduk di kursi plastik biru • Terdapat satu pohon dan dua orang yang sedang duduk di bangku taman dengan warna cokelat • Di bawah rindangnya pepohonan, trotoar ini menjadi tempat pertemuan antara deretan motor parkir dan obrolan santai warga yang menikmati jeda di tengah kesibukan kota. • Ada beberapa orang berdiri dan duduk di sekitar gerobak dagangan yang ada di tepi trotoar, ada juga beberapa sepeda motor dan mobil parkir di sekitar gerobak • Sejumlah orang berdiri dan duduk di trotoar dekat gerobak makanan, sementara seorang pria berbicara dengan wanita yang mengenakan jilbab di bangku, dikelilingi oleh sepeda motor dan mobil.	a. Di latar depan tampak seorang pria sedang mendirikan posisi dirinya disekitar bangku. b. Berdasarkan informasi database dan deskripsi gambar, aktivitas yang dilakukan objek atau subjek tersebut adalah duduk. c. Berdasarkan informasi database yang diberikan, objek-objek yang terlihat adalah seorang pria, bangk besi, trotoarnya, sepeda motor, pepohon, dan udara. Jumlahnya ada satu pria, satu bangku, beberapa	a. Dari informasi database, tampak ada seorang anak sekolah dasar dan pria dalam gambar tersebut sedang berada di area itu. b. Anak SD duduk dikursi plastik biru. Pria itu berada di dekat tempat dia menjual barang. c. Ada satu anak sekolah mengenakan seragam putih- merah yang duduk di sebuah kursi plastik berwarna biru. Di sampingnya ada seorang pria memakai pakaian garis-garis hitam- putih. Gerobak pedagang berada di dekat mereka. Terdapat satu buah kursi	a Ada seorang pria yang mengenakan pakaian bermotif garis-strip berwarna hitam-biru duduk di sebuah bangku beton dekat trottoar. Di sampingnya terdapat anak-anak sekolah dasar yang mengenakan seragam putih- merah duduk di keranjang plastik biru. Beberapa orang tampak berjalan di sekitar lokasi tersebut, serta beberapa sepeda yang tertata rapi di area sekitarnya. b. Objek utama dalam gambar adalah seorang anak Sekolah Dasar yang duduk di sebuah kursi plastik berwarna biru. Di sampingnya, terdapat seorang pria dengan pakaian garis-garis hitam-hitam. Pria itu berada di dekat sebuah gerobaknya dagangan. Ada aktivitas seperti orang-orga lain yang duduk dan berinteraksi di sekitar lokasi tersebut. c. Berdasarkan gambar, terlihat adanya satu buah trotoar dengan warna biru. Di sepanjang trotoarnya terdapat sebuah kursi plastik biru, tempat seorang anak sekolah berusia Sekolah Dasar (SD) duduk. Ada juga pria berpakaian garis-garis hitam-white

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
	sepeda, beberapa pohon, dan pepohonan.	plastik warna biru, satu orang pria dalam pakaian garis - garisan hitam - putih, dan satu gerobaknya.	yang berdiri didekat gerobak dagangan. Terdapat juga beberapa sepeda motor yang terparkir di dekat lokasi.
 • O1029.jpg • Terdapat sebuah penutup saluran berbentuk persegi dari besi dengan warna hitam di tengah-tengah trotoar. • Empat buah besi penghalang dengan warna abu-abu berada di tengah-tengah trotoar. • Sebuah tempat sampah dengan ukuran kecil dengan warna hijau berada di samping trotoar. • Suasana siang yang cerah, jalan setapak dikelilingi pepohonan, dengan pejalan kaki dan kendaraan melintas. • Di ujung trotoar terdapat tiang pembatas jalan, tempat sampah, dan orang yang sedang berjalan • Seorang pria mengenakan hoodie berjalan di trotoar yang dikelilingi tanaman, sementara mobil biru melintas di jalan dan seorang wanita terlihat di sebelah kanan.	a. Objek atau subjek yang terlihat jelas di latar belakang adalah pria tersebut. b. Objek dalam gambar sedang berjalan. c. Objek utama dalam gambar adalah seorang pria. Warna pakaiannya tidak terlihat jelas, tapi tampak seperti mengenakan atasan berwarna gelap dan celana panjang. Terdapat satu kendaraan lalu lintas di dekat dirinya. Ada juga beberapa pohon di sekitar pria itu. Jumlah pohon kurang lebih 3-4 buah.	a. Objek yang terlihat pada latar depan adalah seorang pria berhoodie yang sedang berjalan. b. Pria itu sedang berjalan kaki di trotoar. Ia berjalan saat mobil melintasi di jalan di depannya. c. Pria mengenakan hoodie, ada empat besi penghambat abu-abu, penutup saluran berwarna hitam, serta satu mobil biru. Ada enam objek total dalam gambar tersebut.	a. Pria itu berada di trotoar. Di depannya ada beberapa elemen bangunan seperti besi penghalangan, penutup drainase, serta sebuah mobil biru. b. Pria itu mengenakan hoodie berwarna tidak ditentukan dalam gambar. Dia berdiri di trotoar sambil mengontrol beberapa besi penghalangan abu-abu, menutup saluran hitam dan sebuah mobil biru melaju di jalan setapak di sampingnya. Mobil tersebut terlihat memiliki warna biru identik dengan warna mobil tersebut. Aktivitas pria itu adalah berjalan. c. Berdasarkan gambar yang diberikan, tampak seorang pria berlari di trotoar. Ia mengenakan hoodie berwarna abu-abuan. Di sampingnya terdapat empat besi penahan abu-abu. Kemudian terlihat sebuah mobil biru pula.
	a. Pengendara sepeda motormengan melewati trotoarnya yang dikelipungi pepohonan. Ada juga kendaraan lainnya yang berada di	a. Berdasarkan informasi database, tampak seorang wanita sedang mengendarai sepeda motor berwarna merah-	a. di dalam gambar tampak seorang wanita mengenakan pakaian hitam sedang mengemudi sepeda motor berwarna merah-black di trotoar.

Ground Truth (Image dan Caption Dataset)	Teks Prediksi VLM	Teks Prediksi VLM + RAG	Teks Prediksi VLM + RAG + MCP
 • N0297.jpg • Sepeda motor dengan warna merah dan hitam dikendarai seseorang memakai jaket hitam. • Sebuah tong sampah dengan ukuran sedang memiliki warna merah. • seorang wanita mengendarai sepeda motor menaiki trotoar ke arah kanan. • seorang perempuan mengendarai motor miliknya ke atas trotoar • Seorang wanita mengendarai sepeda motor di trotoar menuju area parkir • Seorang pengendara motor melintas di trotoar dengan papan tanda parkir dan deretan bangunan toko di latar belakang.	jalur dekatnya di belakangnya.	hitam menuju area parking.	Di sampingnya terdapat tong sampah berwarna merah.
	b. Pengendara motor sedang melaju.	b. Wanita itu sedang mengantar sepeda motornya ke area parkir	b. Berdasarkan gambar, tampak seorang wanita sedang berkendara sepeda motornya berwarna merah-black menuju area parkir dekat tong sampah berwarna merah. Ia terlihat memakai jaket hitam. Aktivitas yang dilakukan adalah menghirang sepeda motor dan bergerak menuju area tempat parkir.
	c. Objek utama dalam foto adalah pengendara motor. Terlihat dari warna hitam dan bentuk roda dan ban sepeda motor. Jumlah objek/subjeknya satu.	c. Ada satu wanita yang sedang mengendarainya sepeda motor berwarna merah-black. Dia juga memakai jaket hitam. Sepeda motornya berwarna merah hitam. Ada juga satu tong sampah berwarna merah.	c. Warna jaket wanita itu adalah hitam. Pengendara sepeda motornya memakai jaket hitam, dan terlihat warna motor merah hitam. Di foto tampak satu wanita pengendali motor, satu sepeda motor dan satu tong sampah berwarna merah.

Halaman ini sengaja dikosongkan.

BIODATA PENULIS



Penulis dilahirkan di Surabaya, 23 Mei 2004, merupakan anak tunggal. Penulis telah menempuh pendidikan formal yaitu di TK Pelita Jaya School, SDS Pelita Jaya School, SMPN 1 Surabaya dan SMAN 5 Surabaya. Setelah lulus dari SMAN tahun 2022, Penulis mengikuti SNMPTN dan diterima di Departemen Teknik Informatika FTEIC- ITS pada tahun 2022 dan terdaftar dengan NRP 5025221023.

Selama masa perkuliahan, Penulis aktif mengembangkan keahlian teknis dan profesional di bidang teknologi. Penulis memiliki pengalaman sebagai Chief Technology Officer (CTO) di Asteria Academy (PT Inovasi Anak Cerdas) sejak Februari 2025, di mana Penulis bertanggung jawab sebagai *Project Manager* dan *Fullstack Developer*. Selain itu, Penulis juga memperluas wawasan internasional dengan menjadi AI Engineer di CHI, Rotterdam, Belanda. Pengalaman teknis lainnya meliputi peran sebagai Staff Formalistik di GDSC Indonesia, serta Tim IT Helpdesk untuk PPDB dan SPMB Pemerintah Kabupaten Sidoarjo.