

TUGAS AKHIR - EF234801

**EVALUASI FITUR *HANDCRAFTED* DAN MODEL
SPEECH PRALATIH UNTUK ESTIMASI KEPRIBADIAN
BIG FIVE BERBASIS AUDIO DENGAN PROTOKOL
STRICT SPLIT DAN ADAPTASI LoRA**

Muhammad Aqil Farrukh

NRP 5025221158

Dosen Pembimbing

Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D

NPP 1987202012004

Dosen Ko-pembimbing

Dini Adni Navastara, S.Kom., M.Sc.

NIP 198510172015042001

Program Studi S-1 Teknik Informatika

Departemen Teknik Informatika

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

Halaman ini sengaja dikosongkan.



TUGAS AKHIR - EF234801

EVALUASI FITUR *HANDCRAFTED* DAN MODEL *SPEECH* PRALATIH UNTUK ESTIMASI KEPERIBADIAN BIG FIVE BERBASIS AUDIO DENGAN PROTOKOL *STRICT SPLIT* DAN ADAPTASI LoRA

Muhammad Aqil Farrukh

NRP 5025221158

Dosen Pembimbing

Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D

NPP 1987202012004

Dosen Ko-pembimbing

Dini Adni Navastara, S.Kom., M.Sc.

NIP 198510172015042001

Program Studi S-1 Teknik Informatika

Departemen Teknik Informatika

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

Halaman ini sengaja dikosongkan.



FINAL PROJECT - EF234801

FINAL EVALUATION OF HANDCRAFTED FEATURES AND PRETRAINED SPEECH MODELS FOR AUDIO- ONLY BIG FIVE PERSONALITY ESTIMATION USING A STRICT SPLIT PROTOCOL AND LoRA ADAPTATION

Muhammad Aqil Farrukh

NRP 5025221158

Advisor

Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D

NPP 1987202012004

Co-advisor

Dini Adni Navastara, S.Kom., M.Sc.

NIP 198510172015042001

Undergraduate Study Program of Informatics

Department of Informatics

Faculty of Intelligent Electrical and Informatics Technology

Institut Teknologi Sepuluh Nopember

Surabaya

2026

Halaman ini sengaja dikosongkan.

LEMBAR PENGESAHAN

EVALUASI FITUR *HANDCRAFTED* DAN MODEL *SPEECH* PRALATIH UNTUK ESTIMASI KEPERIBADIAN *BIG FIVE* BERBASIS AUDIO DENGAN PROTOKOL *STRICT SPLIT* DAN ADAPTASI LoRA

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Komputer pada
Program Studi S-1 Teknik Informatika
Departemen Teknik Informatika
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember

Oleh: **Muhammad Aqil Farrukh**

NRP. 5025221158

Disetujui oleh Tim Penguji Tugas Akhir:

- | | | |
|----|--|---------------|
| 1. | Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D | Pembimbing |
| 2. | Dini Adni Navastara, S.Kom., M.Sc. | Ko-pembimbing |
| 3. | <Nama dan gelar penguji> | Penguji |
| 4. | <Nama dan gelar penguji> | Penguji |

SURABAYA

Januari, 2026

Halaman ini sengaja dikosongkan.

APPROVAL SHEET

FINAL EVALUATION OF HANDCRAFTED FEATURES AND PRETRAINED SPEECH MODELS FOR AUDIO-ONLY BIG FIVE *PERSONALITY* ESTIMATION USING A STRICT SPLIT PROTOCOL AND LoRA ADAPTATION

FINAL PROJECT

Submitted to fulfill one of the requirements
for obtaining a Bachelor of Computer Science degree at
Undergraduate Study Program of Informatics
Department of Informatics
Faculty of Intelligent Electrical and Informatics Technology
Institut Teknologi Sepuluh Nopember

By: **Muhammad Aqil Farrukh**

NRP. 5025221158

Approved by Final Project Examiner Team:

- | | | |
|----|--|------------|
| 1. | Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D | Advisor |
| 2. | Dini Adni Navastara, S.Kom., M.Sc. | Co-advisor |
| 3. | <Name and title> | Examiner 1 |
| 4. | <Name and title> | Examiner 2 |

SURABAYA

January, 2026

This page is intentionally left blank.

PERNYATAAN ORISINALITAS

Yang bertanda tangan di bawah ini:

Nama mahasiswa / NRP : Muhammad Aqil Farrukh/5025221158
Program Studi : S-1 Teknik Informatika
Dosen Pembimbing / NPP : Shintami Chusnul Hidayati, S.Kom., M.Sc.,
Ph.D/1987202012004
Dosen Ko-pembimbing / NIP : Dini Adni Navastara, S.Kom., M.Sc./
198510172015042001

dengan ini menyatakan bahwa Tugas Akhir dengan judul “EVALUASI FITUR HANDCRAFTED DAN MODEL *SPEECH* PRALATIH UNTUK ESTIMASI KEPERIBADIAN *BIG FIVE* BERBASIS AUDIO DENGAN PROTOKOL *STRICT SPLIT* DAN ADAPTASI LoRA” adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Mengetahui
Dosen Pembimbing

Surabaya, _____
Mahasiswa

Shintami Chusnul Hidayati, S.Kom., M.Sc.,
Ph.D
NPP. 1987202012004

Muhammad Aqil Farrukh
NRP. 5025221158

Dosen Ko-pembimbing

Dini Adni Navastara, S.Kom., M.Sc.
NIP. 198510172015042001

Halaman ini sengaja dikosongkan.

STATEMENT OF ORIGINALITY

The undersigned:

Student Name / Student ID : Muhammad Aqil Farrukh/ 5025221158
Study Program : Bachelor of Informatics
Advisor / Employee ID : Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D/
1987202012004
Co-advisor / Employee ID : Dini Adni Navastara, S.Kom., M.Sc./
198510172015042001

hereby declares that the Final Project entitled “FINAL EVALUATION OF HANDCRAFTED FEATURES AND PRETRAINED SPEECH MODELS FOR AUDIO-ONLY BIG FIVE PERSONALITY ESTIMATION USING A STRICT SPLIT PROTOCOL AND LoRA ADAPTATION” is my own work, is original, and was written in accordance with the rules of scientific writing.

If any discrepancies with this statement are found in the future, I am willing to accept sanctions in accordance with the provisions of Institut Teknologi Sepuluh Nopember.

Acknowledged
Advisor

Surabaya, _____
Student

Shintami Chusnul Hidayati, S.Kom., M.Sc.,
Ph.D
NPP. 1987202012004

Muhammad Aqil Farrukh
NRP. 5025221158

Co-advisor

Dini Adni Navastara, S.Kom., M.Sc.
NIP. 198510172015042001

This page is intentionally left blank.

PERNYATAAN KODE ETIK PENGUNAAN AI GENERATIF

Code of Conduct Statement: Generative AI or AI-Assisted Usage

Saya yang bertanda tangan di bawah ini:

I, the undersigned:

Nama Mahasiswa / NRP : Muhammad Aqil Farrukh/ 5025221158

Full Name / Student ID

Program Studi : S-1 Teknik Informatika

Study Program

Judul Tugas Akhir : EVALUASI FITUR HANDCRAFTED DAN MODEL
Final Project Title
SPEECH PRALATIH UNTUK ESTIMASI
KEPRIBADIAN BIG FIVE BERBASIS AUDIO
DENGAN PROTOKOL STRICT SPLIT DAN
ADAPTASI LoRA

dengan ini menyatakan bahwa pada Tugas Akhir dengan judul di atas tersebut:

hereby declare that in the Final Project with the above title:

No.	Pernyataan <i>Statement</i>	(☒)
1	Saya hanya menggunakan AI generatif sebagai alat bantu untuk memperbaiki tata bahasa. AI generatif tidak digunakan untuk membuat isi Tugas Akhir. <i>I only used generative AI as a tool to improve the readability or language of the text in my Final Project. It was not used to generate a complete text of my work.</i>	
2	Saya telah memeriksa dan/atau memperbaiki seluruh bagian dari Tugas Akhir saya yang dibantu oleh AI generatif agar sesuai dengan baku mutu penulisan karya ilmiah. <i>I have reviewed and refined all aspects of my work that generative AI assists with, ensuring it adheres to the standards of academic writing.</i>	
3	Saya tidak menggunakan AI generatif untuk pembuatan data primer, grafik dan/atau tabel pada Tugas Akhir saya. <i>I did not use generative AI to generate primary data, figures, and/or tables in my work.</i>	
4	Saya telah memberikan atribusi/pengakuan terhadap alat AI yang digunakan, secara rinci pada suatu bagian pada lampiran. <i>I have acknowledged the use of generative AI in any part of the work in the specific appendix page.</i>	
5	Saya memastikan tidak ada plagiarisme, termasuk hal yang berasal dari penggunaan AI generatif. <i>I have ensured that there is no plagiarism issue in the work, including any parts generated by AI.</i>	

Surabaya, _____
Mahasiswa

Muhammad Aqil Farrukh
NRP. 5025221158

Halaman ini sengaja dikosongkan.

ABSTRAK

EVALUASI FITUR *HANDCRAFTED* DAN MODEL *SPEECH* PRALATIH UNTUK ESTIMASI KEPERIBADIAN *BIG FIVE* BERBASIS AUDIO DENGAN PROTOKOL *STRICT SPLIT* DAN ADAPTASI LoRA

Nama Mahasiswa / NRP : Muhammad Aqil Farrukh / 5025221158
Departemen : Teknik Informatika FTIRS - ITS
Dosen Pembimbing : Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D
Dosen Ko-pembimbing : Dini Adni Navastara, S.Kom., M.Sc.

Abstrak

Kepribadian manusia dapat tercermin melalui cara seseorang berbicara, tetapi estimasi otomatis dari sinyal suara masih menantang karena variasi pembicara, kondisi rekaman, subjektivitas label, dan potensi kebocoran sumber data antar subset evaluasi. Penelitian ini mengevaluasi estimasi *apparent personality Big Five* berbasis *audio-only* pada dataset *ChaLearn First Impressions V2*. Setelah praproses dan kendali kualitas berbasis *Voice Activity Detection*, digunakan 9.974 klip *audio* untuk membangun *pipeline* yang mencakup standardisasi *audio*, pembentukan *strict split* berbasis *group_id*, serta pemodelan regresi lima *trait* kepribadian. Eksperimen membandingkan fitur *handcrafted* eGeMAPS dengan *embedding speech* pralatih wav2vec 2.0, HuBERT, dan WavLM pada skema *frozen feature extraction* menggunakan *Ridge Regression*, lalu mengevaluasi adaptasi LoRA pada WavLM dan HuBERT. Pada *baseline strict split*, WavLM *frozen embedding* + *Ridge* memperoleh MAE 0,099881 dan R^2 0,309102. Pada skenario LoRA, WavLM+LoRA *best-val run* memperoleh MAE 0,100190 dan R^2 0,303067, sedangkan HuBERT+LoRA *best-val run* mencapai MAE 0,098695 dan R^2 0,323789. Hasil terbaik diperoleh *ensemble* 10 runs HuBERT+LoRA dengan MAE 0,097698 dan R^2 0,335042. Temuan ini menunjukkan keunggulan *embedding speech* pralatih dan pentingnya *strict split* untuk evaluasi generalisasi yang lebih realistis.

Kata kunci: *audio-only, Big Five, ChaLearn First Impressions V2, eGeMAPS, HuBERT, LoRA, self-supervised learning, strict split, WavLM.*

Halaman ini sengaja dikosongkan.

ABSTRACT

FINAL EVALUATION OF HANDCRAFTED FEATURES AND PRETRAINED SPEECH MODELS FOR AUDIO-ONLY BIG FIVE PERSONALITY ESTIMATION USING A STRICT SPLIT PROTOCOL AND LoRA ADAPTATION

Full Name / Student ID : Muhammad Aqil Farrukh / 5025221158
Department : Informatics ELECTICS - ITS
Advisor : Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D
Co-advisor : Dini Adni Navastara, S.Kom., M.Sc.

Abstract

Human personality can be reflected in speech, yet automatic estimation from audio remains challenging because of speaker variability, recording conditions, subjective labels, and potential source leakage across evaluation subsets. This study evaluates audio-only Big Five apparent personality estimation on the ChaLearn First Impressions V2 dataset. After preprocessing and Voice Activity Detection based quality control, 9,974 audio clips were used to build an evaluation pipeline consisting of audio standardization, group_id-based strict split construction, and regression modeling for five personality traits. The experiments compare handcrafted eGeMAPS features with pretrained speech embeddings from wav2vec 2.0, HuBERT, and WavLM under a frozen feature extraction scheme using Ridge Regression, followed by LoRA-based parameter-efficient adaptation on WavLM and HuBERT. In the strict-split baseline, WavLM frozen embedding + Ridge achieved the best performance with MAE 0.099881 and R^2 0.309102. In the LoRA setting, WavLM+LoRA best-val run obtained MAE 0.100190 and R^2 0.303067, while HuBERT+LoRA best-val run achieved MAE 0.098695 and R^2 0.323789. The best overall result was obtained by the 10-run HuBERT+LoRA ensemble, with MAE 0.097698 and R^2 0.335042. These findings highlight the advantage of pretrained speech embeddings and the importance of strict split evaluation for more realistic generalization assessment.

Keywords: audio-only, Big Five, ChaLearn First Impressions V2, eGeMAPS, HuBERT, LoRA, self-supervised learning, strict split, WavLM.

This page is intentionally left blank.

KATA PENGANTAR

Assalamu'alaikum warahmatullahi wabarakatuh

Puji syukur penulis panjatkan ke hadirat Allah SWT atas rahmat, karunia, dan pertolongan-Nya sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul “Evaluasi Fitur Handcrafted dan Model Speech Pralatih untuk Estimasi Kepribadian Big Five Berbasis Audio dengan Protokol Strict Split dan Adaptasi LoRA”. Tugas Akhir ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi S-1 Teknik Informatika, Departemen Teknik Informatika, Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember.

Penulisan Tugas Akhir ini tidak akan terlaksana dengan baik tanpa bimbingan, dukungan, dan motivasi dari berbagai pihak. Oleh karena itu, penulis ingin menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Ibu Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D., selaku dosen pembimbing, atas bimbingan, arahan, masukan, serta kesabaran yang diberikan selama proses penyusunan Tugas Akhir ini.
2. Ibu Dini Adni Navastara, S.Kom., M.Sc., selaku dosen ko-pembimbing, atas arahan, saran, dan dukungan yang telah membantu penulis dalam menyempurnakan penelitian dan penulisan Tugas Akhir ini.
3. Bapak/Ibu dosen penguji yang telah memberikan kritik, saran, dan masukan yang membangun demi penyempurnaan Tugas Akhir ini.
4. Orang tua dan keluarga penulis yang senantiasa memberikan doa, dukungan, nasihat, serta semangat yang menjadi sumber kekuatan bagi penulis dalam menyelesaikan studi dan Tugas Akhir ini.
5. Teman-teman dalam grup TCFiesta yang telah memberikan semangat, bantuan, dan dukungan selama proses penelitian berlangsung, baik dalam bentuk diskusi, motivasi, maupun kebersamaan yang membantu penulis melewati berbagai tahap penyusunan Tugas Akhir ini.

Penulis menyadari bahwa Tugas Akhir ini masih jauh dari sempurna. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun untuk perbaikan di masa mendatang. Semoga hasil penelitian ini dapat bermanfaat bagi perkembangan ilmu pengetahuan dan teknologi.

Wassalamu'alaikum warahmatullahi wabarakatuh

**Hormat saya,
Muhammad Aqil Farrukh**

Halaman ini sengaja dikosongkan.

DAFTAR ISI

LEMBAR PENGESAHAN.....	i
APPROVAL SHEET	iii
PERNYATAAN ORISINALITAS	v
STATEMENT OF ORIGINALITY	vii
PERNYATAAN KODE ETIK PENGGUNAAN AI GENERATIF.....	ix
ABSTRAK.....	xi
ABSTRACT.....	xiii
KATA PENGANTAR	xv
DAFTAR ISI.....	xvii
DAFTAR GAMBAR	xxi
DAFTAR TABEL	xxiv
DAFTAR KODE SEMU.....	xxvi
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah	3
1.4 Tujuan.....	3
1.5 Manfaat.....	4
BAB 2 TINJAUAN PUSTAKA	5
2.1 Hasil Penelitian Terdahulu	5
2.2 Dasar Teori	13
2.2.1 Kepribadian <i>Big Five</i>	13
2.2.2 <i>Apparent Personality</i> & Karakter Tugas Prediksi.....	14
2.2.3 Dataset <i>First impressions</i> V2 (<i>Chalearn</i>).....	14
2.2.4 Praproses Audio.....	15
2.2.5 Protokol Pembagian Data & Risiko <i>Leakage</i>	17
2.2.6 Transformer	18
2.2.7 Kerangka Pembelajaran Representasi Ucapan Berbasis <i>Self-Supervised: wav2vec2.0</i>	19
2.2.8 Kerangka Pembelajaran Representasi Ucapan Berbasis <i>Masked Prediction: HuBERT 21</i>	21
2.2.9 Kerangka Pra-latih Ujaran untuk Tugas Umum: WavLM	23
2.2.10 Ekstraksi Fitur	25

2.2.11	Pemodelan untuk Regresi	27
2.2.12	<i>Parameter-Efficient Fine-tuning</i> : LoRA	29
2.2.13	Optimisasi dan Strategi <i>Training</i>	30
2.2.14	Metrik Evaluasi	32
BAB 3	METODOLOGI.....	35
3.1	Perancangan Sistem.....	35
3.1.1	Desain Penelitian & Alur Umum	36
3.1.2	Prosedur Praproses Dataset	37
3.1.3	Prosedur <i>Strict Split</i>	39
3.1.4	Skenario <i>baseline</i> representasi & model	41
3.1.5	Strategi <i>Fine-tuning</i> dan <i>Tuning</i> Hyperparameter LoRA.....	43
3.2	Bahan dan Peralatan yang Digunakan	47
3.2.1	Dataset	47
3.2.2	Perangkat Keras Hardware	47
BAB 4	HASIL DAN PEMBAHASAN	49
4.1	Hasil Penelitian.....	49
4.1.1	Hasil Eksplorasi Dataset.....	50
4.1.2	Hasil Praproses dan Pembentukan <i>Strict Split</i>	57
4.1.3	Hasil <i>Baseline</i> pada <i>Official Split</i>	63
4.1.4	Hasil <i>Baseline</i> pada <i>Strict Split</i>	72
4.1.5	Perbandingan <i>Official Split</i> dan <i>Strict Split</i>	79
4.1.6	Hasil <i>Fine-Tuning</i> WavLM dengan LoRA.....	81
4.1.7	Hasil <i>Fine-Tuning</i> HuBERT dengan LoRA	90
4.1.8	Perbandingan dengan Penelitian Terdahulu	101
4.2	Pembahasan	102
4.2.1	Implikasi Praproses dan <i>Strict Split</i> terhadap Validitas Evaluasi.....	102
4.2.2	Perbandingan Fitur <i>Handcrafted</i> dan Embedding SSL pada <i>Baseline</i>	104
4.2.3	Analisis Per-trait dan Karakteristik Dimensi Big Five pada Skenario berbasis audio	105
4.2.4	Perbedaan <i>Official Split</i> dan <i>Strict Split</i> serta Implikasinya terhadap Generalisasi	106
4.2.5	Evaluasi <i>Fine-Tuning</i> WavLM dan HuBERT dengan LoRA	107
4.2.6	Posisi Hasil Penelitian terhadap Literatur Terdahulu	108
4.2.7	Keterbatasan Penelitian dan Arah Pengembangan	109
BAB 5	KESIMPULAN DAN SARAN	111

5.1	Kesimpulan.....	111
5.2	Saran	112
DAFTAR PUSTAKA		113
LAMPIRAN.....		117
BIODATA PENULIS		152

Halaman ini sengaja dikosongkan.

DAFTAR GAMBAR

Gambar 2.1 Arsitektur Transformer (Vaswani dkk., 2017)	19
Gambar 2.2 Kerangka wav2vec 2.0 (Baevski dkk., 2020)	20
Gambar 2.3 Skema HuBERT untuk memprediksi assignment cluster pada frame yang dilakukan masking (Hsu dkk., 2021).....	22
Gambar 2.4 Arsitektur WavLM (Chen dkk., 2022)	24
Gambar 3.1 Diagram Alir Umum Penelitian Audio-only Personality Estimation	36
Gambar 3.2 Alur Praproses Dataset	37
Gambar 3.3 Alur Split Strict.....	39
Gambar 3.4 Alur Skenario Baseline dan Representasi Model	42
Gambar 3.5 Diagram Alir Strategi Fine-tuning dengan LoRA	44
Gambar 4.1 Distribusi <i>official split</i> awal pada dataset.	51
Gambar 4.2 Distribusi label <i>Big Five</i> pada dataset.	53
Gambar 4.3 Matriks korelasi antar label <i>Big Five</i>	54
Gambar 4.4 Distribusi kombinasi <i>gender</i> dan <i>ethnicity</i> berdasarkan kode kategori.	55
Gambar 4.5 Distribusi durasi ujaran berdasarkan <i>speech_sec</i> VAD.....	56
Gambar 4.6 Perbandingan mean MAE validation terhadap nilai alpha pada baseline official split	66
Gambar 4.7 Kurva <i>train MAE</i> dan <i>validation MAE Ridge Regression</i> terhadap nilai alpha pada <i>baseline official split</i> untuk WavLM	67
Gambar 4.8 Perbandingan metrik rata-rata antar metode pada test set official split.....	69
Gambar 4.9 Perbandingan MAE per-trait pada test set official split.....	71
Gambar 4.10 Perbandingan R^2 per-trait pada <i>test set official split</i>	71
Gambar 4.11 Perbandingan mean MAE validation terhadap nilai alpha pada <i>baseline strict split</i>	74
Gambar 4.12 Kurva <i>train MAE</i> dan <i>validation MAE Ridge Regression</i> terhadap alpha pada <i>strict split</i> untuk WavLM.....	75
Gambar 4.13 Perbandingan metrik rata-rata antar metode pada <i>test set strict split</i>	76
Gambar 4.14 Perbandingan MAE per-trait pada <i>test set strict split</i>	77
Gambar 4.15 Perbandingan R^2 per-trait pada <i>test set strict split</i>	78
Gambar 4.16 Riwayat optimisasi Optuna pada fine-tuning WavLM+LoRA.....	84
Gambar 4.17 Parameter importance pada studi Optuna WavLM+LoRA	85
Gambar 4.18 Histogram label aktual dan prediksi WavLM+LoRA best-val run pada test_strict	88
Gambar 4.19 Scatter plot label aktual dan prediksi WavLM+LoRA best-val run pada test_strict	89
Gambar 4.20 Kurva agregat train loss dan validation loss WavLM+LoRA pada 10 final runs	90
Gambar 4.21 Riwayat optimisasi Optuna pada fine-tuning HuBERT+LoRA	93
Gambar 4.22 Parameter importance pada studi Optuna HuBERT+LoRA.....	94
Gambar 4.23 Kurva agregat <i>train loss</i> dan <i>validation loss</i> pada 10 <i>final runs</i> HuBERT+LoRA	96
Gambar 4.24 Perbandingan MAE per-trait HuBERT+LoRA best-val run pada test_strict	97
Gambar 4.25 Perbandingan R^2 per-trait HuBERT+LoRA best-val run pada test_strict	98

Gambar 4.26 Histogram label aktual dan prediksi HuBERT+LoRA <i>best-val run</i> pada <i>test_strict</i>	99
Gambar 4.27 Scatter plot label aktual dan prediksi HuBERT+LoRA <i>best-val run</i> pada <i>test_strict</i>	99
Gambar 4.28 Perbandingan simpangan baku label aktual dan prediksi HuBERT+LoRA <i>best-val run</i> pada <i>test_strict</i>	100

Halaman ini sengaja dikosongkan.

DAFTAR TABEL

Tabel 2.1 Tabel Penelitian Terkait	10
Tabel 2.2 Ringkasan konfigurasi varian wav2vec 2.0 dan data pralatih (Baevski dkk., 2020)	21
Tabel 2.3 Ringkasan konfigurasi varian HuBERT dan data pralatih (Hsu dkk., 2021)	23
Tabel 2.4 Ringkasan konfigurasi varian WavLM dan data pralatih (Chen dkk., 2022).....	25
Tabel 2.5 Ringkasan kelompok fitur akustik dan contoh parameternya	27
Tabel 2.6 Perbandingan regresi linear dan Ridge regression untuk mengurangi overfitting ...	29
Tabel 2.7 Ringkasan perbedaan Adam dan AdamW terkait penerapan weight decay	32
Tabel 4.1 Ringkasan umum dataset yang digunakan pada skenario berbasis audio	50
Tabel 4.2 Distribusi official split awal pada dataset.....	51
Tabel 4.3 Ringkasan pemeriksaan kelengkapan dan duplikasi dataset	51
Tabel 4.4 Statistik label Big Five pada keseluruhan metadata.	52
Tabel 4.5 Distribusi metadata demografis berdasarkan kode kategori pada dataset.	54
Tabel 4.6 Ringkasan statistik VAD pada audio hasil standardisasi.	55
Tabel 4.7 Ringkasan representasi data dan fitur yang tersedia dari output EDA.....	57
Tabel 4.8 Tabel parameter standardisasi audio	57
Tabel 4.9 Ringkasan statistik speech_sec (VAD awal, N=10.000 klip)	58
Tabel 4.10 Parameter Silero VAD tuned (untuk re-check 42 klip)	59
Tabel 4.11 Ringkasan hasil drop final (vad_drop.csv, N=26 klip).....	59
Tabel 4.12 Ringkasan jumlah data per tahap praproses	60
Tabel 4.13 Ringkasan kandidat strata utama untuk pembentukan strict split	61
Tabel 4.14 Ukuran strict split (3:1:1) pada level <i>group_id</i> dan klip	61
Tabel 4.15 Distribusi <i>gender</i> dan <i>ethnicity</i> per <i>split</i> (proporsi group-level)	62
Tabel 4.16 Distribusi <i>gender</i> dan <i>ethnicity</i> per <i>split</i> (proporsi clip-level)	62
Tabel 4.17 Komposisi data pada <i>official split</i> setelah <i>VAD drop</i>	63
Tabel 4.18 Ringkasan dimensi fitur tiap metode pada <i>official split</i>	64
Tabel 4.19 Ringkasan hasil tuning alpha berdasarkan mean MAE validation	65
Tabel 4.20 Ringkasan diagnostik <i>train-validation</i> MAE pada alpha terpilih.....	66
Tabel 4.21 Hasil baseline official split pada validation set (mean lima trait)	67
Tabel 4.22 Hasil baseline official split pada test set (mean lima trait).....	68
Tabel 4.23 Per-trait MAE pada test set official split	70
Tabel 4.24 Per-trait R^2 pada test set official split	71
Tabel 4.25 Komposisi data pada strict split setelah VAD drop final	72
Tabel 4.26 Ringkasan representasi data pada baseline strict split.....	72
Tabel 4.27 Hasil <i>tuning</i> alpha <i>strict split</i> berdasarkan mean <i>MAE validation</i>	73
Tabel 4.28 Diagnostik <i>train-validation</i> MAE pada alpha terpilih <i>strict split</i>	74
Tabel 4.29 Hasil <i>baseline strict split</i> pada <i>validation set</i> (mean lima <i>trait</i>).....	75
Tabel 4.30 Hasil <i>baseline strict split</i> pada <i>test set</i> (mean lima <i>trait</i>)	76
Tabel 4.31 Per-trait <i>MAE</i> pada <i>test set strict split</i>	77
Tabel 4.32 Per-trait R^2 pada <i>test set strict split</i>	77
Tabel 4.33 Komposisi data <i>official split</i> dan <i>strict split</i> setelah <i>VAD drop final</i>	79
Tabel 4.34 Perbandingan baseline pada validation set official vs strict.....	79
Tabel 4.35 Perbandingan <i>baseline</i> pada <i>test set</i> official vs strict	80
Tabel 4.36 Perbandingan per-trait WavLM pada <i>test set</i> official vs strict	80

Tabel 4.37 Konfigurasi umum fine-tuning WavLM dengan LoRA	82
Tabel 4.38 Ruang pencarian Optuna dan konfigurasi terbaik	83
Tabel 4.39 Lima trial terbaik pada hyperparameter tuning Optuna	83
Tabel 4.40 Ringkasan parameter yang dianalisis pada sensitivitas hasil tuning Optuna	84
Tabel 4.41 Ringkasan agregat final 10 runs WavLM+LoRA	86
Tabel 4.42 Perbandingan best-val run, median run, dan ensemble WavLM+LoRA	86
Tabel 4.43 Perbandingan baseline strict terbaik dengan hasil WavLM+LoRA pada test_strict	86
Tabel 4.44 Metrik per-trait WavLM+LoRA <i>best-val run</i> pada <i>test_strict</i>	87
Tabel 4.45 Konfigurasi umum fine-tuning HuBERT dengan LoRA	91
Tabel 4.46 Ruang pencarian Optuna dan konfigurasi terbaik HuBERT+LoRA	92
Tabel 4.47 Lima trial terbaik pada hyperparameter tuning Optuna HuBERT+LoRA	93
Tabel 4.48 Ringkasan agregat final 10 runs HuBERT+LoRA	94
Tabel 4.49 Perbandingan best-val run, median run, dan ensemble HuBERT+LoRA	95
Tabel 4.50 Perbandingan baseline strict terbaik dengan hasil HuBERT+LoRA pada test_strict	95
Tabel 4.51 Metrik per-trait HuBERT+LoRA <i>best-val run</i> pada <i>test_strict</i>	97
Tabel 4.52 Perbandingan <i>baseline frozen</i> dan hasil LoRA WavLM-HuBERT pada <i>test_strict</i>	100
Tabel 4.53 Perbandingan hasil penelitian ini dengan penelitian terdahulu yang relevan	101

DAFTAR KODE SEMU

Kode Semu 3.1 Praproses Dataset	38
Kode Semu 3.2 Pembentukan Strict Split	40
Kode Semu 3.3 Skenario Baseline dan Representasi Model	43
Kode Semu 3.4 Skenario Fine-tune	45

Halaman ini sengaja dikosongkan.

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Suara manusia tidak hanya menyampaikan isi pesan, tetapi juga berisi informasi paralinguistik, yaitu isyarat di luar kata-kata yang tercermin dari cara berbicara (misalnya prosodi dan kualitas suara) dan dapat mencerminkan karakteristik penutur (Rubio dkk., 2024). Dalam teknologi pemrosesan ujaran, sinyal suara dimanfaatkan tidak hanya untuk mengenali konten, tetapi juga untuk tugas nonlinguistik, yakni tugas yang tidak berfokus pada pengenalan kata atau teks, seperti pengenalan penutur (Barchi dkk., 2023). Sejalan dengan itu, sejumlah studi melaporkan bahwa karakteristik vokal dapat menjadi petunjuk yang relevan terhadap *trait* kepribadian sehingga memungkinkan estimasi kepribadian berbasis ujaran (Barchi dkk., 2023; Rubio dkk., 2024).

Perkembangan model pembelajaran mesin dan ketersediaan dataset berkontribusi pada perkembangan *automatic personality recognition (APR)* serta memungkinkan pengujian sejauh mana fitur suara dapat memprediksi kepribadian (Ghassemi dkk., 2024; Rubio dkk., 2024). Dalam ranah *apparent personality*, label kepribadian merepresentasikan persepsi pengamat terhadap subjek dari cuplikan perilaku yang tampak ataupun terdengar, bukan skor yang diisi sendiri oleh subjek (*self-report*) (Barchi dkk., 2023; Ghassemi dkk., 2024). Sejumlah studi pada konteks ini memanfaatkan isyarat *multimodal* dari klip video pendek (misalnya *audio* dan *visual*) (Ghassemi dkk., 2024; Zhao dkk., 2022). Namun pendekatan berbasis suara tetap relevan terutama pada skenario yang menekankan interaksi lisan, termasuk seleksi personel (Rubio dkk., 2024).

Rubio dkk. (2024) melaporkan bahwa dalam banyak studi, kepribadian dimodelkan menggunakan kerangka *Big Five* dan dianalisis hubungannya dengan ciri vokal. Beberapa penelitian dalam teknologi analisis suara, sudah menggunakan teori umum yang diterima secara luas seperti *Big Five Personality* dan telah melaporkan temuan yang lebih jelas terkait hubungan ciri vokal dan kepribadian dibanding penelitian terdahulu. Seperti fitur-fitur akustik yang berkorelasi dengan kepribadian manusia. Sebagai contoh, *Extraversion* sering dilaporkan berasosiasi dengan isyarat prosodik seperti kecepatan bicara dan variasi *pitch*. Selain itu, tinjauan lain juga merangkum bahwa kelancaran berbicara, *loudness*, dan *speech rate* dilaporkan berkorelasi dengan *Extraversion*, serta ada temuan yang mengaitkan variasi intensitas maupun persepsi *pitch* dengan penilaian seperti *self-confidence* atau *submissiveness/dominance* (Rubio dkk., 2024).

Dari sisi data, Rubio dkk. (2024) menyebutkan bahwa *First impressions V2 Corpus* (Ponce-López dkk., 2016) adalah salah satu contoh dataset yang dipakai di riset *personality* yang diekstrak dari *YouTube*, sehingga audionya dapat dimanfaatkan untuk eksperimen yang hanya menggunakan audio. Korpus ini terdiri dari 10.000 klip dengan durasi rata rata sekitar 15 detik yang diekstrak dari lebih dari 3.000 video *YouTube*, dan pembagiannya mengikuti rasio *train*, validasi, dan *test* sebesar 3:1:1. Selain menyediakan *audio*, korpus ini juga memberikan label *Big Five* pada rentang 0 sampai 1 untuk setiap klip, sehingga sesuai untuk tugas regresi estimasi kepribadian (Zhao dkk., 2022). Karena setiap klip menyediakan *audio*, penelitian ini memanfaatkan *audio* hasil ekstraksi dari korpus tersebut sebagai sumber data untuk eksperimen estimasi kepribadian dengan data suara.

Pada banyak penelitian awal, prediksi *Big Five* dari suara dilakukan dengan mengekstrak fitur akustik *handcrafted* (misalnya prosodik, spektral, *MFCC*, *jitter*, *shimmer*) yang kemudian dipadukan dengan algoritme prediksi (Barchi dkk., 2023; Rubio dkk., 2024). Salah satu *feature set* yang sering digunakan dalam studi paralinguistik adalah *extended Geneva Minimalistic Acoustic Parameter Set* (eGeMAPS), yaitu kumpulan fitur akustik terstandar yang dirancang untuk analisis aspek afektif dan paralinguistik pada ujaran (Barchi dkk., 2023). Hasil dari pendekatan berbasis fitur ini umumnya masih terbatas. Studi yang memakai set deskriptor akustik yang luas untuk memprediksi *self-report* hanya mampu menjelaskan sekitar 16% variansi (Barchi dkk., 2023). Selain itu, kinerja bisa tampak lebih tinggi jika evaluasi dan pemisahan data tidak ketat (misalnya potongan dari video yang sama muncul di data latih dan uji) (Barchi dkk., 2023). Perkembangan terkini kemudian bergeser ke penggunaan *model pralatih* berbasis Transformer yang mampu mempelajari representasi dari sinyal *audio* secara lebih beragam tanpa bergantung pada rekayasa fitur manual (Barchi dkk., 2023).

Baevski dkk. (2020) memperkenalkan wav2vec 2.0, yang merupakan model *self-supervised* untuk *speech* yang menggunakan Transformer sebagai *context network*. Pada model ini sebagian representasi laten dari *encoder* dan dilakukan *masking*, lalu model dilatih dengan *objective* kontrastif untuk memilih representasi yang benar dari sekumpulan kandidat yang mencakup *distractor*. HuBERT memakai ide *masked prediction* juga, tetapi targetnya berasal dari langkah *offline clustering* sehingga model belajar memprediksi label target pada bagian yang dimasking (Hsu dkk., 2021). WavLM memperluas kerangka ini dengan menambahkan komponen *denoising* (misalnya *input* dibuat *Noisy/overlapped* saat *pretraining*) dan memperbesar data pralatih menjadi sekitar 94.000 jam agar representasinya lebih kuat dipakai di beragam tugas, termasuk non-ASR (Chen dkk., 2022). Dalam penelitian ini, *backbone* pralatih digunakan dalam dua skema, yaitu sebagai *frozen feature extractor* dan sebagai model yang diadaptasi melalui *fine-tuning*. Agar *fine-tuning* lebih efisien dan tidak memerlukan pembaruan seluruh parameter *backbone*, digunakan pendekatan *parameter-efficient fine-tuning* (PEFT) berupa *Low-Rank Adaptation* (LoRA) (Goncalves dkk., 2024; Hu dkk., 2021).

Dari sisi penerapan, estimasi kepribadian berbasis suara sering dibahas untuk skenario yang melibatkan interaksi lisan seperti wawancara kerja dan seleksi personel, serta untuk mendukung perancangan antarmuka suara pada interaksi manusia dan komputer (Rubio dkk., 2024). Namun, agar pendekatan *audio-only* dapat diandalkan, evaluasi perlu dilakukan dengan *pipeline* yang terdefinisi jelas dan protokol pemisahan data yang ketat untuk meminimalkan bias, khususnya pada dataset yang bersumber dari video daring (Barchi dkk., 2023; Ghassemi dkk., 2024). Oleh karena itu, penelitian ini menyusun *pipeline* berbasis audio yang mencakup praproses untuk menstandarkan *input audio*, penerapan *strict split* berbasis *group_id* untuk seleksi model dan *tuning*, serta perbandingan *baseline* fitur *handcrafted* (eGeMAPS) dengan *embedding* dari *backbone* Transformer pralatih (wav2vec 2.0, HuBERT, dan WavLM) dalam skema *frozen feature extraction*. Dua *backbone* terbaik berdasarkan performa validasi pada skema frozen feature extraction dengan *strict split* kemudian diadaptasi menggunakan *fine-tuning* yang efisien melalui LoRA dan dievaluasi menggunakan MAE, RMSE, R^2 , serta $\text{Acc}(1-\text{MAE})$.

1.2 Rumusan Masalah

Berdasarkan latar belakang, diperlukan evaluasi yang terukur untuk menilai efektivitas pendekatan *audio-only* dalam estimasi kepribadian *Big Five*, khususnya dengan protokol

pemisahan data yang ketat guna meminimalkan bias. Oleh karena itu, penelitian ini dirumuskan ke dalam beberapa rumusan masalah berikut:

1. Bagaimana rancangan *pipeline* berbasis audio (praproses dan *strict split*) yang memadai untuk evaluasi estimasi *Big Five*?
2. Bagaimana perbandingan kinerja *embedding* dari *backbone* pralatih dan fitur *handcrafted* pada protokol pemisahan data *strict split* dan *non-strict split* dengan konfigurasi evaluasi yang sama?
3. Bagaimana pengaruh adaptasi LoRA pada *backbone speech* pralatih yang dianalisis pada tahap *fine-tuning* terhadap kinerja prediksi dibandingkan skema *frozen feature extraction*, serta bagaimana pola perubahan kinerjanya pada masing-masing dimensi *Big Five*?

1.3 Batasan Masalah

Untuk menjaga fokus dan keterkelolaan penelitian, maka batasan masalah yang ditetapkan adalah sebagai berikut:

1. Penelitian ini hanya membahas estimasi kepribadian menggunakan kerangka *Big Five*, yaitu *Openness*, *Conscientiousness*, *Extraversion*, *Agreeableness*, dan *Neuroticism*, dengan label regresi.
2. Penelitian ini dibatasi hanya menggunakan dataset *Chlearn First impressions V2* (*First impressions V2 Corpus*) sebagai sumber data dan label. Dataset lain di luar *Chlearn* tidak termasuk dalam ruang lingkup penelitian.
3. Data yang dianalisis hanya berupa suara/*audio*. Data *visual* atau *multimodal* lain tidak termasuk dalam lingkup penelitian ini.
4. *Audio* yang digunakan merupakan hasil ekstraksi dari video pada dataset, dengan durasi maksimum 15 detik per sampel. Seluruh *audio* diseragamkan formatnya melalui praproses (menjadi *mono* 16 kHz) agar konsisten untuk pemodelan.
5. Penelitian ini tidak berfokus pada perbaikan kualitas rekaman secara mendalam. Variasi kualitas suara seperti *noise* atau *musik latar* ditangani sebatas penyesuaian dasar, dan sebagian data dapat dikeluarkan bila tidak memenuhi kriteria kelayakan penelitian.
6. Pendekatan yang dibandingkan dibatasi pada dua kelompok: (a) fitur akustik *handcrafted* (eGeMAPS) dan (b) representasi dari *backbone* Transformer pralatih (wav2vec 2.0, HuBERT, WavLM) dalam skema *frozen feature extractor*.
7. *Fine-tuning* dibatasi pada adaptasi *parameter-efficient* menggunakan LoRA pada *backbone speech* pralatih yang dianalisis pada tahap lanjutan, tanpa melakukan *full fine-tuning* seluruh parameter *backbone* dan tanpa merancang arsitektur *speech* baru.

1.4 Tujuan

Berdasarkan rumusan masalah yang telah disusun, tujuan penelitian ini adalah sebagai berikut:

1. Menyusun dan mendeskripsikan rancangan *pipeline* berbasis audio yang mencakup tahapan praproses dan penerapan *strict split*, sehingga evaluasi estimasi kepribadian *Big Five* dapat dilakukan secara terukur dan konsisten.
2. Membandingkan kinerja representasi suara berupa *embedding backbone* pralatih dengan fitur *handcrafted* pada dua protokol pemisahan data (*strict split* dan *non-strict*

split) menggunakan konfigurasi evaluasi yang sama (praproses, model prediksi, dan metrik).

3. Menganalisis pengaruh adaptasi LoRA pada *backbone speech* pralatih yang dianalisis pada tahap *fine-tuning* terhadap kinerja prediksi dibandingkan skema *frozen feature extraction*, serta mengidentifikasi pola perubahan kinerja pada masing-masing dimensi *Big Five*.

1.5 Manfaat

Penelitian ini diharapkan memberikan kontribusi baik secara akademik maupun praktis. Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan gambaran dan referensi mengenai estimasi kepribadian *Big Five* berbasis *audio-only*, termasuk perbandingan antara fitur akustik *handcrafted* (eGeMAPS) dan representasi dari model *audio* pralatih.
2. Menyediakan rancangan *pipeline* dan protokol evaluasi yang lebih jelas untuk eksperimen yang hanya menggunakan audio pada dataset *Chlearn First impressions V2*, terutama terkait praproses, pemisahan data yang ketat, dan evaluasi kinerja.
3. Memberikan hasil perbandingan kinerja beberapa *backbone* pralatih (wav2vec 2.0, HuBERT, dan WavLM) serta menunjukkan dampak adaptasi efisien menggunakan LoRA terhadap peningkatan kinerja model.
4. Menjadi bahan pertimbangan awal bagi pengembangan sistem yang memanfaatkan informasi suara dalam konteks interaksi lisan, dengan tetap mempertimbangkan batasan dan cakupan penelitian ini.

BAB 2

TINJAUAN PUSTAKA

Bab ini membahas referensi dan teori yang digunakan dalam penelitian. Pembahasan dimulai dari ringkasan penelitian terdahulu yang relevan untuk memberikan gambaran pendekatan yang sudah digunakan pada estimasi kepribadian *Big Five*, terutama pada skenario berbasis suara. Setelah itu, dijelaskan dasar teori yang mendukung perancangan metode penelitian, meliputi karakteristik tugas dan dataset, ekstraksi fitur *audio-only*, penggunaan representasi pralatih, protokol pemisahan data yang lebih ketat untuk mengurangi potensi bias, serta metrik evaluasi yang digunakan. Susunan ini membantu menghubungkan pembahasan literatur dengan rancangan metode pada bab berikutnya.

2.1 Hasil Penelitian Terdahulu

Penyusunan penelitian ini melibatkan penelitian-penelitian terdahulu yang relevan, yang dijadikan sebagai dasar perancangan *pipeline* dan pembandingan hasil pada tugas estimasi kepribadian *Big Five* berbasis *audio-only*. Studi-studi tersebut digunakan untuk memahami karakteristik tugas dan dataset, memilih pendekatan ekstraksi fitur dan pemodelan yang sesuai, serta mengidentifikasi praktik evaluasi yang valid agar hasil yang diperoleh tidak bias. Selain itu, penelitian terdahulu juga dimanfaatkan sebagai pembandingan untuk menempatkan capaian penelitian ini dalam konteks literatur yang ada, baik dari sisi metrik kinerja maupun asumsi dan keterbatasan yang dilaporkan. Ringkasan penelitian terdahulu yang menjadi rujukan utama dalam proposal ini disajikan pada Tabel 2.1.

Studi awal yang menjadi fondasi dataset pada ranah *apparent personality* adalah Ponce-López dkk. (2016) yang dalam konteks *Challenge Chalearn Looking at People (LAP)* 2016. Studi ini memperkenalkan dataset “*First impressions*” yang berisi 10.000 klip pendek dari *YouTube* dengan durasi 15 detik, dan label *Big Five* yang diperoleh dari penilaian manusia (*AMT*), sehingga merepresentasikan *apparent personality* alih-alih *self-report*. Selain itu, dijelaskan juga proses kurasi data dari video *YouTube* dan penekanan konteks “*first impression*” sebagai skenario penilaian. Penelitian ini mengambil dataset tersebut sebagai sumber data utama karena relevan untuk skenario berbasis audio dan memiliki label *Big Five* kontinu. Perbedaannya, penelitian ini memfokuskan eksperimen pada *track audio* serta menerapkan pemisahan data ketat berbasis *group_id* untuk meminimalkan potensi *overlap* antar *split*.

Pada sisi metodologi pemodelan modern, Hu dkk. (2021) memperkenalkan LoRA sebagai pendekatan *parameter-efficient fine-tuning* yang mengadaptasi model besar tanpa memperbarui seluruh bobot pralatih. Ide utamanya adalah menjaga bobot pralatih tetap *frozen* lalu menambahkan komponen ber-*rank* rendah yang dilatih untuk tugas target. Penelitian ini mengambil konsep LoRA untuk tahap adaptasi *backbone* terbaik agar *fine-tuning* lebih efisien. Perbedaannya, pada penelitian ini LoRA dimanfaatkan untuk mengadaptasi *backbone audio* pada tugas regresi estimasi *Big Five* berbasis suara.

Penelitian yang dijadikan referensi dalam penelitian ini adalah Aslan dkk. (2021) yang mengevaluasi prediksi *apparent personality* pada dataset *Chalearn First impressions V2*, yaitu 10.000 video berdurasi rata-rata sekitar 15 detik dengan pembagian *official split* 6.000 *train*, 2.000 *validation*, dan 2.000 *test*, serta label *Big Five* kontinu pada rentang 0 sampai 1 yang diperoleh melalui penilaian manusia (*AMT*). Dengan demikian, label yang digunakan bukan

self-report, melainkan persepsi pengamat. Dari sisi metode, Aslan dkk. (2021) mengusulkan kerangka *multimodal* dengan empat modalitas, yakni *ambient appearance*, *facial appearance*, *voice*, dan *transcribed speech*, yang masing-masing dibangun menggunakan *backbone* pralatih yang dinyatakan eksplisit, yaitu ResNet-v2-101 untuk jalur *visual* (*ambient* dan *face*), *VGGish* untuk jalur *audio* (*voice*), serta ELMo untuk jalur teks (*transcription*). Pada jalur *voice*, *audio* diproses menjadi *log mel-spectrogram* dan dipotong menjadi segmen berdurasi 960 ms (sesuai masukan *VGGish*) sebelum diekstraksi menjadi representasi suara menggunakan *VGGish*, sedangkan jalur teks memanfaatkan representasi ELMo dengan bobot yang dibekukan sebelum dilanjutkan ke lapisan *fully-connected*.

Strategi pelatihan yang dilakukan oleh Aslan dkk. (2021) terbagi oleh dua tahap, yaitu (1) pelatihan *subnetwork* per-modalitas untuk meminimalkan rata-rata MAE lima *trait*, kemudian (2) penggabungan representasi melalui konkatenasi dan pemodelan lanjut menggunakan *feature attention* serta *error consistency constraint* untuk mengurangi perbedaan tingkat kesalahan antar-*trait* sehingga prediksi lebih seimbang. Pada tahap pelatihan digunakan *Adam*, dan *learning rate* dipilih berdasarkan kesalahan validasi terendah, dengan ruang pencarian 10^{-3} hingga 10^{-6} . Nilai terbaik yang dilaporkan adalah 10^{-4} untuk *voice subnetwork* dan 10^{-5} untuk *subnetwork* lainnya. Karena kompleksitas komputasi, hanya enam detik pertama video digunakan untuk modalitas *visual*, sementara *audio* digunakan sepenuhnya. Evaluasi mengikuti metrik *challenge*, yaitu $accuracy = 1 - MAE$, dan kinerja dirangkum sebagai *mean accuracy* (rata-rata akurasi per-*trait*). Hasil utama menunjukkan bahwa *voice* saja mencapai *mean accuracy* 0,9045, penggabungan seluruh modalitas mencapai 0,9172, dan konfigurasi dengan *feature attention* serta *error consistency constraint* mencapai 0,9181. Studi ini diadopsi sebagai rujukan definisi evaluasi berbasis MAE (termasuk pelaporan *mean accuracy*) dan praktik pelatihan yang eksplisit (pemakaian *Adam* dan pemilihan *learning rate* berbasis validasi). Namun, studi tersebut berfokus pada kerangka *multimodal* dengan *official split* serta pembatasan durasi *visual*, sehingga kajian *audio-only* dan protokol pemisahan data yang lebih ketat belum menjadi fokus utama. Berbeda dari (Aslan dkk., 2021), penelitian ini berfokus pada skenario berbasis audio, menerapkan pemisahan data yang lebih ketat berbasis *group_id* untuk mengurangi potensi bias, membandingkan *baseline* fitur *handcrafted* (eGeMAPS) dengan *embedding* dari *backbone* Transformer pralatih khusus *audio* (wav2vec 2.0, HuBERT, dan WavLM) dalam skema *frozen feature extraction*, lalu mengadaptasi *backbone* terbaik melalui *fine-tuning* efisien menggunakan LoRA.

Penelitian yang dilakukan oleh Zhao dkk. (2022) menggunakan dataset *ChaLearn First Impressions V2* untuk memprediksi skor *Big Five* dan interview score dengan memanfaatkan modalitas *audio* dan *visual*. Pada sisi *audio*, studi tersebut menggunakan *VGGish* sebagai ekstraktor representasi suara, sedangkan pada sisi *visual* digunakan representasi berbasis *VGG-Face* untuk fitur wajah dan latar. Representasi tiap modalitas kemudian dimodelkan menggunakan kombinasi *Bi-LSTM* dan Transformer, lalu hasil prediksi digabungkan melalui *weighted decision-level fusion*. Evaluasi mengikuti metrik *challenge*, yaitu ($S = 1 - MAE$). Hasil eksperimen menunjukkan bahwa pada skenario *single-modality*, *audio* memperoleh rata-rata *Big Five* sebesar 0,8952, lebih rendah dibandingkan latar sebesar 0,9039 dan wajah sebesar 0,9124, sedangkan penggabungan *multimodal* meningkatkan kinerja menjadi 0,9167. Penelitian ini relevan sebagai pembanding karena menggunakan dataset dan metrik yang sama, sekaligus menunjukkan bahwa performa *audio-only* pada *official split* cenderung berada di bawah *visual* dan *multimodal*. Berbeda dari Zhao dkk. (2022), penelitian ini berfokus pada skenario berbasis audio, menerapkan *strict split* berbasis *group_id*, membandingkan eGeMAPS dengan

embedding SSL wav2vec 2.0, HuBERT, dan WavLM, serta mengadaptasi *backbone* melalui LoRA.

Penelitian selanjutnya yang dijadikan rujukan adalah Barchi dkk. (2023) yang memfokuskan prediksi *apparent personality* dari sinyal ujaran dengan memanfaatkan representasi *self-supervised* (wav2vec 2.0) dan fitur akustik *handcrafted* pada “*First impressions Dataset*” (Chalearn LAP 2016), yaitu sekitar 10.000 klip berdurasi 15 detik dari *YouTube vlog* dengan label *Big Five* hasil penilaian pendengar (AMT) dan kemudian dinormalisasi, sehingga labelnya bukan *self-report*. Studi ini menyoroti isu kualitas data *audio*, khususnya keberadaan *musik latar*, lalu melakukan anotasi keberadaan musik dan memfokuskan eksperimen utama pada subset tanpa musik agar sinyal ujaran lebih dominan. Dari sisi representasi, Barchi dkk. (2023) membandingkan dua jalur utama pada skenario berbasis audio: (1) jalur “klasik” berupa eGeMAPS yang diekstraksi dengan openSMILE serta ditambah fitur *speech ratio* (rasio durasi bicara) yang dihitung menggunakan Silero VAD, dan (2) jalur “modern” berupa *embedding* wav2vec 2.0 base yang diekstraksi dari seluruh *layer* (bukan hanya *layer* terakhir. Untuk pemodelan, digunakan *Random Forest Regressor* dengan ringkasan *embedding* wav2vec 2.0 yang direduksi dimensinya menggunakan *PCA*, serta DNN yang memanfaatkan urutan *embedding* wav2vec 2.0 sebelum dilakukan *pooling* untuk memprediksi lima *trait*. Berbeda dengan metrik berbasis MAE pada *challenge*, Barchi dkk. (2023) mengevaluasi kinerja menggunakan koefisien determinasi R^2 dan melaporkan R^2_{avg} sebagai rata-rata per-*trait*.

Barchi dkk. (2023) menekankan pentingnya protokol pemisahan data yang tidak “bocor” dengan menunjukkan bahwa *official split* dapat menghasilkan kinerja yang terlalu optimistis karena potongan dari video yang sama bisa muncul di *split* berbeda, sehingga mereka menerapkan pemisahan berdasarkan *video identifier* dan menjaga keseimbangan distribusi melalui stratifikasi (*gender*, *ethnicity*, dan rata-rata *rating*) dalam skema *5-fold cross-validation*. Hasil utamanya menunjukkan bahwa model DNN berbasis wav2vec 2.0 mencapai R^2_{avg} sekitar 0,33 pada *official split*, namun turun menjadi sekitar 0,28 pada *split* yang lebih ketat berbasis *video identifier*, yang memperkuat argumen bahwa evaluasi sangat sensitif terhadap strategi *split* (Barchi dkk., 2023). Studi ini relevan dan selaras dengan penelitian ini karena sama-sama menempatkan eGeMAPS sebagai *baseline*, memanfaatkan *embedding self-supervised* dari model *audio* pralatih, dan menekankan perlunya pemisahan data yang ketat untuk mengurangi bias pada dataset berbasis video daring. Metode yang diadopsi dari Barchi dkk. (2023) dalam penelitian ini adalah (1) penggunaan eGeMAPS sebagai pembanding *baseline audio-only*, (2) pemanfaatan Silero VAD untuk memperoleh informasi terkait durasi bicara dan rasionya, serta (3) prinsip pemisahan data yang ketat berbasis grup untuk meminimalkan *overlap* yang dapat membuat kinerja terlihat lebih tinggi. Adapun perbedaannya, penelitian ini tidak membatasi eksplorasi pada wav2vec 2.0 saja, melainkan membandingkan beberapa *backbone* Transformer pralatih khusus *audio* (wav2vec 2.0, HuBERT, dan WavLM) pada skema *frozen feature extraction*, kemudian mengadaptasi *backbone* terbaik melalui *fine-tuning* efisien menggunakan LoRA. Selain itu, evaluasi difokuskan pada metrik berbasis MAE agar konsisten dengan karakter tugas regresi *Big Five* pada dataset tersebut. Gap yang dapat ditarik dari studi Barchi dkk. (2023) untuk menjadi motivasi penelitian ini adalah terbatasnya eksplorasi *backbone audio* pralatih di luar wav2vec 2.0 serta belum adanya kajian adaptasi parameter-efisien untuk meningkatkan kinerja pada skenario berbasis audio dengan protokol pemisahan data yang ketat.

Salah satu referensi lain yang diambil adalah penelitian oleh Rubio dkk. (2024) yang melakukan estimasi kepribadian dengan merekam 100 partisipan saat wawancara, lalu membandingkan prediksi berbasis suara terhadap skor *Big Five* dari *NEO-FFI (NEO Five-Factor Inventory)* yang mana merupakan sebuah kuesioner yang bersifat *self-report*, penilaian orang dekat, dan *rating* ahli. Pada sisi pemrosesan, Rubio menggunakan pendekatan *audio-only* yang masih klasik, yaitu mengambil segmen *audio* dari wawancara lalu mengekstrak fitur menggunakan OpenSMILE dengan set AVEC2011 sebanyak sekitar 1941 fitur yang mencakup *MFCC*, *jitter*, *shimmer*, dan berbagai fitur akustik lain. Untuk tahap prediksi, skor tiap *trait Big Five* yang awalnya kontinu diubah menjadi tiga kelas (low/medium/high) menggunakan batas persentil P25 dan P75 pada data *training*, sehingga 25% terbawah menjadi low, 50% di tengah menjadi medium, dan 25% teratas menjadi high. Selanjutnya dalam studi dilakukan *Random Forest* untuk mengklasifikasikan *level* tersebut, dengan *input* top-5 fitur yang korelasinya paling tinggi terhadap *trait* yang diprediksi. Hasilnya menunjukkan adanya sinyal prediktif pada fitur suara dengan korelasi yang cenderung moderat (skor *pearson r* sekitar 0,3–0,4), sehingga suara dapat memberi “petunjuk” terhadap *trait* meskipun belum deterministik, dan kemudian dilakukan prediksi model klasifikasi (low/medium/high) dan didapatkan kinerja yang memiliki akurasi keseluruhan 43% hingga 60% tergantung *trait* dan sumber label. Dalam penelitian ini, bagian yang diadopsi dari Rubio dkk. (2024) adalah konteks bahwa sinyal paralinguistik pada suara dapat digunakan untuk mengestimasi *Big Five* dan pentingnya pelaporan evaluasi yang eksplisit, namun perbedaan utama terletak pada penggunaan dataset *Chlearn First impressions V2* dengan label *apparent personality* pada rentang 0 sampai 1, fokus pada skenario regresi *audio-only*, penerapan pemisahan data yang lebih ketat berbasis *group_id* untuk meminimalkan potensi bias, serta perbandingan representasi fitur *handcrafted* eGeMAPS dibanding AVEC2011 yang digunakan Rubio dkk. (2024) dalam penelitiannya. Selain itu, penelitian ini menambahkan perbandingan dari *backbone* Transformer pra-latih khusus *audio* (wav2vec 2.0, HuBERT, WavLM), kemudian mengadaptasi *backbone* terbaik melalui *fine-tuning* efisien menggunakan LoRA.

Penelitian lain yang dijadikan referensi dalam penelitian ini adalah penelitian oleh Ghassemi dkk. (2024) yang mengusulkan kerangka *multimodal* untuk prediksi *apparent personality* pada dataset *Chlearn First impressions V2*, yang berisi 10.000 video berdurasi 15 detik dengan label *Big Five* (serta *Interview score*) pada rentang 0 sampai 1 dari penilaian pengamat. Dalam studi tersebut digunakan tiga modalitas utama yaitu *audio*, *visual*, dan *verbal* (transkrip) dengan representasi yang menggabungkan fitur *handcrafted* dan *embedding* hasil *transfer learning*: *audio* diekstrak sebagai fitur akustik berbasis jendela waktu dan *embedding* berbasis Wav2Vec, *visual* menggunakan fitur OpenFace serta *embedding CNN* bergaya FaceNet/Inception, sedangkan transkrip dipetakan menjadi *embedding* menggunakan BERT. Untuk merangkum informasi temporal, Ghassemi dkk. (2024) memperkenalkan agregasi temporal tak terawasi yang mengombinasikan fungsi statistik dan *temporal autoencoder*, lalu melakukan *early fusion* sebelum modul regresi berbasis *deep ensemble MLP*.

Aspek penting lain pada penelitian (Ghassemi dkk., 2024) adalah protokol pemisahan data: selain mengevaluasi pada *official split*, studi ini menekankan adanya *subject-dependency* pada *split* asli dan mengusulkan *dependency-free split* berbasis *YouTube channel ID* dengan pembagian 6.000/2.000/2.000 agar validasi lebih mencerminkan generalisasi antarsubjek. Evaluasi dilaporkan menggunakan R^2 dan *mean accuracy* $A = 1 - \text{MAE}$, dengan R^2 sebagai metrik utama dan A untuk perbandingan dengan literatur. Hasil kunci menunjukkan bahwa pada *dependency-free split* gabungan *audio* dan *visual* mencapai R^2 rata-rata sekitar 0,369,

sedangkan fitur *verbal* sendiri relatif lemah (R^2 rata-rata sekitar 0,037), dan pada *split* asli nilai rata-rata dapat meningkat hingga sekitar R^2 0,514 (dengan *mean accuracy* sekitar 0,919), yang mengindikasikan bahwa evaluasi pada *split* asli berpotensi terlalu optimis. Keterbatasan yang relevan untuk konteks penelitian ini adalah fokus Ghassemi dkk. (2024) yang dominan pada skenario *multimodal* dan rancangan agregasi temporal/strategi fitur, sehingga eksplorasi khusus skenario berbasis audio serta perbandingan sistematis antar *backbone audio* terkini dan adaptasi *parameter-efficient fine-tuning* tidak menjadi fokus utama. Kontribusi yang diadopsi pada penelitian ini terutama adalah penekanan pentingnya pemisahan data yang lebih ketat untuk meminimalkan bias/*leakage* serta pelaporan evaluasi berbasis MAE (dan $1 - \text{MAE}$) sebagai pembanding literatur, sedangkan pembedanya adalah fokus *audio-only* tanpa *visual*/transkrip, pembandingan *baseline* eGeMAPS dengan *backbone* Transformer pralatih khusus *audio* dalam skema *frozen feature extraction*, dan adaptasi *backbone* terbaik melalui *fine-tuning* efisien menggunakan LoRA.

Tabel 2.1 Tabel Penelitian Terkait

Judul	Setup Dataset	Metode Inti	Diadopsi pada Penelitian Ini	Perbedaan dan Gap yang diisi
<i>Multimodal assessment of apparent personality using feature attention and error consistency constraint</i> (Aslan dkk., 2021)	<i>Chalearn</i> FI-V2 (Ponce-López dkk., 2016), <i>official split</i> 6.000/2.000/2.000 label <i>Big Five</i> 0 sampai 1 (AMT) dengan 4 modalitas : visual <i>ambient</i> , wajah, suara, transkrip.	<i>Backbone</i>: ResNet-v2-101 (visual), VGGish (suara), ELMo (teks). - Dua tahap: pelatihan per modalitas lalu fusi dengan <i>feature attention</i> dan <i>error consistency</i>. - Metrik: 1 – MAE dengan <i>mean accuracy</i> terbaik sekitar 0,918.	Evaluasi berbasis MAE dan pelaporan 1 – MAE (<i>mean accuracy</i>) dan contoh pelaporan hasil per- <i>trait</i> dan rata-rata.	Fokus utama multimodal dan <i>official split</i> . Sedangkan penelitian ini berfokus <i>audio-only</i> , dengan dua jenis <i>split</i> , dan membandingkan eGeMAPS vs <i>backbone</i> audio Transformer, lalu LoRA untuk adaptasi <i>backbone</i> terbaik.
<i>Integrating audio and visual modalities for multimodal personality trait recognition via hybrid deep learning</i> (Zhao dkk., 2022)	<i>Chalearn</i> FI-V2 (Ponce-López dkk., 2016), <i>split</i> 6.000/2.000/2.000 dengan prediksi <i>Big Five</i> dan <i>Interview score</i> dengan modalitas audio dan visual (latar dan wajah).	- Representasi: VGGish (audio) dan VGG-Face (visual). - Model temporal: Bi-LSTM dan Transformer dan fusi keputusan berbobot. - Metrik: $S = 1 - \text{MAE}$, kinerja multimodal sekitar 0,9167, <i>audio-only</i> lebih rendah dari visual.	Acuan metrik <i>challenge</i> berbasis MAE ($S = 1 - \text{MAE}$) sebagai pembanding literatur.	Studi berfokus multimodal dan representasi audio VGGish dan tidak ada perbandingan <i>backbone</i> audio Transformer modern. Sedangkan penelitian ini mengevaluasi <i>audio-only</i> dengan eGeMAPS vs wav2vec 2.0/HuBERT/WavLM, <i>split</i> ketat berbasis <i>group_id</i> , lalu LoRA pada <i>backbone</i> terbaik.

Judul	Setup Dataset	Metode Inti	Diadopsi pada Penelitian Ini	Perbedaan dan Gap yang diisi
<i>Apparent personality prediction from speech using expert features and wav2vec 2.0</i> (Barchi dkk., 2023)	<i>First impressions.</i> Berisi sekitar 10.000 klip 15 detik; label <i>Big Five</i> dari AMT (<i>apparent</i>) dengan analisis musik latar dan subset tanpa musik.	• <i>Baseline</i>: eGeMAPS dan fitur durasi bicara dari Silero VAD. • Representasi modern: <i>embedding</i> wav2vec 2.0; model RF dan DNN. • Metrik: R^2_{avg}; DNN sekitar 0,33 (<i>official</i>) turun sekitar 0,28 pada <i>split</i> lebih ketat.	eGeMAPS sebagai <i>baseline</i> , Silero VAD untuk statistik durasi bicara, dan sebagai motivasi pentingnya <i>split</i> ketat.	Studi mengeksplor wav2vec 2.0 dan belum membahas adaptasi PEFT untuk <i>audio-only</i> . Sedangkan penelitian ini membandingkan wav2vec 2.0/HuBERT/WavLM pada skema <i>frozen</i> , lalu LoRA untuk <i>backbone</i> terbaik dengan protokol <i>split</i> berbasis <i>group_id</i> .
<i>Feasibility of Big Data Analytics to Assess Personality Based on Voice Analysis</i> (Rubio dkk., 2024)	100 partisipan wawancara dengan label <i>Big Five</i> dari NEO-FFI (<i>self-report</i>) dan pembandingan dengan penilaian pihak lain (orang dekat dan ahli).	• Fitur akustik OpenSMILE (AVEC2011 sekitar 1941 fitur). • Prediksi dibuat klasifikasi 3 kelas; model Random Forest. • Prediksi dibuat klasifikasi 3 kelas dengan model Random Forest.	Konteks relevansi sinyal paralinguistik dan pentingnya pelaporan evaluasi eksplisit.	Setup berbeda (<i>self-report</i> dan klasifikasi 3 kelas, bukan regresi <i>apparent personality</i>). Penelitian ini memakai <i>Chlearn</i> FI-V2 (<i>apparent</i> , regresi dengan nilai 0 sampai 1), <i>audio-only</i> , <i>split</i> ketat berbasis <i>group_id</i> , serta membandingkan eGeMAPS dan <i>embedding backbone</i> audio Transformer.

Judul	Setup Dataset	Metode Inti	Diadopsi pada Penelitian Ini	Perbedaan dan Gap yang diisi
<i>Unsupervised Multimodal Learning for Dependency-free Personality Recognition</i> (Ghassemi dkk., 2024)	<i>Chalearn</i> FI-V2 (Ponce-López dkk., 2016), 10.000 video 15 detik; label <i>Big Five</i> nilai 0 sampai 1 (<i>apparent</i>) dan konteks evaluasi pada <i>official</i> vs <i>dependency-free split</i> berbasis YouTube <i>channel ID</i> .	- Representasi: BERT (teks), wav2vec (audio), OpenFace dan CNN (visual). - Peringkasan temporal tak terawasi dan <i>ensemble</i> MLP untuk regresi. - Hasil: audio dan visual R^2_{avg} sekitar 0,369 pada <i>dependency-free</i>, pada <i>official split</i> bisa lebih tinggi.	Motivasi bahwa pemisahan data yang lebih ketat diperlukan untuk mengurangi bias pada dataset berbasis kanal. Dan ide pelaporan MAE/1 – MAE sebagai pembandingan literatur.	Fokus dominan multimodal dan desain peringkasan temporal. Masih tidak ada eksplorasi <i>audio-only</i> dan perbandingan beberapa <i>backbone</i> audio modern. Sedangkan penelitian ini memusatkan evaluasi pada <i>audio-only</i> dengan ekstraksi fitur eGeMAPS dan Transformers

2.2 Dasar Teori

Subbab ini menjelaskan dasar teori yang digunakan sebagai acuan dalam penelitian. Pembahasan mencakup konsep kepribadian *Big Five* dan karakter tugas prediksi berbasis *audio*, serta gambaran umum dataset yang digunakan. Selanjutnya dibahas prinsip pengolahan sinyal ujaran dan pendekatan ekstraksi fitur, baik fitur *handcrafted* maupun representasi *embedding* dari model *self supervised speech*. Subbab ini juga menguraikan konsep pemodelan regresi untuk memprediksi lima *trait* kepribadian, termasuk pilihan *baseline* dan pendekatan *fine-tuning* yang efisien parameter seperti LoRA. Pada bagian akhir dijelaskan konsep optimisasi dan strategi pelatihan model, metrik evaluasi, serta prinsip pembagian data sebagai landasan untuk metode yang dipaparkan pada bab berikutnya.

2.2.1 Kepribadian *Big Five*

Model Lima Faktor atau yang dikenal sebagai *Big Five Personality* merupakan organisasi hierarkis dari sifat-sifat kepribadian yang dikelompokkan ke dalam lima dimensi dasar, yaitu *Extraversion*, *Agreeableness*, *Conscientiousness*, *Neuroticism*, dan *Openness to Experience* (McCrae & John, 1992). Model ini berakar pada hipotesis leksikal, yang menyatakan bahwa perbedaan individu yang paling penting dalam transaksi manusia akan dikodekan sebagai istilah tunggal dalam bahasa (Goldberg, 1990). Pendekatan ini mengasumsikan bahwa analisis terhadap struktur bahasa sifat (*trait adjectives*) dapat mengungkap taksonomi komprehensif dari kepribadian manusia (Goldberg, 1990; McCrae & John, 1992).

Secara spesifik, kelima dimensi tersebut merepresentasikan *level* abstraksi tertinggi dalam deskripsi kepribadian sebagai berikut.

1. *Extraversion* (atau *Surgency*), berkaitan dengan kuantitas dan intensitas interaksi interpersonal serta tingkat aktivitas, di mana individu dengan skor tinggi cenderung bersosialisasi, aktif, dan asertif, sedangkan individu dengan skor rendah cenderung pendiam dan menarik diri (Goldberg, 1990; McCrae & John, 1992).
2. *Agreeableness*, mencerminkan kualitas orientasi interpersonal seseorang mulai dari belas kasih (*compassion*) hingga antagonisme dalam pikiran, perasaan, dan tindakan (McCrae & John, 1992).
3. *Conscientiousness* (atau *Dependability*), menggambarkan derajat organisasi, ketekunan, dan motivasi dalam perilaku yang diarahkan pada tujuan, yang membedakan individu yang dapat diandalkan dan tertib dengan mereka yang lalai atau tidak teratur (Goldberg, 1990; McCrae & John, 1992).
4. *Neuroticism* (lawan dari *Emotional Stability*) mengacu pada kecenderungan untuk mengalami distress psikologis dan afek negatif kronis seperti kecemasan, depresi, dan rasa tidak aman (McCrae & John, 1992).
5. *Openness to Experience* yang mencakup apresiasi terhadap seni, emosi, petualangan, ide-ide yang tidak biasa, serta rasa ingin tahu. Meskipun terdapat variasi dalam penamaan faktor kelima, struktur lima faktor ini terbukti kuat (*robust*) dan dapat direplikasi lintas berbagai metode ekstraksi faktor maupun budaya yang berbeda (Goldberg, 1990; McCrae & John, 1992).

2.2.2 *Apparent Personality & Karakter Tugas Prediksi*

Dalam ranah komputasi kepribadian, terdapat perbedaan mendasar antara kepribadian yang dilaporkan sendiri (*self-reported personality*) dan kepribadian yang tampak (*apparent personality*). Sementara *self-reported personality* diperoleh melalui kuesioner yang diisi oleh subjek, *apparent personality* mengacu pada persepsi atau kesan pertama (*first impressions*) yang dibentuk oleh pengamat eksternal terhadap subjek berdasarkan paparan perilaku yang singkat (Barchi dkk., 2023; Ponce-López dkk., 2016). Dataset *First impressions V2* yang digunakan dalam penelitian ini dirancang khusus untuk tugas prediksi *apparent personality*, di mana label kebenaran dasar (*ground truth*) tidak mencerminkan profil psikologis internal subjek, melainkan bagaimana subjek tersebut dipersepsikan oleh orang lain dalam konteks interaksi sosial singkat, seperti wawancara kerja (Ponce-López dkk., 2016).

Karakteristik utama dari tugas prediksi pada dataset ini adalah penggunaan label kontinu dalam rentang untuk kelima dimensi *Big Five*. Label ini diperoleh melalui mekanisme anotasi manusia menggunakan *Amazon Mechanical Turk (AMT)*. Karena penilaian kepribadian bersifat subjektif dan rentan terhadap bias penilai, Ponce-López dkk. (2016) menerapkan strategi pelabelan berbasis perbandingan berpasangan (*pairwise comparisons*). Dalam metode ini, penganotasi tidak memberikan skor absolut, melainkan membandingkan dua video dan menentukan subjek mana yang lebih menonjol pada *trait* tertentu. Skor kardinal akhir kemudian direkonstruksi menggunakan model *Bradley-Terry-Luce (BTL)* untuk mengurangi variansi dan bias kalibrasi antar penganotasi (Ponce-López dkk., 2016).

Tugas prediksi ini pada dasarnya adalah masalah regresi, di mana model dilatih untuk meminimalkan selisih antara skor prediksi dan label persepsi manusia. Evaluasi standar dalam tugas ini umumnya menggunakan metrik akurasi rata-rata (*Mean Accuracy*) yang didefinisikan sebagai $1 - \text{MAE}$ (*Mean Absolute Error*) (Ponce-López dkk., 2016). Namun, Barchi dkk. (2023) menyarankan penggunaan koefisien determinasi (R^2) sebagai metrik pelengkap untuk melihat proporsi variansi yang dapat dijelaskan oleh model, mengingat tugas ini memiliki tingkat kesulitan yang tinggi. Berdasarkan analisis Barchi dkk. (2023), dimensi *Agreeableness* konsisten menjadi *trait* yang paling sulit diprediksi dibandingkan *trait* lainnya, yang diduga disebabkan oleh rendahnya kesepakatan antar penganotasi manusia untuk dimensi tersebut.

Tantangan lain dalam tugas prediksi ini berkaitan dengan bias demografis dan protokol evaluasi. Barchi dkk. (2023) mencatat adanya ketidakseimbangan representasi etnis dalam dataset serta bias penilaian, di mana subjek perempuan cenderung mendapatkan skor rata-rata yang lebih tinggi dibandingkan laki-laki pada kelima *trait*. Selain itu, terdapat isu kritical pada pembagian data resmi (*official split*) dataset ini, di mana potongan klip dari video asli yang sama dapat tersebar ke dalam data latih (*training*) dan data uji (*test*). Kondisi ini dapat menyebabkan kebocoran informasi (*data leakage*), sehingga model mengenali kondisi akustik atau latar belakang subjek alih-alih mempelajari fitur kepribadian, yang berujung pada hasil evaluasi yang terlalu optimis (Barchi dkk., 2023). Oleh karena itu, strategi pembagian data yang ketat berdasarkan identitas video atau grup sangat diperlukan untuk memastikan validitas pengukuran kinerja model prediksi.

2.2.3 *Dataset First impressions V2 (Chalearn)*

Dataset *First impressions V2* merupakan korpus skala besar yang dikembangkan untuk tugas analisis kepribadian otomatis berdasarkan persepsi (*apparent personality*) dalam konteks

tantangan *Chalearn Looking at People*. Dataset ini terdiri dari 10.000 klip video pendek berdurasi rata-rata 15 detik yang diekstraksi dari lebih dari 3.000 video *YouTube* definisi tinggi (HD). Subjek dalam video berbicara menghadap kamera dalam bahasa Inggris, yang merepresentasikan situasi presentasi diri atau wawancara kerja daring (Ponce-López dkk., 2016).

Label anotasi utama pada dataset ini mencakup lima dimensi kepribadian (*Big Five Personality Traits*), yaitu *Openness*, *Conscientiousness*, *Extraversion*, *Agreeableness*, dan *Neuroticism*. Dalam konteks *apparent personality*, label tersebut tidak merepresentasikan kepribadian internal subjek secara objektif, melainkan skor persepsi yang dibentuk dari penilaian manusia menggunakan layanan *Amazon Mechanical Turk (AMT)* melalui mekanisme perbandingan berpasangan (*pairwise comparisons*) antar video. Skor akhir direkonstruksi menggunakan model *Bradley-Terry-Luce (BTL)* menjadi nilai kontinu dalam rentang (Ponce-López dkk., 2016). Pada pengembangan selanjutnya untuk kompetisi penyaringan kandidat kerja, dimensi *Neuroticism* sering dikonversi menjadi *Non-Neuroticism* (kestabilan emosi) agar semua skor memiliki skala positif (Escalante dkk., 2022).

Selain dimensi kepribadian, Escalante dkk. (2022) memperkaya dataset ini dengan label tambahan untuk mendukung tugas analisis *explainability* dan rekomendasi perekrutan. Anotasi tambahan tersebut adalah sebagai berikut.

1. Variabel Wawancara Kerja (*Job-Interview Variable*): Sebuah label yang mengindikasikan apakah seseorang layak diundang untuk wawancara kerja atau tidak, berdasarkan skor kuantitatif prediksi kepribadian.
2. Atribut Demografis: untuk keperluan analisis bias, dataset ini dilengkapi dengan anotasi manual terhadap *gender* dan *apparent ethnicity*. Pada metadata *ChaLearn First Impressions V2*, *gender* direpresentasikan secara numerik dengan nilai 1 untuk laki-laki dan 2 untuk perempuan. Sementara itu, *ethnicity* direpresentasikan dengan nilai 1 untuk Asian, 2 untuk Caucasian, dan 3 untuk African-American. Kategori ini perlu dipahami sebagai anotasi perseptual berdasarkan tampilan video, bukan sebagai identitas etnis aktual yang diverifikasi langsung dari subjek.
3. Kelompok Usia (*Age Groups*): Subjek dalam video dianotasi ke dalam delapan kelompok usia terpisah, yaitu: 0–6, 7–13, 14–18, 19–24, 25–32, 33–45, 46–60, dan 61+ tahun.
4. Transkripsi Teks: Transkripsi manual dari ucapan *audio* disediakan untuk memungkinkan penggunaan modalitas teks dalam analisis.

Distribusi data standar membagi 10.000 klip ini menjadi 6.000 data latih (*training*), 2.000 data validasi, dan 2.000 data uji (*test*) (Escalante dkk., 2022; Ponce-López dkk., 2016). Keberagaman subjek dijaga dengan mengambil sumber dari ribuan saluran *YouTube* yang berbeda, mencakup variasi luas dalam hal *gender*, usia, dan latar belakang etnis (Ponce-López dkk., 2016).

2.2.4 Praproses Audio

Dalam sistem prediksi kepribadian berbasis suara, praproses bertujuan memastikan sinyal audio memiliki format yang konsisten dan memuat informasi ujaran yang memadai sebelum masuk ke tahap ekstraksi fitur maupun pemodelan. Pada dataset *First impressions Chalearn* (Ponce-

López dkk., 2016), data berasal dari klip YouTube sehingga variasi kondisi perekaman (misalnya perbedaan format, laju sampel, serta keberadaan segmen hening atau musik latar) perlu ditangani melalui standarisasi dan pembersihan berbasis kualitas ujaran (Barchi dkk., 2023; Ghassemi dkk., 2024).

a) Standardisasi format sinyal

Langkah awal praproses adalah memuat dan mendekode audio untuk memastikan berkas dapat diproses dengan benar dan menghasilkan sinyal yang valid. Setelah audio berhasil dibaca, sinyal diseragamkan ke format deterministik (misalnya mono) dan laju sampel disesuaikan agar konsisten dengan praktik *input* pada model *self-supervised speech* yang umum digunakan. Sebagai contoh, pada implementasi *feature extractor wav2vec 2.0*, parameter *sampling_rate* secara default menggunakan 16.000 Hz sehingga audio umumnya diseragamkan ke 16 kHz sebelum diekstraksi fiturnya (Baevski dkk., 2020).

b) Penyeragaman durasi (*trim*/pad ke durasi target)

Dataset *First impressions* menyediakan klip berdurasi 15 detik. Untuk memudahkan pemrosesan *batch* dan menjaga konsistensi dimensi *input*, sinyal biasanya dipaksa menjadi panjang tetap T (misalnya 15 detik) melalui *trimming* atau *padding* (Barchi dkk., 2023). Secara operasional, panjang target dalam satuan sampel dapat dinyatakan sebagai:

$$LT = T \cdot f_s \quad (2.1)$$

Hubungan ini mengikuti definisi f_s sebagai “jumlah sampel per detik”, sehingga total sampel untuk durasi T diperoleh dari perkalian T dan f_s (Smith, 1999). Jika panjang sinyal $L \geq L_T$, sinyal dipotong hingga L_T . Jika $L < L_T$, sinyal diisi (*padding*) sampai L_T , dan sampel dapat ditandai sebagai durasi pendek untuk analisis lanjutan. Selain itu, sampel yang sangat pendek umumnya kurang informatif karena tidak menyediakan konteks temporal yang memadai. Barchi dkk. menunjukkan bahwa kinerja model menurun tajam ketika durasi sinyal semakin pendek.

c) *Voice Activity Detection* dan pengukuran rasio ujaran

Voice Activity Detection (VAD) merupakan teknik pemrosesan wicara untuk membedakan bagian yang mengandung *speech* dan *non-speech* (misalnya hening/*noise*) pada sinyal audio. Dalam konteks penelitian *audio-only* pada *First impressions*, Barchi dkk. mengekstraksi *speech* timestamps menggunakan Silero VAD, lalu menghitung *speech* ratio sebagai rasio durasi ujaran terhadap durasi total seperti pada persamaan 2.2 berikut (Silero Team, 2024).

$$speech_{sec} = \sum_{i=1}^N (t_i^{end} - t_i^{start}) \quad (2.2)$$

Selanjutnya, *speech* ratio (atau *voiced* ratio) didefinisikan sebagai perbandingan durasi ujaran terhadap durasi total sinyal. Dengan durasi total T , perhitungannya tertulis pada persamaan 2.3 sebagai berikut:

$$speech_{ratio} = \frac{speech_{sec}}{T} \quad (2.3)$$

2.2.5 Protokol Pembagian Data & Risiko *Leakage*

Pembagian data ke dalam set pelatihan, validasi, dan pengujian dilakukan agar kinerja model dapat dinilai pada data yang tidak ikut dipakai saat pelatihan. Pada dataset yang dikumpulkan dari lingkungan tidak terkontrol seperti *YouTube*, sampel sering berasal dari sumber yang sama sehingga pola rekaman, karakter pembicara, atau konteks video dapat menjadi mirip antar sampel. Jika kemiripan yang berasal dari sumber tersebut ikut terbawa ke set yang berbeda, maka kinerja yang diukur tidak sepenuhnya menggambarkan kemampuan generalisasi model pada data baru. Kondisi ini dibahas dalam konteks *First impressions* oleh Barchi dkk. (2023) dan Ghassemi dkk. (2024).

Pada protokol pembagian resmi, risiko kebocoran dapat muncul ketika potongan dari video yang sama terdistribusi ke lebih dari satu *split*. Situasi ini dijelaskan oleh Barchi dkk. (2023), dan hasil evaluasi yang diperoleh kemudian dapat menjadi lebih tinggi karena model berhadapan dengan kondisi data uji yang masih memiliki kedekatan dengan data latih. Dalam konteks ini, kebocoran tidak selalu berarti duplikasi file yang persis sama, namun lebih sering muncul sebagai kemiripan sumber yang membuat data uji tidak benar benar independen dari data latih (Barchi dkk., 2023).

Risiko yang serupa juga dijelaskan pada *level* yang lebih tinggi oleh Ghassemi dkk. (2024), yaitu pada *level* kanal *YouTube*. Ketika video dari kanal yang sama tersebar ke *train*, validasi, dan *test*, hubungan antar sampel dapat terbentuk karena gaya perekaman dan karakteristik konteks kanal cenderung konsisten. Hal tersebut dapat membuat proses pengembangan model menjadi bias, karena pemilihan hiperparameter yang dilakukan berdasarkan validasi berpotensi ikut terbantu oleh kesamaan kanal antara *training* dan *validation*. Dalam studi tersebut, pembagian yang dibuat bebas ketergantungan pada *level* kanal ditujukan untuk mengurangi efek ini, sehingga pengukuran kinerja lebih mendekati kondisi generalisasi yang diharapkan Ghassemi dkk. (2024).

Ketika protokol pembagian dibuat lebih ketat, penurunan kinerja dapat terjadi karena model tidak lagi diuntungkan oleh kemiripan sumber antar *split*. Ghassemi dkk. (2024) melaporkan adanya penurunan kinerja ketika pembagian bebas ketergantungan diterapkan, dan temuan tersebut dapat dipandang sebagai indikasi bahwa pembagian yang mengandung ketergantungan memang cenderung memberi hasil evaluasi yang lebih optimistis. Dengan kata lain, perbedaan hasil antara *split* resmi dan *split* ketat dapat membantu menunjukkan seberapa besar pengaruh ketergantungan sumber terhadap evaluasi (Ghassemi dkk., 2024).

Selain memastikan independensi sumber antar *split*, keseimbangan distribusi juga perlu diperhatikan agar perbandingan kinerja lebih adil. Barchi dkk. (2023) menjelaskan bahwa proses pembagian dapat dilakukan dengan mempertimbangkan distribusi atribut seperti *gender* dan *ethnicity*, serta ringkasan label yang dihitung dari lima *trait*, sehingga karakteristik set pelatihan, validasi, dan pengujian tidak jauh berbeda. Pendekatan ini membantu mengurangi kemungkinan bahwa kinerja yang terlihat baik hanya dipengaruhi oleh komposisi set uji yang lebih mudah, bukan karena model yang lebih baik (Barchi dkk., 2023).

Berdasarkan uraian tersebut, protokol pembagian data pada penelitian ini secara prinsip diarahkan pada dua hal. Independensi sumber antar *split* dijaga untuk menekan kemungkinan kebocoran, dan distribusi atribut penting dijaga agar perbandingan hasil antar skenario tetap wajar. Rincian implementasi teknis terkait pembentukan unit kelompok dan prosedur pembagiannya ditempatkan pada Bab 3, sedangkan bagian ini menekankan alasan konseptual dan risiko yang ingin dikurangi melalui protokol pembagian yang lebih ketat (Barchi dkk., 2023; Ghassemi dkk., 2024).


2.2.6 Transformer

Transformer merupakan arsitektur jaringan saraf untuk pemodelan data berurutan yang dibangun dengan mekanisme atensi. Pada pendekatan ini, ketergantungan antarposisi dalam suatu urutan tidak perlu dimodelkan melalui proses rekuren, karena hubungan antarposisi dapat dihitung langsung melalui *self-attention*. Arsitektur Transformer diperkenalkan dalam konteks *sequence transduction* berbasis struktur *encoder* dan *decoder*, lalu ditunjukkan bahwa tumpukan *self-attention* dan *feed-forward network* dapat digunakan sebagai komponen utama pemodelan urutan (Vaswani dkk., 2017).

Pada Transformer, sebuah *encoder* digunakan untuk memetakan urutan masukan menjadi representasi kontinu, lalu *decoder* digunakan untuk menghasilkan urutan keluaran secara autoregresif. Arsitektur lengkap *encoder* dan *decoder* ditampilkan pada gambar utama paper tersebut. Dalam penelitian ini, Transformer dipahami sebagai komponen utama pada *backbone speech* pralatih seperti wav2vec 2.0, HuBERT, dan WavLM. Relevansi utamanya bukan pada perancangan ulang arsitektur Transformer, melainkan pada kemampuannya membentuk representasi kontekstual dari urutan sinyal *audio* melalui mekanisme *self-attention*. Mekanisme ini memungkinkan model memperhitungkan hubungan antarframe atau antarsegmen dalam sinyal ujaran secara lebih fleksibel dibanding pendekatan yang hanya mengandalkan fitur akustik manual. Oleh karena itu, pembahasan Transformer pada penelitian ini dibatasi pada perannya sebagai fondasi representasi *speech* pralatih yang kemudian digunakan sebagai *frozen embedding* maupun sebagai *backbone* untuk adaptasi LoRA.

Pada bagian *encoder*, beberapa lapisan identik ditumpuk. Pada paper Vaswani dkk. (2017), jumlah lapisan *encoder* ditetapkan $N = 6$. Setiap lapisan *encoder* terdiri dari dua sublapisan, yaitu *multi-head self-attention* dan *position-wise feed-forward network*. Pada bagian *decoder*, struktur yang mirip digunakan, namun satu sublapisan tambahan diberikan untuk melakukan atensi ke keluaran *encoder*. Selain itu, *masking* diterapkan pada *self-attention* di *decoder* agar sebuah posisi tidak “melihat” token pada posisi setelahnya, sehingga sifat autoregresif tetap terjaga (Vaswani dkk., 2017).


Dalam penelitian ini, Transformer tidak dibahas sebagai arsitektur yang dirancang ulang, melainkan sebagai fondasi dari model *speech* pralatih yang digunakan, yaitu wav2vec 2.0, HuBERT, dan WavLM. Komponen *self-attention* pada Transformer memungkinkan representasi *audio* dibentuk dengan memperhatikan hubungan antarsekuens *frame* secara kontekstual. Oleh karena itu, pembahasan Transformer dibatasi pada perannya sebagai dasar pembentukan *embedding speech* pralatih yang kemudian digunakan dalam skema *frozen feature extraction* dan adaptasi LoRA. Arsitektur Transformer yang menjadi dasar *backbone speech* pralatih ditunjukkan pada Gambar 2.1



Gambar 2.1 Arsitektur Transformer (Vaswani dkk., 2017)

2.2.7 Kerangka Pembelajaran Representasi Ucapan Berbasis *Self-Supervised*: wav2vec2.0

wav2vec2.0 diperkenalkan sebagai kerangka pembelajaran representasi ucapan secara *self supervised* yang memakai *audio* mentah sebagai masukan, lalu representasi yang dihasilkan dapat dipakai kembali pada tugas berlabel melalui tahap *fine-tuning*. Gambaran alur model dari sinyal *audio* hingga perhitungan *Loss* kontrastif ditampilkan pada ilustrasi arsitektur, sehingga keterkaitan antara *feature encoder*, *context network*, dan modul kuantisasi dapat dilihat secara utuh pada Gambar 2.2 (Baevski dkk., 2020).



Gambar 2.2 Kerangka wav2vec 2.0 (Baevski dkk., 2020)

wav2vec 2.0 merupakan model *self-supervised speech* yang mempelajari representasi dari *audio* mentah melalui kombinasi *feature encoder* berbasis konvolusi, *context network* berbasis Transformer, dan mekanisme pembelajaran pada bagian sinyal yang dimasking. Pada tahap pralatih, model dilatih untuk membedakan representasi target yang benar dari kandidat lain sehingga dapat membentuk *embedding* ujaran tanpa membutuhkan transkripsi manual. Dalam penelitian ini, wav2vec 2.0 tidak dilatih ulang dari awal, melainkan digunakan sebagai *backbone* pralatih untuk menghasilkan *embedding audio* pada skenario *frozen feature extraction*. Oleh karena itu, pembahasan pada bagian ini difokuskan pada peran wav2vec 2.0 sebagai sumber representasi ujaran yang dibandingkan dengan HuBERT, WavLM, dan eGeMAPS, bukan pada formulasi lengkap *loss* pralatihnya (Baevski dkk., 2020).

Secara arsitektural, wav2vec 2.0 terdiri atas *feature encoder* konvolusional yang menerima *waveform* mentah, *context network* berbasis Transformer, serta modul kuantisasi yang menghasilkan target diskret untuk *objective* pralatih. *Feature encoder* menggunakan beberapa blok konvolusi temporal untuk mengubah sinyal *audio* menjadi representasi laten berdimensi waktu, sedangkan Transformer membentuk representasi kontekstual dengan memperhatikan hubungan antarposisi dalam urutan *audio*. Pada konfigurasi Base yang relevan dengan *embedding* berdimensi 768, wav2vec 2.0 menggunakan 12 blok Transformer, dimensi hidden 768, dimensi *feed-forward* 3.072, dan 8 *attention head*, dengan jumlah parameter sekitar 95 juta. Konfigurasi Large pada paper aslinya lebih besar, yaitu 24 blok Transformer, dimensi hidden 1.024, 16 *attention head*, dan sekitar 317 juta parameter (Baevski dkk., 2020).

Objective pralatih wav2vec 2.0 bersifat contrastive. Sebagian representasi laten dari *feature encoder* dimasking, kemudian *context network* dilatih untuk mengenali representasi target yang benar dari sekumpulan kandidat yang mencakup *distractor*. Target tersebut diperoleh dari proses kuantisasi laten, dan pelatihan juga disertai *diversity loss* agar *codebook* tidak hanya menggunakan sebagian kecil entri. Dengan mekanisme ini, wav2vec 2.0 dapat mempelajari representasi ujaran dari data *audio* tanpa transkripsi manual, lalu representasi tersebut dapat digunakan pada tugas hilir seperti pengenalan ujaran atau ekstraksi *embedding* untuk pemodelan lain (Baevski dkk., 2020).

Dalam konteks penelitian ini, wav2vec 2.0 diposisikan sebagai fondasi *contrastive self-supervised speech representation* yang menjadi salah satu *baseline frozen feature extraction*. Model ini tidak diasumsikan memahami kepribadian secara langsung. Representasi yang dihasilkan hanya digunakan sebagai *embedding audio* yang kemudian diuji secara empiris menggunakan model regresi untuk estimasi *apparent personality Big Five*. Karena wav2vec 2.0 tidak dilanjutkan ke tahap adaptasi LoRA pada penelitian ini, pembahasannya cukup diarahkan pada prinsip *objective*, konfigurasi varian Base, data pralatih, jumlah parameter, dan perannya sebagai pembanding terhadap HuBERT serta WavLM.

Ringkasan konfigurasi varian wav2vec 2.0 ditampilkan pada Tabel 2.2. Dalam penelitian ini, varian yang relevan adalah wav2vec 2.0 Base karena digunakan sebagai *backbone frozen feature extraction* dengan keluaran *embedding* berdimensi 768. Varian Large dan Large LV-60k ditampilkan sebagai konteks arsitektural bahwa wav2vec 2.0 juga tersedia dalam skala parameter dan data pralatih yang lebih besar, tetapi tidak digunakan sebagai *backbone* utama dalam eksperimen penelitian ini (Baevski dkk., 2020).

Tabel 2.2 Ringkasan konfigurasi varian wav2vec 2.0 dan data pralatih (Baevski dkk., 2020)


Varian	Layer Transformer	Dimensi hidden	Head atensi	Jumlah parameter	Data pralatih	Langkah pembaruan
wav2vec 2.0 Base	12	768	8	95M	LS-960 / LibriSpeech 960 jam	400k
wav2vec 2.0 Large	24	1024	16	317M	LS-960 / LibriSpeech 960 jam	250k
wav2vec 2.0 Large LV-60k	24	1024	16	317M	LV-60k / Libri-Light sekitar 60.000 jam	600k

2.2.8 Kerangka Pembelajaran Representasi Ucapan Berbasis *Masked Prediction*: HuBERT

HuBERT diperkenalkan sebagai pendekatan *self-supervised speech representation learning* yang mempelajari representasi ujaran melalui tugas *masked prediction*. Berbeda dari wav2vec 2.0 yang menggunakan *objective* kontrastif, HuBERT memanfaatkan target diskret yang diperoleh dari proses *clustering offline* terhadap fitur akustik atau representasi laten. Pada tahap pralatih, sebagian *frame audio* disembunyikan, lalu model dilatih untuk memprediksi unit *cluster* pada bagian yang dimasking berdasarkan konteks di sekitarnya. Alur umum HuBERT, mulai dari pembentukan label *cluster* hingga prediksi pada *frame* yang dimasking, ditunjukkan pada Gambar 2.3. Dengan cara ini, HuBERT dapat mempelajari struktur temporal dan pola akustik ujaran tanpa membutuhkan transkripsi manual. (Hsu dkk., 2021).

Dalam penelitian ini, HuBERT tidak dilatih ulang dari awal, melainkan digunakan sebagai *backbone* pralatih untuk menghasilkan representasi *audio*. Relevansi utama HuBERT terletak pada kemampuannya membentuk *embedding* ujaran berbasis konteks yang dapat dibandingkan dengan wav2vec 2.0, WavLM, dan eGeMAPS pada skenario *frozen feature extraction*. Selain itu, HuBERT juga digunakan sebagai salah satu kandidat *backbone* yang diadaptasi

menggunakan LoRA pada tahap *fine-tuning*. Oleh karena itu, pembahasan HuBERT pada penelitian ini dibatasi pada prinsip *masked prediction* dan perannya sebagai sumber representasi *audio* pralatih untuk tugas regresi *apparent personality* (Hsu dkk., 2021).



Gambar 2.3 Skema HuBERT untuk memprediksi assignment cluster pada frame yang dilakukan masking (Hsu dkk., 2021).

Perbedaan utama HuBERT dari wav2vec 2.0 terletak pada target pralatih yang digunakan. Jika wav2vec 2.0 memakai *objective* kontrasif untuk membedakan target kuantisasi yang benar dari kandidat lain, HuBERT menggunakan target diskret yang dibuat terlebih dahulu melalui *offline clustering*. Pada iterasi awal, *clustering* dapat dilakukan terhadap fitur akustik seperti *MFCC*, kemudian model yang sudah dipralatih dapat digunakan kembali untuk menghasilkan representasi yang lebih baik dan membentuk target *clustering* pada iterasi berikutnya. Hsu dkk. (2021) menekankan bahwa konsistensi target *cluster* menjadi aspek penting, karena model dilatih untuk memprediksi unit tersembunyi pada bagian *audio* yang dimasking berdasarkan konteks sekitarnya.

Dari sisi konfigurasi model, HuBERT mengikuti kerangka arsitektur yang dekat dengan wav2vec 2.0, yaitu *convolutional waveform encoder* diikuti *encoder Transformer*. Pada varian Base, HuBERT menggunakan 12 *layer Transformer*, dimensi *embedding* 768, dimensi *feed-forward* 3.072, 8 *attention head*, dan jumlah parameter sekitar 95 juta. Varian Large memiliki 24 *layer*, dimensi *embedding* 1.024, 16 *attention head*, dan sekitar 317 juta parameter, sedangkan X-Large diperluas hingga sekitar 964 juta parameter. Untuk konteks penelitian ini, konfigurasi yang paling relevan adalah HuBERT Base karena checkpoint yang digunakan pada *fine-tuning* adalah facebook/hubert-base-ls960, yang dipralatih pada *LibriSpeech* 960 jam (Hsu dkk., 2021).

Relevansi HuBERT dalam penelitian ini adalah sebagai representasi *masked prediction* berbasis unit diskret yang berbeda prinsip dari wav2vec 2.0 dan WavLM. Pada tahap *baseline*, HuBERT digunakan sebagai *frozen feature extractor* untuk menghasilkan *embedding audio* berdimensi 768 yang dibandingkan dengan eGeMAPS, wav2vec 2.0, dan WavLM. Pada tahap lanjutan, HuBERT juga dianalisis menggunakan LoRA sebagai pembanding terhadap WavLM, karena kinerja *baseline*-nya masih kompetitif dan karakter pralatihnya berbeda. Dengan demikian, HuBERT tidak diposisikan sebagai model yang secara langsung menilai kepribadian, melainkan sebagai *backbone* representasi ujaran yang diuji secara empiris untuk tugas regresi *apparent personality*.

Ringkasan konfigurasi varian HuBERT ditampilkan pada Tabel 2.3. Dalam penelitian ini, varian yang relevan adalah HuBERT Base karena digunakan sebagai *backbone frozen feature extraction* dan sebagai salah satu *backbone* yang dianalisis pada tahap adaptasi LoRA. Varian Large dan X-Large ditampilkan sebagai konteks perkembangan skala model HuBERT, tetapi tidak digunakan dalam eksperimen karena kebutuhan komputasi dan ukuran parameter yang lebih besar (Hsu dkk., 2021).

Tabel 2.3 Ringkasan konfigurasi varian HuBERT dan data pralatih (Hsu dkk., 2021)


Varian	Layer Transformer	Dimensi hidden	Head atensi	Jumlah parameter	Data pralatih	Langkah pembaruan
HuBERT Base	12	768	8	95M	LS-960 / LibriSpeech 960 jam	250k iterasi pertama + 400k iterasi kedua
HuBERT Large	24	1024	16	317M	LL-60k / Libri-Light sekitar 60.000 jam	400k
HuBERT X-Large	48	1280	16	964M	LL-60k / Libri-Light sekitar 60.000 jam	400k

2.2.9 Kerangka Pra-latih Ujaran untuk Tugas Umum: WavLM

WavLM diperkenalkan sebagai model pralatih *self supervised* untuk pemrosesan suara yang ditujukan agar representasi yang dipelajari dapat digunakan pada berbagai tugas, tidak hanya pengenalan ujaran. Pada sinyal suara, informasi yang berkaitan dengan konten ujaran, identitas pembicara, dan aspek paralinguistik dapat muncul secara bersamaan, sehingga representasi universal perlu dibentuk melalui rancangan objektif dan data pralatih yang sesuai. Pada WavLM, pemodelan *masked speech prediction* tetap dipertahankan seperti pada pendekatan berbasis unit diskret, namun pembelajaran juga diarahkan melalui denoising dengan cara masukan dibuat menyerupai ucapan yang bising atau tumpang tindih antar pembicara. Dengan strategi tersebut, representasi diharapkan tidak hanya memadai untuk tugas ASR, tetapi juga dapat mendukung tugas non ASR seperti diarization dan separation. Selain itu, pada *backbone* Transformer ditambahkan *Gated relative position* bias agar informasi urutan dapat dimodelkan

dengan lebih adaptif, dan data pralatih diperluas menjadi campuran 94 ribu jam dari beberapa sumber untuk mengurangi ketidakcocokan domain (Chen dkk., 2022).

Arsitektur WavLM disusun dari *convolutional feature encoder* dan *Transformer encoder*. *Convolutional encoder* dibentuk dari tujuh blok konvolusi temporal yang diikuti *layer normalization* dan aktivasi GELU, dengan 512 *channel*, stride (5, 2, 2, 2, 2, 2, 2) dan lebar kernel (10, 3, 3, 3, 3, 2, 2). Dengan konfigurasi ini, satu keluaran representasi dipetakan untuk kurang lebih 25 ms audio dengan pergeseran 20 ms. Keluaran konvolusi kemudian dimasking dan dipakai sebagai masukan Transformer. Skema umum arsitektur tersebut dapat dilihat pada Gambar 2.4 (Chen dkk., 2022).



Gambar 2.4 Arsitektur WavLM (Chen dkk., 2022)

Salah satu komponen penting pada WavLM adalah penggunaan *gated relative position bias* dalam mekanisme *self-attention*. Mekanisme ini memungkinkan model memperhitungkan hubungan posisi relatif antarframe *audio* secara lebih adaptif, sehingga urutan temporal dalam sinyal ujaran dapat dimodelkan tanpa hanya bergantung pada posisi absolut. Pada konteks penelitian ini, detail matematis *gated relative position bias* tidak dimodifikasi secara langsung, tetapi dipahami sebagai bagian dari rancangan arsitektur WavLM yang mendukung pembentukan representasi ujaran pralatih. Oleh karena itu, WavLM relevan digunakan sebagai *backbone speech* pralatih untuk menghasilkan *embedding audio* pada skenario *frozen feature extraction* maupun sebagai *backbone* yang diadaptasi menggunakan LoRA.

Salah satu karakteristik utama WavLM adalah penggunaan strategi *masked speech prediction* yang dipadukan dengan kondisi masukan yang dibuat lebih menantang, misalnya melalui *noise* atau tumpang tindih ujaran. Strategi ini mendorong model untuk membentuk representasi yang tidak hanya bergantung pada sinyal ujaran yang bersih, tetapi juga lebih tahan terhadap variasi kondisi *audio*. Dalam konteks penelitian ini, aspek tersebut relevan karena dataset *ChaLearn*

First Impressions V2 berasal dari video daring yang dapat memiliki variasi kualitas rekaman, latar akustik, dan karakteristik pembicara. Oleh karena itu, WavLM digunakan sebagai salah satu *backbone speech* pralatih untuk menghasilkan *embedding audio* pada skenario *frozen feature extraction* dan sebagai kandidat *backbone* yang diadaptasi menggunakan LoRA (Chen dkk., 2022).

Untuk meningkatkan kemampuan generalisasi, WavLM juga dipralatih pada data ujaran berskala besar dan beragam. Informasi ini penting untuk menjelaskan alasan WavLM dipertimbangkan sebagai *backbone* yang kuat pada tugas non-ASR, termasuk estimasi kepribadian berbasis audio. Namun, penelitian ini tidak melakukan *pretraining* WavLM dari awal dan tidak memodifikasi *objective pretraining*-nya. Karena itu, pembahasan WavLM pada bagian ini dibatasi pada karakteristik representasi dan relevansinya terhadap eksperimen, sedangkan rincian implementasi *frozen feature extraction* dan *fine-tuning* LoRA dijelaskan pada Bab 3 (Chen dkk., 2022).

Untuk meningkatkan keragaman domain, data pralatih diperluas menjadi Mix 94.000 jam yang terdiri dari 60.000 jam *Libri Light*, 10.000 jam *GigaSpeech*, dan 24k jam *VoxPopuli*. Pada konfigurasi eksperimen, WavLM Base dilatih pada 960 jam *LibriSpeech* untuk 400.000 langkah, sedangkan WavLM Base+ dan WavLM *Large* dilatih pada Mix 94.000 jam dengan jumlah langkah yang lebih besar. Label semu untuk Base diambil dari *clustering* keluaran *layer* ke 6 pada model HuBERT iterasi pertama, sedangkan untuk Base+ dan *Large* label semu diambil dari *clustering* keluaran *layer* ke 9 pada HuBERT Base iterasi kedua yang dirilis. *Denoising modeling* diterapkan pada sebagian *utterance*, dengan probabilitas *mixing noise* yang dibedakan antar varian model (Chen dkk., 2022). Ringkasan perbedaan konfigurasi arsitektur, jumlah parameter, skala data pralatih, dan langkah pembaruan pada masing-masing varian WavLM disajikan pada Tabel 2.4.

Tabel 2.4 Ringkasan konfigurasi varian WavLM dan data pralatih (Chen dkk., 2022)

Varian	Layer Transformer	Dimensi hidden	Head atensi	Jumlah parameter	Data pralatih	Langkah pembaruan
WavLM Base	12	768	8	94.70M	960 jam	400k
WavLM Base+	12	768	8	94.70M	94k jam	1.2M
WavLM <i>Large</i>	24	1024	12	316.62M	94k jam	700k

2.2.10 Ekstraksi Fitur

Ekstraksi fitur akustik dilakukan untuk mengubah sinyal ucapan mentah menjadi representasi numerik yang lebih ringkas, sehingga informasi yang relevan bagi tugas prediksi dapat dimodelkan lebih stabil. Pada praktiknya, fitur umumnya dibentuk dari analisis sinyal berdurasi pendek, karena karakteristik ucapan berubah seiring waktu dan lebih mudah diperkirakan pada potongan sinyal yang pendek. Pendekatan ini juga digunakan oleh banyak perangkat ekstraksi fitur yang menghasilkan deret waktu deskriptor tingkat rendah, lalu diringkaskan menjadi vektor

statis dengan berbagai fungsi statistik, sehingga satu rekaman dapat diwakili oleh satu vektor fitur (Eyben dkk., 2010). Beberapa fitur akustik yang dapat diekstrak adalah sebagai berikut.

a) Fitur spektral dan *MFCC*

Fitur spektral memanfaatkan distribusi energi terhadap frekuensi, misalnya energi pada pita frekuensi tertentu, kemiringan spektrum, atau ukuran bentuk spektrum. Salah satu representasi yang sangat umum adalah *Mel Frequency Cepstral Coefficients* atau *MFCC*. Secara historis, *MFCC* diperkenalkan sebagai representasi parametrik yang efektif untuk sinyal ucapan dengan memakai bank filter pada skala mel dan kompresi log sebelum dilakukan transformasi kosinus diskrit (Davis & Mermelstein, 1980).

Pada praktik ekstraksi fitur berbasis toolkit, *MFCC* biasanya dihitung sebagai deret waktu per *frame*, kemudian dapat diturunkan lagi dengan operasi turunan waktu seperti delta, atau diringkas menjadi statistik global per rekaman. Mekanisme “deret waktu lalu diringkas” ini juga merupakan pola yang dinyatakan oleh openSMILE, yaitu deskriptor tingkat rendah seperti *MFCC*, *F0*, *formant*, dan *loudness* dapat diproses lanjut dengan delta *regression* dan berbagai *functionals* statistik agar diperoleh fitur ringkasan (Eyben dkk., 2010).

b) Fitur prosodik, kualitas suara, dan fungsi ringkasan

Selain *MFCC*, fitur prosodik sering dibentuk dari kontur *pitch* atau *F0*, intensitas, serta indikasi ritme seperti laju suku kata semu atau jeda. Fitur kualitas suara juga sering digunakan, misalnya *jitter* dan *shimmer* untuk menangkap variasi periodisitas, serta ukuran terkait harmonik dan *noise*. Dalam konteks ekstraksi berbasis perangkat lunak, openSMILE dinyatakan mendukung berbagai deskriptor tingkat rendah seperti *MFCC*, *loudness*, fundamental *frequency*, dan *formant frequencies*, serta mendukung penerapan delta *regression* dan *functionals* statistik pada deret waktu tersebut (Eyben dkk., 2010).

c) eGeMAPS dan openSMILE

GeMAPS diperkenalkan sebagai set parameter akustik minimalistik untuk analisis suara dan affective computing, dan implementasinya dinyatakan tersedia melalui toolkit openSMILE. Pada definisinya, total 62 parameter dijelaskan sebagai hasil dari penerapan *functionals* pada 18 *low level descriptors* serta sejumlah *functionals* tambahan pada *pitch* dan *loudness*, ditambah beberapa fitur temporal. Untuk melengkapi keterbatasan set minimal yang tidak memuat parameter *cepstral*, eGeMAPS ditetapkan sebagai set perluasan yang menambahkan antara lain *MFCC* 1 sampai 4, *spectral flux*, serta bandwidth *formant* tertentu, sehingga total parameter menjadi 88 ketika digabungkan dengan set minimal (Eyben dkk., 2016).

Di sisi implementasi, openSMILE dijelaskan sebagai toolkit ekstraksi fitur *audio* yang dapat dikonfigurasi melalui satu berkas konfigurasi, dan mendukung pemrosesan incremental maupun *batch*. Dukungan fitur yang disebut meliputi *MFCC*, *PLP cepstral coefficients*, *LPC*, *LSF*, fundamental *frequency*, dan *formant frequencies*, serta penerapan delta *regression* dan berbagai *functionals* statistik (Eyben dkk., 2010). Dengan demikian, eGeMAPS dapat dipandang sebagai salah satu konfigurasi fitur yang terstandarisasi, sementara openSMILE berperan sebagai mesin ekstraksinya. Ringkasan dari kelompok fitur akustik yang sudah dijelaskan sebelumnya akan ditunjukkan pada Tabel 2.5 sebagai berikut.

Tabel 2.5 Ringkasan kelompok fitur akustik dan contoh parameternya

Kelompok fitur	Contoh parameter	Bentuk keluaran	Catatan ringkas
Spektral	energi pita, spectral slope, spectral roll-off, spectral flux	per <i>frame</i> lalu diringkas	diturunkan dari representasi spektrum hasil STFT atau DFT
Cepstral	MFCC	per <i>frame</i> lalu diringkas	energi mel yang dilogaritmakan lalu diproyeksikan dengan DCT menjadi koefisien cepstral
Prosodik	F0 atau <i>pitch</i> , rentang F0, <i>loudness</i> atau energi	kontur lalu diringkas	menggambarkan intonasi dan dinamika kuat lemah suara sepanjang waktu
Kualitas suara	jitter, shimmer, HNR	per <i>frame</i> atau per segmen	<i>voiced</i> segment sering dipakai sebagai dasar perhitungan ukuran ketakteraturan dan <i>noise</i> relatif
Temporal	durasi <i>voiced</i> , durasi unvoiced, rasio <i>voiced</i> , jumlah segmen <i>voiced</i>	per rekaman atau per segmen	meringkas pola aktivitas bicara dan jeda yang muncul pada rekaman

2.2.11 Pemodelan untuk Regresi

Pada prediksi skor *Big Five* berbasis fitur audio, keluaran yang dihasilkan berupa nilai kontinu. Karena itu, pemodelan regresi digunakan untuk memetakan vektor fitur $x \in \mathbb{R}^p$ menjadi target $y \in \mathbb{R}$. Jika lima *trait* diprediksi sekaligus, target dapat dinyatakan sebagai $Y \in \mathbb{R}^{n \times 5}$ sehingga pemodelan dilakukan sebagai regresi multi output. Dukungan regresi multi output telah disediakan pada implementasi Ridge ketika y diberikan sebagai array dua dimensi (scikit-learn developers, 2007).

a) Regresi linear sebagai model dasar

Regresi linear digunakan sebagai *baseline* karena hubungan antara fitur dan target dinyatakan melalui kombinasi linear koefisien. Bentuk model dituliskan pada Persamaan (2.4), di mana $X \in \mathbb{R}^{n \times p}$ adalah matriks fitur, $\beta \in \mathbb{R}^p$ adalah koefisien, dan ϵ adalah galat. Persamaan ini dipakai untuk menyatakan bahwa prediksi dihasilkan dari perkalian $X\beta$ dan deviasi terhadap target dimodelkan sebagai *Residual* (Hastie dkk., 2009).

$$y = X\beta + \epsilon \quad (2.4)$$

Koefisien pada *ordinary least squares* diperoleh dengan meminimalkan jumlah kuadrat *Residual*. Objektif ini dituliskan pada Persamaan (2.5) dan dipakai untuk mencari $\hat{\beta}$ yang membuat selisih y dan $X\beta$ sekecil mungkin dalam norma Euclidean (James dkk., 2013).

$$\widehat{\beta}_{(OLS)} = \operatorname{argmin}_{(\beta)} \|y - X\beta\|_2^2 \quad (2.5)$$

Pada fitur *audio*, kolinearitas sering muncul karena beberapa fitur diturunkan dari sumber spektral yang sama atau dari ringkasan statistik yang serupa. Dalam kondisi demikian, estimator *OLS* dapat memiliki varians yang tinggi sehingga generalisasi dapat menurun walaupun *error* pelatihan terlihat kecil. Fenomena ini dibahas dalam konteks *trade off* bias varians dan regularisasi pada metode pemodelan statistik (Hastie dkk., 2009; James dkk., 2013).

b) *Ridge regression* untuk menekan *overfitting*

Ketika jumlah fitur cukup banyak atau antar fitur saling berkorelasi, koefisien pada regresi linear biasa cenderung menjadi tidak stabil, sehingga kinerja pada data baru dapat menurun walaupun galat pada data latih terlihat kecil. Kondisi seperti ini dibahas dalam kerangka *trade off* bias dan varians pada pemodelan statistik, di mana varians estimator yang tinggi dapat memicu *overfitting* pada data latih (Hastie dkk., 2009; James dkk., 2013).

Ridge regression digunakan untuk mengurangi ketidakstabilan tersebut dengan cara melakukan regularisasi L2, sehingga koefisien model didorong menjadi lebih kecil dan solusi menjadi lebih terkondisi ketika prediktor tidak ortogonal atau saling berkorelasi (Hoerl & Kennard, 1970). Pada pengaturan ini, sebuah parameter regularisasi dipakai untuk mengatur seberapa kuat *shrinkage* dilakukan. Jika regularisasi dibuat lebih kuat, model cenderung menjadi lebih sederhana karena sensitivitas koefisien terhadap variasi pada data latih menjadi berkurang. Prinsip bahwa regularisasi memperbaiki conditioning masalah dan dapat menurunkan varians estimasi juga dinyatakan pada dokumentasi fungsi *ridge regression* (scikit-learn developers, 2007).

c) Standardisasi fitur sebelum *Ridge*

Karena penalti L2 dipengaruhi oleh skala fitur, standardisasi umumnya diterapkan sebelum *Ridge* agar kontribusi penalti tidak didominasi oleh fitur yang memiliki rentang lebih besar. Praktik yang lazim adalah menghitung rata-rata dan simpangan baku dari data latih, lalu transformasi yang sama diterapkan pada data validasi dan uji. Penjelasan kebutuhan rescaling dalam konteks metode *shrinkage* dan regularisasi dibahas sebagai praktik umum pada pembahasan regresi teratur (James dkk., 2013).

d) Regresi multi output untuk *Big Five*

Jika lima *trait Big Five* diprediksi sekaligus, target dapat diperlakukan sebagai keluaran multi output sehingga satu estimator dipakai untuk memprediksi beberapa target kontinu secara bersamaan. Dukungan multi variate *regression* dinyatakan tersedia pada *Ridge* ketika y diberikan sebagai array dua dimensi, dan parameter regularisasi juga dapat diberikan per target bila diperlukan. Dengan cara tersebut, sebuah fitur *audio* yang sama dapat dipetakan menjadi lima skor *trait* tanpa harus melatih lima model yang terpisah, walaupun pelatihan terpisah tetap mungkin dilakukan jika ingin memisahkan konfigurasi tiap target (scikit-learn developers, 2007).

e) Pemilihan parameter regularisasi

Nilai regularisasi umumnya tidak ditetapkan secara langsung, tetapi dipilih menggunakan validasi atau *cross validation*. Prosedur ini dipakai agar tingkat regularisasi ditentukan berdasarkan kinerja pada data yang tidak dipakai untuk fitting, sehingga risiko *overfitting* terhadap data latih dapat ditekan. Pemilihan parameter regularisasi berbasis validasi dibahas dalam pembahasan metode *shrinkage* pada literatur pengantar *statistical learning* (James dkk., 2013). Tabel 2.6 di bawah ini dapat dipakai untuk merangkum perbedaan regresi linear biasa dan Ridge pada konteks fitur audio.

Tabel 2.6 Perbandingan regresi linear dan Ridge regression untuk mengurangi overfitting

Aspek	Regresi linear (OLS)	Ridge regression
Tujuan	pemetaan linear dari fitur ke target	pemetaan linear dengan regularisasi L2 agar koefisien lebih stabil
Perilaku saat fitur saling berkorelasi	koefisien dapat sensitif terhadap perubahan data	koefisien cenderung mengalami <i>shrinkage</i> sehingga varians berkurang
Kontrol kompleksitas	tidak ada parameter khusus	ada parameter regularisasi alpha atau lambda yang mengatur kekuatan <i>shrinkage</i>
Risiko <i>overfitting</i>	dapat meningkat saat fitur banyak dan kolinear	cenderung ditekan melalui regularisasi
Kebutuhan standardisasi	fitur disarankan distandarisasi	standardisasi lebih penting karena penalti bergantung pada skala fitur
Dukungan multi output	umumnya dapat menerima y 2D tergantung implementasi	mendukung multi output ketika y berbentuk (n_samples, n_targets)

2.2.12 Parameter-Efficient Fine-tuning: LoRA

Pada tahap adaptasi *model pralatih*, pembaruan seluruh parameter sering dilakukan melalui *fine-tuning* penuh. Namun pada model Transformer berukuran besar, pendekatan tersebut cenderung membuat kebutuhan memori meningkat karena parameter yang dilatih, gradien, dan *state optimizer* harus disimpan untuk seluruh bobot. Sebagai alternatif, pendekatan *parameter efficient fine-tuning* dapat digunakan dengan cara hanya melatih sejumlah kecil parameter tambahan, sementara bobot pralatih tetap dibekukan. Salah satu metode yang banyak digunakan adalah *Low Rank Adaptation* atau LoRA. Pada LoRA, pembaruan bobot dianggap tidak perlu memiliki derajat kebebasan penuh, sehingga pembaruan dapat direpresentasikan sebagai matriks berperingkat rendah. Dengan cara ini, penyimpanan model adaptasi per tugas dapat dibuat lebih ringkas dibanding menyimpan salinan model hasil *fine-tuning* penuh (Hu dkk., 2021).

Misalkan terdapat transformasi linear pada Transformer, misalnya proyeksi pada *attention* atau pada *feed forward network*. Untuk sebuah *input* vektor x , keluaran linear standar dapat dituliskan pada Persamaan (2.6).

$$y = Wx \quad (2.6)$$

Pada LoRA, bobot pralatih W tidak diperbarui. Sebagai gantinya, pembaruan bobot ΔW dimodelkan sebagai hasil perkalian dua matriks berukuran kecil, yaitu B dan A , dengan *rank* r yang dipilih jauh lebih kecil daripada dimensi aslinya. Formulasi tersebut dapat dituliskan pada Persamaan (2.7) sampai Persamaan (2.8) (Hu dkk., 2021).

$$W' = W + \Delta W \quad (2.7)$$

$$\Delta W = \alpha/r BA \quad (2.8)$$

Dengan demikian, keluaran *layer* menjadi seperti pada Persamaan (2.9).

$$y = Wx + \alpha/r BAx \quad (2.9)$$

Pada persamaan tersebut, $A \in \mathbb{R}^{r \times d_{in}}$ dan $B \in \mathbb{R}^{d_{out} \times r}$, sedangkan α digunakan sebagai faktor skala agar besar pembaruan dapat diatur tanpa harus menaikkan *rank*. Karena hanya Adan Byang dilatih, jumlah parameter yang diperbarui dapat ditekan. Dampak praktisnya adalah kebutuhan memori selama pelatihan dapat berkurang, terutama karena *state optimizer* tidak lagi disimpan untuk seluruh bobot model (Hu dkk., 2021).

Pada arsitektur Transformer, LoRA umumnya disisipkan pada *layer* linear tertentu, misalnya pada proyeksi *query* dan *value* di *self attention*, atau pada proyeksi lain yang dianggap dominan terhadap adaptasi tugas. Pada tahap inferensi, kontribusi LoRA dapat digabungkan ke dalam bobot efektif W' , sehingga tidak diperlukan modul tambahan yang menambah latensi, berbeda dari beberapa pendekatan *adapter* yang menambahkan blok baru di antara *layer* (Houlsby dkk., 2019; Hu dkk., 2021).

Jika dibandingkan dengan metode *parameter efficient* lain, posisi LoRA dapat dipahami sebagai pendekatan yang mengubah transformasi linear melalui pembaruan berperingkat rendah, sementara metode seperti *prefix tuning* menambahkan vektor kondisi yang dapat diatensi tanpa mengubah bobot utama, dan metode seperti *BitFit* hanya memperbarui bias pada *layer* tertentu. Pemilihan LoRA pada penelitian berbasis *backbone audio* Transformer umumnya dilakukan ketika adaptasi perlu tetap stabil, namun pembaruan penuh dianggap kurang efisien dari sisi sumber daya dan penyimpanan model per skenario (Lisa Li & Liang, 2021; Zaken dkk., 2022).

2.2.13 Optimisasi dan Strategi Training

Optimisasi dibutuhkan untuk memperbarui parameter model agar nilai fungsi *loss* menurun secara bertahap. Pada pelatihan jaringan saraf modern, *optimizer* berbasis gradien stokastik sering dipakai karena pembaruan dilakukan menggunakan minibatch sehingga komputasi lebih terjangkau pada dataset besar. Pada sub bab ini, Adam dan AdamW dijelaskan karena keduanya banyak dipakai pada pelatihan model berbasis Transformer (Kingma & Ba, 2017).

a) Adam

Adam digunakan dengan menggabungkan dua ide utama, yaitu momentum dan adaptasi laju belajar per parameter. Gradien pada setiap langkah tidak hanya dipakai secara langsung, tetapi

diringkas melalui estimasi momen pertama sebagai rata rata bergerak eksponensial dari gradien, dan estimasi momen kedua sebagai rata rata bergerak eksponensial dari kuadrat gradien. Koreksi bias juga diterapkan pada dua estimasi tersebut karena nilai awalnya dimulai dari nol, sehingga pada langkah awal estimasi dapat terlalu kecil jika tidak dikoreksi. Dengan mekanisme ini, pembaruan parameter cenderung menjadi lebih stabil ketika gradien bersifat bising atau berskala berbeda antar dimensi (Kingma & Ba, 2017).

Parameter yang umumnya melekat pada *Adam* adalah laju belajar, dua koefisien peluruhan untuk momen pertama dan kedua, serta konstanta kecil untuk stabilitas numerik. Nilai default yang sering dijadikan rujukan juga diberikan pada paper aslinya, sehingga titik awal konfigurasi dapat ditetapkan secara lebih terarah sebelum dilakukan penalaan lebih lanjut (Kingma & Ba, 2017).

b) *AdamW*

Regularisasi berbasis *weight decay* sering ditambahkan untuk menekan kompleksitas model. Pada SGD, *weight decay* memiliki hubungan yang sepadan dengan penalti L2 ketika ditinjau dalam bentuk tertentu, namun kesepadanan ini tidak lagi berlaku untuk *optimizer* adaptif seperti *Adam*. Kondisi ini menyebabkan penggunaan penalti L2 yang disebut sebagai *weight decay* pada implementasi tertentu dapat memberi efek regularisasi yang berbeda dari *weight decay* yang dimaksud dalam literatur (Loshchilov & Hutter, 2019).

AdamW diperkenalkan dengan memisahkan *weight decay* dari langkah pembaruan gradien. *Weight decay* diterapkan langsung pada bobot sebagai peluruhan parameter, sementara pembaruan berbasis gradien tetap mengikuti mekanisme *Adam*. Pemisahan ini ditujukan agar pengaturan *weight decay* menjadi lebih konsisten dan tidak tercampur ke dalam estimasi momen pada *Adam* (Loshchilov & Hutter, 2019).

c) Strategi *training* yang sering dipakai bersama *Adam* dan *AdamW*

Agar pelatihan lebih stabil, laju belajar umumnya tidak dijaga tetap. Pada pelatihan Transformer, strategi warmup sering dipakai, yaitu laju belajar dinaikkan secara bertahap pada langkah awal, lalu diturunkan mengikuti jadwal tertentu. Skema warmup dan penurunan laju belajar telah digunakan pada Transformer, dan pemakaian jadwal laju belajar dibahas sebagai bagian penting dari stabilitas *training* (Vaswani dkk., 2017). Di luar itu, berbagai bentuk penurunan laju belajar seperti step, linear, atau cosine juga sering dipakai dan dibahas dalam studi tentang jadwal *learning rate* (Lewkowycz, 2021).

Ketika gradien menjadi sangat besar, pembaruan dapat menjadi tidak stabil. Untuk kondisi ini, pemotongan norma gradien sering diterapkan agar ledakan gradien dapat diredam tanpa mengubah arah pembaruan secara ekstrem. Strategi *gradient norm clipping* dibahas sebagai solusi praktis untuk exploding *gradients* (Pascanu dkk., 2013).

Selain itu, penghentian pelatihan berbasis kinerja validasi sering digunakan ketika indikasi *overfitting* mulai muncul. Pada pendekatan ini, pelatihan dihentikan ketika metrik validasi tidak membaik dalam beberapa epoch tertentu, sehingga model yang disimpan adalah model dengan kinerja validasi terbaik. *Early stopping* dibahas sebagai teknik yang memanfaatkan validasi untuk mendeteksi saat *overfitting* mulai terjadi (Prechelt, 1997). Tabel 2.7 berikut bisa dipakai untuk meringkas perbedaan *Adam* dan *AdamW* pada praktik *training*.

Tabel 2.7 Ringkasan perbedaan Adam dan AdamW terkait penerapan weight decay

Aspek	Adam	AdamW
Mekanisme inti	Optimisasi adaptif dengan estimasi momen pertama dan momen kedua serta koreksi bias	Mekanisme Adam yang sama
Cara memasukkan <i>weight decay</i>	Pada implementasi yang umum, regularisasi L2 sering digabung ke gradien sehingga efeknya tidak identik dengan <i>weight decay</i> pada <i>optimizer</i> adaptif	<i>Weight decay</i> dipisahkan dari update gradien sehingga peluruhan bobot diterapkan secara terpisah
Alasan pemakaian	Stabil untuk gradien yang bising atau jarang muncul	<i>Weight decay</i> dibuat lebih konsisten pada <i>optimizer</i> adaptif melalui <i>decoupling</i>

2.2.14 Metrik Evaluasi

Pada tugas prediksi *Big Five* dengan keluaran kontinu, nilai target umumnya berada pada rentang 0 sampai 1 sehingga kesalahan prediksi dapat diukur sebagai jarak numerik antara nilai prediksi dan nilai ground truth. Pada *Chlearn First impressions Challenge*, metrik yang dipakai untuk pelaporan kinerja disebut sebagai *accuracy* dan metrik ini didefinisikan sebagai satu dikurangi MAE. Karena terdapat lima *trait* yang diprediksi terpisah, nilai *mean accuracy* dihitung sebagai rata rata dari *accuracy* per *trait* (Aslan dkk., 2021).

a) *Accuracy* berbasis MAE

Accuracy per *trait* didefinisikan dari MAE per *trait* sebagai berikut (Aslan dkk., 2021).

$$Acc_j = 1 - MAE_j \quad (2.10)$$

dengan j menyatakan indeks *trait Big Five*. Selanjutnya, ringkasan kinerja dilaporkan sebagai *mean accuracy*, yaitu rata rata dari lima nilai *accuracy* (Aslan dkk., 2021).

$$MeanAcc = 1/|S| \sum_{(j \in S)} Acc_j \quad (2.11)$$

Dengan $S = Openness, Conscientiousness, Extraversion, Agreeableness, Neuroticism$ dan $|S| = 5$ (Aslan dkk., 2021).

b) *Mean Absolute Error* (MAE)

MAE mengukur rata rata selisih absolut antara nilai prediksi dan nilai target. Untuk kasus multi output seperti *Big Five*, MAE dapat dihitung per *trait*, lalu dapat dirata ratakan untuk mendapatkan ringkasan kesalahan. Pada notasi per *trait*, MAE didefinisikan sebagai berikut (Aslan dkk., 2021).

$$MAE_j = 1/n \sum_{(i=1)}^n |y_i^{(j)} - \widehat{y}_i^{(j)}| \quad (2.12)$$

dengan n menyatakan jumlah sampel, $y_i^{(j)}$ adalah target *trait* ke j untuk sampel ke i , dan $\widehat{y}_i^{(j)}$ adalah prediksi model. Jika diperlukan satu nilai ringkas untuk semua *trait*, MAE dapat dirata-ratakan di atas himpunan *trait*, sehingga diperoleh *average* MAE (Aslan dkk., 2021).

$$MAE = \frac{1}{|S|} \sum_{j \in S} MAE_j \quad (2.13)$$

c) Root Mean Squared Error (RMSE)

RMSE mengukur akar dari rata-rata kuadrat selisih prediksi terhadap target. RMSE sering dipakai ketika kesalahan besar ingin diberi penalti lebih berat karena adanya operasi kuadrat sebelum dirata-ratakan. Definisinya dapat dituliskan sebagai berikut (National Institute of Standards & Technology, 2010).

$$RMSE_j = \sqrt{\left(\frac{1}{n} \sum_{(i=1)}^n (y_i^{(j)} - \widehat{y}_i^{(j)})^2 \right)} \quad (2.14)$$

Dalam implementasi evaluasi regresi, RMSE juga didukung sebagai metrik regresi pada pustaka umum pembelajaran mesin (scikit-learn developers, 2007).

d) Koefisien Determinasi R^2

Koefisien determinasi R^2 menilai seberapa besar variasi target yang dapat dijelaskan oleh prediksi model relatif terhadap prediktor *baseline* yang selalu memprediksi rata-rata target. Pada definisi umum, R^2 dituliskan sebagai berikut (scikit-learn developers, 2007).

$$R^2 = 1 - \left(\sum_{(i=1)}^n (y_i - \widehat{y}_i)^2 \right) / \left(\sum_{(i=1)}^n (y_i - \bar{y})^2 \right) \quad (2.15)$$

dengan $\bar{y}$ adalah rata-rata dari y_i . Nilai terbaik adalah 1, nilai 0 setara dengan model konstan yang selalu memprediksi rata-rata target, dan nilai dapat menjadi negatif bila prediksi lebih buruk daripada *baseline* tersebut (scikit-learn developers, 2007).

Halaman ini sengaja dikosongkan.

BAB 3

METODOLOGI

Bab ini menjelaskan metodologi penelitian yang digunakan untuk membangun dan mengevaluasi *pipeline* estimasi kepribadian *Big Five* berbasis suara. Tahapan yang dibahas disusun secara sistematis, mulai dari penyiapan data, praproses audio, pembagian data untuk evaluasi yang terkontrol, perancangan skenario pemodelan, hingga prosedur pelatihan dan pengujian. Keluaran yang dituju pada *pipeline* ini berupa nilai prediksi untuk lima dimensi *Big Five* dalam bentuk regresi, sehingga fokus utama metodologi adalah memastikan proses ekstraksi dan evaluasi berjalan konsisten.

Metodologi pada bab ini dituliskan untuk memperjelas alur implementasi dan memastikan setiap langkah memiliki keterkaitan yang konsisten dengan tujuan evaluasi. Penjelasan disusun agar proses yang dilakukan dapat ditelusuri kembali, termasuk alasan teknis di balik pemilihan tahapan tertentu dan bagaimana tahapan tersebut mempengaruhi hasil eksperimen. Selain alur proses, bagian-bagian yang berkaitan dengan pengaturan eksperimen seperti konsistensi parameter, pencatatan hasil, dan cara membandingkan antar skenario juga dijelaskan secara ringkas agar interpretasi hasil tidak terlepas dari prosedur yang digunakan.

Struktur bab disusun sebagai berikut. Subbab 3.1 memaparkan perancangan sistem dan alur umum penelitian beserta rincian tahap utama. Subbab 3.2 menjelaskan bahan dan peralatan yang digunakan selama penelitian. Subbab 3.3 merangkum urutan pelaksanaan penelitian sebagai acuan rencana kerja, sehingga keterkaitan antar tahap dapat terlihat secara runtut dari awal hingga akhir.

3.1 Perancangan Sistem


Subbab ini membahas perancangan sistem yang menjadi dasar pelaksanaan eksperimen pada penelitian ini. Gambaran alur umum ditunjukkan terlebih dahulu untuk memperlihatkan hubungan antar tahapan, sebelum masing-masing proses dijelaskan lebih rinci pada subbab berikutnya. Diagram alur juga digunakan untuk menandai batas antar blok proses, sehingga pembaca dapat melihat bagian mana yang merupakan praproses, bagian pembagian data, dan bagian pemodelan serta evaluasi.

Secara umum, alur sistem dimulai dari penyiapan dataset dan ekstraksi audio dari video. Setelah itu dilakukan praproses audio pada *level* per sampel untuk menyeragamkan kondisi *input*, sehingga data yang masuk ke tahap pemodelan berada pada format yang konsisten. Pada tahap ini dapat terjadi penyesuaian tambahan sesuai kebutuhan penelitian, misalnya penanganan kualitas audio atau pembuatan varian audio yang lebih fokus pada segmen ujaran, selama tetap mengikuti aturan praproses yang sama untuk seluruh sampel.

Tahap berikutnya mencakup penerapan protokol pembagian data yang digunakan untuk evaluasi, kemudian proses *training* dan *validation* dijalankan sesuai protokol tersebut. Dengan rancangan ini, perbandingan antar skenario dapat dilakukan dalam kerangka *pipeline* yang sama dan hasil eksperimen dapat diinterpretasikan dengan lebih terstruktur. Selain itu, pengaturan eksperimen seperti konfigurasi pelatihan, pencatatan kinerja, dan keluaran model disusun konsisten agar perbedaan hasil lebih merefleksikan perbedaan skenario, bukan perbedaan

prosedur. Penjelasan desain penelitian dan alur umum sistem dijabarkan pada Subbab 3.1.1 sebagai pengantar sebelum masuk ke rincian tahap berikutnya.

3.1.1 Desain Penelitian & Alur Umum



Gambar 3.1 Diagram Alir Umum Penelitian Audio-only Personality Estimation

Penelitian ini menggunakan desain eksperimen untuk melakukan estimasi kepribadian *Big Five* berbasis suara (*audio-only personality estimation*). Secara umum, alur penelitian dimulai dari menyiapkan data mentah berupa video, mengubahnya menjadi audio, melakukan praproses audio, menyusun protokol pembagian data (*split*), menjalankan beberapa skenario representasi fitur dan model, hingga memperoleh konfigurasi terbaik dan melakukan evaluasi final pada data uji. Alur lengkap penelitian ditunjukkan pada Gambar 3.1.


Tahap awal penelitian adalah menyiapkan dataset yang digunakan sebagai sumber data utama. Dari dataset tersebut, setiap video diekstraksi menjadi audio agar seluruh sampel dapat diproses dalam domain suara secara seragam. Setelah itu, dilakukan praproses audio untuk menyiapkan masukan yang konsisten dan layak digunakan pada tahap eksperimen berikutnya. Tahap praproses ini mencakup penyesuaian format audio dan langkah-langkah lain yang diperlukan agar kualitas data masukan lebih stabil. Karena tahap ini cukup rinci, penjelasan teknis lengkapnya disajikan pada subbab tersendiri, sedangkan pada Gambar 3.1 tahap ini hanya ditampilkan sebagai ringkasan alur besar.

Setelah audio hasil praproses tersedia, penelitian menyusun pembagian dataset melalui dua jalur, yaitu *official split* dan *strict split*. *Official split* dipertahankan agar hasil penelitian dapat dibandingkan dengan studi-studi terdahulu yang menggunakan pembagian resmi dataset. Sementara itu, *strict split* disusun untuk memberikan evaluasi yang lebih konservatif dengan mengurangi potensi kebocoran informasi antar split. Dengan demikian, penelitian tidak hanya berfokus pada pelaporan hasil pada split resmi, tetapi juga menguji ketahanan model pada protokol evaluasi yang lebih ketat. Rincian pembentukan *strict split* dijelaskan lebih lanjut pada subbab khusus.

Berikutnya, penelitian menjalankan seluruh skenario representasi dan model pada dataset yang telah disiapkan. Tahap ini mencakup eksperimen dengan beberapa bentuk representasi fitur dan pendekatan pemodelan yang digunakan dalam penelitian. Setiap skenario menghasilkan prediksi kepribadian Big Five beserta metrik evaluasi yang kemudian digunakan untuk menganalisis kinerja masing-masing pendekatan pada *official split* maupun *strict split*. Karena tahap ini juga melibatkan beberapa rancangan eksperimen yang berbeda, uraian rinci mengenai skenario representasi dan model disajikan pada subbab tersendiri.

Dengan susunan tersebut, Gambar 3.1 berfungsi sebagai gambaran umum alur penelitian dari awal hingga akhir, sedangkan setiap blok besar, yaitu praproses audio, penyusunan *strict split*, serta skenario representasi dan model, dijelaskan lebih rinci pada subbab-subab berikutnya.

3.1.2 Prosedur Praproses Dataset



Gambar 3.2 Alur Praproses Dataset

1	INPUT: official_metadata, extracted_audio_files
2	OUTPUT: preprocessed_full_wav, manifest_csv, drop_list_csv
3	Load official metadata and extracted audio paths
4	Select important metadata fields: clip_id, labels, and supporting attributes
5	Parse clip_id to obtain group_id for each sample
6	FOR each clip in metadata DO

7	Load audio file for the current clip
8	Decode audio and validate file format
9	IF audio cannot be decoded THEN
10	Mark sample as dropped with reason = <code>decode_failed</code>
11	CONTINUE to next clip
12	ENDIF
13	Check minimum duration requirement
14	IF duration is below minimum threshold THEN
15	Mark sample as dropped with reason = <code>too_short</code>
16	CONTINUE to next clip
17	ENDIF
18	Convert audio to mono, 16 kHz
19	Standardize audio duration to 15 seconds by trimming or <i>padding</i>
20	END FOR
21	Run VAD on all standardized audio files
22	Compute VAD statistics: <code>speech_sec</code> , <code>voiced_ratio</code> , <code>n_seg</code>
23	Verify samples in the drop list based on VAD results
24	IF a sample has too little speech THEN
25	Mark sample as dropped with reason = <code>too_little_speech</code>
26	ENDIF
27	Save final artifacts: <code>preprocessed_full.wav</code> , <code>manifest.csv</code> , <code>drop_list.csv</code>
28	RETURN <code>preprocessing_artifacts</code>

Kode Semu 3.1 Praproses Dataset

Pada tahap praproses, data *audio* dan metadata disiapkan agar memiliki format yang seragam serta memenuhi kualitas minimum sebelum digunakan pada tahap pembagian data dan eksperimen model. Alur umum tahap ini ditunjukkan pada Gambar 3.2. Proses diawali dengan menyiapkan masukan berupa metadata *official* dan *audio* hasil ekstraksi dari video. Dari metadata tersebut, diambil informasi penting yang diperlukan untuk tahapan berikutnya, seperti *clip_id*, label *Big Five*, dan metadata pendukung lainnya. Selanjutnya dilakukan *parsing clip_id* menjadi *group_id* agar setiap sampel dapat dikaitkan dengan identitas grup yang konsisten, sehingga informasi ini siap digunakan pada tahap *strict split*.

Setelah metadata siap, *audio* dimuat untuk setiap klip, kemudian dilakukan proses *decode* dan validasi format. Tahap ini bertujuan memastikan bahwa berkas *audio* dapat dibaca dengan benar dan tidak mengalami kerusakan. Selain itu, parameter dasar *audio*, seperti durasi dan format sinyal, juga diperiksa pada tahap ini. Apabila berkas gagal diproses atau tidak memenuhi syarat minimum, sampel tersebut dicatat sebagai data yang perlu dikeluarkan dari *pipeline* lebih lanjut.


Untuk sampel yang lolos, dilakukan pengecekan durasi minimum sebagai bagian dari kontrol kualitas awal. *Audio* yang memenuhi syarat kemudian dikonversi ke format *mono* dengan *sampling rate* 16 kHz agar seluruh sampel memiliki representasi sinyal yang seragam. Setelah itu, durasi *audio* distandarisasi menjadi 15 detik melalui proses *trimming* atau *padding*, sehingga setiap klip memiliki panjang input yang konsisten. Penyeragaman ini penting agar

variasi panjang sinyal tidak memengaruhi tahap ekstraksi representasi maupun proses pelatihan model.

Berikutnya, dilakukan ekstraksi statistik VAD untuk memperoleh ringkasan informasi terkait aktivitas ujaran pada setiap klip. Tahap ini digunakan sebagai bentuk *quality control* tambahan, sehingga sampel yang mengandung ujaran terlalu sedikit, terlalu dominan hening, atau tidak memenuhi kriteria kualitas dapat diidentifikasi. Hasil pemeriksaan tersebut kemudian digunakan pada tahap verifikasi daftar *drop*, yaitu untuk meninjau kembali sampel-sampel yang perlu dikeluarkan dari dataset hasil *preprocessing*.

Seluruh keluaran tahap *preprocessing* kemudian disimpan sebagai artefak yang akan digunakan pada tahap berikutnya. Artefak tersebut mencakup *audio* hasil akhir *preprocessed_full.wav*, berkas *manifest.csv* yang memuat metadata setelah *preprocessing*, serta log *drop_list.csv* yang mencatat sampel yang dikeluarkan beserta alasannya. Dengan demikian, tahap *preprocessing* tidak hanya menghasilkan *audio* yang telah distandarisasi, tetapi juga menyediakan metadata dan catatan pembersihan data yang mendukung reproduktibilitas *pipeline*. Artefak inilah yang selanjutnya digunakan sebagai masukan untuk proses pembentukan *strict split* dan eksperimen model. Rangkaian langkah utama pada tahap ini juga diringkas dalam bentuk kode semu pada Kode Semu 3.1 untuk memperjelas urutan proses *preprocessing* yang diterapkan pada setiap sampel.

3.1.3 Prosedur *Strict Split*



Gambar 3.3 Alur Split Strict

1	INPUT: preprocessed_audio, manifest_csv
---	---

2	OUTPUT: group_split_strict_csv, manifest_strict_csv
3	Load preprocessing outputs and metadata files
4	Merge and prepare clean sample-level data
5	Compute label summary for splitting (e.g., avg_trait)
6	Aggregate sample-level records into group-level records using group_id
7	Evaluate candidate stratification schemes
8	Select the most stable stratification columns
9	split_ok <- False
10	WHILE split_ok = False DO
11	Perform strict split 3:1:1 at group_id level
12	Assign each group_id to train, validation, and test
13	Validate the split:
14	Check group_id disjointness across splits
15	Check clip_id uniqueness as sanity check
16	Check group and clip ratios against target 3:1:1
17	Check distribution balance of selected strata
18	IF all validation criteria are satisfied THEN
19	split_ok <- True
20	ELSE
21	Improve group_id allocation and repeat split
22	ENDIF
23	ENDWHILE
24	Save group-level split mapping as group_split_strict.csv
25	Save clip-level manifest with split_strict labels as manifest_strict.csv
26	RETURN strict split artifacts

Kode Semu 3.2 Pembentukan Strict Split

Pada tahap ini disusun *strict split* sebagai protokol pembagian dataset yang dirancang untuk meminimalkan potensi kebocoran informasi antar *split*, sebagaimana ditunjukkan pada Gambar 3.3. Berbeda dari pembagian data biasa pada level sampel, *strict split* dibentuk pada level grup menggunakan variabel *group_id*, sehingga seluruh sampel yang berasal dari *group_id* yang sama harus ditempatkan pada *split* yang sama dan tidak boleh tersebar ke *split* lain. Dengan pendekatan ini, evaluasi diharapkan lebih merefleksikan kemampuan generalisasi model pada grup yang berbeda, bukan karena kemiripan identitas atau sumber data yang pernah muncul pada tahap pelatihan.

Proses dimulai dari menyiapkan masukan berupa *audio* hasil praproses dan berkas *manifest* yang memuat informasi metadata tiap sampel. Berdasarkan input tersebut, terlebih dahulu dihitung ringkasan label yang diperlukan untuk membantu pembagian data secara lebih seimbang. Setelah itu, data diagregasikan pada level *group_id*, sehingga informasi yang semula berada pada level sampel dirangkum menjadi representasi per grup. Tahap ini penting karena unit pembagian pada *strict split* bukan lagi sampel individual, melainkan grup.

Selanjutnya dilakukan pemilihan kolom stratifikasi yang akan digunakan sebagai dasar pembagian data. Pemilihan ini bertujuan agar distribusi karakteristik penting pada dataset tetap relatif terjaga di setiap *split*. Setelah kolom stratifikasi ditentukan, dilakukan pembagian *strict split* dengan rasio 3:1:1 untuk membentuk *train_strict*, *val_strict*, dan *test_strict*. Karena pembagian dilakukan pada level *group_id*, seluruh anggota dari grup yang sama akan tetap berada pada *split* yang sama.


Setelah pembagian awal terbentuk, dilakukan validasi *split* untuk memeriksa apakah hasil pembagian sudah memenuhi kriteria yang diinginkan. Validasi ini mencakup pemeriksaan keterpisahan grup antar *split*, kesesuaian rasio pembagian, serta kewajaran distribusi karakteristik data pada masing-masing *split*. Jika hasil validasi belum memenuhi kriteria, maka alokasi *group_id* diperbaiki dan proses pembagian diulang kembali sampai diperoleh *split* yang dinyatakan lolos. Apabila validasi telah terpenuhi, hasil akhir disimpan sebagai *train_strict*, *val_strict*, dan *test_strict* untuk digunakan pada tahap eksperimen berikutnya.

Dengan demikian, Gambar 3.3 merangkum bahwa pembentukan *strict split* tidak hanya berupa pembagian data sekali jalan, tetapi melibatkan proses peringkasan label, agregasi per grup, pemilihan stratifikasi, validasi, dan perbaikan alokasi secara iteratif hingga diperoleh pembagian data yang sesuai dengan prinsip *strict split*. Rangkaian langkah utama pada tahap ini juga diringkas dalam bentuk kode semu pada Kode Semu 3.2 untuk memperjelas urutan pembentukan *strict split* pada level *group_id*.

3.1.4 Skenario *baseline* representasi & model

Pada tahap skenario representasi dan model, penelitian ini merancang beberapa pendekatan dasar (*baseline*) untuk memprediksi Big Five dari audio, sebagaimana ditunjukkan pada Gambar 3.4. Secara umum, skenario dibagi ke dalam dua jalur utama, yaitu representasi berbasis *self-supervised learning* (SSL) dalam kondisi *frozen* dan representasi berbasis fitur *handcrafted* menggunakan eGeMAPS. Kedua jalur ini digunakan untuk membangun pembandingan awal sebelum dilakukan tahap lanjutan berupa *fine-tuning* pada backbone SSL terbaik. Uraian lama yang menjadi dasar bagian ini telah disesuaikan dengan diagram terbaru.

Pada jalur SSL *frozen*, langkah “pilih model” pada Gambar 3.4 menunjukkan bahwa skenario dijalankan secara bergantian untuk tiga backbone, yaitu HuBERT, wav2vec2, dan WavLM. Untuk masing-masing backbone, audio direpresentasikan menjadi *embedding*, kemudian dilakukan *pooling* agar keluaran model diringkas menjadi vektor tetap untuk setiap sampel. Vektor tersebut selanjutnya digunakan sebagai masukan bagi model regresi Ridge dengan *tuning* parameter alpha, sehingga dihasilkan prediksi untuk lima trait Big Five. Dengan demikian, setiap backbone membentuk satu skenario *baseline* yang dibandingkan secara terpisah.



Gambar 3.4 Alur Skenario Baseline dan Representasi Model

1	INPUT: preprocessed audio, official split, strict split
2	OUTPUT: scenario predictions, metrics, and saved models
3	Choose representation pathway
4	IF representation = SSL Frozen THEN
5	FOR each backbone in {HuBERT, wav2vec2, WavLM} DO
6	Extract clip-level embeddings from audio
7	Apply pooling to obtain fixed-length vector per clip
8	FOR each split setting in {official, strict} DO
9	Fit Ridge regressor with alpha tuning on training split
10	Generate validation and test predictions
11	Compute evaluation metrics and save model outputs
12	ENDFOR
13	ENDFOR
14	ELSE IF representation = eGeMAPS THEN
15	Extract eGeMAPS handcrafted features from audio
16	Apply feature scaling using training data only
17	FOR each split setting in {official, strict} DO
18	Fit Ridge regressor with alpha tuning on training split
19	Generate validation and test predictions
20	Compute evaluation metrics and save model outputs
21	ENDFOR
22	ENDIF
23	Collect all scenario outputs: predictions, metrics, and model artifacts
24	IF scenario uses strict split THEN
25	Select best SSL backbone from validation results
26	Mark selected backbone for fine-tuning stage
27	ENDIF
28	RETURN baseline scenario summary

Kode Semu 3.3 Skenario Baseline dan Representasi Model


Pada jalur eGeMAPS, audio diekstraksi menjadi fitur akustik *handcrafted* menggunakan himpunan fitur eGeMAPS. Fitur yang diperoleh kemudian melalui tahap *scaling* sebelum digunakan sebagai masukan bagi model regresi Ridge dengan *tuning* parameter alpha. Dari jalur ini dihasilkan prediksi Big Five berbasis fitur akustik konvensional yang berfungsi sebagai pembanding terhadap pendekatan berbasis representasi SSL.

Seluruh keluaran dari setiap skenario, baik pada jalur SSL *frozen* maupun eGeMAPS, dikumpulkan dalam bentuk prediksi, metrik evaluasi, dan artefak model untuk dianalisis lebih lanjut. Pada skenario yang menggunakan *strict split*, hasil evaluasi pada data validasi digunakan sebagai dasar untuk memilih backbone SSL terbaik. Backbone terpilih tersebut kemudian menjadi kandidat untuk tahap lanjutan berupa *fine-tuning*, yang dijelaskan pada subbab terpisah. Dengan demikian, Gambar 3.4 merangkum bahwa tahap ini tidak hanya membandingkan dua jenis representasi audio, tetapi juga menjadi dasar pemilihan backbone terbaik untuk eksperimen lanjutan. Rangkaian langkah utama pada tahap skenario representasi dan model juga diringkas dalam bentuk kode semu pada Kode Semu 3.3 untuk memperjelas urutan pelaksanaan setiap skenario *baseline* pada jalur SSL *frozen* maupun eGeMAPS.

3.1.5 Strategi *Fine-tuning* dan *Tuning* Hyperparameter LoRA

Pada skenario *fine-tuning* seperti yang ditunjukkan pada Gambar 3.5, proses dimulai dari data *manifest_strict* yang telah disusun pada tahap sebelumnya. Pembagian data *train_strict*,

val_strict, dan *test_strict* digunakan secara terpisah, dengan *test_strict* tetap dikunci agar tidak terlibat dalam proses pemilihan hiperparameter maupun seleksi model. Dengan demikian, seluruh keputusan selama *fine-tuning* hanya didasarkan pada kinerja validasi, sedangkan evaluasi pada *test_strict* dilakukan setelah konfigurasi model ditetapkan.



Gambar 3.5 Diagram Alir Strategi Fine-tuning dengan LoRA

1	INPUT: manifest_strict_csv, pretrained_backbone_weights
2	OUTPUT: selected_checkpoints, prediction_csvs, metrics_json, plots
3	Load manifest_strict and split data into train_strict, val_strict, and test_strict
4	Load pretrained SSL backbone
5	Freeze backbone parameters
6	Attach LoRA adapters to target modules: q_proj and v_proj
7	Add regression head for 5 Big Five traits
8	Define Optuna search space: learning_rate, r, lora_alpha, lora_dropout, weight_decay, warmup_ratio
9	FOR each Optuna trial DO

10	Sample one hyperparameter configuration
11	Train model on train_strict and validate on val_strict
12	Use MAE-based score S on validation as selection metric
13	Save best checkpoint for the trial
14	Apply early stopping and Optuna pruning when needed
15	ENDFOR
16	Select best hyperparameter configuration from Optuna study
17	FOR each seed in FINAL_SEEDS DO
18	Train one final run on train_strict using BEST_HP
19	Select best checkpoint by validation score S
20	Load best checkpoint of the run
21	Evaluate the run on test_strict
22	Save checkpoint, predictions, metrics, and training history
23	ENDFOR
24	Aggregate results from all final runs
25	Select best-val run and median run
26	Build simple ensemble by averaging test predictions across final runs
27	Export final checkpoints, prediction files, metrics, and plots
28	RETURN fine-tuning artifacts

Kode Semu 3.4 Skenario Fine-tune

Tahap berikutnya adalah memuat *backbone* SSL yang akan digunakan sebagai dasar *fine-tuning*. Pada rancangan ini, *backbone* dimuat dari bobot pralatih, kemudian parameter *backbone* utama dibekukan agar tidak diperbarui secara penuh selama pelatihan. Setelah itu dipasang LoRA (*Low-Rank Adaptation*) pada modul target tertentu di dalam *backbone*, dan ditambahkan *regression head* untuk memetakan representasi keluaran model menjadi lima skor *Big Five*. Dengan rancangan ini, parameter yang dioptimasi terutama berasal dari komponen LoRA dan *regression head*, sehingga proses *fine-tuning* menjadi lebih ringan dibandingkan pelatihan ulang seluruh *backbone*.

Untuk mencari konfigurasi yang sesuai, digunakan *hyperparameter search* berbasis Optuna. Pada tahap ini, setiap *trial* merepresentasikan satu kombinasi hiperparameter yang diuji pada data *train_strict* dan dievaluasi pada *val_strict*. Hiperparameter yang direncanakan untuk ditelusuri meliputi parameter utama LoRA dan parameter optimisasi, seperti *learning rate*, *rank*

LoRA (*r*), *lora_alpha*, *lora_dropout*, *weight_decay*, dan *warmup_ratio*. Setiap konfigurasi dinilai menggunakan skor validasi terbaik selama pelatihan. Sejalan dengan rancangan evaluasi pada penelitian ini, metrik seleksi yang digunakan adalah skor S, yang didefinisikan dari nilai MAE validasi sehingga konfigurasi dengan nilai S terbaik dipilih sebagai kandidat utama. Pada rancangan eksperimen ini, pencarian hiperparameter dilakukan menggunakan Optuna sebanyak 50 *trial*. Setiap *trial* direncanakan dilatih hingga maksimum 100 *epoch* dengan *early stopping patience* sebesar 5, *batch size* 40, *optimizer AdamW*, dan *gradient clipping* 1.0. Setelah hiperparameter terbaik diperoleh, model dijalankan kembali dalam 10 *final runs* menggunakan *fixed seeds* untuk menilai kestabilan kinerja hasil *fine-tuning*.

Selama proses pelatihan pada setiap *trial* maupun *run* final, model dilatih menggunakan *train_strict* dan divalidasi menggunakan *val_strict*. Fungsi objektif yang digunakan adalah MAE untuk regresi multi-output pada lima trait Big Five. Optimisasi dilakukan menggunakan AdamW, dengan dukungan pengaturan umum seperti jumlah epoch maksimum, *early stopping* berbasis *patience*, *gradient clipping*, dan *checkpointing* berdasarkan skor validasi terbaik. Dengan pengaturan ini, model terbaik pada tiap *trial* atau *run* dipilih berdasarkan kinerja pada *val_strict*, bukan berdasarkan hasil pada data uji. Ukuran *batch* dan parameter teknis lain disesuaikan dengan kapasitas perangkat komputasi yang digunakan, sehingga nilai pastinya mengikuti konfigurasi implementasi pada notebook eksperimen.

Setelah proses pencarian hiperparameter selesai, dipilih kombinasi hiperparameter terbaik berdasarkan skor validasi terbaik. Konfigurasi tersebut kemudian digunakan pada tahap *final 10 runs dengan fixed seeds*. Tahap ini bertujuan untuk mengevaluasi kestabilan kinerja model ketika dilatih ulang beberapa kali dengan *seed* yang berbeda, tetapi tetap menggunakan hiperparameter yang sama. Setiap *run* menghasilkan model terbaik berdasarkan validasi, yang kemudian digunakan untuk evaluasi pada *test_strict*. Hasil evaluasi dari seluruh *run* dikumpulkan dan diagregasikan untuk memperoleh gambaran kinerja akhir yang lebih stabil.

Pada tahap pelaporan hasil *fine-tuning*, digunakan beberapa bentuk ringkasan untuk membedakan stabilitas pelatihan dan performa model tunggal. Mean 10 runs merujuk pada rata-rata metrik evaluasi dari sepuluh pelatihan ulang dengan *seed* berbeda, sehingga digunakan sebagai ringkasan utama kestabilan performa. *Best-val run* merujuk pada *run* tunggal dengan skor validasi terbaik, sehingga digunakan ketika analisis membutuhkan satu checkpoint atau satu set prediksi tertentu, misalnya visualisasi histogram, scatter plot, dan evaluasi per-trait. *Median run* digunakan sebagai contoh *run* yang lebih representatif terhadap performa tengah dari kumpulan *final runs*. Sementara itu, *ensemble run* diperoleh dengan merata-ratakan prediksi dari sepuluh *final runs* sebelum metrik dihitung, sehingga hasil ini merepresentasikan performa gabungan prediksi dan tidak diperlakukan sebagai satu checkpoint model tunggal.

Dengan alur tersebut, *fine-tuning* pada penelitian ini dirancang sebagai proses yang tetap mengikuti prinsip evaluasi ketat pada *strict split*, tetapi lebih sistematis dalam pencarian hiperparameter melalui Optuna dan lebih stabil dalam pelaporan hasil melalui beberapa *final runs*. Gambar 3.5 menampilkan ringkasan alur utama tahap ini, sedangkan rincian konfigurasi pelatihan dan implementasi eksperimen dijelaskan lebih lanjut pada bagian eksperimen. Rangkaian langkah utama pada tahap *fine-tuning* tersebut juga diringkas dalam bentuk kode semu pada Kode Semu 3.4 untuk memperjelas urutan pencarian hiperparameter, pelatihan ulang, evaluasi, dan agregasi hasil pada skenario LoRA.

3.2 Bahan dan Peralatan yang Digunakan

Bagian ini menjelaskan bahan dan peralatan yang digunakan selama penelitian. Bahan penelitian berfokus pada dataset yang menjadi sumber data utama untuk pemodelan kepribadian berbasis suara. Peralatan penelitian mencakup perangkat keras dan lingkungan komputasi yang digunakan untuk menjalankan tahap praproses audio, ekstraksi fitur, pelatihan model, serta evaluasi kinerja.

3.2.1 Dataset

Dataset yang digunakan adalah *Chalearn First impressions V2*. Dataset ini terdiri dari 10.000 klip dengan durasi rata-rata sekitar 15 detik yang diekstraksi dari lebih dari 3.000 video YouTube berkualitas tinggi. Data pada dataset ini pada dasarnya bersifat multimodal karena memuat video dan audio, namun pada penelitian ini hanya sinyal audio yang digunakan. Audio diperoleh dengan mengekstraksi kanal suara dari setiap klip sehingga seluruh tahapan pemodelan dilakukan dalam skenario berbasis audio.

Setiap sampel memiliki anotasi target berupa lima skor kepribadian *Big Five* yaitu *Openness*, *Conscientiousness*, *Extraversion*, *Agreeableness*, dan *Neuroticism*. Kelima skor tersebut berbentuk nilai kontinu dengan rentang 0 sampai 1, sehingga tugas yang dikerjakan termasuk regresi multivariabel. Dataset juga menyediakan pembagian data resmi ke dalam *train*, *validation*, dan *test* dengan rasio 3 banding 1 banding 1.

3.2.2 Perangkat Keras Hardware

Proses komputasi pada penelitian ini dijalankan menggunakan perangkat laptop sebagai lingkungan utama untuk pengolahan data, praproses *audio*, ekstraksi fitur, pelatihan model pada skala terbatas, serta evaluasi awal. Laptop yang digunakan memiliki prosesor Intel Core i5 1135G7 generasi ke-11 dengan 4 inti dan 8 thread, serta memori utama sebesar 16 GB DDR4 yang berjalan pada konfigurasi dual *channel*. Untuk kebutuhan grafis dan akselerasi komputasi tertentu pada skala terbatas, perangkat menyediakan GPU terintegrasi Intel Iris Xe Graphics dan GPU diskrit NVIDIA GeForce MX350 dengan VRAM 2 GB.

Pada tahap eksperimen yang membutuhkan komputasi lebih berat, terutama pelatihan model Transformer pralatih dengan pendekatan LoRA dan eksekusi eksperimen berulang, penelitian ini menggunakan lingkungan komputasi berbasis cloud melalui platform Vast.ai. Lingkungan cloud dipilih untuk memperoleh akses terhadap GPU dengan kapasitas komputasi dan memori yang lebih memadai dibandingkan perangkat lokal. Pada eksperimen utama, konfigurasi GPU yang digunakan adalah NVIDIA RTX A6000 dengan VRAM 48 GB. Penggunaan Vast.ai difokuskan pada tahap pelatihan dan evaluasi model yang membutuhkan akselerasi GPU, sedangkan pengelolaan data, pencatatan hasil eksperimen, dan dokumentasi konfigurasi tetap dilakukan secara konsisten agar hasil yang dilaporkan sesuai dengan implementasi penelitian.

Halaman ini sengaja dikosongkan.

BAB 4

HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil penelitian dan pembahasan dari eksperimen estimasi kepribadian *Big Five* berbasis data suara. Seluruh hasil yang dipaparkan diperoleh dari rangkaian tahapan penelitian yang telah dijelaskan pada bab sebelumnya, mulai dari eksplorasi dataset, praproses audio, pembentukan *strict split*, ekstraksi fitur, hingga pelatihan dan evaluasi model.

Penyajian hasil diawali dengan eksplorasi dataset untuk memberikan gambaran mengenai kelengkapan metadata, distribusi *label Big Five*, karakteristik demografis, kondisi audio, serta ketersediaan representasi fitur yang digunakan dalam eksperimen. Setelah itu, pembahasan dilanjutkan pada hasil praproses audio dan pembentukan *strict split* berbasis *group_id* sebagai dasar evaluasi model yang lebih terkontrol.

Bagian berikutnya menyajikan hasil *baseline* pada *official split* dan *strict split* untuk membandingkan pengaruh protokol pembagian data terhadap kinerja model. Berdasarkan hasil *baseline* pada *strict split*, WavLM menjadi *backbone frozen* terbaik sehingga digunakan sebagai acuan utama untuk menilai apakah *fine-tuning* LoRA dapat melampaui skema *frozen embedding + Ridge*. Namun, HuBERT juga dipertahankan sebagai kandidat pembanding kuat karena termasuk dalam kelompok *embedding SSL* dengan kinerja kompetitif dan memiliki karakter pralatih yang berbeda dari WavLM. Oleh karena itu, tahap *fine-tuning* tidak hanya dimaksudkan untuk menguji WavLM sebagai *baseline frozen* terbaik, tetapi juga untuk melihat apakah adaptasi LoRA memberi pola peningkatan yang konsisten pada *backbone SSL* lain. Pada bagian akhir, hasil WavLM+LoRA dan HuBERT+LoRA dibandingkan kembali terhadap *baseline frozen* masing-masing dan terhadap penelitian terdahulu.

4.1 Hasil Penelitian

Subbab ini menyajikan hasil penelitian yang diperoleh dari seluruh tahapan eksperimen. Hasil disusun secara berurutan agar alur penelitian dapat ditelusuri secara jelas, dimulai dari eksplorasi dataset, praproses audio dan pembentukan *strict split*, evaluasi *baseline* pada *official split* dan *strict split*, hingga *fine-tuning* model terbaik menggunakan LoRA.

Penyajian hasil diawali dengan eksplorasi dataset untuk menjelaskan kondisi awal data yang digunakan, meliputi ke lengkapan metadata, distribusi *label Big Five*, komposisi demografis, karakteristik audio, statistik aktivitas ujaran, serta ketersediaan representasi fitur. Bagian ini penting sebagai dasar untuk memahami kualitas dan karakteristik dataset sebelum data digunakan dalam eksperimen model.

Setelah eksplorasi dataset, subbab ini dilanjutkan dengan hasil praproses audio dan pembentukan *strict split* berbasis *group_id* untuk memastikan data yang digunakan telah melalui kendali kualitas dan memiliki pembagian yang mengurangi potensi ketergantungan sumber antar subset. Selanjutnya, hasil *baseline* pada *official split* dan *strict split* disajikan sebagai pembanding, kemudian diikuti oleh hasil *fine-tuning* WavLM dan HuBERT menggunakan LoRA. Seluruh hasil pada Subbab 4.1 menjadi dasar untuk pembahasan lebih lanjut pada Subbab 4.2.

4.1.1 Hasil Eksplorasi Dataset

Subbab ini menyajikan hasil eksplorasi awal terhadap dataset yang digunakan dalam penelitian sebelum pembahasan praproses, pembentukan *strict split*, *baseline*, dan *fine-tuning*. Eksplorasi dilakukan dalam skenario berbasis audio pada dataset *ChaLearn First Impressions V2*, sehingga fokus analisis diarahkan pada karakteristik *metadata*, label *Big Five*, kondisi audio, serta ketersediaan representasi fitur yang akan digunakan pada eksperimen berikutnya. Tahap eksplorasi ini tidak dimaksudkan untuk mengevaluasi kinerja model, melainkan untuk memastikan bahwa data yang digunakan memiliki kelengkapan dan karakteristik yang dapat dipahami sebelum masuk ke tahap pemodelan.

Setiap klip pada dataset memiliki lima label target *Big Five*, yaitu *extraversion*, *neuroticism*, *agreeableness*, *conscientiousness*, dan *openness*. Seluruh label berbentuk nilai kontinu pada rentang 0 sampai 1, sehingga tugas estimasi kepribadian pada penelitian ini diperlakukan sebagai regresi multi-output. Ringkasan umum dataset ditunjukkan pada Tabel 4.1.

Tabel 4.1 Ringkasan umum dataset yang digunakan pada skenario berbasis audio

Komponen	Nilai	Keterangan
Jumlah total klip metadata	10.000	Gabungan metadata <i>train</i> , <i>validation</i> , dan <i>test</i> official
Jumlah <i>clip_id</i> unik	10.000	Setiap <i>clip_id</i> merepresentasikan satu klip
Jumlah <i>group_id</i> unik	3.060	Unit sumber video atau grup
Jumlah <i>trait</i> target	5	<i>extraversion</i> , <i>neuroticism</i> , <i>agreeableness</i> , <i>conscientiousness</i> , <i>openness</i>
Rentang label	0 sampai 1	Rentang keseluruhan label <i>Big Five</i>
Modalitas eksperimen	audio-only	Data visual tidak digunakan sebagai input eksperimen


Pembagian awal dataset mengikuti *official split* dengan rasio 3:1:1, yaitu 6.000 klip untuk *train*, 2.000 klip untuk *validation*, dan 2.000 klip untuk *test*. Komposisi ini ditunjukkan pada Tabel 4.2 dan divisualisasikan pada Gambar 4.1. Pada tahap EDA, pembagian *official* ini digunakan sebagai gambaran komposisi awal dataset, sedangkan pembahasan mengenai pembentukan *strict split* ditempatkan pada subbab berikutnya.

Pemeriksaan kelengkapan data dilakukan pada kolom utama yang digunakan dalam penelitian, meliputi *clip_id*, *group_id*, *split_official*, *metadata* pendukung, lima label *Big Five*, dan *avg_trait*. Hasil pemeriksaan menunjukkan bahwa tidak ditemukan *missing value* pada kolom-

kolom tersebut. Selain itu, tidak ditemukan duplicate *clip_id* maupun *duplicate full rows*, sehingga metadata dapat digunakan sebagai dasar eksplorasi dan eksperimen lanjutan. Ringkasan pemeriksaan kelengkapan dan duplikasi disajikan pada Tabel 4.3. Detail missing *value* per kolom disajikan pada Lampiran 1, ringkasan duplikasi metadata disajikan pada Lampiran 2, sedangkan ringkasan ketersediaan audio disajikan pada Lampiran 3.

Tabel 4.2 Distribusi official split awal pada dataset.

<i>Split</i>	Jumlah klip	Proporsi
<i>Train</i>	6.000	60,00%
<i>Validation</i>	2.000	20,00%
<i>Test</i>	2.000	20,00%



Gambar 4.1 Distribusi *official split* awal pada dataset.

Tabel 4.3 Ringkasan pemeriksaan kelengkapan dan duplikasi dataset

Pemeriksaan	Hasil	Keterangan
<i>Missing value</i> pada kolom utama	0	Tidak ditemukan missing value pada 14 kolom utama yang dicek
<i>Duplicate clip_id</i>	0	Tidak ada <i>clip_id</i> ganda

Pemeriksaan	Hasil	Keterangan
<i>Duplicate full rows</i>	0	Tidak ada baris metadata yang duplikat
Audio tidak ditemukan	0	Audio tersedia untuk seluruh 10.000 metadata

Distribusi label *Big Five* ditinjau untuk memahami rentang dan kecenderungan nilai target sebelum model dibangun. Berdasarkan Tabel 4.4, seluruh *trait* memiliki 10.000 observasi dengan nilai minimum 0 dan maksimum 1. Rata-rata label berada di sekitar area tengah, dengan mean *extraversion* sebesar 0,476636, *neuroticism* sebesar 0,520833, *agreeableness* sebesar 0,549451, *conscientiousness* sebesar 0,524272, dan *openness* sebesar 0,566667. Sebaran label untuk kelima *trait* ditunjukkan pada Gambar 4.2. Pola tersebut menunjukkan bahwa label tidak terkonsentrasi pada nilai ekstrem, namun tetap memiliki variasi antar sampel yang perlu dipertimbangkan pada tahap pemodelan. Visualisasi histogram masing-masing *trait* secara terpisah disajikan pada Lampiran 6.

Pola distribusi tersebut memiliki implikasi terhadap proses pemodelan regresi. Karena sebagian besar nilai label berada di sekitar rentang tengah, model dapat memperoleh nilai *MAE* yang relatif kecil apabila prediksinya cenderung mendekati nilai rata-rata. Namun, prediksi seperti itu belum tentu mampu menjelaskan variasi antar sampel secara baik. Oleh karena itu, evaluasi pada penelitian ini tidak hanya menggunakan *MAE* dan $\text{Acc}(1-\text{MAE})$, tetapi juga melibatkan R^2 untuk melihat sejauh mana model mampu menangkap variasi skor *Big Five*, bukan sekadar menghasilkan prediksi yang dekat dengan pusat distribusi label.


Tabel 4.4 Statistik label Big Five pada keseluruhan metadata.

<i>Trait</i>	<i>Count</i>	<i>Mean</i>	<i>Std</i>	<i>Min</i>	<i>Q1</i>	<i>Median</i>	<i>Q3</i>	<i>Max</i>
<i>extraversion</i>	10.000	0,476636	0,151005	0	0,373832	0,476636	0,579439	1
<i>neuroticism</i>	10.000	0,520833	0,152766	0	0,416667	0,53125	0,635417	1
<i>agreeableness</i>	10.000	0,549451	0,134057	0	0,461538	0,56044	0,637363	1
<i>conscientiousness</i>	10.000	0,524272	0,154804	0	0,417476	0,524272	0,640777	1
<i>openness</i>	10.000	0,566667	0,145812	0	0,466667	0,566667	0,666667	1

Selain statistik per-*trait*, *avg_trait* juga dihitung sebagai ringkasan rata-rata dari lima label *Big Five* pada setiap klip. Nilai *avg_trait* memiliki mean 0,527572, standar deviasi 0,128212, nilai minimum 0,049752, median 0,534115, dan nilai maksimum 0,923902. Ringkasan ini digunakan untuk memberi gambaran umum kecenderungan skor *apparent personality* pada level klip, bukan sebagai target tunggal pengganti lima *trait* utama.

Hubungan antar skor *trait* dapat diamati melalui matriks korelasi pada Gambar 4.3. Matriks tersebut menunjukkan korelasi positif antar *trait*, dengan beberapa pasangan memiliki korelasi yang relatif tinggi, misalnya *extraversion* dengan *neuroticism*, *extraversion* dengan *openness*, dan *neuroticism* dengan *openness*. Pola ini menunjukkan adanya keterkaitan antar skor


apparent personality yang diberikan oleh anotator, tetapi tidak dapat ditafsirkan sebagai hubungan sebab-akibat antar dimensi kepribadian. Perbandingan distribusi label berdasarkan *official split* ditampilkan lebih lengkap pada Lampiran 7 dalam bentuk boxplot, sedangkan statistik ringkas label per *split* dan per *trait* disajikan pada Lampiran 8.



Gambar 4.2 Distribusi label *Big Five* pada dataset.

Eksplorasi *metadata* demografis dilakukan untuk melihat komposisi kategori pendukung pada dataset. Karena file EDA menggunakan kode numerik dan tidak memuat mapping kategori secara eksplisit, pembahasan ini mempertahankan penamaan kategori sebagai *gender=1*, *gender=2*, *ethnicity=1*, *ethnicity=2*, *ethnicity=3*, dan *age_group* sesuai kode pada data. Distribusi *gender* relatif lebih seimbang, yaitu *gender=1* sebanyak 4.538 klip atau 45,38% dan *gender=2* sebanyak 5.462 klip atau 54,62%. Sebaliknya, distribusi *ethnicity* didominasi oleh *ethnicity=2* sebanyak 8.598 klip atau 85,98%, sedangkan *ethnicity=1* dan *ethnicity=3* masing-masing berjumlah 331 klip atau 3,31% dan 1.071 klip atau 10,71%. Pada *age_group*, kategori terbesar adalah *age_group=5* sebanyak 4.908 klip atau 49,08%, diikuti *age_group=6* sebanyak 2.344 klip atau 23,44%, dan *age_group=4* sebanyak 1.960 klip atau 19,60%. Ringkasan distribusi *metadata* disajikan pada Tabel 4.5, sedangkan heatmap kombinasi *gender* dan *ethnicity* ditunjukkan pada Gambar 4.4. Detail distribusi *metadata* demografis disajikan pada Lampiran 9.

Pemeriksaan audio menunjukkan bahwa audio ditemukan untuk seluruh 10.000 *metadata*. Visualisasi durasi pada output EDA menunjukkan seluruh klip berdurasi 15 detik karena audio yang digunakan pada tahap eksplorasi sinyal merupakan audio hasil *standardisasi*. Dengan demikian, statistik durasi ini perlu dibaca sebagai kondisi audio yang masuk ke tahap eksplorasi dan representasi setelah *standardisasi*, bukan sebagai durasi mentah sebelum pra-proses.




Gambar 4.3 Matriks korelasi antar label *Big Five*.

Tabel 4.5 Distribusi metadata demografis berdasarkan kode kategori pada dataset.

Metadata	Kategori	Jumlah klip	Proporsi
gender	gender=1	4.538	45,38%
gender	gender=2	5.462	54,62%
ethnicity	ethnicity=1	331	3,31%
ethnicity	ethnicity=2	8.598	85,98%
ethnicity	ethnicity=3	1.071	10,71%
age_group	age_group=1	2	0,02%
age_group	age_group=2	18	0,18%
age_group	age_group=3	250	2,50%
age_group	age_group=4	1.960	19,60%
age_group	age_group=5	4.908	49,08%
age_group	age_group=6	2.344	23,44%

Metadata	Kategori	Jumlah klip	Proporsi
age_group	age_group=7	413	4,13%
age_group	age_group=8	105	1,05%




Gambar 4.4 Distribusi kombinasi *gender* dan *ethnicity* berdasarkan kode kategori.

Kualitas aktivitas ujaran dianalisis secara awal menggunakan statistik *VAD*, yaitu *speech_sec*, *voiced_ratio*, dan *n_seg*. Nilai *speech_sec* merepresentasikan total durasi segmen yang terdeteksi sebagai ujaran, *voiced_ratio* menyatakan rasio durasi ujaran terhadap durasi total klip, sedangkan *n_seg* menunjukkan jumlah segmen ujaran yang terdeteksi. Berdasarkan Tabel 4.6, *speech_sec* memiliki mean 13,118778 detik dan median 13,612 detik, *voiced_ratio* memiliki mean 0,874585, dan *n_seg* memiliki mean 4,2892. Distribusi *speech_sec* pada Gambar 4.5 menunjukkan bahwa sebagian besar klip memiliki durasi ujaran yang cukup tinggi, meskipun terdapat sejumlah kecil klip dengan aktivitas ujaran rendah. File *vad_drop.csv* pada output EDA memuat 26 klip yang ditandai dengan reason *too_little_speech*, sehingga temuan ini digunakan sebagai indikasi *quality control* awal. Distribusi tambahan *voiced_ratio* dan *n_seg* berdasarkan hasil *VAD* disajikan pada Lampiran 10, sedangkan contoh *waveform* dan *log-mel spectrogram* audio hasil *standardisasi* disajikan pada Lampiran 11.

Tabel 4.6 Ringkasan statistik VAD pada audio hasil standardisasi.

Metrik	Count	Mean	Std	Min	Q1	Median	Q3	Max
speech_sec	10.000	13,118778	1,844391	0	12,486	13,612	14,35	15
voiced_ratio	10.000	0,874585	0,122959	0	0,8324	0,907467	0,956667	1

Metrik	Count	Mean	Std	Min	Q1	Median	Q3	Max
n_seg	10.000	4,2892	1,931201	0	3	4	6	13



Gambar 4.5 Distribusi durasi ujaran berdasarkan *speech_sec* VAD.

Output EDA juga memuat ringkasan representasi data dan fitur yang tersedia untuk eksperimen berikutnya. Metadata dan label terdiri atas 10.000 sampel dengan 16 kolom, sedangkan audio WAV tersedia untuk 10.000 sampel dalam format 16 kHz *mono* berdurasi 15 detik. Setelah *quality control* awal berbasis *VAD*, fitur *eGeMAPS* tersedia untuk 9.974 sampel dengan 88 fitur, sedangkan *embedding* SSL dari *HuBERT*, *wav2vec2*, dan *WavLM* masing-masing tersedia untuk 9.974 sampel dengan dimensi 768. Ringkasan tersebut ditampilkan pada Tabel 4.7.

Pemeriksaan file *embedding* SSL yang tersedia menunjukkan tidak ada NaN dan tidak ada Inf pada *split train*, *validation*, maupun *test*, sehingga representasi tersebut layak digunakan sebagai masukan eksperimen berikutnya. Detail pemeriksaan bentuk *embedding*, jumlah sampel, dimensi fitur, serta pengecekan NaN dan Inf pada setiap *backbone* SSL disajikan pada Lampiran 4. Selain itu, ringkasan *explained variance* dari *PCA* 2D *embedding* SSL disajikan pada Lampiran 5 sebagai informasi tambahan mengenai proporsi variasi *embedding* yang tertangkap oleh dua komponen utama.

Distribusi fitur *eGeMAPS* terpilih disajikan pada Lampiran 12. Distribusi norm *embedding* SSL disajikan pada Lampiran 13, sedangkan visualisasi *PCA* 2D *embedding* SSL disajikan pada Lampiran 14 sebagai eksplorasi struktur representasi awal. *PCA* pada bagian ini hanya digunakan sebagai visualisasi eksploratif terhadap struktur representasi awal, bukan sebagai bukti bahwa suatu model memiliki kinerja prediksi lebih baik.

Berdasarkan keseluruhan eksplorasi, dataset memiliki *metadata* utama yang lengkap, label kontinu pada lima dimensi *Big Five*, audio yang tersedia untuk seluruh klip, serta beberapa bentuk representasi fitur yang siap digunakan pada eksperimen berikutnya. Namun, EDA juga menunjukkan adanya ketidakseimbangan pada beberapa *metadata* demografis, terutama *ethnicity* dan *age_group*, serta sejumlah kecil klip dengan aktivitas ujaran rendah. Oleh karena

itu, tahap praproses dan pembentukan *strict split* pada subbab berikutnya tetap diperlukan untuk menjaga kualitas data dan evaluasi, tanpa mencampurkan interpretasi EDA dengan hasil kinerja model.

Tabel 4.7 Ringkasan representasi data dan fitur yang tersedia dari output EDA.

Representasi	Dimensi	Keterangan
Metadata + Label	16	Memuat <i>clip_id</i> , <i>group_id</i> , <i>split</i> official, metadata, dan label <i>Big Five</i>
Audio WAV	16 kHz mono, 15 detik	Audio hasil standarisasi untuk kebutuhan <i>preview</i> sinyal dan ekstraksi fitur
eGeMAPS	88	Fitur handcrafted akustik
HuBERT	768	Embedding SSL pooled per klip
wav2vec2	768	Embedding SSL pooled per klip
WavLM	768	Embedding SSL pooled per klip

4.1.2 Hasil Praproses dan Pembentukan Strict Split

Subbab ini menyajikan hasil praproses audio dan pembentukan *strict split* berbasis *group_id* yang digunakan sebagai dasar eksperimen *baseline* dan *fine-tuning*. Tahap ini diarahkan untuk memastikan masukan audio memiliki format yang konsisten, kualitas ujaran yang memadai, serta pembagian data yang mengurangi potensi ketergantungan sumber antar subset. Dengan demikian, hasil evaluasi pada subbab berikutnya dapat ditafsirkan sebagai kinerja model pada data yang telah melalui kendali kualitas dan memiliki protokol pembagian yang terdefinisi.

Proses diawali dengan standarisasi audio. Seluruh audio hasil ekstraksi diseragamkan menjadi *mono* dengan *sampling rate* 16 kHz dan durasi tetap 15,0 detik. Audio yang lebih panjang dari durasi target dipotong, sedangkan audio yang lebih pendek diberi *zero padding* hingga mencapai panjang target. Penyeragaman ini dilakukan agar setiap klip memiliki panjang masukan yang sama, sehingga proses ekstraksi representasi dan pemrosesan *batch* dapat berjalan lebih konsisten. Ringkasan parameter standarisasi audio ditunjukkan pada Tabel 4.8.

Tabel 4.8 Tabel parameter standarisasi audio

Komponen	Nilai	Keterangan
Sampling rate target	16.000 Hz	Seluruh audio diseragamkan pada 16 kHz

Komponen	Nilai	Keterangan
Kanal	Mono	Jika <i>multi-channel</i> , dirata-rata menjadi mono
Durasi target	15,0 detik	Seluruh audio dipotong/ <i>padding</i> ke durasi tetap
<i>Padding</i>	<i>Zero padding</i>	Jika durasi < 15 detik
Format output	PCM_16	Format WAV untuk konsistensi penyimpanan
Output folder	output/preprocessing/preprocessed_full	Folder audio final hasil <i>trim/pad</i>
Manifest	trim_pad_manifest.csv	Berisi jalur <i>audio_in/out</i> dan <i>flag</i> durasi

Hasil standardisasi menunjukkan bahwa seluruh 10.000 klip berhasil diproses menjadi audio berdurasi tetap. Dari jumlah tersebut, 73 klip memiliki durasi asli kurang dari 15 detik sehingga diberi penanda *flag_short* dan diproses menggunakan *padding*. Setelah tahap ini, seluruh klip memiliki format audio yang seragam dan siap digunakan pada pemeriksaan kualitas berbasis VAD.

Pemeriksaan kualitas ujaran dilakukan menggunakan Silero VAD untuk menghitung tiga statistik utama pada setiap klip, yaitu *speech_sec*, *voiced_ratio*, dan *n_seg*. Variabel *speech_sec* menyatakan total durasi segmen yang terdeteksi sebagai ujaran dalam satuan detik, *voiced_ratio* menyatakan rasio durasi ujaran terhadap durasi total 15 detik, sedangkan *n_seg* menyatakan jumlah segmen ujaran yang terdeteksi. Pemeriksaan ini diperlukan karena klip yang terlalu banyak memuat hening atau gangguan non-ujaran dapat menghasilkan representasi audio yang kurang informatif untuk tugas estimasi kepribadian. Ringkasan statistik *speech_sec* pada pemeriksaan awal disajikan pada Tabel 4.9.

Tabel 4.9 Ringkasan statistik *speech_sec* (VAD awal, N=10.000 klip)

Statistik	Nilai (detik)
Rata-rata	13,103
Standar deviasi	1,906
Minimum	0,000
Persentil 1%	5,721
Persentil 5%	9,663
Median (50%)	13,612
Persentil 95%	14,934
Persentil 99%	15,000
Maksimum	15,000

Berdasarkan Tabel 4.9, sebagian besar klip masih memiliki cakupan ujaran yang tinggi karena median *speech_sec* mencapai 13,612 detik dari total durasi 15 detik. Namun, terdapat klip

dengan nilai *speech_sec* sangat rendah, termasuk nilai minimum 0,000 detik. Pada pemeriksaan awal, kriteria *speech_sec* < 2,0 detik menghasilkan 42 klip yang terindikasi terlalu sedikit memuat ujaran. Ambang tersebut digunakan untuk mengurangi kemungkinan model belajar dari sampel yang didominasi hening, *noise*, atau kondisi audio yang tidak representatif.

Sebanyak 42 klip yang terindikasi bermasalah kemudian diperiksa ulang. Pemeriksaan ulang dilakukan karena ditemukan beberapa kasus anomali ekstraksi, misalnya audio yang tidak terekstrak dengan baik atau sinyal stereo yang mengalami *phase cancellation* ketika kedua kanal dirata-ratakan menjadi *mono*. Perbaikan dilakukan melalui re-ekstraksi audio dari video asli dan pemilihan representasi *mono* terbaik dengan membandingkan kanal kiri, kanal kanan, dan rata-rata kanal berdasarkan nilai *root mean square* (*RMS*). Setelah itu, audio kembali distandarkan menjadi 15 detik dan diperiksa ulang menggunakan parameter *VAD* yang lebih sensitif terhadap ujaran pelan. Parameter *Silero VAD* yang digunakan pada tahap pemeriksaan ulang ditunjukkan pada Tabel 4.10.

Tabel 4.10 Parameter Silero VAD tuned (untuk re-check 42 klip)

Parameter	Nilai	Alasan
threshold	0,35	Lebih sensitif dibanding default (umumnya ~0,5)
min_speech_duration_ms	100	Mengakomodasi segmen ujaran pendek
min_silence_duration_ms	50	Mengurangi pemotongan ujaran pelan
speech_pad_ms	30	Memberi <i>padding</i> kecil pada segmen ujaran

Hasil re-ekstraksi menunjukkan seluruh 42 klip berhasil diproses ulang. Setelah pemeriksaan menggunakan parameter *VAD* yang telah disesuaikan, jumlah klip yang tetap memenuhi kondisi *speech_sec* < 2 berkurang menjadi 26 klip. Dengan demikian, terdapat 16 klip yang sebelumnya masuk daftar *drop* tetapi berhasil dipulihkan setelah perbaikan ekstraksi dan penalaan *VAD*. Ringkasan akhir klip yang tetap dikeluarkan dari dataset disajikan pada Tabel 4.11. Statistik utama *VAD* pada 26 klip *drop final* juga diringkas pada Lampiran 30 untuk menunjukkan bahwa klip yang dikeluarkan memang memiliki kandungan ujaran yang sangat rendah.

Tabel 4.11 Ringkasan hasil drop final (vad_drop.csv, N=26 klip)

Komponen	Nilai
Kriteria <i>drop</i>	<i>speech_sec</i> < 2,0 detik
Jumlah drop final	26
<i>speech_sec</i> minimum	0,000
<i>speech_sec</i> kuartil-1 (25%)	0,324
<i>speech_sec</i> median (50%)	0,506
<i>speech_sec</i> rata-rata	0,698
<i>speech_sec</i> kuartil-3 (75%)	1,128

Komponen	Nilai
speech_sec maksimum	1,682
voiced_ratio rata-rata	0,0465
voiced_ratio maksimum	0,1121
n_seg maksimum	5
<i>Reason</i>	<i>too_little_speech</i>

Setelah tahap pembersihan selesai, dataset bersih yang digunakan untuk pembentukan *strict split* berjumlah 9.974 klip dari total 10.000 klip awal. Karena jumlah klip yang dikeluarkan hanya 26 dari 10.000 klip awal, penghapusan ini terutama diperlakukan sebagai *quality control* audio dan tidak mengubah ukuran dataset secara substansial. Jumlah *group_id* keseluruhan sebelum pembersihan adalah 3.060, sedangkan jumlah *group_id* pada data bersih menjadi 3.054. Penurunan jumlah *group_id* tersebut menunjukkan bahwa terdapat beberapa grup yang seluruh klipnya terhapus karena tidak memenuhi kriteria kualitas ujaran. Ringkasan jumlah data pada setiap tahap praproses disajikan pada Tabel 4.12.

Tabel 4.12 Ringkasan jumlah data per tahap praproses

Tahap	Jumlah klip	Keterangan
Total data ter-merge	10.000	Meta + manifest audio
Audio fixed 15 detik	10.000	Trim/pad berhasil untuk seluruh klip
flag_short = 1	73	Durasi asli < 15 detik (<i>dipadding</i>)
Drop VAD awal	42	speech_sec < 2 (sebelum perbaikan)
Drop final	26	Setelah re-ekstraksi + VAD tuned
Total clean	9.974	Digunakan untuk strict split

Tahap berikutnya adalah pembentukan *strict split* pada level *group_id*. Nilai *group_id* dibentuk dari awalan *clip_id*, misalnya *--Ymqszjv54.001* dipetakan menjadi *--Ymqszjv54*. Dengan pendekatan ini, seluruh klip yang berasal dari *group_id* yang sama ditempatkan pada subset yang sama, sehingga tidak ada *group_id* yang tersebar ke *train*, *validation*, dan *test* secara bersamaan. Karena *group_id* dibentuk dari awalan *clip_id*, pembagian ini lebih tepat dipahami sebagai *group-disjoint split*, bukan verifikasi *group-disjoint strict split* secara eksplisit. Target pembagian ditetapkan mengikuti rasio 3:1:1 pada level grup, atau sekitar 60% untuk *train*, 20% untuk *validation*, dan 20% untuk *test*.

Agar pembagian tetap seimbang dari sisi metadata demografis, beberapa kandidat strata diuji sebelum *split* akhir ditetapkan. Evaluasi kandidat strata mempertimbangkan jumlah strata, ukuran minimum, median, maksimum, serta jumlah strata yang terlalu kecil. Strata yang terlalu kecil dapat membuat pembagian 3:1:1 tidak stabil karena kombinasi kategori tertentu tidak memiliki jumlah grup yang memadai untuk didistribusikan ke tiga subset. Hasil evaluasi kandidat strata ditunjukkan pada Tabel 4.13.

Tabel 4.13 Ringkasan kandidat strata utama untuk pembentukan strict split

Kandidat strata	Jumlah strata	Ukuran minimum strata	Strata < 3 grup	Strata < 5 grup	Keputusan
gender ethnicity	6	33	0	0	Dipilih
gender avg_bin	10	159	0	0	Tidak dipilih karena tidak mempertimbangkan ethnicity
ethnicity avg_bin	15	14	0	0	Tidak dipilih karena tidak mempertimbangkan gender
gender ethnicity avg_bin	30	2	1	2	Terlalu granular
gender ethnicity age avg_bin	138	1	38	60	Terlalu banyak strata kecil

Berdasarkan hasil pada Tabel 4.13, strata *gender|ethnicity* dipilih sebagai dasar pembentukan *strict split* karena memiliki jumlah strata yang masih sederhana, ukuran minimum strata yang memadai, serta tidak menghasilkan strata dengan jumlah grup kurang dari tiga maupun kurang dari lima. Kombinasi ini juga tetap mempertahankan dua metadata demografis utama yang relevan untuk menjaga keseimbangan pembagian. Kandidat strata yang lebih granular, seperti *gender|ethnicity|avg_bin* atau *gender|ethnicity|age|avg_bin*, tidak dipilih karena menghasilkan strata berukuran sangat kecil sehingga berisiko membuat pembagian 3:1:1 pada level *group_id* menjadi kurang stabil. Detail evaluasi seluruh kandidat strata disajikan pada Lampiran 22.

Hasil akhir pembagian *strict split* dengan stratifikasi *gender|ethnicity* ditunjukkan pada Tabel 4.14. Jumlah *group_id* dan jumlah klip pada masing-masing subset mendekati target rasio 3:1:1, baik pada level grup maupun level klip. Statistik tambahan mengenai jumlah klip per *group_id* pada *strict split* disajikan pada Lampiran 31 untuk memperlihatkan bahwa pembagian dilakukan pada level grup, sehingga proporsi jumlah klip dapat sedikit berbeda dari target 3:1:1.

Tabel 4.14 Ukuran strict split (3:1:1) pada level *group_id* dan klip

<i>Split</i>	Jumlah <i>group_id</i>	Proporsi <i>group_id</i>	Jumlah klip	Proporsi klip
<i>Train</i>	1.829	0,5989	5.936	0,5951
<i>Validation</i>	608	0,1991	1.999	0,2004
<i>Test</i>	617	0,2020	2.039	0,2044
<i>Total</i>	3.054	1,0000	9.974	1,0000

Validasi formal terhadap hasil pembagian menunjukkan bahwa seluruh *group_id* antar subset saling lepas, seluruh *clip_id* bersifat unik, rasio jumlah grup dan klip masih berada dalam toleransi yang ditetapkan, serta seluruh jalur *audio_out* valid dan tidak ada berkas audio yang

hilang. Hasil ini menunjukkan bahwa pembentukan *strict split* telah memenuhi syarat utama, yaitu menjaga independensi grup antar subset dan mempertahankan ukuran data yang mendekati rasio target.

Selain ukuran subset, distribusi demografis juga diperiksa pada level grup dan level klip. Metadata demografis pada dataset menggunakan pengkodean numerik, yaitu *gender* dengan nilai 1 dan 2 serta *ethnicity* dengan nilai 1, 2, dan 3. Pemeriksaan pada level grup menunjukkan proporsi *gender* dan *ethnicity* yang relatif konsisten antara *train*, *validation*, dan *test*, sebagaimana ditunjukkan pada Tabel 4.15.

Tabel 4.15 Distribusi *gender* dan *ethnicity* per *split* (proporsi group-level)

<i>Split</i>	<i>Gender=1</i>	<i>Gender=2</i>	<i>Ethnicity=1</i>	<i>Ethnicity=2</i>	<i>Ethnicity=3</i>
<i>Train</i>	0,4297	0,5703	0,0350	0,8578	0,1072
<i>Validation</i>	0,4293	0,5707	0,0345	0,8602	0,1053
<i>Test</i>	0,4311	0,5689	0,0389	0,8509	0,1102

Pemeriksaan tambahan pada level klip juga menunjukkan pola distribusi yang searah. Proporsi *gender* dan *ethnicity* pada level klip tidak menunjukkan pergeseran besar antar subset, sehingga data hasil *strict split* tetap dapat digunakan untuk evaluasi yang lebih adil terhadap model. Ringkasan distribusi pada level klip disajikan pada Tabel 4.16.

Selain distribusi demografis, distribusi label *Big Five* pada *train*, *validation*, dan *test* strict juga diperiksa untuk memastikan bahwa pembagian berbasis *group_id* tidak menghasilkan pergeseran target yang terlalu besar antar subset. Pemeriksaan dilakukan terhadap lima *trait* utama serta *avg_trait* sebagai ringkasan skor per klip. Hasil pemeriksaan menunjukkan bahwa distribusi label antar subset masih relatif searah, dengan selisih mean maksimum antar *split* berada pada kisaran sekitar 0,008 sampai 0,010. Dengan demikian, *strict split* tidak hanya memenuhi keterpisahan *group_id*, tetapi juga tetap layak digunakan untuk evaluasi regresi *Big Five*. Statistik lengkap distribusi label per *split* strict disajikan pada Lampiran 23, sedangkan ringkasan selisih mean label antar *split* disajikan pada Lampiran 29.

Tabel 4.16 Distribusi *gender* dan *ethnicity* per *split* (proporsi clip-level)

<i>Split</i>	<i>Gender=1</i>	<i>Gender=2</i>	<i>Ethnicity=1</i>	<i>Ethnicity=2</i>	<i>Ethnicity=3</i>
<i>Train</i>	0,4510	0,5490	0,0313	0,8587	0,1100
<i>Validation</i>	0,4627	0,5373	0,0320	0,8684	0,0996
<i>Test</i>	0,4571	0,5429	0,0373	0,8568	0,1059

Keluaran akhir dari tahap praproses dan pembentukan *strict split* terdiri dari folder audio final *output/preprocessing/preprocessed_full*, laporan *VAD* berupa *vad_report.csv*, daftar *drop final* berupa *vad_drop.csv* dengan 26 klip, pemetaan grup *group_split_strict.csv*, serta *manifest_strict.csv* yang memuat 9.974 klip beserta jalur *audio_out*, label *Big Five*, metadata, dan penanda *split_strict*. Seluruh artefak tersebut menjadi masukan langsung untuk eksperimen *baseline* pada *official split* dan *strict split*, serta untuk tahap *fine-tuning* menggunakan LoRA pada subbab berikutnya.

Perbandingan tambahan antara *official split* setelah *VAD drop* dan *strict split* disajikan pada Lampiran 24. Pemeriksaan *overlap group_id* secara tabular disajikan pada Lampiran 25. Visualisasi heatmap *overlap group_id* pada *official split* dan *strict split* masing-masing disajikan pada Lampiran 26 dan Lampiran 27. Hasil tersebut menunjukkan bahwa *official split* masih memiliki *group_id* yang muncul pada lebih dari satu subset, sedangkan *strict split* menghasilkan *overlap* nol antar *train*, *validation*, dan *test*. Distribusi demografis lengkap pada *official split* dan *strict split* disediakan pada Lampiran 28 dalam berkas spreadsheet pendukung. Temuan ini digunakan sebagai dasar empiris bahwa pembentukan *strict split* diperlukan untuk mengurangi potensi ketergantungan sumber antar subset, tanpa mengklaim bahwa seluruh bentuk bias pada data telah hilang sepenuhnya.

4.1.3 Hasil Baseline pada Official Split

Subbab ini menyajikan hasil eksperimen *baseline* pada *official split* setelah tahap *quality control* berbasis *VAD drop final*. Pelaporan pada *official split* tetap diperlukan karena pembagian ini merupakan protokol resmi dataset *ChaLearn First Impressions V2* dan banyak digunakan sebagai acuan pembandingan pada penelitian terdahulu. Namun, hasil pada subbab ini tidak diposisikan sebagai satu-satunya ukuran generalisasi utama penelitian. *Official split* digunakan sebagai *baseline* awal dan pembandingan literatur, sedangkan evaluasi yang lebih konservatif melalui *strict split* dibahas pada subbab berikutnya.

Setelah 26 klip yang memiliki kandungan ujaran terlalu rendah dikeluarkan, jumlah data *official split* yang digunakan dalam eksperimen *baseline* menjadi 9.974 klip. Komposisi data tersebut tetap mengikuti struktur *train*, *validation*, dan *test* dari *official split*, tetapi jumlahnya sedikit berkurang dari pembagian awal karena sebagian sampel tidak memenuhi kriteria kualitas ujaran. Ringkasan komposisi data ditunjukkan pada Tabel 4.17.

Tabel 4.17 Komposisi data pada *official split* setelah *VAD drop*

<i>Split</i>	Jumlah sampel (klip)
<i>Train</i>	5.988
<i>Validation</i>	1.994
<i>Test</i>	1.992
Total	9.974

Eksperimen *baseline* membandingkan empat representasi audio, yaitu wav2vec2, HuBERT, WavLM, dan eGeMAPS. wav2vec2, HuBERT, dan WavLM diperlakukan sebagai representasi *embedding* SSL dari model speech pralatih, sedangkan eGeMAPS diposisikan sebagai *baseline handcrafted acoustic features*. Pembandingan ini penting karena eGeMAPS merepresentasikan pendekatan fitur akustik yang lebih eksplisit dan terdesain manual, sedangkan *embedding* SSL merepresentasikan pendekatan modern yang memanfaatkan representasi pralatih dari data ujaran berskala besar. Dimensi fitur tiap metode ditunjukkan pada Tabel 4.18.

Tabel 4.18 Ringkasan dimensi fitur tiap metode pada *official split*

Metode	Jenis fitur	Dimensi fitur	Keterangan
wav2vec2	SSL embedding	768	embedding per klip
HuBERT	SSL embedding	768	embedding per klip
WavLM	SSL embedding	768	embedding per klip
eGeMAPS	handcrafted	88	fitur eGeMAPS tanpa clip_id

Pada eksperimen *baseline* ini, model memprediksi lima *trait Big Five*, yaitu *Extraversion*, *Neuroticism*, *Agreeableness*, *Conscientiousness*, dan *Openness*, secara multi-output menggunakan *Ridge Regression*. *Ridge Regression* dipilih sebagai *baseline* karena model ini memberikan pemetaan linear yang sederhana, stabil, dan memiliki regularisasi L2 untuk mengurangi sensitivitas koefisien terhadap fitur yang saling berkorelasi. Dengan demikian, perbandingan antar representasi dapat lebih berfokus pada kualitas fitur atau *embedding*, bukan pada kompleksitas model prediksi yang terlalu tinggi.

Sebelum *Ridge Regression* dilatih, fitur distandarisasi menggunakan *StandardScaler*. Proses *fitting StandardScaler* hanya dilakukan pada *training set*, kemudian parameter rata-rata dan simpangan baku yang sama digunakan untuk mentransformasi *validation set* dan *test set*. Prosedur ini penting untuk mencegah *data leakage*, karena informasi statistik dari *validation* maupun *test* tidak boleh ikut membentuk transformasi fitur yang digunakan pada tahap pelatihan. Setelah standarisasi, setiap kandidat alpha diuji dengan melatih model pada *training set* dan mengevaluasinya pada *validation set*. Alpha terbaik dipilih berdasarkan mean *MAE validation*, sedangkan *test set* hanya digunakan untuk evaluasi akhir setelah alpha ditetapkan.

Nilai alpha pada *Ridge* mengatur kekuatan regularisasi L2. Alpha yang terlalu kecil membuat regularisasi lemah sehingga model berpotensi terlalu mengikuti variasi pada *training set*, sedangkan alpha yang terlalu besar dapat membuat koefisien terlalu tertekan dan model menjadi terlalu sederhana. Oleh karena itu, eksperimen ini menggunakan rentang alpha yang luas, yaitu 0.001, 0.003, 0.01, 0.03, 0.1, 0.3, 1, 3, 10, 30, 100, 300, 1000, 3000, 10000, 30000, dan 100000. Rentang tersebut digunakan agar titik optimal regularisasi dan efek penurunan kinerja pada regularisasi yang terlalu kuat dapat diamati secara eksplisit.

Ringkasan pada Tabel 4.19 menunjukkan bahwa WavLM dan HuBERT memperoleh mean *MAE validation* terbaik pada $\alpha=1000$, sedangkan wav2vec2 dan eGeMAPS memperoleh mean *MAE validation* terbaik pada $\alpha=100$. Karena alpha terbaik tidak berada pada ujung kanan grid, hasil ini menunjukkan bahwa penambahan regularisasi tidak selalu memperbaiki kinerja. Setelah melewati titik tertentu, *validation MAE* cenderung meningkat kembali, terutama pada alpha yang sangat besar. Pola alpha sweep tersebut divisualisasikan pada Gambar 4.6. Rincian lengkap alpha sweep disajikan pada Lampiran 15, sedangkan grafik best alpha dan perbandingan metrik *validation* dapat dirujuk pada Lampiran 16 dan Lampiran 17.

Untuk melengkapi evaluasi *baseline Ridge Regression*, eksperimen ini juga menyertakan kurva galat *train-validation* berbasis *MAE* terhadap variasi nilai alpha. Kurva ini digunakan sebagai


bentuk diagnosis terhadap pengaruh regularisasi, karena *Ridge Regression* tidak dilatih secara epoch-based seperti neural network dan tidak menghasilkan riwayat *loss per epoch*. Oleh sebab itu, visualisasi yang digunakan pada *baseline Ridge* tidak ditafsirkan sebagai *loss per epoch*, melainkan sebagai perubahan galat *training* dan *validation* pada setiap nilai alpha yang diuji. Setiap titik pada kurva merepresentasikan satu model *Ridge* yang dilatih dengan konfigurasi alpha tertentu, kemudian dievaluasi pada *training set* dan *validation set*.

Melalui kurva tersebut, kecenderungan *overfitting* dan *underfitting* dapat dianalisis dari hubungan antara *train MAE*, *validation MAE*, dan besar regularisasi. Pada alpha yang terlalu kecil, regularisasi masih lemah sehingga model berpotensi terlalu menyesuaikan diri terhadap data *training*, terutama apabila *train MAE* jauh lebih rendah daripada *validation MAE*. Sebaliknya, alpha yang terlalu besar dapat membuat model terlalu sederhana karena regularisasi menekan koefisien secara berlebihan. Kondisi ini tercermin ketika *train MAE* dan *validation MAE* sama-sama meningkat. Dengan demikian, alpha terbaik dipilih sebagai titik kompromi berdasarkan mean *MAE* terendah pada *validation set*, sementara *test set* hanya digunakan untuk evaluasi akhir setelah proses pemilihan alpha selesai.

Dengan demikian, alpha terbaik dipilih sebagai titik kompromi berdasarkan mean *MAE* terendah pada *validation set*, sementara *test set* hanya digunakan untuk evaluasi akhir setelah proses pemilihan alpha selesai. Ringkasan nilai *train MAE*, *validation MAE*, dan gap *validation–train* pada alpha terpilih untuk setiap metode disajikan pada Tabel 4.20. Tabel ini digunakan untuk memperjelas apakah konfigurasi alpha terbaik menunjukkan indikasi *overfitting* atau *underfitting* pada *baseline Ridge Regression*.

Tabel 4.19 Ringkasan hasil tuning alpha berdasarkan mean MAE validation

Metode	<i>Best alpha</i>	<i>Best val MAE</i>	<i>Best val Acc (1–MAE)</i>	<i>Best val RMSE</i>	<i>Best val R²</i>	Catatan titik balik
WavLM	1000	0.094497	0.905503	0.118895	0.318673	Optimal alpha=1000, setelahnya MAE naik.
HuBERT	1000	0.095947	0.904053	0.120795	0.297344	Optimal alpha=1000, setelahnya MAE naik.
wav2vec2	100	0.097613	0.902387	0.122423	0.278639	Optimal alpha=100, >100 MAE naik.
eGeMAPS	100	0.103167	0.896833	0.130353	0.185565	Optimal alpha=100, >100 tidak membaik.




Gambar 4.6 Perbandingan mean MAE validation terhadap nilai alpha pada baseline official split

Tabel 4.20 Ringkasan diagnostik *train-validation* MAE pada alpha terpilih

Metode	Alpha terpilih	Train MAE	Validation MAE	Gap validation–train	Interpretasi ringkas
WavLM	1000	0.092533	0.094497	0.001965	Gap kecil, kompromi validation terbaik.
HuBERT	1000	0.092903	0.095947	0.003044	Gap berkurang setelah regularisasi, alpha kecil memiliki gap lebih besar.
wav2vec2	100	0.091811	0.097613	0.005802	Gap berkurang setelah regularisasi, alpha kecil memiliki gap lebih besar.
eGeMAPS	100	0.103690	0.103167	-0.000523	Gap sangat kecil, keterbatasan lebih dominan pada daya representasi.

Pada alpha terpilih, WavLM memiliki *train MAE* 0.092533 dan *validation MAE* 0.094497, sehingga gap *validation–train* sebesar 0.001964. HuBERT memiliki gap 0.003044, wav2vec2 memiliki gap 0.005802, sedangkan eGeMAPS memiliki *validation MAE* yang sedikit lebih

rendah daripada *train MAE*. Pola ini tidak menunjukkan *overfitting* berat pada alpha terpilih. Pada sisi lain, hasil alpha sweep menunjukkan bahwa alpha yang sangat besar membuat *train* dan *validation MAE* sama-sama meningkat, sehingga regularisasi yang terlalu kuat dapat menimbulkan *underfitting*. Kurva diagnostik WavLM sebagai model terbaik ditunjukkan pada Gambar 4.7, sedangkan kurva lengkap untuk metode lain disajikan pada Lampiran 32 sampai Lampiran 34.



Gambar 4.7 Kurva *train MAE* dan *validation MAE Ridge Regression* terhadap nilai alpha pada *baseline official split* untuk WavLM

Ringkasan hasil evaluasi pada *validation set* ditunjukkan pada Tabel 4.21. Hasil *validation* digunakan untuk memilih konfigurasi dan memeriksa urutan awal kinerja antar metode sebelum *test set* dibuka untuk evaluasi akhir.

Tabel 4.21 Hasil baseline official split pada validation set (mean lima trait)

Metode	Acc(1-MAE)	MAE	RMSE	R ²
WavLM	0.905503	0.094497	0.118895	0.318673
HuBERT	0.904053	0.095947	0.120795	0.297344
wav2vec2	0.902387	0.097613	0.122423	0.278639
eGeMAPS	0.896833	0.103167	0.130353	0.185565

Berdasarkan Tabel 4.21, WavLM memperoleh kinerja *validation* terbaik dengan Acc(1-MAE) sebesar 0.905503, MAE sebesar 0.094497, RMSE sebesar 0.118895, dan R² sebesar 0.318673. HuBERT berada pada posisi kedua, diikuti oleh wav2vec2 dan eGeMAPS. Hasil ini menunjukkan bahwa *embedding SSL* cenderung lebih kuat daripada fitur *handcrafted* pada

validation set, tetapi keputusan akhir tetap perlu dikonfirmasi pada *test set* setelah alpha terbaik ditentukan dari *validation set*.

Hasil evaluasi pada *test set* disajikan pada Tabel 4.22. *Test set* hanya digunakan pada tahap akhir sehingga tidak memengaruhi pemilihan alpha. Dengan demikian, hasil pada *test set* dapat dibaca sebagai evaluasi akhir *baseline official split* untuk konfigurasi yang telah dipilih melalui *validation set*.


Tabel 4.22 Hasil baseline official split pada test set (mean lima trait)

Metode	Acc(1-MAE)	MAE	RMSE	R ²
WavLM	0.903623	0.096377	0.120835	0.313054
HuBERT	0.902526	0.097474	0.121944	0.300851
wav2vec2	0.901239	0.098761	0.123295	0.285255
eGeMAPS	0.895163	0.104837	0.131557	0.188670

Pola pada *test set* konsisten dengan hasil *validation set*. WavLM menjadi metode terbaik secara agregat dengan Acc(1-MAE) sebesar 0.903623, MAE sebesar 0.096377, RMSE sebesar 0.120835, dan R² sebesar 0.313054. HuBERT berada pada posisi kedua, wav2vec2 pada posisi ketiga, dan eGeMAPS menghasilkan kinerja terendah. Urutan ini juga terlihat pada ranking metode berdasarkan *test set* yang dapat dirujuk pada Lampiran 18. Perbandingan visual keempat metrik tersebut disajikan pada Gambar 4.8, yang menunjukkan bahwa WavLM memiliki Acc(1-MAE) dan R² tertinggi, sekaligus MAE dan RMSE terendah dibandingkan metode lain.

Keunggulan WavLM pada *baseline official split* dapat dijelaskan secara konseptual dari karakter representasinya. WavLM merupakan model speech pralatih yang dirancang untuk menangkap representasi ujaran yang lebih umum dan robust melalui data pralatih berskala besar serta *objective denoising/overlapped speech*. Pada tugas *audio-only apparent personality*, informasi yang relevan tidak hanya berupa isi ujaran, tetapi juga pola paralinguistik seperti intonasi, dinamika suara, dan karakteristik temporal. Representasi SSL memiliki peluang lebih besar untuk membawa informasi tersebut dalam *embedding* berdimensi 768, sedangkan eGeMAPS hanya merangkum seperangkat fitur akustik *handcrafted* berdimensi 88. Oleh karena itu, eGeMAPS tetap penting sebagai *baseline* interpretatif, tetapi kinerjanya lebih rendah dibandingkan *embedding* SSL pada eksperimen ini.

Nilai Acc(1-MAE) perlu dibaca secara hati-hati. Metrik ini bukan akurasi klasifikasi, melainkan transformasi langsung dari MAE pada target yang berada dalam rentang 0 sampai 1. Sebagai contoh, ketika MAE WavLM pada *test set* sebesar 0.096377, nilai Acc(1-MAE) otomatis menjadi 0.903623. Dengan demikian, angka Acc(1-MAE) yang tampak tinggi tidak boleh ditafsirkan sebagai model benar pada sekitar 90% kelas, melainkan sebagai indikasi bahwa rata-rata error absolut berada di sekitar 0.096 pada skala label 0 sampai 1. Oleh karena itu, Acc(1-MAE) harus dibaca bersama MAE, RMSE, dan R².



Gambar 4.8 Perbandingan metrik rata-rata antar metode pada test set official split

Meskipun MAE relatif kecil dan $Acc(1-MAE)$ tinggi, nilai R^2 pada *baseline official split* masih berada pada rentang terbatas. R^2 mengukur proporsi variasi target yang dapat dijelaskan oleh model relatif terhadap prediktor rata-rata. Pada WavLM, R^2 test sebesar 0.313054 menunjukkan bahwa model mampu menangkap sebagian variasi target, tetapi belum menjelaskan seluruh variasi penilaian *Big Five*. Kondisi ini wajar pada tugas *apparent personality* karena label berasal dari persepsi manusia, bersifat subjektif, dan dapat mengandung *noise* anotasi. Selain itu, distribusi label yang cenderung berada di area tengah membuat prediksi yang mendekati pusat distribusi dapat menghasilkan MAE yang cukup kecil, tetapi tetap menghasilkan R^2 yang tidak terlalu tinggi apabila variasi antar sampel belum tertangkap dengan kuat.

Diagnosis variasi prediksi mendukung interpretasi tersebut. Pada *test set* WavLM, simpangan baku prediksi lebih kecil daripada simpangan baku target pada seluruh *trait*. Rasio $pred_std$ terhadap $target_std$ adalah sekitar 0.618 pada *Extraversion*, 0.605 pada *Neuroticism*, 0.490 pada *Agreeableness*, 0.620 pada *Conscientiousness*, dan 0.595 pada *Openness*. Pola ini menunjukkan kecenderungan prediksi yang lebih sempit daripada distribusi target atau *regression toward the mean*. Kecenderungan ini bukan berarti model gagal, tetapi menjelaskan mengapa MAE dapat terlihat cukup baik sementara R^2 masih terbatas. Detail diagnosis variasi prediksi WavLM disajikan pada Lampiran 20 dan perbandingan simpangan baku target-prediksi pada Lampiran 21.

Analisis per-*trait* dilakukan untuk melihat apakah kinerja agregat tersebut merata pada kelima dimensi *Big Five*. Tabel 4.23 menyajikan MAE per *trait* pada *test set official split*. Berdasarkan

MAE, WavLM menjadi metode terbaik pada *Extraversion*, *Neuroticism*, *Conscientiousness*, dan *Openness*. Pada *Agreeableness*, HuBERT sedikit lebih baik daripada WavLM, tetapi selisihnya hanya 0.000012, sehingga perbedaan tersebut sebaiknya ditafsirkan sebagai keunggulan tipis, bukan perbedaan substantif yang besar. Ringkasan pemenang per-*trait* dapat dirujuk pada Lampiran 19. Pola perbedaan MAE antar metode pada setiap *trait* tersebut dapat dilihat lebih jelas melalui visualisasi pada Gambar 4.9.


Tabel 4.23 Per-*trait* MAE pada test set official split

<i>Trait</i>	WavLM	HuBERT	wav2vec2	eGeMAPS
<i>Extraversion</i>	0.097651	0.099172	0.100141	0.107184
<i>Neuroticism</i>	0.096976	0.099146	0.099690	0.106512
<i>Agreeableness</i>	0.095209	0.095197	0.096750	0.098986
<i>Conscientiousness</i>	0.097242	0.098900	0.099916	0.110650
<i>Openness</i>	0.094807	0.094956	0.097308	0.100855

Tabel 4.24 dan Gambar 4.10 menunjukkan nilai R^2 per *trait* pada *test set*. Pada WavLM, nilai R^2 tertinggi terdapat pada *Neuroticism* sebesar 0.355580, diikuti oleh *Conscientiousness* sebesar 0.350883, *Extraversion* sebesar 0.339560, *Openness* sebesar 0.325928, dan *Agreeableness* sebesar 0.193316. Dengan demikian, *Agreeableness* tampak sebagai *trait* yang paling sulit dijelaskan oleh sinyal audio pada *baseline official split*, meskipun *MAE* absolut pada *trait* tersebut tidak selalu menjadi yang paling besar.

Kesulitan pada *Agreeableness* dapat dibaca dari dua sisi. Pertama, nilai R^2 *Agreeableness* pada seluruh metode lebih rendah dibandingkan sebagian besar *trait* lain, sehingga variasi target pada *trait* ini lebih sulit dijelaskan oleh representasi audio. Kedua, diagnosis WavLM menunjukkan rasio simpangan baku prediksi terhadap target pada *Agreeableness* hanya sekitar 0.490, lebih rendah dibandingkan *trait* lain. Artinya, prediksi *Agreeableness* paling kuat mengalami penyempitan variasi menuju pusat distribusi. Interpretasi ini perlu disampaikan secara hati-hati: hasil tersebut tidak membuktikan bahwa sinyal audio tidak relevan untuk *Agreeableness*, tetapi menunjukkan bahwa pada konfigurasi *baseline official split*, variasi *Agreeableness* lebih sulit ditangkap dibandingkan *trait* lain.


Berdasarkan keseluruhan hasil, WavLM menjadi *baseline* terbaik pada *official split* baik pada *validation set* maupun *test set*. Seluruh *embedding* SSL juga secara konsisten mengungguli eGeMAPS pada metrik agregat. Namun, *official split* tetap diposisikan sebagai acuan awal dan pembanding dengan literatur, bukan sebagai klaim utama generalisasi. Hasil ini kemudian digunakan sebagai dasar pembanding ketika *baseline* yang sama dievaluasi pada *strict split* pada Subbab 4.1.4, sehingga dampak protokol pembagian data terhadap kinerja model dapat dianalisis secara lebih terkontrol.



Gambar 4.9 Perbandingan MAE per-trait pada test set official split

Tabel 4.24 Per-trait R^2 pada test set official split

<i>Trait</i>	WavLM	HuBERT	wav2vec2	eGeMAPS
<i>Extraversion</i>	0.339560	0.317287	0.308226	0.173403
<i>Neuroticism</i>	0.355580	0.336162	0.328178	0.233508
<i>Agreeableness</i>	0.193316	0.185865	0.175170	0.118461
<i>Conscientiousness</i>	0.350883	0.336355	0.327717	0.179500
<i>Openness</i>	0.325928	0.328589	0.286984	0.238480



Gambar 4.10 Perbandingan R^2 per-trait pada test set official split

4.1.4 Hasil *Baseline* pada *Strict Split*

Subbab ini menyajikan hasil *baseline* pada *strict split* setelah tahap praproses dan *VAD drop final*. Konfigurasi eksperimen mengikuti *baseline* pada *official split*, yaitu membandingkan representasi wav2vec2, HuBERT, WavLM, dan eGeMAPS menggunakan *Ridge Regression* multi-output. Perbedaannya, data *train*, *validation*, dan *test* pada bagian ini mengikuti *strict split* berbasis *group_id*, sehingga *group_id* pada ketiga subset dibuat saling lepas. Dengan demikian, evaluasi *strict split* digunakan sebagai pengujian generalisasi yang lebih konservatif karena model tidak lagi berhadapan dengan *group_id* yang sama antar subset.

Karena mekanisme umum *Ridge Regression*, *StandardScaler*, metrik *MAE*, *RMSE*, R^2 , dan $\text{Acc}(1-\text{MAE})$ telah dijelaskan pada Subbab 4.1.3, bagian ini tidak mengulang seluruh penjelasan metodologis tersebut. Penekanan pembahasan diarahkan pada perubahan protokol *split*, hasil *tuning* alpha pada *validation set* strict, kinerja *validation* dan *test*, serta pola per-*trait* yang menjadi dasar pemilihan *backbone* untuk tahap *fine-tuning*.

Tabel 4.25 Komposisi data pada strict split setelah VAD drop final

<i>Split</i>	Jumlah <i>group_id</i>	Jumlah klip
<i>Train</i>	1.829	5.936
<i>Validation</i>	608	1.999
<i>Test</i>	617	2.039
<i>Total</i>	3.054	9.974

Berdasarkan Tabel 4.25, Setelah 26 klip dengan kandungan ujaran terlalu rendah dikeluarkan, *strict split* memuat 9.974 klip dari 3.054 *group_id*. Pembagian data pada level *group_id* menghasilkan 1.829 *group_id* dan 5.936 klip pada *train*, 608 *group_id* dan 1.999 klip pada *validation*, serta 617 *group_id* dan 2.039 klip pada *test*. Karena unit pembagiannya adalah *group_id* yang dibentuk dari awalan *clip_id*, protokol ini lebih tepat disebut sebagai *group-disjoint split*. Dengan kata lain, *strict split* mengurangi potensi ketergantungan sumber antar subset, tetapi tidak diklaim sebagai verifikasi identitas pembicara yang sepenuhnya *group-disjoint strict split*.

Tabel 4.26 Ringkasan representasi data pada baseline strict split

Metode	Jenis representasi	Dimensi	Keterangan
wav2vec2	SSL embedding	768	embedding per klip
HuBERT	SSL embedding	768	embedding per klip
WavLM	SSL embedding	768	embedding per klip
eGeMAPS	handcrafted	88	fitur akustik eGeMAPS

Tabel 4.26 merangkum empat representasi data yang digunakan pada *baseline strict split*, yaitu wav2vec2, HuBERT, WavLM, dan eGeMAPS. Empat representasi tersebut digunakan untuk membandingkan pendekatan fitur akustik *handcrafted* dengan *embedding* dari model speech pralatih. Seluruh representasi diperlakukan dalam skema *frozen feature extraction*, kemudian dipetakan ke lima *trait Big Five* menggunakan *Ridge Regression* multi-output. Pemilihan alpha dilakukan hanya berdasarkan mean *MAE* pada *validation set*. *Test set* tidak digunakan untuk memilih alpha, melainkan hanya dibuka setelah konfigurasi alpha terpilih ditetapkan.


Tabel 4.27 Hasil *tuning* alpha *strict split* berdasarkan mean *MAE validation*

Metode	Best alpha	Best MAE val	Best Acc(1-MAE) val	Best RMSE val	Best val R ²
WavLM	3.000	0,097582	0,902418	0,122693	0,283911
HuBERT	3.000	0,098642	0,901358	0,124451	0,263530
wav2vec2	1.000	0,101230	0,898770	0,127404	0,228406
eGeMAPS	300	0,105965	0,894035	0,133390	0,156003

Hasil *tuning* alpha pada Tabel 4.27 menunjukkan bahwa WavLM dan HuBERT mencapai mean *MAE validation* terbaik pada alpha 3.000, wav2vec2 pada alpha 1.000, dan eGeMAPS pada alpha 300. WavLM memperoleh *validation MAE* terendah sebesar 0,097582 dengan *R²* sebesar 0,283911. Pola ini menunjukkan bahwa representasi WavLM memberikan kompromi regularisasi terbaik pada *validation set* strict dibandingkan metode lain. Rincian lengkap alpha sweep untuk seluruh metode disajikan pada Lampiran 35.

Gambar 4.11 memperlihatkan perubahan mean *MAE validation* terhadap variasi alpha. Visualisasi ini digunakan untuk memastikan bahwa alpha terpilih berasal dari titik dengan galat validasi terendah, bukan dari evaluasi *test*. Pada nilai alpha yang terlalu besar, beberapa metode mulai menunjukkan kenaikan *validation MAE*. Hal ini mengindikasikan bahwa regularisasi yang terlalu kuat dapat membuat model terlalu sederhana dan kehilangan kemampuan menjelaskan variasi target.

Berdasarkan Tabel 4.28, gap antara *train MAE* dan *validation MAE* pada alpha terpilih masih relatif kecil untuk seluruh metode. *Ridge Regression* tidak menghasilkan *loss curve* per epoch karena model ini bukan neural network yang dilatih secara iteratif berbasis epoch. Oleh karena itu, grafik diagnostik yang digunakan pada *baseline Ridge* adalah kurva *train MAE* dan *validation MAE* terhadap variasi alpha. Setiap titik pada kurva merepresentasikan satu model *Ridge* dengan nilai alpha tertentu. Jika *train MAE* jauh lebih rendah daripada *validation MAE*, konfigurasi tersebut dapat mengarah pada *overfitting*. Sebaliknya, jika *train* dan *validation MAE* sama-sama meningkat pada alpha yang sangat besar, regularisasi dapat dianggap terlalu kuat dan mengarah pada *underfitting*.




Gambar 4.11 Perbandingan mean *MAE validation* terhadap nilai alpha pada *baseline strict split*

Tabel 4.28 Diagnostik *train-validation* MAE pada alpha terpilih *strict split*

Metode	Alpha terpilih	Train MAE	Validation MAE	Gap validation–train	Interpretasi ringkas
WavLM	3.000	0,092169	0,097582	0,005413	Gap kecil, tidak menunjukkan overfitting berat
HuBERT	3.000	0,092860	0,098642	0,005782	Gap kecil, tidak menunjukkan overfitting berat
wav2vec2	1.000	0,093541	0,101230	0,007690	Gap kecil, tidak menunjukkan overfitting berat
eGeMAPS	300	0,102901	0,105965	0,003064	Gap kecil, keterbatasan lebih tampak pada daya representasi

Pada alpha terpilih, WavLM memiliki *train MAE* 0,092169 dan *validation MAE* 0,097582, sehingga gap *validation–train* sebesar 0,005413. HuBERT memiliki gap 0,005782, wav2vec2 memiliki gap 0,007689, dan eGeMAPS memiliki gap 0,003064. Pola ini tidak menunjukkan *overfitting* berat pada alpha terpilih, meskipun wav2vec2 memiliki gap yang relatif lebih besar dibandingkan metode lain. Kurva diagnostik WavLM sebagai model terbaik ditunjukkan pada Gambar 4.12, dan disajikan lebih lengkap pada Lampiran 36, sedangkan kurva diagnostik untuk HuBERT, wav2vec2, dan eGeMAPS disajikan pada Lampiran 37, Lampiran 38, dan Lampiran 39.



Gambar 4.12 Kurva *train MAE* dan *validation MAE Ridge Regression* terhadap alpha pada *strict split* untuk WavLM

Tabel 4.29 Hasil *baseline strict split* pada *validation set* (mean lima *trait*)


Metode	Best Alpha	Acc(1–MAE)	MAE	RMSE	R ²
WavLM	3.000	0,902418	0,097582	0,122693	0,283911
HuBERT	3.000	0,901358	0,098642	0,124451	0,263530
wav2vec2	1.000	0,898770	0,101230	0,127404	0,228406
eGeMAPS	300	0,894035	0,105965	0,133390	0,156003

Hasil pada Tabel 4.29 menunjukkan bahwa WavLM menjadi metode terbaik pada *validation set* dengan Acc(1–MAE) 0,902418, MAE 0,097582, RMSE 0,122693, dan R² 0,283911. Urutan kinerja berikutnya adalah HuBERT, wav2vec2, dan eGeMAPS. Pola ini konsisten dengan hasil *official split*, yaitu *embedding* SSL lebih unggul daripada fitur *handcrafted* eGeMAPS.

Tabel 4.30 Hasil *baseline strict split* pada *test set* (mean lima *trait*)

Metode	Best Alpha	Acc(1-MAE)	MAE	RMSE	R ²
WavLM	3.000	0,900119	0,099881	0,126029	0,309102
HuBERT	3.000	0,898928	0,101072	0,127392	0,294469
wav2vec2	1.000	0,897850	0,102150	0,128440	0,282504
eGeMAPS	300	0,893506	0,106494	0,133659	0,224846


Evaluasi akhir pada Tabel 4.30 menunjukkan urutan kinerja yang sama pada *test set*. WavLM memperoleh *test MAE* terendah sebesar 0,099881, *Acc(1-MAE)* 0,900119, *RMSE* 0,126029, dan *R²* 0,309102. HuBERT berada pada posisi kedua dengan *test MAE* 0,101072 dan *R²* 0,294469, diikuti wav2vec2 dengan *test MAE* 0,102150 dan *R²* 0,282504. eGeMAPS memiliki kinerja paling rendah dengan *test MAE* 0,106494 dan *R²* 0,224846. Perbandingan metrik rata-rata pada *test set* divisualisasikan pada Gambar 4.13.



Gambar 4.13 Perbandingan metrik rata-rata antar metode pada *test set strict split*

Tabel 4.31 Per-trait MAE pada test set strict split


<i>Trait</i>	WavLM	HuBERT	wav2vec2	eGeMAPS
<i>extraversion</i>	0,099199	0,101122	0,101671	0,106329
<i>neuroticism</i>	0,101920	0,102842	0,103282	0,108729
<i>agreeableness</i>	0,098583	0,098885	0,100712	0,101740
<i>conscientiousness</i>	0,102996	0,103863	0,105430	0,114569
<i>openness</i>	0,096710	0,098646	0,099653	0,101102



Gambar 4.14 Perbandingan MAE per-trait pada test set strict split

Tabel 4.32 Per-trait R^2 pada test set strict split

<i>Trait</i>	WavLM	HuBERT	wav2vec2	eGeMAPS
<i>extraversion</i>	0,346724	0,326025	0,320020	0,259314
<i>neuroticism</i>	0,344391	0,329242	0,330206	0,264346
<i>agreeableness</i>	0,194475	0,187374	0,166387	0,142374
<i>conscientiousness</i>	0,332724	0,317764	0,293185	0,195708
<i>openness</i>	0,327196	0,311941	0,302722	0,262490



Gambar 4.15 Perbandingan R^2 per-trait pada *test set strict split*

Berdasarkan Tabel 4.31 dan Tabel 4.32, WavLM tidak hanya unggul pada rata-rata lima *trait*, tetapi juga memberikan *MAE* terendah dan R^2 tertinggi pada seluruh *trait test set* strict. Hasil perbandingan *MAE* per-trait pada *test set strict split* pada Tabel 4.31 divisualisasikan pada Gambar 4.14 agar perbedaan kesalahan prediksi antar metode pada setiap *trait* dapat diamati secara lebih jelas. *MAE* WavLM berada pada rentang 0,096710 sampai 0,102996. Nilai *MAE* terendah diperoleh pada *openness*, sedangkan nilai *MAE* tertinggi pada *conscientiousness*. Dari sisi R^2 , WavLM juga memperoleh nilai tertinggi pada seluruh *trait*, dengan R^2 sebesar 0,346724 pada *extraversion*, 0,344391 pada *neuroticism*, 0,194475 pada *agreeableness*, 0,332724 pada *conscientiousness*, dan 0,327196 pada *openness*. Selain *MAE*, perbandingan R^2 per-trait pada *test set strict split* juga divisualisasikan pada Gambar 4.15 untuk menunjukkan perbedaan kemampuan tiap metode dalam menjelaskan variasi label pada masing-masing *trait*. Tabel lengkap metrik per-trait *MAE* dan R^2 pada *test set strict split* disajikan pada Lampiran 40.

Trait yang paling sulit diprediksi pada *strict split* adalah *agreeableness* karena nilai R^2 WavLM pada *trait* tersebut hanya 0,194475, lebih rendah dibandingkan *trait* lain. Hal ini berarti prediksi untuk *agreeableness* masih menjelaskan variasi target dalam porsi yang lebih terbatas, walaupun *MAE*-nya tidak tampak paling buruk. Fenomena ini selaras dengan karakter label *Big Five* yang berada pada rentang 0 sampai 1 dan cenderung berpusat di area tengah. Pada kondisi tersebut, model dapat memperoleh *MAE* yang relatif kecil dengan memprediksi nilai yang dekat dengan pusat distribusi, tetapi prediksi tersebut belum tentu mampu menangkap variasi antar sampel secara kuat. Oleh karena itu, $\text{Acc}(1-\text{MAE})$ yang tinggi perlu dibaca bersama R^2 agar tidak memberi kesan bahwa model telah sepenuhnya memahami variasi kepribadian.

Berdasarkan hasil *baseline* pada *strict split*, WavLM menempati posisi terbaik pada skema *frozen embedding + Ridge*, sehingga model ini dipilih sebagai acuan utama pada tahap *fine-tuning* LoRA. Pemilihan ini didasarkan pada kinerja *validation set* strict, di mana WavLM memperoleh mean *MAE* terendah dibandingkan representasi lain. Hasil *test_strict* kemudian digunakan sebagai evaluasi akhir setelah konfigurasi *baseline* ditetapkan, dan hasilnya menunjukkan urutan kinerja yang tetap searah, yaitu WavLM berada di posisi terbaik, diikuti

HuBERT, wav2vec2, dan eGeMAPS. Dengan demikian, pemilihan WavLM tidak didasarkan pada pembacaan *test set*, tetapi pada prosedur seleksi berbasis validasi.

Meskipun demikian, HuBERT tetap relevan untuk dianalisis pada tahap lanjutan karena kinerjanya masih berada dalam kelompok *backbone* SSL yang kompetitif dan secara arsitektural berbeda dari WavLM. Dengan demikian, eksperimen LoRA pada HuBERT berfungsi sebagai pembanding untuk melihat apakah adaptasi *parameter-efficient* hanya menguntungkan *backbone* tertentu atau juga dapat meningkatkan *backbone* SSL lain pada protokol *strict split*.

4.1.5 Perbandingan *Official Split* dan *Strict Split*

Subbab ini membandingkan hasil *baseline* pada *official split* dan *strict split* untuk melihat perubahan kinerja ketika protokol pembagian data dibuat lebih ketat. *Official split* tetap dilaporkan karena merupakan pembagian resmi dataset dan penting sebagai acuan terhadap penelitian terdahulu. Namun, *strict split* digunakan sebagai dasar keputusan model final dalam penelitian ini karena pembagiannya menjaga *group_id* agar tidak tumpang tindih antar *train*, *validation*, dan *test*. Perbandingan pada subbab ini menggunakan hasil terbaik dari masing-masing metode pada setiap protokol *split*, dengan alpha dipilih berdasarkan mean *MAE validation* pada *split* terkait. Dengan demikian, perbandingan *official split* dan *strict split* tidak memaksakan nilai alpha yang sama, melainkan membandingkan kinerja terbaik yang diperoleh setiap metode setelah proses *tuning* pada masing-masing *split*.

Tabel 4.33 Komposisi data *official split* dan *strict split* setelah *VAD drop final*

<i>Split</i>	Train <i>group_id</i>	Train klip	Val <i>group_id</i>	Val klip	Test <i>group_id</i>	Test klip	Total klip
<i>Official</i>	Tidak digunakan sebagai unit split	5.988	Tidak digunakan sebagai unit split	1.994	Tidak digunakan sebagai unit split	1.992	9.974
<i>Strict</i>	1.829	5.936	608	1.999	617	2.039	9.974

Tabel 4.33 menunjukkan bahwa kedua protokol memakai jumlah total klip yang sama setelah *VAD drop final*, yaitu 9.974 klip. Perbedaannya terletak pada unit pembagian. *Official split* mengikuti pembagian resmi pada level sampel dataset, sedangkan *strict split* melakukan pembagian pada level *group_id*. Oleh karena itu, jumlah klip pada *train*, *validation*, dan *test* strict sedikit berbeda dari *official split* karena seluruh klip dari satu *group_id* harus ditempatkan pada subset yang sama.

Tabel 4.34 Perbandingan baseline pada validation set official vs strict

Metode	<i>Official</i> MAE	<i>Strict</i> MAE	Δ MAE	Official R²	Strict R²	Δ R²
WavLM	0,094497	0,097582	0,003085	0,318673	0,283911	-0,034762
HuBERT	0,095947	0,098642	0,002695	0,297344	0,263530	-0,033814

Metode	<i>Official</i> MAE	<i>Strict</i> MAE	Δ MAE	Official R^2	Strict R^2	ΔR^2
wav2vec2	0,097613	0,101230	0,003617	0,278639	0,228406	-0,050233
eGeMAPS	0,103167	0,105965	0,002798	0,185565	0,156003	-0,029562

Berdasarkan Tabel 4.34, pada *validation set*, seluruh metode mengalami kenaikan *MAE* ketika berpindah dari *official split* ke *strict split*. Kenaikan *MAE validation* terbesar terjadi pada wav2vec2 sebesar 0,003617, sedangkan yang terkecil pada HuBERT sebesar 0,002695. Dari sisi R^2 , seluruh metode juga mengalami penurunan pada *strict split*. Penurunan R^2 WavLM sebesar -0,034762, HuBERT sebesar -0,033814, wav2vec2 sebesar -0,050233, dan eGeMAPS sebesar -0,029563. Pola ini menunjukkan bahwa *validation strict* memberikan evaluasi yang lebih berat dibandingkan *validation official*. Tabel lengkap perbandingan *official split* dan *strict split* pada *validation set* dan *test set* disajikan pada Lampiran 41.

Tabel 4.35 Perbandingan *baseline* pada *test set* official vs strict

Metode	<i>Official</i> MAE	<i>Strict</i> MAE	Δ MAE	Official R^2	Strict R^2	ΔR^2
WavLM	0,096377	0,099881	0,003505	0,313054	0,309102	-0,003952
HuBERT	0,097474	0,101072	0,003598	0,300851	0,294469	-0,006382
wav2vec2	0,098761	0,102150	0,003389	0,285255	0,282504	-0,002751
eGeMAPS	0,104837	0,106494	0,001656	0,188670	0,224846	0,036176

Berdasarkan Tabel 4.35, pada *test set*, *MAE* strict juga lebih tinggi daripada official untuk seluruh metode. WavLM meningkat dari 0,096377 menjadi 0,099881, sehingga selisih strict minus official sebesar 0,003504. HuBERT meningkat sebesar 0,003598, wav2vec2 meningkat sebesar 0,003389, dan eGeMAPS meningkat sebesar 0,001657. Pada R^2 test, seluruh SSL mengalami penurunan kecil, sedangkan eGeMAPS justru meningkat. Perbedaan ini menunjukkan bahwa interpretasi kinerja tidak boleh hanya bergantung pada satu metrik, karena *MAE* mengukur besar galat absolut sedangkan R^2 dipengaruhi oleh variasi target pada subset evaluasi.

Tabel 4.36 Perbandingan per-trait WavLM pada *test set* official vs strict

Trait	<i>Official</i> MAE	<i>Strict</i> MAE	Δ MAE	Official R^2	Strict R^2	ΔR^2
<i>extraversion</i>	0,097651	0,099199	0,001549	0,339560	0,346724	0,007164
<i>neuroticism</i>	0,096976	0,101920	0,004944	0,355580	0,344391	-0,011189
<i>agreeableness</i>	0,095209	0,098583	0,003374	0,193316	0,194475	0,001159
<i>conscientiousness</i>	0,097242	0,102996	0,005754	0,350883	0,332724	-0,018160
<i>openness</i>	0,094807	0,096710	0,001903	0,325928	0,327196	0,001268

Perbandingan khusus WavLM pada Tabel 4.36 menunjukkan bahwa *MAE* strict lebih tinggi daripada official pada seluruh *trait*. Selisih *MAE* terbesar muncul pada *conscientiousness* sebesar 0,005754, sedangkan selisih terkecil muncul pada *extraversion* sebesar 0,001548. Dari sisi R^2 , *strict split* menghasilkan nilai yang lebih tinggi pada *extraversion*, *agreeableness*, dan *openness*, tetapi lebih rendah pada *neuroticism* dan *conscientiousness*. *Agreeableness* tetap menjadi *trait* dengan R^2 paling rendah pada kedua *split*, yaitu 0,193316 pada official dan 0,194475 pada strict. Pola ini memperkuat bahwa tantangan utama tidak hanya berasal dari protokol *split*, tetapi juga dari karakteristik *trait* dan kecenderungan prediksi regresi yang dapat mendekati pusat distribusi label. Tabel lengkap perbandingan per-*trait* WavLM pada *official split* dan *strict split* disajikan pada Lampiran 42.

Secara umum, *strict split* cenderung membuat *MAE* lebih tinggi dibandingkan *official split*. Hal ini wajar karena model tidak lagi terbantu oleh kedekatan *group_id* atau sumber antar subset. Pada *official split*, klip dari sumber yang sama masih berpotensi muncul di subset yang berbeda, sehingga model dapat memperoleh evaluasi yang lebih optimistik. Sebaliknya, *strict split* mengurangi potensi ketergantungan sumber tersebut dengan menempatkan seluruh klip dari *group_id* yang sama pada subset yang sama. Namun, hasil *strict split* tidak boleh ditafsirkan sebagai penghapusan seluruh bias, karena faktor lain seperti distribusi demografis, kondisi rekaman, variasi label, dan keterbatasan *group_id* tetap dapat memengaruhi evaluasi.

Official split tetap penting karena menjadi protokol resmi dataset dan memungkinkan hasil penelitian ini dibandingkan dengan studi terdahulu. Akan tetapi, *strict split* lebih sesuai dijadikan dasar pengambilan keputusan model final pada penelitian ini karena evaluasinya lebih konservatif terhadap ketergantungan sumber antar subset. Oleh karena itu, WavLM dan HuBERT pada *strict split* dipilih sebagai *baseline* utama untuk tahap berikutnya, yaitu *fine-tuning* menggunakan LoRA.

4.1.6 Hasil *Fine-Tuning* WavLM dengan LoRA

Subbab ini menyajikan hasil *fine-tuning* WavLM menggunakan LoRA pada *strict split*. WavLM dipilih sebagai eksperimen LoRA pertama karena menjadi *backbone frozen* terbaik pada *baseline strict split* dibandingkan wav2vec2, HuBERT, dan eGeMAPS. Dengan demikian, WavLM+LoRA digunakan untuk menjawab pertanyaan utama apakah adaptasi *parameter-efficient* mampu melampaui *baseline frozen embedding + Ridge* yang sudah kuat. Tahap adaptasi hanya dilakukan pada *strict split* agar evaluasi tetap mengikuti protokol pembagian data yang lebih konservatif. Data *test_strict* tidak digunakan dalam *hyperparameter tuning* maupun pemilihan checkpoint; seluruh keputusan model ditentukan dari *validation set* melalui skor $S = 1 - MAE_mean$.

Eksperimen ini terdiri atas pencarian hiperparameter menggunakan Optuna, pelatihan ulang pada 10 *final runs* dengan fixed distinct *seeds*, pemilihan *best-val run* dan *median run*, pembentukan *ensemble* prediksi, analisis per-*trait*, diagnostik *train loss* dan *validation loss* secara *post-hoc*, audit *strict split*, serta analisis sensitivitas konfigurasi LoRA berdasarkan hasil *tuning*. Analisis sensitivitas tersebut tidak diposisikan sebagai *ablation study* murni, karena beberapa hiperparameter berubah secara bersamaan pada setiap trial Optuna. Konfigurasi umum eksperimen disajikan pada Tabel 4.37.

Tabel 4.37 Konfigurasi umum fine-tuning WavLM dengan LoRA

Komponen	Nilai	Keterangan
<i>Backbone</i>	microsoft/wavlm-base-plus	Model pralatih utama yang diadaptasi
Protokol data	<i>train_strict</i> , <i>val_strict</i> , <i>test_strict</i>	<i>test_strict</i> dikunci sampai evaluasi akhir
Input audio	16 kHz, mono, maksimum 15 detik	Mengikuti format hasil praproses audio
<i>Loss training</i>	F.l1_loss(yhat, y, reduction="mean")	L1 loss/MAE pada lima trait
<i>Optimizer</i>	AdamW	Mengoptimasi parameter LoRA dan regression head
<i>Batch size</i>	40	Berdasarkan konfigurasi notebook utama
Maksimum epoch	100	Dibatasi oleh <i>early stopping</i>
<i>Early stopping patience</i>	5	Seleksi checkpoint berdasarkan val_S
<i>Gradient clipping</i>	1,0	Menstabilkan pembaruan gradien
<i>Target module</i> LoRA	q_proj dan v_proj	Backbone utama dibekukan
<i>Final seeds</i>	42, 52, 62, 72, 82, 92, 102, 112, 122, 132	Dipakai untuk final 10 runs

Konfigurasi pada Tabel 4.37 menunjukkan bahwa *fine-tuning* dilakukan sebagai adaptasi *parameter-efficient*. Parameter utama *backbone* WavLM dibekukan, sedangkan parameter yang dilatih terutama berasal dari *adapter* LoRA dan *regression head*. Dengan demikian, proses adaptasi lebih ringan dibandingkan *fine-tuning* penuh seluruh parameter *backbone*.

Ruang pencarian Optuna pada Tabel 4.38 mencakup hiperparameter optimisasi dan konfigurasi LoRA. Trial terbaik adalah *trial_028* dengan nomor Optuna 27 dan nilai *best validation S* sebesar 0,901935. Pemilihan menggunakan $S = 1 - MAE_mean$ karena objektif utama tugas ini adalah meminimalkan kesalahan absolut prediksi pada skala label 0 sampai 1. R^2 tetap dilaporkan sebagai metrik pelengkap untuk menilai kemampuan model menangkap variasi target, tetapi tidak digunakan untuk memilih *checkpoint*. Konfigurasi studi Optuna disajikan pada Lampiran 43, sedangkan riwayat lengkap trial Optuna disediakan pada Lampiran 44.

Tabel 4.38 Ruang pencarian Optuna dan konfigurasi terbaik

Parameter	Ruang pencarian	Nilai terbaik
learning_rate	5e-5 sampai 3e-4, log scale	0,000249056
r	{4, 8, 16}	8
lora_alpha	{16, 32, 64}	32
lora_dropout	{0,00; 0,05; 0,10; 0,15}	0,00
weight_decay	1e-4 sampai 2e-2, log scale	0,00127186
warmup_ratio	{0,00; 0,03; 0,05; 0,08; 0,10}	0,08
Jumlah trial	50	50
Pruner	MedianPruner	MedianPruner
Metrik seleksi	S = 1 - MAE_mean pada val_strict	Best validation S = 0,901935


Tabel 4.39 Lima trial terbaik pada hyperparameter tuning Optuna

Rank	Trial	val_S	LR	r	alpha	dropout	WD	warmup
1	trial_028	0,901935	0,000249056	8	32	0,00	0,00127186	0,08
2	trial_032	0,901934	0,000299807	4	64	0,15	0,00805072	0,03
3	trial_042	0,901932	0,000298400	4	64	0,15	0,00665009	0,03
4	trial_043	0,901919	0,000294537	4	64	0,15	0,00569648	0,03
5	trial_047	0,901909	0,000298007	4	64	0,05	0,00237471	0,00

Tabel 4.39 memperlihatkan bahwa nilai validasi pada lima trial terbaik sangat berdekatan, yaitu berada pada kisaran 0,901909 sampai 0,901935. Kedekatan nilai ini menunjukkan bahwa ruang konfigurasi terbaik tidak hanya terdiri dari satu titik tunggal, melainkan beberapa konfigurasi dapat mencapai kinerja validasi yang hampir sama. Grafik riwayat optimisasi pada Gambar 4.16 memperlihatkan bahwa peningkatan nilai terbaik terjadi relatif awal dan kemudian mendatar setelah trial terbaik ditemukan.

Optuna digunakan untuk mencari kombinasi hiperparameter terbaik, tetapi hasil pencarian ini tidak diperlakukan sebagai *ablation study* murni. *Ablation study* murni memerlukan eksperimen terkontrol dengan mengubah satu komponen atau satu parameter saja, sementara komponen lain dijaga tetap sama. Pada eksperimen ini, beberapa hiperparameter seperti *learning rate*, *rank* LoRA, *lora_alpha*, *lora_dropout*, *weight decay*, dan *warmup ratio* berubah secara bersamaan

pada setiap *trial*. Oleh karena itu, analisis pada bagian ini lebih tepat disebut sebagai analisis sensitivitas berbasis hasil *hyperparameter tuning*, bukan bukti kausal dari satu parameter tertentu. Ringkasan parameter yang dianalisis ditunjukkan pada Tabel 4.40.




Gambar 4.16 Riwayat optimisasi Optuna pada fine-tuning WavLM+LoRA

Tabel 4.40 Ringkasan parameter yang dianalisis pada sensitivitas hasil tuning Optuna

Aspek yang dianalisis	Dasar analisis	Status interpretasi
learning rate	Distribusi nilai val_S pada seluruh trial Optuna	Analisis sensitivitas, bukan ablasi murni
weight decay	Distribusi nilai val_S berdasarkan rentang weight decay	Analisis sensitivitas, bukan ablasi murni
rank LoRA (r)	Perbandingan val_S pada nilai r = 4, 8, dan 16 dalam trial Optuna	Analisis sensitivitas, bukan ablasi murni
lora_alpha	Perbandingan val_S pada nilai alpha yang diuji	Analisis sensitivitas, bukan ablasi murni
lora_dropout	Perbandingan val_S pada nilai dropout yang diuji	Analisis sensitivitas, bukan ablasi murni
warmup ratio	Perbandingan val_S pada nilai warmup ratio yang diuji	Analisis sensitivitas, bukan ablasi murni

Aspek yang dianalisis	Dasar analisis	Status interpretasi
Target module LoRA	Tidak diuji secara terpisah pada eksperimen ini	Tidak dilaporkan sebagai hasil ablasi

Parameter *importance* pada Gambar 4.17 menunjukkan bahwa *learning_rate* memiliki kontribusi *importance* paling besar pada studi Optuna WavLM+LoRA, diikuti oleh *warmup_ratio*, *lora_dropout*, dan *lora_alpha* dengan nilai yang jauh lebih kecil. Hasil ini menunjukkan bahwa konfigurasi WavLM+LoRA pada ruang pencarian yang diuji lebih sensitif terhadap parameter optimisasi, terutama *learning_rate*, dibandingkan parameter struktur LoRA seperti *r*. Meskipun demikian, hasil ini tidak dibaca sebagai bukti kausal tunggal karena setiap trial Optuna mengubah beberapa parameter sekaligus. Pembacaan yang lebih aman adalah bahwa performa WavLM+LoRA dipengaruhi oleh kombinasi hiperparameter dalam ruang pencarian yang diuji, dengan *learning_rate* menjadi parameter yang paling menonjol pada analisis sensitivitas tersebut. Riwayat lengkap trial Optuna disediakan pada Lampiran 44.



Gambar 4.17 Parameter importance pada studi Optuna WavLM+LoRA

Setelah konfigurasi terbaik Optuna ditetapkan, eksperimen final dijalankan sebanyak 10 kali menggunakan hiperparameter yang sama, tetapi dengan *seed* berbeda untuk mengevaluasi stabilitas hasil. Ringkasan agregat dari 10 *final runs* ditampilkan pada Tabel 4.41 yang mencakup skor validasi terbaik sebagai dasar seleksi checkpoint serta metrik evaluasi pada *test_strict* sebagai pelaporan akhir. Evaluasi pada *test_strict* hanya dilakukan setelah model pada setiap *run* dipilih berdasarkan kinerja validasi, sehingga hasil *test* tidak digunakan untuk proses *tuning* maupun pemilihan checkpoint. Hasil lengkap setiap *run* disajikan pada Lampiran 45.

Tabel 4.41 Ringkasan agregat final 10 runs WavLM+LoRA

Metrik	Mean	Std	Min	Max
best_val_S	0,901828	0,000094	0,901672	0,901935
test_MAE_mean	0,100275	0,000081	0,100157	0,100405
test_RMSE_mean	0,126627	0,000116	0,126471	0,126842
test_R2_mean	0,302657	0,001359	0,300112	0,304404
test_Acc_mean	0,899725	0,000081	0,899595	0,899843

Ringkasan pada Tabel 4.41 menunjukkan bahwa 10 *final runs* menghasilkan rata-rata *MAE* sebesar 0,100275 dengan simpangan baku 0,000081, serta rata-rata R^2 sebesar 0,302657 dengan simpangan baku 0,001359. Nilai simpangan baku yang kecil menunjukkan bahwa kinerja model relatif stabil antar *seed* pada konfigurasi hiperparameter yang sama.

Tabel 4.42 Perbandingan best-val run, median run, dan ensemble WavLM+LoRA

Pilihan	Identitas	Seed	best_val_S	MAE	RMSE	R ²	Acc
Best-val run	run_01_seed_042	42	0,901935	0,100190	0,126587	0,303067	0,899810
Median run	run_07_seed_102	102	0,901874	0,100253	0,126471	0,304404	0,899747
Ensemble mean 10 runs	ensemble_mean_10runs	-	-	0,100132	0,126450	0,304565	0,899868

Tabel 4.42 membedakan tiga bentuk pelaporan hasil WavLM+LoRA. *Best-val run* adalah *run_01_seed_042* dengan *seed* 42, *test_MAE_mean* 0,100190, dan *test_R2_mean* 0,303067. *Median run* adalah *run_07_seed_102* dengan *seed* 102, *test_MAE_mean* 0,100253, dan *test_R2_mean* 0,304404. *Ensemble* dari 10 *run* menghasilkan *test_MAE_mean* 0,100132 dan *test_R2_mean* 0,304565. Hasil *ensemble* digunakan sebagai analisis tambahan terhadap stabilitas prediksi karena diperoleh dari rata-rata prediksi beberapa *run*, sehingga tidak boleh diklaim sebagai satu model checkpoint. Oleh karena itu, hasil utama untuk pelaporan agregat tetap mengacu pada rerata final 10 runs pada Tabel 4.41, sedangkan *best-val run* digunakan ketika analisis membutuhkan satu checkpoint tunggal, misalnya untuk analisis per-*trait* dan visualisasi prediksi. Hasil metrik *ensemble* lengkap disajikan pada Lampiran 46.

Tabel 4.43 Perbandingan baseline strict terbaik dengan hasil WavLM+LoRA pada test_strict

Metode	MAE	RMSE	R ²	Acc	Delta MAE vs baseline	Delta R ² vs baseline
WavLM + Ridge strict baseline	0,099881	0,126029	0,309102	0,900119	0,000000	0,000000

Metode	MAE	RMSE	R ²	Acc	Delta MAE vs baseline	Delta R ² vs baseline
WavLM + LoRA rerata 10 runs	0,100275	0,126627	0,302657	0,899725	0,000394	-0,006445
WavLM + LoRA best-val run	0,100190	0,126587	0,303067	0,899810	0,000309	-0,006035
WavLM + LoRA median run	0,100253	0,126471	0,304404	0,899747	0,000372	-0,004698
WavLM + LoRA ensemble	0,100132	0,126450	0,304565	0,899868	0,000251	-0,004537


Perbandingan pada Tabel 4.43 menunjukkan bahwa hasil WavLM+LoRA menghasilkan kinerja yang kompetitif, tetapi masih belum melampaui baseline WavLM+Ridge pada metrik agregat *test_strict*. Mean 10 run LoRA memiliki *MAE_mean* 0,100275 dan *R2_mean* 0,302657, sedangkan baseline WavLM+Ridge memiliki MAE 0,099881 dan R² 0,309102. Dengan demikian, LoRA bersifat kompetitif dan stabil, tetapi belum menjadi model agregat terbaik pada *strict split*.

Tabel 4.44 Metrik per-trait WavLM+LoRA *best-val run* pada *test_strict*

Trait	MAE	RMSE	R ²	Acc	PredVar/TrueVar
<i>extraversion</i>	0,098991	0,124656	0,348083	0,901009	0,350299
<i>neuroticism</i>	0,102272	0,129901	0,335410	0,897728	0,373203
<i>agreeableness</i>	0,098856	0,124438	0,190541	0,901144	0,204223
<i>conscientiousness</i>	0,103458	0,130749	0,324850	0,896542	0,368005
<i>openness</i>	0,097374	0,123192	0,316450	0,902626	0,340535
<i>mean</i>	0,100190	0,126587	0,303067	0,899810	-

Analisis per-trait pada Tabel 4.44 menunjukkan bahwa *Openness* memperoleh MAE terendah, yaitu 0,097374, sedangkan *Conscientiousness* memiliki MAE tertinggi, yaitu 0,103458. Dari sisi R², *Extraversion* menjadi yang tertinggi dengan R² sebesar 0,348083, sedangkan *Agreeableness* menjadi yang terendah dengan R² sebesar 0,190541. Rasio *PredVar/TrueVar* yang lebih kecil dari 1 pada seluruh *trait* menunjukkan bahwa sebaran prediksi lebih sempit daripada sebaran label aktual, sehingga mendukung indikasi *regression-to-the-mean*. Metrik per-trait utama disajikan pada Tabel 4.44, sedangkan statistik tambahan yang mencakup rata-rata dan simpangan baku label aktual maupun prediksi disediakan pada Lampiran 47 untuk mendukung analisis penyempitan variansi prediksi.

Visualisasi distribusi pada Gambar 4.18 memperlihatkan bahwa prediksi model cenderung terkonsentrasi pada rentang tengah dibandingkan label aktual. Pola ini konsisten dengan nilai $\text{PredVar}/\text{TrueVar}$ pada Tabel 4.44, terutama pada Agreeableness yang memiliki rasio variansi prediksi terhadap variansi label paling rendah. Karena label berada pada rentang 0 sampai 1, nilai $\text{Acc}(1-\text{MAE})$ dapat tetap tinggi ketika MAE relatif kecil, tetapi R^2 tetap penting untuk membaca kemampuan model menangkap variasi target. Hasil prediksi best-val run, median run, dan ensemble disediakan sebagai Lampiran 48 sampai Lampiran 50, sedangkan visualisasi tambahan disediakan pada Lampiran 55 sampai Lampiran 57.




Gambar 4.18 Histogram label aktual dan prediksi WavLM+LoRA best-val run pada test_strict

Scatter plot pada Gambar 4.19 menunjukkan hubungan positif antara prediksi dan label aktual, tetapi titik prediksi belum sepenuhnya mengikuti garis diagonal ideal. Penyempitan prediksi pada nilai tengah membuat kesalahan pada label ekstrem menjadi lebih besar. Oleh karena itu, pola ini tidak dibaca sebagai kegagalan total model, melainkan sebagai indikasi bahwa WavLM+LoRA pada konfigurasi ini masih memiliki kecenderungan *regression-to-the-mean*, yaitu prediksi belum mereplikasi variasi label aktual secara penuh.

Analisis diagnostik *loss* dilakukan secara *post-hoc* menggunakan artefak riwayat pelatihan yang telah tersimpan, sehingga tidak melibatkan *training* ulang, Optuna ulang, maupun perubahan terhadap hasil eksperimen utama. Pada eksperimen ini, *train_loss* didefinisikan sebagai L1 *loss* dengan reduksi rata-rata, sehingga merepresentasikan *MAE* pada data *training*. Sementara itu, *val_loss* pada analisis pelengkap merujuk pada *val_mae_mean*. Dengan demikian, *train_loss* dan *val_loss* dapat dibandingkan dari sisi skala metrik, meskipun *train_loss* dihitung pada mode *training* dan *val_loss* dihitung pada mode evaluasi.

Berdasarkan diagnostik *loss*, rata-rata gap *validation loss* terhadap *train loss* pada best epoch adalah 0,003692, sedangkan rata-rata gap pada epoch terakhir yang dijalankan sebelum *early stopping* adalah 0,004575. Rata-rata *val_loss* minimum per *run* adalah 0,098172, sedangkan rata-rata *val_loss* pada epoch terakhir adalah 0,098460. Kurva agregat pada Gambar 4.20

menunjukkan bahwa *train loss* dan *validation loss* sama-sama menurun pada awal epoch, lalu *validation loss* cenderung mendatar. Pola ini tidak menunjukkan *overfitting* berat maupun *underfitting* yang jelas, tetapi tetap perlu dibaca sebagai diagnostik sederhana, bukan bukti mutlak bahwa *overfitting* tidak terjadi sama sekali. Ringkasan diagnostik dan kurva pendukung disediakan pada Lampiran 51 sampai Lampiran 54.




Gambar 4.19 Scatter plot label aktual dan prediksi WavLM+LoRA best-val run pada test_strict

Pemeriksaan ulang terhadap penerapan *strict split* pada data yang digunakan dalam tahap *fine-tuning* menunjukkan bahwa tidak ditemukan *overlap clip_id* maupun *group_id* antara subset *train*, *validation*, dan *test*. Jumlah data yang digunakan pada tahap ini adalah 5.936 sampel pada *train*, 1.999 sampel pada *validation*, dan 2.039 sampel pada *test*. Dengan demikian, tahap *fine-tuning* tetap mengikuti prinsip *group-disjoint strict split* yang telah dibangun pada Subbab 4.1.2. Hasil ini penting karena pemilihan model dilakukan berdasarkan *validation set*, sedangkan *test set* tetap digunakan hanya untuk evaluasi akhir.

Dari sisi keterulangan eksperimen, *final runs* telah dijalankan menggunakan daftar *seed* tetap sehingga evaluasi akhir dapat dibandingkan secara konsisten antar *run*. Namun, urutan trial pada tahap Optuna dapat bergantung pada konfigurasi sampler yang digunakan. Oleh karena itu, replikasi penuh terhadap urutan pencarian hiperparameter perlu merujuk pada artefak trial yang telah disimpan, sedangkan pelaporan kinerja akhir tetap didasarkan pada konfigurasi terbaik yang diperoleh dan dievaluasi ulang melalui 10 *final runs*.

Secara keseluruhan, konfigurasi terbaik Optuna untuk WavLM+LoRA pada *strict split* menggunakan *learning rate* 0,000249056, *rank* LoRA $r = 8$, *lora_alpha* = 32, *lora_dropout* = 0,00, *weight_decay* = 0,00127186, dan *warmup_ratio* = 0,08. Evaluasi pada 10 *final runs* menghasilkan rata-rata *MAE_mean* sebesar 0,100275, *RMSE_mean* sebesar 0,126627, *R²_mean* sebesar 0,302657, dan *Acc_mean* sebesar 0,899725. Hasil tersebut menunjukkan kinerja yang

relatif stabil antar-*seed*, tetapi masih sedikit berada di bawah *baseline* WavLM+*Ridge* pada *strict split*.



Gambar 4.20 Kurva agregat train loss dan validation loss WavLM+LoRA pada 10 final runs

Bagian sensitivitas hiperparameter disajikan secara hati-hati karena eksperimen ini belum memenuhi definisi *ablation study* murni per parameter. Pada *ablation study* murni, satu komponen atau satu parameter diubah sementara komponen lain dijaga tetap. Sebaliknya, pada studi Optuna ini beberapa hiperparameter berubah secara bersamaan pada setiap *trial*. Oleh karena itu, analisis yang tersedia lebih tepat disebut sebagai analisis sensitivitas berbasis *hyperparameter tuning*. Berdasarkan *parameter importance* dan ringkasan *trial*, *learning rate* tampak paling berasosiasi dengan variasi kinerja validasi dalam ruang pencarian ini, tetapi kesimpulan tersebut bersifat indikatif dan tidak boleh dibaca sebagai hubungan kausal tunggal.

4.1.7 Hasil *Fine-Tuning* HuBERT dengan LoRA

Subbab ini menyajikan hasil *fine-tuning* HuBERT menggunakan LoRA pada *strict split* berbasis *group_id*. HuBERT dievaluasi sebagai pembanding lanjutan terhadap WavLM karena pada tahap *baseline strict split* HuBERT masih termasuk dalam kelompok *backbone* SSL yang kompetitif, meskipun bukan *baseline frozen* terbaik. Evaluasi HuBERT+LoRA diperlukan untuk melihat apakah adaptasi *parameter-efficient* memberikan manfaat yang sama pada *backbone* SSL lain atau justru bergantung pada karakter representasi tiap *model prelatih*. Dengan demikian, eksperimen HuBERT+LoRA tidak menggantikan posisi WavLM sebagai *baseline frozen* terbaik, tetapi melengkapi analisis *fine-tuning* agar perbandingan antar-*backbone* menjadi lebih seimbang. Data *test_strict* tetap tidak digunakan dalam pencarian hiperparameter maupun seleksi checkpoint; seluruh keputusan model didasarkan pada *validation set*, sedangkan *test_strict* hanya digunakan setelah konfigurasi ditetapkan.

Konfigurasi umum eksperimen ditunjukkan pada Tabel 4.45. *Backbone* yang digunakan adalah facebook/hubert-base-ls960 dengan target *adapter* LoRA pada modul *q_proj* dan *v_proj*.

Notebook executed menunjukkan *batch size* 40, maksimum 100 epoch, *patience* 5, dan metrik seleksi $S = 1 - MAE_mean$ pada *validation set*. Maksimum 100 epoch tidak berarti setiap *final run* berjalan sampai 100 epoch karena *early stopping* menghentikan *final run* HuBERT pada stop epoch 8 sampai 13. Pemeriksaan *strict split* pada artefak HuBERT menunjukkan jumlah data *train*, *validation*, dan *test* masing-masing sebesar 5.936, 1.999, dan 2.039 sampel, serta tidak ditemukan *overlap clip_id* maupun *group_id*. Rincian konfigurasi studi disajikan pada Lampiran 58, riwayat seluruh trial Optuna HuBERT disajikan pada Lampiran 59, ringkasan best trial pada Lampiran 60, status trial pada Lampiran 61, dan audit *strict split* pada Lampiran 62.

Tabel 4.45 Konfigurasi umum fine-tuning HuBERT dengan LoRA

Komponen	Nilai	Keterangan
Backbone	facebook/hubert-base-ls960	Model pralatih HuBERT yang diadaptasi.
Protokol data	<i>train_strict</i> , <i>val_strict</i> , <i>test_strict</i>	<i>test_strict</i> dikunci sampai evaluasi akhir
Input audio	16 kHz, mono, maksimum 15 detik	Mengikuti format hasil praproses audio
<i>Loss training</i>	$F_{l1_loss}(yhat, y, reduction="mean")$	L1 loss/MAE pada lima trait
<i>Optimizer</i>	AdamW	Mengoptimasi parameter LoRA dan regression head
<i>Batch size</i>	40	Disamakan dengan eksperimen WavLM.
Maksimum epoch	100	Disamakan dengan WavLM yang dibatasi oleh <i>early stopping</i> .
<i>Early stopping patience</i>	5	Seleksi checkpoint berdasarkan <i>val_S</i>
<i>Gradient clipping</i>	1,0	Menstabilkan pembaruan gradien
<i>Target module</i> LoRA	q_proj dan v_proj	Backbone utama dibekukan
<i>Final seeds</i>	42, 52, 62, 72, 82, 92, 102, 112, 122, 132	Dipakai untuk final 10 runs

Pencarian hiperparameter dilakukan menggunakan Optuna dengan ruang pencarian yang sejenis dengan eksperimen WavLM. Ruang pencarian dan konfigurasi terbaik ditampilkan pada Tabel 4.46. Trial terbaik adalah trial nomor 41 dengan nilai S *validation* sebesar 0,902964. Konfigurasi tersebut menggunakan *learning rate* 0,000183232, *rank* LoRA $r = 8$, *lora_alpha* = 64, *lora_dropout* = 0,05, *weight_decay* 0,019905951, dan *warmup_ratio* = 0. Daftar trial

terbaik disajikan pada Lampiran 63, sedangkan parameter importance disajikan pada Lampiran 64.

Tabel 4.46 Ruang pencarian Optuna dan konfigurasi terbaik HuBERT+LoRA

Parameter	Ruang pencarian	Konfigurasi terbaik
learning_rate	5e-5 sampai 3e-4, log scale	0,000183232
r	{4, 8, 16}	8
lora_alpha	{16, 32, 64}	64
lora_dropout	{0,00; 0,05; 0,10; 0,15}	0,05
weight_decay	1e-4 sampai 2e-2, log scale	0,019905951
warmup_ratio	{0,00; 0,03; 0,05; 0,08; 0,10}	0
Jumlah trial	50	50
Pruner	MedianPruner	MedianPruner
Metrik seleksi	S = 1 - MAE_mean pada val_strict	Best validation S = 0,902964


Status trial perlu dilaporkan secara transparan karena target pencarian adalah 50 trial, tetapi tidak semua *trial* berakhir complete. Berdasarkan *trial_state_counts.csv*, terdapat 30 trial complete dan 20 *trial pruned*. Kondisi ini tidak menjadi kesalahan fatal karena pruning digunakan untuk menghentikan konfigurasi yang kurang menjanjikan lebih awal. Namun, interpretasi *parameter importance* dan kecenderungan hiperparameter tetap perlu dibaca sebagai analisis sensitivitas berbasis *hyperparameter tuning*, bukan sebagai *ablation study* murni.

Tabel 4.47 memperlihatkan bahwa lima trial terbaik berada pada nilai S *validation* yang sangat berdekatan. Trial terbaik hanya sedikit lebih tinggi dibandingkan trial peringkat kedua, sehingga konfigurasi terbaik tidak berdiri sebagai satu titik yang sangat dominan. Gambar 4.21 menampilkan riwayat optimisasi Optuna, sedangkan Gambar 4.22 menampilkan parameter importance. Kedua gambar tersebut digunakan sebagai ringkasan visual proses *tuning* dan dilengkapi daftar trial pada Lampiran 63 serta parameter importance pada Lampiran 64. Selain lima trial terbaik pada Tabel 4.47, riwayat lengkap seluruh trial Optuna HuBERT+LoRA

disediakan pada Lampiran 59, sehingga proses pencarian hiperparameter dapat ditelusuri tidak hanya dari konfigurasi terbaik, tetapi juga dari keseluruhan percobaan yang dijalankan.

Tabel 4.47 Lima trial terbaik pada *hyperparameter tuning* Optuna HuBERT+LoRA


Trial	S Val	learning_rate	r	lora_alpha	dropout	weight_decay	warmup
41	0,902964	0,000183232	8	64	0,05	0,019905951	0
18	0,902953	0,000230031	8	32	0,05	0,003672503	0
42	0,902868	0,000174971	8	64	0,05	0,018159266	0
31	0,902848	0,000174166	8	64	0,05	0,009797142	0
24	0,902819	0,000218010	8	64	0,05	0,001800049	0



Gambar 4.21 Riwayat optimisasi Optuna pada fine-tuning HuBERT+LoRA

Parameter importance pada Gambar 4.22 menunjukkan bahwa *lora_dropout* memiliki kontribusi *importance* paling besar pada studi Optuna HuBERT, diikuti *learning_rate*. Hasil ini tidak dibaca sebagai bukti kausal tunggal karena setiap trial mengubah beberapa parameter

sekaligus. Pembacaan yang lebih aman adalah bahwa konfigurasi HuBERT+LoRA sensitif terhadap kombinasi parameter di dalam ruang pencarian yang diuji.



Gambar 4.22 Parameter importance pada studi Optuna HuBERT+LoRA

Tabel 4.48 Ringkasan agregat final 10 runs HuBERT+LoRA

Metrik	Mean	Std	Min	Max
best_val_S	0,902104	0,000624	0,900836	0,902983
test_MAE_mean	0,099061	0,000381	0,098381	0,099719
test_RMSE_mean	0,125301	0,000622	0,124523	0,126286
test_R2_mean	0,317294	0,006822	0,306610	0,325869
test_Acc_mean	0,900939	0,000381	0,900281	0,901619

Setelah konfigurasi terbaik ditetapkan, model dilatih ulang dalam 10 *final runs* menggunakan *seed* berbeda. Ringkasan pada Tabel 4.48 menunjukkan bahwa rata-rata *test_MAE_mean* adalah 0,099061, rata-rata *test_RMSE_mean* adalah 0,125301, rata-rata *test_R2_mean* adalah

0,317294, dan rata-rata *test_Acc_mean* adalah 0,900939. Simpangan baku *test_MAE_mean* sebesar 0,000381 menunjukkan variasi antar *seed* relatif kecil, walaupun R^2 tetap lebih sensitif terhadap perubahan *seed*. Rincian seluruh *final runs* disajikan pada Lampiran 65, sedangkan statistik ringkasnya disajikan pada Lampiran 66.

Tabel 4.49 Perbandingan best-val run, median run, dan ensemble HuBERT+LoRA

Pilihan	Identitas	Seed	best_val_S	MAE	RMSE	R ²	Acc
Best-val run	run_04_seed_072	72	0,902983	0,098695	0,124714	0,323789	0,901305
Median run	run_05_seed_082	82	0,902216	0,099013	0,125023	0,320394	0,900987
Ensemble mean 10 runs	ensemble_mean_10runs	-	-	0,097698	0,123640	0,335042	0,902302

Tabel 4.49 membedakan tiga bentuk pelaporan hasil HuBERT+LoRA. *Best-val run* adalah *run_04_seed_072*, *test_MAE_mean* 0,098695, dan *test_R2_mean* 0,323789. *Median run* adalah *run_05_seed_082* dengan *seed* 82, *test_MAE_mean* 0,099013, dan *test_R2_mean* 0,320394. *Ensemble* dari 10 run menghasilkan *test_MAE_mean* 0,097698 dan *test_R2_mean* 0,335042. Hasil *ensemble* digunakan sebagai analisis tambahan terhadap stabilitas prediksi karena diperoleh dari rata-rata prediksi beberapa run, sehingga tidak boleh diklaim sebagai satu model checkpoint. Oleh karena itu, hasil utama untuk pelaporan agregat tetap mengacu pada rerata final 10 runs pada Tabel 4.48, sedangkan *best-val run* digunakan ketika analisis membutuhkan satu checkpoint tunggal, misalnya untuk analisis per-trait dan visualisasi prediksi. Metrik per-trait untuk *best-val run*, *median run*, dan *ensemble* disajikan pada Lampiran 67, Lampiran 68, dan Lampiran 69. Sementara itu, prediksi pada *test_strict* untuk *best-val run*, *median run*, dan *ensemble* masing-masing disediakan pada Lampiran 70, Lampiran 71, dan Lampiran 72 sebagai dasar keterlacakan perhitungan metrik pada Tabel 4.49.


Tabel 4.50 Perbandingan baseline strict terbaik dengan hasil HuBERT+LoRA pada *test_strict*

Metode	MAE	RMSE	R ²	Acc	Delta MAE vs baseline	Delta R ² vs baseline
HuBERT + Ridge strict baseline	0,101072	0,127392	0,294469	0,898928	0,000000	0,000000
HuBERT + LoRA rerata 10 runs	0,099061	0,125301	0,317294	0,900939	-0,002011	0,022825
HuBERT + LoRA best-val run	0,098695	0,124714	0,323789	0,901305	-0,002377	0,029320

Metode	MAE	RMSE	R ²	Acc	Delta MAE vs baseline	Delta R ² vs baseline
HuBERT + LoRA median run	0,099013	0,125023	0,320394	0,900987	-0,002059	0,025925
HuBERT + LoRA ensemble	0,097698	0,123640	0,335042	0,902302	-0,003374	0,040573

Tabel 4.50 menunjukkan bahwa *fine-tuning* HuBERT dengan LoRA memberi peningkatan dibandingkan *baseline frozen embedding* HuBERT + *Ridge* pada *strict split*. Pada rerata 10 *final runs*, HuBERT+LoRA menurunkan *MAE* sebesar 0,002011 dan meningkatkan *R²* sebesar 0,022825 dibandingkan *baseline*. *Best-val run* juga menunjukkan peningkatan dengan *MAE* 0,098695 dan *R²* 0,323789. Sementara itu, *ensemble* 10 *run* menghasilkan kinerja terbaik secara agregat dengan *MAE* 0,097698 dan *R²* 0,335042. Namun, seperti pada WavLM, hasil *ensemble* tetap diposisikan sebagai analisis tambahan berbasis rata-rata prediksi, bukan sebagai satu checkpoint model tunggal. Dengan demikian, hasil utama pelaporan tetap mengacu pada rerata 10 *final runs*, sedangkan *best-val run* digunakan untuk analisis yang memerlukan satu checkpoint tunggal.

Gambar 4.23 menunjukkan kurva agregat *train loss* dan *validation loss* pada *final runs* HuBERT+LoRA. Secara umum, pola kurva tidak menunjukkan indikasi *overfitting* berat yang konsisten, meskipun terdapat gap ringan pada sebagian *run*. Oleh karena itu, diagnostik *loss* digunakan sebagai pendukung interpretasi stabilitas pelatihan, sedangkan kesimpulan utama tetap didasarkan pada metrik validasi dan evaluasi *test_strict*. Ringkasan gap *train-validation* disajikan pada Lampiran 73. Rincian diagnostik pelatihan HuBERT+LoRA disediakan pada Lampiran 77 sampai Lampiran 79, yang mencakup ringkasan kurva *loss* agregat, gap *train-validation* per *run*, serta overlay *train-validation loss* dari seluruh *final runs*.




Gambar 4.23 Kurva agregat *train loss* dan *validation loss* pada 10 *final runs* HuBERT+LoRA


Tabel 4.51 Metrik per-trait HuBERT+LoRA *best-val run* pada *test_strict*

<i>Trait</i>	MAE	RMSE	R²	Acc	PredVar/TrueVar
<i>extraversion</i>	0,097734	0,123318	0,361995	0,902266	0,391606
<i>neuroticism</i>	0,100278	0,126970	0,365063	0,899722	0,344394
<i>agreeableness</i>	0,096105	0,121851	0,223842	0,903895	0,272738
<i>conscientiousness</i>	0,102117	0,129485	0,337837	0,897883	0,388951
<i>openness</i>	0,097242	0,121946	0,330209	0,902758	0,376969
<i>mean</i>	0,098695	0,124714	0,323789	0,901305	-

Analisis per-trait pada Tabel 4.51 menunjukkan bahwa *agreeableness* memperoleh *MAE* terendah sebesar 0,096105, sedangkan *conscientiousness* memiliki *MAE* tertinggi sebesar 0,102117. Dari sisi R^2 , *neuroticism* dan *extraversion* menjadi dua *trait* tertinggi, sedangkan *agreeableness* menjadi *trait* dengan R^2 paling rendah. Temuan ini memperlihatkan bahwa *MAE* yang relatif rendah tidak selalu berarti variasi label dapat dijelaskan dengan kuat. Visualisasi *MAE* dan R^2 per-trait disajikan pada Gambar 4.24 dan Gambar 4.25.



Gambar 4.24 Perbandingan MAE per-trait HuBERT+LoRA *best-val run* pada *test_strict*




Gambar 4.25 Perbandingan R^2 per-trait HuBERT+LoRA best-val run pada test_strict

Pola distribusi prediksi ditinjau melalui histogram dan scatter plot pada Gambar 4.26 dan Gambar 4.27. Kedua visualisasi tersebut menunjukkan hubungan positif antara label aktual dan prediksi, tetapi prediksi masih cenderung menyempit ke nilai tengah. Indikasi ini diperkuat oleh Gambar 4.28 yang membandingkan simpangan baku label aktual dan prediksi. Pada seluruh *trait*, nilai $PredVar/TrueVar$ di Tabel 4.51 masih di bawah 1, sehingga prediksi belum mereplikasi variasi target secara penuh. Ringkasan *regression-to-the-mean* disajikan pada Lampiran 74, sedangkan contoh error prediksi terbesar dan terkecil disajikan pada Lampiran 75 dan Lampiran 76. Untuk meninjau pola penyempitan prediksi secara lebih rinci, analisis berbasis bin antara label aktual dan prediksi HuBERT+LoRA *best-val run* disajikan pada


Lampiran 80. Selain itu, distribusi *residual* per *trait* disajikan pada Lampiran 81 untuk melihat sebaran galat prediksi dan mengidentifikasi apakah terdapat *trait* tertentu dengan variasi error yang lebih besar.

Perbandingan pada Tabel 4.52 menunjukkan dua pola utama. Pertama, pada backbone WavLM, fine-tuning dengan LoRA belum melampaui baseline frozen embedding + Ridge. Rerata 10 runs WavLM+LoRA memperoleh MAE 0,100275 dan R^2 0,302657, sedangkan baseline WavLM frozen embedding + Ridge memperoleh MAE 0,099881 dan R^2 0,309102. Dengan demikian, pada WavLM, adaptasi LoRA belum memberikan peningkatan agregat dibandingkan baseline frozen. Kedua, pada backbone HuBERT, fine-tuning dengan LoRA justru meningkatkan kinerja dibandingkan baseline frozen embedding + Ridge. Rerata 10 runs HuBERT+LoRA memperoleh MAE 0,099061 dan R^2 0,317294, sedangkan baseline HuBERT frozen embedding + Ridge memperoleh MAE 0,101072 dan R^2 0,294469.


Jika dibandingkan antarhasil LoRA, HuBERT+LoRA juga menunjukkan kinerja lebih baik daripada WavLM+LoRA pada seluruh bentuk pelaporan utama. Pada rerata 10 runs, HuBERT+LoRA menghasilkan MAE lebih rendah dan R^2 lebih tinggi dibandingkan WavLM+LoRA. Pola yang sama juga terlihat pada best-val run, median run, dan ensemble 10 runs. Hasil terbaik secara numerik diperoleh oleh ensemble HuBERT+LoRA dengan MAE 0,097698 dan R^2 0,335042. Namun, hasil ensemble tetap diposisikan sebagai analisis tambahan berbasis rata-rata prediksi beberapa run, bukan sebagai satu checkpoint model tunggal. Oleh karena itu, kesimpulan utama lebih aman ditekankan pada rerata 10 runs dan best-val run, dengan catatan bahwa selisih metrik masih berada pada skala kecil dan seluruh hasil berasal dari satu strict split.



Gambar 4.26 Histogram label aktual dan prediksi HuBERT+LoRA *best-val run* pada *test_strict*



Gambar 4.27 Scatter plot label aktual dan prediksi HuBERT+LoRA *best-val run* pada *test_strict*



Gambar 4.28 Perbandingan simpangan baku label aktual dan prediksi HuBERT+LoRA *best-val run* pada *test_strict*.

Tabel 4.52 Perbandingan *baseline frozen* dan hasil LoRA WavLM-HuBERT pada *test_strict*

Model	Pelaporan	MAE	RMSE	R ²	Acc
-------	-----------	-----	------	----------------	-----

WavLM frozen embedding + Ridge	Baseline frozen WavLM strict split	0,099881	0,126029	0,309102	0,900119
WavLM+LoRA	Mean 10 runs	0,100275	0,126627	0,302657	0,899725
	Best-val run	0,100190	0,126587	0,303067	0,899810
	Median run	0,100253	0,126471	0,304404	0,899747
	Ensemble 10 runs	0,100132	0,126450	0,304565	0,899868
HuBERT frozen embedding + Ridge	Baseline frozen HuBERT di <i>split strict</i>	0,101072	0,127392	0,294469	0,898928
HuBERT+LoRA	Mean 10 runs	0,099061	0,125301	0,317294	0,900939
	Best-val run	0,098695	0,124714	0,323789	0,901305
	Median run	0,099013	0,125023	0,320394	0,900987
	Ensemble 10 runs	0,097698	0,123640	0,335042	0,902302

4.1.8 Perbandingan dengan Penelitian Terdahulu

Perbandingan dengan penelitian terdahulu dilakukan untuk menempatkan hasil penelitian ini dalam konteks studi estimasi kepribadian berbasis dataset ChaLearn First Impressions V2. Perbandingan tidak dimaksudkan sebagai klaim keunggulan mutlak karena penelitian terdahulu menggunakan modalitas, protokol pembagian data, metrik evaluasi, dan strategi agregasi yang berbeda. Oleh karena itu, hasil penelitian ini diposisikan sebagai pembanding audio-only pada strict split berbasis group_id, bukan sebagai pembanding langsung terhadap pendekatan multimodal pada official split.

Tabel 4.53 Perbandingan hasil penelitian ini dengan penelitian terdahulu yang relevan

Studi	Setup	Hasil yang dilaporkan	Catatan kesetaraan perbandingan
Aslan dkk. (2021)	ChaLearn FI-V2, official split, multimodal	Voice-only Acc sekitar 0,9045, multimodal terbaik sekitar 0,9181	Tidak langsung sebanding karena penelitian ini audio-only dan memakai strict split berbasis group_id sebagai evaluasi utama.
Zhao dkk. (2022)	ChaLearn FI-V2, official split, audio dan visual	Audio-only sekitar 0,8952, multimodal sekitar 0,9167	Menjadi konteks bahwa audio-only umumnya berada di bawah visual atau multimodal pada official split.

Studi	Setup	Hasil yang dilaporkan	Catatan kesetaraan perbandingan
Barchi dkk. (2023)	First Impressions, audio-only, split lebih ketat berbasis video identifier	wav2vec 2.0 DNN sekitar R^2 0,33 pada official dan sekitar R^2 0,28 pada split lebih ketat	Paling dekat dari sisi audio-only dan perhatian terhadap leakage, tetapi backbone dan protokol tidak sama.
Ghassemi dkk. (2024)	ChaLearn FI-V2, multimodal, dependency-free split berbasis channel	Audio+visual R^2 sekitar 0,369 pada dependency-free, official dapat lebih tinggi	Menunjukkan pentingnya split bebas ketergantungan sumber, tetapi masih multimodal.
Penelitian yang diusulkan (WavLM frozen embedding + Ridge strict split)	Audio-only, strict split berbasis group_id, WavLM frozen embedding + Ridge	MAE 0,099881, Acc 0,900119, RMSE 0,126029, R^2 0,309102	Menjadi baseline strict terbaik pada skema frozen feature extraction.
Penelitian yang diusulkan (WavLM+LoRA audio-only strict split)	Audio-only, strict split berbasis group_id, mean 10 final runs	MAE 0,100275, Acc 0,899725, RMSE 0,126627, R^2 0,302657	Menunjukkan bahwa LoRA pada WavLM belum melampaui baseline frozen WavLM yang ditunjukkan pada Tabel 4.52.
Penelitian yang diusulkan (HuBERT+LoRA audio-only strict split)	Audio-only, strict split berbasis group_id, mean 10 final runs	MAE 0,099061, Acc 0,900939, RMSE 0,125301, R^2 0,317294	Menjadi hasil model tunggal rata-rata terbaik pada eksperimen LoRA yang diuji.
Penelitian yang diusulkan (HuBERT+LoRA ensemble audio-only strict split)	Audio-only, strict split berbasis group_id, ensemble 10 runs	MAE 0,097698, Acc 0,902302, RMSE 0,123640, R^2 0,335042	Digunakan sebagai analisis tambahan stabilitas prediksi, bukan pengganti pelaporan model tunggal.

Tabel 4.53 menunjukkan bahwa hasil penelitian ini perlu dibaca pada dua tingkat. Pertama, baseline WavLM frozen embedding + Ridge tetap penting karena menjadi pembanding strict terbaik pada skema frozen feature extraction. Kedua, WavLM+LoRA dan HuBERT+LoRA menunjukkan bahwa efek adaptasi LoRA tidak seragam pada setiap backbone. Berdasarkan perbandingan pada Tabel 4.52, WavLM+LoRA belum melampaui baseline frozen WavLM, sedangkan HuBERT+LoRA menghasilkan MAE lebih rendah dan R^2 lebih tinggi pada metrik agregat. Namun, hasil tersebut tetap tidak dapat dibandingkan secara langsung dengan studi multimodal atau official split karena perbedaan modalitas, protokol split, metrik evaluasi, dan strategi pelaporan.

4.2 Pembahasan

Subbab ini membahas dan menginterpretasikan hasil penelitian yang telah disajikan pada Subbab 4.1. Pembahasan diarahkan untuk menjelaskan keterkaitan antara eksplorasi dataset, praproses audio, pembentukan *strict split*, evaluasi *baseline* pada *official split* dan *strict split*,

serta evaluasi *fine-tuning backbone* dengan LoRA. Bagian ini tidak hanya membaca angka kinerja secara deskriptif, tetapi juga menempatkan hasil tersebut dalam konteks validitas evaluasi, karakteristik tugas *apparent personality*, dan batasan pendekatan *audio-only*.

Pembahasan disusun secara bertahap agar alur interpretasi mengikuti urutan eksperimen. Bagian pertama menyoroti implikasi eksplorasi dataset dan praproses terhadap kelayakan data. Bagian berikutnya membahas perbandingan fitur *handcrafted* dan *embedding* SSL pada *baseline*, dilanjutkan dengan analisis per-trait, perbedaan *official split* dan *strict split*, serta evaluasi khusus terhadap *fine-tuning backbone* dengan LoRA. Seluruh interpretasi pada subbab ini dibatasi pada hasil yang sudah muncul dalam Subbab 4.1 dan tidak dimaksudkan untuk menampilkan hasil eksperimen baru.

4.2.1 Implikasi Praproses dan Strict Split terhadap Validitas Evaluasi

Hasil eksplorasi dataset menunjukkan bahwa data awal memiliki 10.000 klip, 10.000 *clip_id* unik, dan 3.060 *group_id* unik, sebagaimana diringkas pada Tabel 4.1. Pemeriksaan kelengkapan pada Tabel 4.3 juga tidak menemukan *missing value* pada kolom utama, *duplicate clip_id*, *duplicate full rows*, maupun audio yang tidak tersedia. Kondisi ini penting karena eksperimen regresi *Big Five* membutuhkan keterhubungan yang konsisten antara metadata, audio, label, dan identitas grup. Jika salah satu komponen tersebut tidak lengkap, hasil model dapat terganggu bukan karena keterbatasan representasi, melainkan karena kesalahan administrasi data.

Distribusi label pada Tabel 4.4 dan Gambar 4.2 memperlihatkan bahwa kelima *trait* berada pada rentang 0 sampai 1 dengan nilai rata-rata yang cenderung berada di area tengah. Pola ini menjelaskan mengapa pembacaan metrik tidak dapat hanya mengandalkan $Acc(1-MAE)$. Pada label yang terpusat di sekitar nilai tengah, model yang menghasilkan prediksi dekat dengan rata-rata tetap dapat memperoleh *MAE* yang tampak kecil. Oleh karena itu, penggunaan R^2 sebagai metrik pelengkap menjadi penting untuk menilai sejauh mana model menangkap variasi antarsampel, bukan sekadar menghasilkan prediksi yang dekat dengan pusat distribusi label.

Eksplorasi metadata demografis pada Tabel 4.5 dan Gambar 4.4 memperlihatkan adanya ketidakseimbangan pada beberapa kategori, terutama *ethnicity* dan *age_group*. Temuan ini tidak secara langsung menyatakan bahwa model pasti bias, tetapi memberi alasan mengapa pembentukan *split* perlu mempertimbangkan distribusi atribut pendukung. Apabila pembagian data dilakukan tanpa memperhatikan komposisi grup dan metadata, kinerja model dapat ikut dipengaruhi oleh komposisi subset yang tidak seimbang. Karena itu, penggunaan stratifikasi *gender|ethnicity* pada pembentukan *strict split* di Tabel 4.13 merupakan keputusan yang lebih aman dibanding strata yang terlalu granular dan menghasilkan kelompok kecil.

Kontrol kualitas audio juga berperan penting terhadap validitas evaluasi. Statistik VAD pada Tabel 4.6 dan Gambar 4.5 menunjukkan bahwa sebagian besar klip memiliki durasi ujaran yang memadai, tetapi tetap terdapat klip dengan *speech_sec* sangat rendah. Tahap praproses kemudian menindaklanjuti temuan tersebut melalui standardisasi audio, pemeriksaan ulang 42 klip bermasalah, dan penghapusan final 26 klip dengan kandungan ujaran terlalu rendah, sebagaimana ditunjukkan pada Tabel 4.8 sampai Tabel 4.12. Penghapusan ini tidak mengubah ukuran dataset secara substansial karena data bersih tetap berjumlah 9.974 klip, tetapi membantu mencegah model belajar dari sampel yang lebih banyak berisi hening, gangguan, atau sinyal non-ujaran.

Ketersediaan representasi fitur pada Tabel 4.7 memperlihatkan bahwa eGeMAPS tersedia dalam 88 dimensi, sedangkan HuBERT, wav2vec2, dan WavLM tersedia sebagai *embedding* 768 dimensi untuk 9.974 sampel. Pemeriksaan *NaN* dan *Inf* yang disajikan pada Lampiran 4 memperkuat bahwa representasi tersebut layak digunakan sebagai masukan eksperimen. Namun, kelayakan numerik fitur tidak cukup untuk menjamin validitas evaluasi. Model tetap dapat memperoleh hasil yang terlalu optimistis apabila data *train*, *validation*, dan *test* memiliki ketergantungan sumber yang kuat.

Alasan utama pembentukan *strict split* adalah mengurangi potensi ketergantungan sumber antar subset. Pada Tabel 4.14, *strict split* dibentuk pada level *group_id* dengan 1.829 *group_id* pada *train*, 608 pada *validation*, dan 617 pada *test*. Jumlah klipnya adalah 5.936, 1.999, dan 2.039. Validasi *overlap* pada Lampiran 25 sampai Lampiran 27 menunjukkan bahwa *strict split* menghasilkan *overlap group_id* nol antar subset, sedangkan *official split* masih memiliki *group_id* yang muncul pada lebih dari satu subset. Dengan demikian, *strict split* lebih tepat dipahami sebagai *group-disjoint strict split* yang mengurangi peluang model memanfaatkan kemiripan sumber, bukan sebagai jaminan bahwa seluruh bentuk bias dataset telah hilang.

Poin terakhir tersebut penting untuk menghindari klaim yang terlalu kuat. *Strict split* tidak menjamin bahwa evaluasi sepenuhnya bebas *leakage* dalam semua bentuk, karena *group_id* dibentuk dari awalan *clip_id* dan tidak memverifikasi identitas pembicara secara langsung. Akan tetapi, dibandingkan pembagian berbasis sampel yang dapat menempatkan klip dari *group_id* sama pada subset berbeda, pembagian *group-disjoint* memberikan dasar evaluasi yang lebih konservatif dan lebih sesuai untuk menilai kemampuan generalisasi model terhadap sumber data yang tidak muncul pada proses pelatihan.

4.2.2 Perbandingan Fitur *Handcrafted* dan *Embedding SSL* pada *Baseline*

Hasil *baseline* menunjukkan pola yang konsisten pada *official split* dan *strict split*. Pada Tabel 4.21 dan Tabel 4.22, tiga model berbasis *embedding SSL*, yaitu WavLM, HuBERT, dan wav2vec2, mengungguli eGeMAPS pada metrik agregat *validation set* maupun *test set official split*. WavLM menjadi metode terbaik pada *official test set* dengan *MAE* 0,096377, *RMSE* 0,120835, R^2 0,313054, dan $Acc(1-MAE)$ 0,903623. Sementara itu, eGeMAPS menghasilkan *MAE* 0,104837 dan R^2 0,188670. Selisih ini memperlihatkan bahwa representasi SSL memberi keuntungan yang cukup konsisten dibanding fitur akustik *handcrafted* dalam pengaturan *Ridge Regression* yang sama.

Pola yang sama juga muncul pada *strict split*. Pada Tabel 4.29 dan Tabel 4.30, WavLM tetap menjadi *baseline* terbaik dengan *MAE test* 0,099881, *RMSE* 0,126029, R^2 0,309102, dan $Acc(1-MAE)$ 0,900119. HuBERT berada pada posisi berikutnya, kemudian wav2vec2, sedangkan eGeMAPS menjadi *baseline* dengan kinerja agregat terendah. Konsistensi urutan ini penting karena menunjukkan bahwa keunggulan *embedding SSL* tidak hanya muncul pada *official split*, tetapi juga bertahan pada evaluasi *group-disjoint* yang lebih ketat.

Keunggulan *embedding SSL* dapat dipahami dari sifat representasinya. Model seperti WavLM, HuBERT, dan wav2vec2 dipelajari pada data ujaran berskala besar sehingga representasinya berpotensi menangkap pola akustik, temporal, dan paralinguistik yang lebih kaya daripada fitur *handcrafted* yang dirancang secara eksplisit. Namun, interpretasi ini perlu tetap hati-hati. Hasil *baseline* tidak berarti model SSL memahami kepribadian secara psikologis. Hasil tersebut lebih aman dibaca sebagai indikasi bahwa *embedding SSL* menyediakan representasi suara yang

lebih informatif untuk memetakan sinyal audio pendek ke label *apparent personality* dibandingkan ringkasan akustik manual.

eGeMAPS tetap memiliki peran penting sebagai *baseline*. Walaupun kinerjanya lebih rendah daripada *embedding* SSL, eGeMAPS menyediakan pembandingan yang transparan karena fiturnya berkaitan dengan parameter akustik seperti prosodi, kualitas suara, dan pola temporal. Pada Tabel 4.18 dan Tabel 4.26, eGeMAPS hanya memiliki 88 fitur, jauh lebih ringkas dibanding *embedding* SSL 768 dimensi. Dengan demikian, hasil eGeMAPS membantu menunjukkan batas capaian pendekatan *handcrafted* pada *pipeline* yang sama, sedangkan hasil SSL menunjukkan manfaat representasi pralatih yang lebih kaya.

Perbandingan antar *backbone* SSL juga perlu dibaca secara proporsional. WavLM konsisten menjadi yang terbaik pada *official split* dan *strict split*, tetapi selisihnya terhadap HuBERT tidak sangat besar. Pada *strict test set*, *MAE* WavLM adalah 0,099881, sedangkan HuBERT adalah 0,101072. Perbedaan ini cukup untuk menjadikan WavLM sebagai kandidat adaptasi LoRA pada penelitian ini, tetapi tidak cukup untuk menyatakan bahwa HuBERT tidak relevan. wav2vec2 juga tetap kompetitif, meskipun berada di bawah WavLM dan HuBERT pada kedua protokol.

Hasil *tuning alpha* pada Tabel 4.19, Tabel 4.20, Tabel 4.27, dan Tabel 4.28 memperlihatkan bahwa regularisasi *Ridge* berperan dalam menjaga keseimbangan antara galat *training* dan *validation*. Karena *Ridge* tidak dilatih secara *epoch* seperti jaringan saraf, kurva diagnostik yang relevan adalah perubahan *train MAE* dan *validation MAE* terhadap *alpha*, bukan kurva *loss* berbasis *epoch*. Selisih *train-validation* yang relatif kecil pada *alpha* terpilih menunjukkan bahwa hasil *baseline* tidak hanya berasal dari model yang terlalu mengikuti *training set*, melainkan dari kombinasi representasi fitur dan regularisasi yang cukup stabil.

4.2.3 Analisis Per-trait dan Karakteristik Dimensi Big Five pada Skenario berbasis audio

Analisis per-*trait* memperlihatkan bahwa tingkat kesulitan prediksi tidak sama untuk semua dimensi *Big Five*. Pada *official test set*, Tabel 4.23 menunjukkan bahwa WavLM memiliki *MAE* terendah pada *Openness* sebesar 0,094807, sedangkan *Extraversion*, *Neuroticism*, *Agreeableness*, dan *Conscientiousness* berada pada rentang 0,095209 sampai 0,097651. Pada *strict test set*, Tabel 4.31 menunjukkan bahwa WavLM kembali memiliki *MAE* terendah pada *Openness* sebesar 0,096710, sedangkan *Conscientiousness* menjadi yang tertinggi dengan *MAE* 0,102996. Perbedaan ini mengindikasikan bahwa sebagian *trait* lebih mudah ditangkap dari sinyal audio pendek dibanding *trait* lain.

Dari sisi R^2 , pola kesulitan tampak lebih jelas. Pada Tabel 4.24 dan Tabel 4.32, *Agreeableness* memiliki R^2 terendah untuk WavLM, yaitu 0,193316 pada *official test set* dan 0,194475 pada *strict test set*. Sebaliknya, *Extraversion*, *Neuroticism*, *Conscientiousness*, dan *Openness* umumnya memiliki R^2 yang lebih tinggi. Temuan ini dapat dipahami pada skenario berbasis audio karena sebagian aspek seperti *Extraversion* berpeluang lebih mudah tercermin melalui isyarat paralinguistik, misalnya energi suara, dinamika berbicara, dan variasi prosodik. Sebaliknya, *Agreeableness* dapat lebih bergantung pada konteks sosial, ekspresi *visual*, atau isi *verbal*, sehingga sinyal audio pendek tanpa transkrip dan tanpa *visual* mungkin kurang cukup untuk menjelaskan variasinya.

Karakter label *apparent personality* juga perlu dipertimbangkan. Label pada dataset ini merepresentasikan persepsi pengamat terhadap kesan pertama, bukan *self-report* dari subjek.

Karena itu, model tidak sedang memprediksi kepribadian internal secara langsung, melainkan memetakan sinyal audio ke skor persepsi manusia pada klip pendek. Keterbatasan ini membuat hubungan antara audio dan label bersifat tidak deterministik. Sinyal suara dapat memberi petunjuk, tetapi sebagian variasi label kemungkinan berasal dari faktor non-audio seperti penampilan *visual*, isi ucapan, konteks video, dan subjektivitas penilai.

Kondisi distribusi label juga berpengaruh terhadap pembacaan metrik. Tabel 4.4 menunjukkan bahwa label cenderung berada di sekitar rentang tengah. Pada kondisi seperti ini, *MAE* dapat terlihat baik karena prediksi yang terkonsentrasi di sekitar rata-rata sering kali tidak terlalu jauh dari sebagian besar label. Namun, R^2 dapat tetap relatif rendah apabila model belum mampu membedakan variasi antarsampel secara tajam. Oleh sebab itu, nilai $Acc(1-MAE)$ yang mendekati 0,90 tidak boleh dibaca sebagai akurasi klasifikasi yang tinggi, melainkan sebagai transformasi langsung dari *MAE* pada label kontinu 0 sampai 1.

Kecenderungan *regression-to-the-mean* perlu dibahas secara hati-hati. Pada *baseline*, indikasi awal dapat dibaca dari kombinasi *MAE* yang relatif kecil, $Acc(1-MAE)$ yang tinggi, dan R^2 yang masih terbatas. Pada hasil *fine-tuning*, indikasi tersebut terlihat lebih eksplisit pada WavLM+LoRA dan HuBERT+LoRA. Tabel 4.44 dan Tabel 4.51 menunjukkan bahwa rasio $PredVar/TrueVar$ berada di bawah 1 pada seluruh *trait*, sehingga sebaran prediksi kedua model masih lebih sempit daripada sebaran label aktual. Pola ini juga terlihat pada visualisasi WavLM+LoRA di Gambar 4.18 dan Gambar 4.19 serta visualisasi HuBERT+LoRA di Gambar 4.26 sampai Gambar 4.28. Dengan demikian, *regression-to-the-mean* diposisikan sebagai kecenderungan yang didukung oleh diagnostik prediksi, bukan sebagai satu-satunya penjelasan atas seluruh pola kinerja model.

Dengan demikian, kinerja per-*trait* perlu dibaca sebagai gabungan antara karakter sinyal audio, karakter label *apparent personality*, dan distribusi target. Perbedaan kinerja antartrait pada penelitian ini menunjukkan bahwa sebagian dimensi lebih mudah ditangkap oleh representasi audio dibandingkan dimensi lain, tetapi hasil tersebut belum cukup untuk menyimpulkan penyebab psikologisnya secara tunggal. Pada skenario berbasis audio, *trait* dengan R^2 lebih rendah, seperti *Agreeableness*, sebaiknya dipahami sebagai dimensi yang masih sulit dijelaskan oleh sinyal suara saja, sehingga interpretasinya perlu tetap dikaitkan dengan keterbatasan modalitas dan sifat label *apparent personality*.

4.2.4 Perbedaan Official Split dan Strict Split serta Implikasinya terhadap Generalisasi

Pelaporan *official split* tetap diperlukan karena pembagian tersebut merupakan protokol resmi dataset dan menjadi dasar pembandingan bagi banyak penelitian terdahulu. Dengan melaporkan *official split*, hasil penelitian disajikan dalam konteks literatur yang menggunakan pembagian data yang sama. Namun, *official split* tidak cukup sebagai satu-satunya dasar generalisasi karena hasil *overlap* pada Lampiran 25 sampai Lampiran 27 menunjukkan adanya *group_id* yang dapat muncul pada lebih dari satu subset. Kondisi ini membuka kemungkinan bahwa model memanfaatkan kemiripan sumber, bukan hanya pola audio yang benar-benar umum.

Perbandingan *official split* dan *strict split* pada Tabel 4.33 sampai Tabel 4.36 menunjukkan bahwa evaluasi strict secara umum menjadi lebih berat, terutama jika dilihat dari kenaikan *MAE* pada seluruh metode dan penurunan R^2 pada *embedding* SSL. Namun, pola ini tidak identik untuk seluruh metrik dan seluruh metode, karena R^2 eGeMAPS pada *test set* justru meningkat.

Oleh karena itu, dampak *strict split* sebaiknya dibaca sebagai perubahan kondisi evaluasi yang lebih konservatif, bukan sebagai aturan bahwa semua metrik pasti menurun pada semua model.

Pola serupa muncul pada HuBERT dan wav2vec2. Keduanya mengalami peningkatan *MAE* dari *official test set* ke *strict test set*, masing-masing sebesar 0,003598 dan 0,003389 sebagaimana ditunjukkan pada Tabel 4.35. eGeMAPS juga mengalami kenaikan *MAE*, meskipun perubahan R^2 -nya berbeda arah. Perbedaan arah R^2 pada eGeMAPS mengingatkan bahwa R^2 sensitif terhadap distribusi target pada subset uji dan tidak selalu bergerak identik dengan *MAE*. Karena itu, interpretasi perbandingan *split* perlu mempertimbangkan lebih dari satu metrik.

Implikasi utama dari *strict split* adalah meningkatnya kehati-hatian dalam membaca evaluasi. Jika model tetap kompetitif pada *strict split*, maka kinerja tersebut lebih kuat sebagai indikasi kemampuan generalisasi ke *group_id* yang tidak muncul saat *training*. Dalam penelitian ini, urutan kinerja *baseline* tetap relatif stabil, yaitu WavLM berada di posisi terbaik, diikuti HuBERT, wav2vec2, dan eGeMAPS. Konsistensi urutan tersebut memperkuat argumen bahwa keunggulan WavLM tidak hanya bergantung pada *official split*.

Meskipun demikian, istilah yang paling aman untuk pembagian ini adalah *group-disjoint strict split*. Klaim independensi pembicara secara mutlak perlu dihindari apabila identitas pembicara tidak diverifikasi langsung. *Group_id* mengurangi potensi kemiripan sumber antar subset, tetapi tidak menjamin seluruh relasi identitas atau konteks telah hilang. Dengan batasan tersebut, *strict split* tetap merupakan pilihan evaluasi yang lebih realistis dibanding *official split*, terutama untuk dataset berbasis video daring yang memiliki kemungkinan ketergantungan sumber.

Perbedaan *official split* dan *strict split* juga menjawab mengapa kedua protokol tetap dilaporkan. *Official split* memberikan jembatan pembandingan terhadap penelitian terdahulu, sedangkan *strict split* menyediakan ukuran yang lebih konservatif untuk evaluasi internal penelitian ini. Membaca keduanya secara bersamaan membuat interpretasi lebih lengkap. *Official split* menunjukkan posisi terhadap protokol umum, sementara *strict split* membantu menilai sejauh mana kinerja bertahan ketika potensi ketergantungan sumber dikurangi.

4.2.5 Evaluasi *Fine-Tuning* WavLM dan HuBERT dengan LoRA

Hasil *fine-tuning* LoRA perlu dibaca dari dua tingkat perbandingan. Tingkat pertama adalah perbandingan setiap model LoRA terhadap *baseline frozen embedding + Ridge* masing-masing. Pada eksperimen WavLM, rata-rata 10 *final runs* memperoleh *MAE* 0,100275 dan R^2 0,302657 pada *test_strict*. Nilai ini masih sedikit di bawah *baseline* WavLM *frozen embedding + Ridge* yang memperoleh *MAE* 0,099881 dan R^2 0,309102. Dengan demikian, adaptasi LoRA pada WavLM belum memberikan perbaikan agregat terhadap *baseline frozen* yang sudah kuat.

Tingkat kedua adalah perbandingan antarhasil LoRA, yaitu WavLM+LoRA dan HuBERT+LoRA. Pada eksperimen HuBERT, rata-rata 10 *final runs* memperoleh *MAE* 0,099061 dan R^2 0,317294, sedangkan *best-val run* memperoleh *MAE* 0,098695 dan R^2 0,323789. *Ensemble 10 run* menghasilkan *MAE* 0,097698 dan R^2 0,335042. Berdasarkan ringkasan perbandingan pada Tabel 4.52, HuBERT+LoRA menghasilkan metrik agregat yang lebih baik daripada WavLM+LoRA, baik pada pelaporan mean 10 runs maupun *ensemble*. Namun, hasil *ensemble* tetap perlu diposisikan sebagai analisis tambahan terhadap stabilitas prediksi, bukan sebagai pengganti pelaporan model tunggal.

Perbedaan pola antara WavLM dan HuBERT menunjukkan bahwa efek LoRA pada eksperimen ini bersifat bergantung pada *backbone*. WavLM sudah unggul pada skema *frozen feature extraction*, tetapi konfigurasi LoRA yang diuji belum mampu meningkatkan kinerja agregatnya. Sebaliknya, HuBERT memiliki *baseline frozen* yang lebih rendah daripada WavLM, tetapi tampak lebih terbantu oleh adaptasi LoRA. Karena itu, kesimpulan yang lebih aman adalah bahwa WavLM merupakan *backbone frozen* terbaik pada *baseline strict split*, sedangkan HuBERT+LoRA menjadi konfigurasi LoRA terbaik pada protokol, ruang *tuning*, dan output eksperimen ini.

Stabilitas antar *seed* juga perlu dibaca secara komparatif. Pada WavLM+LoRA, simpangan baku *test_MAE_mean* sebesar 0,000081 dan simpangan baku *test_R2_mean* sebesar 0,001359 menunjukkan kinerja yang sangat stabil antar *seed*, meskipun rerata metriknya masih sedikit di bawah *baseline frozen* WavLM. Pada HuBERT+LoRA, simpangan baku *test_MAE_mean* sebesar 0,000381 dan simpangan baku *test_R2_mean* sebesar 0,006822 menunjukkan variasi antar *seed* yang masih kecil dari sisi *MAE*, tetapi R^2 lebih sensitif terhadap perubahan *seed*. Dengan demikian, HuBERT+LoRA memberi peningkatan agregat yang lebih baik, sedangkan WavLM+LoRA menunjukkan stabilitas *seed* yang lebih rapat pada konfigurasi yang diuji.

Dari sisi *loss*, kurva *train* dan *validation* pada HuBERT menunjukkan proses pelatihan yang tidak mengarah pada *overfitting* berat secara konsisten. Beberapa *run* memang memiliki gap *train-validation* yang lebih besar pada epoch akhir, tetapi diagnosis output masih menempatkannya sebagai gap ringan yang perlu dibaca bersama kurva. Dengan demikian, keterbatasan utama bukan hanya *overfitting*, melainkan juga kecenderungan model memprediksi ke arah pusat distribusi label.

Kecenderungan *regression-to-the-mean* terlihat pada WavLM maupun HuBERT. Pada HuBERT *best-val run*, rasio variansi prediksi terhadap variansi aktual masih berada di bawah 1 pada seluruh *trait*. Artinya, model menangkap pola representasi audio yang berkaitan dengan skor *apparent personality*, tetapi belum mampu menghasilkan sebaran prediksi yang selebar label aktual. Kondisi ini menjelaskan mengapa *MAE* dapat membaik sementara R^2 belum mendekati nilai tinggi.

Secara per-*trait*, *agreeableness* tetap menjadi dimensi yang sulit dijelaskan oleh model. Pada HuBERT *best-val run*, *agreeableness* memiliki R^2 paling rendah dibandingkan *trait* lain meskipun *MAE*-nya bukan yang paling buruk. Hal ini memperkuat argumen bahwa pembacaan kinerja tidak cukup hanya berdasarkan *MAE*. Untuk tugas dengan label yang berpusat di tengah, R^2 dan analisis variansi prediksi perlu digunakan agar model yang terlalu konservatif tidak terlihat terlalu baik.

4.2.6 Posisi Hasil Penelitian terhadap Literatur Terdahulu

Posisi hasil penelitian ini terhadap literatur perlu ditempatkan secara hati-hati. Studi seperti Aslan dkk. dan Zhao dkk. melaporkan kinerja yang tinggi pada dataset *ChaLearn First Impressions V2*, tetapi keduanya menggunakan skenario *multimodal* atau *official split*. Karena penelitian ini hanya menggunakan audio dan menjadikan *strict split* berbasis *group_id* sebagai evaluasi utama, hasilnya tidak dapat dibandingkan secara langsung dengan angka *multimodal* pada *official split*.

Dibandingkan studi *audio-only* yang memakai representasi suara, kontribusi penelitian ini terletak pada perbandingan sistematis antara eGeMAPS dan *embedding SSL* dari wav2vec2,

HuBERT, serta WavLM pada dua protokol *split*. Hasil *baseline* menunjukkan bahwa *embedding* SSL lebih kuat daripada eGeMAPS pada *official* maupun *strict split*. Temuan ini sejalan dengan arah penelitian Barchi dkk. yang menunjukkan bahwa representasi *self-supervised* dapat menangkap informasi suara yang lebih kaya daripada fitur *handcrafted*, tetapi penelitian ini memperluas evaluasi ke beberapa *backbone* dan menambahkan adaptasi LoRA.

Hasil HuBERT+LoRA juga perlu dibaca bersama temuan Ghassemi dkk. mengenai *dependency-free split*. Studi tersebut menunjukkan bahwa kinerja pada *official split* dapat terlihat lebih tinggi ketika masih ada ketergantungan sumber, sedangkan evaluasi bebas ketergantungan memberikan gambaran generalisasi yang lebih konservatif. Penelitian ini mengambil posisi serupa dengan menggunakan *strict split* berbasis *group_id*. Namun, karena penelitian ini *audio-only*, hasilnya tidak dapat disetarakan langsung dengan hasil *audio+visual* pada *dependency-free split*.

Dengan demikian, kontribusi utama penelitian ini bukan klaim bahwa *audio-only* sudah mengungguli *multimodal*, melainkan menunjukkan bahwa *pipeline* berbasis audio dengan *strict split*, *embedding* SSL, dan LoRA dapat menghasilkan kinerja yang kompetitif tanpa memakai *visual* atau transkrip. Hasil terbaik HuBERT+LoRA *ensemble* mencapai *MAE* 0,097698 dan R^2 0,335042 pada *test_strict*, yang menunjukkan adanya sinyal prediktif pada audio, tetapi masih menyisakan ruang pengembangan terutama pada variasi prediksi dan *trait* yang sulit seperti *agreeableness*.

4.2.7 Keterbatasan Penelitian dan Arah Pengembangan

Keterbatasan pertama berasal dari definisi *strict split* yang digunakan. Pembagian data dibuat *group-disjoint* berdasarkan *group_id* yang diturunkan dari awalan *clip_id*. Protokol ini mengurangi potensi ketergantungan sumber antar *split*, tetapi tidak sama dengan verifikasi identitas pembicara secara langsung. Oleh karena itu, istilah yang lebih aman adalah *strict split* berbasis *group_id* atau *group-disjoint strict split*, bukan klaim *group-disjoint strict split* secara mutlak.

Keterbatasan kedua berkaitan dengan interpretasi hasil LoRA. Analisis parameter pada Optuna tidak dapat disebut sebagai *ablation study* murni karena beberapa hiperparameter berubah bersamaan pada setiap trial. Hasil parameter *importance* lebih tepat diposisikan sebagai analisis sensitivitas berbasis *hyperparameter tuning*. Untuk menyimpulkan pengaruh satu parameter secara kausal, diperlukan eksperimen tambahan yang mengubah satu faktor saja sementara faktor lain dijaga tetap.

Keterbatasan ketiga adalah kecenderungan prediksi menuju nilai tengah. Baik WavLM maupun HuBERT masih menunjukkan penyempitan variansi prediksi dibandingkan label aktual. Kondisi ini membuat *MAE* dan *Acc* tampak cukup baik, tetapi R^2 tetap terbatas. Pengembangan lanjutan perlu menargetkan kemampuan model menangkap variasi label, bukan hanya menurunkan rata-rata galat absolut.

Keterbatasan keempat berada pada cakupan modalitas. Penelitian ini sengaja dibatasi pada *audio-only* untuk menjaga fokus dan menguji seberapa jauh sinyal suara dapat digunakan tanpa *visual* atau transkrip. Karena dataset *First Impressions V2* pada dasarnya *multimodal*, pendekatan *multimodal* tetap menjadi arah lanjutan yang relevan. Namun, eksperimen *multimodal* harus tetap menggunakan protokol pembagian data yang ketat agar peningkatan kinerja tidak berasal dari *leakage* sumber.

Arah pengembangan yang paling dekat adalah mengevaluasi strategi *pooling* yang lebih kaya, seperti *attentive pooling* atau *statistics pooling*, memperluas target module LoRA, menguji *partial unfreezing* pada *layer* atas *backbone*, dan melakukan validasi tambahan melalui *group-based cross-validation*. Selain itu, analisis error berdasarkan metadata demografis, *speech coverage*, *noise*, atau karakteristik prosodi dapat membantu menjelaskan mengapa beberapa *trait* lebih sulit diprediksi dibandingkan *trait* lain.

Halaman ini sengaja dikosongkan.

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan tujuan penelitian, metodologi yang dirancang pada Bab III, serta hasil eksperimen pada Bab IV setelah penambahan HuBERT, kesimpulan penelitian ini adalah sebagai berikut.

1. *Pipeline* berbasis audio yang mencakup standardisasi *audio*, pemeriksaan aktivitas ujaran, dan *strict split* berbasis *group_id* berhasil membentuk data eksperimen yang lebih terkontrol. Setelah *quality control*, data bersih berjumlah 9.974 klip dengan pembagian *strict* sebesar 5.936 *train*, 1.999 *validation*, dan 2.039 *test*. Pemeriksaan artefak menunjukkan tidak ada *overlap clip_id* maupun *group_id* antar *split*, sehingga evaluasi lebih konservatif terhadap ketergantungan sumber.
2. *Embedding* berbasis *self-supervised learning* lebih efektif dibandingkan fitur *handcrafted* eGeMAPS pada skema *frozen feature extraction*. Pada *official split* maupun *strict split*, wav2vec2, HuBERT, dan WavLM secara umum menghasilkan MAE lebih rendah dan R^2 lebih tinggi dibandingkan eGeMAPS. Temuan ini menunjukkan bahwa representasi *speech* pralatih mampu menangkap pola *audio* yang lebih relevan untuk estimasi *apparent personality* dibandingkan fitur akustik manual saja.
3. Pada *baseline strict split*, WavLM menjadi *backbone frozen* terbaik dengan MAE 0,099881, Acc 0,900119, RMSE 0,126029, dan R^2 0,309102 pada *test_strict*. Hasil ini menjadi pembanding utama untuk menilai apakah *fine-tuning* LoRA memberi peningkatan terhadap skema *frozen embedding + Ridge*.
4. *Fine-tuning* WavLM dengan LoRA menghasilkan kinerja yang stabil, tetapi belum melampaui *baseline* WavLM *frozen* pada metrik agregat. Berdasarkan output WavLM yang dilampirkan, mean 10 *final runs* memperoleh MAE 0,100275 dan R^2 0,302657. Konfigurasi terbaik WavLM pada output tersebut adalah *learning_rate* 0,000249056, $r = 8$, *lora_alpha* = 32, *lora_dropout* = 0, *weight_decay* 0,001271857, dan *warmup_ratio* = 0,08.
5. *Fine-tuning* HuBERT dengan LoRA menjadi konfigurasi dengan metrik agregat terbaik pada eksperimen ini. Mean 10 *final runs* HuBERT+LoRA memperoleh MAE 0,099061, Acc 0,900939, RMSE 0,125301, dan R^2 0,317294 pada *test_strict*. *Best-val run* memperoleh MAE 0,098695 dan R^2 0,323789, sedangkan *ensemble 10 run* memperoleh MAE 0,097698 dan R^2 0,335042. Hasil ini menunjukkan bahwa pada protokol dan ruang *tuning* yang diuji, HuBERT+LoRA memperoleh MAE lebih rendah dan R^2 lebih tinggi daripada WavLM+LoRA serta *baseline* *strict* terbaik, tetapi selisihnya tetap perlu dibaca proporsional.
6. Evaluasi *per-trait* menunjukkan bahwa tingkat kesulitan prediksi tidak sama pada semua dimensi *Big Five*. *Agreeableness* cenderung memiliki R^2 paling rendah, sedangkan beberapa *trait* seperti *extraversion* dan *neuroticism* lebih mudah dijelaskan oleh model. Selain itu, analisis variansi prediksi menunjukkan kecenderungan *regression-to-the-mean*, sehingga kinerja harus dibaca menggunakan MAE, Acc, RMSE, R^2 , dan diagnostik distribusi secara bersamaan.

7. Penelitian ini menegaskan pentingnya evaluasi *strict split* berbasis *group_id* dalam estimasi kepribadian berbasis *audio*. Hasil *official split* tetap berguna untuk pembandingan literatur, tetapi *strict split* memberikan pengujian yang lebih konservatif terhadap generalisasi karena mengurangi ketergantungan sumber antar subset.

5.2 Saran

Berdasarkan hasil penelitian dan keterbatasan yang teridentifikasi selama eksperimen, beberapa saran pengembangan lanjutan adalah sebagai berikut.

1. Menguji strategi *pooling* yang lebih informatif. Penelitian ini masih bergantung pada ringkasan representasi yang relatif sederhana. Pengembangan berikutnya dapat mengevaluasi *attentive pooling*, *statistics pooling*, atau temporal *attention* agar informasi prosodik dan dinamika ujaran tidak terlalu banyak hilang saat *embedding* diringkas.
2. Memperluas strategi adaptasi LoRA secara terkontrol. Hasil HuBERT menunjukkan bahwa LoRA dapat membantu, sedangkan WavLM belum melampaui *baseline frozen*. Penelitian lanjutan dapat menguji target module tambahan seperti *k_proj* atau *out_proj*, variasi *rank*, variasi *lora_alpha*, dan *lora_dropout* dengan desain yang lebih terkendali. Jika ingin membahas ablasi, eksperimen harus mengubah satu parameter pada satu waktu.
3. Mengevaluasi partial unfreezing pada *layer* atas *backbone*. Jika LoRA masih membatasi kapasitas adaptasi, pembukaan sebagian *layer* atas dapat diuji sebagai kompromi antara efisiensi dan fleksibilitas model. Eksperimen ini perlu dilaporkan bersama biaya komputasi dan risiko *overfitting*.
4. Melakukan validasi tambahan berbasis *group*. *Strict split* tunggal sudah mengurangi *overlap group_id*, tetapi *group-based cross-validation* dapat memberi gambaran yang lebih kuat mengenai kestabilan hasil terhadap variasi pembagian data.
5. Memperdalam analisis error per-*trait* dan per-kondisi data. *Trait* seperti *agreeableness* perlu dianalisis lebih lanjut dengan mempertimbangkan *speech coverage*, *noise*, durasi ujaran efektif, distribusi label, dan metadata demografis. Analisis ini penting untuk membedakan keterbatasan sinyal *audio* dari keterbatasan label *apparent personality*.
6. Menguji pendekatan *multimodal* sebagai arah lanjutan, tetapi bukan sebagai pembandingan langsung dengan *audio-only*. Karena dataset menyediakan *visual* dan transkrip, pengembangan *multimodal* dapat dilakukan untuk melihat batas kinerja yang lebih tinggi. Namun, protokol *split* menggunakan *group-disjoint* agar peningkatan kinerja tidak berasal dari ketergantungan sumber antar subset.

DAFTAR PUSTAKA

- Aslan, S., Gdkbay, U., & Dibeklioglu, H. (2021). Multimodal assessment of apparent personality using feature attention and error consistency constraint. *Image and Vision Computing, 110*. <https://doi.org/10.1016/j.imavis.2021.104163>
- Baevski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations*. <http://arxiv.org/abs/2006.11477>
- Barchi, R., Pepino, L., Gauder, L., Estienne, L., Meza, M., Riera, P., & Ferrer, L. (2023). *Apparent personality prediction from speech using expert features and wav2vec 2.0*. 21–25. <https://doi.org/10.21437/smm.2023-5>
- Chen, S., Wang, C., Chen, Z., Wu, Y., Liu, S., Chen, Z., Li, J., Kanda, N., Yoshioka, T., Xiao, X., Wu, J., Zhou, L., Ren, S., Qian, Y., Qian, Y., Wu, J., Zeng, M., Yu, X., & Wei, F. (2022). *WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing*. <https://doi.org/10.1109/JSTSP.2022.3188113>
- Davis, S. B., & Mermelstein, P. (1980). *Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences*.
- Escalante, H. J., Kaya, H., Salah, A. A., Escalera, S., Gucluturk, Y., Guclu, U., Baro, X., Guyon, I., Junior, J. C. S. J., Madadi, M., Ayache, S., Viegas, E., Gurpnar, F., Wicaksana, A. S., Liem, C. C. S., Van Gerven, M. A. J., & Van Lier, R. (2022). Modeling, Recognizing, and Explaining Apparent Personality from Videos. *IEEE Transactions on Affective Computing, 13*(2), 894–911. <https://doi.org/10.1109/TAFFC.2020.2973984>
- Eyben, F., Scherer, K. R., Schuller, B. W., Sundberg, J., Andre, E., Busso, C., Devillers, L. Y., Epps, J., Laukka, P., Narayanan, S. S., & Truong, K. P. (2016). The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for Voice Research and Affective Computing. *IEEE Transactions on Affective Computing, 7*(2), 190–202. <https://doi.org/10.1109/TAFFC.2015.2457417>
- Eyben, F., Wllmer, M., & Schuller, B. (2010). OpenSMILE - The Munich versatile and fast open-source audio feature extractor. *MM'10 - Proceedings of the ACM Multimedia 2010 International Conference*, 1459–1462. <https://doi.org/10.1145/1873951.1874246>
- Ghassemi, S., Zhang, T., Van Breda, W., Koutsoumpis, A., Oostrom, J. K., Holtrop, D., & De Vries, R. E. (2024). Unsupervised Multimodal Learning for Dependency-Free Personality Recognition. *IEEE Transactions on Affective Computing, 15*(3), 1053–1066. <https://doi.org/10.1109/TAFFC.2023.3318367>
- Goldberg, L. R. (1990). *An Alternative “Description of Personality”: The Big-Five Factor Structure*.
- Goncalves, L., Robinson, D., Richerson, E., & Busso, C. (2024). Bridging Emotions Across Languages: Low Rank Adaptation for Multilingual Speech Emotion Recognition. *Proceedings of the Annual Conference of the International Speech Communication Association, INTERSPEECH*, 4688–4692. <https://doi.org/10.21437/Interspeech.2024-1226>

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *Springer Series in Statistics The Elements of Statistical Learning Data Mining, Inference, and Prediction*.
- Hoerl, A. E., & Kennard, R. W. (1970). *Ridge Regression: Biased Estimation for Nonorthogonal Problems* (Vol. 12, Nomor 1).
- Houlsby, N., Giurgiu, A., Jastrzebski, S. J., Morrone, B., De Laroussilhe, Q., Gesmundo, A., Attariyan, M., & Gelly, S. (2019). *Parameter-Efficient Transfer Learning for NLP*. <https://gluebenchmark.com/>
- Hsu, W.-N., Bolte, B., Tsai, Y.-H. H., Lakhotia, K., Salakhutdinov, R., & Mohamed, A. (2021). *HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units*. <http://arxiv.org/abs/2106.07447>
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). *LoRA: Low-Rank Adaptation of Large Language Models*. <http://arxiv.org/abs/2106.09685>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning with Applications in R Second Edition*.
- Kingma, D. P., & Ba, J. (2017). *Adam: A Method for Stochastic Optimization*. <http://arxiv.org/abs/1412.6980>
- Lewkowycz, A. (2021). *How to decay your learning rate*. <http://arxiv.org/abs/2103.12682>
- Lisa Li, X., & Liang, P. (2021). *Prefix-Tuning: Optimizing Continuous Prompts for Generation*.
- Loshchilov, I., & Hutter, F. (2019). *Decoupled Weight Decay Regularization*. <http://arxiv.org/abs/1711.05101>
- Mccrae, R. R., & John, O. P. (1992). *An Introduction to the Five-Factor Model and Its Applications*. <https://digitalcommons.unl.edu/publichealthresources>
- National Institute of Standards, & Technology. (2010). *Root Mean Square Error (LET)*. <https://www.itl.nist.gov/div898/software/dataplot/refman2/auxillar/rms.htm>
- Pascanu, R., Mikolov, T., & Bengio, Y. (2013). *On the difficulty of training recurrent neural networks*.
- Ponce-López, V. P., Chen, B., Oliu, M., Corneanu, C., Clapes, A., Guyon, I., Baro, X., Escalante, H. J., & Escalera, S. (2016). *ChaLearn LAP 2016: First Round Challenge on First Impressions - Dataset and Results* (G. Hua & H. Jégou, Ed.; Vol. 9915). Springer International Publishing. <https://doi.org/10.1007/978-3-319-49409-8>
- Prechelt, L. (1997). *Early Stopping | but when?*
- Rubio, V. J., Aguado, D., Toledano, D. T., & Fernández-Gallego, M. P. (2024). Feasibility of Big Data Analytics to Assess Personality Based on Voice Analysis. *Sensors*, 24(22). <https://doi.org/10.3390/s24227151>
- scikit-learn developers. (2007). *scale — scikit-learn 1.8.0 documentation*. <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.scale.html>

- Silero Team. (2024). Silero VAD: pre-trained enterprise-grade Voice Activity Detector (VAD), Number Detector and Language Classifier. Dalam *GitHub repository*. <https://github.com/snakers4/silero-vad>
- Smith, S. W. (1999). *Digital Signal Processing Second Edition* (Vol. 2). California Technical Publishing. www.DSPguide.com
- Vaswani, A., Brain, G., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention Is All You Need*.
- Zaken, E. Ben, Ravfogel, S., & Goldberg, Y. (2022). *BitFit: Simple Parameter-efficient Fine-tuning for Transformer-based Masked Language-models*. <http://arxiv.org/abs/2106.10199>
- Zhao, X., Liao, Y., Tang, Z., Xu, Y., Tao, X., Wang, D., Wang, G., & Lu, H. (2022). Integrating audio and visual modalities for multimodal personality trait recognition via hybrid deep learning. *Frontiers in Neuroscience*, 16. <https://doi.org/10.3389/fnins.2022.1107284>

Halaman ini sengaja dikosongkan.

LAMPIRAN

Lampiran 1 Detail missing value pada kolom utama yang dicek

Kolom	Missing count	Missing ratio
group_id	0	0
clip_id	0	0
split_official	0	0
video_name	0	0
ethnicity	0	0
gender	0	0
age_group	0	0
extraversion	0	0
neuroticism	0	0
agreeableness	0	0
conscientiousness	0	0
openness	0	0
interview	0	0
avg_trait	0	0

Lampiran 2 Detail pemeriksaan duplikasi metadata.

Pemeriksaan	Nilai
duplicate_clip_id	0
duplicate_full_rows	0

Lampiran 3 Ringkasan ketersediaan audio.

Komponen	Nilai
Jumlah metadata	10.000
Audio ditemukan	10.000
Audio tidak ditemukan	0
Rasio audio ditemukan	1

Lampiran 4 Ringkasan pemeriksaan embedding SSL






Model	Split	Jumlah sampel	Embedding shape	Dimensi	Has NaN	Has Inf
hubert	train	5.988	(5988, 768)	768	False	False
hubert	val	1.994	(1994, 768)	768	False	False
hubert	test	1.992	(1992, 768)	768	False	False
wav2vec2	train	5.988	(5988, 768)	768	False	False
wav2vec2	val	1.994	(1994, 768)	768	False	False
wav2vec2	test	1.992	(1992, 768)	768	False	False
wavlm	train	5.988	(5988, 768)	768	False	False
wavlm	val	1.994	(1994, 768)	768	False	False
wavlm	test	1.992	(1992, 768)	768	False	False

Lampiran 5 Ringkasan explained variance PCA 2D embedding SSL


Model	Explained variance PC1	Explained variance PC2	Total explained variance 2D
hubert	0,160208	0,077032	0,23724

Model	Explained variance PC1	Explained variance PC2	Total explained variance 2D
wav2vec2	0,256492	0,088377	0,344869
wavlm	0,099939	0,078082	0,178021

Lampiran 6 Histogram label Big Five per trait



Lampiran 7 Boxplot Label Big Five Berdasarkan Official Split




Lampiran 8 Distribusi Label Big Five Berdasarkan Official Split


Split	Trait	Mean	Std	Min	Max
train	extraversion	0,476146	0,152297	0,000000	0,925234
train	neuroticism	0,520286	0,153546	0,020833	0,979167
train	agreeableness	0,548181	0,136385	0,000000	1,000000
train	conscientiousness	0,522731	0,155219	0,000000	0,970874
train	openness	0,566281	0,146990	0,000000	1,000000
validation	extraversion	0,476813	0,148001	0,018692	1,000000
validation	neuroticism	0,521563	0,149901	0,000000	0,968750

validation	agreeableness	0,551049	0,127571	0,021978	0,934066
validation	conscientiousness	0,528019	0,155717	0,097087	1,000000
validation	openness	0,566317	0,143433	0,033333	1,000000
test	extraversion	0,477925	0,150149	0,009346	0,897196
test	neuroticism	0,521745	0,153327	0,010417	1,000000
test	agreeableness	0,551659	0,133358	0,109890	0,923077
test	conscientiousness	0,525146	0,152633	0,087379	0,980583
test	openness	0,568172	0,144682	0,100000	0,977778


Lampiran 9 Distribusi gender, ethnicity, dan age_group berdasarkan kode kategori











Lampiran 10 Distribusi voiced_ratio dan n_seg berdasarkan hasil VAD.




Lampiran 11 Contoh waveform dan log-mel spectrogram audio hasil standardisasi.




Lampiran 12 Distribusi fitur eGeMAPS terpilih.



Lampiran 13 Distribusi norm embedding SSL



Lampiran 14 Visualisasi PCA 2D embedding SSL.




Lampiran 15 Hasil Alpha Sweep Lengkap pada Official Split


Alpha	WavLM	HuBERT	wav2vec2	eGeMAPS
0.001	0.098106	0.099668	0.100322	0.103516
0.003	0.098106	0.099667	0.100323	0.103516
0.01	0.098104	0.099666	0.100319	0.103514
0.03	0.098101	0.099664	0.100310	0.103511
0.1	0.098088	0.099656	0.100282	0.103502
0.3	0.098054	0.099632	0.100202	0.103488
1	0.097939	0.099554	0.099958	0.103471
3	0.097657	0.099357	0.099479	0.103450
10	0.097003	0.098862	0.098698	0.103397
30	0.096114	0.098157	0.098009	0.103298
100	0.095147	0.097224	0.097613*	0.103167*
300	0.094604	0.096463	0.097702	0.103168
1000	0.094497*	0.095947*	0.098242	0.103499
3000	0.094817	0.096070	0.099061	0.104160
10000	0.095680	0.097010	0.100249	0.105458
30000	0.097257	0.098859	0.101708	0.107357

Alpha	WavLM	HuBERT	wav2vec2	eGeMAPS
100000	0.100562	0.102080	0.104259	0.110336

Lampiran 16 Grafik best alpha per metode pada baseline official split



Lampiran 17 Perbandingan metrik rata-rata antar metode pada validation set official split



Lampiran 18 Ranking metode baseline official split berdasarkan kinerja test set

Metode	Best alpha	Test MAE	Test Acc(1-MAE)	Test RMSE	Test R ²	Final rank
WavLM	1000	0.096377	0.903623	0.120835	0.313054	1
HuBERT	1000	0.097474	0.902526	0.121944	0.300851	2
wav2vec2	100	0.098761	0.901239	0.123295	0.285255	3
eGeMAPS	100	0.104837	0.895163	0.131557	0.188670	4


Lampiran 19 Pemenang per-trait berdasarkan MAE pada test set official split

Trait	Metode terbaik	MAE	R ² metode tersebut
Agreeableness	HuBERT	0.095197	0.185865
Conscientiousness	WavLM	0.097242	0.350883
Extraversion	WavLM	0.097651	0.339560
Neuroticism	WavLM	0.096976	0.355580
Openness	WavLM	0.094807	0.325928

Lampiran 20 Diagnosis variasi prediksi WavLM pada test set official split

Trait	Target std	Prediction std	Pred/Target std	RMSE improvement vs naive	R ² model
Extraversion	0.149493	0.092379	0.617952	0.028021	0.339560
Neuroticism	0.152750	0.092486	0.605475	0.030141	0.355580
Agreeableness	0.132797	0.065088	0.490130	0.013583	0.193316
Conscientiousness	0.151960	0.094284	0.620453	0.029562	0.350883
Openness	0.144165	0.085779	0.595006	0.025822	0.325928

Lampiran 21 Perbandingan simpangan baku target dan prediksi WavLM pada test set official split



Lampiran 22 Evaluasi lengkap kandidat strata untuk stratified group split

Kandidat strata	n_strata	min	median	max	Strata <3	Strata <5	count
gender ethnicity	6	33	164	1446	0	0	1446
gender avg_bin	10	159	305	452	0	0	452
ethnicity avg_bin	15	14	65	559	0	0	559
gender age	14	4	57	916	0	1	916
gender ethnicity avg_bin	30	2	29	414	1	2	414
ethnicity age	18	1	38	1276	1	3	1276
age avg_bin	34	1	22	334	3	7	334
gender ethnicity age avg_bin	138	1	6	229	38	60	229

Lampiran 23 Distribusi Label Big Five Berdasarkan Strict Split

Split	Trait	Count	Mean	Std	Min	Median	Max
test	extraversion	2039	0.470627	0.154427	0.009346	0.46729	0.925234
test	neuroticism	2039	0.513191	0.159383	0.020833	0.520833	1.0
test	agreeableness	2039	0.543479	0.138344	0.10989	0.549451	0.912088
test	conscientiousness	2039	0.518315	0.159164	0.038835	0.524272	0.980583
test	openness	2039	0.560553	0.14904	0.111111	0.566667	0.977778

Split	Trait	Count	Mean	Std	Min	Median	Max
test	avg_trait	2039	0.521233	0.133502	0.116503	0.527802	0.923902
train	extraversion	5936	0.479521	0.150189	0.0	0.485981	1.0
train	neuroticism	5936	0.52343	0.150915	0.0	0.53125	0.979167
train	agreeableness	5936	0.552451	0.132958	0.0	0.56044	1.0
train	conscientiousness	5936	0.526184	0.154187	0.038835	0.533981	1.0
train	openness	5936	0.569164	0.144943	0.0	0.577778	1.0
train	avg_trait	5936	0.53015	0.126996	0.049752	0.535753	0.908998
val	extraversion	1999	0.475144	0.149135	0.018692	0.476636	0.88785
val	neuroticism	1999	0.522636	0.150167	0.020833	0.53125	0.916667
val	agreeableness	1999	0.54823	0.131898	0.087912	0.56044	0.923077
val	conscientiousness	1999	0.526297	0.151479	0.0	0.524272	0.951456
val	openness	1999	0.566528	0.144157	0.133333	0.566667	0.977778
val	avg_trait	1999	0.527767	0.125254	0.086161	0.536419	0.85735

Lampiran 24 Perbandingan Ukuran Official Split dan Strict Split


Protocol	Split	Clip_count	Group_count	Clip_prop	Group_prop
official_after_vad_drop	test	1992	1451	0.199719	0.475115
official_after_vad_drop	train	5988	2620	0.600361	0.857891
official_after_vad_drop	val	1994	1480	0.19992	0.48461
strict_group_based	test	2039	617	0.204432	0.20203
strict_group_based	train	5936	1829	0.595147	0.598887
strict_group_based	val	1999	608	0.200421	0.199083

Lampiran 25 Pemeriksaan Overlap *group_id* Official vs Strict


Protocol	Split Official	Split Strict	Jumlah overlap group_id
official_after_vad_drop	test	train	1198
official_after_vad_drop	test	validation	687
official_after_vad_drop	train	validation	1220

Protocol	Split Official	Split Strict	Jumlah overlap group_id
strict_group_based	test	train	0
strict_group_based	test	validation	0
strict_group_based	train	validation	0

Lampiran 26 Heatmap Overlap group_id pada Official Split



Lampiran 27 Heatmap Overlap group_id pada Strict Split



Lampiran 28 Distribusi Demografis Official Split dan Strict Split

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L28_Demografi**.

Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut:

<https://its.id/m/LampiranTAQIQI>

Lampiran 29 Ringkasan Selisih Mean Label Big Five pada Strict Split

Trait	train	val	test	max_mean_diff
extraversion	0.479521	0.475144	0.470627	0.008894
neuroticism	0.52343	0.522636	0.513191	0.010239
agreeableness	0.552451	0.54823	0.543479	0.008972
conscientiousness	0.526184	0.526297	0.518315	0.007982
openness	0.569164	0.566528	0.560553	0.008611
avg trait	0.53015	0.527767	0.521233	0.008917


Lampiran 30 Ringkasan statistik VAD pada klip drop final

Metrik	Minimum	Rata-rata	Maksimum	Interpretasi
speech_sec	0,000000	0,697769	1,682000	Durasi ujaran seluruh klip drop final berada di bawah ambang 2 detik
voiced_ratio	0,000000	0,046518	0,112133	Proporsi ujaran sangat rendah dibandingkan durasi total 15 detik
n_seg	0	1,500000	5	Sebagian besar klip hanya memiliki sedikit segmen ujaran terdeteksi


Lampiran 31 Statistik Jumlah Klip per group_id pada Strict Split

split_strict	group_count	mean	std	min	median	max
test	617	3.3047	1.846687	1	3.0	6
train	1829	3.245489	1.772445	1	3.0	6
val	608	3.287829	1.82813	1	3.0	6


Lampiran 32 Kurva train MAE dan validation MAE HuBERT terhadap alpha Official split



Lampiran 33 Kurva train MAE dan validation MAE wav2vec2 terhadap alpha Official split




Lampiran 34 Kurva train MAE dan validation MAE eGeMAPS terhadap alpha Official split




Lampiran 35 Tabel lengkap alpha sweep strict split untuk semua metode

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L35 alpha sweep strict split**. Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>


Lampiran 36 Kurva train MAE dan validation MAE terhadap alpha untuk WavLM pada strict split




Lampiran 37 Kurva train MAE dan validation MAE terhadap alpha untuk HuBERT pada strict split



Lampiran 38 Kurva train MAE dan validation MAE terhadap alpha untuk wav2vec2 pada strict split



Lampiran 39 Kurva train MAE dan validation MAE terhadap alpha untuk eGeMAPS pada strict split



Lampiran 40 Tabel lengkap metode *baseline per-trait* MAE dan R² *strict split* pada *test set*

model	trait	Acc(1-MAE)	MAE	RMSE	R2
-------	-------	------------	-----	------	----

wav2vec2	extraversion	0,898329	0,101671	0,127310	0,320020
wav2vec2	neuroticism	0,896718	0,103282	0,130408	0,330206
wav2vec2	agreeableness	0,899288	0,100712	0,126280	0,166387
wav2vec2	conscientiousness	0,894570	0,105430	0,133780	0,293185
wav2vec2	openness	0,900347	0,099653	0,124423	0,302722
HuBERT	extraversion	0,898878	0,101122	0,126747	0,326025
HuBERT	neuroticism	0,897158	0,102842	0,130502	0,329242
HuBERT	agreeableness	0,901115	0,098885	0,124681	0,187374
HuBERT	conscientiousness	0,896137	0,103863	0,131433	0,317764
HuBERT	openness	0,901354	0,098646	0,123598	0,311941
WavLM	extraversion	0,900801	0,099199	0,124786	0,346724
WavLM	neuroticism	0,898080	0,101920	0,129020	0,344391
WavLM	agreeableness	0,901417	0,098583	0,124135	0,194475
WavLM	conscientiousness	0,897004	0,102996	0,129984	0,332724
WavLM	openness	0,903290	0,096710	0,122220	0,327196
eGeMAPS	extraversion	0,893671	0,106329	0,132872	0,259314
eGeMAPS	neuroticism	0,891271	0,108729	0,136669	0,264346
eGeMAPS	agreeableness	0,898260	0,101740	0,128086	0,142374
eGeMAPS	conscientiousness	0,885431	0,114569	0,142707	0,195708
eGeMAPS	openness	0,898898	0,101102	0,127962	0,262490

Lampiran 41 Tabel lengkap metode *baseline* perbandingan *official* vs *strict* untuk *validation* dan *test set*

Metode	Subset	Official MAE	Strict MAE	Δ MAE	Official R ²	Strict R ²	Δ R ²
WavLM	Validation	0,094497	0,097582	0,003085	0,318673	0,283911	-0,034762
WavLM	Test	0,096377	0,099881	0,003505	0,313054	0,309102	-0,003952

Metode	Subset	Official MAE	Strict MAE	Δ MAE	Official R ²	Strict R ²	Δ R ²
HuBERT	Validation	0,095947	0,098642	0,002695	0,297344	0,263530	-0,033814
HuBERT	Test	0,097474	0,101072	0,003598	0,300851	0,294469	-0,006382
wav2vec2	Validation	0,097613	0,101230	0,003617	0,278639	0,228406	-0,050233
wav2vec2	Test	0,098761	0,102150	0,003389	0,285255	0,282504	-0,002751
eGeMAPS	Validation	0,103167	0,105965	0,002798	0,185565	0,156003	-0,029562
eGeMAPS	Test	0,104837	0,106494	0,001656	0,188670	0,224846	0,036176

Lampiran 42 Tabel lengkap perbandingan per-trait WavLM official vs strict

Trait	Official MAE	Strict MAE	Δ MAE	Official R ²	Strict R ²	Δ R ²
extraversion	0,097651	0,099199	0,001549	0,339560	0,346724	0,007164
neuroticism	0,096976	0,101920	0,004944	0,355580	0,344391	-0,011189
agreeableness	0,095209	0,098583	0,003374	0,193316	0,194475	0,001159
conscientiousness	0,097242	0,102996	0,005754	0,350883	0,332724	-0,018160
openness	0,094807	0,096710	0,001903	0,325928	0,327196	0,001268

Lampiran 43 Konfigurasi Studi Optuna

Kunci	Nilai
study_name	wavlm_lora_strict_optuna_v2
model_name	microsoft/wavlm-base-plus

Kunci	Nilai
n_trials	50
selection_metric	S
patience	5
batch_size	40
split_source	/workspace/finetunev2/data/manifest_strict_vast.csv
pruner	<optuna.pruners._median.MedianPruner object at 0x76b93b31b020>
optuna_seed	42

Lampiran 44 Seluruh Trial Optuna WavLM

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L44_OptunaTrialWavLM**. Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>

Lampiran 45 Ringkasan final 10 runs WavLM+LoRA

Run ID	Seed	Best epoch	Stop epoch	best_val_S	MAE	RMSE	R ²	Acc
run_01_seed_042	42	24	29	0,901935	0,100190	0,126587	0,303067	0,899810
run_02_seed_052	52	20	25	0,901672	0,100338	0,126723	0,301679	0,899662
run_03_seed_062	62	21	26	0,901894	0,100174	0,126508	0,304086	0,899826
run_04_seed_072	72	23	28	0,901856	0,100350	0,126765	0,300896	0,899650
run_05_seed_082	82	24	29	0,901691	0,100302	0,126842	0,300112	0,899698
run_06_seed_092	92	19	24	0,901748	0,100288	0,126567	0,303232	0,899712
run_07_seed_102	102	17	22	0,901874	0,100253	0,126471	0,304404	0,899747
run_08_seed_112	112	17	22	0,901810	0,100405	0,126578	0,303256	0,899595
run_09_seed_122	122	29	34	0,901893	0,100296	0,126615	0,302902	0,899704
run_10_seed_132	132	29	34	0,901911	0,100157	0,126609	0,302933	0,899843

Lampiran 46 Metrik Ensemble

Metrik	Nilai
mae_mean	0,100132

Metrik	Nilai
rmse_mean	0,12645
r2_mean	0,304565
acc_mean	0,899868
S	0,899868
mae_extraversion	0,09908
rmse_extraversion	0,124683
r2_extraversion	0,347798
acc_extraversion	0,90092
mae_neuroticism	0,102329
rmse_neuroticism	0,129778
r2_neuroticism	0,336664
acc_neuroticism	0,897671
mae_agreeableness	0,098793
rmse_agreeableness	0,124364
r2_agreeableness	0,191499
acc_agreeableness	0,901207
mae_conscientiousness	0,103327
rmse_conscientiousness	0,130553
r2_conscientiousness	0,326877
acc_conscientiousness	0,896673
mae_openness	0,097131
rmse_openness	0,122873
r2_openness	0,319988
acc_openness	0,902869

Lampiran 47 Metrik Per-trait Best-val Run

Trait	MAE	RMSE	R ²	Acc	Korelasi	True mean	Pred mean	True std	Pred std
extraversion	0,098991	0,124656	0,348083	0,901009	0,590178	0,470627	0,468313	0,154389	0,091377
neuroticism	0,102272	0,129901	0,335410	0,897728	0,580374	0,513191	0,516724	0,159343	0,097343

Trait	MAE	RMSE	R ²	Acc	Korelasi	True mean	Pred mean	True std	Pred std
agreeableness	0,098856	0,124438	0,190541	0,901144	0,440674	0,543479	0,551693	0,138310	0,062504
conscientiousness	0,103458	0,130749	0,324850	0,896542	0,573416	0,518315	0,526814	0,159125	0,096531
openness	0,097374	0,123192	0,316450	0,902626	0,563878	0,560553	0,565540	0,149004	0,086952

Lampiran 48 Prediksi Test Strict Best-val Run WavLM

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L48 PredictBestRunWavLM**. Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>

Lampiran 49 Prediksi Test Strict Median Run WavLM

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L49 PredictMedianRunWavLM**. Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>

Lampiran 50 Prediksi Test Strict Ensemble WavLM

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L50 PredictEnsembleRunWavLM**. Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>


Lampiran 51 Ringkasan Diagnostik Loss per Run

Run ID	Seed	Best epoch	Stop epoch	Train loss best	Val loss best	Gap best	Final gap
run_01_seed_042	42	24	29	0,094404	0,098065	0,003661	0,004668
run_02_seed_052	52	20	25	0,094986	0,098328	0,003343	0,004674
run_03_seed_062	62	21	26	0,094607	0,098106	0,003500	0,004591
run_04_seed_072	72	23	28	0,094336	0,098144	0,003808	0,004350
run_05_seed_082	82	24	29	0,094085	0,098309	0,004224	0,004682
run_06_seed_092	92	19	24	0,094785	0,098252	0,003467	0,004612
run_07_seed_102	102	17	22	0,094730	0,098126	0,003397	0,004123
run_08_seed_112	112	17	22	0,095250	0,098190	0,002940	0,004386
run_09_seed_122	122	29	34	0,093732	0,098107	0,004375	0,005120
run_10_seed_132	132	29	34	0,093886	0,098089	0,004203	0,004544


Lampiran 52 Kurva Loss Agregat Berbasis Epoch WavLM

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L52 KurvaLossAgregatWavLM**. Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>


Lampiran 53 Grafik Gap Train-Validation Loss WavLM




Lampiran 54 Overlay Train-Validation Loss Seluruh Run WavLM




Lampiran 55 Bin Analysis Prediksi vs Aktual WavLM



Lampiran 56 Residual Boxplot Best-val WavLM



Lampiran 57 True-vs-Pred Boxplot Best-val WavLM



Lampiran 58 Konfigurasi Studi Optuna HuBERT

Item	Nilai
study_name	hubert_lora_strict_optuna
model_name	facebook/hubert-base-ls960
n_trials	50
selection_metric	S
patience	5
batch_size	40
split_source	/workspace/hubert_finetune/data/manifest_strict_vast.csv
optuna_seed	42
note	Optuna default sampler is used to mirror the WavLM notebook.
pruner	MedianPruner, n_startup_trials=10, n_warmup_steps=8, interval_steps=1, n_min_trials=5

Lampiran 59 Seluruh Trial Optuna HuBERT

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet [L59_OptunaTrialHuBERT](#). Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>

Lampiran 60 Ringkasan Best Trial dan Konfigurasi Terbaik HuBERT

Lampiran ini memuat nomor trial terbaik, nilai validation S, serta konfigurasi hiperparameter terbaik yang dipakai sebagai dasar final runs HuBERT.

Item	Nilai
best trial number	41
best validation S	0,902964182198
learning_rate	0,000183232
r	8
lora_alpha	64
lora_dropout	0,050000000
weight_decay	0,019905951
warmup_ratio	0,000000000

Lampiran 61 Status Trial Optuna HuBERT

Status trial	Jumlah
TrialState.COMPLETE	30
TrialState.PRUNED	20

Lampiran 62 Audit Strict Split HuBERT

Pemeriksaan	Nilai	Status	Detail
required_columns_missing	0	PASS	-
split_counts	train 5.936, validation 1.999, test 2.039	PASS	-

audio_exists	9974/9974	PASS	-
label_nan_count	0	PASS	-
clip_id_unique	True	PASS	-
group_id_overlap	{"train_val": 0, "train_test": 0, "val_test": 0}	PASS	-
clip_id_overlap	{"train_val": 0, "train_test": 0, "val_test": 0}	PASS	-

Lampiran 63 Trial Complete Terbaik Optuna HuBERT

Trial	S validation	learning_rate	r	lora_alpha	dropout	weight_decay	warmup
41	0,902964	0,000183232	8	64	0,05	0,019905951	0
18	0,902953	0,000230031	8	32	0,05	0,003672503	0
42	0,902868	0,000174971	8	64	0,05	0,018159266	0
31	0,902848	0,000174166	8	64	0,05	0,009797142	0
24	0,902819	0,000218010	8	64	0,05	0,001800049	0

Lampiran 64 Parameter Importance Optuna HuBERT

Parameter	Importance
lora_dropout	0,564348
learning_rate	0,214142
r	0,098492
warmup_ratio	0,088524
lora_alpha	0,020342
weight_decay	0,014152

Lampiran 65 Final Runs HuBERT+LoRA

Run	Seed	Best epoch	Stop epoch	best_val_S	MAE	RMSE	R2	Acc
run_01_seed_042	42	5	10	0,902869	0,099161	0,125301	0,316773	0,900839
run_02_seed_052	52	3	8	0,902253	0,098853	0,124562	0,325443	0,901147
run_03_seed_062	62	5	10	0,901995	0,098381	0,124523	0,325869	0,901619
run_04_seed_072	72	5	10	0,902983	0,098695	0,124714	0,323789	0,901305
run_05_seed_082	82	5	10	0,902216	0,099013	0,125023	0,320394	0,900987
run_06_seed_092	92	8	13	0,901653	0,099429	0,125646	0,313960	0,900571
run_07_seed_102	102	6	11	0,902435	0,099086	0,125447	0,315698	0,900914
run_08_seed_112	112	6	11	0,901680	0,099328	0,126286	0,306610	0,900672
run_09_seed_122	122	7	12	0,902119	0,098945	0,125313	0,317059	0,901055
run_10_seed_132	132	6	11	0,900836	0,099719	0,126193	0,307347	0,900281

Lampiran 66 Statistik Ringkas Final Runs HuBERT+LoRA

Metrik	n	Mean	Std	Min	Median	Max	CI95 half-width
best_val_S	10	0,902104	0,000624	0,900836	0,902167	0,902983	0,000387
test_MAE_mean	10	0,099061	0,000381	0,098381	0,099049	0,099719	0,000236
test_RMSE_mean	10	0,125301	0,000622	0,124523	0,125307	0,126286	0,000385
test_R2_mean	10	0,317294	0,006822	0,306610	0,316916	0,325869	0,004228
test_Acc_mean	10	0,900939	0,000381	0,900281	0,900951	0,901619	0,000236

Lampiran 67 Metrik Per-trait Best-Val Run HuBERT

Trait	MAE	RMSE	R2	Acc
extraversion	0,097734	0,123318	0,361995	0,902266
neuroticism	0,100278	0,126970	0,365063	0,899722

agreeableness	0,096105	0,121851	0,223842	0,903895
conscientiousness	0,102117	0,129485	0,337837	0,897883
openness	0,097242	0,121946	0,330209	0,902758
mean	0,098695	0,124714	0,323789	0,901305

Lampiran 68 Metrik Per-trait Median Run HuBERT

Trait	MAE	RMSE	R2	Acc
extraversion	0,097453	0,122692	0,368459	0,902547
neuroticism	0,099715	0,126903	0,365732	0,900285
agreeableness	0,096847	0,122358	0,217368	0,903153
conscientiousness	0,103734	0,131508	0,316986	0,896266
openness	0,097317	0,121653	0,333427	0,902683
mean	0,099013	0,125023	0,320394	0,900987

Lampiran 69 Metrik Per-trait Ensemble HuBERT

Trait	MAE	RMSE	R2	Acc
extraversion	0,096141	0,121508	0,380595	0,903859
neuroticism	0,098410	0,125332	0,381333	0,901590
agreeableness	0,095974	0,121496	0,228353	0,904026
conscientiousness	0,101675	0,129140	0,341369	0,898325
openness	0,096287	0,120725	0,343558	0,903713
mean	0,097698	0,123640	0,335042	0,902302

Lampiran 70 Prediksi Test Strict Best-val Run HuBERT

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L70 PredictBestRunHuBERT**. Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>

Lampiran 71 Prediksi Test Strict Median Run HuBERT

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L71 PredictMedianRunHuBERT**. Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>

Lampiran 72 Prediksi Test Strict Ensemble HuBERT

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet **L72 PredictEnsembleRunHuBERT**. Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>

Lampiran 73 Diagnostik Train-Validation Gap HuBERT

Run	Seed	Best epoch	Stop epoch	Gap best	Final gap	Diagnosis
run_01_seed_042	42	5	10	0,003743	0,012013	tidak menunjukkan overfitting berat
run_02_seed_052	52	3	8	0,000984	0,010232	tidak menunjukkan overfitting berat
run_03_seed_062	62	5	10	0,004979	0,014680	tidak menunjukkan overfitting berat
run_04_seed_072	72	5	10	0,003388	0,010803	tidak menunjukkan overfitting berat
run_05_seed_082	82	5	10	0,004446	0,013990	tidak menunjukkan overfitting berat
run_06_seed_092	92	8	13	0,009184	0,018424	indikasi gap ringan; perlu dibaca

						bersama kurva
run_07_seed_102	102	6	11	0,006688	0,015002	indikasi gap ringan; perlu dibaca bersama kurva
run_08_seed_112	112	6	11	0,006175	0,018345	indikasi gap ringan; perlu dibaca bersama kurva
run_09_seed_122	122	7	12	0,007741	0,019434	indikasi gap ringan; perlu dibaca bersama kurva
run_10_seed_132	132	6	11	0,008377	0,017912	indikasi gap ringan; perlu dibaca bersama kurva

Lampiran 74 Ringkasan Regression-to-the-Mean HuBERT

Trait	True mean	True std	Pred mean	Pred std	PredVar/TrueVar	Corr	MAE	RMSE	R2
extraversion	0,470627	0,154389	0,453212	0,096614	0,391606	0,612291	0,097734	0,123318	0,361995
neuroticism	0,513191	0,159343	0,501640	0,093511	0,344394	0,608938	0,100278	0,126970	0,365063
agreeableness	0,543479	0,138310	0,546682	0,072231	0,272738	0,475944	0,096105	0,121851	0,223842
conscientiousness	0,518315	0,159125	0,523871	0,099240	0,388951	0,583658	0,102117	0,129485	0,337837
openness	0,560553	0,149004	0,550612	0,091485	0,376969	0,579523	0,097242	0,121946	0,330209

Lampiran 75 Prediksi dengan Error Terbesar HuBERT

clip_id	MAE sampel	Err E	Err N	Err A	Err C	Err O
j3jdT1V-DeI.004	0,420953	0,454257	0,433105	0,426473	0,389867	0,401063

h9jIdLBaMEo.002	0,377973	0,387312	0,426839	0,265550	0,277455	0,532709
Jv2lyDcOmEM.002	0,365577	0,303807	0,354736	0,349325	0,383040	0,436979
j3jdT1V-DeI.005	0,363483	0,311482	0,412598	0,337579	0,415371	0,340386
f7togdqeEoo.001	0,357963	0,288494	0,341634	0,450898	0,346898	0,361892
f7togdqeEoo.004	0,345329	0,262196	0,322021	0,435032	0,335610	0,371788
dB2XYhvqUBU.000	0,342666	0,279224	0,400798	0,255283	0,428123	0,349902
VoPuhcQc_mg.002	0,318432	0,227986	0,271810	0,417937	0,386766	0,287663
TNtcyfM9jak.002	0,316424	0,359188	0,326823	0,368121	0,390160	0,137826
h9jIdLBaMEo.000	0,313641	0,288405	0,375651	0,228441	0,339931	0,335775


Lampiran 76 Prediksi dengan Error Terkecil HuBERT

clip_id	MAE sampel	Err E	Err N	Err A	Err C	Err O
Y8gv_ZK3w4A.001	0,012008	0,029742	0,018636	0,007195	0,003015	0,001454
a84s1DYag-I.004	0,014008	0,021763	0,004883	0,008440	0,016379	0,018576
8OckVmEZ8X8.002	0,016150	0,024759	0,029948	0,020908	0,002610	0,002528
cvHqtadNJDo.004	0,016848	0,023912	0,026204	0,002592	0,003925	0,027604
0FVu7VKIg2s.000	0,017190	0,004205	0,051595	0,018925	0,010249	0,000977
ygUEI08LgcM.003	0,018572	0,002868	0,022135	0,009411	0,039010	0,019434
oGa05H9UXxU.004	0,018788	0,002836	0,000407	0,018681	0,066288	0,005729
PRcOtefm17s.003	0,018824	0,026842	0,003906	0,002109	0,037252	0,024013
a84s1DYag-I.001	0,018830	0,031656	0,036051	0,009878	0,015947	0,000619
EvZ0esZgPK4.005	0,020230	0,023198	0,058431	0,014992	0,003171	0,001356


Lampiran 77 Kurva Loss Agregat Berbasis Epoch HuBERT

Lampiran ini disediakan dalam berkas spreadsheet pendukung pada sheet [L77 KurvaLossAgregatHuBERT](#). Untuk memudahkan akses, berkas pendukung tersebut juga disediakan melalui tautan berikut: <https://its.id/m/LampiranTAQIQI>


Lampiran 78 Grafik Gap Train-Validation Loss HuBERT




Lampiran 79 Overlay Train-Validation Loss Seluruh Run HuBERT



Lampiran 80 Bin Analysis Prediksi vs Aktual HuBERT



Lampiran 81 Residual Boxplot Best-val HuBERT



Halaman ini sengaja dikosongkan.

BIODATA PENULIS



Penulis dilahirkan di Kudus, 10 Januari 2005, merupakan anak pertama dari 2 bersaudara. Penulis telah menempuh pendidikan formal yaitu di TK Taman Ceria, SDN 1 Gondosari, SMPN 1 Kudus dan SMAN 1 Kudus. Setelah lulus dari SMAN tahun 2022, Penulis mengikuti SBMPTN dan diterima di Departemen Teknik Informatika FTEIC - ITS pada tahun 2022 dan terdaftar dengan NRP 5025221158.

Selama masa perkuliahan, Penulis aktif mengembangkan kompetensi teknis dan profesional, khususnya pada bidang pengembangan website sebagai *front-end developer*. Penulis menguasai JavaScript, TypeScript, dan PHP dengan pemanfaatan framework seperti Next.js dan Laravel, serta berpengalaman dalam membangun antarmuka yang responsif, melakukan integrasi API, dan melakukan *slicing* berdasarkan *design system* agar komponen bersifat konsisten dan *reusable*. Selain itu, Penulis memiliki kemampuan pendukung di bidang UI/UX dan desain grafis menggunakan Figma dan Adobe Photoshop untuk menunjang kualitas antarmuka dan komunikasi visual produk.

Dalam pengalaman praktik, Penulis pernah terlibat sebagai Full-Stack Developer pada proyek penelitian dosen ITS melalui pengembangan aplikasi internal berbasis AI (Aplikasi Atomics). Penulis juga memiliki pengalaman sebagai Front-End Developer pada proyek pengembangan website Design Simplified, serta sebagai Front-End Developer pada pengembangan website marketplace pupuk di PT. Bumi Rekayasa Persada, dengan fokus pada implementasi antarmuka, integrasi data dari backend, dan penyusunan komponen UI yang rapi serta mudah dipelihara. Selain pengalaman kerja/proyek, Penulis aktif berkontribusi dalam kegiatan kepanitiaan dan organisasi, antara lain sebagai Expert Front-End Developer ITS EXPO 2024, Expert Staff UI/UX SCHEMATICS 2024, serta memimpin pelaksanaan pemilu internal HMTC sebagai Ketua KPU & PPU HMTC 2025.